

PathRAG: 그래프 기반 검색 증강 생성 가지치기 관계 경로

보유 첸1, 지리루이 귀2, 양지단1, 추안시1 첸위루오1, 준택 첸1, 리우 정hao3, 양첸1

1베이징 우정통신대학교, 중국

2홍콩대학교, 중국

3중국 동북대학교

chenbys4@bupt.edu.cn, yangcheng@bupt.edu.cn

추상적인

검색 증강 생성(RAG)은 외부 데이터베이스에서 지식을 검색하여 대규모 언어 모델(LLM)의 응답 품질을 향상시킵니다. 일반적인 RAG 접근 방식은 텍스트 데이터베이스를 청크로 분할하고 이를 구성합니다.

효율적인 검색을 위해 평면 구조로 되어 있습니다. 더 나은 정보 수집을 위해 내재적 의존성과 구조화된 관계 텍스트 데이터베이스에서 연구자들은 텍스트 정보를 그래프 기반 RAG라고 알려진 인덱싱 그래프로 구성할 것을 제안합니다. 그러나 우리는 현재 그래프 기반 방식의 한계에 대해 주장합니다. RAG 방법의 핵심은 검색된 정보의 불충분함이 아니라 중복성에 있다. 더욱이, 기존 방법들은

검색된 정보를 구성하기 위해 평면 구조를 사용합니다. 프롭프트로 인해 최적의 성능을 발휘하지 못합니다. 이러한 한계를 극복하기 위해 PathRAG를 제안합니다. PathRAG는 다음을 검색합니다.

인덱싱 그래프의 주요 관계 경로 및 변환 이러한 경로를 텍스트 형식으로 변환하여 LLM(학습 관리 방법)을 안내합니다. 구체적으로 PathRAG는 중복 정보를 효과적으로 줄입니다.

흐름 기반 가지치기를 통해 LLM이 생성되도록 안내합니다. 경로 기반 프롭프트를 통해 더욱 논리적이고 일관성 있는 응답을 얻을 수 있습니다. 실험 결과는 PathRAG가 일관되게 이러한 결과를 보여준다는 것을 나타냅니다. 6개의 데이터 세트에서 최첨단 기준 모델보다 우수한 성능을 보입니다. 다섯 가지 평가 기준.

코드 — <https://github.com/BUPT-GAMMA/PathRAG>

소개

검색 증강 생성(RAG)은 대규모 언어 모델(LLM)이 외부 데이터베이스에서 최신 또는 도메인별 지식에 접근할 수 있도록 하여 성능을 향상시킵니다.

추가 교육 없이 응답 품질이 향상됨 (Gao et al. 2023a,b; Fan et al. 2024; Procko and Ochoa 2024; Mavromatis and Karypis 2024; Su et al. 2025; Zhang, Feng, and (You 2025)). 대부분의 접근 방식은 텍스트 데이터베이스를 다음과 같이 나눕니다. 데이터를 청크로 나누고, 효율적인 검색을 용이하게 하기 위해 평면 구조로 구성합니다(Yepes et al. 2024; Lyu et al. 2025).

내재된 의존성과 구조를 더 잘 파악하기 위해 데이터베이스의 텍스트 간 관계를 파악하기 위해 연구자들은 그래프 기반 RAG(Edge et al. 2024; Guo et al.)를 도입했습니다. 텍스트 정보를 인덱싱 그래프로 구성하는 도구(2024)입니다. 이 그래프에서 노드는 추출된 엔티티를 나타냅니다.

†교신 저자.

저작권 © 2026, 인공지능학 발전 협회
인공지능(www.aaai.org). 모든 권리 보유.




그림 1: 서로 다른 그래프 기반 RAG 비교

방법론으로는 GraphRAG(Edge et al. 2024)는 특정 커뮤니티 내의 모든 정보를 활용하는 반면, LightRAG(Guo)는 et al. (2024)은 쿼리 관련 노드의 모든 인접 노드를 사용합니다. 이와 대조적으로, 제안된 PathRAG는 특정 노드에 초점을 맞춥니다. 쿼리 관련 노드 간의 주요 관계 경로에서 노이즈를 완화하고 토큰 소비를 줄입니다.

텍스트에서 가져온 것이고, 모서리는 그 사이의 관계를 나타냅니다. 이러한 개체들. 전통적인 RAG(Liu et al. 2021; Yasunaga et al. 2021; Gao et al. 2022)는 일반적으로 질문에 초점을 맞춥니다. 그 질문은 특정 장소에 대한 지역 정보로 답할 수 있습니다. 엔티티 또는 관계를 대상으로 합니다. 이와 대조적으로 그래프 기반 RAG는 대상을 지정합니다. 글로벌 차원의 질문들, 즉 다양한 분야의 정보가 필요한 질문들에 대해 데이터베이스를 사용하여 요약과 유사한 응답을 생성합니다. 예를 들어, GraphRAG(Edge et al. 2024)는 먼저 그래프에 커뮤니티 탐지 기능을 적용한 후, 각 커뮤니티의 정보를 점진적으로 요약합니다. 최종 결과가 생성됩니다.

가장 검색어와 관련성이 높은 커뮤니티를 기반으로 합니다. LightRAG (Guo et al. 2024)는 지역 키워드와 전역 키워드를 모두 추출합니다. 입력 쿼리로부터 관련 노드와 에지를 검색합니다. 이러한 키워드를 사용하여, 에고 네트워크 정보는 다음과 같습니다. 검색된 노드는 검색 결과로 사용됩니다.

그러나 우리는 기존의 그래프 기반 RAG 방법에서 고려되는 정보가 종종 중복된다고 주장합니다. 노이즈를 유발하고 성능을 저하시키며 토큰 소모를 증가시킬 수 있습니다. GraphRAG 방식은 특정 커뮤니티 내의 노드와 엣지에서 얻은 모든 정보를 활용합니다. 마찬가지로 LightRAG는 바로 인접한 것들을 검색합니다. 쿼리와 관련된 노드를 사용하여 답변을 생성합니다. 이러한 방법에서 검색되는 중복 정보는 노이즈로 작용할 수 있습니다.

후세대에 부정적인 영향을 미칩니다. 더욱이, 둘 다 검색된 정보를 프롬프트에 구성하기 위해 평면적인 구조를 채택하는 방법들이 있습니다. 예를 들어, 텍스트를 직접 연결하는 방식입니다. 검색된 모든 노드와 에지에 대한 정보가 포함되어 있어 논리적 타당성과 일관성이 최적화되지 않은 답변이 도출됩니다.

위의 한계를 극복하기 위해 PathRAG를 제안합니다. 검색된 노드들 사이에서 핵심 경로 검색을 수행합니다. 그리고 이러한 경로들을 LLM 프롬프트에 사용할 수 있도록 텍스트 형식으로 변환합니다. 우리는 검색된 경로들 간의 주요 관계 경로에 초점을 맞춥니다. 노드를 사용하여 노이즈를 줄이고 토큰 소모를 감소시킵니다. 구체적으로, 먼저 쿼리의 키워드를 기반으로 인덱싱 그래프에서 관련 노드를 검색합니다. 그런 다음 우리는 거리를 고려한 흐름 기반 가지치기 알고리즘을 설계합니다.

각 요소 간의 주요 관계 경로를 파악하기 위한 인식 검색된 노드 쌍. 가지치기 알고리즘은 낮은 성능을 자랑합니다. 시간 복잡도를 계산할 수 있으며, 각 항목에 신뢰도 점수를 부여할 수 있습니다. 검색된 경로를 얻은 후, 순차적으로 연결합니다. 각 경로와 함께 노드 및 에지 정보가 텍스트로 표시됩니다. 관계적 경로. LLM의 "중간에서 길을 잃다" 문제(Liu et al. 2024)를 고려하여 텍스트 경로를 배치합니다.

신뢰도 점수가 높은 순서대로 프롬프트에 입력하세요. 더 나은 답변 생성을 위해. 종합적으로 평가하기 위해 PathRAG의 효과를 검증하기 위해 벤치마크를 확장합니다. 이전 연구(Guo et al. 2024)의 데이터 세트와 4개의 추가 데이터 세트(Wang et al. 2022; Chen et al. 2022; Qian et al.)를 사용했습니다. 2024) 다양한 도메인에서 가져온 데이터를 사용했습니다. 실험 결과는 PathRAG가 5가지 평가 차원 모두에서 최첨단 기준 모델보다 일관되게 우수한 성능을 보임을 입증합니다. 특히 GraphRAG와 비교했을 때 PathRAG는

각각 평균 59.93%와 57.09%의 승률을 달성했습니다. 본 연구의 주요 기여는 다음과 같습니다.

- 우리는 현재 그래프 기반 방식의 한계를 강조합니다. RAG 방법의 핵심은 검색된 정보의 불충분함이 아니라 중복성에 있다. 더욱이, 이전의 이 방법들은 검색된 정보를 구성하기 위해 평면적인 구조를 사용합니다. 프롬프트 내에서 발생하여 최적의 성능을 발휘하지 못합니다.
- 우리는 킬 효율적으로 검색하는 PathRAG를 제안합니다. 흐름 기반 인덱싱 그래프의 관계형 경로 가지치기를 통해 경로 기반으로 효과적으로 답변을 생성합니다. LLM 프롬프트.
- PathRAG는 여러 분야에서 최첨단 기준선보다 우수한 성능을 보입니다. 6개의 데이터 세트와 5개의 평가 차원. 광범위한 실험을 통해 PathRAG의 설계가 더욱 검증되었습니다.

관련 작업

텍스트 기반 RAG. 텍스트 품질 향상을 위해 (Fang et al. 2024; Xu et al. 2024; Zhu et al. 2024) 및 환각 효과를 완화하기 위해(Lewis et al. 2020; Guu et al. 2020), 외부 데이터베이스를 활용하여 검색 증강 생성(RAG)이 대규모 언어 모델(LLM)에 널리 사용되고 있습니다.

이러한 데이터베이스는 주로 텍스트 형태로 데이터를 저장하며, LLM이 활용할 수 있는 방대한 양의 도메인 지식을 포함하고 있습니다. 직접 검색합니다. 우리는 이러한 시스템을 텍스트 기반 시스템이라고 부릅니다. RAG. 다양한 검색 메커니즘 기반(Fan et al. 2024년) 텍스트 기반 RAG는 크게 두 가지로 분류할 수 있다. 범주: 희소 벡터 검색 (Alon et al. 2022; Schick) 외. 2023년; Jianget al. 2023년; Cheng et al. 2023) 밀도가 높은 벡터 검색 (Lewis et al. 2020; Hofstadter et al. 2023; Li et al. 2024; Zhang et al. 2024). 희소 벡터 검색

일반적으로 각 항목에서 가장 대표적인 단어를 식별합니다. 단어 빈도를 기준으로 텍스트를 분할하고 관련 텍스트를 검색합니다. 키워드 일치를 기반으로 하는 특정 쿼리에 대해 검색합니다. 이와 대조적으로, 밀집 벡터 검색은 어휘적 문제와 같은 다양한 문제를 다룹니다. 쿼리 용어와 동의어를 모두 인코딩하여 불일치 및 동의어를 찾습니다. 텍스트를 벡터 임베딩으로 변환한 다음 관련 정보를 검색합니다. 이러한 임베딩 간의 유사성을 기반으로 콘텐츠를 생성합니다. 그러나 대부분의 텍스트 기반 RAG 방법은 텍스트 세그먼트를 평면적으로 구성하여 청크 간의 필수적인 관계(예: 문맥적 의존성)를 포착하지 못합니다.

LLM에서 생성된 응답의 품질을 제한함(Edge et al.) 2024; Guo et al. 2024).

KG-RAG. 텍스트 데이터베이스 외에도 연구자들은 지식 그래프(KG)에서 정보를 검색하는 방법을 제안해 왔다. KG-RAG로 알려져 있음(Yasunaga et al. 2021; Gao et al. 2022; Li, Miao, and Li 2024; Procko and Ochoa 2024; He et al. 2025). 이러한 방법은 기존 KG를 활용할 수 있습니다(Wen, Wang, 및 Sun 2024; Dehghan et al. 2024) 또는 이들의 최적화된 버전(Fang, Meng, and Macdonald 2024; Panda et al. 2024) LLM이 관련 엔티티에 대한 정보를 검색할 수 있도록 합니다.

그리고 그 관계. 구체적으로, KG-RAG 방법은 일반적으로 KG에서 로컬 부분 그래프를 추출합니다(Bordes et al.). 2015; Talmor 및 Berant 2018; Gu et al. 2021) 등 쿼리에서 언급된 엔티티의 바로 인접한 엔티티. 하지만 대부분의 KG-RAG 방법은 단일 개체 또는 관계로 답변할 수 있는 질문을 다루는 데 중점을 둡니다. KG(Joshi et al. 2017; Yang et al. 2018; Kwiatkowski) et al. 2019; Ho et al. 2020)은 연구 범위를 좁혔습니다. 적용 가능성.

그래프 기반 RAG. 미리 구성된 모델을 활용하는 대신 KG, 그래프 기반 RAG(Edge et al. 2024; Guo et al. 2024) 일반적으로 텍스트 데이터베이스를 텍스트 관련 그래프로 구성합니다. 또한 데이터베이스의 여러 부분에서 정보를 필요로 하는 전역 수준의 작업에 초점을 맞춥니다. 그래프 건설 과정에는 종종 다음으로부터 개체를 추출하는 작업이 포함됩니다. 텍스트를 분석하고 이러한 요소들 간의 관계를 파악합니다. 또한, 맥락 정보는 설명 텍스트로 포함됩니다. 텍스트를 그래프로 변환하는 과정에서 정보 손실을 최소화하기 위해 변환. GraphRAG(Edge et al. 2024)는 먼저 그래프에 커뮤니티 탐지 알고리즘을 적용한 다음 하위 커뮤니티의 정보를 점진적으로 집계합니다.

상위 수준 커뮤니티 정보를 형성합니다. LightRAG(귀 et al. (2024)은 검색 프로세스 속도를 높이기 위해 이중 단계 검색 프레임워크를 채택합니다. 첫째, 로컬 및 질문에서 전역 키워드를 추출합니다. 그런 다음 이러한 키워드를 사용하여 관련 노드와 엣지를 검색하고 처리합니다. 검색된 노드의 에고 네트워크 정보를 최종 정보로 사용합니다. 검색 결과입니다. 이 접근 방식은 검색을 단순화하고 전역 수준의 작업을 효과적으로 처리합니다. 그러나 검색된 정보는 관련 노드의 모든 인접 노드를 포함합니다.

이는 답변의 질을 떨어뜨리는 노이즈를 유발할 수 있습니다. 최근 연구인 MiniRAG(Fan et al. 2025)에서도 경로를 고려합니다. 검색을 돕기 위한 정보입니다. 하지만 그들은 정보로 답할 수 있는 질문들을 다루는 데 초점을 맞춥니다. 특정 노드를 대상으로 쿼리 관련 경로 간의 연결을 탐색합니다. 그리고 KG 추론과 같은 답변 관련 노드(Yasunaga et al.) 2021; Liu et al. 2021; Tianet al. 2022).

예비 단계

이 섹션에서는 워크플로우를 소개하고 공식화하겠습니다.

그래프 기반 RAG 시스템의 경우.

텍스트 덩어리를 순서가 없는 컬렉션으로 저장하는 대신, 그래프 기반 RAG는 텍스트 데이터베이스를 자동으로 구조화합니다. 인덱싱 그래프 로 변환 하는 것을 전처리 단계로 수행합니다. 주어진 경우 텍스트 데이터베이스, 엔티티 및 그 내부의 상호 관계 텍스트 콘텐츠는 LLM을 통해 식별되며, 이를 이용하여 노드 집합 V와 에지 집합 E를 구성합니다. 구체적으로, 각 노드는 $v \in V$ 는 식별자 k_v 를 가진 별개의 개체를 나타냅니다 (예: 엔티티 이름) 및 텍스트 덩어리 t_v (예: 관련 텍스트) 각 에지 $e \in E$ 는 설명적인 텍스트 덩어리 t_e 를 가진 엔티티 쌍 간의 관계를 나타냅니다.

관계적 맥락을 풍부하게 하기 위해, 우리는 인덱싱 그래프를 다음과 같이 나타냅니다. $G = (V, E, KV, T)$ 로 표현되며, 여기서 KV는 집합을 나타냅니다. 노드 식별자이며 T는 텍스트 덩어리들의 모음입니다.

인덱싱 그래프.

주어진 질의 q 에 대해 그래프 기반 검색기는 인덱싱 그래프에서 관련 노드와 에지를 추출합니다. 그런 다음 텍스트 검색을 수행합니다. 검색된 요소들의 덩어리가 쿼리 q 와 통합됩니다. LLM 생성기를 통해 답을 얻으세요. 위의 과정을 다음과 같이 간략화할 수 있습니다.

$$A(q, G) = F \circ M(q; R(q, G)), \tag{1}$$

여기서 A는 검색 결과를 포함하는 증강된 생성을 나타내고, R은 그래프 기반 검색기를 의미하며, M과 F는 각각 프롬프트 템플릿과 LLM 생성기를 나타냅니다. 본 논문에서는 주로 보다 효율적인 설계를 목표로 합니다.

효과적인 그래프 지향 검색기와 자원 프롬프트 그래프 기반 RAG를 더욱 효과적으로 구현하기 위한 템플릿입니다.

방법론

이 섹션에서는 경로 기반 검색기와 맞춤형 프롬프트를 갖춘 새로운 그래프 기반 RAG 프레임워크를 제안합니다. 템플릿은 공식적으로 PathRAG로 지정되어 있습니다. 그림에서 볼 수 있듯이 그림 2에서 제안된 프레임워크는 인덱싱을 기반으로 작동합니다. 그래프는 노드 검색, 경로 생성, 세 가지 순차적인 단계를 거쳐 생성됩니다. 검색 및 답변 생성.

노드 검색

이 단계에서는 입력 쿼리에서 키워드를 식별합니다. LLM을 사용하여 인덱싱 그래프에서 관련 노드를 추출합니다. 쿼리 q 가 주어지면 LLM을 이용하여 쿼리 텍스트에서 키워드를 추출합니다. 쿼리 q 에서 추출된 키워드 모음을 K_q 라고 합니다.

추출된 키워드에 대해 밀집 벡터 매칭이 사용됩니다. 인덱싱 그래프 G 에서 관련 노드를 검색합니다. 밀집된 그래프에서 벡터 매칭, 키워드와 벡터 간의 관련성 노드 간 유사도는 의미 임베딩 공간에서의 유사도를 기반으로 계산되며, 일반적으로 코사인 유사도가 사용됩니다. 본 연구에서는 이 방법을 채택합니다. 구체적으로, 먼저 두 가지 모두를 인코딩합니다. 노드 식별자와 의미론적 임베딩 모델 $f: K_q \cup KV \rightarrow X_q \cup XV$ 를 사용하여 추출된 키워드, 여가서 $XV = \{x_v\}_{v \in V}$ 는 노드 식별자의 임베딩을 나타냅니다. $|K_q|$ fiers, 그리고 $X_q = \{x_q, i\}_{i=1}^n$ 는 추출된 키워드의 임베딩을 나타냅니다. 위에서 얻은 임베딩을 기반으로, 그런 다음 X_q 를 순화하여 가장 관련성이 높은 노드를 검색합니다. XV 중에서 임베딩 유사성을 사용하여 미리 정의된 값까지

노드 수 N에 도달했습니다. 검색된 노드의 결과 부분집합을 $V_q \subseteq V$ 로 표시합니다.

경로 검색

이 하위 섹션에서는 경로 검색 모듈을 소개합니다. 관계형 경로 형태로 텍스트 덩어리를 집계합니다. 검색된 노드 간의 연결을 포착합니다.

서로 다른 두 개의 검색된 노드 $v_{start}, v_{end} \in V_q$ 가 주어졌을 때, 그들 사이에는 도달 가능한 경로가 여러 개 있을 수 있습니다. 모든 경로가 그런 것은 아니기 때문입니다. 해당 경로들은 작업에 도움이 되지만, 추가적인 개선이 필요합니다. 효과성과 효율성을 모두 향상시키기 위해. 다음에서 영감을 받았습니다. 자원 할당 전략(Lu and Zhou 2011; Lin et al. 2015)을 바탕으로, 본 논문에서는 핵심 경로를 추출하기 위해 거리 인식을 고려한 흐름 기반 가치치기 알고리즘을 제안합니다.

형식적으로, v_i 를 가리키는 노드들의 집합을 다음과 같이 나타냅니다. v_i 가 가리키는 노드를 각각 $N(\cdot, v_i)$ 와 $N(v_i, \cdot)$ 로 정의합니다. 노드 v_i 의 리소스를 $S(v_i)$ 로 정의 합니다.

$S(v_{start}) = 1$ 로 설정하고 다른 리소스는 0으로 초기화한 후 이웃을 통해 리소스를 전파합니다. v_i 로 흐르는 리소스는 다음과 같이 정의됩니다.

$$S(v_i) = \frac{\alpha \cdot S(v_j)}{\sum_{v_j \in N(\cdot, v_i)} |N(v_j, \cdot)|}, \tag{2}$$

여기서 α 는 에지를 따라 정보가 전파되는 감쇠율을 나타냅니다. 가까울수록 정보가 전파되는 감쇠율이 높아진다는 가정에 근거합니다. 인덱싱 그래프에 두 노드가 있을 때, 두 노드 간의 연결이 강할수록 검색 엔진이 거리를 인지할 수 있도록 페널티 메커니즘을 도입했습니다. 우리의 접근 방식은 경로를 엄격하게 정렬하는 방식과는 다르다는 점을 강조하는 것이 중요합니다.

제한된 수의 흐름. 상세한 비교 실험 자세한 내용은 후속 섹션에서 다루겠습니다.

특히, 붕괴 페널티와 이웃 할당으로 인해, 초기 노드에서 멀리 떨어진 노드에는 무시할 수 있을 정도의 자원이 할당됩니다. 따라서 조기 종료 기능을 도입합니다. 경로를 미리 가치치기하는 전략

$$\frac{S(v_i)}{|N(v_i, \cdot)|} < \theta, \tag{3}$$

여기서 θ 는 가치치기 임계값입니다. 이는 알고리즘이 최소한의 기여만 하는 노드에 대해 조기에 종료되도록 합니다. 전체 전파량을 나타냅니다. 효율성을 고려하여 업데이트합니다. 노드의 리소스는 최대 한 번만 사용할 수 있습니다.

각 경로를 순서가 지정된 시퀀스 $P = v_0 \xrightarrow{e_0} \dots \xrightarrow{e_i} v_i \xrightarrow{e_{i+1}} \dots \xrightarrow{e_n} v_n = (VP, EP)$ 으로 나타냅니다. 여기서 v_i 와 e_i 는 i 번째를 나타냅니다. 노드와 방향 간선, 그리고 VP와 EP는 집합을 나타냅니다. 경로 P의 노드와 간선입니다. 각 경로에 대해 $P = (VP, EP)$ 로 자원의 평균값을 계산합니다. 신뢰도 측정 기준으로서 가장자리를 통해 흐르는 것, 이는 다음과 같이 표현될 수 있습니다:

$$S(P) = \frac{1}{|EP|} \sum_{v_i \in VP} S(v_i), \tag{4}$$

여기서 $|EP|$ 는 경로에 있는 간선의 개수입니다. 그런 다음 정렬합니다. 이러한 경로는 신뢰도 $S(P)$ 를 기반으로 하며 다음만 유지합니다. 이 노드 쌍에 대한 가장 신뢰할 수 있는 관계 경로입니다. 이러한 경로는 다음과 같습니다. 경로-신뢰도 쌍($P, S(P)$) 형태로 전역 후보 풀에 추가됩니다. 위 과정을 반복합니다.




그림 2: 제안하는 PathRAG의 전체 프레임워크는 세 가지 주요 단계로 구성됩니다. 1) 노드 검색 단계: 쿼리의 키워드를 기반으로 인덱싱 그래프에서 관련 노드를 검색합니다. 2) 경로 검색 단계: 검색된 각 노드 쌍 간의 핵심 관계 경로를 추출하기 위해 흐름 기반 가지치기 알고리즘을 설계하고, 신뢰도 점수가 가장 높은 경로를 검색합니다. 3) 답변 생성 단계: 검색된 경로를 신뢰도 점수가 높은 순서대로 프롬프트에 배치하고, 최종적으로 LLM에 입력하여 답변을 생성합니다.

각기 다른 노드 쌍을 선택하여 궁극적으로 모든 후보 경로를 얻습니다. 그런 다음 후보 경로 풀에서 가장 신뢰할 수 있는 상위 K개 경로를 추출하여 후속 생성을 위한 쿼리 q의 검색 정보로 사용하며, 이를 Pq로 나타냅니다.

답변 생성 더 나은 답변 생성을 위해

우리는 신뢰도를 기반으로 경로 우선순위를 설정한 다음 LLM의 성능 패턴과 일치하도록 이러한 경로를 전략적으로 배치합니다(Qin et al.).

2023년; Liu et al. 2024년; Cuconasuet al. 2024).

형식적으로, 검색된 각 관계형 경로에 대해, 경로 내의 모든 노드와 엣지의 텍스트 덩어리를 연결하여 텍스트 관계형 경로를 얻습니다. 이 경로는 다음과 같이 공식화할 수 있습니다.

$$tP = \text{concat}([\cdot \cdot \cdot ; tvi ; tvi+1 ; \cdot \cdot \cdot]), (5)$$
 여기서 $\text{concat}(\cdot)$ 는 연결 작업을 나타내고 vi 와 ei 는 경로 P의 번째 노드와 엣지입니다.

긴 컨텍스트 사나리오에서 LLM의 "중간에서 길을 잃다" 문제(Liu et al. 2024; Cao et al. 2025)를 고려할 때, 서로 다른 관계 경로를 사용하여 쿼리를 직접 집계하면 최적의 결과를 얻지 못할 수 있습니다. 따라서 우리는 LLM 이해를 위한 황금 메모리 영역으로 간주되는 템플릿의 양쪽 끝에 가장 중요한 정보를 배치합니다. 구체적으로, 쿼리를 템플릿의 시작 부분에 배치하고 텍스트 관계 경로를 신뢰도 오름차순으로 구성하여 가장 신뢰할 수 있는 관계 경로는 템플릿의 끝에 위치하도록 합니다. 최종 프롬프트는 다음과 같이 나타낼 수 있습니다. $M(q; R(q, G)) = \text{concat}([q; tPK; \cdot \cdot \cdot ; tP1])$, (6) 여기서 P1은 가장 신뢰할 수 있는 경로이고 PK는 K번째 신뢰할 수 있는 경로입니다. 이러한 간단한 안내 전략은 실험에서 경로를 무작위 또는 신뢰도 오름차순으로 배치하는 것과 비교했을 때 LLM의 응답 성능을 크게 향상시킬 수 있습니다.

논의

RAG에서의 경로 선택 알고리즘. 기존 KG-RAG 방법론은 경로 선택 알고리즘을 통해 모델 추론 성능을 향상시켰지만(Asai et al. 2019; Sun et al. 2023; Chen et al. 2024), 주로 단일 노드 또는 엣지에 포함된 정보로 답을 얻을 수 있는 작업에 맞춰 설계되어 전역 수준의 작업에는 적합하지 않았습니다. 더욱이, 기존 접근 방식에서는 경로가 검색 결과 자체의 일부가 아니라 검색 결과를 얻기 위한 수단으로 사용되는 경우가 많았습니다. 여러 경로가 검색 결과로 이어지는 경우, 경로를 효율적으로 필터링할 방법이 없었습니다. 이와 대조적으로, PathRAG는 흐름 기반 가지치기 알고리즘을 사용하여 노드 간의 여러 경로를 평가하고, 관련 경로를 검색 결과의 일부로 선택하여 전역 수준의 작업을 처리합니다.

경로 검색의 복잡도 분석. 자원 전파의 번째 단계 후, 감소 페널티와 초기 종료로 인해 최대 개의 노드가 살아남습니다. 따라서 이 전파에 관련된 총 노드 수는 $\alpha i/\theta$ 입니다. 따라서 extract-most의 복잡도는 (1) α/θ 입니다.

$$\sum_{i=0}^{\infty} \frac{1}{\alpha i/\theta}$$
 든 노드 쌍 사이의 후보 경로를 N2로 계산하는 것은 $O(\cdot)$ 입니다. (1) α/θ 설정에서 검색된 노드 수 $N_2 \in [10, 80]$ 는 전체 정 그래프의 총 노드 수 $|V|$ 104보다 훨씬 적습니다.

따라서 시간 복잡도는 완전히 허용 가능한 수준입니다. 자세한 내용은 부록 H에 제공됩니다.

경로 기반 프롬프트의 필요성. 검색된 여러 경로가 공통 노드 또는 엣지를 가질 수 있다는 점에 유의하십시오. 프롬프트 길이를 줄이기 위해 경로를 평면화하고 노드와 엣지 집합으로 중복을 제거할 수 있습니다. 그러나 이 변환을 통해 각 경로의 두 끝점 간의 의미적 관계가 손실됩니다. 또한 실험을 통해 경로 기반 프롬프트의 필요성을 검증했습니다.

표 1: 6개 데이터 세트와 5개 평가 기준에 걸친 승률 기준 성능.

	합법적인		역사		생물학		혼합		품질		스크린	
	NaiveRAG	PathRAG	NaiveRAG	PathRAG	NaiveRAG	PathRAG	NaiveRAG	PathRAG	NaiveRAG	PathRAG	NaiveRAG	PathRAG
포괄성	31.6%	68.4%	33.2%	66.8%	29.8%	70.2%	26.2%	73.8%	35.2%	64.8%	30.0%	70.0%
다양성	24.4%	75.6%	38.4%	61.6%	35.2%	64.8%	33.2%	66.8%	29.2%	70.8%	24.2%	75.8%
논리성	35.2%	64.8%	40.4%	59.6%	34.4%	65.6%	36.2%	63.8%	34.4%	65.6%	30.2%	69.8%
관련성	27.2%	72.8%	37.2%	62.8%	42.0%	58.0%	38.4%	61.6%	31.4%	68.6%	33.0%	67.0%
통일	34.0%	66.0%	42.4%	57.6%	38.4%	61.6%	42.0%	58.0%	37.2%	62.8%	30.2%	69.8%

	하이드	패스래그	하이드	패스래그	하이드	패스래그	하이드	패스래그	하이드	패스래그	하이드	패스래그
포괄성	38.4%	61.6%	34.8%	65.2%	33.2%	66.8%	42.8%	57.2%	37.2%	62.8%	30.2%	69.8%
다양성	21.6%	78.4%	35.2%	64.8%	36.0%	64.0%	33.8%	66.2%	33.2%	66.8%	30.0%	70.0%
논리성	30.2%	69.8%	38.4%	61.6%	45.2%	54.8%	45.6%	54.4%	35.6%	64.4%	35.2%	64.8%
관련성	35.6%	64.4%	35.6%	64.4%	46.4%	53.6%	43.4%	56.6%	40.4%	59.6%	31.4%	68.6%
통일	42.0%	58.0%	40.4%	59.6%	42.4%	57.6%	45.6%	54.4%	40.0%	60.0%	35.6%	64.4%

G-리트리버 패스RAG G-리트리버 패스RAG G-리트리버 패스RAG G-리트리버 패스RAG G-리트리버 패스RAG G-리트리버 패스RAG												
포괄성	33.8%	66.2%	41.2%	58.8%	43.6%	56.4%	27.4%	72.6%	35.2%	64.8%	44.2%	55.8%
다양성	35.2%	64.8%	43.6%	56.4%	32.0%	68.0%	24.4%	75.6%	38.4%	61.6%	30.0%	70.0%
논리성	34.4%	65.6%	42.0%	58.0%	40.0%	60.0%	30.2%	69.8%	40.2%	59.8%	44.8%	55.2%
관련성	35.6%	64.4%	44.0%	56.0%	38.4%	61.6%	36.2%	63.8%	40.0%	60.0%	41.2%	58.8%
통일	38.0%	62.0%	46.6%	53.4%	35.2%	64.8%	34.4%	65.6%	37.2%	62.8%	43.6%	56.4%

HippoRAG PathRAG HippoRAG PathRAG HippoRAG PathRAG HippoRAG PathRAG HippoRAG PathRAG HippoRAG PathRAG												
포괄성	34.4%	65.6%	43.6%	56.4%	46.0%	54.0%	35.8%	64.2%	43.0%	57.0%	30.0%	70.0%
다양성	38.0%	62.0%	38.4%	61.6%	24.4%	75.6%	37.2%	62.8%	27.2%	72.8%	26.4%	73.6%
논리성	34.4%	65.6%	45.6%	54.4%	41.8%	58.2%	40.2%	59.8%	47.2%	52.8%	33.0%	67.0%
관련성	40.2%	59.8%	43.2%	56.8%	40.0%	60.0%	44.0%	56.0%	46.6%	53.4%	34.4%	65.6%
통일	41.2%	58.8%	44.4%	55.6%	43.6%	56.4%	45.4%	54.6%	42.6%	57.4%	31.8%	68.2%

GraphRAG PathRAG GraphRAG PathRAG GraphRAG PathRAG GraphRAG PathRAG GraphRAG PathRAG GraphRAG PathRAG												
포괄성	33.8%	66.2%	41.0%	59.0%	39.6%	60.4%	41.2%	58.8%	42.0%	58.0%	37.0%	63.0%
다양성	29.8%	70.2%	36.6%	63.4%	38.2%	61.8%	36.2%	63.8%	38.4%	61.6%	41.2%	58.8%
논리성	41.6%	58.4%	43.6%	56.4%	34.4%	65.6%	42.0%	58.0%	42.0%	58.0%	40.0%	60.0%
관련성	40.6%	59.4%	44.0%	56.0%	42.4%	57.6%	40.4%	59.6%	42.4%	57.6%	44.4%	55.6%
통일	38.2%	61.8%	40.8%	59.2%	43.6%	56.4%	41.6%	58.4%	41.6%	58.4%	43.6%	56.4%

LightRAG 경로RAG LightRAG 경로RAG LightRAG 경로RAG LightRAG 경로RAG LightRAG 경로 RAG LightRAG 경로RAG												
포괄성	36.6%	63.4%	44.0%	56.0%	42.6%	57.4%	40.4%	59.6%	44.0%	56.0%	46.4%	53.6%
다양성	38.2%	61.8%	43.2%	56.8%	43.6%	56.4%	42.0%	58.0%	43.2%	56.8%	46.4%	53.6%
논리성	37.2%	62.8%	41.6%	58.4%	45.2%	54.8%	43.6%	56.4%	44.8%	55.2%	44.8%	55.2%
관련성	40.0%	60.0%	44.0%	56.0%	44.8%	55.2%	44.0%	56.0%	45.6%	54.4%	44.4%	55.6%
통일	38.8%	61.2%	44.4%	55.6%	44.4%	55.6%	38.4%	61.6%	44.4%	55.6%	46.4%	53.6%

실험

우리는 다음과 같은 질문에 답하기 위해 광범위한 실험을 수행합니다. 연구 질문 (RQ): RQ1: 본 연구에서 제안하는 PathRAG는 최첨단 기준 모델에 비해 얼마나 효과적인가? RQ2: 우리 프레임워크의 각 구성 요소가 제 역할을 다했습니까? 효과적으로? RQ3: 다양한 희소성 수준을 가진 인덱싱 그래프에서 모델의 성능은 어떻습니까? RQ4: 우리의 모델은 어떻게 작동합니까? 프레임워크는 서로 다른 LLM 백본 환경에서 제대로 작동합니까? RQ5: PathRAG가 해당 목표를 달성하는 데 필요한 토큰 비용은 얼마입니까? 최첨단 기준선의 성능은 어떠한가?

실험 장치 구성

데이터셋. 우리는 Ligh-tRAG(Guo et al. 2024)의 실험 설정을 따르며, 추가적으로 네 가지를 고려합니다. UltraDomain(Qian et al. 2024), SQuAL-ITY(Wang et al. 2022) 및 SummScreen(Chen et al.)의 데이터 세트. 2022) 철저한 평가를 위해, 이 데이터 세트들은 규모가 상당히 다양하며, 토큰 수는 180,000개에서 2022년까지 다양합니다. 5,000,000까지. 우리는 농업 분야에서 하이퍼파라미터를 조정합니다. CS 데이터셋을 먼저 테스트한 다음, 나머지 6개의 데이터셋에서 테스트합니다.

기준선. PathRAG를 6개의 최첨단 기술과 비교합니다. 방법: NaiveRAG(Gao et al. 2023b), HyDE(Gao et al. 2023a), G-리트리버(He et al. 2025), HippoRAG(Gutierrez

et al. 2024), GraphRAG(Edge et al. 2024) 및 LightRAG (Guo et al. 2024). 이러한 방법들은 최첨단 텍스트 기반, KG 기반 및 그래프 기반 RAG 접근 방식을 포함합니다.

구현 세부 사항. 실험 과정의 공정성을 보장하기 위해 모든 실험에서 "GPT-4o-mini"를 일관되게 사용했습니다. 모든 방법에 대한 기본 모델을 구축하고, 임베딩에는 "text-embedding-3-small" 모델을 채택합니다. 또한, 다음을 구축합니다. GraphRAG 방식을 따르는 인덱싱 그래프(엣지 et al. 2024), 그리고 이에 해당하는 검색된 엣지 LightRAG의 글로벌 키워드(Guo et al. 2024)가 배치됩니다. 쿼리 후에. 무작위성을 포함하는 요소의 경우, 10회 시도의 평균값입니다. 최대 입력 토큰 길이는 다음과 같습니다. LLM은 검색된 다양한 형태의 정보를 공정하게 처리하기 위해 8,000개로 제한됩니다. 하이퍼파라미터는 다음과 같습니다. PathRAG의 값은 N = 40, K = 15, α = 0.7로 고정되어 있습니다.

평가 지표. 정답 데이터가 없기 때문에 답변의 경우, LLM 기반 평가 절차를 따릅니다. GraphRAG 및 LightRAG를 사용합니다. 특히, "GPT-4o-mini"를 활용하여 생성된 답변을 다양한 차원에서 평가합니다. 평가 차원은 다음과 같습니다.

GraphRAG 및 LightRAG의 포괄성 및 다양성을 포함한 여러 요소를 통합하는 동시에 세 가지 요소도 포함합니다. LLM 기반 평가의 최근 발전에서 비롯된 새로운 차원

표 2: PathRAG의 경로 복원 알고리즘에 대한 절제 연구.

	합법적인		역사		생물학		혼합		품질		스크린	
	랜덤 흐름 기반	랜덤 흐름 기반	랜덤 흐름 기반	랜덤 흐름 기반	랜덤 흐름 기반	랜덤 흐름 기반	랜덤 흐름 기반	랜덤 흐름 기반	랜덤 흐름 기반	랜덤 흐름 기반	랜덤 흐름 기반	랜덤 흐름 기반
포괄성	44.0%	56.0%	46.0%	54.0%	44.0%	56.0%	42.8%	57.2%	45.6%	54.4%	46.6%	53.4%
다양성	45.2%	54.8%	31.4%	68.6%	29.8%	70.2%	46.0%	54.0%	44.4%	55.6%	42.8%	57.2%
논리성	46.6%	53.4%	44.0%	56.0%	42.0%	58.0%	46.4%	53.6%	41.8%	58.2%	43.6%	56.4%
관련성	44.8%	55.2%	46.0%	54.0%	45.8%	54.2%	45.6%	54.4%	45.6%	54.4%	44.8%	55.2%
통일	44.6%	55.4%	41.0%	59.0%	41.6%	58.4%	44.0%	56.0%	43.6%	56.4%	46.4%	53.6%

홈퍼스트 플로우 기반 홈퍼스트 플로우 기반 홈퍼스트 플로우 기반 홈 퍼스트 플로우 기반 홈퍼스트 플로우 기반 홈퍼스트 플로우 기반												
포괄성	44.4%	55.6%	45.8%	54.2%	48.8%	51.2%	43.2%	56.8%	45.2%	54.8%	46.4%	53.6%
다양성	36.0%	64.0%	49.6%	50.4%	46.0%	54.0%	47.6%	52.4%	44.0%	56.0%	45.4%	54.6%
논리성	45.2%	54.8%	41.2%	58.8%	44.8%	55.2%	43.6%	56.4%	46.0%	54.0%	46.0%	54.0%
관련성	43.6%	56.4%	46.0%	54.0%	37.4%	62.6%	41.4%	58.6%	44.8%	55.2%	46.8%	53.2%
통일	41.0%	59.0%	40.0%	60.0%	42.6%	57.4%	44.8%	55.2%	46.8%	53.2%	46.4%	53.6%

표 3: PathRAG의 프롬프트 형식에 따른 절제술 연구.

	법률 경		이력 경로		생물학 경		혼합		SQuALITY 플랫폼 경		스크린	
	평판	로 기반 60.0%	기반 51.2%		로 기반 54.4%	49.6%	경로 기반 50.4%		로 기반 47.2%	52.8%	경로 기반	
포괄성	40.0%	다양성 42.0%	논리성 관	48.8% 고정	39.6%	60.4%	44.4%	55.6%	43.2%	56.8%	44.4%	55.6%
다양성	36.0%	64.0%	49.6%	50.4%	46.0%	54.0%	47.6%	52.4%	44.0%	56.0%	45.4%	54.6%
논리성	45.2%	54.8%	41.2%	58.8%	44.8%	55.2%	43.6%	56.4%	46.0%	54.0%	46.0%	54.0%
관련성	43.6%	56.4%	46.0%	54.0%	37.4%	62.6%	41.4%	58.6%	44.8%	55.2%	46.8%	53.2%
통일	41.0%	59.0%	40.0%	60.0%	42.6%	57.4%	44.8%	55.2%	46.8%	53.2%	46.4%	53.6%

평가(Chan et al. 2023), 즉 논리성, 관련성, 그리고 일관성을 고려합니다. 각 도구가 생성한 답변을 비교합니다. 기준선과 우리의 방법론을 사용하여 승률 통계를 산출합니다.

승률이 높을수록 성능 면에서 우위가 크다는 것을 의미합니다.

다른 답변보다. 두 답변의 제시 순서는 번갈아 가며 나타나며, 평균 승률은 다음과 같습니다.

보고되었습니다. 실험 설정에 대한 자세한 내용은 다음에서 확인할 수 있습니다.

부록 A, B, C 및 D.

주요 결과 (RQ1)

표 1에서 볼 수 있듯이 PathRAG는 모든 평가 차원에서 기준선보다 일관되게 우수한 성능을 보였습니다.

데이터 세트. 평가 차원의 관점에서 보면, 모든 기준선과 비교했을 때 PathRAG는 평균적으로 더 나은 결과를 보여줍니다. 포괄성 부문에서 62.52%, 다양성 부문에서 65.37%의 점수를 받았습니다. 논리성 60.68%, 관련성 59.92%, 그리고 59.43% 평균적으로 일관성 측면에서 이러한 장점은 두드러집니다.

우리가 제안한 경로 기반 검색의 효율성은 다음과 같습니다.

다양한 측면에서 더 나은 성능에 기여합니다.

생성된 응답들. 데이터셋 수준의 관점에서 보면, PathRAG는 64.66%라는 주목할 만한 평균 승률을 달성했습니다.

법률, 역사, 생물학 및 혼합 데이터 세트에서 각각 58.94%, 60.44%, 61.59%의 정확도를 보였습니다. 더 나아가, 더욱 까다로운 데이터 세트에서도 견고한 성능을 입증했습니다.

비전통적인 SQuALITY 및 SummScreen 벤치마크, 평균 승률은 각각 60.67%와 63.20%였습니다. 이러한 결과 종합적으로 볼 때 PathRAG는 우수한 다중 도메인 적응성을 제공하며 기준선 대비 지속적으로 우수한 성능을 보여줍니다.

다양한 평가 사례리오에 걸친 모델.

SQuAL-ITY 데이터셋에 포함된 사람이 작성한 요약물 고려하여, 자동화된 측정 지표를 사용하여 생성된 답변과 참고 자료 간의 일치도를 추가로 평가합니다.

BLEU, ROUGE, METEOR와 같이. 표 4에 나타난 바와 같이, PathRAG는 모든 지표에서 탁월한 성능을 달성합니다. 최고 기준치 대비 평균 7.06% 향상되었습니다.

향후 연구에서는 인간 평가도 통합할 예정입니다. 다른 의미 수준 평가 방법.

표 4: 사람이 작성한 요약을 사용한 SQuALITY 데이터 세트에 대한 평가.

BLEU-1 BLEU-2 ROUGE-1-F1 ROUGE-2-F1 유성				
NaiveRAG 31.78%	12.31%	HyDE 31.68%	13.80%	3.51%
11.84% G-retriever 32.42%	12.03%	HippoRAG 32.12%	11.89%	GraphRAG 32.98%
12.27%	14.02%	3.12%	17.50%	17.61%
13.81%	14.23%	3.59%	17.52%	17.66%
	14.56%	3.30%	18.53%	
	15.35%	3.95%		

절제술 연구 (RQ2)

우리는 설계의 유효성을 검증하기 위해 절제 실험을 수행합니다. PathRAG. 변형에 대한 자세한 소개는 다음과 같습니다.

부록 G에서 찾을 수 있습니다.

경로 순서 지정의 필요성. 우리는 두 가지 다른 경우를 고려합니다.

프롬프트에서 검색된 경로의 순위를 매기는 전략, 즉 무작위 및 흡 우선 방식. 표 2에서 볼 수 있듯이 평균은 PathRAG의 승률을 무작위 및 흡 우선 방식과 비교 변이체의 비율은 각각 56.44%와 55.64%이며, 이는 다음을 나타냅니다.

프롬프트에서 경로 순서 지정의 필요성.

경로 기반 프롬프트의 필요성. 검색은 다음과 같습니다.

경로를 사용하여 수행되었으며, 검색된 정보는 다음과 같습니다.

프롬프트는 반드시 다음과 같은 형식으로 정리될 필요는 없습니다.

동일한 방식으로. 경로 기반 구성의 필요성을 평가하기 위해 경로로 구조화된 프롬프트와 그렇지 않은 프롬프트를 비교합니다.

수평적 조직을 사용합니다. 표 3에서 볼 수 있듯이 경로 기반 프롬프트는 평균 55.19%의 승률을 달성하여 평면 형식보다 우수한 성능을 보입니다.

PathRAG에서 경로 내의 노드 및 에지 정보는 본질적으로 상호 연결되어 있으며, 이를 분리하면 정보 손실이 발생할 수 있습니다. 따라서 경로 생성 후에는 검색 시 문맥적 관계를 유지하고 답변의 질을 향상시키기 위해 프롬프트는 구조화된 형태로 유지되어야 합니다.

그래프 희소성 분석(RQ3)

다양한 수준에서 PathRAG의 견고성을 평가하기 위해 그래프 희소성에 대한 실험을 농업 및 컴퓨터 과학 데이터셋을 이용하여 수행했습니다. 다양한 희소성 수준을 시뮬레이션했습니다. 10%, 20%, 30%, 40%, 50%를 무작위로 제거함으로써 원래 인덱싱 그래프의 엣지들입니다. 그 후, 각 희소성 조건에서 PathRAG, Light-tRAG 및 NaiveRAG 간의 쌍별 비교를 수행합니다. 이 평가 결과는 그림 3에 제시되어 있습니다.




그림 3: PathRAG, LightRAG 및 그래프 희소성 수준에 따른 NaiveRAG의 성능 농업 및 CS 데이터 세트.

그래프 기반 방법은 어느 정도 한계를 보이지만 점점 더 높은 값에 적용할 때 성능 저하가 발생합니다. 희소 인덱싱 그래프에서 PathRAG는 실질적인 견고성을 지속적으로 입증하고 있습니다. 희소성 시뮬레이션 상당 부분을 무작위로 제거함으로써 엣지는 효율성의 측정 가능한 감소로 이어집니다. 그럼에도 불구하고 PathRAG는 두 가지 모드를 일관되게 능가합니다. LightRAG는 마찬가지로 그래프 구조에 의존하며 NaiveRAG는 그래프 기반 컨텍스트와 독립적으로 작동합니다. 특히 농업 및 컴퓨터 과학 분야에서 그렇습니다. 데이터 세트에서 PathRAG는 평균 승률 범위가 다음과 같습니다. NaiveRAG와 비교했을 때, 각각 54.84%에서 57.32%, 그리고 51.72%에서 54.92%로 증가했습니다. LightRAG와 비교했을 때는, PathRAG는 50.92%에서 53.24% 사이의 승률을 유지합니다.

농업 분야에서는 52.24%에서 53.28% 사이이며, 소비자보호 분야에서는 52.24%에서 53.28% 사이입니다. 이러한 결과는 그래프 희소성이 심각한 조건에서도 PathRAG의 견고성과 일반화 가능성을 강조합니다.

다양한 LLM 조건에서의 성능 (RQ4)

성과 수준이 서로 다른 LLM을 고려할 때 이는 프레임워크의 전반적인 효과성에 영향을 미칠 수 있습니다. 평가의 신뢰성을 높이기 위해 "GPT-4o-mini"를 "GPT-4o" 또는 "DeepSeek-V3"로 일관되게 대체했습니다. 비교 실험을 위한 기본 및 평가 모델. 표 5에서 볼 수 있듯이, "GPT-4o-mini"를 사용할 경우 PathRAG는 기본 모델과 평가 모두에서 뛰어난 성능을 발휘합니다. 농업 분야에서 평균 승률은 53.92%입니다. CS 데이터셋. "DeepSeek-V3" 모델을 사용할 경우, 평균 승률이 56.48%로 증가했습니다. 가장 뛰어난 성능을 보인 모델인 "GPT-4o"를 사용했을 때 승률이 최고치를 기록했습니다. 58.36%입니다. 이러한 결과는 LLM이 강할수록 더 나은 결과를 보인다는 것을 나타냅니다. 사용량이 많을수록 프레임워크의 전반적인 성능이 향상됩니다.

표 5: 다양한 기본 모델 및 평가 모델에 따른 PathRAG와 Light-tRAG의 성능 비교.

GPT-4o-미니	농업		CS	
	LightRAG	PathRAG	LightRAG	PathRAG
포괄성	47.6%	52.4%	47.6%	52.4%
다양성	44.4%	55.6%	42.6%	57.4%
논리성	48.0%	52.0%	42.6%	57.4%
관련성	46.6%	53.4%	45.2%	54.8%
통일	45.6%	54.4%	47.2%	52.8%
GPT-4o	LightRAG	PathRAG	LightRAG	PathRAG
	47.4%	52.6%	32.8%	67.2%
다양성	43.2%	56.8%	34.0%	66.0%
논리성	45.6%	54.4%	42.4%	57.6%
관련성	42.0%	58.0%	41.6%	58.4%
통일	42.2%	57.8%	45.2%	54.8%
딥시크-V3	LightRAG	PathRAG	LightRAG	PathRAG
	47.4%	52.6%	46.0%	54.0%
포괄성	47.4%	52.6%	46.0%	54.0%
다양성	42.0%	58.0%	42.4%	57.6%
논리성	44.0%	56.0%	42.0%	58.0%
관련성	44.4%	55.6%	42.2%	57.8%
통일	43.2%	56.8%	41.6%	58.4%

PathRAG는 다양한 모델에서 안정적인 성능을 유지합니다. 다양한 능력.

토큰 비용 분석 (RQ5)

토큰 소비량에 초점을 맞춘 공정한 비교를 위해, 우리는 또한 N = 를 사용하는 PathRAG의 경량 버전을 고려해 보세요. 20이고 K=5인 PathRAG-It라고 명명되었습니다. PathRAG-It는 다음과 같은 기능을 수행합니다. 전반적인 성능 면에서 LightRAG와 동등한 수준을 달성했습니다. 평균 승률 50.56%, 상세 결과 제공 부록 1에 있습니다.

표 6: LightRAG, PathRAG-It 및 PathRAG는 토큰, 시간 및 금전적 비용 측면에서 우수합니다.

라이트RAG 패스RAG-It 패스RAG			
토큰 비용	16,728	9,968	14,438
금전적 비용	2.51×10^{-3}	1.50×10^{-3}	2.17×10^{-3}

표 6에서 볼 수 있듯이 PathRAG는 상당한 성과를 달성했습니다. 토큰 소비를 줄이면서 성능을 향상시킵니다. 13.69%의 절감 효과를 거두었으며, 이에 상응하는 비용은 단 0.002달러에 불과합니다. 한편, PathRAG-It는 토큰 사용량을 40.41% 감소시킵니다. LightRAG와 유사한 성능을 유지합니다. 이러한 결과는 우리 방법의 토큰 효율성을 입증합니다.

결론

본 논문에서는 그래프 기반의 새로운 알고리즘인 PathRAG를 제안합니다. 핵심 관계 경로 검색에 초점을 맞춘 RAG 방법 인덱싱 그래프에서 노이즈를 줄이기 위해 PathRAG를 사용할 수 있습니다. 흐름 기반 가지치기 알고리즘을 사용하여 핵심 경로를 효율적으로 식별하고, 경로 기반 알고리즘을 사용하여 효과적으로 해답을 생성합니다. LLM 프롬프트. 실험 결과는 다음을 보여줍니다. PathRAG는 6가지 항목에서 기존 방법보다 일관되게 우수한 성능을 보입니다. 데이터 세트. 향후 연구에서는 인덱싱 그래프를 최적화할 예정입니다. 구축 과정을 살펴보고, 그래프 기반 RAG를 위해 사람이 직접 주석을 단 데이터셋을 더 많이 수집하는 것을 고려해 볼 수 있습니다. 또한 경로 외의 다른 하위 구조를 탐색하여 성능을 향상시키는 것도 가능합니다. 모델 성능.

감사의 말씀 본 연구는 중국

국가자연과학기금(과제번호 62192784, 62236003, 62576082), 중국과학기술협회(CAST)의 젊은 엘리트 과학자 후원 프로그램(과제번호 2023QNRC001), 그리고 베이징시 자연과학기금(과제번호 L253004)의 지원을 받아 수행되었습니다.

참고 자료

Alon, U.; Xu, F.; He, J.; Sengupta, S.; Roth, D.; 및 Neu-big, G. 2022. 오토마톤 증강 검색을 이용한 신경-상징 언어 모델링. ICML 2023에서 발표.

Asai, A.; Hashimoto, K.; Hajishirzi, H.; Socher, R.; 및 Xiong, C. 2019. 질문 답변을 위한 위키피디아 그래프에서 추론 경로를 검색하는 학습. ICLR 2020.

보르데스, A.; 우스니에, N.; 초프라, S.; 및 웨스턴, J. 2015. 메모리 네트워크를 이용한 대규모 단순 질문 답변. arXiv 사전 공개 논문 arXiv:1506.02075.

Cao, Y.; Han, S.; Gao, Z.; Ding, Z.; Xie, X.; 및 Zhou, SK 2025. Graphinsight: 그래프 구조 이해를 위한 대규모 언어 모델에서 통찰력을 추출합니다. ACL 2025에서 발표.

Chan, C.-M.; Chen, W.; Su, Y.; Yu, J.; Xue, W.; Zhang, S.; Fu, J.; 및 Liu, Z. 2023. ChatEval: 다중 에이전트 토론을 통한 더 나은 LLM 기반 평가자를 향하여. ICLR 2024.

Chen, L.; Tong, P.; Jin, Z.; Sun, Y.; Ye, J.; 및 Xiong, H. 2024. Plan-on-graph: 지식 그래프 기반 대규모 언어 모델의 자체 수정 적응형 계획 수립. NeurIPS 2024 발표 예정.

Chen, M.; Chu, Z.; Wiseman, S.; 및 Gimpel, K. 2022. SummScreen: 추상적 시나리오 요약을 위한 데이터셋. ACL 2022 발표 논문.

첸, X.; 루오, D.; 첸, X.; 리우, L.; 자오, D.; 그리고 안, R. 2023. Lift yourself up: 자기 기억을 활용한 검색 증강 텍스트 생성. NeurIPS 2023 발표 논문.

쿠코나수, F.; Trappolini, G.; 시실리아노, F.; 필리스, S.; 캄파냐노, C.; 마렉, Y.; 토넬로토, N.; 및 실베스트리, F. 2024. 노이즈의 힘: rag 시스템을 위한 검색의 재정의. SIGIR 2024에서 발표.

데간, M.; 알룰라니, M.; 바가, S.; 알폰소-헤르멜로, D.; 비비, K.; 가다르, A.; 장 Y.; 리, X.; 하오, J.; 리우, Q.; 외. 2024. EWEK-QA: 인용 기반 질문 응답 시스템을 위한 향상된 웹 및 효율적인 지식 그래프 검색. ACL 2024에서.

Edge, D.; Trinh, H.; Cheng, N.; Bradley, J.; Chao, A.; Mody, A.; Truitt, S.; 및 Larson, J. 2024. 로컬에서 글로벌로: 쿼리 중심 요약을 위한 그래프 래그 접근 방식. arXiv 사전 인쇄본 arXiv:2404.16130.

Fan, T.; Wang, J.; Ren, X.; 및 Huang, C. 2025. MiniRAG: 극도로 간단한 검색 증강 생성을 향하여. arXiv 사전 인쇄 arXiv:2501.06713.

Fan, W.; Ding, Y.; Ning, L.; Wang, S.; Li, H.; Yin, D.; Chua, T.-S.; 및 Li, Q. 2024. rag meeting llms에 대한 조사: 검색 증강 대규모 언어 모델을 향하여. KDD 2024에서 발표.

팡, F.; 바이, Y.; 니, S.; 양, M.; 첸, X.; 및 쉬, R. 2024. 적응형 적대적 학습을 통한 검색 증강 언어 모델의 노이즈 내성 향상. ACL 2024 발표 논문.

Fang, J.; Meng, Z.; 및 Macdonald, C. 2024. Reano: 지식 그래프 생성을 통한 검색 증강 리더 모델 최적화. ACL 2024.

Gao, H.; Wu, L.; Hu, P.; Wei, Z.; Xu, F.; 및 Long, B. 2022. 대규모 지식 그래프 질의를 위한 그래프 증강 학습 기반 순위 결정. AAAL 2022 발표.

Gao, L.; Ma, X.; Lin, J.; 및 Callan, J. 2023a. 관련성 레이블 없이 정확한 제로샷 밀집 검색. ACL 2023.

Gao, Y.; Xiong, Y.; Gao, X.; Jia, K.; Pan, J.; Bi, Y.; Dai, Y.; Sun, J.; and Wang, H. 2023b. 대규모 언어 모델을 위한 검색 증강 생성: 설문 조사. arXiv preprint arXiv:2312.10997.

Gu, Y.; Kase, S.; Vanni, M.; Sadler, B.; Liang, P.; Yan, X.; 및 Su, Y. 2021. IID를 넘어서: 지식 기반 질의응답을 위한 세 가지 수준의 일반화. WWW 2021.

Guo, Z.; Xia, L.; Yu, Y.; Ao, T.; 및 Huang, C. 2024. Light-trag: 간단하고 빠른 검색 증강 생성. arXiv 사전 인쇄 arXiv:2410.05779.

Gutierrez, BJ; Shu, Y.; Gu, Y.; Yasunaga, M.; 및 Su, Y. 2024. Hipporag: 대규모 언어 모델을 위한 신경생물학적 영감을 받은 장기 기억. NeurIPS 2024.

구, K.; 이경; 톱, Z.; 파수팻, P.; 및 Chang, M. 2020. 검색 증강 언어 모델 사전 학습. ICML 2020 발표.

He, X.; Tian, Y.; Sun, Y.; Chawla, N.; Laurent, T.; LeCun, Y.; Bresson, X.; 및 Hooi, B. 2025. G-retriever: 텍스트 그래프 이해 및 질문 답변을 위한 검색 증강 생성. NeurIPS 2024.

호, X.; Nguyen, A.-KD; 스가와라, S.; 그리고 아이자와 A. 2020. 추론 단계의 종합적인 평가를 위한 멀티홉 QA 데이터셋 구축. COLING 2020 학회 발표 논문. 호프슈타터, S.; 첸, J.; 라만, K.; 및 자마니, H. 2023. Fid-light: 효율적이고 효과적인 검색 증강 텍스트 생성. SIGIR 2023 발표 예정.

지양, Z.; 쉬, FF; 가오, L.; 썬, Z.; 리우, Q.; 드위베디유, J.; 양Y.; 칼란, J.; 및 Neubig, G. 2023. 능동 검색 증강 생성. EMNLP 2023에서.

조시, M.; 최, E.; 웰드, DS; 및 제틀모이어, L. 2017. TriviaQA: 독해력 향상을 위한 대규모 원격 지도 학습 데이터셋. ACL 2017 발표 논문.

Kwiatkowski, T.; Palomaki, J.; Redfield, O.; Collins, M.; Parikh, A.; Alberti, C.; Epstein, D.; Polosukhin, I.; Devlin, J.; Lee, K.; 외. 2019. 자연스러운 질문: 질문 답변 연구의 벤치마크. TACL 2019.

루이스, P.; 페레즈, E.; 피크투스, A.; 페트로니, F.; 카르푸킨, V.; 고알, N.; 커틀러, H.; 루이스, M.; Yih, W.-t.; Rockt Aschel, T.; 외. 2020. 지식 집약적 자연어 처리 작업을 위한 검색 증강 생성. NeurIPS 2020 발표 논문.

Li, C.; Liu, Z.; Xiao, S.; Shao, Y.; 및 Lian, D. 2024. Llama2vec: 대규모 언어 모델의 비지도 학습 적응을 통한 밀집 검색. ACL 2024 발표 예정.

Li, M.; Miao, S.; 및 Li, P. 2024. 단순함이 효과적이다: 지식 그래프 기반 검색 증강 생성에서 그래프와 대규모 언어 모델의 역할. ICLR 2025.

린, Y.; 류, Z.; 루안, H.; 썬, M.; 라오, S.; 그리고 류, S.
2015. 지식 베이스의 표현 학습을 위한 관계 경로 모델링. EMNLP 2015 학회 발표 논문.

Liu, NF; Lin, K.; Hewitt, J.; Paranjape, A.; Bevilacqua, M.; Petroni, F.; 및 Liang, P. 2024. 중간에 갇히다: 언어 모델은 긴 컨텍스트를 어떻게 사용하는가. TACL 2024.

Liu, Y.; Wan, Y.; He, L.; Peng, H.; 및 Philip, SY 2021.
Kg-bart: 지식 그래프로 증강된 생성적 상식 추론을 위한 bart 모델. AAAI 2021 발표 예정.

Lu, L.; 및 Zhou, T. 2011. 복잡한 네트워크의 링크 예측: 조사. Physica A: 통계 역학 및 응용, 390(6): 1150–1170.

Lyuu, Y.; Li, Z.; Niu, S.; Xiong, F.; Tang, B.; Wang, W.; Wu, H.; Liu, H.; Xu, T.; and Chen, E. 2025. Crud-rag: 대규모 언어 모델의 검색 증강 생성을 위한 포괄적인 중국어 벤치마크. TOIS 2025.

Mavromatis, C.; 및 Karypis, G. 2024. Gnn-rag: 대규모 언어 모델 추론을 위한 그래프 신경 검색. arXiv 사전 인쇄본 arXiv:2405.20139.

팬더, P.; 아가르왈, A.; 데바굽타푸, C.; 카울, M.; 외.
2024. HOLMES: LLM을 사용한 다중 홉 질의응답을 위한 초관계형 지식 그래프. ACL 2024 발표.

Procko, TT; 및 Ochoa, O. 2024. 대규모 언어 모델을 위한 그래프 검색 증강 생성: 설문 조사.
AlxSET 2024에서 발표됨. IEEE.

첸, H.; 장, P.; 류, Z.; 마오, K.; 그리고 도우, Z.
2024. Memorag: 메모리에서 영감을 받은 지식 발견을 통해 차세대 rag로 나아가기. arXiv 사전 인쇄본 arXiv:2409.05591.

Qin, Z.; Jagerman, R.; Hui, K.; Zhuang, H.; Wu, J.; Yan, L.; Shen, J.; Liu, T.; Liu, J.; Metzler, D.; et al. 2023. Large language models are effective text rankers with pairwise ranking prompting. In NAACL 2024.

쉬크, T.; 드워베다유, J.; Dess` , R.; 라일레아누, R.; 로멜리, M.; 함브로, E.; Zettlemoyer, L.; Cancedda, N.; and Scialom, T. 2023. Toolformer: 언어 모델은 도구 사용 방법을 스스로 가르칠 수 있습니다. NeurIPS 2023에서.

Su, Y.; Fang, Y.; Zhou, Y.; Xu, Q.; 및 Yang, C. 2025. Clue-RAG: 다중 파티 그래프 및 쿼리 기반 반복 검색을 통한 정확하고 비용 효율적인 그래프 기반 RAG 구현. arXiv 사전 인쇄본 arXiv:2507.08445.

Sun, J.; Xu, C.; Tang, L.; Wang, S.; Lin, C.; Gong, Y.; Ni, LM; Shum, H.-Y.; and Guo, J. 2023. Think-on-graph: 지식 그래프 기반 대규모 언어 모델의 심층적이고 책임감 있는 추론. ICLR 2024.

Talmor, A.; 및 Berant, J. 2018. 복잡한 질문에 답하기 위한 지식 기반으로서의 웹. NAACL 2018에서 발표.
Tian, L.; Zhou, X.; Wu, Y.-P.; Zhou, W.-T.; Zhang, J.-H.; 및 Zhang, T.-S. 2022. 지식 그래프 및 지식 추론: 체계적 검토. JEST 2022.

Wang, A.; Pang, RY; Chen, A.; Phang, J.; 및 Bowman, S.
2022. SQuALITY: 장문 문서 요약 데이터셋 구축의 어려움. EMNLP 2022 학회 발표.

Wen, Y.; Wang, Z.; 및 Sun, J. 2024. 마인드맵: 대규모 언어 모델에서 사고의 그래프를 촉진하는 지식 그래프. ACL 2024.

Xu, S.; Pang, L.; Yu, M.; Meng, F.; Shen, H.; Cheng, X.; 및 Zhou, J. 2024. 검색 증강 생성을 위한 대규모 언어 모델의 비지도 정보 정제 훈련. ACL 2024.

양, Z.; 치, 피.; 장, S.; 벤지오, Y.; 코헨, WW; Salakhutdinov, R.; 및 Manning, CD 2018. HotpotQA: 다양하고 설명 가능한 다중 홉 질문 답변을 위한 데이터셋입니다. EMNLP 2018에서.

야스나가, M.; 렌, H.; 보셀루트, A.; 리앙, 피.; 및 Leskovec, J. 2021. QA-GNN: 질문 답변을 위한 언어 모델 및 지식 그래프를 사용한 추론. NAACL 2021에서.

네, AJ; 당신, Y.; 말체크, J.; 라베르데, S.; 그리고 리, R.
2024. 효과적인 검색 증강 생성을 위한 재무 보고서 청킹. arXiv 사전 인쇄본 arXiv:2402.05131.

Zhang, H.; Feng, T.; 및 You, J. 2025. 기록 그래프: 그래프를 이용한 장문맥 요약을 위한 검색 증강 생성 강화. ACL 2025.

Zhang, L.; Yu, Y.; Wang, K.; 및 Zhang, C. 2024. Arl2: 자체 안내 적응적 관련성 레이블링을 통한 블랙박스 대규모 언어 모델용 검색기 정렬. ACL 2024.

Zhu, K.; Feng, X.; Du, X.; Gu, Y.; Yu, W.; Wang, H.; Chen, Q.; Chu, Z.; Chen, J.; and Qin, B. 2024. 검색 증강 생성에서 효과적인 노이즈 필터링을 위한 정보 병목 현상 관점. ACL 2024.