

# AutothinkRAG: 복잡성 인식 검색 증강 제어 이미지-텍스트 상호작용에 대한 추론

양지아슈1,3,      치 장1,      Abudukelimu Wuerkaixi2,3,      쉬신 쟁3,  
차오류3      , 케 쟁3,      쉬지아1, Xunliang Cai3  
1다롄공업대학교 2칭화대학교 3메이투안 롱캣 인터랙션 팀

## 추상적인

다중모드 문서 질의응답은 시각적으로 풍부한 장문의 문서에서 분산된 증거를 검색하고 이를 해석하는 작업을 필요로 합니다.

이질적인 정보에 대한 신뢰할 수 있는 추론. 기존 멀티모달 RAG 시스템

두 가지 병목 현상으로 인해 여전히 제한을 받고 있습니다. 하나는 쿼리 복잡성을 무시하는 정적 검색이고, 다른 하나는 엔드 투엔드 비전-언어 모델(VLM)입니다.

시각적 인식과 논리적 추론을 결합하는 것은 비효율적인 계산과 불안정한 답변 생성을 초래합니다. 본 논문에서는 다중 모달 문서 품질 보증을 위한 복잡성 인식 추론 아키텍처인 Auto-ThinkRAG를 제안합니다.

두 가지 구성 요소가 있습니다: (1) 쿼리 복잡성 질의 난이도와 구조를 분석하여 검색 및 추론 방식을 적응적으로 선택하는 라우터

(1) 경로; 및 (2) 경량 VLM을 사용하는 지각-추론 분리 아키텍처

고품질 시각적 해석 도구로서 변환합니다.

질의와 관련된 시각적 단서를 텍스트 표현으로 변환한 다음, 이를 LLM(언어 관리자)에게 전달합니다.

논리적 추론 및 답변 종합. 이것은

이 설계는 특히 장문 문서 및 답변 불가능한 질의에 대해 효율성과 견고성을 모두 향상시킵니다. DocBench에서 수행된 실험 결과입니다.

그리고 MMLongBench는 AutoThinkRAG가 82.13% 및 51.29%의 전체 정확도를 달성했습니다.

각각 쿼리당 토큰 수를 줄이면서

소비는 18.9%, 금전적 비용은 다음과 같습니다.

18.2%. 추가 분석 결과, 증가율은 다음과 같습니다.

특히 복잡한 쿼리에서 이러한 현상이 두드러지게 나타납니다.

적응형 검색 및 다단계 추론.

## 1. 서론

검색 증강 생성(RAG)은 다음과 같은 역할을 합니다.

이중 시스템 처리를 위한 핵심 기술

멀티모달 문서. 그 목적은 검색하는 것입니다.

주어진 쿼리와 관련된 멀티모달 정보

문서에서 맥락적 내용을 추출하여 질문에 답변함으로써 정확도를 높입니다.

생성된 결과의 풍부함과 다양성. 이 분야의 발전 방향으로서 멀티모달 RAG(MM-RAG)는 두 가지 핵심 문제를 동시에 해결해야 합니다.

## Traditional RAG



## AutoThink RAG




그림 1: 기존 RAG와 비교하여 Auto-thinkRAG는 적응형 검색을 통해 더욱 효과적이고 견고한 장문 문서 질의응답을 가능하게 합니다.

그리고 지각과 추론을 분리했습니다.

neously: 다중 모드 정보 처리 및

고정밀 추론.

지식 그래프는 효과적으로 표현할 수 있습니다.

정보의 관계와 속성은 다음과 같습니다.

밀집 벡터 표현은 직접적인 구조적 연결이 부족한 의미적으로 관련된 콘텐츠를 식별할 수 있습니다. 최근 몇 년 동안 연구자들은 멀티모달 그래프에 대한 광범위한 탐구를 진행해 왔습니다.

RAG 및 복잡한 질문 답변.

최첨단(SOTA) 접근 방식, RAG-Anything

(Guo et al., 2025)는 적용 가능성을 검증했습니다.

문서 기반 질의응답에서 멀티모달 그래프의 활용.

HyperGraphRAG (Luo et al., 2025)는 하이퍼엣지 모델링을 통해 복잡한 지식 베이스의 고차 의존성을 효과적으로 포착하여 복잡한 다중 홉의 정확도를 향상시킵니다.

추리.

기존 방법으로 달성한 진전에도 불구하고 현재의 SOTA 프레임워크는 여전히 성능에 심각한 영향을 미치는 두 가지 중요한 문제에 직면해 있습니다. (1)

검색의 경직성: 기존 시스템은 정적인 방식을 채택합니다. 질의 복잡성을 기반으로 합리적인 판단과 계획을 세우지 못하는 검색 전략. 임의의 쿼리에 대한 정확한 이해 복잡성을 고려하면 대규모 모델이 필요하며, 이는 계산 비용이 높은 접근 방식은 비효율적인 결과를 초래합니다. (2) 컴퓨팅 자원의 할당. 결함: 다중 모드 정보 질의응답은 단일화된 시각-언어 모델에 의존합니다. (VLM)은 엔드투엔드 생성을 위한 가상 언어 모델(VLM)입니다. 그러나 최근 연구에 따르면 VLM은 대규모 가상 언어 모델(Large Virtual Model)에 비해 추론 성능이 현저히 낮은 것으로 나타났습니다. 언어 모델(LLM)은 다음과 같은 문제를 야기합니다. "시각적 인식은 정확하지만 답은 틀렸습니다." 세대”(Wan and Yu, 2025).

본 논문에서는 AutothinkRAG를 제안합니다. 앞서 언급한 문제들을 해결하기 위한 프레임워크. 정보 검색의 경직성을 해결하기 위해 우리는 오토싱크(Autothink)를 설계했습니다. 경량 인지 라우터는 동적으로 작동합니다. 쿼리 구문 분석을 기반으로 검색 경로를 선택합니다. 복잡성 평가를 통해 컴퓨팅 리소스를 필요에 따라 할당할 수 있습니다. 추론 문제를 해결하기 위해 결핍 문제를 해결하기 위해, 우리는 VLM의 역할을 "시각적 설명자"로 제한하는 시각 및 추론 분해(DPR) 아키텍처를 제안합니다.

그리고 논리적 통합 작업을 LLM에게 위임합니다. 더 정확한 추론을 달성하면서도 손실은 없습니다. 관련 정보.

- 우리의 기여는 네 가지입니다.
  - 본 논문에서는 MinerU 기반 구문 분석을 통합한 확장 가능한 아키텍처인 AutothinkRAG를 소개합니다. 하이브리드 그래프-벡터 스토리지를 통해 효율성과 정확성 사이의 새로운 파레토 최적 경계를 설정합니다.
  - 우리는 Autothink 라우터를 다음과 같은 기능을 처리하도록 설계했습니다. 복잡성을 알 수 없는 쿼리; 이를 활용하여 경량 소형 언어 모델(SLM) 심층적인 복잡성 분석 및 작업 분해를 위해 이 모델은 적응형 실행 경로 선택을 가능하게 하여 효과적으로 문제를 해결합니다. 검색 강성이라는 과제.
  - 본 논문에서는 정보 변환을 명시적으로 분리하는 다중 모드 문제 해결을 위한 분리형 패러다임을 소개합니다.

추론 단계. 이 접근 방식은 다음을 다룹니다. 기존 방법의 한계는 다음과 같습니다. VLM을 사용한 엔드투엔드 직접 추론.

- 두 가지 문서 이해에 대한 실험 AutothinkRAG의 벤치마크 디스플레이 최첨단 성능을 달성합니다 대규모 모델에 의존하지 않고.

2. 관련 연구

2.1 그래프 기반 검색 증강 세대

전통적인 검색 증강 생성(RAG) 청킹과 벡터 검색에 의존하지만, 종종 분산된 증거의 위치 파악에 미흡하다 길고 여러 문서로 구성된 데이터에 대한 멀티홉 추론 컨텍스트. GraphRAG (Edge et al., 2024a) 는 다음을 다룹니다. 이는 검색 단위 간의 관계를 모델링함으로써 가능해집니다. 구조화된 검색 및 추론을 가능하게 하는 그래프. 후속 연구에서는 (i) 경량/임시 그래프를 통해 효율성과 증거 범위를 개선합니다. 및 다단계 검색(LightRAG (Guo et al., 2024), REANO (Fang 외, 2024a), HopRAG (Liu et al., 2025) 및 (ii) 후보 부분 그래프/경로 추출을 통한 다중 홉 증거 구성 구조화된 증거 사슬 형성(GNN-RAG (Mavromatis and Karypis, 2024), TRACE ) 증거 (Fang et al., 2024b), PathRAG (Chen et al., 2025a)). 계층적 설계는 다중 세분화 추론을 더욱 지원합니다 (ArchRAG (Wang) ). et al., 2025a), 지역에서 세계로 (Edge et al., 2024b)) 를 통해 견고성이 강화됩니다. 부분 그래프 가지치기, 부분 그래프 수준 검색 또는 외부 그래프 지식 (G-Retriever (He et al., 2024), RAGRAPH (Jiang et al., 2024)). 이진 관계를 넘어서 , 하 이퍼그래프 및 고차 관계 모델링은 표현력을 향상시키고 감소시킵니다. 복잡한 추론에서의 정보 손실(Hyper- GraphRAG (Luo et al., 2025), 구조가 전부입니다) 필요함 (리 및 황)).

2.2 멀티모달 검색 증강 세대

멀티모달 RAG는 텍스트 기반 RAG를 다음과 같이 보강합니다. 외부 지식 자료로서의 이미지 및 비디오 매개변수 메모리의 한계 완화(RA- TTA (Lee et al., 2025), MMed-RAG (Xia et al.,) 2024년)); 그러나 많은 시스템은 여전히 이에 의존합니다. 텍스트화 또는 단일 모달리티 정렬은 세밀한 교차 모달리티 정보 보존을 방해합니다. 구조. 시각적으로 풍부한 문서를 위해서는 전체 페이지를 사용하십시오. 시각적 검색 장치는 OCR/선형화 손실을 방지합니다. (VisDOM (Suri et al., 2025), VisRAG (Yu et al., 2024), ColPali (Faysse et al., 2024)). 이미지 캡 셔닝 및 VQA에서 견고성 문제(예: 검색) 불안정성 및 빈도 편향은 일반적으로 다양한 검색 및 후기 상호 작용을 통해 완화됩니다. 메커니즘. 긴 동영상의 경우, 세그먼트 수준 또는 질의 정보를 고려한 검색은 계산 비용을 줄입니다. (VideoRAG (Ren et al., 2025)). 검색도




그림 2: AutothinkRAG 개요. 이 프레임워크는 네 가지 주요 단계로 구성됩니다. (1) 정보 추출: 이질적인 다중 모달 데이터가 수집됩니다. (2) 데이터 처리: 레이아웃 분석을 통해, 이 시스템은 데이터를 텍스트 덩어리와 이미지 인덱스로 분할한 다음, 반복적인 "추출-판단" 루프를 통해 구성합니다. 그래프 지식 기반. (3) 데이터 랭커: 하이브리드 검색 메커니즘은 기존의 Top-K 벡터를 통합합니다. 그래프 기반 병합을 이용한 검색을 통해 복잡한 엔티티 관계를 포착합니다. (4) 추론 및 응답: 쿼리 라우터는 원래 쿼리를 하위 쿼리 (Q1, Q2, Q3)로 분해한 다음, 이러한 하위 쿼리들을 분리된 과정을 통해 처리합니다. 관련 텍스트와 시각적 단서를 모두 활용하여 최종 응답을 종합하는 지각 추론 아키텍처.

## 시각-언어 대조 학습의 이점 및

일반화 및 정렬 개선을 위한 생성 (검색 강화 VLM (Iscen et al., 2023))

GarmentAligner (Zhang et al., 2024)); 도메인에서 의료 및 콘텐츠 검토와 같은 분야에서는 높은 신뢰도 또는 개인화된 사전 정보를 도입합니다.

시스템 복잡성 증가로 인한 비용 (Sun et al., 2025년).

## 2.3 문서 이해

### 검색 증강 생성

문서가 많고 내용이 복잡한 QA에는 제약이 있습니다.

문맥 길이와 증거 위치 파악 난이도에 따라 검색 정확도가 달라집니다. 최근 방법들은 논리적 추론을 통해 검색 세분성과 문맥 패킹을 개선합니다.

블록 분해 및 반복 검색(Document Haystacks (Chen et al., 2025b)), 문서 재구성 및 적응형 병합(Virtual)

문서 (Mass et al., 2024), 문서 분할의 중요성 (Wang et al., 2025c)) 및

구조화된 색인 또는 계층적 요약

(PdfTriage (Saad-Falcon 외, 2024), MemSum-DQA (Gu 외, 2023), BookRAG (Wang et al., 2025b)). 고전적 패러다임은 확립한다.

세밀한 국소화로의 전환(동적 콘텐츠)

네트워크 (Xiong et al., 2016), 거친 단계에서 미세 단계로 QA (Choi et al., 2017) 및 이후 작업 모델

글로벌 구조 및 답변 계층 구조(압축 그래프 선택기 네트워크 (Nie et al.,

2022), 청킹을 넘어서 (Chen et al., 2026));

문서 간 추론을 위해 링크 인식 사전 학습은 문서 간 의미 모델링을 더욱 강화합니다 (Yasunaga et al., 2022). 검색과 생성은 점점 더 밀접하게 연관되고 있습니다.

반복/교정 방식을 통해 (Generate-then-Ground (Shi et al., 2024), REAR (Wang et al., 2024), 액티브 RAG (Jiang et al., 2023), 반복적 검색-생성 시너지 (Shao et al., 2023)

IAG (Zhang et al., 2023)). 시각적으로 풍부한 문서의 경우, 멀티모달 문서 RAG는 다음을 통합합니다.

다중 페이지 이해를 위한 레이아웃, 엔티티 및 지식 구조 (REVEAL (Hu et al., 2023))

VDocRAG (Tanaka et al., 2025), VisDoM (Suri 등, 2025), MMGraphRAG (Wan 및 Yu, 2025));

에이전트 기반 방법은 견고성을 더욱 향상시킵니다.

다중 에이전트 협업 및 반복적인 피드백을 통해 (DocAgent (Yang 외, 2025), DocLens (Zhu 외, 2025), Doc-React (Wu et al., 2025)).

## 3. 방법론

이 섹션에서는 먼저 전체 워크플로를 소개합니다.

AutothinkRAG. 그 후, 우리는 다음을 명시합니다.

정보 추출, 저장 및 전략

전송. 마지막으로 구현에 대해 자세히 설명합니다.

쿼리 복잡도 라우터 및 기능

분리형 아키텍처.

3.1 전체 워크플로

AutothinkRAG는 멀티모달 문서 질의응답(DocQA) 작업을 다음과 같이 분해합니다.  
의도 인식 라우팅 및 분리된 추론,  
그림 2에 나타난 바와 같이, 엔드투엔드 추론  
이 프로세스는 공식적으로 다음과 같이 정의됩니다.

$$A = \Psi(Q, D) = \text{LLM}(T_v, R, I_p) \tag{1}$$

여기서 Q는 입력 쿼리, D는 문서 모음, R은 검색된 관련 컨텍스트,  $T_v$ 는 텍스트화된 시각적 증거,  $I_p$ 는 추론이다.  
경로 지침이며, A는 최종 합성 결과입니다. 워크플로는 세 가지 핵심 단계를 거쳐 진행됩니다.  
단계:

1. 지식 기반 구축: 시스템

D를 메타데이터를 포함하는 콘텐츠 블록 b로 파싱합니다 .  
 $M_b = \{T, C, B, P, S\}$ , 포괄적인 유형,  
콘텐츠, 공간 좌표, 페이지 및 저장소  
경로. 이것들은 하이브리드 그래프에 통합됩니다.  
지식 기반(GKB) 및 벡터 저장소  
공간-의미론적 검색을 지원합니다(자세한 내용은 [제 3.2절](#)에 설명되어 있습니다).

2. 질의 복잡성 라우팅(QCR) :

각 쿼리 Q에 대해 QCR은 실행 전 분석을 수행하여 복잡도 레이블  $c(Q) \in \{\text{단순}, \text{보통}, \text{복잡}\}$ 을 출력 합니다 .

그리고 라우팅 지침 IP를 사용합니다. 이 단계에서는 하위 쿼리 분해를 결정하고 리콜 모듈 R에 대한 검색 경로를 최적화 합니다.

(자세한 내용은 3.3.1절에 설명되어 있습니다.)

3. 인지 및 추론 분해 (DPR):  $I_p$ 에 따라 시스템은 정보를 가져옵니다.  
컨텍스트 R을 통해 원시 시각적 자산을 호출합니다.  
경로 S. 훈련이 필요 없는 소규모 VLM  
구조화 된 텍스트 설명  $T_v$ 를 생성하는 시각적 해석기 역할을 합니다 . 마지막으로 고성능 LLM은  $\{T_v, R\}$ 을 통합하여  $I_p$  (3.3.2절에 자세히 설명 )에 따른 엄격한 연역을 통해 최종 답변 A를 합성합니다 .

AutothinkRAG는 지각과 추론을 기능적으로 분리함으로써 독립형 모델의 논리적 병목 현상을 해소하고 광범위한 멀티모달 컨텍스트 전반에 걸쳐 견고한 이해를 보장합니다.

3.2 정보 추출, 저장 및 전염

복잡한 멀티모달 추론을 지원하기 위해, 우리는 높은 정확도의 정보 처리 파이프라인을 설계했습니다.

이 파이프라인은 PDF, PPT 등 다양한 형식의 문서를 구조화된 형식으로 변환하도록 설계되었습니다.  
그리고 검색 가능한 지식 시스템을 유지하면서 보존합니다.  
원래의 공간 배치와 의미적 완전성.

3.2.1 고충실도 구문 분석 및 메타데이터 추출

우리는 강력한 구문 분석 엔진(예: MinerU)을 사용합니다.  
입력 문서에 대한 심층 분석을 수행하기 위해  
D. 구문 분석 출력은 구조화된 형태로 구성됩니다.  
분해된 콘텐츠 블록이 포함된 JSON 파일  
B와 멀티모달 객체를 위한 자산 저장소  
(이미지, 표, 방정식). 추출된 각 항목에 대해  
블록  $b \in B$ 에 대해 메타데이터 튜플  $M_b =$  를 유지합니다.  
 $\{T, C, B, P, S\}$ , 여기서:

- T는 유형 (예: 텍스트, 이미지 또는 기타) 을 나타냅니다. (ble);
- C는 원본 콘텐츠 또는 캡션을 나타냅니다. 블록과 관련;
- B는 경계 상자 (Bbox) 좌표 입니다. 공간적 위치 파악을 위해;
- P는 페이지 번호를 나타냅니다.
- S는 스토리지 경로이며, 고유한 역할을 합니다. 자산 이전 지표.

3.2.2 차별화된 정보 처리

이 시스템은 콘텐츠 유형에 따라 두 부분으로 나뉘는 이미지 추출 논리를 구현합니다.

- 텍스트 스트림: 원시 텍스트가 직렬화됩니다.  
1,200개의 토큰으로 구성된 슬라이딩 윈도우를 사용하여 100개의 토큰이 겹치도록 청크로 분할했습니다.  
이어서 정보 추출(IE)이 수행됩니다.  
모듈은 엔티티 및 관계 트리플릿을 식별합니다.  
각 덩어리에서.
- 멀티모달 스트림: 텍스트 이외의 자산의 경우,  
이 시스템은 상세한 의미론적 설명을 생성합니다 . 원본 캡션은 이 설명과 연결되어 증강 표현을 형성하고, 이어서 IE를 통해 정렬됩니다.

글로벌 지식을 활용한 시각적 개념 개요.

3.2.3 하이브리드 에너지 저장 및 전송 규약

처리된 정보는 이중 계층 저장 아키텍처에 통합됩니다 .

1. 그래프 지식 기반(GKB): 당사는 그래프 지식 기반을 활용합니다 .  
엔티티 모호성 해소 및 병합을 위한 하드 매칭 알고리즘을 사용하여 전역 변수를 구성합니다.  
관계형 그래프.
2. 벡터 저장소: 모든 엔티티, 관계 및 텍스트  
청크는 밀집 임베딩으로 매핑됩니다.  
공간이며, S, B, P 는 속성으로 인덱싱됩니다.

정보 전달 메커니즘 .  
이 프레임워크는 메타데이터 기반 프로토콜을 통해 효율적인 모듈 간 전송을 가능하게 합니다 . 검색 시 저장 경로 S는 직접적인 원시 멀티모달 데이터를 허용합니다.  
VLM으로 데이터 전송이 진행됩니다. 한편, 시스템은 B 와 P 를 활용하여 인접한 컨텍스트 정보를 가져옵니다.  
원본 문서에서 효과적으로 연결됩니다.  
분리된 조각들 사이의 "정보 격차"  
그리고 그것들의 출처 맥락.

3.3 자동 사고 라우터 및 기능  
분리형 아키텍처

이 섹션에서는 쿼리 복잡성 측정기의 설계 동기와 기술적 구현에 대해 자세히 설명합니다.  
라우터(QCR)와 지각 및 추론 분해 (DPR) 전략.

3.3.1 질의 복잡성 라우터(QCR)  
RAG 시스템의 정확도는 근본적으로 쿼리 의도와 결과 간의 연관성에 의해 제약됩니다.  
상응하는 컨텍스트, 파이프라인의 순차적 특성을 고려할 때 , 쿼리 이해는 다음과 같은 역할을 합니다.  
심각한 병목 현상입니다. 문의 사항을 처리할 때  
복잡성이 알려지지 않은 기존의 엔드투엔드  
이러한 접근 방식은 종종 대규모 모델을 필요로 합니다.  
암묵적인 의미나 중첩된 문제를 분석하여 발생하는 비용 높은 비용. QCR은 쿼리 복잡성을 직접 평가하여 후속 작업에 영향을 줌으로써 이 문제를 해결합니다.  
검색 및 처리 경로를 통해 간접적으로  
모델 정확도를 높이기 위해 SLM을 사용합니다.  
쿼리가 분해를 필요로 하는지 여부를 판단합니다.  
하위 질문으로 나누고 최적의 실행 경로로 연결합니다.  
최소한의 계산 비용으로 경로를 찾습니다.  
기술적 구현: 라우터가 추출합니다  
Q에서 제시하는 세 가지 기능 범주:

- (a) 의미론적 특징: 핵심 의도를 포착합니다.  
(예: 사실 검색, 비교 추론)  
인과 분석);
- (b) 요소 특징: 엔티티  $|E(Q)|$ , 시각적 참조  $|M(Q)|$  및 제약 조건을 계산합니다.
- (c) 종속성 기능: 교차 청크/다단계 추론 요구 사항( $ctx(Q)$ )을 식별합니다.

이를 바탕으로 QCR은 복잡도를 할당합니다.  
레이블  $c(Q)$ 를 지정 하고 라우팅 지침을 생성합니다.  
구체적으로, 지역화된 증거에 의존하는 쿼리는 단순 쿼리로 간주되는 반면, 다중 엔티티, 다중 모드 집계 및

다단계 추론은 복잡한 것으로 간주됩니다.

| 의사       | 유형                           |      |      |      | 도메인  |      |           |      | 모두   |      |      |      |
|----------|------------------------------|------|------|------|------|------|-----------|------|------|------|------|------|
|          | 학술 금융 정부 법률 뉴스 문자 메시지 음. 우나. |      |      |      |      |      |           |      |      |      |      |      |
| LLM 41.3 | MLLM                         | 16.3 | 50.7 | 49.7 | 16.3 | 28.4 | 77.3      | 53.9 | 20.1 | 75.8 | 44.8 |      |
| 19.8     |                              | 31.4 | 46.5 | 35.7 |      |      |           | 15.9 | 39.5 | 27.7 |      |      |
|          |                              |      |      |      |      |      |           |      |      |      |      |      |
| MM       | 위치                           |      |      |      | 형식   |      |           |      | 전반적인 |      |      |      |
|          | 죄. 물. 우나. CT 텍스트. 레이. 그림.    |      |      |      |      |      |           |      | 모두   |      |      |      |
| LLM 22.5 | 20.0                         | 53.2 | 14.7 | 33.3 | 23.5 | 16.1 | MLLM 13.3 | 13.9 | 8.4  | 10.7 | 11.8 | 11.4 |
|          |                              |      | 7.9  |      |      |      |           |      |      |      | 27.8 | 11.6 |

표 1: VLM과 의 비교 실험 결과  
DocBench 및 MMLongBench 벤치마크에서 LLM.

3.3.2 DPR을 통한 기능적 분리  
최근 연구에 따르면 VLM은 LLM에 비해 논리적 추론 능력이 현저히 떨어지는 것으로 나타났 으며, 특히 문서 관련 질문에서 이러한 경향이 두드러진다.  
답변할 수 없는 질문이 포함된 작업에 답변하기.  
MMGraphRAG (Wan and Yu, 2025)에 보고된 바와 같이, LLM 기반 시스템은 DocBench 및 MMLong-Bench 벤치마크에서 멀티모달 모델보다 일관되게 우수한 성능을 보입니다. 특히, VLM 기반 모델은 특정 상황에서 왜곡된 답변을 생성하는 경향이 있습니다.  
필요한 증거가 없습니다(표 1 참조). 장문 문서 다중 모드 QA에서 시각적  
인지, 페이지 간 증거 정렬 및 추론은 단일 세대 내에서 간밀하게 연결되어 있어 모델이 연쇄적인 오류를 일으키기 쉽습니다.

증거의 정렬이 미흡하면 과도한 투자가 발생합니다.  
신뢰할 수 있는 기원 대신 근거 없는 답변으로 이어집니다. 반대로, VLM은 지각 후 서술적 작업에서 우수한 성능을 보여줍니다 . 따라서 우리는 분리된 지각(Decoupled Perception)을 제안합니다.

DPR(디지털 추론) 전략, 작업 분할  
두 개의 전문화된 하위 프로세스로 나눕니다.

1. 시각적 지각(소규모 VLM): A  
경량 VLM(예: Qwen2.5-VL-3B)  
시각적 해석기 역할을 하며, 생성합니다.  
훈련 없이 TV를 구조화된 방식으로 설명합니다 .  
제로샷 모드:  
$$T_v = VLM_{small}(v, P) \tag{2}$$
2. 논리적 추론(LLM): 멀티모달  
DocQA는 텍스트 전용 추론으로 변환됩니다 . 통합 컨텍스트  $C = \{T_v\} \cup R(Q, D) \cup \{Intent(Q)\}$ 가 구성됩니다. 그러면 LLM이 생성됩니다.

| 방법           | 도메인   |       |       |       |       |       |       | 유형    | 전반적인  |
|--------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
|              | 아카.   | 지느러미. | 정부.   | 법률.   | 뉴스.   | 문자.   | 음.    |       |       |
| AutothinkRAG | 80.16 | 75.40 | 85.71 | 87.09 | 92.50 | 86.43 | 77.31 | 81.25 | 82.13 |
| 생각하지 마세요     | 77.34 | 73.46 | 80.59 | 85.29 | 88.78 | 84.08 | 76.12 | 77.84 | 79.37 |
| VLM만 기준선     | 77.03 | 74.00 | 81.54 | 84.39 | 89.26 | 85.32 | 75.09 | 76.42 | 79.47 |
| 으로 사용        | 76.34 | 72.93 | 79.77 | 84.07 | 84.52 | 84.65 | 74.47 | 75.83 | 78.02 |
| RAG-Anything | 74.90 | 70.68 | 77.41 | 83.06 | 81.67 | 84.21 | 76.36 | 52.80 | 75.47 |

표 2: DocBench 데이터셋에 대한 정확도(%). 도메인 범주에는 학계(Aca.), 금융(Fin.)이 포함됩니다. 정부(Gov.), 법률 문서(Law), 뉴스 기사(News)로 문서 유형이 분류됩니다. 텍스트 전용(Txt.), 멀티모달(Mm.) 및 답변 불가능한 쿼리(Una.).

| 방법           | 도메인   |       |             |       |       |       |       | 전반적인  |
|--------------|-------|-------|-------------|-------|-------|-------|-------|-------|
|              | 레스.   | 투스.   | 학술 안내 책자 관리 |       |       |       | 지느러미. |       |
| 오토싱크RAG      | 44.86 | 52.20 | 52.26       | 52.34 | 51.00 | 62.19 | 56.14 | 51.29 |
| 생각하지 마세요     | 43.15 | 48.55 | 43.21       | 52.25 | 46.00 | 53.08 | 50.42 | 47.21 |
| VLM(직접)      | 41.43 | 49.27 | 43.43       | 52.25 | 41.00 | 54.32 | 48.72 | 45.55 |
| VLM(무유도)     | 42.07 | 51.12 | 45.24       | 52.34 | 43.00 | 55.78 | 50.13 | 47.21 |
| 기준선          | 40.41 | 47.82 | 42.42       | 50.96 | 42.00 | 51.85 | 46.15 | 44.86 |
| 8B           | 42.80 | 44.12 | 43.21       | 52.34 | 46.00 | 50.61 | 50.42 | 46.09 |
| RAG-Anything | 41.09 | 41.30 | 44.22       | 45.16 | 40.00 | 54.32 | 52.13 | 44.36 |

표 3: 다양한 도메인 및 전반적인 성능에 대한 MMLongBench의 정확도(%). 도메인 범주 연구 보고서/소개서(Res.), 튜토리얼/워크숍(Tut.), 학술 논문(Acad.), 안내서 등이 포함됩니다. (가이드), 브로셔(Broch.), 관리/산업 파일(Admin.), 재무 보고서(Fin.).

경로별 지침에 따라 답변 A 를 종합합니다 .

- 간단: "대상 행/열 추출"  
테이블 설명에서 얻은 값입니다.
- 중급: “ 표 설명을 사용하여 데이터를 계산/비교합니다 (단계별 설명 포함).”
- 복잡한 경우: "여러 테이블/텍스트 데이터 통합"  
단계별 분석을 위해서요.

A = LLM(C, Instruction(c(Q))) (3)

지각과 추론을 분리함으로써,  
LLM은 정확한 텍스트화된 시각적 증거에 대해 엄격한 추론을 수행하여 효과적으로 두 영역을 연결합니다.  
독립형 멀티모달 모델의 추론 격차.

### 4가지 실험

이 섹션에서는 AutothinkRAG의 효과성을 실증적으로 검증합니다. 우리의 목표는 다음과 같은 문제를 해결하는 것입니다.  
두 가지 주요 연구 질문: (1) 비교

정적 검색에서 Autothink 라우터는 환각을 효과적으로 줄이고 복잡한 상황을 처리할 수 있을까요?  
쿼리 의도는 무엇입니까? (2) 분리된 인식-추론(DPR) 아키텍처는 다양한 길이의 멀티모달 문서를 포함하는 추론 작업에서 우수한 성능을 보여줍니까?

#### 4.1 실험 장치 구성

벤치마크. 우리는 두 가지 기준으로 프레임워크를 평가합니다 .

종합적인 멀티모달 벤치마크:

- DocBench : 5개 분야를 포괄하는 다양한 데이터 세트 영역 (학술, 금융, 정부, 법률, 뉴스) 및 세 가지 검색 유형(텍스트 전용, 다중 모드 및 답변 불가능). "답변 불가능 " 범주는 특히 중요합니다.  
모델의 환각 및 거부 능력 평가 .
- MMLongBench : 벤치마크 도구로 설계되었습니다.  
다양한 맥락에 걸쳐 장기적인 이해도를 테스트합니다.




그림 3: 문서 길이에 따른 라우팅 전략 분포 비교. 이 그림은 다음을 보여줍니다. 사고 모드와 비사고 모드에서 길이 간격 내 그래프 및 하이퍼그래프의 선택 비율.

모델이 필요로 하는 문서 유형(예: 연구 논문, 매뉴얼, 재무 보고서) 여러 페이지에 걸쳐 있는 정보를 종합합니다. 그리고 방식들.

#### 4.2 구현 세부 사항

AutothinkRAG에 대한 실험적 평가에서, 우리는 분리된 아키텍처를 특징으로 하는 다중 모델 협업 프레임워크를 구현합니다. 구체적으로, 우리는 Qwen2.5-VL-3B를 사용합니다. Autothink Router는 글로벌 작업 오케스트레이션 및 의도 스케줄링을 용이하게 합니다. 지식 구축 단계에서는 Qwen3-8B (비추론)를 사용합니다. 버전은 견고한 엔티티 및 관계 추출, 검색 정확도를 최적화하기 위해 Qwen3-embedding-8B (1024-)를 채택합니다. 밀집 벡터 표현을 위한 차원 임베딩)에 이어 bge-reranker-v2-m3가 적용됩니다. 세밀한 재순위를 위해, 분리된 시각-추론(DPR) 패러다임을 구현하기 위해, 우리는 복잡한 시각 정보를 정제하는 Perception Expert로서 Qwen2.5-VL-7B를 사용합니다. 뻘뻘한 텍스트 설명으로 그 후, Qwen3-32B-Instruct는 고수준 논리적 추론을 실행하는 추론 전문가 역할을 합니다. 통합된 컨텍스트에서, 하이퍼 파라미터 구성과 관련하여 모든 생성 모델은 설정됩니다. 온도는 0.7 이고 Top-p 값은 0.9입니다. 검색 단계에서 Top-K를 설정했습니다.

엔티티 리콜은 40 까지 가능 하며 검색된 텍스트 수는 다음과 같습니다. 충분한 맥락 범위를 확보하기 위해 체크 수를 20 으로 제한합니다.

#### 4.3 주요 결과

DocBench에서의 성능. 표 2 는 다음과 같습니다.

AutothinkRAG는 최고의 전반적인 정확도를 달성했습니다. 82.13% 의 수치를 기록하며 기준치(78.02%)를 상회했습니다. 가장 큰 폭의 상승은 Unanswerable(Una)에서 나타납니다. 정확도가 52.80%에서 81.25% 로 향상됩니다. (+28.45%), 이는 오토 씹크 라우터가 불충분한 증거를 탐지하는 데 효과적임을 나타냅니다.

#### 환각 증상 감소. 지속적인 개선

뉴스 부문 (+10.83%)과 정부 부문 (+8.30%) 에서 상승세를 보였습니다. 이는 단순 벡터 검색을 넘어 복잡한 개체 관계를 모델링하는 데 있어 하이브리드 하이퍼그래프 검색의 장점을 더욱 입증합니다.

MMLongBench에서의 성능. 표 3은 장시간 컨텍스트 작업에 대한 결과를 보여줍니다. Auto-thinkRAG는 기준 모델보다 지속적으로 우수한 성능을 보였습니다.

모든 문서 범주에 걸쳐 51.29% 의 전반적인 정확도 (+6.43%)를 달성했습니다. 기준선은 긴 문서의 시각적 노이즈 처리에서 어려움을 겪는 반면, 당사의 DPR 아키텍처는 관리 (+10.34%) 및 재무 (+9.99%) 와 같은 복잡한 범주에서도 여전히 효과적이며, "추론 격차"를 해소합니다.

#### 시각적 신호를 텍스트 설명으로 변환

그리고 종합적인 분석을 전문 LLM 과정에 위임합니다.

AutothinkRAG의 효율성을 정량화하기 위해, 우리는 쿼리별 토큰 소비량 및 모니터링을 분석합니다.




그림 4: VLM 출력을 변환하는 접근 방식  
LLM은 여러 페이지로 구성된 긴 문서를 처리할 때 정확도를 크게 향상시킵니다.

총비용(표 4 및 표 5). 전체 추론은 질의 라우팅 (Qwen2.5-VL-3B), 시각적 설명 생성 (Qwen2.5-VL-7B), 최종 답변 합성의 세 단계로 구성됩니다.

(LLM). 합성 단계의 입력 컨텍스트  
주요 비용 항목입니다. 라우팅이 없으면,  
순수 하이퍼그래프 검색은 LLM에 상당한 중복 컨텍스트를  
제공하며, 이로 인해 63,000 토큰이 소모됩니다.  
쿼리당 0.132위안. 오토싱크 라우터를 사용하는 경우,  
합성 입력값이 51.4k로 크게 감소했습니다.  
토큰/0.108위안, 18.9% 절약 효과  
그리고 각각 18.2%입니다. 이는 다음을 보여줍니다.  
라우터는 불필요한 장문 컨텍스트를 효과적으로 방지합니다.  
검색 경로를 동적으로 선택하여 추론합니다.  
쿼리 복잡성에 따라.

#### 4.4 기준선

실험의 엄밀성과 공정성을 보장하기 위해 우리는 다음과 같은 시스템을 구축했습니다.  
기준 모델을 사용했으며 동일한 모델을 적용했습니다.  
RAG-Anything (Guo et al., 2025) 에서 테스트  
그리고 비교. 기본 구성에서 우리는  
쿼리 분해를 우회하고 VLM을 사용합니다.  
직접적인 엔드투엔드 추론을 위해, 대신  
우리가 제안하는 분리형 패러다임. RAG-Anything 벤치마크  
의 경우, 내부 값을 대체합니다.  
당사에서 사용하는 특정 모델을 포함하는 구성 요소  
프레임워크를 유지하고 동일한 하이퍼파라미터를 적용합니다.  
통제된 비교를 보장하기 위한 구성.

#### 4.5 절제술 연구

제안된 아키텍처의 우수성을 입증하기 위해 라우팅 및 디커플링  
을 체계적으로 제거하는 어블레이션 연구를 수행했습니다.

각각 모듈별로 수행했습니다. 또한, 우리는 다음과 같은 작업을 수행했습니다.

다양한 페이지 범위에 걸쳐 관련 성능 지표에 대한 심  
층 분석을 통해 이러한 구성 요소의 효율성을 입증하  
입니다.

자동 사고 라우터의 효율성. 당사의 임의 질의 라우터는 3B를 사용  
하여 구현되었습니다.

소규모 언어 모델(SLM). 그 기여도를 평가하기 위해, 우리  
는 다음과 같은 제거 연구를 수행했습니다.

라우터가 제거되는 동안 후속 분리가 진행됩니다.  
추론 모듈은 유지됩니다. 다양한 페이지 범위에 걸친  
하이퍼그래프의 분포를 보고합니다.

(그림 3) 및 다양한 시나리오에 걸친 정확도 (표 3). 결과는 SLM  
이

라우터는 하이퍼그래프의 비율을 크게 줄여주며, 이러한 효과는  
더욱 두드러지게 나타납니다.

문서 길이가 증가함에 따라. 이는 다음을 나타냅니다.

라우터가 정보 유출을 효과적으로 완화한다는 것  
초기 질의 처리 과정에서의 구조적 복잡성으로 인해 정확도가  
향상됩니다.

복잡한 추론 작업을 단순화함으로써, 예를 들어  
다중 단계 질의응답.

| 관로                      | 이미지 설명 요약 총계 |       |       |
|-------------------------|--------------|-------|-------|
| 하이퍼그래프 2.7k 라우팅 강화 2.7k |              | 60.3k | 63.0k |
|                         |              | 48.3k | 51.4k |
| 저축(절대값)                 | -            | 12.0k | 11.6k |
| 저축(상대적)                 | -            | 19.9% | 18.9% |

표 4: 단계별 토큰 비교.

| 관로                          | 이미지 설명 요약 총계 |        |       |
|-----------------------------|--------------|--------|-------|
| 하이퍼그래프 0.0084 라우팅 향상 0.0084 |              | 0.1239 | 0.132 |
|                             |              | 0.0984 | 0.108 |
| 저축(절대값)                     | -            | 0.0255 | 0.024 |
| 저축(상대적)                     | -            | 20.6%  | 18.2% |

표 5: 단계별 비용 비교.

지각 분해의 효과성

그리고 추론. 저희의 분리 모듈은 VLM의 직접 추론을  
VLM+LLM 하이브리드 간접 추론 패러다임으로 변환합니다.

효능을 평가하기 위해 절제술 연구를 진행합니다.

이 모듈을 독립형 LLM으로 교체함으로써  
상류를 유지하면서 추론 구성 요소를

라우터 상수. 우리는 정확도를 평가합니다.

그림 4에 나타난 바와 같이 다양한 페이지 범위.

결과는 직접적인 VLM 추론과

시각 인식을 위한 비유도 VLM 분리

장문 문서 설정은 성능이 상당히 떨어집니다.

제안된 완전 분리 프레임워크는 다음과 같습니다.

성과 격차가 더욱 두드러지게 나타나고 있습니다.

문서 길이가 늘어납니다.

5. 결론

본 논문에서는 쿼리 복잡성 라우터와 기능적으로 분리된 파이프라인을 결합한 다중 모델 협업 프레임워크인 AutothinkRAG를 소개합니다. 장기적인 맥락과 정보 과부하 문제를 해결하기 위해 정보 집약적인 문서 품질 보증(DocQA)의 과제. 저자: 경량 VLM을 고충실도 도구로 활용

시각적 해석기와 논리적 추론을 위한 LLM을 결합한 AutothinkRAG는 DocBench와 MMLongBench에서 최첨단 성능을 달성 하는 동시에 추론 비용을 크게 절감했습니다. 광범위한 실험 과 제거 실험을 통해 그 효과가 입증되었습니다 .

라우터와 분리형 아키텍처 모두 마찬가지입니다.

제한 사항

AutothinkRAG는 기존의 멀티모달 GraphRAG에 비해 상당한 성능 향상을 달성했습니다. 매개변수가 더 적은 모델을 사용하는 아키텍처, 여전히 순차적인 문서 구문 분석에 의존합니다. 파이프라인 내장으로 인해 전체 처리 속도가 제한됩니다. 향후 연구에서는 이 부분을 집중적으로 다룰 예정입니다. 문서의 효율적인 결합을 달성하기 위해 구문 분석 및 정보 인코딩을 통해 개선 전반적인 처리 속도 및 정확도.

윤리적 고려사항

우리의 모든 실험은 널리 사용되는 자료를 이용하여 수행됩니다. 본 연구에서는 학술 연구 목적으로 선별된, 채택되고 인정받은 오픈 소스 데이터셋을 사용했습니다. 따라서 이러한 데이터셋에는 부적절하거나 민감한 정보가 포함되어 있지 않습니다 . 본 프레임 워크는 최첨단 성능을 달성하지만, 모델이 또한 최첨단 기술을 기반으로 구축되었음을 인지하는 것이 중요합니다. 커뮤니티 주도형 오픈 소스 모델을 기반으로 완벽하지 않습니다. 따라서 사용자는 연습해야 합니다. 생성된 정보에만 전적으로 의존하지 말고 주의를 기울이십시오. 결과. 실제 적용에서는 정확성을 보장하기 위해 사람의 개입이 권장됩니다.

참고 자료

Boyuan Chen, Zirui Guo, Zidan Yang, Yuluo Chen, Junze Chen, Zhenghao Liu, Chuan Shi 및 Cheng Yang. 2025a. [Pathrag: 관계형 경로를 이용한 그래프 기반 검색 증강 생성의 가치치기](#). arXiv 사전출판물 arXiv:2502.14902.

Huiyao Chen, Yi Yang, Yinghui Li, Meishan Zhang, Baotian Hu, Min Zhang. 2026. [청킹을 넘어서 : 장문 검색을 위한 담화 인식 계층적 검색 문서 관련 질문 답변](#).

Jun Chen, Dannong Xu, Junjie Fei, Chun-Mei Feng 및 모하메드 엘호세이니. 2025b. [문서 더미](#):

[1000개 이상의 문서 더미에 대한 시각-언어 추론 . 컴퓨터 비전 학회 논문집 및 패턴 인식 학회, 24817페이지 – 24826.](#)

최은솔, 다니엘 휴렛, 야콥 우슈코라이트, 일리아 폴로수킨, 알렉상드르 라코스테, 조나단 베란트. 2017년. [오랜 기간에 걸친 거친 질문에서 세밀한 질문으로의 답변 서류](#). 전산언어학회 제55차 연례 학술대회 논문집 (제1권: 장편 논문), 209~220쪽.

대런 에지, 하 트린, 뉴먼 쉐, 조슈아 브래들리, 알렉스 차오, 아프르바 모디, 스티븐 트루이트, 다샤 메트로폴리탄스키, 로버트 오사주와 네스, 그리고 조너선 라슨. 2024a. [지역에서 세계로: A 질의 중심 요약을 위한 그래프 래그\(graph rag\) 접근법](#). arXiv 사전 인쇄 arXiv:2404.16130.

대런 에지, 하 트린, 뉴먼 쉐, 조슈아 브래들리, 알렉스 차오, 아프르바 모디, 스티븐 트루이트, 다샤 메트로폴리탄스키, 로버트 오사주와 네스, 그리고 조너선 라슨. 2024b. [지역에서 세계로: A 질의 중심 요약을 위한 그래프 래그\(graph rag\) 접근법](#). arXiv 사전 인쇄 arXiv:2404.16130.

Jinyuan Fang, Zaiqiao Meng, Craig Macdonald. 2024a. [Reano: 검색 증강 최적화 지식 그래프 생성을 통해 독자 모델을 구축합니다](#). 제62회 연례 회의 회의록에서 전산언어학회(권) 1: 장문 논문), 2094~2112쪽.

Jinyuan Fang, Zaiqiao Meng, Craig Macdonald. 2024b. [증거 추적: 검색 증강을 위한 지식 기반 추론 사슬 구축 세대](#). arXiv 사전 인쇄 arXiv:2406.11460.

Manuel Faysse, Hugues Sibille, Tony Wu, Bilel Om-rani, Gautier Viaud, Céline Hudelot 및 Pierre 콜롬보. 2024. [Colpali: 비전 언어 모델을 이용한 효율적인 문서 검색](#). arXiv 사전 공개 논문 arXiv:2407.01449.

Nianlong Gu, Yingqiang Gao, and Richard HR Hahn-loser. 2023. [Memsum-dqa: 효율적인 장문서 추출 요약 도구의 적용](#)

[문서 관련 질문 답변](#). arXiv 사전 공개 논문 arXiv:2310.06436.

Zirui Guo, Xubin Ren, Linrui Xu, Jiahao Zhang 및 차오 황. 2025. [Rag-anything: 올인원 래그 뼈대](#). arXiv 사전 인쇄 arXiv:2510.12323.

Zirui Guo, Lianghao Xia, Yanhua Yu, Tu Ao 및 차오 황. 2024. [Lightrag: 간단하고 빠른 검색 증강 생성](#). arXiv 사전 공개 논문 arXiv:2410.05779.

Xiaoxin He, Yijun Tian, Yifei Sun, Nitesh Chawla, 토마스 로랑, 안 르쿤, 자비에 브레송, 브라이언 후이. 2024. [G-리트리버: 검색-증강 텍스트 그래프 이해 및 질문 답변을 위한 생성](#). 신경 정보 분야의 발전 처리 시스템, 37:132876–132907.

Ziniu Hu, Ahmet Iscen, Chen Sun, Zirui Wang, Kai-Wei Chang, Yizhou Sun, Cordelia Schmid, David A Ross, Alireza Fathi. 2023. [Reveal: 다중 소스 다중 모달 지식 메모리를 사용한 검색 증강 시각 언어 사전 훈련](#) . IEEE/CVF 컴퓨터 비전 학회 회의록에 수록 됨

패턴 인식에 관한 내용은 23369~23379페이지에 있습니다.

아흐메트 이센, 마틸데 카론, 알리레자 파티, 코델리아 슈미드. 2023. [검색 강화 대조적인 시각-텍스트 모델](#). arXiv 사전 공개 논문 arXiv:2306.07196.

Xinke Jiang, Rihong Qiu, Yongxin Xu, Yichen Zhu, Ruizhe Zhang, Yuchen Fang, Chu Xu, Junfeng Zhao, Yasha Wang. 2024. [Ragraph: 일반 검색 증강 그래프 학습 프레임워크](#). 발전 신경 정보 처리 시스템, 37:29948–29985.

Zhengbao Jiang, Frank F Xu, Luyu Gao, Zhiqing Sun, Qian Liu, Jane Dwivedi-Yu, 양이밍, 제이미 캘런, 그레이엄 노아빅. 2023. [능동적 검색 증강 세대](#). 2023년 학술대회 논문집 자연어 처리 분야의 경험적 방법론에 관한 학술대회 논문집 , 7969~7992쪽.

이재준과 황조이스지영. 구조는 다음과 같습니다 . 필요한 모든 것: 구조적 표현 학습 초관계형 지식 그래프. 42번째 국제 기계 학습 컨퍼런스.

이영준, 김도영, 강준혁, 지한 방씨, 송환준, 이재길. 2025. [라파: 시각-언어 모델을 위한 검색 증강 테스트 시간 적응](#) . 제13차 인터내셔널에서 학습 표현에 관한 컨퍼런스.

Hao Liu, Zhengren Wang, Xi Chen, Zhiyu Li, Feiyu Xiong, Qinhan Yu, Wentao Zhang. 2025. [Hoprag: 논리 인식을 위한 다중 홉 추론 검색 증강 생성](#). arXiv 사전 공개 논문 arXiv:2502.12442.

Haoran Luo, Guanting Chen, Yandan Zheng, Xi-aobao Wu, Yikai Guo, Qika Lin, Yu Feng, Zemin Kuang, Meina Song, Yifan Zhu 외 1명. 2025. Hypergraphrag: [하이퍼그래프 구조화된 지식 표현을 통한 검색 증강 생성](#) . arXiv 사전 인쇄 arXiv:2503.21322.

요시 미사, 보아즈 카르멜리, 아사프 예후다이, 아사프 톨레도, 그리고 나다니엘 밀스. 2024년. [더 큰 만족을 위해 맥락: 질문 답변을 위한 가상 문서 긴 문서에 대해서](#). 협회 조사 결과에서 전산언어학 분야: EMNLP 2024, 페이지 12936–12942.

코스타스 마브로마티스와 조지 카리피스. 2024. [Gnn-rag: 대규모 언어 모델을 위한 그래프 신경망 검색 추리](#). arXiv 사전 인쇄 arXiv:2405.20139.

Yuxiang Nie, He-Yan Huang, Wei Wei, Xian-Ling 마오. 2022. [글로벌 구조 정보 포착 긴 문서에 대한 질의응답을 압축 그래프 선택기 네트워크를 이용하여 처리합니다](#). 다음 학술대회 논문집에서

2022 자연과학 분야의 경험적 방법론 컨퍼런스 언어 처리, 5036~5047쪽.

X. Ren 외 1명. 2025. [Videorag: 극도로 긴 컨텍스트를 활용한 검색 증강 생성 동영상](#). arXiv 사전 인쇄 arXiv:2502.01549.

존 사드-팔콘, 조 배우우, 알렉사 시우, 아니 넨코바, 윤승현, 라이언 A. 로시, 프랑크 데르 농쿠르. 2024. [Pdfriage: 질문 답변에 관하여 길고 구조화된 문서](#). 학회 회의록에서 2024 자연과학 분야의 경험적 방법론 컨퍼런스 언어 처리: 산업 분야, 153페이지~169.

Zhihong Shao, 공예운, 심예룡, Minlie Huang, Nan Duan, and Weizhu Chen. 2023. [Enhancing retrieval-augmented large language models with 반복적인 검색-생성 시너지](#). arXiv 사전 공개 논문 arXiv:2305.15294.

Zhengliang Shi, Shuo Zhang, Weiwei Sun, Shen Gao, Pengjie Ren, Zhumin Chen, Zhaochun Ren. 2024. [다중 홉 질의응답을 위한 검색 증강 생성에서 생성 후 접지](#) . 협회 제62차 연례 회의 회의록

전산언어학(제1권: 장편 논문 ), 7339~7353쪽.

Liwen Sun, James Jialun Zhao, Wenjing Han 및 Chenyan Xiong. 2025. [정확한 의료 방사선학을 위한 사실 인식 다중 모달 검색 증강 보고서 생성](#). 2025년 미주 국가 회의 회의록 에서

전산언어학 협회: 인간 언어 기술 (제1권: 장편 논문) 643~655쪽.

Manan Suri 외 1명. 2025. [Visdom: 멀티모달 래그를 사용하여 시각적으로 풍부한 요소를 갖춘 멀티 문서 QA](#) . 2025년 NAACL에서.

다나카 료타, 이키 타이치, 하세가와 타쿠, 코스케 니시다, 사이트 쿠니코, 스즈키 준. 2025. [Vdocrag: 검색 증강 생성 시각적으로 풍부한 문서](#). 컴퓨터 비전 및 패턴 인식 학회 회의록에서 , 24827~24837페이지.

쉐야오 완(Xueyao Wan)과 항 유(Hang Yu). 2025. [음그라그: 해석 가능한 기술로 시각과 언어를 연결합니다](#). 멀티모달 지식 그래프. arXiv 사전 공개 논문 arXiv:2507.20804.

Shu Wang, Yixiang Fang, Yingli Zhou, Xilin Liu 및 Yuchi Ma. 2025a. [Archrag: 속성 기반 커뮤니티 기반 계층적 검색 증강 생성](#). arXiv 사전 인쇄 arXiv:2502.09891.

Shu Wang, Yingli Zhou 및 Yixiang Fang. 2025b. [Bookrag: 계층 구조를 인식하는 인덱스 기반 복잡한 문서에 대한 검색 증강 생성 접근 방식](#) .

Yuhao Wang, Ruiyang Ren, Junyi Li, Wayne Xin Zhao, Jing Liu 및 Ji-Rong Wen. 2024. [후면 : A 관련성 인식 검색 증강 프레임워크 개방형 도메인 질문 답변](#).

Zhitong Wang, Cheng Gao, Chaojun Xiao, Yufei Huang, Shuzheng Si, Kangyang Luo, Yuzhuo Bai, Wenhao Li, Tangjian Duan, Chuancheng Lv 외 1명. 2025c. [검색 증강 생성에는 문서 분할이 중요합니다](#) . 전산언어 학회 연구 결과 : ACL 2025, 8063~8075쪽.

Junda Wu, Yu Xia, Tong Yu, Xiang Chen, Sai Sree Harsha, Akash V Maharaj, Ruiyi Zhang, Victor Bursz-tyn, 김성철, Ryan A Rossi 외 1명.

2025. [Doc-react: 다중 페이지 이중 문서 질의응답](#). 제63회 전산언어학회 연례회의 회의록 (제2권: 단편 논문), 67-78쪽.

Peng Xia, Kangyu Zhu, Haoran Li, Tianze Wang, Weijia Shi, Sheng Wang, Linjun Zhang, James Zou 및 Huaxiu Yao. 2024. [Mmed-rag: 의료 비전 언어 모델을 위한 다목적 다중 모드 래그 시스템](#) . arXiv 사전 인쇄 arXiv:2410.13085.

차이밍 송, 빅터 중, 리처드 소처.  
2016. [질문에 대한 동적 코트렌션 네트워크 답변하고 있습니다](#). arXiv 사전 인쇄 arXiv:1611.01604.

Dayu Yang, Antoine Simoulin, Xin Qian, Xiaoyi Liu, Yuwei Cao, Zhaopu Teng 및 Gray Yang. 2025.  
[Docagent: 코드 문서 자동 생성을 위한 다중 에이전트 시스템](#) . arXiv 사전 인쇄 arXiv:2504.08725.

야스나가 미치히로, 주레 레스코벡, 퍼시 리앙.  
2022. [Linkbert: 사전 학습된 언어 모델 문서 링크](#).  
arXiv 사전 인쇄 arXiv:2203.15827.

Shi Yu, Chaoyue Tang, Bokai Xu, Junbo Cui, Jun-hao Ran, Yukun Yan, Zhenghao Liu, Shuo Wang, Xu Han, Zhiyuan Liu 외 1명. 2024. [Visrag: 다중 양식 문서에 대한 비전 기반 검색 증강 생성](#). arXiv 사전 인쇄 arXiv:2410.10594.

Shiyue Zhang, Zheng Chong, Xujie Zhang, Hanhui Li, Yuhao Cheng, Yiqiang Yan 및 Xiaodan Liang.  
2024. Garmentaligner: [검색 증강 다단계 교정을 통한 텍스트-의류 생성](#) . 유럽 컴퓨터 비전 학회(European Conference on Computer Vision), 148~164쪽. 스프링거 출판사.

Zhebin Zhang, Xinyu Zhang, Yuanhang Ren, Saijiang Shi, Meng Han, Yongkang Wu, Ruofei Lai 및 Zhao Cao. 2023. [Iag: 유도증강세대 추론 문제에 답하기 위한 틀](#).

Dawei Zhu, Rui Meng, Jiefeng Chen, Sujian Li, Tomas Pfister, Jinsung Yoon.  
2025. [Doclens: 긴 시각적 문서 이해를 위한 도구 증강 다중 에이전트 프레임워크](#) .  
arXiv 사전 인쇄 arXiv:2511.11552.