

ManuRAG: 다중 모달 검색 증강 제조 관련 질문 답변 생성

리윤칭 (Yunqing Li^a), 지한 동 b, 파르하드 아메리아, 장방 장크(Jianbang Zhang^c)

애리조나 주립대학교 제조 시스템 및 네트워크 학부
a대학교, 메사, 85212, 애리조나, 미국 b노
스캐롤라이나 주립대학교 기계항공공학과
대학교, 롤리, 27607, 노스캐롤라이나, 미국 cAI
연구소, 레노버, 모리스빌, 27560, 노스캐롤라이나, 미국

추상적인

디지털 제조의 발전은 텍스트, 이미지, 수식, 표와 같은 복잡한 멀티모달 데이터를 원활하게 통합 및 분석할 수 있는 지능형 질의응답(QA) 시스템을 필요로 합니다. 기존의 검색 증강 생성(RAG) 방식은 이러한 복잡성을 처리하는 데 종종 한계를 보여 성능 저하를 초래합니다. 본 논문에서는 제조 분야 질의응답(MQA)을 위해 설계된 새로운 멀티모달 RAG 프레임워크인 ManuRAG를 소개합니다. ManuRAG는 답변의 정확성, 신뢰성, 해석 가능성을 향상시키는 특수 기법을 통합했습니다. 성능 벤치마킹을 위해 제조 원리 및 실무에 관한 수학, 객관식, 복습 문제로 구성된 1,515쌍의 질의응답 데이터셋을 제공했습니다. 실험 결과, ManuRAG4는 모든 데이터셋에서 기존 방식보다 훨씬 우수한 성능을 보였습니다. 또한, ManuRAG의 적응성 있는 설계는 법률, 의료, 금융 등 다른 분야에도 적용 가능하며, 특정 분야에 특화된 질의응답을 위한 다목적 도구로서의 가능성을 보여줍니다.

키워드: 검색 증강 생성, 다중 모달리티
제조 분야 질의응답 및 정보 추출

*교신 저자: 파르하드 아메리 (Farhad.Ameri@asu.edu)

10.26434/chemrxiv-2024-15434v2

1. 서론

1.1. 배경 및 동기

산업 5.0으로의 전환 과정에서 질의응답(QA) 시스템은 중요한 역할을 합니다. 제조 분야에서 빅데이터를 활용하는 데 있어 중요한 역할을 하는 것이 바로 QA 시스템입니다. 사용자가 자연어로 질문했을 때 자동으로 답변하도록 설계된 정보 검색 시스템의 한 유형입니다. 이러한 시스템은 여러 가지 기술을 조합하여 사용합니다.

자연어 처리(NLP), 기계 학습(ML), 그리고 종종

질문을 이해하고 생성하기 위해 지식 기반 또는 대규모 데이터 세트를 활용합니다.

적절한 답변입니다. QA 시스템은 데이터 기반 의사결정을 지원함으로써 엔지니어, 운영자 및 관리자에게 정확하고 관련성 있는 정보를 제공합니다.

다양한 데이터 형식에 걸쳐 통찰력을 얻을 수 있습니다. 이러한 접근성은 센서, 기계 및 설비에서 발생하는 복잡한 데이터를 다루는 지능형 제조에 필수적입니다.

효율적이고 정확한 생산을 위해서는 파일들이 원활하게 통합되어야 합니다.

연결성을 우선시하는 시스템과 정보 검색 기능을 통합합니다.

자동화 및 안전한 협업을 통해 제조업체는 생산 공정을 간소화할 수 있습니다.

아이디어 구상 및 생산부터 지속가능성에 이르기까지 전체 가치 창출 프로세스

또한 적응성도 뛰어납니다. 이러한 고급 기능은 자율적으로 조직화되고 지능적인 생산 시스템을 촉진하며, 안정적이고 안전한 통신을 보장합니다.

제조 가치 사슬에 있어서도 마찬가지입니다. 또한, 품질 보증 시스템은 매우 중요합니다.

상호 운용성을 달성하여 기존 시스템과 새로운 시스템 간의 원활한 상호 작용을 가능하게 합니다.

차세대 장비 및 플랫폼, 그리고 그 영향 평가를 위해

제품 수명 주기 전반에 걸친 외부 요인. MQA의 잠재적 사용자

(제조 관련 질문 답변) 시스템에는 정밀 공차를 계산하는 기계 설계 엔지니어, 조립 공정을 최적화하는 생산 엔지니어, 온도 조절을 수행하는 기계 작업자 등이 포함됩니다.

치수 정확도를 검증하는 품질 보증팀과 연구팀

제조 효율성 향상을 위한 첨단 소재 및 기술 연구.

1.2. 과제

제조 데이터의 복잡성은 효과적인 정보 검색 및 품질 관리에 있어 고유한 과제를 제시합니다. 제조 문서는 광범위한 영역을 포괄합니다.

텍스트, 이미지, 수식, CAD 모델, 표 등을 포함한 다양한 데이터 유형

센서 데이터 및 비디오[1, 2, 3]. 각 형식은 제조 공정, 설계 등을 이해하고 최적화하는 데 필요한 중요한 정보를 담고 있습니다.

그리고 운영 관련 통찰력을 제공합니다. 예를 들어, 텍스트 데이터에는 운영 관련 정보가 포함될 수 있습니다.

지침, 유지 관리 로그[4] 또는 자연을 요구하는 규정 준수 기록

효율적인 검색을 위한 자연어 처리(NLP). 결합 사진과 같은 이미지

또는 조립 라인 스냅샷과 같은 이미지를 식별하려면 컴퓨터 비전 기술이 필요합니다.

패턴을 분석하거나 품질 문제를 감지합니다. 문서에 포함된 공식과 방정식은 정확한 분석을 위해 정밀한 인식과 해석이 필요합니다.

복잡한 프로세스의 복제 및 문제 해결. 이러한 다양한 기능들이 함께 어우러져 데이터 형식은 고급 정보 추출의 필수적인 역할을 강조합니다.

효율적이고 데이터 기반의 제조 통찰력을 얻기 위한 처리 기술.

산업계에서 MQA 시스템의 도입은 아직 초기 단계에 머물러 있습니다.

제조 공정의 복잡성이 증가하고 고급 데이터 관리 솔루션에 대한 필요성이 증가함에 따라 GPT 기반 챗봇[5] (예: Streebo[6]에서 제공하는 것)이 가장 유사한 것으로 나타났습니다.

하지만 이러한 도구들은 주로 대화형 상호작용에 초점을 맞추고 있어 부족한 점이 있습니다.

강력한 멀티모달 검색 및 도메인별 추론 기능

포괄적인 MQA 애플리케이션에 필요합니다.

MQA에 대한 기존 정보 검색 방법은 일반적으로 한계가 있습니다.

텍스트 기반 또는 이미지 기반 데이터 검색으로, 종종 다음을 포착하지 못합니다.

다중 모달 정보의 전체적인 맥락과 복잡성을 제대로 이해하지 못하는 것이 한계입니다.

생산 워크플로의 비효율성을 초래하고 효과적인 의사 결정을 방해합니다. 예를 들어, 설계 및 개발 부서, 특히

자동차 제조와 같은 복잡한 산업 분야에서는 다양한 데이터 형식에서 관련 정보를 검색하는 것이 상당한 어려움을 야기합니다.

예를 들어, 엔지니어는 "다음 모델 중 5링크 서스펜션을 가진 모델은 무엇입니까? 옵션: A: 모델 1, B: 모델 2,

C: 모델 3." 답변은 여러 문서 유형에 걸쳐 있을 수 있습니다.

이전 모델들이 정보를 텍스트로 저장하는 반면, 모델 2의 데이터는 다른 방식으로 저장될 수 있습니다.

도면 및 기술 사양과 모델이 포함된 PDF 파일에 내장되어 있습니다.

3번 항목의 세부 정보는 CAD 모델, 분해도 또는 주석이 달린 이미지에 있을 수 있습니다.

이러한 형식들을 수동으로 분류하는 것은 시간이 많이 소요되고 위험을 증가시킵니다.

핵심 세부 정보가 누락되면 문제가 발생하며, 문서가 방대할수록 더욱 어려워집니다. 이 예시는 핵심적인 문제, 즉 시급한 필요성을 강조합니다.

텍스트, 시각 데이터 및 구조화된 표를 원활하게 통합하고 해석하여 복잡한 요구 사항을 충족할 수 있는 강력한 검색 시스템입니다.

설계 및 제조.

오늘날 QA 분야의 정보 검색 시스템에는 여러 가지 제약 요소가 있습니다.

제조 분야. 제조 데이터는 다양하고 복잡하며 기술적이어서 각 유형별로 특수 처리가 필요합니다[7, 8, 9]. 텍스트 데이터는 분야별 전문 용어를 포함하는 반면, 그림, 표 등의 시각적 데이터는

슬라이드를 해석하려면 고급 해석 도구가 필요하지만, 많은 시스템에서 이러한 기능이 부족합니다.

현재 시스템에서 또 다른 과제는 텍스트 및 이미지 데이터를 변환하는 것입니다. 또 다른 과제는 텍스트 및 이미지 데이터를 변환하는 것입니다.

정보 손실이 최소화된 통합 컴퓨터 처리 형식[10].

이러한 문제들은 오해를 불러일으키거나 중요한 세부 정보를 손실하게 하여 효율적인 데이터 검색 및 통합을 방해합니다. 현대 제조 분야에서 더 빠르고 정확한 의사결정을 위해서는 고급 멀티모달 검색 접근 방식이 필수적입니다.

1.3. 목표 본 연구에

서는 MQA(Machine Quality Assessment)에 특화된 다중 모달 검색 증강 생성(MMRAG) 시스템을 제안하여 이러한 한계를 극복하고자 합니다. MMRAG 시스템은 이미지, 수식, 표, 텍스트 등 다양한 데이터 유형을 원활하게 통합 및 처리하여 제조 문서에 대한 더욱 심층적이고 맥락에 맞는 정확한 이해를 제공합니다. 다양한 데이터 형식과 복잡한 제조 관련 질의 간의 격차를 해소함으로써, MMRAG는 사용자에게 신뢰할 수 있고 포괄적인 실행 가능한 인사이트를 제공합니다. 이를 통해 사용자는 정보에 기반한 의사결정을 내리고, 워크플로우를 간소화하며, 운영 효율성을 개선하고, 생산 오류를 최소화하여 궁극적으로 생산성을 향상시키고 제조 시스템의 혁신을 주도할 수 있습니다.

본 논문은 MQA 및 의사결정 지원을 향상시키기 위해 멀티모달 데이터 통합 및 검색의 강력한 기능을 활용하는 것을 목표로 합니다. 본 논문의 주요 기여는 다음과 같습니다.

1. 제조 분야에 특화된 포괄적인 멀티모달 품질 보증 시스템을 소개합니다. 이 시스템은 운영상의 병목 현상을 파악하고, 제품 설계를 개선하며, 복잡한 제조 공정에서 데이터 기반 의사결정을 지원하도록 설계되었습니다.
2. 전통적인 RAG 및 MMRAG 프레임워크를 포함한 다양한 품질 보증 시스템을 설계 및 평가하여 다양한 제조 시나리오에 대한 귀중한 통찰력을 제공하는 동시에 법률, 의료 및 금융과 같은 다른 영역으로 적용 범위를 확장합니다.
3. 텍스트 데이터에 내장된 링크를 활용하고 텍스트와 이미지를 내장 전후에 정렬함으로써 다중 모달 정보 색인 및 검색을 위한 혁신적인 접근 방식을 제안합니다. 이를 통해 시각 정보를 더욱 견고하고 정확하게 해석하여 MQA 시스템 성능을 향상시킬 수 있습니다.

본 논문의 나머지 부분은 다음과 같이 구성됩니다. 2절에서는 관련 연구를 검토합니다. 3절에서는 ManuRAG를 구성하는 방법을 소개합니다.

제4절에서는 본 논문에서 제시하는 방법의 효과를 입증하는 실험 결과를 제시합니다.

마지막으로, 5절에서는 본 방법의 한계점에 대해 논의합니다.
향후 연구 방향을 제시합니다.

2. 관련 연구

2.1. 질문 답변 시스템

QA 시스템은 다양한 기술을 활용하여 크게 발전해 왔습니다.
쿼리를 검색하고 응답하기 위해 [11]. 전통적인 전문가 시스템은 구축되었습니다.
도메인별 전문 지식에 기반하여 오랫동안 QA 작업에 사용되어 왔지만, 종종
복잡하고 데이터가 풍부한 환경에 대한 확장성과 적응성이 부족합니다. 대규모
GPT[12] 및 BERT[13]와 같은 언어 모델(LLM)이 도입되었습니다.
딥러닝을 활용하여 질의를 해석함으로써 QA 분야에서 상당한 발전을 이루었습니다.
방대한 데이터 세트에서 관련 정보를 추출합니다. 이러한 모델은 탁월한 성능을 발휘합니다.
맥락과 언어를 이해하는 데 능숙하여 매우 효과적인 업무 수행이 가능합니다.
범용 QA. 멀티모달 모델은 이 분야를 더욱 발전시켰습니다.
이미지와 텍스트 처리를 결합하여 시각적 질문 답변(VQA)을 가능하게 하고[14] 표 형식과 텍스트 형식의 통
합을 통해 QA를 지원합니다.
맥락적으로 풍부한 응답을 위한 데이터[15]. 그러나 이러한 모델 중 어느 것도
복잡성과 고도의 기술력으로 인해 제조 분야에 적합합니다.
제조 데이터의 특성. 제조 질의응답(MQA)은 다양하고 다중 모드적인 데이터의 정확한 추출과 견고한 통합을
요구합니다.
기존 기술로는 해결할 수 없는 독특한 과제를 제시하는 유형
QA 모델.

2.2. 정보 추출

정보 추출(IE)은 다양한 형식을 처리할 수 있도록 발전해 왔습니다.
텍스트, 이미지, 표, 멀티미디어를 포함한 정형 및 비정형 데이터. PDF와 같은 멀티미디어 문서는 텍스트, 이미
지, 표, 그리고 때로는 오디오나 비디오까지 통합되어 있어 특별한 어려움을 야기합니다. 고급
IE 접근 방식은 R-CNN[16] 및 Lay-outLMv3[17]과 같은 레이아웃 감지 모델을 사용하여 콘텐츠 영역을 식
별합니다. 수식 인식은 딥러닝에 의존합니다.
학습 방법[18, 19, 20, 21]. OCR 도구[22, 23]는 글꼴과 언어에 걸쳐 정확한 텍스트 추출에 필수적이며 포괄
적인 IE를 제공합니다.
멀티미디어 콘텐츠를 위한 기능. 제조 분야의 IE는 추출을 포함합니다.
의사결정을 지원하기 위해 텍스트, 이미지 및 기타 데이터 유형에서 정보를 추출합니다. 텍스트의
경우, Li et al.[24]은 텍스트에서 지식을 추출하는 방법을 개발했습니다.
제조업체 웹사이트는 서버 검색을 간소화합니다. 이미지의 경우 Bhan-darkar와 Nagi[25]는 기하학적 데
이터를 더 높은 수준의 제조 정보로 변환합니다.

통찰력. 제조 분야에서 멀티미디어가 널리 사용되고 있음에도 불구하고, 관련 연구는 전무하다. 다양한 출처에서 정보를 추출하는 데 집중하면서 연구의 공백을 강조해 왔습니다.

2.3. 신속한 엔지니어링 및 검색 증강 생성

대규모 언어 모델(LLM)은 일반적인 품질 보증(QA)에서는 우수한 성능을 보이지만, 전문 용어, 복잡한 데이터 등으로 인해 제조 분야에서는 어려움에 직면합니다.

기술적 세부 사항은 [26]을 요구합니다. 제조 관련 질의에는 정확하고 도메인별 전문 지식이 필요하며, LLM은 그럴듯하지만 부정확한 결과를 생성하기 쉽습니다.

답변(환각)[27]은 전문적인 도움 없이는 신뢰할 수 있게 제공할 수 없습니다.

접지 문제로 인해 추가적인 개선 없이는 MQA에 적합하지 않습니다.

프롬프트 엔지니어링은 LLM이 정확하고 맥락적으로 관련된 응답을 하도록 안내하는 프롬프트를 만드는 것을 포함합니다. 사고의 연쇄[28]와 같은 기술 그리고 사고의 나무[29]는 다단계 과정을 촉진함으로써 이 과정을 향상시킵니다. 추론 능력을 통해 LLM은 복잡한 쿼리를 더욱 효과적으로 처리할 수 있습니다. MQA의 프롬프트 엔지니어링은 업계별 언어 및 기술적 제약 조건을 맞춤형 프롬프트에 통합하여 LLM이 정확한 프롬프트를 생성할 수 있도록 합니다.

해당 분야와 관련된 답변을 제공하고 전문 용어를 효과적으로 관리합니다.

복잡성 [30, 31].

또 다른 강력한 접근 방식은 RAG입니다. RAG는 실제 세계에서 관련 문서나 데이터베이스를 검색하여 LLM 결과물을 외부 지식에 기반을 두도록 합니다.

제조 데이터. Llama-Index[32] 및 LangChain[33]과 같은 도구를 사용하면

효율적인 검색을 위해 GraphRAG [34]는 그래프 기반 검색을 도입했습니다.

상호 연결된 데이터에 대한 추론. RAG는 문서나 데이터베이스에서 관련 제조 데이터를 검색하여 LLM 출력 결과를 향상시킵니다. 다음과 같은 방법들이 사용됩니다.

텍스트 임베딩 RAG 및 그래프 임베딩 RAG는 쿼리를 문서와 일치시키거나 상호 연결된 데이터 내의 관계를 캡처합니다. Llama-Index[32] 및 LangChain[33]과 같은 도구는 텍스트 임베딩을 지원하는 반면 GraphRAG[34]는

복잡한 추론을 위해 그래프 기반 검색을 사용합니다. 제조 분야에서 RAG는

응용 분야는 도메인별 용어 검색[35], 엔지니어링 분석을 위한 온톨로지 지식 그래프 통합, 재료 설계[36]에 이르기까지 다양합니다.

텍스트, 이미지 및 기타 요소를 통합하는 새로운 확장 기능인 멀티모달 RAG

복잡한 질문에 대해 더 풍부한 맥락을 제공하기 위한 다른 데이터 유형[37, 38]

이 기술은 의료 분야에서 활용 가능성을 보여주었지만, 제조 분야에 맞게 특화된 것은 아닙니다.

Ovis [10], GPT-4O, Qwen [39]과 같은 멀티모달 대규모 언어 모델(MLLM)은 텍스트와

시각적 데이터 처리에 탁월한 이러한 다단계 모델(MLLM)은 멀티모달 입력을 이해하는 데는 뛰어나지만, 입력 토큰 수에 제한이 있어 방대한 양의 정보를 처리할 때 어려움을 겪습니다.

MMRAG는 대규모 정보를 인덱싱하고 추론 과정에서 관련 컨텍스트를 검색하여 광범위한 외부 지식에 효율적으로 접근할 수 있도록 함으로써 이러한 한계를 해결합니다. 텍스트 기반 데이터에 초점을 맞춘 기존 RAG와 달리 MMRAG는 텍스트와 시각적 모달리티를 모두 통합하도록 기능을 확장합니다. MMRAG는 일반적으로 다양한 데이터 형식을 처리하기 위해 두 가지 주요 접근 방식을 사용합니다. (1) 이미지를 설명 텍스트로 변환하여 텍스트 기반 워크플로에 원활하게 통합하고, (2) CLIP[40] 및 Jina-CLIP[41]과 같은 멀티모달 임베딩을 사용하여 텍스트와 이미지 데이터를 공유 임베딩 공간에 정렬합니다. 이러한 방법을 통해 모델은 다양한 모달리티에 걸쳐 정보를 검색하고 추론할 수 있으므로 시각적 이해와 텍스트 이해가 모두 필요한 작업에서 성능이 향상됩니다. 멀티모달 RAG는 의료와 같은 분야에서 응용 가능성을 보여주었지만, 제조 분야에서의 잠재력은 아직 충분히 탐구되지 않았습니다. 제조 분야에서는 복잡한 회로도, 기술 다이어그램, 공정별 콘텐츠를 높은 정확도와 문맥적 관련성을 가지고 처리할 수 있는 맞춤형 솔루션이 필요합니다.

3. 방법론

기존의 RAG 시스템은 주로 텍스트 입력을 처리하도록 설계되어 있어 실제 데이터에 존재하는 다중 모달 정보의 특성을 간과하는 경우가 많습니다. 이러한 한계를 극복하기 위해, 제조 문서에서 다양한 데이터 유형을 처리할 수 있도록 다중 모달리티를 통합한 RAG의 확장 버전인 ManuRAG를 제안합니다. ManuRAG에 사용된 MLLM은 일반 텍스트와 이미지를 모두 입력으로 받아들이며, 객체 탐지 및 텍스트 인식 모델 파이프라인을 통해 PDF 파일을 처리할 수 있습니다. 이 과정을 통해 문서를 그림, 이미지, 수식, 텍스트 내용과 같은 명확한 구성 요소로 효과적으로 분류합니다.

ManuRAG 프레임워크는 다중 모달 데이터 추출, 인덱싱, 검색 및 답변 생성의 네 가지 주요 단계로 구성됩니다. 최첨단 PDF 추출 파이프라인은 고급 비전 및 분할 모델을 통합하여 강력한 그림 및 콘텐츠 인식을 가능하게 합니다[42]. 다중 모달 데이터 추출 프로세스에 대한 자세한 내용은 3.1절에 제시되어 있습니다. 인덱싱 메커니즘은 3.1.4절에서, 검색 전략은 3.3절에서, 답변 생성 접근 방식은 3.4절에서 논의됩니다.

또한, ManuRAG 프레임워크의 네 가지 변형을 소개합니다.

이러한 변형들은 다중 모달 데이터를 통합하기 위한 다양한 전략을 탐구합니다.

이러한 변형에 대한 자세한 내용은 3.5절에 제시되어 있습니다.

3.1. 멀티모달 데이터 추출

RAG에서 원본 제조 파일을 직접 사용하는 것은 상당한 이점을 제공합니다.

어려움이 있습니다. 이러한 파일에는 이미지 등 복잡한 구조가 포함되어 있는 경우가 많습니다.

표, 수식, 비표준 텍스트 레이아웃 등으로 인해 PDF 파일을 직접 사용하면 효율적인 정보 검색이 어렵습니다. PDF 파일을 일반 텍스트로 변환하면 이러한 문제를 해결할 수 있습니다.

이는 종종 중요한 맥락적 및 구조적 정보의 손실을 초래하여 MQA 성능을 저해하는 저품질 데이터를 생성합니다.

이러한 문제들을 해결하기 위해, 우리는 제조 관련 PDF 파일에서 텍스트, 이미지, 표, 수식 등 다양한 형태의 데이터를 추출하고 정리하는 데 집중합니다.

RAG 시스템에 견고한 입력값을 생성하기 위해.

이 섹션의 주요 목표는 기본적인 제조 지식을 정확하게 반영하는 고품질 데이터 표현을 구축하는 것입니다.

노이즈를 최소화하면서 이 과정을 진행합니다. 이 과정은 추출 및 처리로 시작됩니다.

제조 PDF 파일에서 정보를 추출하여 텍스트와 이미지를 분리합니다.

표현 방식을 통해 중요한 데이터의 보존을 보장합니다. pdf-extract-kit 프레임워크[43, 44, 21, 45]를 사용하여 다중 모달 데이터 추출을 위한 최첨단 방법론을 적용했습니다. 여기에는 레이아웃 감지가 포함됩니다.

문서 구조를 유지하고, 수학적 내용을 보존하기 위해 수식을 추출하고, 시각적 데이터를 통합하기 위해 이미지와 표를 추출했습니다. 광학 문자 인식(OCR)을 적용하여 텍스트 콘텐츠를 디지털화했습니다.

선택 불가능한 영역. 이러한 다중 모달 표현은 통합 데이터베이스에 내장되어 저장되며, 이 데이터베이스는 영역 간의 관계를 보존합니다.

다양한 방식을 지원하여 원활한 통합과 후속 작업에서의 효과적인 활용을 가능하게 합니다.

3.1.1. 레이아웃 감지

제조 PDF의 구조적 무결성을 유지하고 관련 콘텐츠를 효과적으로 추출하려면 정확한 레이아웃 감지가 매우 중요합니다.

이 과정은 문서를 개별 요소로 분해하는 동시에 페이지 번호나 제목과 같이 불필요한 구성 요소를 걸러내는 것을 포함합니다.

QA 성능에 부정적인 영향을 미칩니다. 이를 위해 이미지, 테이블, 제목 및 텍스트와 같은 영역을 감지하는 데 Lay-outLMv3 [17]을 사용했습니다.

3.1.2. 화학식 추출

우리는 정확한 공간적 위치를 갖는 인라인 및 블록 공식을 식별하기 위해 YOLOv8 [46]을 사용합니다. 이 방법은 특히 $E = (\text{영률 공식, 여기서 } \sigma \text{는 응력이고 } n \text{는 픽의 제1법칙, 여기서 } J \text{는 확산 플럭스, } D \text{는 농도 기울기})$ 와 같은 인라인 공식을 식별하는 데 효과적입니다.

는 변형률), 또는 $J = -D \frac{\partial C}{\partial x}$

확산 계수 및 주변 텍스트 콘텐츠 $\frac{\partial C}{\partial x}$

의 수식을 활용하는 이 탐지 방법은 중요한 수학적 표현을 보존하여 텍스트 추출 중 오류를 방지하고 제조 문서의 문맥적 무결성을 유지합니다.

3.1.3. 이미지 및 테이블 추출

이미지와 표는 방대한 정보를 직관적으로 전달하는 데 필수적인 도구이며 제조 시스템에서 널리 사용됩니다. 그러나 복잡한 구조로 인해 품질 보증 시스템에 통합하는 데 어려움이 있습니다.

이를 해결하기 위해 PubTabNet 데이터셋[47]에서 학습된 변환 모델을 사용하여 테이블을 LaTeX 형식으로 변환하는 파이프라인을 구현하여 정확하고 구조화된 표 형식 데이터 추출을 보장했습니다.

3.1.4. 광학 문자 인식

비텍스트 요소를 처리한 후, Paddle-OCR[48]을 사용하여 일반 텍스트를 추출했습니다. 이 접근 방식은 전체 페이지를 단일 입력으로 처리할 때 발생하는 오류를 방지합니다. 추출된 콘텐츠는 위치 및 유형 정보를 포함하는 메타데이터와 함께 저장됩니다. LaTeX 형식의 수식, 이미지 파일 형식의 그림 및 표, 그리고 마크다운 형식의 일반 텍스트가 포함됩니다. 각 시각적 요소에는 텍스트 내에서 이러한 요소를 일관되게 참조하는 데 사용되는 128비트 식별자인 UUID(Universally Unique Identifier)가 할당되어 원활한 통합이 가능합니다. 이러한 구조화된 방법론은 고품질의 잘 정리된 데이터 표현을 보장합니다.

3.2. 인덱싱 인덱싱

은 RAG에서 매우 중요한 역할을 합니다. 질의 해결 과정에서 관련 정보를 효율적이고 정확하게 검색할 수 있도록 해주기 때문입니다. ManuRAG에서 인덱싱은 텍스트 정보와 시각 정보를 포함한 멀티모달 데이터를 구조화하고 저장하여 후속 검색 및 생성 작업에 원활하게 통합될 수 있도록 합니다. 데이터를 고차원 임베딩 공간에 투영함으로써, 시스템은 효과적인 정보 검색에 필수적인 유사성 기반 검색과의 호환성을 보장합니다.

3.2.1. 텍스트 벡터 데이터베이스

단락, 수식, 이미지 링크 등을 포함한 텍스트 데이터는 문맥적 관련성과 일관성을 유지하기 위해 관리 가능한 단위로 분할하는 전처리 과정을 거칩니다. 이러한 분할 과정은 두 가지 핵심 매개변수에 의해 결정됩니다. 하나는 각 세그먼트의 최대 길이를 정의하는 청크 크기이고, 다른 하나는 문맥의 연속성을 유지하기 위해 연속적인 청크 간의 중첩 정도를 결정하는 청크 중첩입니다. 텍스트 입력(Text)이 주어졌을 때, 중첩되는 청크로의 분할은 다음과 같이 표현할 수 있습니다.

$$\text{청크} = C_i : C_i = \text{Text}[i : i + S + O], i \in [0, |\text{Text}|], \text{step} = S \quad (1)$$

여기서 S는 청크 크기를 나타내고, O는 청크 중첩을 나타내며, C_i 는 i 번째 청크이고, $|\text{T}|$ 는 텍스트의 전체 길이입니다.

우리는 각 텍스트 덩어리 C_i 를 다음과 같은 쌍으로 모델링합니다.

$$C_i = T_i, \text{아이}, \alpha_i = \{li1, li2, \dots, \text{이비}\}, \quad (2)$$

여기서 T_i 는 텍스트 내용이고, α_i 는 T_i 에서 참조되는 이미지 집합입니다. 청크는 LLM 기반 텍스트 임베딩 모델인 EmbedText를 사용하여 임베딩 공간으로 투영됩니다. 각 청크 C_i 의 임베딩은 다음과 같이 표현됩니다.

$$v_{C_i} = \text{EmbedText}(C_i) \quad (3)$$

이러한 임베딩은 해당 텍스트 덩어리와 함께 텍스트 벡터 데이터베이스에 저장되어 쿼리 해결 과정에서 효율적인 검색이 가능합니다.

3.2.2. 이미지 벡터 데이터베이스 추출된 그

림과 표를 포함한 시각적 데이터의 경우, 텍스트와 동일한 임베딩 공간에 정보를 인코딩하기 위해 멀티모달 임베딩 모델이 사용됩니다. 이 모델은 텍스트와 이미지를 모두 처리할 수 있으므로 텍스트-이미지 검색 및 이미지-텍스트 검색과 같은 교차 모달 검색 기능을 지원합니다. 각 이미지 I_j 는 다음과 같이 정의된 멀티모달 임베딩 함수 EmbedMM을 사용하여 임베딩 벡터 I_j 로 인코딩됩니다.

$$v_{I_j} = \text{EmbedMM}(I_j) \quad (4)$$

생성된 이미지 임베딩과 관련 이미지 데이터는 이미지 벡터 데이터베이스에 저장됩니다. 이 데이터베이스는 다음을 지원하도록 설계되었습니다.

질의 과정에서 시각적 정보를 검색하고 텍스트 데이터를 보완하는 데 사용됩니다.

멀티모달 임베딩 모델은 텍스트와 이미지를 모두 처리할 수 있지만, 복잡하고 긴 텍스트 콘텐츠를 이해하는 능력은 대부분의 LLM 기반 텍스트 임베딩 모델에 비해 떨어집니다. 방대한 텍스트 데이터셋으로 특별히 학습된 텍스트 임베딩 모델은 복잡한 텍스트 구조와 의미를 보다 포괄적으로 이해할 수 있습니다. 두 접근 방식의 장점을 모두 활용하기 위해 ManuRAG의 일부 변형에서는 텍스트와 이미지에 대해 별도의 벡터 데이터베이스를 사용합니다.

자세한 내용은 3.5절에 설명되어 있습니다. 이 이중 데이터베이스 접근 방식을 통해 ManuRAG는 텍스트 임베딩 모델의 특수 기능과 멀티모달 임베딩 모델의 유연성을 효과적으로 활용할 수 있습니다.

3.3. 검색

검색은 RAG 시스템의 핵심 구성 요소로, 시스템이 색인된 데이터에서 가장 관련성이 높은 정보를 식별하고 추출할 수 있도록 합니다.

ManuRAG에서 검색은 벡터 데이터베이스에 저장된 텍스트와 이미지 등 멀티모달 데이터를 선별하는 핵심적인 역할을 수행합니다. 이를 통해 제조 관련 질문에 대한 답변을 생성하는 언어 모델에 가장 관련성이 높은 데이터 조각만 제공합니다. 검색 기능을 통합함으로써 시스템은 방대하고 다양한 데이터 세트를 효율적이고 정확하게 처리할 수 있습니다.

검색 프로세스는 입력된 제조 쿼리의 임베딩과 저장된 데이터의 임베딩 간의 유사도를 계산하는 것을 기반으로 합니다. 사용되는 유사도 측정 기준은 코사인 유사도이며, 다음과 같이 정의됩니다.

$$\text{Sim}(q, v) = \frac{q \cdot v}{\|q\| \|v\|} \quad (5)$$

여기서 q 는 입력 제조 질문 Q 의 임베딩이고, v 는 저장된 데이터 벡터(텍스트 덩어리 또는 이미지)의 모든 임베딩 벡터입니다.

코사인 유사도는 쿼리와 저장된 임베딩 간의 각도 정렬을 평가하여 관련성을 측정하는 지표를 제공합니다.

3.3.1. 텍스트 벡터 데이터베이스에서의 검색

텍스트 데이터의 경우, 시스템은 쿼리 임베딩과 인덱싱된 모든 텍스트 청크의 임베딩 간의 코사인 유사도를 계산합니다. 식 (5)의 코사인 유사도 Sim 을 사용하여 상위 k 개의 텍스트 청크는 다음과 같이 검색됩니다.

$$\text{Top@Ktext} = \arg\max_k \text{sim}(q_1, v_{C_i}), \forall i \quad (6)$$

여기서 q_1 은 텍스트 공간의 쿼리 임베딩이고 v_{C_i} 는 청크 C_i 의 임베딩입니다. 검색이 완료되면 이러한 청크에서 참조하는 모든 이미지 세트를 수집합니다.

$$\text{이미지 참조됨} = \alpha_{ir} = \sum_{r=1}^R \alpha_{ir} \cdot \text{이미지 } i_r \quad (7)$$

3.3.2. 이미지 벡터 데이터베이스에서의 검색

시각 데이터의 경우, 입력 쿼리는 멀티모달 임베딩 모델을 사용하여 이미지 임베딩과 동일한 임베딩 공간으로 인코딩됩니다. 그런 다음 쿼리 임베딩과 이미지 벡터 데이터베이스에 저장된 이미지 임베딩 간의 코사인 유사도를 계산합니다. 유사도 점수가 가장 높은 상위 k 개의 이미지가 검색됩니다.

$$\text{Top@KImage} = \arg\max_k \text{sim}(q_2, v_{I_j}), \forall j \quad (8)$$

여기서 q_2 는 입력 쿼리를 멀티모달 임베딩 공간에 임베딩한 것이고, v_{I_j} 는 j 번째 이미지 I_j 의 임베딩을 나타냅니다. 이를 통해 임베딩 유사성을 이용하여 관련 시각 데이터를 직접 검색할 수 있습니다.

3.4. 답변 생성

답변 생성은 RAG 파이프라인의 최종 단계로, 시스템이 검색 단계에서 수집된 관련 데이터를 활용하여 입력 질의에 대한 응답을 생성하는 단계입니다. 이 단계에서는 검색된 텍스트 및 시각 정보를 제로 질문과 통합하고 LLM 또는 MLLM을 통해 처리하여 정확하고 맥락에 맞는 답변을 생성합니다.

3.4.1. 텍스트 전용 검색 데이터를 사용한 답변 생성 첫 번째 전략에서 시스템은

검색된 텍스트 데이터, 제로 질문 및 도메인별 프롬프트를 텍스트 기반 처리에 최적화된 대규모 언어 모델(LLM)의 입력으로 결합합니다. 이 접근 방식은 검색된 시각적 데이터를 제외하고 답변 합성을 위해 텍스트 컨텍스트에만 집중합니다. 이 과정은 다음과 같이 표현할 수 있습니다.

$$\text{ALLM} = \text{LLM}(\text{concat}(P, Q, \text{Top@Ktext})) \quad (9)$$

여기서 P는 제조 분야에 특화된 질문으로 구성된 프롬프트이고, Q는 입력 쿼리를 나타냅니다. 이 전략은 검색된 텍스트 데이터만으로 쿼리에 대한 충분한 맥락을 제공하는 경우에 효율적이며 적합합니다. 그러나 시각적 정보를 고려하지 않기 때문에 다중 모드 쿼리에는 효과가 제한될 수 있습니다.

3.4.2. 다중 모달 검색 데이터를 활용한 답변 생성

두 번째 전략에서 시스템은 검색된 텍스트 데이터, 검색된 시각 데이터 및 제조 질문을 다중 모달 언어 모델(MLLM)의 입력으로 결합합니다. 이 접근 방식은 텍스트와 이미지를 모두 통합하여 모델이 답변을 생성할 때 텍스트 정보와 함께 시각적 맥락을 고려할 수 있도록 합니다. 생성된 답변은 다음과 같이 공식화할 수 있습니다.

처럼:

$$AMLLM = MLLM(\text{concat}(P, Q, T_{\text{op}@K\text{text}}, T_{\text{op}@K\text{Image}}, \text{air})) \quad (10)$$

이 전략은 텍스트에 참조된 이미지와 이미지 벡터 데이터베이스에서 직접 가져온 관련 이미지를 사용하여 답변을 생성합니다. 시각적 데이터가 연결, 색인화 또는 검색되지 않은 경우에는 Top @KImage 및 air가 항상 존재하지 않을 수 있다는 점에 유의해야 합니다.

부록 A에는 다양한 유형의 제조 관련 질문에 대한 저희가 설계한 프롬프트가 포함되어 있으며, ManuRAG 변형 간의 차이점에 대해서는 아래 3.5절에서 자세히 설명드리겠습니다.

3.5. ManuRAG 변형

본 논문에서는 MQA(다중 모달 인텔리전스)에서 텍스트 및 시각 데이터 정렬을 위한 최적의 접근 방식을 탐구하기 위해 ManuRAG 프레임워크의 네 가지 변형을 제안합니다. 구체적으로, 이 프레임워크는 텍스트와 이미지 데이터를 통합하는 다양한 전략, 즉 정렬이 임베딩 전에 이루어져야 하는지, 임베딩 공간 내에서 이루어져야 하는지, 또는 임베딩 후에 이루어져야 하는지를 살펴봅니다. 그림 1은 각 변형의 워크플로우를 보여주며, 다중 모달 데이터 처리, 인덱싱 전략 및 답변 생성 방법의 차이점을 강조합니다.

ManuRAG1은 텍스트 정보를 텍스트 벡터 데이터베이스에, 시각 데이터를 이미지 벡터 데이터베이스에 임베딩하여 텍스트 데이터와 시각 데이터를 모두 처리합니다. 답변 생성은 MLLM을 사용하여 수행됩니다.

ManuRAG3는 검색된 텍스트 덩어리 내에 연결된 시각적 데이터의 검색을 우선시함으로써 ManuRAG1을 확장한 것입니다. 텍스트와 이미지를 모두 사용합니다.




그림 1: ManuRAG 프레임워크의 네 가지 유형

벡터 데이터베이스는 인덱싱에 사용되지만, 특히 참조된 이미지를 검색하는 데 중점을 둡니다.

본문.

ManuRAG2는 이미지 벡터 데이터베이스를 제거하여 ManuRAG3를 간소화합니다. 이 시스템은 텍스트 데이터만을 기반으로 작동하며, 임베딩을 텍스트 벡터 데이터베이스에 저장하고 LLM을 사용하여 답변을 생성합니다.

ManuRAG4는 멀티모달 데이터 처리에서 독창적인 단계를 도입합니다.

텍스트에서 참조된 시각적 데이터(예: 그림 및 표)를 식별한 후, MLLM을 사용하여 해당 시각적 콘텐츠를 설명 텍스트로 변환합니다. 변환된 텍스트는 텍스트 벡터 데이터베이스에 색인화되고, LLM(또는 선택적으로 MLLM)을 사용하여 답변이 생성됩니다. 이 변형은 시각적 데이터를 텍스트 기반 표현으로 변환하여 임베딩 전에 텍스트 데이터와 시각적 데이터를 정렬합니다. 그러나 이러한 변환 과정에서 특히 원래의 시각적 맥락이 중요한 경우 일부 정보 손실이 발생할 수 있습니다.

4. 실험

본 절에서는 실제 데이터셋을 사용하여 MQA(Machine Content Application)에 대한 제안된 방법들의 효과를 평가하는 실험을 제시하여 실질적인 타당성을 확보합니다. 본 연구는 다양한 RAG(Recognition Assessment) 시스템이 MQA 성능을 어떻게 향상시키는지 평가하고, 문맥 정밀도와 문맥 재현율이 관련 정보 검색 효율성에 미치는 영향을 분석하는 데 중점을 둡니다. 데이터셋, 기준 모델, 구성 등을 포함한 실험 설정은 4.1절에 자세히 설명되어 있으며, 평가 지표는 4.2절에서 소개합니다. 모델의 전반적인 성능과 문맥 검색 관련 성능은 각각 4.3절과 4.4절에서 논의합니다.

4.1. 설정 4.1.1.

기준선 및 구성

본 연구에서는 ManuRAG의 다양한 변형 모델을 다른 QA 솔루션과 비교하여 성능 향상 및 본 접근 방식이 제공하는 고유한 장점을 입증합니다. 비교에 사용된 모든 모델은 동일한 MLLM인 GPT-4O를 기반으로 하므로 다중 모드 기능을 위한 일관된 토대를 제공합니다. 본 평가는 표준 구성 및 제조 관련 프롬프트가 추가된 기본 GPT-4O뿐만 아니라 기존 RAG 방식 및 다중 모드 RAG 방식을 포함한 다양한 RAG 모델을 포괄합니다.

모든 RAG 모델은 텍스트 인덱싱 및 검색에 Ada v2를 사용하고, 이미지 벡터 저장소를 사용하는 경우 이미지 인덱싱 및 검색에 CLIP을 사용합니다.

최종 답변 생성에는 GPT-4O가 사용됩니다. ManuRAG 변형과 RAG 방법 모두 LlamaIndex 프레임워크[32]를 사용하여 구축되었습니다. RAG 컨텍스트 검색을 위한 소스 문서는 동일한 PDF 버전에서 추출되었습니다.

널리 인정받는 교재인 현대 제조의 기초[49]의 공학 재료, 제조 공정 및 전자 기술을 다루고 있습니다.

모든 실험은 Edge et al.의 연구를 따라 $k=1$, $S=600$, $O=100$ 으로 설정하여 Google Colab에서 실행되었습니다. k , S , O 값은 5% 샘플 테스트에서의 성능을 기반으로 선정되었습니다. 기준 모델을 제외한 모든 모델은 부록 A에 자세히 설명된 통합 프롬프트 구성을 사용합니다. 벤치마크 모델에 대한 추가 정보는 다음과 같습니다.

- GPT-4O: 별도의 프롬프트 없이 GPT-4O를 사용한 직접적인 품질 보증.
- GPT-4O (CoT): 사고 연쇄(CoT)를 통해 강화된 직접 QA
GPT-4O를 이용한 단계별 추론을 가능하게 하는 프롬프트입니다.
- RAG: 파일에서 직접 추출한 원시 텍스트에 RAG를 적용한 예
모든 시각적 데이터를 포함합니다.
- RAGhq: 3.1절에 설명된 방법론을 사용하여 추출한 고도로 구조화된 텍스트를 활용하는 고품질 RAG 프레임워크입니다.
- ManuRAG1 3: 3.5절에 설명된 MMRAG의 변형입니다.
- ManuRAG4: 3.5절에서 소개된 MMRAG의 변형으로, GPT-4O를 통합하여 이미지 데이터를 텍스트로 변환함으로써 문맥 이해를 더욱 풍부하게 합니다.

4.1.2. 평가 데이터 세트 본 연구에서는

Fundamentals of Modern Manufacturing [49]의 공식 해답에서 추출한 1,515개의 질문-답변 쌍으로 구성된 세 가지 데이터 세트를 사용하여 벤치마크를 평가합니다. 특히, 이 데이터 세트는 RAG 검색에 사용된 콘텐츠에서 제외됩니다. 데이터 세트는 다음과 같이 구성됩니다.

- MathQ: 사실적 정확성과 의미론적 이해를 요구하는 309개의 수학 관련 질의응답 쌍으로 구성되어 있으며, 공식, 표, 그림 등을 포함한 다양한 형식을 사용합니다. 전체리 과정에서 지나치게 긴 질문/답변(토큰 600개 이상)은 제외하거나, LLM 호환성을 위해 하위 질문을 삭제합니다.

- 객관식 문제: 정답을 선택하는 능력을 평가하는 471개의 객관식 문항으로 구성되며, 일부 문항은 다중 모드 분석을 요구합니다. 정답은 (예: abcd)와 같이 명확한 선택지로 분류되어 있으며, 정확한 평가를 위해 설명이 제공됩니다.

- 연구 질문: 개념적 이해도를 평가하기 위해 상세한 텍스트 내용에 대한 이해와 추론에 초점을 맞춘 735개의 리뷰 QA 쌍을 작성합니다.

각 데이터 세트 유형의 예시는 부록 B에 제공됩니다.

4.2. 평가 지표

우리는 사실적 정확성, 의미 유사성, ROUGE, 컨텍스트 정밀도 및 컨텍스트 재현율과 같은 QA 모델의 성능을 종합적으로 평가하기 위해 GPT-4와 함께 RAGAS[50]의 5가지 평가 지표를 채택합니다.

자세한 측정 기준과 그 공식은 다음과 같습니다.

4.2.1. 사실적 정확성

사실적 정확성은 생성된 답변을 정답과 비교하여 F1 점수를 측정하는 방식으로, 모든 평가 모델에 적용됩니다. 이 지표는 생성된 답변이 기준 답변과 얼마나 일치하는지를 평가하며, 0에서 1 사이의 값을 가지며, 값이 높을수록 성능이 우수함을 나타냅니다. GPT-4는 답변과 기준 답변을 각각 독립적인 주장으로 분해하는 데 사용되며, 자연어 추론을 통해 두 주장 간의 사실적 일치도를 평가합니다. F1 점수를 통해 정밀도와 재현율의 균형을 맞추므로써, 이 지표는 기준 답변 대비 생성된 답변의 정확도를 종합적으로 측정합니다.

참양성(TP)은 응답에 있는 주장 중 참조 항목에 존재하는 주장의 수를 나타냅니다. 거짓양성(FP)은 응답에 있는 주장 중 참조 항목에 존재하지 않는 주장의 수를 나타내며, 거짓음성(FN)은 참조 항목에 있지만 응답에 존재하지 않는 주장의 수를 나타냅니다. 이러한 값을 사용하여 정밀도, 재현율 및 F1 점수는 다음과 같이 계산됩니다.

$$\text{정밀도} = \frac{TP}{TP + FP} \quad (1)$$

$$\text{회상} = \frac{TP}{TP + FN} \quad (2)$$

$$\text{사실 정확성 (F1 점수)} = \frac{2 \times \text{정밀도} \times \text{재현율}}{\text{정밀도} + \text{재현율}} \quad (3)$$

4.2.2. 의미적 유사성

의미 유사성은 생성된 답변이 참조 답변과 의미적으로 얼마나 가까운지를 평가하며, 이는 평가 대상인 모든 모델에 적용됩니다.

이는 0에서 1 사이의 의미 유사성 점수를 계산하는 교차 인코더 모델을 사용하여 측정됩니다. 점수가 높을수록 생성된 답변과 실제 답변 간의 의미적 일치도가 높다는 것을 나타냅니다.

4.2.3. ROUGE ROUGE

는 객관식 문제(MCQ)에서 생성된 답과 참조 답 사이의 중복도를 평가합니다. F1 점수를 사용하여 생성된 응답과 참조 응답 간의 유사성을 정량화함으로써 n-그램(n=1)의 중복도를 측정합니다. ROUGE의 공식은 다음과 같습니다.

$$\text{정밀도} = \frac{\text{겹치는 n-그램의 개수}}{\text{생성된 답변에 포함된 n-그램의 총 개수}} \quad (11)$$

$$\text{회상} = \frac{\text{겹치는 n-그램의 개수}}{\text{참조에 포함된 n-그램의 총 개수}} \quad (12)$$

$$\text{Recalln (정밀도)} \quad \text{ROUGEn} = 2 \times \frac{\text{Precisionn} \times \text{Recalln}}{\text{Precisionn} + \text{Recalln}} \quad (13)$$

한 일치 평가에 중요한 객관식 문제 데이터 세트에서 어휘 유사성을 평가하는 간단하고 효과적인 방법을 제공합니다.

4.2.4. 문맥 정밀도

컨텍스트 정밀도는 검색된 컨텍스트 청크가 쿼리와 얼마나 관련성이 있는지를 측정합니다. 이는 RAG1, RAG2, ManuRAG1부터 ManuRAG4까지를 포함한 RAG 기반 모델에서 검색된 컨텍스트 중 관련성 있는 청크의 비율을 평가합니다. 이 지표는 가중 정밀도 접근 방식을 사용하며, 여기서 vk 는 순위 k 에 있는 각 청크에 할당된 가중치를 나타냅니다. 순위 k ($\text{topk} = 3$)에서의 정밀도는 다음과 같이 계산됩니다.

$$\text{정밀도}@k = \frac{\text{트루 포지티브}@k}{\text{참양성}@k + \text{거짓양성}@k} \quad (1)$$

이러한 정밀도 값을 사용하여 상위 K 개 결과에 대한 컨텍스트 정밀도는 다음과 같이 계산됩니다.

$$\text{컨텍스트 정밀도@K} = \frac{\sum_{k=1}^K (\text{정밀도@k} \times vk)}{\text{Top@K에 있는 관련 항목의 총 개수}} \quad (2)$$

4.2.5. 컨텍스트 재현율 컨텍스트

재현율은 RAG 기반 모델에서 검색된 컨텍스트 중 관련 컨텍스트의 비율을 전체 관련 컨텍스트 대비 얼마나 정확하게 검색되었는지를 측정합니다. 정답(Ground Truth, GT)은 정확하다고 알려져 있고 평가 기준으로 사용되는 참조 주장 또는 사실 집합을 의미합니다. 이 지표는 정답에 있는 주장 중 검색된 컨텍스트에 기인하는 주장의 수를 계산합니다. 컨텍스트 재현율 공식은 다음과 같습니다.

$$\text{문맥 회상} = \frac{|\text{GT는 검색된 컨텍스트에 귀속됨}|}{\text{GT의 총 청구 건수}} \quad (1)$$

4.3. 전반적인 성능

표 1에 제시된 MQA 모델의 성능 분석 결과, ManuRAG4는 모든 데이터셋에서 일관되게 최고의 성능을 보였습니다. 특히 MathQ 데이터셋에서 GPT-4O 및 CoT를 적용한 GPT-4O보다 높은 사실적 정확도를 달성하여 수학적 추론 처리 능력이 뛰어남을 입증했습니다. 객관식 문제(MCQ)에서도 사실적 정확도, 의미 유사성, ROUGE 점수 모두에서 최고를 기록했습니다(표 2). 추론형 문제(RQ)에서는 비교적 단순한 텍스트 기반 질문 특성상 모델 간 성능 차이가 크지 않지만, ManuRAG4는 여전히 가장 높은 사실적 정확도를 보여주며 전반적인 효율성을 재확인했습니다.

네스 호.

MMRAG 설계는 데이터 세트에 따라 다양한 성능을 보입니다. ManuRAG4는... ManuRAG는 일관적으로 최상의 결과를 제공하지만, ManuRAG1 및 ManuRAG2와 같은 다른 구성은 특정 작업에서 강점을 보입니다. 예를 들어, ManuRAG1은 텍스트 컨텍스트에 포함된 링크를 통해 이미지를 효과적으로 검색하여 MCQ 및 RQ 작업에서 우수한 성능을 보이지만 MathQ에서는 저조한 성능을 보여 이 검색 방법으로는 수학적 추론을 처리하는 데 한계가 있음을 나타냅니다. ManuRAG3의 낮은 성능은 더 많은 이미지를 검색하는 것이 MQA에서 더 나은 답변으로 이어지는 것은 아니라는 점을 시사합니다.

모든 데이터 세트에서 CoT 추론을 포함시키면 GPT-4O의 성능이 향상되어 논리적 추론 능력을 향상시키는 데 효과적임을 보여줍니다.

QA 작업에 대한 정확도. RAGhq는 RAG보다 우수한 성능을 보여주며, 다중 모달 데이터 추출 방법의 효과성을 강조합니다.

의미 유사성 점수는 모든 모델과 데이터 세트에서 전반적으로 높게 나타납니다.

참고 답변과의 높은 일치도를 반영합니다. 그러나 의미적 유사성만으로는 사실적 정확성을 보장할 수 없으며, 특히 정확한 추론과 정보 검색이 중요한 MathQ 및 MCQ 문제에서는 더욱 그렇습니다. 의미적 유사성은 전반적인 일치도를 평가하는 데 유용하지만, MQA 과제에서는 사실적 정확성이 수행 능력을 나타내는 더욱 신뢰할 수 있는 지표입니다.

부록 B에는 다양한 모델 간의 QA 예시 비교를 포함했습니다.

4.4. 상황 기반 성능

사실적 정확성은 생성된 답변이 GT와 얼마나 잘 일치하는지를 평가하지만, RAG 기반 모델에서 중요한 검색된 맥락의 질은 평가하지 않습니다. 맥락 정밀도와 재현율은 검색된 맥락의 관련성과 포괄성을 측정하여 추가적인 통찰력을 제공하며, 모델이 생성된 답변을 얼마나 잘 뒷받침하는지에 대한 더 깊은 이해를 가능하게 합니다.

이 섹션에서는 표 3에 나타난 바와 같이 생성된 답변의 품질과 검색된 맥락의 완전성을 모두 평가합니다.

ManuRAG4는 임베딩 전에 텍스트와 이미지 데이터를 정렬함으로써 뛰어난 통합성과 다양한 작업에서 일관된 성능을 달성합니다. 이 알고리즘은 다양한 데이터셋에서 견고한 성능을 보여주며, MathQ 및 MCQ에서 최고 수준의 문맥 정밀도를, MCQ 및 RQ에서 높은 재현율을, 그리고 검색 증강 작업에서 관련성과 적용 범위를 효과적으로 균형 있게 유지합니다.

RAGhq는 RQ에서 문맥 정확도가 뛰어난 고품질의 인덱싱된 텍스트 데이터의 중요성을 강조하는 반면, 인덱싱된 텍스트 길이가 더 짧은 표준 RAG는 MathQ에서 가장 높은 재현율을 달성하고 MCQ 및 RQ에서는 경쟁력 있는 재현율을 보여 정확도와 재현율 간의 상충 관계를 드러냅니다. 이와 대조적으로 ManuRAG1, ManuRAG2, ManuRAG3는 RQ에서 경쟁력 있는 정확도를 보이지만 MathQ 정확도에서는 어려움을 겪고 MathQ 및 MCQ에서는 낮은 재현율을 보이는데, 이는 텍스트와 이미지 데이터를 별도의 벡터 저장소에 저장하는 데 따른 한계를 반영합니다.

5. 결론 및 향후 연구 방향

디지털 제조 기술의 발전은 복잡한 다중 모드 데이터를 통합 및 분석할 수 있는 지능형 품질 보증 시스템을 요구합니다. 기존의 RAG(Reduced Assessment Group) 방식은 이러한 데이터를 효과적으로 처리하는 데 어려움을 겪는 경우가 많습니다. ManuRAG는 맞춤형 MMRAG(Multi-Mode Assessment Group) 프레임워크를 도입하여 이러한 문제를 해결합니다.

표 1: MQA에 대한 다양한 방법별 여러 지표 비교 (최고 성능 기준)
 각 데이터 세트는 굵게 표시되어 있습니다.

사실적 정확성(%) 의미적 유사성(%)		
범주	사실적 정확성(%) 의미적 유사성(%)	
매스큐		
GPT-4O	49.91	87.03
GPT-4O(CoT)	56.22	86.85
조각	59.51	87.66
라그크	59.48	87.90
마누라그1	19.14	77.03
마누라그2	56.69	87.32
마누라그3	55.31	87.32
마누라그4	62.03	87.82
객관식 문제		
GPT-4O	6.99	77.60
GPT-4O(CoT)	78.58	94.79
조각	85.22	96.52
라그크	86.38	96.62
마누라그1	86.82	95.27
마누라그2	60.54	91.20
마누라그3	61.62	90.15
마누라그4	87.61	96.82
RQ		
GPT-4O	38.01	89.93
GPT-4O(CoT)	40.47	89.92
조각	45.51	91.08
라그크	45.64	91.12
마누라그1	45.34	90.97
마누라그2	40.53	91.15
마누라그3	39.10	91.13
마누라그4	45.75	91.00

표 2: 다양한 모델에서 MCQ(전체)에 대한 ROUGE 점수

모델	붉은색 (%)
GPT-4O	10.35
GPT-4O(CoT)	77.61
조각	86.10
라그크	86.71
마누라그1	81.19
마누라그2	63.13
마누라그3	58.88
마누라그4	86.77

표 3: MathQ, MCQ 및 RQ에 대한 문맥 재현율 및 정밀도

카테고리	문맥 정확도(%)				문맥 회상률(%)			
	MCQ	MathQ	RQ	MCQ	MathQ	RQ		
RAG	81.95	92.56	92.24	33.39	67.83	81.23		
RAGhq	85.35	93.20	93.74	34.61	57.00	81.27		
마누RAG1	79.41	33.66	92.79	33.36	30.95	81.47		
마누RAG2	80.89	33.33	92.52	32.01	22.98	80.63		
ManuRAG3	79.41	33.33	92.65	33.44	20.47	80.86		
ManuRAG4	86.84	93.53	91.84	37.88	62.26	81.56		

MQA의 경우, 실험 결과는 ManuRAG4가 우수한 성능을 보임을 입증합니다.

기존 방법을 활용하여 적절한 RAG를 선택하는 데 유용한 통찰력을 제공합니다.

다양한 제조 시나리오에 맞춰 이미지와 텍스트 데이터를 정렬하는 전략을 수립합니다. 제조 분야를 넘어, ManuRAG의 적응형 디자인은 다양한 분야에서 활용될 수 있는 가능성을 제시합니다.

법률, 의료 등 다양한 분야에서 도메인별 품질 보증을 위한 다목적 도구
재원.

ManuRAG는 여러 장점에도 불구하고 개선의 여지가 있는 한계점을 가지고 있습니다. 첫째, Jina-CLIP[41]과 같은 더욱 강력한 멀티모달 임베딩 모델을 채택하면 텍스트 정렬을 향상시킬 수 있습니다.

그리고 임베딩 공간에 시각적 정보를 포함합니다. 둘째, 다른 RAG 프레임워크의 고급 검색 설계를 통합하면 성능을 더욱 향상시킬 수 있습니다.

성능[51, 52]. 마지막으로, ManuRAG의 향후 버전에서는 이를 지원해야 합니다.

CAD 모델[53], 비디오[54] 또는 시계열을 포함한 추가 데이터 유형

센서 데이터는 현대 제조 정보의 복잡성과 다양성이 증가하는 문제에 대응하기 위해 사용됩니다.

부록 A. 프롬프트 디자인

다음은 MathQ 시험을 위해 설계된 문제입니다.

MathQ 프롬프트

제조 전문가로서, 다음 방법을 사용하여 수학 문제를 단계별로 풀어보세요.

제공된 맥락과 제조 계산에 대한 여러분의 지식을 바탕으로, 추론 과정을 명확하게 설명하십시오.

{context_str}

질문:

쿼리: {query_str}

답변:

다음은 객관식 문제(MCQ)를 위해 고안된 질문입니다.

객관식 문제

제조 전문가로서, 제공된 맥락을 바탕으로 다음 객관식 질문에 단계별로 답하십시오. 정답인 문자만 선택하십시오.

답변 형식: "설명": "여기
에 설명을 입력하세요.", "선택 사항": "답변: (d), (e), (g)."

다음 질문에 답하세요: 쿼리: {query_str}

답변:

다음은 RQ에 대해 설계된 프롬프트입니다.

RQ 프롬프트

귀하는 제조 분야 전문가입니다. 제조 공정 및 재료에 대한 귀하의 지식을 바탕으로 다음 단답형 질문에 답하십시오.
자세한 설명과 함께 답변의 근거를 제시해 주십시오. 간결하고 명확하며 정확하게 답변해 주시기 바랍니다.

다음 질문에 답하세요: 쿼리: {query_str}

답변:

부록 B. QA 예시

이 섹션에서는 다양한 유형의 QA 예제와 세 가지 모델(GPT-4O(CoT), 기존 RAG, 그리고 가장 성능이 뛰어난 ManuRAG 변형)이 생성한 답변을 비교합니다.

부록 B.1. MathQ 예제

다음은 MathQ의 QA 쌍 예시입니다. ManuRAG4는 정확한 답을 생성하는 반면, RAG와 GPT-4O(CoT)는 실패합니다. GPT-4O(CoT)는 제조 문서의 표 4.1이나 관련 공식을 참조할 수 없어 정확도가 떨어집니다. 반면 RAG는 관련 정보를 검색합니다.

텍스트 데이터에서 공식을 도출하는 데에는 한계가 있지만, 표 4.1(교과서)의 데이터와 같은 시각적 정보에 접근할 수 없다는 제약이 있습니다.

MathQ 문제

샤프트의 초기 직경은 25.00mm입니다. 이 샤프트는 팽창 끼워맞춤 조립 공정을 통해 구멍에 삽입됩니다. 쉽게 삽입될 수 있도록 샤프트는 냉각을 통해 직경을 줄여야 합니다.

샤프트의 직경을 24.98mm로 줄이려면 샤프트를 실온(20°C)에서 몇 도까지 낮춰야 하는지 결정하십시오. 표 4.1을 참조하십시오.

정답

표 4.1에 따르면 강철의 경우 $\alpha = 12 \times 10^{-6} \text{ mm/mm/}^\circ\text{C}$ 입니다. 식 (4.1)을 다음과 같이 수정합니다.

$$D_2 - D_1 = \alpha D_1 (T_2 - T_1)$$

알려진 값을 대입하세요:

$$24.98 - 25.00 = 12 \times 10^{-6} \cdot 25.00 \cdot (T_2 - 20)$$

단순화하세요:

$$0.02 = 300 \times 10^{-6} \cdot (T_2 - 20)$$

$$0.02 = 0.0003(T_2 - 20)$$

$$0.02 = 0.0003T_2 - 0.006$$

$$0.02 + 0.006 = 0.0003T_2$$

$$0.014 = 0.0003T_2$$

$$T_2 = \frac{-0.014}{0.0003}$$

$$T_2 = \underline{46.67^\circ\text{C}}$$

GPT-40(COT)

이 문제를 해결하려면 다음이 필요합니다...

계산: 1단계: 열 수축의 개념 이해하기...

4단계: 제공된 표를 이용하여 선팅창 계수를 찾으십시오...

구체적인 데이터(표 4.1)가 언급되어 있지만 여기에 제공되지 않았으므로, 다음과 같이 가정해 보겠습니다...

6단계: 최종 온도를 계산합니다...

가정한 선팅창 계수를 사용하여 계산한 온도는 다음과 같습니다.

$$T_2 = -52.73^{\circ}\text{C}$$

결론: 축의 직경을 25.00mm에서 24.98mm로 줄이려면 축을 약 -52.73°C 까지 냉각해야 합니다.

조각

이 문제를 해결하려면 다음이 필요합니다...

열팽창 또는 수축으로 인한 지름 변화 계산 공식은 다음과 같습니다.

$$D_2 = D_1 + \alpha \cdot D_1 \cdot (T_2 - T_1)$$

먼저 지름의 변화를 계산합니다... 선형 열팽창 계수(α)를 이용하여 온도는 다음과 같이 계산됩니다.

$$T_2 = -48.39^{\circ}\text{C}$$

결론: 팅창 끼워맞춤 조립 공정에서 원하는 직경 감소를 얻으려면 샤프트를 약 -48.39°C 까지 냉각해야 합니다.

마누라그4

이 문제를 해결하려면 다음이 필요합니다...
열수축으로 인한 직경 변화는 다음과 같습니다.

$$D_2 = D_1 \cdot \alpha \cdot (T_2 - T_1)$$

계산: 1. 지름의 변화량을 계산합니다. ... 2. 계산된 값을 공식에 대입합니다. ... 3. 온도의 변화량을 계산합니다.

$$T_2 = +20 - \frac{0.02}{0.0003}$$

$$T_2 = -46.67^{\circ}\text{C}$$

결론: 팽창 끼워맞춤 조립 작업을 위해 샤프트의 직경을 25.00mm에서 24.98mm로 줄이려면 샤프트를 약 -46.67°C까지 냉각해야 합니다.

부록 B.2. 객관식 문제 예시

이 문제는 제조 재료에 관한 객관식 문제입니다.

GPT-4o(CoT)는 완전히 정확한 답을 생성하지 못하는 반면, RAG와 ManuRAG4는 모두 정확한 답을 제공합니다. RAG와 ManuRAG4는 제조 교재에서 추출한 텍스트 맥락을 효과적으로 활용하여 정확한 결과를 얻습니다.

객관식 문제

다음 중 섬유 강화 플라스틱(FRP)의 섬유로 사용되는 재료는 무엇입니까? (두 개 이상 선택) (a) 산화알루미늄, (b) 붕소, (c) 탄소/흑연, (d) 에폭시, (e) 케블라 49, (f) S-유리, (g) 불포화 폴리 에스터.

정답

FRP에서 섬유로 사용되는 올바른 재료는 (a), (b), (c), (e), (f)입니다.

GPT-4O(CoT)

설명: 섬유 강화 플라스틱(FRP)은 기계적 특성을 향상시키기 위해 섬유로 보강된 고분자 매트릭스로 만들어진 복합 재료입니다. 주어진 보기 중: - (a) 산화알루미늄은 일반적으로 FRP에서 섬유로 사용되지 않습니다. 오히려 세라믹이나 분말 형태의 보강재로 더 흔하게 사용됩니다. - (b) 붕소는 특정 고성능 FRP에서 섬유로 사용됩니다. - (c) 탄소/흑연은 가장 일반적이고 효과적인 섬유 보강재 중 하나입니다. - (d)

(e) 에폭시는 일반적으로 FRP에서 섬유가 아닌 폴리머 매트릭스의 한 종류입니다. - (f) 케블라 49는 고강도로 알려진 아라미드 섬유로 FRP에 사용됩니다. - (g) S-유리는 더 높은 강도를 위해 FRP에 사용되는 특수 유리 섬유입니다. - (g) 불포화 폴리에스터 또한 섬유가 아닌 폴리머 매트릭스의 한 종류입니다.

선택 사항: (b), (c), (e), (f). _____

조각

설명: 섬유 강화 플라스틱(FRP)은 고분자 매트릭스에 섬유를 보강한 복합 재료입니다.

제공된 문맥에 따르면 FRP에 사용되는 주요 섬유 재료에는 유리(E-유리 및 S-유리 등), 탄소 및 케블라 49가 포함됩니다. 또한, 덜 일반적인 섬유로는 붕소, 탄화규소(SiC), 산화알루미늄 및 강철이 언급됩니다. 에폭시와 불포화 폴리에스터는 섬유가 아니라 FRP에 사용되는 고분자 매트릭스의 일종입니다.

선택 사항: (a), (b), (c), (e), (f). _____

마누라그4

설명: 이 문제는 섬유 강화 플라스틱(FRP)에 섬유로 사용되는 재료를 묻고 있습니다. 주어진 맥락에 따르면 FRP에 섬유로 사용되는 재료는 다음과 같습니다. - (a) 산화알루미늄 (Al_2O_3)

(a) FRP에서 덜 일반적인 섬유 재료로 언급됨. - (b) 붕소

(a) 첨단 복합재료에 사용되는 섬유로 언급됩니다. - (c) 탄소/흑연은 FRP의 주요 섬유 재료입니다.

- (e) 케블라 49

FRP의 주요 섬유 재료로 등재되어 있습니다. - (f) S-유리는 한 종류입니다.

FRP에 사용되는 유리 섬유.

에폭시와 불포화 폴리에스터는 섬유가 아니라 FRP에 사용되는 매트릭스 재료입니다.

선택 사항: (a), (b), (c), (e), (f). _____

부록 B.3. RQ 예시

다음은 데이터 세트에 포함된 검토 질문의 예입니다. GPT-4O(CoT)는 포괄적인 목록을 제공하지만 관련성이 떨어지는 변수도 포함합니다.

압력이나 장애물과 같은 요소들이 집중력을 저하시킬 수 있습니다. RAG는 핵심 요소를 파악합니다.

변수를 정확하게 활용하고 검색된 컨텍스트를 사용하지만 일관성이 부족합니다.

변수 우선순위 지정. ManuRAG4는 가장 간결하고 정확한 결과를 제공합니다.

관련 맥락 정보를 효과적으로 검색하고 통합하여 설명합니다.

출처.

RQ 문제

물질 확산에 영향을 미치는 중요한 변수는 무엇입니까?

정답

픽의 제1법칙에 따르면 물질 확산은 다음과 같은 변수들에 따라 달라진다.

- 확산 계수(D): 확산 계수는 온도가 증가함에 따라 급격히 증가하므로 온도는 중요한 변수입니다.
- 농도 기울기(dc/dx): 농도 차이
확산하는 물질이 거리에 걸쳐 이동하는 현상.
- 접촉 면적(A): 확산이 일어나는 영역.
- 시간(t): 확산 과정의 지속 시간.

GPT-4O(CoT)

설명: 물질 확산은 제조 및 재료 과학에서 매우 중요한 공정입니다. 확산에 영향을 미치는 변수는 다음과 같습니다.

1. 온도: 온도는 확산에 영향을 미치는 가장 중요한 요인일 것입니다. 온도가 높을수록 원자 운동이 증가하여 확산 속도가 빨라집니다.
2. 농도 기울기: 농도 기울기, 즉 두 지점 사이의 확산 물질 농도 차이는 확산 속도에 직접적인 영향을 미칩니다.
3. 확산 물질: 확산되는 입자의 크기, 질량 및 화학적 성질은 확산 속도에 영향을 미칩니다.
4. 매질 또는 기질 구조: 확산이 일어나는 물질의 구조는 매우 중요합니다.
5. 압력: 기체와 어느 정도는 액체에서 압력은 확산 속도에 영향을 미칩니다.
6. 시간: 장기간에 걸쳐 입자가 매질을 통해 퍼져나가면서 확산 범위는 자연스럽게 증가합니다.
7. 장벽 또는 계면의 존재: 코팅이나 상 경계와 같은 물리적 장벽 또는 계면은 확산 경로 및 속도를 변경할 수 있습니다.

조각

설명: 고체, 특히 금속에서의 물질 확산은 여러 가지 주요 변수의 영향을 받습니다.

1. 온도: 확산에 영향을 미치는 중요한 요소이며, 온도가 높을수록 확산 속도가 빨라집니다.
온도가 높아지면 원자의 이동성이 증가한다.
2. 농도 기울기(dc/dx): 차이를 나타냅니다.
확산되는 물질의 농도가 거리에 따라 변하는 현상.
3. 확산 계수(D): 물질 특유의 매개변수
원자가 물질을 통해 얼마나 쉽게 이동할 수 있는지를 정량화합니다.
4. 결정 구조 및 결합: 결정 구조 내의 빈자리 및 기타 불완전성은 원자 운동을 촉진합니다.
5. 재료 특성: 원자 크기, 결합 및 격자 구조
자연은 확산 행동에 영향을 미칩니다.
6. 표면적(A): 경계를 통과하는 면적
확산이 일어난다.

마누라그4

설명: 물질 확산에 영향을 미치는 중요한 변수에는 다음이 포함됩니다.

1. 온도: 확산에 있어 매우 중요한 요소입니다. 온도가 높을수록 열적 진동이 증가하여 원자들이 더 자유롭게 움직일 수 있습니다.
자유로이.
2. 농도 기울기(dc/dx): 확산의 원동력으로, 원자 농도의 차이를 나타냅니다.
거리.
3. 확산 계수(D): 물질 특유의 매개변수
원자가 물질을 통해 이동할 수 있는 용이성을 정량화합니다.
4. 시간(t): 확산이 일어나는 기간은 다음과 같은 영향을 미칩니다.
확산 정도.
5. 경계면적(A): 확산이 일어나는 영역
이러한 현상이 발생하면 물질 전달 속도에 영향을 미칩니다.

참고 자료

- [1] Fei Tao, Qinglin Qi, Ang Liu 및 Andrew Kusiak. 데이터 기반 스마트 제조. 제조 시스템 저널, 48:157-169, 2018.
- [2] Montasser Billah Letaief, Mehdi Tlija 및 Borhen Louhichi. 제조 비용 추정을 위한 CAD/CAM 데이터 재사용 접근법. International Journal of Computer Integrated Manufacturing, 33(12):1208– 1226, 2020.
- [3] Chuanni He, Min Liu, Yuxiang Zhang, Zhigao Wang, Simon M Hsiang, Gongfan Chen, Weiqiang Li 및 Gongfu Dai. 불확실성 속의 시간간 인력 시각화 및 조건부 용량 합성. Journal of Management in Engineering, 39(2):04022071, 2023.
- [4] Mohamed Hedi Karray, Farhad Ameri, Melinda Hodkiewicz 및 Thierry Louge. Romain: 산업 유지보수를 위한 bfo 호환 참조 온톨로지. 응용 온톨로지, 14(2):155–177, 2019.
- [5] OpenAI. Chatgpt(autocad master). <https://openai.com/chatgpt>, 2025. AutoCAD 및 설계 관련 안내를 위한 AI 기반 도우미. 2025년 1월 26일에 접속함.
- [6] Streebo. 제조 분야의 Chatgpt: 사용 사례. <https://www.streebo.com/chatgpt-manufacturing-use-cases> . 접속일: 2025년 1월 26일.
- [7] Binil Starly, Pavel Koprov, Akshay Bharadwaj, Thomas Batchelder 및 Bennett Breitenbach. "비현실적인" 공장: 산업 메타버스에서 기계와 공장의 차세대 디지털 트윈. Manufacturing Letters, 37:50–52, 2023. ISSN 2213-8463. doi: <https://doi.org/10.1016/j.mfglet.2023.07.021>. URL <https://www.sciencedirect.com/science/article/pii/S2213846323000512> .
- [8] Yunqing Li, Xiaorui Liu 및 Binil Starly. 그래프 신경망을 이용한 제조 서비스 역량 예측. Journal of Manufacturing Systems, 74:291–301, 2024.
- [9] Akshay G Bharadwaj 및 Binil Starly. 대규모 CAD 모델 저장소에서 제품 설계를 위한 지식 그래프 구성. Advanced Engineering Informatics, 53:101680, 2022.

- [10] Shiyin Lu, Yang Li, Qing-Guo Chen, Zhao Xu, Weihua Luo, Kaifu Zhang 및 Han-Jia Ye. Ovis: 다중 모드 대형 언어 모델을 위한 구조적 임베딩 정렬. arXiv 사전 인쇄 arXiv:2405.20797, 2024.
- [11] 마르코 안토니오 칼리호네 소아레스(Marco Antonio Calijorne Soares)와 페르난도 실바 파레이라스(Fernando Silva Parreiras). 질문 답변 기술, 패러다임 및 시스템에 대한 문헌 검토. 킹 사우드 대학교 컴퓨터 및 정보 과학 저널, 32(6):635–646, 2020.
- [12] Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat 등. Gpt-4 기술 보고서. arXiv 사전 인쇄 arXiv:2303.08774, 2023.
- [13] A Vaswani. 당신에게 필요한 것은 오직 주의력뿐입니다. 신경 정보 처리 시스템의 발전, 2017.
- [14] Amanpreet Singh, Vivek Natarajan, Meet Shah, Yu Jiang, Xinlei Chen, Dhruv Batra, Devi Parikh 및 Marcus Rohrbach. 읽을 수 있는 vqa 모델을 향하여. IEEE/CVF 컴퓨터 비전 및 패턴 인식 컨퍼런스 프로시딩, 8317-8326페이지, 2019.
- [15] Fengbin Zhu, Wenqiang Lei, Youcheng Huang, Chao Wang, Shuo Zhang, Jiancheng Lv, Fuli Feng 및 Tat-Seng Chua. Tat-qa: 금융 분야의 표 형식 콘텐츠와 텍스트 콘텐츠의 혼합에 대한 질문 답변 벤치마크입니다. arXiv 사전 인쇄 arXiv:2105.07624, 2021.
- [16] Carlos Soto 및 Shinjae Yoo. 문서 레이아웃 분석을 위한 컨텍스트를 사용한 시각적 감지. 2019 자연어 처리의 경험적 방법 컨퍼런스 및 제9회 자연어 처리 국제 공동 컨퍼런스(EMNLP-IJCNLP) 프로시딩, 3464–3470페이지, 2019.
- [17] Yupan Huang, Tengchao Lv, Lei Cui, Yutong Lu 및 Furu Wei. Lay-outlmv3: 통합 텍스트 및 이미지 마스킹을 사용한 문서 AI 사전 훈련. 제30회 ACM 국제 멀티미디어 컨퍼런스 프로시딩, 4083-4091페이지, 2022.
- [18] Liangcai Gao, Xiaohan Yi, Yuan Liao, Zhuoren Jiang, Zuoyu Yan 및 Zhi Tang. 딥러닝 기반 PDF 수식 탐지 방법

문서. 2017년 제14회 IAPR 국제 문서 분석 및 인식 학회(ICDAR), 제1권, 553-558쪽. IEEE, 2017.

[19] Mingle Zhou, Ming Cai, Gang Li 및 Min Li. 주의 메커니즘이 통합된 엔드투엔드 공식 인식 방법. 수학, 11(1):177, 2022.

[20] Juan Terven, Diana-Margarita Córdova-Esparza 및 Julio-Alejandro Romero-González. 컴퓨터 버전의 YOLO 아키텍처에 대한 종합적인 검토: YOLOV1에서 YOLOV8 및 YOLONAS까지. 기계 학습 및 지식 추출, 5(4):1680–1716, 2023.

[21] Bin Wang, Zhuangcheng Gu, Chao Xu, Bo Zhang, Botian Shi 및 Conghui He. Unimernet: 실제 수학 표현 인식을 위한 범용 네트워크. arXiv preprint arXiv:2404.15254, 2024.

[22] Yanjun Ma, Dianhai Yu, Tian Wu 및 Haifeng Wang. Paddlepaddle: 산업 실무에서 얻은 오픈 소스 딥 러닝 플랫폼. 데이터 및 컴퓨팅의 최전선, 1(1):105–115, 2019.

[23] Arindam Chaudhuri, Krupa Mandaviya, Pratixa Badelia, Soumya K Ghosh, Arindam Chaudhuri, Krupa Mandaviya, Pratixa Badelia 및 Soumya K Ghosh. 광학 문자 인식 시스템. 스프링거, 2017.

[24] Yunqing Li 및 Binil Starly. 제조 서비스 검색에서 chat-gpt 응답을 풍부하게 하기 위한 지식 그래프 구축. 산업 정보 통합 저널, 40:100612, 2024.

[25] Mangesh P Bhandarkar 및 Rakesh Nagi. 민첩한 제조를 위한 단계 형상에서 단계 기반 특징 추출. 산업 컴퓨터, 41(1):3–24, 2000.

[26] Zhiyi Xue, Liangguo Li, Senyue Tian, Xiaohong Chen, Pingping Li, Liangyu Chen, Tingting Jiang 및 Min Zhang. 도메인 지식만 있으면 됩니다: 핀테크 도메인에서 llm 기반 테스트 케이스 생성의 현장 배포. 2024 IEEE/ACM 제46회 국제 소프트웨어 엔지니어링 컨퍼런스: 동반 논문집, 314-315페이지, 2024.

- [27] Jia-Yu Yao, Kun-Peng Ning, Zhen-Hui Liu, Mu-Nan Ning, Yu-Yang Liu 및 Li Yuan. Llm 거짓말: 환각은 버그가 아니라 적대적인 예로서의 기능입니다. arXiv 사전 인쇄 arXiv:2310.01469, 2023.
- [28] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Fei Xia, Ed Chi, Quoc V Le, Denny Zhou 등. 사고 연쇄 촉진은 대규모 언어 모델에서 추론을 유도합니다. 신경 정보 처리 시스템의 발전, 35:24824–24837, 2022.
- [29] Shunyu Yao, Dian Yu, Jeffrey Zhao, Izhak Shafran, Tom Griffiths, Yuan Cao 및 Karthik Narasimhan. 사고의 나무: 대규모 언어 모델을 사용한 의도적인 문제 해결. 신경 정보 처리 시스템의 발전, 36, 2024.
- [30] Liqiao Xia, Chengxi Li, Canbin Zhang, Shimin Liu 및 Pai Zheng. 오류 지원 미세 조정을 활용한 대규모 언어 모델을 통한 제조 우수성 향상. 로봇공학 및 컴퓨터 통합 제조, 88:102728, 2024.
- [31] Rod Valentine et al. 엔지니어링 설계 프로세스에 대한 즉각적인 엔지니어링. DS 131: 국제 엔지니어링 및 제품 설계 교육 컨퍼런스(E&PDE 2024) 회의록, 449-454페이지, 2024.
- [32] LlamaIndex 기여자. Llamaindex: llms와 외부 데이터 소스 간의 인터페이스, 2024. URL <https://www.llamaindex.ai/>. 접속일: 2024-10-09.
- [33] LangChain 기여자. Langchain: 대규모 언어 모델을 사용한 애플리케이션 구축, 2024. URL <https://www.langchain.com/>. 접속일: 2024-10-09.
- [34] GraphRAG 기여자. Graphrag: 그래프 기반 검색 증강 생성 프레임워크, 2024. URL <https://www.github.com/facebookresearch/graphrag>. 접속일: 2024년 10월 9일.
- [35] Yijun Bei, Zhibin Fang, Shenyu Mao, Shuyi Yu, Yan Jiang, Yining Tong 및 Weimin Cai. 통합 용어 Enhanced rag를 사용한 제조 도메인 QA입니다. 2024 신경망 국제 합동 컨퍼런스(IJCNN), 1~8페이지. IEEE, 2024.

- [36] Markus J Buehler. 해석적 대규모 언어 모델 기반 자료 설계를 위한 생성 검색 증강 오토로지 그래프 및 다중 에이전트 전략. ACS Engineering Au, 4(2):241–277, 2024.
- [37] Tienlan Sun, Anaiy Somalwar 및 Hinson Chan. 다중 모드 검색 증강 생성 평가 벤치마크. 2024 IEEE 제99회 차량 기술 컨퍼런스(VTC2024-Spring), 1-5페이지. IEEE, 2024.
- [38] Yinghao Zhu, Changyu Ren, Shiyun Xie, Shukai Liu, Hangyuan Ji, Zixiang Wang, Tao Sun, Long He, Zhoujun Li, Xi Zhu 등. 영역: 대규모 언어 모델을 통한 다중 모드 전자 건강 기록 분석의 래그 기반 향상입니다. arXiv 사전 인쇄 arXiv:2402.07016, 2024.
- [39] An Yang, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chengyuan Li, Dayiheng Liu, Fei Huang, Haoran Wei, Huan Lin, Jian Yang, Jianhong Tu, Jianwei Zhang, Jianxin Yang, Jiaxi Yang, Jingren Zhou, Junyang Lin, Kai Dang, Keming Lu, Keqin Bao, Kexin Yang, Le Yu, Mei Li, Mingfeng Xue, Pei Zhang, Qin Zhu, Rui Men, Runji Lin, Tianhao Li, Tingyu Xia, Xingzhang Ren, Xuancheng Ren, Yang Fan, Yang Su, Yichang Zhang, Yu Wan, Yuqiong Liu, Zeyu Cui, Zhenru Zhang 및 Zihan Qiu. Qwen2.5 기술 보고서. arXiv 사전 인쇄 arXiv:2412.15115, 2024.
- [40] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark 등. 자연어 감도를 통한 전이 가능한 시각 모델 학습. 국제 기계 학습 컨퍼런스, 8748–8763페이지. PMLR, 2021.
- [41] Han Xiao, Georgios Mstrapas 및 Bo Wang. Jina 클립: 클립 모델은 텍스트 검색기이기도 합니다. ICML2024의 Multi-modal Foundation Model meets Embodied AI Workshop, 2024.
- [42] Bin Wang, Chao Xu, Xiaomeng Zhao, Linke Ouyang, Fan Wu, Zhiyuan Zhao, Rui Xu, Kaiwen Liu, Yuan Qu, Fukai Shang, Bo Zhang, Liqun Wei, Zhihao Sui, Wei Li, Botian Shi, Yu Qiao, Dahua Lin 및 Conghui He. Mineru: 정확한 문서 콘텐츠 추출을 위한 오픈 소스 솔루션, 2024. URL <https://arxiv.org/abs/2409.18839>.

- [43] Bin Wang, Chao Xu, Xiaomeng Zhao, Linke Ouyang, Fan Wu, Zhiyuan Zhao, Rui Xu, Kaiwen Liu, Yuan Qu, Fukai Shang 등. Mineru: 정확한 문서 내용 추출을 위한 오픈 소스 솔루션입니다. arXiv 사전 인쇄 arXiv:2409.18839, 2024.
- [44] Zhiyuan Zhao, Hengrui Kang, Bin Wang 및 Conghui He. Doclayout-yolo: 다양한 합성 데이터와 전역-지역 적응 인식을 통한 문서 레이아웃 분석 향상, 2024. URL <https://arxiv.org/abs/2410.12628>.
- [45] Conghui He, Wei Li, Zhenjiang Jin, Chao Xu, Bin Wang 및 Dahua Lin. Opendatalab: 오픈 데이터셋으로 일반 인공지능을 강화합니다. arXiv 사전 인쇄 arXiv:2407.13773, 2024.
- [46] Muhammad Hussain. Yolo-v1에서 Yolo-v8까지, Yolo의 등장과 디지털 제조 및 산업 결함 감지에 대한 보완적 특성. Machines, 11(7):677, 2023.
- [47] Xu Zhong, Elaheh ShafieiBavani, Antonio Jimeno Yepes. 이미지 기반 테이블 인식: 데이터, 모델 및 평가. arXiv 사전 인쇄 arXiv:1911.10683, 2019.
- [48] PaddleOCR 기여자. Paddleocr: paddlepaddle 기반의 다중 언어 및 다중 알고리즘 ocr 툴킷. <https://github.com/PaddlePaddle/PaddleOCR/tree/main>, 2021. 접속일: 2024-12-29.
- [49] Mikell P Groover. 현대 제조의 기초: 재료, 프로세스 및 시스템. 존 와일리 앤 선즈, 2010.
- [50] Shahul Es, Jithin James, Luis Espinosa-Anke 및 Steven Schockaert. Ragas: 검색 증강 생성의 자동 평가. arXiv 사전 인쇄본 arXiv:2309.15217, 2023.
- [51] Kartik Sharma, Peeyush Kumar 및 Yunqing Li. Og-rag: 대규모 언어 모델을 위한 온톨로지 기반 검색 증강 생성. arXiv 사전 인쇄 arXiv:2412.15235, 2024.
- [52] 윤칭 리, 현웅 코, 파르하드 아메리. 공급자를 위한 대규모 언어 모델과 그래프 검색 증강 생성 통합

발견. 엔지니어링 컴퓨팅 및 정보 과학 저널, 25(2):021010, 2025년 1월. ISSN 1530-9827.
doi: 10.1115/1.4067389.
URL <https://doi.org/10.1115/1.4067389>.

- [53] Sifan Wu, Amir Khasahmadi, Mor Katz, Pradeep Kumar Jayaraman, Yewen Pu, Karl Willis 및 Bang Liu. Cad-llm: CAD 생성을 위한 대규모 언어 모델. 신경 정보 처리 시스템 컨퍼런스(neurIPS) 회의록, 2023.

- [54] Bin Huang, Xin Wang, Hong Chen, Zihan Song 및 Wenwu Zhu.
Vtimellm: llm이 비디오의 순간을 포착하도록 강화합니다. IEEE/CVF 컴퓨터 비전 및 패턴 인식 학회 회의록, 14271~14280쪽, 2024.