

검색 증강 다중 LLM 앙상블 산업 부품 사양 추출

Muzakiruddin A. Mohammed ERIQ 연구 센터
터 아칸소 대학교 - Little Rock 미국
아칸소 주 리틀 록 mmohammed6@ualr.edu

존 R. 탈버트 ERIQ 연구
센터, 아칸소 대학교 리틀록 캠퍼스, 미
국 아칸소주 리틀록 jrtalburt@ualr.edu

레온 클라센스
PiLog 그룹
leon.claassens@pilog.co.za

아드리안 마라이스
PiLog 그룹
adriaan.marais@pilog.co.za

요약—비정형 텍스트에서 산업 부품 사양을 추출하는 것은 제조, 조달 및 유지보수 분야에서 여전히 해결해야 할 과제이며, 수동 처리는 시간 소모적이고 오류 발생 가능성이 높습니다. 본 논문에서는 구조화된 3단계 파이프라인 내에서 9개의 최첨단 대규모 언어 모델(LLM)을 통합하는 검색 강화형 다중 LLM 앙상블 프레임워크인 RAGsemble을 소개합니다.

RAGsemble은 Gemini(2.0, 2.5, 1.5), OpenAI(GPT-4o, o4-mini), Mistral Large 및 Gemma(1B, 4B, 3n-e4b)를 포함한 모델 제품군의 상호 보완적인 강점을 결합함으로써 단일 모델 시스템의 주요 제한 사항을 해결하고 FAISS 기반 의미 검색을 사용하여 출력을 사실 데이터에 기반합니다.

시스템 아키텍처는 세 단계로 구성됩니다. (1) 다양한 LLM에 의한 병렬 추출, (2) 고성능 모델을 활용한 목표 연구 증강, (3) 충돌 해결 및 신뢰도 인식 점수를 통한 지능형 합성.

RAG 통합은 구조화된 부품 데이터베이스에 대한 실시간 액세스를 제공하여 시스템이 유사성 기반 참조 검색을 통해 출력을 검증, 개선 및 보강할 수 있도록 합니다. 실제 산업 데이터 세트를 사용한 실험 결과는 기존의 단일 LLM 기준선과 비교하여 추출 정확도, 기술적 완성도 및 구조화된 출력 품질에서 상당한 향상을 보여줍니다.

주요 기여 사항으로는 산업 분야를 위한 확장 가능한 앙상블 아키텍처, 파이프라인 전반에 걸친 원활한 RAG 통합, 포괄적인 품질 평가 메커니즘, 그리고 지식 집약적인 제조 환경에 배포하기에 적합한 즉시 사용 가능한 솔루션이 있습니다.

색인 용어—다중 LLM 앙상블, 검색 증강 생성, 산업 부품 사양 추출, 의미 벡터 검색, 신뢰도 인식 합성, 지식 접지

I. 서론

산업 제조, 조달 및 유지보수 운영 과정에서는 조달 문서, 유지보수 기록, 기술 사양 및 공급업체 카탈로그에 포함된 방대한 양의 비정형 부품 설명이 생성됩니다. 이러한 정보를 추출하고 표준화하는 것은 여전히 중요한 병목 현상이며, 종종 시간 소모적이고 오류 발생 가능성이 높은 수동 처리가 필요합니다. 기존의 규칙 기반 접근 방식과 초기 머신 러닝 방식은 언어적 복잡성을 처리하는 데 한계가 있습니다.

산업 부품 데이터의 전형적인 복잡성, 도메인별 용어 및 미묘한 맥락[16], [17].

최근 대규모 언어 모델(LLM)의 발전으로 복잡한 추출 작업을 자동화할 수 있는 새로운 가능성이 열렸지만, 단일 모델에 의존하는 것은 산업 환경에서 상당한 위험을 초래합니다. 이러한 위험에는 기술 사양의 왜곡, 부품 범주별 성능 불균형, 제한된 도메인 적응성, 신뢰도 추정의 투명성 부족 등이 포함됩니다[18], [22]. 특히 중요한 환경에서는 이러한 문제로 인해 비용이 많이 드는 오식별, 안전 위험, 운영 비효율성이 발생할 수 있습니다.

본 논문은 산업 부품 사양의 고정밀 추출을 위해 특별히 설계된, 생산 준비가 완료된 새로운 멀티 LLM 앙상블 시스템을 소개합니다. 제안된 아키텍처는 Gemini, OpenAI, Mistral, Gemma 등 4대 주요 모델 패밀리 중 최첨단 LLM 9개를 통합하고, 병렬 추출, 문맥 인식 연구 향상, 지능형 합성을 포함하는 구조화된 3단계 파이프라인으로 구성됩니다.

검색 증강 생성(RAG)은 모든 단계에 걸쳐 원활하게 통합되어 FAISS 기반 유사성 검색[21], [23]을 통해 역사적 부품 데이터베이스에 대한 의미론적 접근을 제공함으로써 접지를 크게 개선하고 환각을 줄입니다.

우리 시스템은 다음과 같은 몇 가지 핵심적인 기여를 제공합니다.

- 확장 가능한 앙상블 아키텍처를 통해 상호 보완적인 모델의 강점을 체계적으로 활용하여 견고하고 고품질의 부품 정보 추출을 구현합니다.
- 업계 최초로 RAG와 다중 LLM 파이프라인을 통합하여 산업 사양 기반화를 구현하고, 컨텍스트 강화 및 실시간 검증을 가능하게 합니다.
- 신뢰도 점수, 합의 지표, RAG 검증 지표 등을 포함한 투명한 품질 평가를 통해 정보에 기반한 의사 결정을 지원합니다. • 모듈식 설계, 구성 가능한 모델 선택, 강력한 오류 처리, 다양한 산업 분야에 적용 가능한 실용적인 기능을 갖춘 완벽하고 배포 가능한 구현 솔루션을 제공합니다.

본 연구는 단일 모델 패러다임에서 협력적인 다중 모델 접근 방식으로 전환함으로써 새로운 토대를 마련합니다. 산업 정보 시스템의 방향, 아키텍처 항공우주, 자동차 등 다양한 분야에 적용 가능합니다. 전자 및 화학 제조 분야에서 임무 수행에 필수적인 신뢰성, 투명성 및 확장성을 제공합니다. 전개.

II. 문헌 고찰

양상블 학습은 성능 향상을 위한 핵심 전략이 되었습니다. 대규모 언어 모델의 견고성과 일반화 (LLM) 기법은 일반적으로 추론 전 양상블, 추론 중 양상블, 추론 후 양상블 전략으로 분류되며, 여러 모델을 활용합니다.

변동성을 줄이고 상호 보완적인 장점을 활용하기 위해 강점[4]. LLM-Synergy와 같은 최근 연구는 다음과 같은 점을 보여줍니다. 양상블 투표 및 동적 선택 접근 방식이 어떻게 특히 의료 질문 답변과 같은 중요한 작업에서 도메인별 성능을 향상시킵니다[8]. 신뢰도 인식 양상블 전략은 LLM에서 보정된 불확실성 추정치를 제공함으로써 안정적인 배포에 더욱 기여합니다.

분류 작업[18]. 또한, 새로운 응용 프로그램 Gemini-1.5와 같은 고급 모델을 사용하는 양상블 방법 복잡한 산업 작업을 처리할 수 있음이 입증되었습니다. 비정형 데이터 세트에서의 엔티티 해상도 [19], [20]. 최근 종합적인 검토 결과 양상블 답변이 주목받고 있습니다. 이러한 접근 방식은 분류, 생성 및 정보 추출 작업 전반에 걸쳐 성능을 지속적으로 향상시키는 동시에 비용과 통합의 절충점을 인정합니다[13]. 검색 증강 생성(RAG) 방법은 다음과 같은 특징을 가지고 있습니다. LLM 결과물을 사실에 기반하여 도출하는 데 큰 가능성을 보여주었습니다. 지식, 환각 문제 및 모델 메모리의 한계를 해결합니다. 원래의 RAG 아키텍처

[7]에서 소개된 방법은 매개변수 생성과 비매개변수 메모리를 결합하여 지식 집약적 작업의 성능을 향상시킵니다. 포괄적인 조사 [6]에서는 최근의 방법들을 분류합니다.

RAG 전략은 사실성을 향상시키는 데 있어 그 역할을 강조합니다. 일관성, 투명성 및 검색 기반 추론 도메인별 응용 프로그램. 이러한 원칙들은 현재 적용되고 있습니다. 다중 모델 영역으로 확장되어 시스템이 텍스트뿐만 아니라 시각적 및 구조화된 데이터도 통합할 수 있게 되었습니다. 검색 컨텍스트의 일부 [12]. 의미 유사성 검색 FAISS와 같은 엔진은 확장 가능한 RAG에 필수적인 요소가 되었습니다. 실시간으로 밀집된 벡터 기반 검색을 가능하게 하는 애플리케이션 수십억 개의 문서에 걸쳐 [23].

산업 분야에서 전통적인 규칙 기반 정보는 추출 시스템은 기계-전기-배관 문서 처리와 같은 작업에 사용되어 왔지만, 다음과 같은 한계가 있습니다. 미묘한 의미론과 다양한 용어를 포착합니다[16]. 그 결과, 신경망 접근 방식으로는 뚜렷한 전환이 이루어졌습니다. 기술 텍스트에서 정보 추출을 위해 [17]. 더 넓은 연구 결과에 따르면 스마트 제조 분야에서 머신 러닝은 다음과 같은 성과를 보이고 있습니다. 구조화된 지식 생성에 점점 더 집중하고 있습니다. 비정형 기록과 시스템 간 데이터 통합. 제조 분야별 개체 인식에 관한 기초 연구는 부품별 데이터 수집의 어려움을 부각시켰습니다.

이질적인 문서에서 추출하는 것이 중요했지만[1], [2], 이후 연구에서는 구조화된 데이터와 표준화의 중요성을 강조했습니다. 제품 수명주기 관리에서 [5].

NIST KEA 프로젝트[9] 및 관련 연구와 같은 노력 서로 양립할 수 없는 정보 출처를 종합하는 데 집중합니다. 제조 의사결정 시스템 개선. 형식 온톨로지 그리고 엔터프라이즈 모델링 프레임워크는 이를 가능하게 하는 데 핵심적인 역할을 합니다. 산업 4.0 목표에 부합하는 상호 운용 가능한 시스템[10], [24]. 이와 병행하여 지식 관리 시스템 중복을 줄이고 효율성을 향상시키는 것으로 나타났습니다. 중앙 집중화를 통해 제조 환경에서 문서 일관성[3]. 예측 유지보수 애플리케이션은 또한 구조화된 지식에 크게 의존합니다.

과거 진단 정보, 작동 조건 및 장비 메타데이터 [11]. 이전 연구에서는 두 가지 방법 모두의 가치를 입증했지만 LLM 양상블 또는 RAG 개별적으로는 몇 가지 접근 방식만 있습니다. 이러한 패러다임을 통합하여 응집력 있는 아키텍처를 설계했습니다. 생산 규모의 산업적 적용을 위한 것입니다. 본 논문은 이러한 요구를 충족합니다. 9개의 LLM을 협력적인 파이프라인에 통합함으로써 격차를 해소합니다. RAG 기반 컨텍스트 기반화 및 신뢰도 인식 합성 기능을 포함하여 확장 가능하고 투명하며 정확한 결과를 제공합니다. 비정형 데이터에서 산업 부품 사양을 추출하는 솔루션.

III. 시스템 아키텍처

제한된 시스템은 모듈식이며 생산 지향적입니다. 여러 대규모 언어 모델을 통합하는 아키텍처 (LLM)(Large Language Models), 검색 증강 생성(RAG) 하위 시스템 및 중앙 집중식 합성 계층으로 구성됩니다. 그림 1에서 보는 바와 같이, 아키텍처는 의미 검색, 분산 모델 오케스트레이션 및 합성의 세 가지 핵심 계층으로 구성됩니다.

및 검증. 모델 통합 및 모듈성: 시스템은 다음을 지원합니다. Gemini, OpenAI, Mistral, Gemma 계열의 최첨단 LLM 9개 모델이 포함되어 있습니다. 각 모델은 다음을 통해 접근할 수 있습니다. API 호출, 오류 복구 및 JSON 출력 유효성 검사를 관리하는 표준화된 인터페이스입니다. 모델은 동적으로 생성됩니다. 추출이나 연구와 같은 작업에 배정된 성능 프로필, 가용성 또는 배포 제약 조건. 공동 JSON 스키마를 통해 일관된 출력 결과를 보장합니다. 이 양상블은 원활한 후속 처리를 가능하게 합니다. 모듈형 아키텍처는 향후 모델 확장을 가능하게 합니다.

핵심 시스템을 변경할 필요 없이. RAG 및 지식 기반 아키텍처: RAG 하위 시스템은 모든 단계에 걸쳐 의미론적 맥락을 제공합니다. 처리 중입니다. 입력 설명 및 지식 기반 레코드가 표시됩니다. 모든 MiniLM-L6-v2 모델[15]을 사용하여 내장되었으며 유사성 검색은 FAISS[14]를 사용하여 수행됩니다. 지식 기반은 산업 부품 기록(예:

Pilog Group 데이터 세트)는 평면화된 스키마를 사용하여 인덱싱되었습니다. 매핑. 레코드는 효율적인 매핑을 위해 밀집 벡터로 인코딩됩니다. 검색을 통해 유사성 기반 접지 및 검증이 가능해집니다. 모든 LLM 출력물에 대해 시스템은 구조화된 형식을 지원합니다. CSV 및 JSON과 유사하여 산업 전반에 걸쳐 쉽게 적용할 수 있습니다. 데이터 세트.




그림 1. 모듈형 구성 요소 및 모델 구성을 보여주는 멀티 LLM 산업 부품 추출 프레임워크의 시스템 아키텍처.

합성 및 구성 계층: 합성 계층은 추출 및 연구 단계의 결과물을 통합합니다.

이 시스템은 구조화된 충돌 해결을 수행하고, 모델 일치도 및 RAG 유사도 수준에 기반하여 신뢰도 점수를 계산하며, 검증된 스카마에 따라 최종 출력을 생성합니다. 이 계층은 결과의 신뢰성과 해석 가능성을 보장합니다. 구성 파일을 통해 다양한 하드웨어 설정, 모델 선택 및 대체 전략에 맞게 시스템을 조정할 수 있습니다. CPU 및 GPU 환경 모두와의 호환성을 통해 산업 현장의 다양한 배포 사나리오를 지원합니다.

IV. 방법론 및 실행

제안된 프레임워크는 여러 개의 대규모 언어 모델(LLM)과 검색 증강 생성(RAG) 하위 시스템을 통합하도록 설계된 구조화된 3단계 방법론을 따릅니다. 그림 2에서 볼 수 있듯이, 워크플로는 정보 추출, 검색 강화, 검증을 통한 합성의 세 가지 상호 연결된 단계로 구성됩니다. 각 단계는 의미론적 기반을 사용하여 오류를 줄이고 도메인 충실도를 보장하면서, 신뢰도가 높은 구조화된 명세 출력을 점진적으로 도출합니다.

1단계: 정보 추출: 시스템은 Gemini, OpenAI, Mistral, Gemma 계열의 9개 LLM으로 구성된 다양한 앙상블을 사용하여 입력 부품 설명을 병렬로 처리하는 것으로 시작합니다. 모델은 상호 보완적인 강점을 고려하여 선정되었습니다. OpenAI 모델은 구조화된 출력에서 높은 신뢰성을 제공하고, Gemini는 기술적 추론에 탁월하며, Mistral은 비용과 품질의 균형을 제공하고, Gemma는 효율적인 처리를 제공합니다.

경량 추론. 각 모델은 부품 이름, 제조업체, 부품 번호 및 사양과 같은 주요 필드와 신뢰도 점수를 포함하는 구조화된 JSON을 생성합니다. 컨텍스트 참조는 강력한 의미 일치 및 검색 효율성을 위해 선택된 all-MiniLM-L6-v2 임베딩[15] 및 FAISS[14]를 사용한 의미 유사성 검색을 통해 검색됩니다. 모델 간의 불일치는 하위 합성을 위해 유지되어 내결함성과 필드 적용 범위를 향상시킵니다.

2단계: 연구 강화: 추출된 데이터를 기반으로 Gemini 2.5 및 GPT-4o와 같은 고용량 모델이 연구 모드에 진입하여 누락되거나 불완전한 사양을 보완합니다. 이 단계에서는 재료, 치수, 작동 허용 오차 및 산업 표준과 같은 추가 세부 정보를 추출합니다. RAG 시스템은 산업 지식 기반에서 상위 k개의 의미론적 일치 항목을 식별하여 지속적으로 맥락 정보를 제공합니다. 프롬프트는 이전 추출 결과를 기반으로 동적으로 조정되어 모델이 불확실하거나 불완전한 속성에 집중하도록 합니다. 일부 모델은 허용되는 경우 실시간 웹 연결을 활용하여 최신 정보와 맥락을 고려한 데이터 보강을 제공합니다.

3단계: 종합 및 검증: 최종 단계에서는 지정된 종합 모델이 추출 단계와 연구 단계의 결과를 통합합니다. 충돌 해결은 다수결 합의, RAG 정렬 점수 및 신뢰도 수준 분석을 통해 수행됩니다. 종합 모델은 내부 일관성, 모델 간 일치도 및 외부 검증 신호를 평가하여 각 데이터 필드에 대한 전반적인 신뢰도 프로파일을 계산합니다. 최종 결과는 구조화된 부품 사양입니다.




그림 2. 연속적인 RAG 통합을 포함하는 3단계 다중 LLM 처리 워크플로. 각 단계는 추출, 농축 및 정제에 고유한 방식으로 기여합니다. 부품 사양 검증.

출처를 포함한 추적성 메타데이터가 풍부하게 포함된 양이온 기여도 및 품질 점수.

RAG 하위 시스템: RAG 모듈은 세 단계 전체에 걸쳐 활성화 상태를 유지합니다. 이는 부품 지식 기반을 변환합니다. 여기에는 과거 사양, 상호 참조 번호 및 공급업체 설명이 포함되며, 공유 임베딩 모델을 사용하여 밀집 벡터 표현으로 변환합니다. FAISS는 다음과 같은 작업을 수행합니다. 낮은 지연 시간으로 유사성 검색을 수행하고, 가장 높은 순위의 문서를 검색하여 신속하게 처리합니다. 이 메커니즘은 다음과 같은 기능을 향상시킵니다. 사실적 근거를 바탕으로 모델의 독립성을 유지하면서 세대. 상위 k개 검색 깊이 및 유사도 임계값 특수성과 일반성의 균형을 맞추도록 구성할 수 있습니다.

시스템 스택 및 배포: 이 시스템은 Python으로 구현되었으며, 웹 인터페이스는 Streamlit을 사용하여 구축되었습니다. 비동기 작업 오케스트레이션은 asyncio를 사용하여 처리됩니다. 병렬 LLM 호출을 가능하게 하고 중단 간 지연 시간을 줄입니다. OpenAI, Google GenAI 및 기타 AI용 API 래퍼가 통합되었습니다. 통합 스키마 유효성 검사 및 오류 처리 기능을 갖춘 Mistral 플랫폼 처리. RAG 엔진은 CPU 및 GPU 백엔드를 모두 지원하며 CSV와 같은 구조화된 입력 형식을 처리합니다. JSON 형식입니다. 구성 가능한 매개변수에는 모델 선택, 상위 k개 등이 포함됩니다. 검색 깊이, 임베딩 모델 및 대체 전략. 모듈식 설계는 모델에 대한 업데이트 또는 교체를 용이하게 합니다. 또는 지식 소스는 아키텍처 변경을 필요로 하지 않습니다.

V. 결과 및 분석

본 논문에서 제안하는 시스템의 성능을 평가하기 위해, RAGsemble에서 우리는 비교를 위한 통제된 실험을 수행했습니다.

이 모델은 GPT-4o, Claude, Gemini 2.5, Grok 3을 포함한 여러 강력한 개별 LLM 기준선과 비교되었습니다. 각 모델은 표준화된 산업 데이터 세트를 기반으로 평가되었습니다. 구조화되지 않은 부품 설명에서 구조화된 사양을 추출해야 합니다. 또한 심층적인 벤치 마크도 포함했습니다. GE9X 탄소 섬유 복합재 팬 블레이드는 복잡한 구조를 가지고 있습니다. 기술적 세부 사항이 풍부한 항공우주 부품입니다. 완전성을 평가하기 위해 5가지 표준화된 평가 지표가 사용되었습니다. 기술적 풍부함, 형식 신뢰성, 모델 간 차이 및 환각 행동.

평가 지표

본 연구에서는 완전성, 명세의 세분성, 구조적 품질, 출력 변동성 및 착각이라는 차원을 기준으로 모델 성능을 평가하기 위한 다섯 가지 정규화된 지표를 정의합니다.

제어.

정보 완전성 점수(ICS)는 비율을 측정합니다. 모델이 성공적으로 추출한 예상 핵심 필드:

$$ICS = \frac{\text{추출된 필드}}{\text{예상 필드}}, \quad 0 \leq ICS \leq 1$$

여기서 Fexpected는 각 부품 범주에 필요한 필드(예: 부품 번호, 재질, 치수)를 나타내고, Fextracted는 추출된 필드를 나타냅니다. 부분집합이 성공적으로 포착되었습니까? 기술심도지수(TDI)는 추출된 사양서의 세부적인 정도를 정량화합니다.

$$TDI = \frac{\sum_{i=1}^N d_i}{n \cdot D_{max}}, \quad 0 \leq TDI \leq 1$$

여기서 d_i 는 i 부분에 대해 추출된 보조 또는 상세 필드(예: 인장 강도, 전압 정격)의 개수이고, D_{max} 는 예상되는 최대 필드 개수입니다. 값이 높을수록 기술적 이해도가 더 깊음을 나타냅니다.

구조화된 데이터 품질(SDQ)은 백분율을 나타냅니다. 스카마 유효성 검사를 통과하고 올바른 형식으로 출력되는 결과물:

$$SDQ = \frac{|v_{valid}|}{|v_{total}|}$$

이 지표는 최종 출력 JSON이 예상 스카마를 준수하는지, 그리고 오류 없이 프로그램적으로 구문 분석될 수 있는지를 평가합니다.

모델 간 불일치 비율(IDR)은 서로 다른 모델에서 나오는 출력값의 다양성을 나타냅니다.

$$IDR = \frac{2}{n(n-1)} \sum_{i < j} \frac{|O_i \cap O_j|}{|O_i \cup O_j|}$$

여기서 O_i 와 O_j 는 각각 모델 i 와 j 가 예측한 필드 집합입니다. 이 지표는 모델 쌍 간의 평균 자카드 거리를 계산합니다. IDR 값이 높을수록 출력 다양성이 크다는 것을 의미하며, 이는 양상을 합성에 도움이 될 수 있지만 모델 간 불일치가 있음을 나타내기도 합니다.

추가 연구 자료(ARA)는 불필요하거나 허구적인 세부 정보의 비율을 측정합니다.

$$ARA = \frac{|불필요한|}{|총계|}$$

이 지표는 불필요하거나 근거가 없는 과잉 속성을 계산하여 과잉 생성을 불이익으로 처리합니다. 값이 낮을수록 더 간결하고 신뢰할 수 있는 출력을 나타냅니다.

표 1 모델 간 정규화된 평가 결과											
모델	ICS	TDI	SDQ	IDR	ARA						
GPT-4o	0.60	0.45	0.80	0.092	0.85	클로드	0.55	0.40	0.90	0.074	0.90
제미니	2.5	0.65	0.50	0.85	0.118	0.80	그록	3	0.85	0.80	0.70
RAGsemble	1.00	1.00	0.95	0.215	0.40						

표 1의 결과는 RAGsemble이 완전성, 기술적 깊이 및 신뢰성 측면에서 모든 개별 LLM 기준선보다 현저히 우수함을 보여줍니다. RAGsemble은 전체 필드를 포괄하고 최대 사양 세부 정보를 제공하며, 가장 강력한 독립형 모델인 Grok 3까지 능가합니다. 구조화된 출력은 95%의 경우 스카마를 준수하여 후처리 필요성을 최소화합니다.

RAGsemble의 높은 IDR(충돌률 감소)은 의도적으로 다양한 모델 관점을 활용하는 다채로운 아키텍처를 반영합니다. 이러한 다양성은 약점이 아니라 설계 강점입니다. 이는 합성 계층에 반영되어 합의 필터링, 신뢰도 점수 계산 및 RAG 검증을 통해 충돌을 해결하고 신뢰할 수 있는 출력을 보장합니다.

ARA 점수 0.40은 환각과 RAG 기반 프롬프트 설계 및 검증 로직을 통해 과잉 생성을 성공적으로 최소화했습니다.

중증 장황하거나 추측성 내용을 덧붙이는 Claude와 GPT-4o와 달리, RAGsemble은 사실의 경계를 더욱 엄격하게 통제했습니다.

GE9X 팬 블레이드의 경우, RAGsemble은 28개의 기술 사양과 18개의 정량적 데이터 포인트를 추출했는데, 이는 단일 모델 기준선에서 각각 평균 8.5개와 47개였던 것과 비교됩니다. 이는 기술 세부 정보가 3.2배, 수치 속성이 4.5배, 검증된 정보 단위가 5.58배 더 많다는 것을 의미합니다. 이러한 높은 출력 밀도에도 불구하고, 시스템은 높은 SDQ와 낮은 ARA를 유지하여 풍부한 정보와 신뢰성 사이의 균형을 유지하는 능력을 입증했습니다.

전반적으로, 이번 평가는 RAGsemble이 구조화된 정보 추출을 위한 견고하고 도메인 적응성이 뛰어난 프레임워크임을 확인시켜 줍니다. RAG를 기반으로 하고 신뢰도 인식 합성을 통해 구현되는 이 양상을 아키텍처는 완전하고 정확하며 구조가 잘 잡힌 부품 명세를 일관되게 제공합니다.

이러한 특정 덕분에 정확성과 추적성이 필수적인 중요한 산업 워크플로우에 적용하기에 매우 적합합니다.

VI. 사용 사례 및 응용 분야

RAGsemble은 산업 전반에 걸쳐 확장 가능하고 지능적인 데이터 추출을 가능하게 함으로써 산업 부품 정보 관리의 고질적인 과제를 해결합니다. 조달 분야에서는 공급업체 카탈로그 및 데이터시트에서 부품 데이터를 자동으로 추출하고 표준화하며, 내부 시스템과의 정보 유효성 검사를 수행하고, 수동 오류를 줄이고, 처리 주기를 단축하며, 데이터 일관성을 향상시킵니다.

산업 설비 유지보수를 위해 RAGsemble은 매뉴얼과 로그를 분석하여 교체 부품을 식별하고, 호환성을 확인하고, 문서를 정렬하고, 메타데이터를 보강합니다. 이는 예측 유지보수를 지원하고 자산 신뢰성을 향상시킵니다.

품질 보증 팀은 이를 사용하여 사양을 검증하고, 격차를 감지하고, 시스템 전반의 일관성을 보장합니다. 항공우주, 자동차, 방위 산업 및 의료 기기와 같은 안전이 중요한 분야에서는 사실에 기반한 종합 분석 및 추적성 기능이 규정 준수 및 성능 보증을 지원합니다.

모듈형 아키텍처를 통해 모델, 데이터 세트, 추출 스카마 및 유효성 검사 규칙을 도메인별로 조정할 수 있으므로 대량 생산되는 일반 부품과 특수 구성 요소 모두에 적합합니다.

VII. 한계점 및 향후 연구 방향

현재 한계점: RAGsemble은 모델 가변성, 시스템 복잡성 및 운영 비용과 관련된 한계에 직면해 있습니다. LLM 출력 결과는 실행마다 다를 수 있어 재현성이 떨어지고 합의 기반 검증이 필요합니다. 여러 타사 API에 의존하는 것은 비용 증가와 서비스 중단 위험을 초래합니다. 또한 순차적인 3단계 파이프라인은 자연 시간을 발생시켜 실시간 애플리케이션에 제약을 줄 수 있습니다.

RAG 기반 알고리즘을 사용하더라도, 입력 데이터에 훈련 데이터에 잘 나타나지 않는 용어가 사용될 경우 도메인별 정확도가 떨어질 수 있습니다. 또한, 최종 출력에서 특정 모델 계열에 과도한 가중치가 부여되는 합성 편향도 또 다른 문제점입니다. 더불어, RAG 성능은 잘 구조화되고 의미적으로 정렬된 데이터에 의존하며, 일관성 없는 형식은 검색 품질을 저하시키고 환각 현상을 증가시킬 수 있습니다.

향후 개선 사항: 계획된 개선 사항은 다음과 같습니다.

모델 가중치 부여 및 출력 교차 검증을 통한 편향 완화와 입력에 기반한 동적 모델 선택

특성. RAG는 피드백 기반 방식으로 확장될 것입니다.

업데이트, 멀티모달 문서 지원 및 더욱 정확한 정보 제공

프롬프트-컨텍스트 정렬.

도메인 적용에는 특정 목적에 맞춘 미세 조정이 포함됩니다.

산업 분야 및 개선된 임베딩 모델을 다룰 것입니다. 성능 향상은 병렬 처리, 캐싱 및 엣지 배포에 중점을 둘 것입니다. 품질 지표는 불확실성을 포함하도록 확장될 것입니다.

투명성을 향상시키기 위한 추정 및 편향 탐지

신뢰하다.

VIII. 결론

본 논문에서는 다중 LLM 앙상블인 RAGsemble을 소개합니다.

산업 정보를 추출하기 위한 검색 증강 생성

비정형 텍스트에서 부품 사양을 추출합니다. 3상

파이프라인은 병렬 추출, 표적 연구 및

9개의 언어 모델을 통합하여 일관되고 구조화된 결과물을 생성하는 합성 기능.

실제 Pilog Group 데이터셋에서 RAGsemble은 완전성, 기술적 측면에서 강력한 단일 모델 기준선보다 우수한 성능을 보였습니다.

깊이와 형식의 신뢰성. 합성 단계에서 이러한 요소들을 조화시킵니다.

불일치를 확인하고 FAISS 검색을 통해 정보를 검증합니다.

이 프레임워크는 비용을 증가시키고 비결정성을 도입하지만, 모듈식 설계 덕분에 투명성, 적응성 및 정확성이 향상됩니다. 향후 확장 기능에는 동적 기능이 포함될 예정입니다.

모델 선택, 편향 인식 합성 및 멀티모달 검색.

전반적으로 RAGsemble은 협업의 가치를 보여줍니다.

앙상블 다양성, 검색 기반 구축 및 합성을 결합하여 산업 정보 추출을 위한 LLM을 구현합니다.

제조 분야의 확장 가능한 자동화.

승인

본 연구는 미국 국립과학재단의 EPSCoR Award No. OIA-1946391의 부분적인 지원을 받았습니다.

PiLog 그룹. 모든 의견, 조사 결과 및 결론

본 자료에 제시된 내용이나 권장 사항은 해당 전문가의 의견입니다.

이 글의 내용은 저자(들)의 의견이며, 반드시 해당 자자(들)의 견해를 반영하는 것은 아닙니다.

미국 국립과학재단 또는 PiLog 그룹.

참고문헌

[1] G. Palshikar, R. Srivastava, SS Deshpande 및 S. Bhat, "정교한 효과적인 지식 관리를 위한 추출", TCS 백서, pp. 2015년 1월 14일-14일.

[2] MA Mohammed, S. Al Mandalawi, H. Maclean 및 JR Talburt, 다국어 고객 기록 연동: 새로운 접근 방식 "다국어 엔티티 해결을 위한 LLM" (제24회 학술대회 논문집) 정보 및 지식 공학 국제 컨퍼런스 (IKE'25), 세계 컴퓨터 과학 및 컴퓨터 공학 학술대회 및 응용 컴퓨팅, 2025년.

[3] Bloomfire, "지식 관리 시스템 활용" 불룸파이어, 8월 11일 2022년. [온라인]. 다음 웹사이트에서 확인하실 수 있습니다: <https://bloomfire.com/blog/>

제조 분야의 지식 관리 시스템/

[4] Z. Chen, J. Li, P. Chen, Z. Li, K. Sun, Y. Luo, Q. Mao, D. Yang, H. Sun, PS Yu, "다수의 대규모 언어 모델 활용: 설문 조사" LLM 앙상블," arXiv 사전출판물 arXiv:2502.18036, 2025.

[5] Z. Wu 및 C. Liang, "제조 공정의 검토 및 전망" 지식의 획득, 표현 및 응용," 기계, vol. 제12권, 제6호, 416쪽, 2024년.

[6] Y. Gao, Y. Xiong, X. Gao, K. Jia, J. Pan, Y. Bi, Y. Dai, J. Sun 및 H. Wang, "대규모 언어 모델을 위한 검색 증강 생성: "설문조사", arXiv 사전출판물 arXiv:2312.10997, 2권 1호, 2023.

[7] P. 루이스, E. 페레즈, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Kuttler, M. Lewis, W. Yih, T. Rockt aschel, et al., "검색 증강 지식 집약적인 자연어 처리 작업을 위한 생성," 신경망 분야의 발전 정보처리시스템, 제33권, 9459-9474쪽, 2020년.

[8] H. Yang, M. Li, H. Zhou, Y. Xiao, Q. Fang 및 R. Zhang, "One LLM 2.5만으로는 충분하지 않습니다: 의료 분야에서 앙상블 학습의 힘을 활용하기 위한 답변," medRxiv, 2023.

[9] 미국 국립표준기술연구소(NIST), "지식 추출 및 응용", NIST, 2025년 3월 26일. [온라인]. 다음 웹사이트에서 확인할 수 있습니다: <https://www.nist.gov/programs-projects/>

지식 추출 및 응용

[10] FB Vernadat, FTS Chan, A. Molina, SY Nof 및 H. Panetto, "산업공학 분야의 정보 시스템 및 지식 관리: 최근 발전과 새로운 전망", 국제 학술지 생산연구, 제56권, 제8호, 2018년, 2707-2713쪽.

[11] S. Wan, JX Gao, D. Li 및 RD Evans, "지식 관리" "제조 시스템의 유지 보수, 수리 및 서비스에 관한 것" (Proc.) 국제 제조 연구 컨퍼런스, 사우샘프턴 솔렌트 대학교 2014년.

[12] S. Yin, C. Fu, S. Zhao, K. Li, X. Sun, T. Xu 및 E. Chen, "설문조사" "다중 모달 대규모 언어 모델에 관하여", National Science Review, vol. 11권, 12호, p. nwa403, 2024.

[13] A. Mohammed 및 R. Kora, "앙상블에 대한 종합적인 검토" 답례: 기회와 과제, 킹 사우드 저널 대학 컴퓨터 및 정보 과학, 제35권, 제2호, 757쪽 2024, 2023.

[14] J. Johnson, M. Douze 및 H. Jegou, "GPU를 이용한 10억 규모 유사성 검색", IEEE Transactions on Big Data, vol. 7, no. 3, pp. 535-547, 2019.

[15] N. Reimers 및 I. Gurevych, "Sentence-BERT: 문장 임베딩" 삼 BERT 네트워크 사용", arXiv 사전 출판물 arXiv:1908.10084, 2019.

[16] L.-T. Wu, J.-R. Lin, S. Leng, J.-L. Li 및 Z.-Z. Hu, "기계-전기-배관 특정 의미를 위한 규칙 기반 정보 추출" 웹, 건설 자동화, 제135권, 104-108쪽, 2022년.

[17] Y. Yang, Z. Wu, Y. Yang, S. Lian, F. Guo 및 Z. Wang, "설문 조사" 답례: 기반 정보 추출", 응용과학, 권. 12, 아니. 19, p. 9691, 2022.

[18] K. Hovsepian, D. Liu, S. Murugesan, "자신감을 가지고 라벨을 붙이세요: "LLM 기반 분류에서 효과적인 신뢰도 보정 및 앙상블," 사전 출판 논문, 2024.

[19] Mohammed, MA, Talburt, JR, Mohammed, A., 및 Syed, K., "Google을 활용한 가구 이동 탐지를 통한 개체 해상도" 생성형 인공지능(Generative AI)", 국제 학술대회 논문집 정보 기술 - 새로운 세대, 스프링거, 469-481쪽, 2025년.

[20] MA Mohammed, JR Talburt 및 AM Althaf, "다중 LLM 기록" 연계: 동거 패턴에 대한 비교 분석 프레임워크 "발견", 제24회 국제 학술대회 논문집 정보 및 지식 공학(IKE'25), 세계 학술대회 컴퓨터 과학, 컴퓨터 공학 및 응용 컴퓨팅, 2025년.

[21] S. Wu, Y. Xiong, Y. Cui, H. Wu, C. Chen, Y. Yuan, L. Huang, X. Liu, T.-W. Kuo, N. Guan 외, "자연어 생성을 위한 검색 증강 생성" 언어 처리: 개요," arXiv 사전 출판물 arXiv:2407.13193, 2024.

[22] P. Goldstein, "LLM 환각: 비즈니스에 미치는 영향은 무엇인가?", BizTech Magazine, 2025년 2월 7일. [온라인]. 다음 링크에서 확인할 수 있습니다: <https://biztechmagazine.com/article/2025/02/llm-hallucinations-impacts-on-business/>

llm 환각이 기업 성과에 미치는 영향

[23] H. Jegou, "Faiss: 효율적인 유사성 검색을 위한 라이브러리," Meta의 엔지니어링, 2017년 3월 29일. [온라인]. 이용 가능: <https://engineering.fb.com/2017/03/29/데이터/인프라/faiss-a-library-for-efficient-similarity-search/>

[24] Mohammed, MA, "기계 학습 접근법, 기술, 최근 제조 및 산업 분야에서의 응용, 장점 및 과제" "4.0 응용 프로그램," 국제 응용 과학 연구 저널 및 공학 기술, 제10권, 1114-1121쪽, 2022년.