

MechRAG: 기계 공학을 위한 다중 모달 대규모 언어 모델



업데이트 확인

Shuang Li  & 조나단 코니

엔지니어링 설계 및 제조는 본질적으로 다중 모달 활동으로, 엔지니어들은 다양한 엔지니어링 분야와 제품 수명 주기 단계에 걸쳐 다양한 데이터와 표현을 참조하고 생성합니다. 이러한 표현을 위한 확립된 디지털 형식이 존재함에도 불구하고, 그 사용은 전문 애플리케이션 내에서만 제한되어 있어 도메인 간 통합을 제한하는 사일로로 형성합니다. 여기서 우리는 컴퓨터 지원 엔지니어링(CAE) 및 컴퓨터 지원 설계(CAD) 환경에서 흔히 발견되는 다양한 엔지니어링 표현의 정보를 통합하도록 설계된 다중 모달 대규모 언어 모델 아키텍처인 기계적 검색 강화 생성(MechRAG)을 소개한다. 연구 결과에 따르면 MechRAG는 데이터 관리나 분류 작업과 같은 일상적인 기계 공학 활동에서 높은 정확도를 달성하며, 추론적이고 주관적인 맥락에서도 엔지니어 수준의 추론을 효과적으로 재현한다. 이러한 연구 결과는 대화형 인터페이스가 엔지니어링 생산성을 향상시키고, 보다 상호작용적인 패러다임을 촉진하며, 설계 및 제조의 다양한 단계에 걸쳐 혁신적인 워크플로우를 주도한다는 점을 시사한다.

전문 엔지니어들 간의 대화에서는 일반적인 원리와 공학에 대한 지식이 특정 프로젝트나 기업의 구체적인 세부 사항과 종종 뒤섞여 나타납니다¹. 예를 들어, 한 엔지니어가 동료에게 다음과 같이 묻는 것은 당연한 일입니다:

- 1) 특정 부품의 중요한 설계 특징은 무엇인가요?
- 2) 4014 강철로 제작되거나 CNC(컴퓨터 수치 제어) 가공이 필요한 부품은 몇 개인가요?
- 3) 이 부품의 비용을 어떻게 절감할 수 있을까요?

현재의 엔지니어링 소프트웨어를 사용하여 이러한 질문에 답하려면, 사용자가 필요한 데이터를 정확히 지정하고, 이를 기존 컴퓨터 지원 설계(CAD) 소프트웨어 운영에 플러그인이나 확장 기능으로 통합할 알고리즘을 개발해야 합니다. 예를 들어, 형상 특징(예: 가공 또는 조립 특징)과 관련된 질문들은 자동 특징 인식(AFR) 시스템에 대한 연구를 촉진했습니다^{2,3}. 마찬가지로, 형상 분류는 콘텐츠 기반 검색에 대한 연구로 이어졌으며, 이 연구에서는 3D CAD 아카이브 데이터베이스 검색을 위한 키나 레이블을 제공하기 위해 기하학적 특징과 치수가 계산되었다⁴⁻⁶.

대규모 다중 모달 데이터셋에 대화형 인터페이스를 제공할 수 있는 LLM(대규모 언어 모델)의 등장은, 엔지니어링 애플리케이션(예: FEA(유한 요소 해석) 결과, CNC 공작 프로그램)의 내용을 바탕으로 응답을 구성하는 동시에, 텍스트 문서에서 도출된 일반 지식과 기술적 이해를 활용하여 자연어로 제시된 임의의 질문(즉, 프롬프트)에 답변할 수 있는 플랫폼을 구축할 기회를 제공합니다. 본 논문은 현재 LLM이 접근할 수 없는 컴퓨터 지원 엔지니어링(CAE) 및 CAD 데이터의 지식 격차를 해소하기 위해 설계된 시스템인 MechRAG(Mechanical

검색 강화 생성)을 소개한다.

MechRAG 아키텍처의 성공적인 구현은 대규모 언어 모델(LLM)이 CAE 및 CAD 데이터와 효과적으로 연동될 수 있도록 하는 데 달려 있습니다. 텍스트, 이미지, 비디오의 경우 널리 사용되는 형식(예: PDF, JPEG, MP4)을 통해 의미적 내용을 추출하는 도구를 사용하여 LLM이 쉽게 처리할 수 있는 반면, 3D CAD B-rep 모델, FEA 메쉬, 계측 포인트 클라우드 또는 XCT 복셀과 같은 CAE 데이터는 수치적 세부 정보는 풍부하지만 직접 접근 가능한 의미적 표현이 부족합니다. 이러한 비전에 따라, 본 연구의 목적은 제공된 특정 구성 요소와 관련된 CAE 데이터를 추론하고 분석할 수 있는 프롬프트 기반 챗봇을 개발하는 것이다.

이를 실현하기 위해 다음과 같은 목표가 설정되었습니다:

- 1) 성능을 벤치마킹할 수 있는 산업 시나리오를 정의하는 사용 사례 분류 체계를 구축한다.
- 2) 기계 공학용 소프트웨어 및 도구를 통해 대규모 언어 모델(LLM)을 확장한다. 외부 기계 공학용 소프트웨어 및 도구에서 획득한 데이터를 활용하는 방안을 모색한다.
- 3) 입력 데이터를 이해하고 나열된 문제에 대해 다중 모달 방식으로 답변할 수 있는 LLM 기반 시스템을 개발한다.
- 4) 다양한 구성의 LLM 기반 시스템을 실험하고, 가장 우수한 성능을 보이는 구성을 결정한다.
- 5) 제안된 시스템의 실제 산업 적용 가능성을 평가한다.

본 논문에서 제안된 MechRAG는 다양한 장려와 난이도에 걸친 임의의 프롬프트(예: 질문 및 과제)에 응답할 수 있다

—이는 현재의 CAD/CAE 시스템이 갖추지 못한 능력이다. 다중 모드 분류 과제와 개별 모델에 대한 정보 검색에서 MechRAG는 각각 최대 89.41%와 90.48%의 높은 정확도를 달성했다. 모델 모음/전체 데이터셋에 대한 질문 답변 및 추론 과제에서, 엔지니어들은 MechRAG가 인간 수준의 성능을 달성했다고 보고했다.

관련 연구

본 연구는 LLM, LLM의 지식을 확장하기 위한 RAG(Retrieval Augmentation Generation)의 활용, 그리고 CAD/CAM 데이터에 대한 추론이라는 세 가지 학술적 연구 분야를 바탕으로 합니다. 다음 섹션에서는 이러한 분야에서 보고된 연구 내용을 간략히 요약합니다:

LLM

지난 몇 년간 LLM은 모델의 규모와 훈련에 사용되는 데이터 세트의 규모 및 다양성을 지속적으로 확장함으로써 인간 언어의 이해 및 생성 분야에서 획기적인 발전을 이루었습니다. 자연어 처리(NLP) 분야에서 LLM은 텍스트 이해, 자동 질문-응답, 기계 번역 등과 같은 다양한 NLP 작업¹에 널리 활용되고 있습니다.

자연어 처리(NLP) 과제에서 대규모 언어 모델(LLM)이 거둔 성공에 힘입어, 이 범용 아키텍처는 비전 언어 모델(VLM)과 다중 모달 대규모 언어 모델(LLM)을 지원하도록 확장되었습니다. VLM은 시각적 정보와 언어적 정보를 결합함으로써 다중 모달 학습 분야에서 진전을 이루었습니다. 이러한 모델들은 이미지 설명 및 '시각적 질문 응답(VQA)'⁽⁸⁾과 같은 과제에서 뛰어난 성능을 입증했습니다.

특정 작업을 수행할 때, 기존의 심층 신경망(DNN) 모델은 패턴을 학습하고 예측을 내리기 위해, 대개 오랜 시간에 걸쳐 수집된 작업별 라벨링 데이터가 포함된 지도 학습이 필요합니다. 다양한 하위 작업을 수행하기 위해서는 일반적으로 작업별 데이터를 사용하여 파운데이션 모델을 미세 조정해야 합니다. 반면, 대규모 언어 모델(LLM)은 작업 설명을 입력으로 받아 프롬프팅을 통해 다양한 하위 작업에 원활하게 적응할 수 있습니다. LLM은 각 작업마다 방대한 데이터를 필요로 하는 대신, 무엇을 해야 하는지 지시하는 프롬프트만 사용합니다⁹. LLM은 다양한 수준의 수많은 작업에 대한 정보를 포함한 방대한 양의 다양한 데이터로 사전 훈련되었기 때문에 이러한 지시를 이해합니다¹⁰. 프롬프팅을 위해 LLM이 이해하고 추론하도록 더 효과적으로 안내하기 위한 다양한 기법이 개발되었으며, 그 예로는 제로샷(zero-shot) 및 퓨샷(few-shot) 프롬프팅과 사고의 연쇄(Chain-of-Thought, CoT)가 있습니다.

RAG 시스템 및 변형

LLM은 텍스트나 기타 형태의 출력을 생성할 때 파라미터에 저장된 암묵적 지식에 의존하는데, 이러한 의존성은 지식 집약적인 작업을 처리할 때, 특히 환각, 구식 지식, 투명하지 않고 추적 불가능한 추론 과정과 같은 문제들에 직면했을 때 한계가 됩니다. RAG는 외부 데이터베이스의 지식을 통합함으로써 이러한 문제에 대한 유망한 해결책으로 부상했습니다¹¹. 검색 및 생성 구성 요소를 결합함으로써, RAG는 생성 모델이 외부 지식 기반에서 관련 정보를 동적으로 획득할 수 있게 하여, 생성 과정에 더 정확하고 문맥적으로 적합한 콘텐츠를 반영할 수 있게 합니다.

일반적인 RAG는 색인화, 검색, 생성이라는 3단계 과정을 따릅니다. **색인화**는 텍스트 데이터의 경우 PDF, HTML, Word 문서와 같은 다양한 형식의 원시 데이터를 정리하고 추출하는 것으로 시작되며, 이후 이를 통일된 텍스트 형식으로 변환합니다. 언어 모델의 문맥 처리 한계를 보완하기 위해 텍스트는 더 작고 처리하기 쉬운 청크로 분할됩니다. 그런 다음 이러한 청크들은 임베딩 모델을 사용하여 임베딩 처리된 후 벡터 저장소에 저장됩니다. 임베딩된 청크는 후속 검색 단계에서 쿼리와 관련 인덱싱된 청크 간의 유사도 검색을 가능하게 하는 데 핵심적인 역할을 합니다. **검색 단계**에서는 먼저 쿼리를 처리하고, 동일한 임베딩 모델을 사용하여 쿼리를 벡터 표현으로 변환합니다. 그런 다음 쿼리 벡터 표현과 벡터 저장소에 있는 인덱싱된 벡터 간의 유사도를 비교합니다. 벡터들은 유사도에 따라 순위가 매겨지며, 상위 K개 항목이 선정되어 후속 단계인 **생성** 단계에서 증강에 활용됩니다. 쿼리와

원본 외부 데이터에서 선별된 부분들이 LLM의 프롬프트에 포함됩니다. 그러면 LLM은 자체적인 지식과 제공된 외부 지식에 포함된 정보를 바탕으로 쿼리에 응답할 수 있습니다.

RAG는 다양한 분야의 여러 작업에 적용될 수 있는 것으로 보고되었다. 예를 들어, Siriwardhana 등⁽¹²⁾은 RAG-end2end 모델을 제안했는데, 이 모델은 RAG 기법이 의료 및 뉴스 분야의 텍스트 생성 작업에 더 잘 적용될 수 있도록 한다. Ranjit 등¹³은 의료 영상 보고서 생성을 위한 RAG 기반 방법을 제안했다. Bran 등¹⁴은 표준화된 합성 절차를 자율적으로 적용하고 실행하는 RAG 기반 에이전트인 Chem-Crow를 제안했다. 또한 RAG는 예측 불가능한 환경에서 로봇이 장기적인 과제를 수행할 수 있도록 하는 데에도 적용되었다¹⁵. Dai 등⁽¹⁶⁾은 동적 검색 메커니즘을 활용하여 외부 데이터베이스에 접근함으로써 복잡한 교통 상황 하에서 자율 주행 시스템의 안전성과 신뢰성을 향상시켰다. LLM의 환각 현상을 줄이는 데 있어 RAG의 효과는 학생 학습을 돕기 위한 교육용 인공지능(AI) 도구에도 활용되었다¹⁷. RAG는 데이터 분포가 편향되어 대부분의 샘플이 소수의 클래스에 집중되는 롱테일 시각 인식과 같은 현실적인 시나리오에서 딥러닝의 과제를 해결하는 것으로 나타났다. 실제 적용 환경에서 높은 관련성을 보임에도 불구하고, 롱테일 분포에 대한 분류 성능은 여전히 균형 잡힌 데이터셋에 비해 뒤처지지만¹⁸, RAG 지원 기법을 통해 개선되었다¹⁹.

대부분의 RAG 구현은 텍스트 정보에 중점을 두지만, 이미지나 동영상과 같이 다양한 구조와 모달리티로 저장된 방대한 지식도 존재합니다. 이에 따라 복잡한 형식의 정보를 보다 효과적으로 통합하기 위해 다중 모달 RAG가 제안되었습니다. 다중 모달 RAG 기술의 주요 응용 분야는 두 가지 측면에 중점을 둡니다: 이미지 설명의 정확도 향상²⁰과 더 창의적이고 복잡한 이미지 생성^{21,22}입니다. 또한 다중 모달 RAG는 로우코드 플랫폼의 발전을 촉진하는 것으로 보고되었습니다.

CAE 데이터 분석

CAE 기술은 엔지니어링 분야에서 핵심적인 역할을 해왔으며 현재 매우 발전된 수준에 이르렀지만, 3D 모델 생성, 수정 및 시뮬레이션과 같은 작업의 경우, 기존 소프트웨어는 여러 출처에서 수집된 종합적이고 시계열적인 정보가 필요한 계획 수립이나 제조와 같은 주제에 대한 포괄적인 질문에 대응하는데 한계가 있습니다. 이러한 질문의 몇 가지 예로는 다음이 있습니다: 1) 특정 부품이 어떤 특징을 가지고 있는지, 또는 일련의 부품들 간에 어떤 특징이 공통적으로 나타나는지; 2) 특정 기준에 따라 평가했을 때 어떤 부품 그룹이 유사한 것으로 간주될 수 있는지; 3) 임의의 측정 기준(예: 부피, 표면적 등)을 사용한 부품의 측식 비교. 이러한 유형의 질문에 대한 기존 해결책은 일반적으로 토폴로지 분석²³⁻²⁵부터, 최근의 형태 분류 및 인식을 위한 컨볼루션 신경망(CNN)^{4,5} 및 그래프 신경망(GNN)⁶과 같은 하위 기호적 AI 접근법의 적용, 그리고 AFR을 위한 미세 조정된 파운데이션 모델^{26,27}에 이르기까지 다양한 접근법을 구현하는 별도의 소프트웨어 도구들에 의해 제공된다.

앞서 언급된 한계점에도 불구하고, CAE 데이터는 기계 공학 분야의 문제 해결을 가능하게 하고 최적화하는 데 효과적으로 활용되어 왔다. 문헌을 살펴보면, 특정 분야의 인간 전문가의 의사결정 능력을 모방하기 위해 구조화되고 사람이 읽을 수 있는 기호를 사용하는 지식 기반 공학 시스템, 즉 기호적 AI 접근법에 대한 연구 성과가 풍부하다. 제조 분야에서는 이러한 접근법이 공정 계획^{26,27}, 가공 특징 인식^{28,29}, 공구 선정^{30,31}, 제품 개발^{32,33} 등 다양한 주제에 적용되어 왔다.

방법

먼저, 프롬프트에 응답하기 위해 기업 고유의 CAE 데이터를 활용할 수 있는 경우 LLM의 가능한 활용 사례를 검토한 다음, MechRAG의 아키텍처와 구성 변수, 그리고 관련된 데이터 리소스에 대해 개요를 제시합니다.

대화형 CAE 인터페이스의 사용 사례

CAE용 다중 모달 RAG 시스템의 아키텍처를 정의하고 구성 매개변수를 조사하는 첫 번째 단계는 다음을 정의하는 것입니다.




그림 1 | 대규모 언어 모델(LLM)을 위한 컴퓨터 지원 엔지니어링(CAE) 데이터의 활용 및 변환. 이 그림은 CAD 모델, 경계 표현(B-rep), 메쉬, 모델링 이력 등과 같은 원본 컴퓨터 지원 엔지니어링(CAE) 데이터를 대규모 언어

(LLM)과 함께 사용할 수 있도록 변환되는 과정을 보여줍니다. 이러한 소스에서 기하학적 속성, 의미적 주석, 다중 뷰 시각적 표현을 포함한 명시적 및 암시적 정보를 추출할 수 있어, LLM에 의한 풍부한 후속 처리 및 해석이 가능해집니다.

시스템의 사용 사례. 저자들은 LLM에 CAE 데이터를 제공함으로써 다음과 같이 특징지을 수 있는 세 가지 유형의 “사용 사례”가 가능해질 것이라고 지적합니다. 모든 경우에서 MechRAG에 제공되는 모든 CAE 데이터는 고유한 식별자인 “부품 번호”(예: 0021426)와 연관되어 있다고 가정합니다.

레벨 1 작업: 직접적: 계산이 필요 없는 특정 부품에 대한 단일 값을 CAD 또는 PDM(제품 데이터 관리) 데이터에서 요청합니다. 레벨 1 기능은 이중 데이터(예: 서로 다른 CAE 패키지의 데이터)에 대해 일관되고 대화형 인터페이스를 제공합니다. 대표적인 사용 사례 예시는 다음과 같습니다: 1) 부품 00210008의 부피는 cm^3 단위로 얼마입니까? 2) 모델 00210337에는 원형 구멍이 몇 개 있습니까? 3) 부품 00210217에는 어떤 종류의 대칭성이 있습니까?

레벨 2 작업: 집합적: 작업 목표와 관련된 부품 집합에 대한 CAE 또는 PDM 데이터 요청 레벨 2 작업은 서로 다른 부품 간의 대화 및 비교를 가능하게 합니다. 대표적인 사용 사례 예시는 다음과 같습니다: 1) 부피가 가장 큰 부품과 가장 작은 부품은 무엇인가? 2) 구성 요소 데이터셋에는 어떤 대칭성이 존재하는가?

레벨 3 과제: 신흥 과제: CAD 또는 PDM 데이터와 사전 훈련을 통해 습득한 LLM의 일반 지식을 결합한 정보를 요청합니다. 예를 들어, 제조 공정이나 상대적 비용과 같은 개념은 특정 CAE 데이터 세트의 세부 사항을 넘어서는 일반 지식이 필요합니다. 대표적인 사용 사례는 다음과 같습니다: 1) 부품

00217697의 모델링 이력을 바탕으로, 어떤 다른 부품이 이 부품과 가장 유사한가? (모델링 이력은 부품을 정의하는 데 사용된 명령어 시퀀스(예: 스케치 및 돌출 작업)를 의미합니다).

CAE 데이터 소스

본 연구에서는 대규모 언어 모델(LLM)과 CAE 데이터의 디지털 표현 간의 격차를 해소하기 위한 두 가지 접근 방식을 조사하였다. 1) 기하학적 속성 및 치수와 같이 CAE 데이터에서 추출하거나 쉽게 계산할 수 있는 명시적 정보 (그림 1에 예시 제시됨), 그리고 2) CAE 데이터에 직접 포함되어 있지 않지만, 디지털 표현을 넘어서는 자원이거나 소프트웨어가 필요한 모델의 암시적 정보(예: 구성 요소 분류 및 뷰 이미지)

CAE 데이터의 다중 뷰 이미지를 생성하는 데는 다양한 소프트웨어를 활용할 수 있으며, 이를 통해 전문적인 수치 표현을 다중 모달 LLM이 해석할 수 있는 2D 이미지 데이터로 변환하는 일반적인 접근 방식을 제공할 수 있다. 예를 들어, Matlab 프로그램은 OBJ 파일을 조회하고 조작할 수 있으며, 마찬가지로 Solid Edge API는 STEP 파일에 대한 인터페이스를 제공하고, PyOCC 또한 STEP 파일로부터 다중 뷰 이미지를 생성하기 위한 CAD2Image 변환기³⁶를 지원하는 기능을 제공합니다. 다중 뷰 이미지 외에도 3D CAD 모델에는 추출하여 텍스트 데이터로 기록할 수 있는 수많은 메타데이터가 포함되어 있습니다. 여기서 메타데이터란 표면적, 모델 부피, 곡률, 치수 등을 포함한 기하학적 특징을 의미합니다. STEP 모델은 원본 B-rep 정보를 포함하는 반면, STL 파일은 일반적으로 메쉬를 통해 3D 객체를 표현합니다. STL 파일에서는 잘 표현되지 않는 복잡한 기하학적 특징은




그림 2 | MechRAG 아키텍처. MechRAG는 색인화, 검색, 생성이라는 세 가지 주요 단계로 구성된 구조화된 아키텍처를 통해 다중 모달 작업을 지원한다. 이 프레임워크는 성능 최적화를 위해 다섯 가지 구성 가능한 변수를 활용한다.

STEP 파일에서 추출된 데이터와 달리, STL 파일은 대칭성과 같은 전역적 특성을 평가하는 데 더 유용한 계산 도구를 제공합니다. 본 논문에서는 STL 파일에서 기하학적 데이터를 추출하기 위해 Python TriMesh 패키지를 사용하고, STEP 파일의 경우 PyOCC를 사용합니다. 이 패키지들은 3D CAD 모델 내의 방대한 수치 데이터를 필터링하고 정리하여 LLM이 처리할 수 있는 특징으로 변환하는 도메인 특화 기능을 내장하고 있습니다.

CAE 소프트웨어와 자주 연관되는 또 다른 형태의 정보는 모델링 이력으로서, 이는 모델을 구축하는 데 사용된 명령어(즉, 코드)의 순서를 의미합니다. 본 연구에서는 3D CAD 모델과 관련된 구체적인 명령어 이력을 고려하여 이러한 일반적인 표현 방식을 조사합니다. 이러한 연구를 수행하기 위해 사용된 데이터셋은 [참고문헌 23](#)에서 개발되었다. 이 데이터셋에서 모델링 이력은 '스케치' 및 '돌출' 연산으로 구성된다. 비록 단순하지만, 이 두 연산의 조합은 다양한 3D 형상 모음을 생성하기에 충분한 표현력이 있다³⁵.

데이터셋

MechRAG의 훈련 및 평가에 사용된 데이터셋은 기계 CAE 도구에서 생성된 다양한 형태의 출력물로 구성되어 있으며, 엔지니어링 도구의 기계 모델에서 RAG 시스템으로 이어지는 중간 단계를 제공합니다.

데이터셋 1 (제조 공정이 라벨링된 기계 부품). 데이터셋 1([참조 36](#)에 상세히 기술됨)에는 용접, 단조, 기타, 판금, 선반 가공 등 5가지 서로 다른 제조 방법으로 제작된 기계 부품의 예시가 포함되어 있습니다. 각 제조 방법별 부품 수는 약 8,600개이며, 총 부품 수는 43,380개입니다. 각 부품에 연관된 제조 방법은 해당 부품을 생산하는 데 사용된 주된 공정을 의미하며, 생산 공정의 모든 세부 사항을 포괄적으로 기술한 것은 아닙니다. 조립, 단조, 판금, 선반 가공으로 제조되지 않은 부품은 '기타'로 분류됩니다. 데이터셋 1에는 또한 다양한 시점에서 촬영된 각 기계 부품의 이미지가 포함되어 있습니다.

데이터셋 2 (형상 생성 이력이 포함된 기계 부품). 이 데이터셋은 17만 개 이상의 CAD 모델과 해당 모델의 생성 순서를 포함하는 DeepCAD 데이터셋²³에서 파생되었습니다. MechRAG가 요구하는 명시적 및 암시적 정보를 모두 충족하기 위해서는, STEP 형식의 경계 표현(BRep) 모델을 각 부품의 모델링 이력과 연계해야 했습니다. 이는 DeepCAD와 ABC 간의 교집합을 식별함으로써 달성되었습니다.

데이터셋³⁷, 후자는 CAD 모델용 STEP 파일을 제공합니다. 결과 데이터셋에는 명시적 정보와 암시적 정보(그림 1 참조)가 포함되어 있으며, 2,131개의 기계 부품에 대한 모델링 이력이 담겨 있습니다(예시는 보충 표 2에 첨부됨). 원래 JSON 형식으로 되어 있던 모델링 이력은, LLM과의 대화를 원활하게 하기 위해 CAD 시스템 내에서 3D 형상을 생성하는 데 사용된 작업에 중점을 둔 자연어 설명으로 변환되었습니다.

MechRAG 시스템

다른 RAG 시스템과 마찬가지로, MechRAG는 색인화, 검색, 생성이라는 세 단계로 구성됩니다. 그러나 이 세 단계 내에는, 특히 다중 모달 RAG의 경우 다양한 전략과 대안이 존재합니다. 본 논문에서는 MechRAG의 각 단계에서 적용 가능한 다양한 구성 방안을 탐구합니다. MechRAG의 전체 구조와 5가지 번호가 매겨진 구성 변수는 [그림 2](#)에 제시되어 있습니다.

임베딩 방법 (변수 1). 첫 번째 구성 변수는 이미지와 텍스트가 혼합된 다중 모달 데이터에 대한 특징 추출 방법이다. 텍스트 전용 데이터에 대한 특징 추출은 SentenceTransformer³⁸⁾를 사용하여 수행된다. 이미지 추출을 위한 첫 번째 후보(접근법 1)는 다중 모달 임베딩 기반 접근법이다. 즉, 이미지 데이터와 텍스트 데이터 모두 특수화된 모델(예: CLIP³⁹(Contrastive Language-Image Pre-training), ViLT⁴⁰(Vision-and-Language Transformer))를 사용하여 공유 벡터 공간에 임베딩된다. 목표는 서로 다른 유형의 데이터(예: 텍스트와 이미지)를 통합된 방식으로 표현하여, 비교하거나 검색에 함께 사용할 수 있도록 하는 것입니다.

또 다른 접근 방식(접근법 2)은 이미지 요약 및 텍스트 임베딩 기반 접근 방식이다. 즉, 먼저 이미지 캡션 생성 모델이나 요약 모델과 같은 모델을 사용하여 이미지에서 요약문(일반적으로 텍스트 형태)을 생성한 다음, 이 생성된 텍스트를 텍스트 전용 임베딩 모델(예: SentenceTransformer)을 사용하여 벡터 공간에 임베딩한다. 접근법 2와 비교할 때, 접근법 1은 직접적인 교차 모달 정렬과 다중 모달 이해 능력을 갖추고 있는 반면, 접근법 2는 이미지에 대한 보다 중간적인 표현을 사용하여 텍스트 중심적이다. 접근법 1은 이미지와 텍스트를 모두 직접 사용하기 때문에 임베딩된 특징은 원본 데이터를 더 풍부하게 표현하는 반면, 접근법 2의 이미지 표현 품질은 이미지 요약이 이미지를 얼마나 잘 포착하느냐에 크게 좌우됩니다. 그러나 접근법 2의 장점은 계산 부담이 적다는 점이다. 이미지가 요약되면 이후 작업에서는 더 이상 이미지를 다루지 않고 텍스트만 처리하므로, 임베딩을 처리하는 모델과 저장 공간에 대한 요구 사항이 낮아진다.




그림 3 | 레벨 1 과제. 이 그림은 모든 개별 부분에서 레벨 1 과제에 사용된 쿼리 집합을 보여준다.

임베딩 모델(변수 2). CLIP 외에도 다른 시각 언어 모델(VLM)들이 특징 추출 측면에서 어떻게 수행되는지 살펴보는 것도 흥미롭습니다. 이는 본 논문에서 고려한 두 번째 구성 변수이며, 임베딩을 위한 또 다른 VLM인 ViLT도 CLIP의 대안으로 실험적으로 평가되었습니다. CLIP은 대조 학습 접근법을 통해 이미지 및 텍스트 표현을 공동으로 훈련하는 모델입니다. 반면 ViLT는 시각적 정보와 텍스트 정보를 통합된 트랜스포머 모델에 직접 통합합니다⁴⁰. ViLT는 이미지와 텍스트를 별도로 처리하는 대신, 이미지의 패치와 텍스트 시퀀스를 단일 트랜스포머 아키텍처에 임베딩함으로써 두 모달리티를 보다 통합된 방식으로 공동으로 추론할 수 있게 합니다.

검색 단계에서 CLIP은 두 모달리티(텍스트와 이미지)에 대한 쿼리를 동시에 처리할 수 있으며, 텍스트나 이미지 중 하나의 모달리티만 사용하는 쿼리도 임베딩 생성에 활용할 수 있습니다. 반면, ViLT는 두 모달리티를 동시에 처리해야 했습니다. 본 논문에서 ViLT에 단일 모달 쿼리가 사용될 경우, 다른 모달리티의 입력은 빈 데이터로 채워집니다. 즉, 텍스트의 경우 공백으로 채워진 문자열이, 이미지의 경우 흰색 픽셀로 채워진 맵(이는 다중 뷰 이미지의 배경색입니다)이 사용됩니다.

색인 비율 (변수 3). 색인 단계의 또 다른 구성 변수는 색인에 사용되며, 따라서 검색 및 프롬프트 생성에 활용 가능한 데이터셋의 비율입니다. 전통적으로 분류 및 인식과 같은 작업은 해당 작업에 특화된 훈련된 감독 학습 DNN을 통해 수행되며, 여기에서와 같은 일반적인거나 소규모 데이터셋의 경우 훈련/테스트 비율이 대개 큼니다. 일반적인 훈련/테스트 비율은 9:1 또는 8:2로, 이는 데이터셋 내 대부분의 데이터가 훈련에 사용됨을 의미합니다. LLM과 RAG 시스템은 DNN에 대한 특정 훈련 및 대규모 훈련 데이터셋에 대한 부담을 줄여줍니다.

이 세 번째 구성 변수는 훨씬 더 낮은 훈련/테스트 비율을 가진 LLM의 사전 훈련에서 목표하지 않은 작업에 대해 LLM과 RAG가 얼마나 잘 일반화되는지 탐구하기 위해 설정되었습니다.

색인 단계와 관련된 세 가지 구성 변수 외에도, 생성 단계에서도 다양한 접근 방식을 시도할 수 있는 여지가 있습니다. 본 논문에서는 프롬프트 엔지니어링이 RAG 시스템의 성능에 어떤 영향을 미치는지 조사하기 위해 '단순 프롬프트'와 '전문 프롬프트'라는 두 가지 프롬프트 전략을 비교합니다.

프롬프트 전략 (변수 4). 단순 프롬프트 접근법은 기계 공학자의 전문적 배경과 과제 목표를 강조하며, 직접적인 과제 설명과 원하는 출력 형식을 제시한다. 단순 프롬프트는 LLM이 주요 제조 방법과 기계 부품의 핵심 특징을 분석하도록 안내하는 기본적인 분석 프레임워크를 제공한다(보충 그림 1 참조).

반면, 전문 프롬프트 접근법은 소위 "퓨샷(few-shot)" 학습과 CoT 기법을 결합한 보다 정교한 전략을 활용합니다. 이 접근법은 단순 프롬프트의 입력 정보 외에도, 육안 검사, 검색된 유사 부품과의 비교, 제조 방법 분석, 주요 특징 식별 등을 포함한 상세한 단계별 분석 가이드를 제공합니다. 이 접근법은 모델이 보다 심층적이고 체계적인 분석을 수행할 수 있도록 안내하기 위해 고안되었습니다. 전문 프롬프트 전략의 강점은 주로 체계적인 분석 접근 방식에 있습니다. 상세한 분석 단계를 제공함으로써, 전문 프롬프트는

보다 포괄적이고 체계적인 관찰과 추론을 통해 모델을 개선합니다. 이러한 접근 방식은 모델이 더 많은 세부 사항을 포착하도록 돕는 것은 물론, 분류 과정에서 서로 다른 범주 간의 구분을 더욱 명확하게 해줍니다(보충 그림 2 참조).

LLM 플랫폼 (변수 5). 다섯 번째 구성 변수는 최종 생성 단계에 사용되는 다중 모달 LLM의 선택이다. GPT-4o는 자연어 및 다중 모달 데이터 처리와 생성 능력을 입증했기 때문에 확실한 후보이다. 그러나 이것이 유일한 시스템은 아니며, 또 다른 인기 있는 다중 모달 LLM인 Claude-3.5-Sonnet도 비교를 위해 구성 실험에 사용되었다.

결과

이 절에서 수행한 실험을 통해, 레벨 1부터 3에 이르는 다양한 예제 과제를 바탕으로 MechRAG의 성능과 잠재력을 평가합니다. 본 논문에서는 MechRAG 프레임워크로 LangChain을, 벡터 저장소로 ChromaDB를 사용했습니다. 모든 실험은 Google Colab Pro+ A100 GPU와 최대 89GB의 RAM 환경에서 실행되었습니다.

레벨 1 작업에 대한 실험


레벨 1 작업에서 MechRAG는 개별 부품에 대해 CAE 소프트웨어가 생성한 모든 정보를 파악하고 있는 대화형 데이터 관리 도구 역할을 수행하며, 자연어 쿼리를 통해 이 데이터 세트에 대한 접근을 제공합니다. 개별 부품의 속성과 관련된 쿼리 목록은 그림 3에 나와 있으며, 이는 레벨 1 작업에 대한 MechRAG의 응답을 평가하기 위해 수행되었습니다. 그림 3에 표시된 구체적인 모델 식별 번호는 프롬프트 텍스트 내의 예시용 자리 표시자입니다. 평가 과정에서 동일한 쿼리가 모든 모델의 부품 ID를 순차적으로 적용하여 실행되었습니다.

그림 3에 나열된 레벨 1 과제들의 정확도는 90.48%를 기록했다. 그러나 RAG 시스템은 컨텍스트 윈도우, 즉 언어 모델이 쿼리당 처리할 수 있는 최대 토큰 수에 제약을 받습니다. 이러한 제한으로 인해, LLM이 응답을 생성할 때 전체 데이터셋이 아닌 검색된 일부 정보만 이용할 수 있습니다. 여기에서 수행되는 검색 과정이 개별 부분에 대한 정보를 대상으로 하기 때문에, 특정 부분에 대한 정보가 불완전하여 정확도가 100%에 미치지 못하는 경우가 발생할 수 있습니다.

레벨 2 과제에 대한 실험

레벨 2 작업의 경우, MechRAG는 관련 CAE 데이터와 함께 여러 기계 부품을 종합적으로 보여줌으로써 이들 부품 간의 비교를 가능하게 합니다. 레벨 2에서 테스트된 작업의 예시 쿼리는 그림 4에 나열되어 있습니다. 그림 4의 정답 데이터는 각 세대별 모델과 비교할 수 있도록 라벨이 지정되어 있습니다. 주목할 점은 레벨 2 작업에서 MechRAG가 LLM 입력의 토큰 제한에 큰 영향을 받는다는 것입니다. 증강을 통해 LLM에 노출되는 모델과 모델의 수는 세대마다 다릅니다. 따라서 여기서의 정답 데이터는 올바른 순서와 값을 라벨링할 뿐만 아니라, 각 세대에 포함된 모델의 범위를 명시합니다. 모델 MechRAG를 보완하고 결과를 도출하는 데 사용된 모델들은 그림 5에 제시되어 있다. 동일한 모델 집합을 대상으로 여러 실험이 수행되었으며, 수행되었으며, 그림 4의 안정성 표시(오른쪽 열)는 자기 일관성 평가 결과를 상세히 보여준다. 응답의 안정성을 평가하기 위해 각


그림 4 | 레벨 2 과제. 이 그림은 레벨 2 과제에 대해 MechRAG가 생성한 응답을 보여준다. 수치 값의 수가 증가함에 따라 응답의 품질과 정확도는 저하되는 경향을 보이며, 이는 복잡한 정량적 입력 처리에 있어 한계를 보여준다.



실험 과정에서 쿼리가 9회 반복되었습니다. 정답과 비교한 정답 수에 따라 결과는 다음과 같이 분류되었습니다: 1) 나쁨: 정답 1~3개; 2) 보통: 정답 4~6개; 3) 좋음: 정답 7~9개. 처리되는 수치 데이터의 양이 증가할수록 정답률이 낮아지는 경향이 있음은 명백합니다.

그림 4에 나타난 잘못된 수치적 추론의 예로는, 모델 부피의 경우 117363.577 mm³과 121344.748 mm³의 순서가 뒤바뀐 점, 그리고 모델 표면적의 경우 26151.147 mm², 20279.800 mm² 및 29794.086 mm²의 순서가 뒤바뀐 점이 있습니다. 이러한 오류는 응답의 일관성을 저해하여 서로 다른 답을 도출하게 한다.

그림 5 | 세대별 모델 이미지. 보고된 세대에 사용된 개별 부품 이미지.



레벨 3 과제에 대한 실험

레벨 1 및 레벨 2 작업의 경우, MechRAG는 쿼리 시점에 제공된 CAE 데이터를 활용하여 기계 부품에 관한 질문에 답변합니다. 레벨 3에서는 MechRAG가 (RAG 프로세스를 통해) 검색된 부품별 정보와 LLM의 사전 학습된 지식을 통합해야 하는 작업을 처리합니다. 즉, 레벨 3 프롬프트는 특정 상황에 맞는 CAE 데이터와 (모델의 사전 학습 과정에서 습득한) 일반적인 생산 공학 원리를 결합한 응답을 유도합니다.

MechRAG와의 대화. 레벨 3의 첫 번째 텍스트 데이터 기반 과제를 조사하였으며, 그 예시는 그림 6과 그림 7에 제시되어 있다. 이러한 질의는 추상적이며 명확한 정답이 없으므로, 실제 엔지니어들은 합의된 견해를 도출하기 위해 가능한 답변들에 대해 논의해야 하는 경우가 많다. 우리는 현재 엔지니어를 대상으로 한 인간 연구를 통해 MechRAG를 평가했다: 산업계 CPD(지속적 전문성 개발) 수강생 106명을 초청했으며, 그중 21명이 자발적으로 참여하여 그림 6과 그림 7에 제시된 4가지 MechRAG 응답을 4점 척도(1 = 부적절 ... 4 = 완전히 적절)로 평가했다. 본 연구는 저자의 소속 기관 윤리 규정을 준수하였으며, 사전 동의, 안전한 데이터 처리, 보상 없음, 성적 평가에 대한 영향 없음, 저자나 교직원의 감독 권한 없음 등의 원칙을 따랐습니다. 과제의 모호성과 제한된 맥락을 고려할 때 MechRAG의 응답이 만족스럽고 엔지니어의 성과와 대체로 비교 가능하다는 우리의 결론은 “만족스럽다”(≥ 3/4)로 판정된 평가 비율에 근거합니다. 프롬프트를 더 정밀하게 만들 수는 있었지만(예를 들어, 단일 구성 요소의 정의를 명시하거나, 가장 비판 구성 요소를 식별하려는 프롬프트에 배치 크기나 재료 비용을 포함하는 등), 현재 프롬프트만으로도 MechRAG의 핵심 역할, 즉 특정 구성 요소 수준의 데이터를 일반적인 공학 지식과 통합하는 능력을 입증하기에 충분합니다. 중요한 점은 레벨 3 응답이 사실적 정확성만으로 평가되는 것이 아니라, 검색된 CAE 데이터와 LLM의 사전 훈련된 도메인 지식을 포함한 정보 소스의 적절한 활용 및 통합을 기준으로 평가된다는 것입니다. 그림 6에서 주목할 점은 동일한 모델인 00216109가 가장 고유하면서도 제조 비용이 가장 높은 모델로 모두 제안되었다는 사실입니다. 추론 과정을 살펴보면, 두 프롬프트가 각각 ‘독창성’과 ‘비용’이라는 서로 다른 기준을 다루고 있음에도 불구하고, 구멍의 수와 종류와 같은 유사한 평가 지표가 두 프롬프트에 대한 응답을 결정하는 데 사용되었음을 알 수 있습니다.

그림 7에서, 먼저 MechRAG는 모델링 이력을 바탕으로 가장 유사한 모델을 식별해야 합니다. 응답 생성은 부품의 모델링 이력에 대한 신뢰할 수 있는 추론 과정을 보여줍니다. 이러한 유사성 비교를 바탕으로, 그림 7의 후반부에 표시된 바와 같이 기존 모델과 유사한 모델에 대한 모델링 이력을 생성하는 것이 자연스러운 다음 단계입니다. 쿼리된 알려지지 않은 모델은 모델 00219880을 기반으로 무작위로 생성된 기하학적 특징을 가지며, 이 생성은 해당 모델의 유사체를 식별할 뿐만 아니라 모델링 이력도 제한합니다.

레벨 3의 다중 모달 과제. MechRAG는 텍스트 데이터에만 국한되지 않으며, 이 섹션에서는 MechRAG를 사용하여

기계 부품에 대한 다중 모달 이미지 및 텍스트 데이터를 포함하고 있습니다.

이 제조 공정 식별 작업의 경우, MechRAG에 입력되는 쿼리는 다른 작업에서와 같이 텍스트 쿼리가 아닌 부품의 뷰 이미지입니다. MechRAG는 이러한 이미지 쿼리를 바탕으로 일반 지식과 보강 정보를 활용하여 관련 제조 공정을 생성합니다. 생성된 결과를 평가하기 위해, 본질적으로 동일한 제조 공정을 가리킬 수 있는 생성된 문구의 무작위성과 다양성을 고려하기 위해 매핑 방법이 적용되었습니다. (보충 그림 3에 설명된 바와 같이, 동일한 범주에 속하는 모든 설명은 동등한 것으로 간주됩니다.) 다중 모달 RAG 및 LLM은 더 많은 구성 매개변수를 포함하므로, 먼저 다양한 구성 매개변수를 조사하여 성능에 미치는 영향을 비교하고 최적의 구성 전략을 도출했습니다. 모든 구성 변수는 RAG 시스템 내에서 작용하는 단계에 따라 두 그룹으로 나뉩니다. 전체 데이터셋의 10%로 훈련된 CLIP을 다중 모달 데이터의 임베딩 모델로 사용하고 간단한 프롬프팅 전략을 적용한 MechRAG 시스템이 비교를 위한 벤치마크로 간주됩니다. 제조-

제조 공정 식별 작업의 정확도는 80.78%입니다.

인덱싱 단계에서 데이터셋의 임베딩은 다양한 방식으로 구현될 수 있다. 여기서는 가장 널리 사용되는 두 가지 임베딩 모델인 CLIP과 ViT를 다중 모달 임베딩에 적용하였다. 그림 8에서 볼 수 있듯이, ViT는 벤치마크 구성에 비해 RAG 시스템 성능에 부정적인 영향을 미치고 있습니다. 다중 모달 임베딩 외에도 이미지 요약 및 텍스트 임베딩도 탐구되었습니다. 텍스트 요약은 필연적으로 이미지에 내포된 정보의 일부만을 포착하기 때문입니다. 이는 (원본 이미지에 비해) 부분적인 지식을 나타내므로, 이미지 요약과 텍스트 임베딩을 통합하면 성능이 저하됩니다.

LLM이 등장하기 전에는 이미지 콘텐츠 분류가 특정 작업에 맞춰 훈련된 지도 학습 DNN을 통해 수행되었으며, 데이터셋 1과 같은 일반적인 규모의 데이터셋에서는 훈련/테스트 비율이 대개 높았습니다. 일반적인 훈련/테스트 비율은 9:1 또는 8:2입니다. LLM과 RAG 시스템은 DNN에 대한 특정 훈련 및 대규모 훈련 데이터셋에 대한 부담을 줄여줍니다. 여기서는 LLM과 RAG가 사전 훈련 시 타겟으로 삼지 않은 작업에 대해 얼마나 잘 일반화되는지 정확히 검증하기 위해 다양한 훈련/테스트 비율도 조사했다. 그림 8에서 볼 수 있듯이, MechRAG는 감독 학습 DNN과 유사한 양상을 보이며, 훈련 과정에서 더 많은 데이터가 노출될수록 모델의 추론 능력이 향상된다. 훈련 과정에서 전체 데이터셋의 1%, 2%, 5%만 노출된 경우, 전체 데이터셋의 10%를 훈련 데이터로 사용하면 벤치마크 구성에 비해 성능이 저하되는 반면, 전체 데이터셋의 20%를 훈련에 노출하면 성능이 향상됩니다. 그러나 여기서 중요한 점은 전체 데이터셋의 10% 또는 20%만을 훈련에 사용해도 이미 80% 이상의 정확도를 제공한다는 것입니다. 이는 LLM과 RAG 시스템의 장점을 결합한 제안된 MechRAG가 방대한 훈련 데이터의 필요성을 없애고, 전체 데이터셋의 일부만으로도 분류 작업에 만족스러운 성능을 제공한다는 것을 의미합니다.

두 번째 구성 변수 그룹은 RAG 시스템의 생성 단계와 관련이 있습니다. RAG를 전혀 사용하지 않는 경우부터 간단한

Query

Singularity Analysis

Based on the provided information, which model seems to be the rarest among all models and why?

Output

From the provided information, there are 4 distinct models:

- model_00216109: A part with 9 round holes (diameters ranging from 1.5mm to 8.2mm), volume 16,564.106 cubic MM
- model_00214261: A complex part with 40 round holes (diameters ranging from 5.924mm to 95.609mm), volume 973,788.103 cubic MM
- model_00219880: A simple part with 1 round hole, volume 89,501.364 cubic MM
- model_00219090: A part with 24 round holes (diameters of 8mm and 22mm), volume 117,363.577 cubic MM

Among these, model_00214261 appears to be the rarest because:

1. It has the highest number of unique holes (40 holes) with widely varying diameters
2. It has the largest volume (973,788.103 cubic MM)
3. It has the most complex surface characteristics (98.993% curved surface)
4. It has the most elaborate combination of parallel (33) and perpendicular (6) holes
5. It demonstrates the most complex modeling history with multiple sketch and extrude operations
6. It shows unique geometric complexity with significant curved edge percentage (48.498%)

The complexity and scale of model_00214261's features make it stand out as the most unique and intricate design among the four models presented.

Query

Manufacturing Cost Comparison

Based on the provided information, which model seems to be the most expensive one in terms of manufacturing process and why?

Output

Based on the provided information, there are 4 models:

- model_00216109 (a part with 9 round holes ranging from 1.5mm to 8.2mm diameter)
- model_00214261 (a complex part with 40 round holes ranging from 5.924mm to 95.609mm diameter)
- model_00219880 (no hole details provided)
- model_00219090 (a part with 24 round holes ranging from 8mm to 22mm diameter)

Model_00214261 appears to be the most expensive to manufacture because:

1. It has the largest volume (973,788.103 cubic MM) and surface area (206,703.895 square MM)
2. It contains the highest number of holes (40 unique holes)
3. It has the most complex hole pattern with widely varying diameters (from 5.924mm to 95.609mm)
4. It has both parallel (33) and perpendicular (6) hole orientations
5. It has the highest percentage of curved surfaces (98.993%) compared to flat surfaces
6. The modeling history shows extensive sketch and extrude operations, indicating complex geometry

The combination of large size, high number of features, and complex geometry would require more material, machining time, and sophisticated manufacturing processes, making it likely the most expensive to produce.

그림 6 | 레벨 3 과제 1. 레벨 3 과제에 대한 MechRAG의 응답.

프롬프팅, 그리고 CoT에 이르기까지, GPT-4o와 Claude라는 두 LLM 모두 점점 더 우수한 성능을 보여줍니다. 간단한 프롬프팅 (보충 그림 1 참조)의 도움으로, MechRAG는 표 1에서 볼 수 있듯이 생성 과정에 정보가 전혀 입력되지 않은 경우보다 현저히 더 나은 성능을 보였습니다. CoT(보충 그림 2 참조)는 이러한 우위를 더욱 공고히 하며, 표 1에서 볼 수 있듯이 두 LLM 모두의 성능을 지속적으로 향상시킵니다. 이 제조 방법 분류 과제에 대해 Claude와 GPT-4o라는 두 LLM을 비교했을 때, RAG 미적용, 단순 프롬프팅, CoT의 세 가지 시나리오 모두에서 GPT-4o가 대부분의 경우 모든 지표 측면에서 Claude보다 우수한 성능을 보였습니다.

결론적으로, MechRAG의 최적 구성 설정은 제조 공정 식별에서 89.41%의 정확도를 달성하는 반면, 부적절한 구성은 정확도를 38%까지 떨어뜨릴 수 있다.

다양한 MechRAG의 성능에 대한 보다 상세한 실험 결과는 보충 표 1에 제시되어 있습니다.

결론 및 논의

본 논문에서는 CAD/CAM 시스템이 현재 수작업으로 처리되고 있는 기계 부품 관련 질문에 대응할 수 있도록 RAG 기반 시스템인 MechRAG를 제안한다. MechRAG는 다양한 유형과 난이도의 질문 및 작업을 처리할 수 있다. 다중 모달 분류 작업 및 단일 모델에 대한 정보 검색에서 MechRAG는 각각 최대 89.41%와 90.48%의 높은 정확도를 달성했다. 모델 모음/전체 데이터셋에 대한 질문 답변 및 추론 작업의 경우, 엔지니어들은 MechRAG가 인간 수준의 성능을 보였다고 보고했다.




그림 7 | 레벨 3 과제 II. 모델링 이력 데이터와 관련된 레벨 3 과제에 대한 추가 MechRAG 응답.

토큰 제한

현재 MechRAG 구현의 분명한 한계 중 하나는 생성 단계에서 대규모 언어 모델(LLM)에 입력할 수 있는 컨텍스트 윈도우의 토큰 수 제한으로, 이는 LLM을 강화하는 데 활용할 수 있는 데이터의 양이 제한된다는 것을 의미합니다. 이러한 단점 때문에

MechRAG는 쿼리에 대한 불완전한 정보만 확보하게 되어 결과적으로 부정확한 결과를 제공할 수 있습니다.

이 문제를 설명하기 위해, 그림 9는 레벨(Level) 과제를 수행할 때 대규모 언어 모델(LLM)의 토큰 제한이 미치는 영향을 보여줍니다. 첫 번째 시나리오에서는 전체 데이터셋의 크기가 토큰 제한과 동일하므로, 전체 데이터셋을 입력으로 사용할 수 있습니다

그림 8 | 다양한 MechRAG 구성의 성능. 다양한 MechRAG 구성의 성능 요약. 벤치마크 설정에는 임베딩 모델로 CLIP, 다중 모달 임베딩 전략, 훈련에 사용된 전체 데이터셋의 10%, 그리고 GPT의 간단한 프롬프트가 포함됩니다. 테스트된 변형 중에서는 훈련 데이터 비율을 늘리고 체인 오브 씹크(CoT) 프롬프트 전략을 도입한 경우에만 벤치마크 대비 성능이 향상되었습니다.




표 1 | 다양한 MechRAG 구성의 성능

구성	정확도	정밀도	F1 점수
GPT + CLIP	80.78%	82.16%	79.78%
GPT+ViLT	74.12%	76.07%	72.93%
GPT+이미지 요약 및 텍스트 임베딩	38.82%	52.74%	38.25%
GPT + 1% 데이터	63.53%	65.11%	62.45%
GPT + 2% 데이터	68.24%	70.31%	66.38%
GPT + 5% 데이터	75.29%	77.21%	73.31%
GPT + 20% 데이터	85.88%	86.91%	85.39%
Claude	72.16%	77.53%	70.09%
GPT+RAG 미사용	52.16%	55.40%	51.84%
Claude+RAG 없음	51.76%	59.01%	46.49%
클로드+CoT	76.47%	100.00%	85.54%
GPT+CoT	89.41%	100.00%	94.05%

이 표는 정확도, 정밀도 및 F1 점수를 기준으로 다양한 MechRAG 구성의 성능을 요약한 것입니다. 모든 구성 중에서 GPT-4o에 구현된 체인 오브 씹크(CoT) 프롬프트 전략이 가장 높은 종합 성능을 보였습니다.

LLM에 입력하여 개별 부품과 관련된 레벨 1 작업에 대한 정확한 정보를 제공합니다. 이 시나리오에서 검색 횟수를 늘리면, 전체 데이터셋 중 LLM에 입력되는 비율이 증가합니다. 이 비율이 클수록 대상 기계 부품이 LLM에 입력될 확률이 높아지므로, LLM의 성능이 향상됩니다. 그림 9의 우측 상단에서 볼 수 있듯이, 데이터셋의 거의 전부가 LLM에 입력되며, 그 결과 특정 모델의 부피 및 표면적과 관련된 레벨 1 과제 문제를 쿼리할 때 정확도가 90% 이상으로 나타납니다. 두 번째 시나리오에서는 전체 데이터셋이 토큰 제한보다 훨씬 크기 때문에, 허용되는 최대 검색 횟수를 사용하는 것이 대상 모델을 검색하는 최선의 방법이다. 검색 횟수를 줄이면 LLM이 정답 데이터에 접근할 수 있는 가능성이 제한될 뿐이며, 이는 그림 9에 잘 반영되어 있다.

데이터셋 2에 포함된 개별 기계 부품과 관련된 텍스트 데이터의 길이는 약 1,500에서 90,000 토큰 사이입니다. 문맥을 고려할 때




그림 9 | 검색 횟수가 쿼리 응답 정확도에 미치는 영향. 이 그림은 대규모 언어 모델(LLM)의 토큰 제한이 생성 과정에서 MechRAG가 완전한 정보에 접근하는 능력에 어떤 영향을 미치는지 보여줍니다. 데이터셋 크기가 토큰 제한 범위 내에 있는 시나리오에서는 검색 횟수가 늘어날수록 성능이 향상되어 레벨 1 작업에서 90% 이상의 정확도를 달성한다. 그러나 데이터셋이 토큰 제한을 초과할 경우, 관련 데이터에 대한 접근이 제한되어 추가적인 검색은 미미한 향상 효과만을 가져온다.

GPT-4o의 컨텍스트 창은 128,000 토큰으로 제한되어 있어, 이는 불과 수십 개의 부품으로 구성된 비교적 작은 조립체조차도 모델이 효과적으로 컨텍스트를 처리할 수 있는 용량을 초과할 수 있음을 시사합니다. 이러한 한계는 부품의 수와 복잡성이 훨씬 더 큰 자동차 엔진이나 산업용 로봇과 같은 복잡한 시스템의 경우 더욱 두드러집니다. 그 결과 성능은 그림 9의 두 번째 시나리오보다 더 나빠질 수 있습니다.

향후 연구

향후 연구에서는 MechRAG 시스템에 통합될 기계공학 모듈이 더 많이 남아 있습니다. 본 논문에서 사용된 데이터셋은 개별 기계 부품들을 모아놓은 것이지만, MechRAG는 기업이나 공장에서 특정 제품이나 생산 라인을 위해 관리하는 데이터베이스와 연계하여 활용될 경우 더욱 큰 효과를 발휘할 것입니다. 제품별 또는 생산

특정 라인에 대한 공정 계획 MRP(자재요구계획) 데이터 및 EBOM(엔지니어링 자재명세서) 데이터와 같은 보다 공학적인 데이터 소스를 CAE 데이터와 통합하여 MechRAG의 입력 자료로 활용할 수 있습니다. 이러한 통합을 통해 보다 포괄적이고 제품 수명 주기 차원의 관점을 확보할 수 있으며, 궁극적으로 더 효율적이고 최적화된 의사결정을 가능하게 합니다. 또한, MechRAG는 MechRAG 사용자, MechRAG의 대화형 인터페이스 및 기반이 되는 기계 공학 소프트웨어 간의 실시간, 반복적, 자동적인 상호작용과 피드백 루프를 갖춘 에이전트형 기계 공학 AI로 확장될 수 있습니다. 이러한 에이전트형 도구는 MechRAG 인터페이스에 대한 질의와 연계하여 형상 수정이나 물리적/생산 공정 시뮬레이션과 같은 현실적인 생산 작업을 효과적으로 수행하고 시작할 수 있습니다.

향후 연구의 또 다른 방향은 산업 현장의 실질적인 적용을 위해 CAE 데이터를 LLM에 통합하는 방식을 최적화하는 것이다. 컨텍스트 창 토큰 제한은 계속 확대될 것으로 예상되지만, 계산 자원 요구량을 최소화하면서 CAE 데이터를 준비하고 표현하는 더 효율적인 방법을 개발하는 것은 여전히 필수적이다. MechRAG의 범위가 확대됨에 따라 전통적인 엔지니어링 과제에 대한 기존 접근 방식과의 벤치마킹이 가능해질 것이므로, 평가 역시 이 분야의 향후 연구에서 중요한 부분이 될 것이다.

데이터 가용성

데이터셋을 공개하는 공개 저장소에서 데이터를 확인할 수 있습니다^{23,36}; 추가 문의 사항은 교신 저자에게 연락해 주시기 바랍니다.

코드 이용

본 연구를 뒷받침하는 모든 코드는 다음의 공개 GitHub 페이지에서 확인할 수 있습니다: <https://github.com/SydneyGit/MechRAG>.

접수일: 2025년 5월 18일; 승인일: 2025년 9월 20일;

Published online: 11 November 2025

참고문헌

- Alam, M. F. 외. 자동화에서 증강으로: 차세대 AI 시대의 엔지니어링 설계 및 제조 재정의. (2024).
- Shafarenko, L., Petrou, M. & Kittler, J. 무작위 질감을 가진 컬러 이미지의 자동 워터세드 분할. *IEEE Trans. Image Process.* 6, 1530–1544 (1997).
- Shi, P., Qi, Q., Qin, Y., Scott, P. J. & Jiang, X. 단일 샷 멀티박스 특징 검출기를 통한 교차 가공 특징의 국소화 및 인식. *IEEE Trans. Ind. Informatics* 17, 3292–3302 (2021).
- Su, H., Maji, S., Kalogerakis, E. & Learned-Miller, E. 3D 형상 인식을 위한 다중 뷰 컨볼루션 신경망. *IEEE 국제 컴퓨터 비전 및 기계 학습 컨퍼런스 (ICCV) 논문집* 945–953 (2015).
- Qi, C. R., Su, H., Mo, K. & Guibas, L. J. PointNet: 3D 분류 및 분할을 위한 점 집합 기반 딥러닝. 『*IEEE 컴퓨터 비전 및 패턴 인식 컨퍼런스*』 논문집 652–660 (2017).
- Li, S. & Corney, J. 3D CAD 모델 분류를 위한 다중 뷰 표현력 있는 그래프 신경망. *Comput. Ind.* 151, 103993 (2023).
- Min, B. 외. 대규모 사전 훈련 언어 모델을 통한 자연어 처리의 최근 발전: 개요. *ACM Comput. Surv.* 56, 1–40 (2024).
- Antol, S. 외. VQA: 시각적 질문 응답. *IEEE 국제 컴퓨터 비전 학회 논문집* 2425–2433쪽 (2015).
- Radford, A. 외. 언어 모델은 비지도 다중 작업 학습자이다 학습자이다. *OpenAI 블로그* 1, 9 (2019).
- Sahoo, P. 외. 대규모 언어 모델의 프롬프트 엔지니어링에 대한 체계적인 조사: 기법과 응용. *arXiv Prepr. arXiv2402.07927* (2024).
- Gao, Y. 외. 대규모 언어 모델을 위한 검색 강화 생성: 개요. *arXiv Prepr. arXiv2312.10997* 2, (2023).
- Siriwardhana, S. 외. 개방형 도메인 질문 응답을 위한 검색 강화 생성(RAG) 모델의 도메인 적응성 개선. *Trans. Assoc. Comput. Linguist.* 11, 1–17 (2023).
- Ranjit, M., Ganapathy, G., Manuel, R. & Ganu, T. OpenAI GPT 모델을 활용한 검색 강화 후보 X선 소견서 생성. *Machine Learning for Healthcare Conference* 650–666 (2023).
- M Bran, A. 외. 화학 도구를 활용한 대규모 언어 모델 강화 도구를 활용한 대규모 언어 모델 강화. *Nat. Mach. Intell.* 6, 525–535 (2024).
- Mon-Williams, R., Li, G., Long, R., Du, W. & Lucas, C. G. 구체화된 대규모 언어 모델을 통해 로봇이 예측 불가능한 환경에서 복잡한 작업을 수행할 수 있게 함. *Nat. Mach. Intell.* <https://doi.org/10.1038/s42256-025-01005-x> (2025).
- Dai, X. 외. VistaRAG: 검색 강화 생성(Retrieval-Augmented Generation)을 통한 안전하고 신뢰할 수 있는 자율 주행 구현. *IEEE Trans. Intell. Veh.* 9, 4579–4582 (2024).
- Wallisch, P. & Sheikh, I. 머신러닝을 학습하는 맞춤형 AI 어시스턴트를 향하여. *Nat. Mach. Intell.* 6, 1413–1414 (2024).
- Kang, B. 외. 롱테일 인식에 대한 표현과 분류기의 분리. *arXiv Prepr. arXiv1910.09217* (2019).
- Long, A. 외. 롱테일 시각 인식을 위한 검색 강화 분류. *IEEE/CVF 컴퓨터 비전 및 패턴 인식 컨퍼런스 논문집* 6959–6969 (2022).
- Yang, Z. 외. Re-vilm: 제로샷 및 소량 데이터 이미지 캡션 생성을 위한 검색 강화 시각 언어 모델. *arXiv Prepr. arXiv2302.04858* (2023).
- Chen, W., Hu, H., Saharia, C. & Cohen, W. W. Re-imagen: 검색 강화 텍스트-이미지 생성기. *arXiv Prepr. arXiv2209.14491* (2022).
- 롬바흐, R., 블라트만, A. & 오머, B. 검색 강화 확산 모델을 활용한 텍스트 유도 예술 이미지 합성. *arXiv Prepr.*, (2022). *arXiv2207.13038*.
- Wu, R., Xiao, C. & Zheng, C. Deepcad: 컴퓨터 지원 설계 모델을 위한 딥 생성 네트워크. *IEEE/CVF 국제 컴퓨터 비전 컨퍼런스 논문집* 6772–6782 (2021).
- Owen, S. J., Carbajal, A. J., Ernst, C. D. 및 Peterson, M. G. “시뮬레이션으로의 신속한 설계를 위한 CAD 부품의 기계 학습 분류 및 축소.” (2024).
- Lambourne, J. G. 외. Brepnet: 솔리드 모델을 위한 위상적 메시지 전달 시스템. *IEEE/CVF 컴퓨터 비전 및 패턴 인식 컨퍼런스 논문집* 12773–12782 (2021).
- Shehab, E. M. & Abdalla, H. S. 혁신적인 제품 개발을 위한 설계 비용 최적화 시스템. *Proc. Inst. Mech. Eng. Part B J. Eng. Manuf.* 216, 999–1019 (2002).
- Kashkoush, M. & ElMaraghy, H. 마스터 조립 순서 구축을 위한 지식 기반 모델. *J. Manuf. Syst.* 34, 43–52 (2015).
- Babic, B., Nesic, N. & Miljkovic, Z. 규칙 기반 패턴 인식을 이용한 자동 형상 인식에 관한 고찰. *Comput. Ind.* 59, 321–337 (2008).
- Xu, T., Li, J. & Chen, Z. MBD 및 공정 의미론을 기반으로 한 자동 가공 특징 인식. *Comput. Ind.* 142, 103736 (2022).
- Eshel, G., Barash, M. & Johnson, W. 축대칭 심압 성형 계획을 위한 규칙 기반 모델링. *J. Mech. Work. Technol.* 14, 1–115 (1986).
- Arezoo, B., Ridgway, K. & Al-Ahmari, A. M. A. 전문가 시스템을 이용한 절삭 공구 및 가공 조건 선정. *Comput. Ind.* 42, 43–58 (2000).
- Zha, X. F., Du, H. J. & Qiu, J. H. 조립 중심 설계를 위한 지식 기반 접근법 및 시스템, 제1부: 접근법. *Eng. Appl. Artif. Intell.* 14, 61–75 (2001).
- Gleadall, A. 외. 하이브리드 제조 플랫폼을 위한 구현 설계 및 공정 체인 선정을 위한 의사결정 지원 방법론. *Int. J. Adv. Manuf. Technol.* 87, 553–569 (2016).
- Paviot, T. <https://github.com/tpaviot/pythonocc-core>.

35. Willis, K. 외. Fusion 360 갤러리: 의 프로그램 기반 CAD 재구성을 위한 데이터셋 및 환경. (2020).
36. Corney, J. & Kwan, J. C. H. 부품의 제조 방법의 자동 인식. (에든버러 대학교, 2021).
37. Koch, S. 외. Abc: 기하학적 딥 러닝을 위한 대규모 CAD 모델 데이터셋. *IEEE/CVF 컴퓨터 설계, 비전 및 패턴 인식 컨퍼런스 논문집* 9601–9611 (2019).
38. Reimers, N. & Gurevych, I. Sentence-BERT: 시아메스 BERT 네트워크를 활용한 문장 임베딩. *2019년 자연어 처리의 경험적 방법 컨퍼런스 및 제9회 국제 자연어 처리 공동 컨퍼런스 (ICNLP) 논문집*, 3982–3992 (2019).
39. Radford, A. 외. 자연어 감독을 통한 전이 가능한 시각 모델 학습. *국제 기계 학습 컨퍼런스. PMLR* 8748–8763 (2021).
40. Kim, W., Son, B. & Kim, I. Vilt: 킨볼루션이나 영역 감독이 없는 비전-언어 트랜스포머. *국제 기계 학습 컨퍼런스* 5583–5594 (2021).

감사의 말

저자들은 에든버러 대학교 재학생인 Jason Chi Hao Kwan, Hanyu Wang, Zhenghao Li에게 감사를 표합니다. 이들은 학위 논문의 일환으로 수행한 데이터 준비 및 초기 단계의 개념 검증을 통해 본 연구에 귀중한 기여를 해주었습니다. 이들의 노력은 본 연구의 기초를 다지는 데 결정적인 역할을 했습니다. 본 연구는 에든버러 대학교 생성형 AI 연구소(GAIL)의 시드 펀딩을 통해 수행되었습니다.

저자 기여도

S.L.은 연구 방법론의 구성, 실행 및 검증을 담당했다. 초안은 S.L.이 작성했다. J.C.는 연구 방법론의 구성과 원고 편집에 기여했다. 문의처: Shuang Li (sli63@ed.ac.uk).

이해 상충

저자들은 이해 상충이 없음을 선언합니다.

추가 정보

보충 정보 온라인 버전에는 <https://doi.org/10.1038/s44172-025-00517-z>에서

확인할 수 있는 보충 자료가 포함되어 있습니다.

문의 및 자료 요청은 Shuang Li에게 보내주시십시오.

심사 정보: 『*Communications Engineering*』은 본 논문의 심사에 기여해 주신 Eric Coatanea 님과 익명의 심사위원분들께 감사를 표합니다. 주 담당 편집자: [Wenjie Wang, Rosamund Daw]. [심사 파일은 여기에서 확인할 수 있습니다].

재인쇄 및 사용 허가 관련 정보는 <http://www.nature.com/reprints>에서 확인하실 수 있습니다.

출판사 공지: Springer Nature는 출판된 지도 및 소속 기관에 대한 관할권 주장과 관련하여 중립적인 입장을 취합니다.

오픈 액세스: 이 글은 크리에이티브 커먼즈 저작자표시 4.0 국제 라이선스(Creative Commons Attribution 4.0 International License)에 따라 배포됩니다. 이 라이선스는 원저작자와 출처를 적절히 표기하고, 크리에이티브 커먼즈 라이선스 링크를 제공하며, 변경 사항이 있을 경우 이를 명시하는 조건 하에 모든 매체나 형식으로의 사용, 공유, 개작, 배포 및 복제를 허용합니다. 본 기사에 포함된 이미지나 기타 제3자 자료는 해당 자료의 출처 표기에 달리 명시되지 않는 한, 기사의 크리에이티브 커먼즈 라이선스에 포함됩니다. 자료가 본 기사의 크리에이티브 커먼즈 라이선스에 포함되지 않았으며, 귀하의 사용 목적이 법적 규정에 의해 허용되지 않거나 허용된 사용 범위를 초과하는 경우, 저작권 소유자로부터 직접 허가를 받아야 합니다. 이 라이선스의 사본을 보려면 <http://creativecommons.org/licenses/by/4.0/>를 방문하십시오.

© 저자(들) 2025