

OG-RAG: 온톨로지 기반 검색 증강 대규모 언어 모델 생성

사전 공개본

카르틱 샤르마, 페유시 쿠마르, 리윤칭
마이크로소프트 리서치
시애틀

2024년 12월 23일

추상적인

본 논문은 도메인 특화 온톨로지에 기반한 검색 프로세스를 통해 LLM(Long Language Model) 기반 검색 증강 생성 방법인 OG-RAG를 제시합니다. LLM은 질의응답 및 검색과 같은 작업에 널리 사용되지만, 산업 워크플로우나 지식 작업과 같은 전문 지식에는 비용이 많이 드는 미세 조정이나 최적화되지 않은 검색 방법 없이는 적응하기 어렵습니다. RAG와 같은 기존의 검색 증강 모델은 개선 효과를 제공하지만, 구조화된 도메인 지식을 고려하지 못하여 최적화되지 않은 컨텍스트 생성을 초래합니다. 온톨로지는 엔티티와 그 상호 관계를 정의하여 도메인 지식을 개념적으로 구성함으로써 이러한 한계를 극복하는 구조화된 표현을 제공합니다. OG-RAG는 도메인 문서의 하이퍼그래프 표현을 구축하며, 각 하이퍼에지는 도메인 특화 온톨로지를 사용하여 기반화된 사실적 지식 클러스터를 캡슐화합니다. 최적화 알고리즘은 LLM에 대해 정확하고 개념적으로 기반화된 컨텍스트를 구성하는 최소한의 하이퍼에지 집합을 검색합니다. 이 방법은 개체 간의 복잡한 관계를 유지하면서 효율적인 정보 검색을 가능하게 합니다. OG-RAG는 사실 기반 추론이 필수적인 영역, 특히 워크플로 또는 의사 결정 단계가 사전 정의된 규칙과 절차를 따라야 하는 작업에 적용됩니다. 여기에는 의료, 법률, 농업 분야의 산업 워크플로뿐만 아니라 뉴스 저널리즘, 탐사 보도, 컨설팅 등과 같은 지식 기반 작업이 포함됩니다. 평가 결과, OG-RAG는 네 가지 LLM(Learning Level Model)에서 정확한 사실의 재현율을 55% 향상시키고 응답 정확도를 40% 개선하는 것으로 나타났습니다. 또한 OG-RAG는 응답을 문맥에 귀속시키는 속도를 30% 향상시키고 기준 방법 대비 사실 기반 추론 정확도를 27% 높입니다.

키워드 검색 증강 생성, 지식 그래프, 사실 추론, 문맥 속성 부여, 온톨로지
근거 기반 검색

1. 서론

대규모 언어 모델(LLM)은 질의응답 시스템, 검색 엔진, 작업 지향형 챗봇의 기능을 향상시켜 왔습니다[Perplexity, 2024, ChatGPT, 2024, Achiam et al., 2023]. 그러나 특히 정확하고 특정 분야에 특화된 데이터에 의존하는 영역에서는 사실 기반 적용에 상당한 어려움이 있습니다[Cascella et al., 2023, Thirunavukarasu et al., 2023, Singhal et al., 2023, Guha et al., 2024, Wang et al., 2024, Balaguer et al., 2024]. 토양 수분과 기상 데이터의 실시간 변화가 관계 결정에 영향을 미쳐야 하는 정밀 농업 시스템을 생각해 보겠습니다. 범용 LLM은 광범위한 지식을 바탕으로 관계 계획을 제안할 수 있지만, 해당 지역의 특정 토양 조건이나 작물 요구 사항을 고려하지 못할 수 있습니다. 이러한 적응성 부족은 LLM의 권장 사항이 부정확해질 수 있음을 의미하며, 이는 과도한 물주기 또는 물 부족으로 이어져 작물에 해를 끼칠 수 있습니다. 이러한 시나리오는 핵심적인 한계를 부각합니다. 즉, 정확성과 전문 지식이 무엇보다 중요한 특정 분야의 의사 결정에 LLM이 안정적으로 적용할 수 없다는 것입니다[Rudin, 2019, Sharma et al., 2020].

이러한 한계를 극복하기 위해 기성 LLM은 특정 도메인에 맞게 미세 조정되거나[Bommasani et al., 2021] 외부 도구 또는 문서와 결합될 수 있습니다[Lewis et al., 2020, Zhuang et al., 2023, Schick et al., 2024].

202412412.15235v1




그림 1: 제안된 OG-RAG와 기존 검색 증강 생성(RAG) 솔루션의 비교.

그러나 미세 조정은 계산 비용이 많이 들고 광범위한 데이터 큐레이션이 필요하기 때문에 실용적인 해결책이 되기 어렵습니다[Balaguer et al., 2024, Ovadia et al., 2023]. 반면, RAG Lewis et al.[2020], Sarthi et al.[2024], Zhang et al.[2024], Borgeaud et al.[2022], Karpukhin et al.[2020], Edge et al. [2024]과 같은 검색 기반 접근 방식은 도메인에 구애받지 않는 임베딩을 사용하여 도메인별 문서에서 질의 관련 정보를 검색하고, 검색된 정보를 바탕으로 답변을 제공합니다. 이러한 방법들은 유망하지만, 정확한 도메인별 검색에 필요한 심층적인 개념적 관계와 미묘한 사실들을 포착하는 데는 한계가 있습니다.

각 분야는 고유한 방식으로 지식과 용어를 구성하며, 이는 다른 분야에 일반화할 수 없습니다[Mernik et al., 2005]. 예를 들어, 산업 워크플로우에서는 사실과 관계가 신중하게 선별되고 도메인별 프레임워크로 구조화되는 반면, 지식 작업 및 조사 연구에서는 온톨로지가 사실과 개념을 구성하고 분석하는 템플릿 역할을 합니다[Jackson, 1990, Guarino et al., 2009]. 현재의 LLM(Learning Language Model)은 이러한 다양한 구조에 적응하는 데 어려움을 겪고 있으며, 이로 인해 전문 분야에서 정확성과 효율성이 제한됩니다. 또 다른 주요 문제는 사용자가 생성된 응답을 관련 맥락으로 추적하는 데 어려움을 겪는 경우가 많다는 것입니다. 더욱이, 많은 전문 분야는 엄격한 절차적 규칙을 따르는데, 현재의 기술로는 이러한 확립된 도메인 지식을 기반으로 정확한 결론을 도출하는 데 한계가 있습니다. 이러한 격차는 전문 워크플로우에서 LLM의 광범위한 적용을 가로막는 주요 과제입니다.

본 논문에서는 도메인별 온톨로지를 통합하여 사실 기반 적응을 가능하게 함으로써 기존 LLM(Learning Language Model)의 한계를 극복하는 OG-RAG(Ontology-Grounded Retrieval Augmented Generation)를 제시합니다. 도메인 내 핵심 엔티티와 그 관계를 정의하는 온톨로지는 복잡하고 끊임없이 변화하는 정보 환경에 적응하는 데 필수적인 구조화된 표현을 제공합니다. 그림 1에서 볼 수 있듯이, OG-RAG는 이러한 온톨로지를 활용하여 구조화된 도메인 지식에 기반한 검색을 통해 LLM 응답을 향상시킵니다. 이를 통해 응답 정확도를 높이고, 유연한 사실 기반 적응을 지원하며, 검증 가능한 컨텍스트 속성을 제공합니다. OG-RAG의 핵심 특징은 도메인 문서의 하이퍼그래프 표현을 사용한다는 점입니다. 이는 기존 검색 방식보다 더욱 정교하고 다면적인 관계 모델링 방식입니다. 하이퍼그래프의 각 하이퍼엣지는 해당 온톨로지를 기반으로 하는 관련 사실 지식의 집합을 나타냅니다. OG-RAG는 탐욕 알고리즘을 사용하여 주어진 쿼리에 대해 LLM에 대한 간결한 컨텍스트를 구성하는 최소한의 하이퍼엣지 집합을 검색합니다. 기존의 검색 방식과 달리, 이 방법은 복잡한 관계와 도메인별 지식을 구조화된 맥락으로 효과적으로 추출하여, 상당한 계산 오버헤드를 추가하지 않고도 맥락을 인식하는 응답을 생성하도록 LLM을 조정합니다.

OG-RAG는 사실 기반 적응이 필수적인 광범위한 영역에 적용됩니다. 여기에는 의료, 법률, 농업 분야의 산업 워크플로우뿐만 아니라 뉴스 저널리즘, 웹 기반 조사 연구, 컨설팅 등과 같은 지식 기반 업무가 포함됩니다. 농업 및 뉴스 영역에서 OG-RAG를 평가한 결과, OG-RAG는 네 가지 LLM(Learning Language Model) 모두에서 정확한 사실의 재현율을 55% 향상시키고 생성된 응답의 전반적인 정확도를 40% 개선하는 것으로 나타났습니다. 사용자 연구에 따르면 OG-RAG가 검색한 맥락에 LLM 응답을 연결하는 작업이 30% 더 빠르고 효율적입니다. 마지막으로, 사실 기반 추론 작업에서 LLM 응답의 정확도가 27% 더 높은 것으로 확인되었습니다.

OG-RAG의 컨텍스트에 사전 정의된 규칙을 적용할 때 다른 방법들에 비해 더 정확한 결과를 얻을 수 있었습니다. 이러한 결과는 OG-RAG가 특수 워크플로우에서 더욱 신뢰할 수 있고 사실에 기반한 답변을 제공하는 데 효과적임을 보여줍니다.

2. 관련 연구

미세 조정. LLM의 한계를 극복하는 한 가지 접근 방식은 도메인 특화 데이터에 대한 미세 조정입니다[Bommasani et al., 2021]. 미세 조정을 통해 모델은 특화된 데이터 세트로 재학습하여 특정 도메인의 미묘한 차이에 적응할 수 있습니다. 그러나 이 방법은 계산 비용이 많이 들고 상당한 자원과 광범위한 데이터 관리가 필요하기 때문에 많은 실제 응용 분야에 적용하기 어렵습니다[Kumar et al., 2022]. OG-RAG는 검색 기반 솔루션을 통해 비용이 많이 드는 미세 조정의 필요성을 없애 이러한 단점을 해결합니다.

오류 완화. LLM은 입력과 관련이 없거나 사실과 다른 출력을 생성하는 오류, 즉 오류를 발생시키기 쉽습니다 [Ji et al., 2023a]. 이러한 오류는 과학 연구나 산업 워크플로우와 같이 정확성이 요구되는 분야에서 특히 문제가 됩니다[Thirunavukarasu et al., 2023]. 기존 시스템은 생성 후 수정 방법 및 사실성 검사를 통해 오류를 완화하려고 시도했지만, 이러한 방법은 종종 추가적인 계산 계층을 필요로 하며 완벽하지 않습니다[Ji et al., 2023b, Madaan et al., 2024, Welleck et al., 2024].

OG-RAG는 데이터 매핑된 온톨로지를 하이퍼그래프로 변환하고 관련 사실 클러스터의 최적화된 검색을 사용하여 환각을 줄이고 LLM 응답이 도메인별 사실에 기반하도록 보장합니다.

검색 방법 기존의 증강 생성(RAG) 방식[Lewis et al., 2020] 외에도 그래프 기반 접근 방식이 제안되었습니다. 이러한 방식에는 GraphRAG[Edge et al., 2024], RAPTOR[Sarathi et al., 2024], 그리고 Langchain[lan] 및 Neo4J[neo]와 같은 지식 그래프 기반 프레임워크가 포함됩니다. 이들은 구조화된 지식 그래프를 활용하여 문맥적으로 관련된 정보를 구성하고 검색함으로써 LLM 성능을 향상시켰습니다.

GraphRAG는 엔티티와 관계를 체계화하여 의미론적 클러스터링에 탁월하며, 복잡한 쿼리를 효율적으로 처리할 수 있도록 합니다. 반면 RAPTOR는 다단계 추상화를 위한 계층적 구조를 사용하여 대규모 문서 전반에 걸쳐 문맥 이해도를 향상시킵니다. 그러나 이러한 접근 방식들은 종종 도메인 전문 지식에 기반하지 않고 엔티티와 도메인별 정보를 임의적으로 추출하는 데 의존합니다. 이로 인해 정확한 구조적 표현을 생성하는 워크플로가 지나치게 복잡해지고 정확도에 상당한 격차가 발생합니다. 또한 문맥 귀속이 약해져 결론을 관련 사실로 추적하기가 더 어려워집니다. 이러한 접근 방식을 개선하여 OG-RAG는 하이퍼엣지 구성을 통해 문맥 귀속을 강화하고 투명성을 높이는 간결한 사실 표현을 제공하며, 하이퍼그래프 검색 메커니즘은 쿼리에 정확하게 맞춰진 최적의 사실 클러스터를 선택합니다.

출처 표기. LLM 응답의 해석 가능성과 신뢰성을 높이기 위해서는 응답 생성 출처를 신뢰할 수 있는 출처로 표기하는 것이 중요합니다. 한 가지 방법은 인용문을 사용하여 텍스트를 생성하는 것이지만, 기존 연구에서는 제로샷 방식[Gao et al., 2023]과 특수 훈련 모델[Khalifa et al., 2024]의 한계를 보여주었습니다. 또한, 인용문 방식은 사용자가 생성된 응답의 주장을 확인하기 위해 전체 페이지를 검색해야 하므로 바람직하지 않습니다. 따라서, 로컬 출처 표기 방식[Slobodkin et al., 2024]과 인간 개입 방식[Kamalloo et al., 2023]과 같은 전략도 제안되었습니다. 이러한 접근 방식들은 문장 수준의 출처 표기를 제공하지만, 해석 가능한 RAG 컨텍스트를 통해 보편적인 이점을 얻을 수 있습니다. OG-RAG는 사용자가 응답 생성 과정을 추적하는 데 최소한의 노력만 필요한, 출처 표기가 용이한 컨텍스트를 제공합니다.

연역적 추론. 전통적인 규칙 기반 추론 시스템은 주어진 입력으로부터 새로운 결론을 도출하는 해석 가능하고 제어하기 쉬운 방법을 제공합니다 [Jackson, 1990, Saparov et al., 2023]. 그러나 이러한 시스템은 LLM과 같은 신경 모델이 가진 유연성과 일반화 능력이 부족합니다. 또한, LLM은 연역적 추론 과정에서 임의적인 착각에 빠지기 쉬운데, 이는 구조화된 워크플로우에서 문제가 될 수 있습니다[Wang et al., 2024, Saparov et al., 2023].

OG-RAG는 비정형 텍스트를 도메인별 어휘에 연결함으로써 사실 기반 추론의 구조적 정확성과 신경망의 유연성을 결합하여, LLM이 여러 도메인에 걸쳐 확장성을 유지하면서 도메인별 규칙을 보다 효과적으로 적용할 수 있도록 합니다.

3. 주요 기여 사항 요약

본 논문은 대규모 언어 모델(LLM)에서 사실 기반 추론 및 환각 감소와 관련된 과제를 해결하는 데 있어 몇 가지 핵심적인 기여를 제시합니다.

- **사실 기반 컨텍스트 검색을 통한 도메인 적응:** OG-RAG는 도메인별 온톨로지를 LLM 검색 프로세스에 통합하는 혁신적인 프레임워크로, 도메인 전반에 걸쳐 정확하고 사실에 기반한 적응을 가능하게 합니다. OG-RAG는 두 가지 핵심 메커니즘을 통해 이를 달성합니다. (a) 데이터 매핑 온톨로지를 하이퍼그래프로 변환하여 사실을 형식화하고, (b) 최적화 기반 하이퍼그래프 검색을 사용하여 도메인별 쿼리와 정확하게 일치하는 간결한 사실 클러스터를 추출함으로써 문맥적으로 더 정확한 응답을 제공합니다.




그림 2: OG-RAG: 온톨로지 기반 검색 증강 생성

- **사실 추론:** OG-RAG는 도메인에 특화된 사실을 활용하여 기존 지식과 관계를 기반으로 결론을 추론함으로써 사실 추론을 가능하게 합니다. 이를 통해 시스템은 정확하고 도메인 특화된 결론을 동적으로 생성하여 복잡한 사실적 맥락에서의 추론 능력을 향상시키고 LLM 응답의 정확도를 높일 수 있습니다.
- **향상된 문맥 정보 제공:** OG-RAG는 정확하고 사실에 기반한 문맥 정보 제공을 통해 응답 검증력을 강화합니다. 이를 통해 사람과 기계 모두 결론을 그 근거가 되는 사실로 정확하게 추적할 수 있으며, 특정 분야 질의에 대한 신뢰할 수 있고 투명한 사실 확인을 보장합니다.

제6절에서는 열거된 각 기여 사항을 뒷받침하는 광범위한 평가를 제시합니다.

4 오그레

온톨로지 기반 검색 증강 생성(OG-RAG)은 도메인별 개념과 그 관계에 대한 형식적 표현인 온톨로지를 검색 프로세스에 통합하는 새로운 프레임워크입니다. 일반적인 임베딩이나 도메인 전문 지식에 기반하지 않은 임의적인 컨텍스트 생성에 의존하는 기존의 검색 증강 생성(RAG) 시스템이나 다른 온톨로지 기반 접근 방식과 달리, OG-RAG는 온톨로지 기반 하이퍼그래프 검색을 활용하여 LLM(Learning Language Model)을 구조화된 지식 기반과 복잡한 도메인별 쿼리에 동적으로 적용합니다. 그림 2는 제안된 방법의 상위 수준 파이프라인을 보여주며, 각 구성 요소는 아래에서 더 자세히 설명합니다.

4.1 하이퍼그래프 구성

첫 번째 단계는 일반적인 도메인별 문서 D 를 주어진 온톨로지 O 에 매핑하고, 사용 가능한 정보를 검색에 유용한 형식으로 변환하는 것입니다.

4.1.1 온톨로지

각 분야는 고유한 워크플로에 맞춰진 특정 규칙과 절차에 따라 의사결정을 내립니다. 예를 들어 농업에서는 작물에 따라 사실 정보를 정리하는 방식이 다릅니다. 작물 재배는 토양 품질, 기상 패턴, 병해충 관리 전략과 같은 사실에 기반하며, 표현형 및 환경 데이터를 바탕으로 일련의 단계를 거쳐 의사결정이 이루어집니다. 반면 농업 예산 책정은 농장 규모나 작물 종류와 같은 동일한 기본 사실을 사용하지만, 재무 모델과 비용 예측을 통해 이를 적용하므로 완전히 다른 의사결정 체계가 필요합니다.

온톨로지는 특정 영역 내의 주요 개체와 그 관계를 형식적으로 표현한 것입니다. 예를 들어, 농업 영역에서는 작물, 토양, 기상 조건과 같은 개체가 정의되고, "이 작물은 특정 지역에서 재배된다" 또는 "토양의 수분 함량은 특정 수준이다"와 같은 관계가 정의됩니다. 온톨로지는 이러한 개체와 관계를 정의함으로써 해당 영역의 지식을 체계적이고 명확하게 구성하는 틀을 제공합니다 [Guarino et al., 2009, Jackson, 1990]. 온톨로지는 계층적일 필요가 없는 개체 간의 더욱 풍부한 관계를 허용한다는 점에서 분류 체계나 분류법과 차이가 있습니다. 좀 더 형식적으로 설명하면,

정의 1 (온톨로지) 온톨로지 $O \subseteq S \times A \times (S \cup \{ \})$ 는 엔티티 집합을 연결하는 세 쌍의 요소로 이루어진 집합입니다. 속성 집합 A 를 사용하는 S 에서 $(s, a, v) \in O$ 는 주체 엔티티 s 가 속성 a 를 가지고 있음을 나타내고, 값 $v := vO(s, a)$ 는 다음 중 하나입니다.

- 다른 개체 $v \in S$, 또는
- 지정되지 않은 도메인 값으로, $\perp$ 로 표시됩니다.

여기서 $v := vO(s, a)$ 는 엔티티 s 의 속성 a 값을 나타내며, 이 엔티티는 온톨로지 내의 다른 엔티티 이거나 정의되지 않은(지정되지 않은) 텍스트 또는 데이터일 수 있습니다.

예를 들어, 주체 엔티티 $s = \text{"작물"}$ 을 생각해 보면, 이 엔티티는 $a_1 = \text{"재배 지역"}$ 이라는 속성을 가질 수 있으며, 이는 다른 객체 엔티티 $vO(s, a_1) = s = \text{"작물 재배 지역"}$ 에 매핑됩니다. 또한, 동일한 엔티티 s 는 $a_2 = \text{"이름이 있음"}$ 이라는 또 다른 속성을 가질 수 있으며, 이는 임의의 텍스트에 매핑됩니다. $vO(s, a_2) = \perp$ 는 이 값이 지정되지 않았으며 도메인 내의 관련 텍스트 또는 이름이라면 무엇이든 될 수 있음을 나타냅니다.

전문 용어와 불명확한 구조로 인해 특정 분야 문서 (D)에서 사실 정보를 추출하는 것은 어렵습니다. 더욱이 관련 사실들이 서로 관련 없는 여러 문서에 흩어져 있는 경우가 많습니다.

온톨로지 O 는 특정 영역 내의 핵심 용어와 그 용어들 간의 관계를 구조화된 방식으로 정리하는 방법을 제공합니다.

이 문제를 해결하기 위해, 우리는 온톨로지에 명시된 관계를 활용하여 문서에서 사실 정보를 추출하는 방법을 제안합니다. 도메인별 사실은 종종 기본 온톨로지에 기반을 두고 있으므로, 이러한 관계를 적용하면 문서에 포함된 정보를 풍부하게 하고 모호성을 해소하는 데 도움이 될 수 있다고 주장합니다. 특히, 문서 자체에서 관련 도메인별 텍스트 또는 값을 추출하여(즉, $vO(s, a) = \perp$ 일 때) 속성 값을 찾습니다. 도메인별 문서는 다양한 사실을 포함할 수 있으므로, 이러한 값 할당은 모든 문서에서 고유할 필요는 없습니다. 오히려 문서의 각 부분은 동일한 온톨로지 엔티티와 관련된 서로 다르지만 유용한 텍스트/데이터 값을 제공할 수 있습니다.

따라서, 우리는 추출된 정보 $I := D(O)$ 를 자체적으로 완결된 사실 블록 집합 $F \in D(O)$ 를 사용하여 모델링합니다. 여기서 각 사실 블록 F 는 온톨로지 엔티티를 지정되지 않은 도메인 텍스트 $\in V$ 또는 동일한 사실 블록 F 내의 다른 엔티티에 매핑하는 관계로 구성됩니다. 보다 공식적으로 표현하면,

정의 2 (온톨로지 매핑 데이터) 온톨로지 매핑 데이터 $I := D(O)$ 는 온톨로지 O 를 사용하여 문서 D 에서 파생된 정보입니다. 이는 사실 블록 집합으로 구성되며, 각 사실 블록 F 는 온톨로지 관계 집합을 나타냅니다. 임의의 관계 $(s, a, v) \in F$ 에 대해 값 v 는 다음과 같이 도출됩니다. 값 $vO(s, a) = \perp$ 이면 $v \in V$ 는 문서 텍스트에서 추출되고, 그렇지 않으면 $v = vO(s, a)$ 는 온톨로지서 제공하는 값입니다.

따라서 온톨로지 매핑 데이터는 도메인별 문서에서 추출된 자체 포함적이고 온톨로지에 기반한 정보를 나타냅니다. 예를 들어, 사실 블록 F 는 다음과 같이 나타낼 수 있습니다. 용어 $s = \text{"싸앗"}$ 은 $a_1 = \text{"작물의"}$ 이고 $v(s, a_1) = \text{"대두"}$ 는 $a_2 = \text{"에서 재배되는"}$ $v(s, a_2) = (s = \text{"작물 재배 지역"})$ 이며, 이는 $a_3 = \text{"이름이 있는"}$ $v(s, a_3) = \text{"북서부 지역"}$ 입니다.

패턴 매칭 휴리스틱, 규칙 기반 전략, 또는 임베딩 유사성 등 다양한 방법을 적용하여 온톨로지 매핑 데이터를 생성할 수 있습니다 [Otero-Cerdeira et al., 2015, Jackson, 1990]. 그러나 LLM(로지스틱 회귀 모델)의 강력한 기능을 활용하여 자연어 이해 능력을 통해 이러한 온톨로지 엔티티를 해당 문서 텍스트에 더욱 효과적으로 매핑할 수 있습니다 [Babaei Giglou et al., 2023]. 본 연구에서는 LLM에 매핑된 정보를 JSON-LD 형식으로 생성하도록 요청하여 이 작업을 수행합니다. 전체 프롬프트는 부록 B.1에 제공됩니다.

이 방법의 한계점 중 하나는 도메인별 온톨로지가 항상 존재하거나 충분히 포괄적이지 않을 수 있다는 점입니다. 이러한 문제를 해결하기 위해, 우리는 견고한 기준 온톨로지를 자동으로 생성할 수 있는 온톨로지 학습 방법을 개발하고 있습니다. 이 방법은 도메인 전문가에게 출발점을 제공하여, 처음부터 온톨로지를 구축하는 대신 기존 온톨로지를 편집하고 개선하는 것을 더 쉽게 만들어 줍니다. 또한, 많은 분야에서 데이터 모델링 및 온톨로지 개발에 대한 수십 년간의 연구 덕분에 이미 풍부한 기존 온톨로지가 존재하며, 이 방법은 이러한 온톨로지를 직접 활용할 수 있습니다. 이 연구에 대한 자세한 내용은 본 논문의 범위를 벗어나므로 생략합니다.

4.1.2 하이퍼그래프 변환

사실 블록 $F \in D(O)$ 의 정의들이 중첩된 구조를 가지고 있기 때문에, 이러한 블록의 정보를 직접 처리하는 것은 어렵습니다. 다중적인 관계와 의존성의 조합적 특성으로 인해 정보를 효율적으로 추출하거나 속성을 부여하기 어렵고, 이는 간결하고 정확한 문맥 속성 부여라는 우리의 목표를 저해합니다. 이러한 문제를 해결하기 위해, 온톨로지에 매핑된 데이터 I 의 각 사실 블록 F 를 평면화된 사실 블록 F 의 집합으로 변환하여 구조를 평면화합니다. 이렇게 하면 세부 정보 손실을 최소화하면서 정보를 더 쉽게 처리할 수 있습니다. 알고리즘 1은 평면화 과정을 설명하며, 그림 2에서도 이를 확인할 수 있습니다.

알고리즘 1 사실 블록 평면화 필요 조건: 사실 블록 F ,

연결 연산자 $\oplus$.

확인 사항: 평면화된 사실 블록 집합 $F \leftarrow \text{FLATTEN}(F)$ 는 F 에 존재하는 중첩된 정보를 평면화합니다. 1: 프로시저 $\text{FLATTEN}(F)$

```

2:  $F \leftarrow \{\}$ 
3:  $F0 \leftarrow \{(s \oplus a, v) : (s, a, v) \in F, v \in V, (s4: F \leftarrow F \cup \{F0\}. \text{for } (s, a, ' , a', s) \in / F\}.$  ▷ 종속성이 없으므로 직접 평면화할 수 있습니다.
 $s') \in F \setminus F0 \text{ do. if } s \in S \text{ then } F_s$ 
5:  $' \leftarrow F0 \cup \{(s \oplus a \oplus s F \leftarrow F \cup$ 
6:  $\text{FLATTEN}(F_s').$ 
7:  $\text{end if end for return } F$  12:  $\text{end } ' \oplus a', v') : (s', v') \in F\}.$ 
8:  $\text{procedure}$  ▷ s의 중첩 구조를 평면화합니다
9:
10:
11:
```

각 평면화된 사실 블록을 하이퍼에지 $e \in E$ 로 정의합니다. 여기서 하이퍼에지 e 는 여러 하이퍼노드 $\{n_i \in N\}$ 를 연결하며, 각 하이퍼노드 $n_i \in F$ 는 평면화된 블록 내의 기본 집합으로 키-값 쌍으로 표현될 수 있습니다. 중요한 것은 이 평면화 과정에서 데이터 손실 없이 정보의 무결성을 유지한다는 점입니다. 이를 통해 OG-RAG는 쌍별 연결만 처리하는 단순한 그래프 기반 모델과 달리 사실 간의 다차원적 관계를 포착할 수 있습니다. 이제 온톨로지에서 추출한 정보를 다음과 같이 정의된 보다 구조화된 하이퍼그래프로 변환할 수 있습니다.

정의 3 (하이퍼그래프) 하이퍼그래프 $H := (N, E)$ 는 하이퍼노드 N 과 하이퍼에지 E 로 구성되며, 각 하이퍼에지 $e \in E$ 는 임의의 길이를 가진 노드들의 집합입니다. X 의 멱집합을 $P(X)$ 로, 집합 X 의 각 원소 내의 문자열들을 연결하여 형성된 집합을 X 로 정의하면, 하이퍼에지 $E \subseteq P(N)$ 및 하이퍼노드 $N \subseteq [P(S \times A)] \times V$ 가 성립하며, 여기서 $\times$ 는 데카르트 곱입니다.

따라서 온톨로지에 매핑된 문서 I 에서 추출된 모든 평면화된 사실 블록의 집합은 하이퍼그래프 $H(I)$ 로 볼 수 있습니다. 이를 간단히 $H(I)$ 라고 부릅니다. 이 정의에 따르면 하이퍼노드는 기본적으로 키-값 쌍이며, 하이퍼에지는 도메인별 데이터에 기반한 참인 사실입니다. 수학적으로는,

정의 4 (사실) 사실이란 두 개체(주체와 객체) 사이의 논리적 명제를 함수적 속성을 통해 나타내는 것으로, 참 또는 거짓으로 검증될 수 있습니다. 형식적으로는 참 또는 거짓 값을 갖는 것으로 검증될 수 있는 논리적 명제로 표현할 수 있습니다. 예를 들어, $\text{hasCropYield}(\text{Farm A}) = 500$ 톤이라는 명제를 생각해 보겠습니다. 여기서 hasCropYield 는 농장(주체)을 작물 수확량(값)에 연결하는 함수적 속성이며, 참 또는 거짓으로 검증될 수 있습니다.

따라서 OG-RAG에서 하이퍼에지는 복잡한 사실의 표현으로 볼 수 있습니다. 일반성을 잃지 않고, 두 개의 하이퍼노드, $n1(s1 \oplus a1, v1) = (\text{작물의 이름은 대두임})$ 과 $n2(p2 \in P(S \times A), v2) = (\text{작물의 생육 구역 이름은 북서쪽임})$ 이 형성하는 하이퍼에지 $e = ((\text{작물의 이름은 대두임}), (\text{작물의 생육 구역 이름은 북서쪽임}))$ 을 단순화된 사실로 표현할 수 있다고 가정해 보겠습니다.

$\text{hasGrowingZone}(\text{작물 이름이 콩인 경우}) = \text{북서부},$

증거를 통해 참인지 거짓인지 확인할 수 있는 것.

이러한 방식으로 OG-RAG 하이퍼그래프 구조는 특정 도메인에 맞춰 사실을 간결하고 정확하게 표현할 수 있도록 합니다. 이 구조는 엔티티 간의 관계와 의존성을 나타내는 하이퍼엠티를 사용자가 확인할 수 있도록 함으로써 사실 검증을 용이하게 합니다.

4.2 하이퍼그래프 기반 검색

도메인별 정보를 기반으로 구축된 하이퍼그래프, 즉 $H(I(D, O))$ 를 통해 OG-RAG는 이제 사용자 쿼리 Q 를 기반으로 관련 컨텍스트를 검색할 준비가 되었으며, 이는 LLM이 정확하고 도메인별 응답을 생성하는 데 도움이 될 수 있습니다.

알고리즘 2 온톨로지 기반 검색 증강 생성

필수 항목: 쿼리 Q, 도메인별 온톨로지 O, 문서 D, 문장 임베딩 함수 Z, LLM M0, Maximum 길이 L

확인 사항: 검색된 컨텍스트 CH(Q)가 온톨로지에 기반을 두고 있으며 쿼리 1과 관련이 있는지 확인합니다.

다. 프로시저 OG-PREPROCESS(O, D, M0)

2: $I \leftarrow \text{LLM } M0(\text{온톨로지 맵}(D, O))$ ▷ 정의 2 참조

$H(I) \leftarrow$ 간선이 3개인 하이퍼그래프: $F \in I$ 평평하게(F).

4: 프로시저 종료 5: 프로

시저 OG-RETRIEVE(Q, H(I), Z, k, L)

6: $N \leftarrow \emptyset$, $E \leftarrow$ 하이퍼그래프 H(I)의 노드와 에지.

7: $NS(Q) \leftarrow \text{top-k arg max}_{(s,a,v) \in N} (Z(s \oplus a), Z(Q))$.

8: $NV(Q) \leftarrow \text{top-k arg max}_{(s,a,v) \in N} (Z(v), Z(Q))$.

9: $N(Q) \leftarrow NS(Q) \cup NV(Q)$.

10: $CH(Q) \leftarrow \emptyset$

11: while $(|N(Q)| > 0) \vee (|CH(Q)| < L)$ do

12: $CH(Q) \leftarrow CH(Q) \cup \text{arg max}_{e \in E} \{|n \in N(Q) : n \in e\}|$

13: $CH(Q)$ 15를 반환

14: 반환하는 동안 종료 : 프

로시저 종료

4.2.1 관련 노드

먼저 주어진 쿼리와 관련된 하이퍼노드 집합을 식별합니다. 정의 3을 사용하면 하이퍼노드 $n \in N$ 은 집합 S, A, V의 요소에서 가져온 키-값 쌍으로 표현 될 수 있습니다. 하이퍼노드는 다음과 같은 경우 쿼리와 관련이 있는 것으로 간주됩니다. (1) 쿼리가 용어 s의 속성 a와 관련되거나, (2) 쿼리가 특정 값 v를 가진 객체에 초점을 맞추는 경우입니다. 즉, 하이퍼노드는 키(연결된 엔티티와 속성을 나타냄)와 쿼리 Q 사이의 유사성이 높거나, v(값)와 쿼리 Q 사이의 유사성이 높으면 관련이 있습니다. OG-RAG는 쿼리와 관련된 하이퍼노드 집합 두 개(NS(Q) 및 NV(Q))를 각각 찾습니다.

특히, NS(Q)는 벡터 공간 Z에서 속성어(즉, $s \oplus a$)와 쿼리 Q 사이의 유사도가 가장 높은 상위 k개의 하이퍼노드를 나타냅니다. 마찬가지로, NV(Q)는 값 v와 쿼리 Q 사이의 유사도가 가장 높은 상위 k개의 하이퍼노드를 나타냅니다. 따라서 각 쿼리에 대해 $2 \cdot k$ 개의 관련 하이퍼노드를 추출합니다.

4.2.2 관련 계층 구조를 맥락으로 활용

관련 컨텍스트는 관련 하이퍼노드 $N(Q) = NS(Q) \cup NV(Q)$ 를 최소한으로 포함하는 하이퍼에지 집합 $CH(Q) \subset E$ 로 구성됩니다. 이는 최적화 문제로 공식화되어 탐욕적 방식으로 해결됩니다. 하이퍼에지 수를 최소화하는 목적 함수는 매트ROID 제약 조건 하에서 선형이므로, 이 해는 최적해임을 증명할 수 있습니다[Korte et al., 2011]. 구체적으로, 각 하이퍼노드 $n \in N$ 을 해당 하이퍼노드가 속한 하이퍼에지 집합 $E(n)$ 에 매핑하는 사전을 유지합니다. 여기서 $e \in E(n)$ 은 $n \in e$ 를 의미합니다. 각 반복에서, 가장 많은 수의 미포함 노드를 포함하는 하이퍼에지를 컨텍스트에 추가하고 해당 노드를 더 이상 고려하지 않습니다. 이 과정은 하이퍼에지가 L개가 되거나 모든 관련 노드가 포함될 때까지 반복됩니다. 이러한 방식으로 컨텍스트는 주어진 쿼리와 관련된 사실을 나타내는 최대 L개의 하이퍼에지 모음으로 구성됩니다. OG-RAG는 정보를 하이퍼에지로 구성함으로써 관련 사실들을 함께 그룹화하여 검색된 컨텍스트가 간결하면서도 포괄적일도록 보장하고, 정확한 LLM 응답을 지원하는 데 필요한 모든 사실을 포착하는 동시에 효율성을 최적화합니다.

4.2.3 검색 증강 생성

마지막으로, 사용자 질의 Q와 위에서 찾은 관련 컨텍스트가 주어지면, LLM M에게 이 컨텍스트를 사용하여 질의에 $M(P(Q, CH(Q)))$ 로 응답하도록 지시합니다. 여기서 P는 해당 텍스트 프롬프트를 나타냅니다.

아래 주어진 맥락을 바탕으로 질문에 대한 답을 생성하세요. 맥락은 사전 형식의 유효한 사실 목록으로 제공됩니다.

컨텍스트: <줄로 구분된 검색된 컨텍스트 CH(Q)> 쿼리: <사용자 질의 쿼리 Q> 응답:

4.3 복잡도 분석

알고리즘 2는 제안된 방법의 전체 절차를 설명하며 이는 두 가지 주요 구성 요소로 이루어져 있습니다. (1) 문서 집합에 한 번 적용되는 OG-PREPROCESS, (2) 각 쿼리 에 대한 관련 컨텍스트를 검색하는 데 사용되는 OG-RETRIEVE.

4.3.1 쿼리 복잡성

LLM M0의 컨텍스트 크기를 NC라고 가정합니다.

JSON-LD 또는 텍스트 형식으로 작성할 수 있는 온톨로지 O는 길이가 $|O|$ 이며, 속성은 자연어 어휘의 해당 범위에 매핑됩니다. OG-PREPROCESS 단계에서는 문서 청크 수에 따라 여러 번의 LLM 호출이 발생할 수 있으며, 구체적으로 호출 횟수는 $(|D| + |O|)/NC$ 입니다. OG-RETRIEVE 절차에서 쿼리하는 동안에는 추가적인 LLM 호출이 발생하지 않습니다.

4.3.2 시간 복잡도

LLM 호출에 소요되는 시간은 쿼리 복잡도에 포함되어 있으므로 시간 복잡도 계산 시 무시합니다. 따라서 OG-PREPROCESS 단계의 시간 복잡도는 매핑된 데이터를 평면화하는 하이퍼그래프 변환에만 관련됩니다. 문서에서 파생된 사실 블록이 $|I|$ 개이고 각 사실 블록의 최대 길이가 $|F|_{\max} = O(|O|)$ 라고 가정해 보겠습니다. 두 가지 경우를 고려합니다. (1) 최소 또는 중첩 없음: 이 경우 시간 복잡도는 알고리즘의 4단계에서 결정되며, 복잡도는 $O(|O||I|)$ 입니다. (2) 최대 중첩: 이 시나리오에서는 4단계에서 빈 집합이 나올 수 있습니다. 따라서 각 사실 블록 F는 전체 집합을 검색하면서 $\log |O|$ 번 재귀적으로 평면화될 수 있으며, 시간 복잡도는 $O(|I||O| \log |O|)$ 가 됩니다.

4.3.3 공간 복잡성

필요한 저장 공간은 하이퍼그래프 구조 $H(I)$ 에 대한 저장 공간뿐이며, 이는 하이퍼에지 수 $|E| = |I|$ 에 직접 비례합니다.

5. 실험 장치 구성

데이터셋. 본 연구에서는 OG-RAG를 두 가지 주요 워크플로우에 걸쳐 평가합니다. (a) 산업 워크플로우: 작물 관리 및 자원 배분에 있어 정확하고 데이터 기반의 의사 결정이 중요한 농업 분야에 초점을 맞춥니다. (b) 지식 작업: 뉴스 분야의 연구 및 분석 작업에서 OG-RAG의 성능을 평가합니다. LLM 학습 과정에서 발생할 수 있는 데이터 오염을 최소화하기 위해 위키피디아와 같은 일반적인 도메인은 제외했습니다. 농업 분야의 경우, 인도에서 재배되는 콩과 밀에 초점을 맞춘 농업 전문가들이 작성한 85개의 문서로 구성된 두 개의 고품질 자체 데이터셋을 활용했습니다. 뉴스 분야의 경우, Multi-hop RAG [Tang and Yang, 2024]에서 공개적으로 제공되는 데이터셋 중, 상세하고 맥락적으로 풍부한 분석이 필요한 다면적이고 복잡한 뉴스 기사 149개(각 2,000단어 이상)를 선별하여 사용했습니다. 데이터셋의 예시 발췌본은 부록 A를 참조하십시오.

온톨로지. 본 연구에서는 OG-RAG의 전문적인 워크플로우에서의 광범위한 적용 가능성을 반영하여 두 영역 모두에 대한 온톨로지를 반자동 방식으로 구축했습니다. 농업 영역의 경우, 자체 개발한 온톨로지 학습 모듈을 사용하여 온톨로지를 생성한 후 작물 재배 전문가 여러 명의 검토 및 검증을 거쳤습니다. 뉴스 영역의 경우, 기존의 Simple News and Press(SNaP) 온톨로지¹를 수정했습니다. 구체적으로, 이미지, 비디오 및 "stuff" 계층 구조와 관련된 클래스들을 제외하여 구조를 단순화했습니다.

대신, 우리는 하나의 자산이 여러 이벤트와 연결될 수 있도록 하고, 각 이벤트는 여러 조직 및 개인과 연결될 수 있도록 합니다. 두 영역에 대한 전체 온톨로지는 부록 B.2에 제공됩니다.

대규모 언어 모델. 본 연구에서는 서로 다른 방법을 통해 얻은 컨텍스트를 추가하면서 제로샷 질의 응답을 위한 4개의 대규모 언어 모델을 고려합니다. 이 중 2개는 클로즈드 박스 모델(Llama-3.1-8B 및 Llama-3.1-70B)입니다. 이 모델들은 자연어에 대한 뛰어난 이해력과 추론 능력² (GPT-4o-mini 및 GPT-4o)와 2개의 오픈 소스 모델³ (Llama-3.1-8B 및 Llama-3.1-70B)를 갖추고 있어 선택되었습니다. 4096개의 완성 토큰과 0의 온도(temperature)를 고려합니다.

기준선. 본 연구에서는 OG-RAG의 효과를 입증하기 위해 문맥 검색 및 생성 분야의 최첨단 접근 방식을 대표하는 세 가지 주요 검색 기반 방법과 OG-RAG를 비교합니다.

¹<https://iptc.org/thirdparty/snap-ontology/>

²<https://openai.com/index>

³<https://ai.meta.com/blog/meta-llama-3-1/>

표 1: 도메인별 질의응답을 위해 다양한 방법으로 검색된 컨텍스트의 품질. 95% 의 정확도를 확인했습니다. 모든 지표에 대한 신뢰구간이 ≤ 0.05 이므로 오차범위가 작습니다. 따라서 여기서는 보고하지 않습니다. 기호 '·'는 계산이 1일 이내에 완료되지 않았음을 나타냅니다.

방법	공					밀					소식				
	C-Rec	C-ERec	A-Corr	A-Sim	A-Rel	C-Rec	C-ERec	A-Corr	A-Sim	A-Rel	C-Rec	C-ERec	A-Corr	A-Sim	A-Rel
RAG 0.22 벡터 0.54	0.08	0.31	0.62	0.29	0.14	0.04	0.29	0.69	0.28	0.01	0.01	0.27	0.67	0.20	
GraphRAG 0.41 OG-RAG	0.19	0.34	0.68	0.68	0.85	0.29	0.59	0.79	0.89	0.82	0.46	0.58	0.84	0.76	
0.84	0.14	0.26	0.63	0.63	0.78	0.05	-	-	-	-	-	-	-	-	
	0.41	0.48	0.72	0.79	0.95	0.34	0.62	0.79	0.79	0.82	0.52	0.66	0.86	0.73	

1. RAG [Lewis et al., 2020]: RAG(Retrieval-Augmented Generation)는 쿼리와 관련된 문서 덩어리를 검색합니다. 그것들을 벡터 공간에 임베딩한 다음, 최대 청크-쿼리 유사도를 기반으로 컨텍스트를 찾습니다.
2. RAPTOR [Sarathi et al., 2024]: RAPTOR는 문서 덩어리를 계층적 구조로 클러스터링하고 LLM을 사용하여 클러스터를 추가적인 맥락으로 요약합니다. 이 실험에서는 트리 깊이를 3 으로 설정 하고 축소된 트리를 사용했습니다. 검색 전략.
3. GraphRAG [Edge et al., 2024]: GraphRAG는 LLM을 사용하여 구축된 지식 그래프에서 엔티티와 관계를 추출하고 이를 의미론적 커뮤니티로 클러스터링하여 정보를 검색합니다. 기본 그래프 구축 방식을 사용합니다. 검색을 위해 커뮤니티 수준을 2로 설정한 프롬프트 및 로컬 검색.

모든 검색 방법에서 문장 임베딩 함수로 `text-embedding-3-small`을 사용하고, GPT-4o를 사용합니다. 전처리를 위해 LLM(즉, M0) 을 사용합니다. 각 방법에 대해 {2, 5} 개의 유사한 컨텍스트를 찾고 그중 가장 유사한 컨텍스트를 선택합니다. 최고의 성능.

측정 지표. RAGAS 프레임워크[RAGAS, 2024]를 기반으로, 우리는 다음과 같은 측정 지표를 사용하여 품질을 평가합니다. 텍스트 임베딩-3-small을 임베딩 모델로, GPT-4o를 사용하여 검색된 컨텍스트와 생성된 응답

법학 석사(LLM) 학위처럼.

1. 맥락 회상률(C-Rec): 정답에 포함된 주장 중 해당 정보에 근거한 것으로 해석될 수 있는 비율 검색된 컨텍스트에 존재합니다.
2. 컨텍스트 엔티티 재현율(C-ERec): 정답에 있는 엔티티 중 검색된 결과에 존재하는 엔티티의 비율 문맥.
3. 답변 유사도(A-Sim): 생성된 답변과 정답 간의 유사도 임베딩 공간.
4. 답변 정확성(A-Corr): 답변 유사성(위에서 정의됨)과 사실 유사성을 결합한 것으로, 실제 답변의 주장과 생성된 답변의 주장 간의 F1 점수.
5. 답변 관련성(A-Rel): 생성된 답변에서 원래 질문을 얼마나 쉽게 추론할 수 있는지를 측정합니다.

윤리적 고려 사항. 본 설문조사는 ACM의 인체 대상 연구 출판 정책을 준수하여 실시되었습니다. 개인 정보는 수집되지 않았으며 모든 응답은 익명 처리되었습니다. 농업 및 뉴스 분야 실험의 경우, 공개적으로 이용 가능한 데이터셋 또는 독점 데이터셋만 사용했으며, 민감한 데이터는 포함하지 않고 윤리적 연구 원칙을 준수했습니다. 표준.

6가지 실험

6.1 질의응답

6.1.1 문제 생성

본 연구에서는 사실적 정확성을 검증하기 위해 RAGAS 프레임워크[RAGAS, 2024]를 사용하여 질문/답변 쌍 세트를 생성합니다. 본 논문에서 제안하는 방법의 핵심은 RAGAS가 기성 LLM을 활용하여 난이도가 다양한 문제를 생성하도록 하는 것입니다. 각 문제는 다음과 같은 특징을 가집니다. 해당되는 정답 및 맥락을 제공합니다. 구체적으로, RAGAS에서 최대 100개의 고유한 질문을 생성합니다. 전문 분야 작업에서 흔히 요구되는 다중 단계 추론 능력에 중점을 둡니다. 이러한 예시는 다음과 같습니다. 생성된 질문과 그에 대한 정답은 부록 C에 제공됩니다.

6.1.2 OG-RAG는 유용한 컨텍스트를 검색하는 데 도움이 됩니까?

컨텍스트가 쿼리에 유용하다고 판단되는 경우는 해당 컨텍스트가 정답을 도출하는 데 필요한 충분한 정보를 제공하는 경우입니다. 컨텍스트 회상률과 컨텍스트 개체 회상률을 사용하여 이를 평가합니다. 표 1은 다양한 검색 알고리즘의 성능을 비교합니다.

표 2: 서로 다른 검색 방법을 사용하는 다양한 LLM이 생성한 답변의 품질. 95%의 정확도를 확인했습니다. 모든 지표에 대한 신뢰구간이 ≤ 0.05 이므로 여기에 보고하지 않습니다. 기호 '-'는 계산이 잘못되었음을 나타냅니다. 하루 안에 완료되지 않았습니다.

방법	콩						밀				소식			
	C-Rec	C-ERec	A-Corr	A-Sim	A-Rel	C-Rec	C-ERec	A-Corr	A-Sim	A-Rel	C-Rec	A-Corr	A-Sim	A-Rel
라마-3-8B														
RAG 0.22 랭커 0.56	0.07		0.26	0.59	0.22	0.14	0.05	0.26	0.65	0.23	0.01	0.01	0.15	0.52
GraphRAG 0.46 OG-RAG	0.20	0.34	0.66	0.59	0.84	0.35	0.54	0.76	0.67	0.82	0.47	0.53	0.74	0.68
0.82	0.11	0.26	0.63	0.52			0.43	0.35	0.27	-	-	-	-	-
	0.40	0.40	0.65	0.60	0.95	0.33	0.54	0.73	0.72	0.81	0.51	0.52	0.76	0.69
라마-3-70B														
RAG 0.24 랭커 0.55	0.06	0.27	0.59	0.19	0.14	0.03	0.26	0.65	0.14	0.01	0.01	0.17	0.58	0.09
GraphRAG OG-RAG 0.84	0.23	0.41	0.70	0.64	0.85	0.39	0.58	0.77	0.75	0.82	0.47	0.39	0.72	0.64
		0.30	0.65	0.55			0.47	0.37	0.29	-	-	-	-	-
	0.41	0.54	0.75	0.56	0.95	0.31	0.63	0.77	0.73	0.70	0.69	0.51	0.77	0.67
GPT-4o-mini														
RAG 0.24 랭커 0.59	0.07	0.29	0.66	0.59	0.14	0.05	0.33	0.73	0.66	0.34	0.80	0.34	0.51	0.85
GraphRAG 0.42 OG-RAG	0.23	0.34	0.68	0.85	0.84	0.36	0.51	0.77	0.85				0.77	0.88
0.83	0.13	0.25	0.63	0.65	0.78	0.05	0.35	0.70		-	-	-	-	-
	0.41	0.48	0.72	0.77	0.95	0.33	0.62	0.78		0.81	0.51	0.62	0.78	0.85
GPT-4o														
RAG 0.22 랭커 0.54	0.08	0.31	0.62	0.29	0.14	0.04	0.29	0.69	0.28	0.01	0.01	0.27	0.67	0.20
GraphRAG 0.41 OG-RAG	0.19	0.34	0.68	0.68	0.85	0.29	0.59	0.79	0.89	0.83	0.46	0.58	0.84	0.76
0.84	0.14	0.26	0.63	0.63	0.82	0.52	0.35	0.70	0.86	-	-	-	-	-
	0.41	0.48	0.72	0.79	0.95	0.34	0.62	0.79	0.79	0.82	0.52	0.66	0.86	0.73

세 가지 데이터셋에 걸쳐 여러 방법을 비교한 결과, OG-RAG는 거의 모든 경우에서 기존 모델보다 우수한 성능을 보였으며, 정답률(recall of correct)을 향상시켰습니다. 주장의 정확도는 55% , 정확한 개체의 재현율은 110%였습니다. 유일한 예외는 OG-RAG가 일치하는 뉴스 데이터 세트입니다. RAPTOR의 컨텍스트 회상 성능과 비교했을 때, 여전히 더 나은 성능을 제공합니다.

6.1.3 OG-RAG는 사실에 부합하는 정확한 답변을 생성하는 데 도움이 됩니까?

유용한 맥락을 다양한 LLM에 대한 질의에 포함시키면 더욱 사실적이고 정확한 답변을 얻을 수 있습니다. 우리는 생성된 응답/답변이 실제 정답과 얼마나 일치하는지를 비교하여 이를 평가합니다. 다양한 LLM 전반에 걸쳐 맥락으로 추가되었습니다. 표 2는 응답의 정확성, 유사성 및 관련성 결과를 제시합니다. 세 가지 데이터셋 모두에서 OG-RAG는 기존 모델들을 일관되게 능가하며 정답률을 40%나 크게 향상시켰습니다. 그리고 답변 관련성은 16% 향상되었습니다. OG-RAG가 약간 저조한 성능을 보이는 유일한 주목할 만한 예외는 답변 부분입니다. GPT-4o 및 Llama-3-70B에서 밀과 대두 데이터 세트의 관련성. 이는 광범위한 적용 범위 때문일 가능성이 높습니다. 검색된 맥락은 때때로 불필요한 정보를 포함할 수 있습니다. 이는 다음과 같은 방법을 통해 완화될 수 있습니다. 하이퍼그래프 검색 메커니즘을 더욱 세밀하게 조정하여 복잡성에 맞게 세부 정보 수준을 조정합니다. 예상되는 쿼리 수입니다. 현재 접근 방식이 이미 좋은 결과를 제공하고 있으므로 도메인별 최적화는 향후 작업으로 남겨둡니다. 모든 데이터 세트에 걸친 응답.

6.1.4 OG-RAG는 효율적인가?

마지막으로, OG-RAG의 전처리 및 쿼리별 처리량을 비교하여 OG-RAG의 계산 효율성을 입증합니다. 다른 데이터셋에서 다른 방법들을 사용했을 때의 검색 시간을 비교한 표 3은 OG-RAG가 거의 비슷한 효율을 보임을 보여줍니다. 간단한 RAG 방식으로, 쿼리 시간이 최대 2 초 정도만 최소한으로 증가하는 것을 확인할 수 있습니다. 사실적 정확도 면에서 최소 100% 이상 우수합니다. OG-RAG는 또한 기존 방식보다 계산 시간이 현저히 짧은 것으로 나타났습니다. 특히 전처리 및 쿼리 단계 모두에서 RAPTOR 및 GraphRAG와 같은 더욱 경쟁력 있는 기준선 특히 전처리 시간이 50% 단축된 것이 가장 큰 장점입니다 . 이러한 효율성은 실시간 애플리케이션에 특히 중요합니다. 농업 모니터링 시스템, 법률 조사, 자동화된 뉴스 사실 확인 등과 같이 신속한 검색과 정보 활용이 중요한 분야에서는 특정 분야에 대한 지식 처리는 필수적입니다.

6.2 문맥 귀속

6.2.1 설문 설계

제안된 방법이 LLM이 생성한 응답 내 사실 검증에 있어 인간에게 얼마나 효과적인 도움을 주는지 평가하기 위해, 우리는 주어진 맥락이 생성된 반응을 뒷받침하는지 여부를 확인하는 데 걸리는 시간을 측정하는 인체 연구를 수행합니다. 농업 데이터셋에서 무작위로 10개의 쿼리를 선택 하고 GPT-4o가 생성한 응답을 두 가지 방법을 모두 사용하여 제시합니다. RAG와 OG-RAG는 각각 해당 컨텍스트와 쌍을 이룹니다. RAPTOR는 내용 유사성 때문에 제외했습니다. RAG와 GraphRAG는 맥락 길이가 너무 길어 사용하기 어렵습니다. 참가자들은 사실적 근거 수준을 평가하도록 요청받습니다.

표 3: 도메인별 질의응답에 대한 다양한 검색 방법의 효율성. Tpre 와 Tquery는 다음을 나타냅니다. 전처리 및 쿼리 시간의 평균값은 초 단위입니다. 편차가 5 초 이내였으므로 보고하지 않았습니다. 여기.

방법	대두 Tpre ↓			밀			소식	
	Tquery ↓ C RAG 11.41 2.49 랩터			Tpre ↓ Tquery ↓ C 10.55 2.36			Tpre ↓	Tquery ↓ C
71.66 4.81 GraphRAG	157.04	5.95	OG-RAG	61.56	4.38	307.37	449.21	3.56
29.61 3.75				5.65	47.76	4.09	1513.57 >1	5.45
							일 655.15	-
								4.12

표 4: 인간이 생성된 응답을 생성된 맥락에 연결하는 용이성 비교
RAG와 OG-RAG는 95% 신뢰구간과 함께 제시되었습니다.

방법	소요 시간 ↓ 지지도 [1-5] ↑	
조각	61.15 ± 28.48	2.67 ± 0.30
OG-RAG	43.50 ± 18.08	3.46 ± 0.19

주어진 맥락에 따라 1부터 5까지의 척도로 응답할 수 있습니다. 또한 각 참가자가 이 과정을 완료하는 데 걸리는 시간도 기록합니다. 과제. 각 참가자에게는 10개의 질문이 제시되는데, 5개의 무작위 질문과 각 질문마다 RAG와 OG-RAG가 모두 짝지어져 있습니다. 응답과 맥락은 무작위 순서로 제시됩니다. 공정성을 보장하기 위해 각 질문은 동일한 횟수로 제시됩니다. 모든 참가자를 대상으로 합니다. 설문 조사 설계 예시는 부록 D에서 확인할 수 있습니다.

6.2.2 결과

본 설문조사에는 LLM에 익숙한 18~34세 참가자 총 16명이 참여했습니다. 표 4는 평균값을 나타냅니다. 소요 시간과 참가자들이 맥락에 부여한 지원 수준을 분석한 결과, OG-RAG가 유의미한 것으로 나타났습니다. 소요 시간을 평균 28.8% 단축하고, 사람에 의한 지원을 평균 29.6% 증가시켰습니다. 이러한 결과는 OG-RAG가 더 빠른 사실 검증을 가능하게 할 뿐만 아니라 더욱 견고하고 명확한 맥락을 제공한다는 것을 입증합니다. 문맥에 따른 사실 파악을 위한 시스템을 더욱 사용자 친화적이고 신뢰할 수 있게 만듭니다.

6.3 사실적 추론

6.3.1 연역적 사실

본 연구에서는 OG-RAG가 LLM에서 연역적 추론 능력을 향상시키는 데 얼마나 효과적인지 평가하기 위해, OG-RAG가 얼마나 새로운 추론을 생성할 수 있는지를 분석합니다. 미리 정의된 사실 집합에 기반한 결론. 도메인별 온톨로지에 근거한 이러한 사실들은 다음을 제공합니다. 다단계 논리가 필요한 추론 작업을 위한 프레임워크입니다. 구체적으로, 이 실험에서는 6가지 농업 관련 데이터를 사용합니다. 문서에 직접적으로 나와 있지 않은 이산화탄소 배출량을 추론하기 위해 여러 가지 사실을 활용했습니다. 이러한 사실들은 부분적으로만 파악했습니다. 화석 연료, 살충제 및 온실가스 간의 관계에 대한 산업계 자료에서 도출되었습니다.

- 1. 북동부 구릉지대의 농지 면적은 1헥타르(ha)입니다.
- 2. 노스 플레인 힐 지역의 농지 면적은 2헥타르(ha)입니다.
- 3. 제초제 생산량은 농지 면적에 권장 제초제량을 곱하여 계산합니다.
- 4. 제초제 1kg 생산 시 18.22~26.63kg의 CO2e가 배출됩니다.
- 5. 살충제 1kg 생산 시 14.79~18.91kg의 CO2e가 배출됩니다.
- 6. 살균제 1kg 생산 시 11.94~29.19kg의 CO2e가 배출됩니다.

6.3.2 질문 생성

평가 테스트 세트를 생성하기 위해 RAGAS 가이드라인[2024]에 따라 GPT-4o를 실행하여 생성했습니다. 추론적 사실과 온톨로지에 매핑된 데이터에서 무작위로 추출된 조각을 적용해야 하는 질문 응답을 생성하기 위해 구체적으로 다음과 같은 프롬프트를 사용합니다.

4본 내용은 <https://www.panna.org/news/linking-fossil-fuels-and-pesticides-to-greenhouse-gases>에서 일부 발췌 및 수정되었습니다.

표 5: 다양한 LLM에서 연역적 추론을 지원하는 능력 측면에서 다양한 검색 방법 비교.

방법	콩			밀		
	A-Corr	A-Sim	A-Rel	A-Corr	A-Sim	A-Rel
GPT-4o-mini						
RAG 0.46 랩터 0.42	0.89	0.66	0.41	0.92	0.64	
GraphRAG 0.44 OG-RAG	0.89	0.81	0.50	0.92	0.74	
0.50	0.91	0.83	0.49	0.93	0.82	
	0.92	0.75	0.53	0.94	0.83	
GPT-4o						
RAG 0.44 랩터 0.01	0.90	0.56	0.42	0.92	0.54	
GraphRAG 0.48 OG-RAG	0.11	0.03	0.41	0.91	0.74	
0.56	0.92	0.84	0.44	0.90	0.73	
	0.92	0.75	0.47	0.94	0.83	

다음 데이터와 일련의 연역 규칙을 이용하여, 추론 능력을 요구하는 어려운 문제를 생성하세요.

데이터에 규칙을 적용하여 답을 도출합니다.

데이터: <도메인별 데이터>

규칙: <고정된 규칙 세트>

질문:

다음으로, 해당 답변을 생성하고 1부터 10까지의 등급을 할당하기 위해 두 번의 추가 LLM 호출을 수행합니다.

질문에 제시된 규칙이 데이터에 적용되어 답을 도출하는 과정을 얼마나 잘 테스트하는지 평가합니다. 10개를 선택합니다.

평점 7점 이상을 받은 질문들입니다. 생성된 질문 전체 목록은 부록 C에 제공됩니다.

6.3.3 결과

표 5는 GPT-4o와 GPT-4o-mini를 사용하여 두 가지 농업 데이터 세트에 걸쳐 사실 추론 결과를 제시합니다.

기본 LLM에서, 두 가지 경우를 제외한 모든 경우에서 OG-RAG 컨텍스트는 정확성, 유사성 및 정확도를 크게 향상시킵니다.

생성된 답변의 관련성을 기준 방법과 비교했습니다. 이는 OG-RAG가 다음과 같은 점에서 더 효과적임을 보여줍니다.

고정된 사실 집합으로부터 연역적 추론을 뒷받침합니다. 단, 답변 관련성 측면에서 대두 데이터 세트는 예외입니다.

이는 OG-RAG가 더 넓은 맥락을 파악했기 때문에 다소 관련성이 떨어지는 답변으로 이어진다는 점을 다시 한번 시사합니다. 전반적으로 이러한 점들은 결과는 OG-RAG가 다른 검색 방법보다 새로운 사실을 추론하는 데 더 견고한 맥락을 제공한다는 것을 확인시켜 줍니다.

7. 결론

본 연구에서는 온톨로지 기반 검색 증강 알고리즘을 사용하여 LLM의 도메인 적응 문제를 연구합니다.

본 논문에서는 쿼리와 관련된 컨텍스트를 검색하는 새로운 하이퍼그래프 기반 검색 방법인 OG-RAG를 소개합니다.

OG-RAG는 도메인별 온톨로지를 사용하여 문서의 사실들을 하이퍼그래프로 구조화함으로써 문서에서 정보를 추출합니다.

의료, 법률, 농업 분야를 비롯한 다양한 산업 워크플로우에 적용 가능합니다.

뉴스 저널리즘, 탐사 보도, 컨설팅 등 지식 기반 업무뿐만 아니라 광범위한 경험을 바탕으로

두 개의 농업 데이터셋과 하나의 뉴스 데이터셋에 대한 실험을 통해 OG-RAG가 성능을 크게 향상시킨다는 것을 입증했습니다.

LLM에서 생성된 응답의 사실적 정확성을 보장하는 동시에 답변을 뒷받침하는 근거를 더 빠르게 파악할 수 있도록 합니다.

맥락을 더 잘 이해하고, 해당 분야의 사실로부터 결론을 더 효과적으로 도출할 수 있도록 해야 합니다. LLM(법학 석사)들이 이러한 더 나은 방법을 갖추도록 권장합니다.

고정된 온톨로지를 통해 통제된 어휘와 구조화된 증거 검색을 통합하면 효율성이 향상될 뿐만 아니라

생성된 응답에 대한 사용자 이해도를 높일 뿐만 아니라 LLM을 산업 워크플로우에 더욱 원활하게 통합할 수 있도록 지원합니다.

지식 노동 분야에서도 마찬가지입니다. OG-RAG는 컨텍스트를 검색하고 활용하는 방식에 있어 더 큰 유연성과 제어력을 제공함으로써 이러한 유연성과 제어력을 제공합니다.

이는 더욱 적응력이 뛰어나고 신뢰할 수 있는 언어 시스템을 위한 길을 열어줍니다. 향후 연구에서는 자동화된 또는

반자동 온톨로지 구축 기술을 사용하여 이러한 프레임워크를 엔드투엔드 방식으로 구축함으로써 다양한 영역에 걸쳐 검색 기능이 강화된 모델의 적용 범위를 넓힐 수 있습니다.

참고 자료

정확도 지시 그래프를 활용한 RAG 기반 구축 강화 — blog.langchain.dev. <https://blog.langchain.dev/enhancing-rag-based-applications-accuracy-by-constructing-and-knowledge-graphs/>.

[접근일: 2024년 10월 14일].

지식 그래프를 사용하여 RAG 애플리케이션 구현하기 — neo4j.com. <https://neo4j.com/developer-blog/knowledge-graph-rag-application/>. [접근일: 2024년 10월 14일].

Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altmenschmidt, Sam Altman, Shyamal Anadkat 등 Gpt-4 기술 보고서. arXiv 사전 인쇄 arXiv:2303.08774, 2023.

Hamed Babaei Giglou, Jennifer D'Souza, and Sören Auer. Llm4ol: 온톨로지 학습을 위한 대규모 언어 모델. 에 수록됨 국제 시맨틱 웹 컨퍼런스, 408–427쪽. 스프링거, 2023.

양형 발라게르, 비남라 베나라, 레나토 루이스 데 프레이타스 쿠냐, 로베르토 드 M 에스테바오 필류, 토드 헨드리, 다니엘 홀스타인, 제니퍼 마스만, 닉 메클렌버그, 사라 말바르, 레오나르도 오 누네스 등 래그 대 미세 조정: 파이프라인, 절충안, 농업에 대한 사례 연구. arXiv 전자 인쇄물, 페이지 arXiv–2401, 2024.

Rishi Bommasani, Drew A Hudson, Ehsan Adeli, Russ Altman, Simran Arora, Sydney von Arx, Michael S Bernstein, Jeannette Bohg, Antoine Bosselut, Emma Brunskill 등 기초 모델의 기회와 위험에 대해. arXiv 사전 인쇄 arXiv:2108.07258, 2021.

Sebastian Borgeaud, Arthur Mensch, Jordan Hoffmann, Trevor Cai, Eliza Rutherford, Katie Millican, George Bm Van Den Driessche, Jean-Baptiste Lespiau, Bogdan Damoc, Aidan Clark 외. 수조 개의 토큰에서 정보를 추출하여 언어 모델을 개선합니다. 국제 기계 학습 학회(International Conference on Machine Learning), 2206–2240쪽. PMLR, 2022.

Marco Cascella, Jonathan Montomoli, Valentina Bellini 및 Elena Bignami. 의료 분야에서 chatgpt의 실현 가능성 평가: 다양한 임상 및 연구 시나리오 분석. 의료 시스템 저널, 47(1):33, 2023.

ChatGPT. <https://chatgpt.com/>, 2024. [2024년 10월 8일 접속].

Darren Edge, Ha Trinh, Newman Cheng, Joshua Bradley, Alex Chao, Apurva Mody, Steven Truitt 및 Jonathan Larson. 로컬에서 글로벌로: 쿼리 중심 요약물 위한 그래프 래그 접근법. arXiv 사전 인쇄본 arXiv:2404.16130, 2024.

Tianyu Gao, Howard Yen, Jiatong Yu, Danqi Chen. 대규모 언어 모델을 사용하여 인용이 포함된 텍스트를 생성할 수 있도록 지원. arXiv 사전 인쇄 arXiv:2305.14627, 2023.

니콜라 구아리노, 다니엘 오버레, 스테펜 스타브. 온톨로지란 무엇입니까? 온톨로지에 관한 핸드북, 2009년 1~17페이지.

Neel Guha, Julian Nyarko, Daniel Ho, Christopher Ré, Adam Chilton, Alex Chohlas-Wood, Austin Peters, Brandon Waldon, Daniel Rockmore, Diego Zambrano 외. Legalbench: 대규모 언어 모델에서 법적 추론을 측정하기 위해 공동으로 구축한 벤치마크. 신경 정보 처리 시스템의 발전, 36, 2024.

피터 잭슨. 전문가 시스템 개론. 애디슨-웨슬리 롱맨 출판사, 1990.

Ziwei Ji, 이나연, Rita Frieske, Tiezheng Yu, Dan Su, Yan Xu, Etsuko Ishii, Ye Jin Bang, Andrea Madotto 및 Pascale Fung. 자연어 생성의 환각에 대한 조사. ACM 컴퓨팅 설문조사, 55(12):1–38, 2023a.

Ziwei Ji, Tiezheng Yu, Yan Xu, Nayeon Lee, Etsuko Ishii, and Pascale Fung. 자기 성찰을 통한 llm 환각 완화에 관하여. EMNLP 2023 전산언어학회 연구 결과집, 1827–1843쪽, 2023b.

Ehsan Kamalloo, Aref Jafari, Xinyu Zhang, Nandan Thakur, and Jimmy Lin. Hagrid: A human-llm collaborative dataset for generative information-seeking with attribution. arXiv preprint arXiv:2307.16883, 2023.

Vladimir Karpukhin, Barlas Oguz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, and Wen-tau Yih. 개방형 도메인 질문 답변을 위한 밀집 문단 검색. arXiv 사전 출판물 arXiv:2004.04906, 2020.

무하마드 칼리파, 데이비드 와든, 엠마 스트루벨, 이홍락, 루 왕, 이즈 벨타기, 하오 펑. 소스 인식 훈련은 언어 모델에서 지식 귀속을 가능하게 합니다. arXiv 사전 출판물 arXiv:2404.01019, 2024.

Bernhard H Korte, Jens Vygen, B Korte 및 J Vygen. 조합 최적화, 1권. Springer, 2011.

Ananya Kumar, Aditi Raghunathan, Robbie Jones, Tengyu Ma, Percy Liang. 미세 조정은 사전 학습된 특징을 왜곡하고 분포 외 데이터셋에서 성능이 저하될 수 있습니다. arXiv 사전 공개 논문 arXiv:2202.10054, 2022.

Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel 외. 지식 집약적 자연어 처리 작업을 위한 검색 증강 생성. 신경 정보 처리 시스템의 발전, 33:9459–9474, 2020.

Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegrefe, Uri Alon, Nouha Dziri, Shrimai Prabhunoye, Yiming Yang 외. Self-refine: 자체 피드백을 통한 반복적 정제. 신경 정보 처리 시스템의 발전, 36, 2024.

마르얀 메르니크, 얀 히어링, 앤서니 M. 슬론. 도메인 특화 언어 개발의 시기와 방법. ACM 컴퓨팅 조사(CSUR), 37(4):316–344, 2005.

로레나 오테로-세르데이라, 프란시스코 J 로드리게스-마르티네즈, 알마 고메스-로드리게스. 온톨로지 매칭: 문헌 리뷰. 응용 전문가 시스템, 42(2):949–971, 2015.

Oded Ovadia, Menachem Brief, Moshik Mishaeli, Oren Elisha. 미세 조정인가 검색인가? llms에서 지식 주입 비교. arXiv 사전 인쇄본 arXiv:2312.05934, 2023.

Perplexity. <https://www.perplexity.ai/>, 2024. [2024년 10월 8일 접속].

RAGAS. <https://docs.ragas.io/en/stable/>, 2024. [2024년 10월 8일 접속].

신시아 루딘. 중요한 결정을 내릴 때 블랙박스 머신러닝 모델을 설명하는 대신 해석 가능한 방법을 사용하세요. 대신 모델을 사용합니다. Nature machine intelligence, 1(5):206–215, 2019.

Abulhair Saparov, Richard Yuanzhe Pang, Vishakh Padmakumar, Nitish Joshi, Mehran Kazemi, Najoung Kim, and He He. 좋은 예제를 사용하여 대규모 언어 모델의 일반 연역 추론 능력 테스트. 신경 정보 처리 시스템의 발전, 36:3083–3105, 2023.

Parth Sarthi, Salman Abdullah, Aditi Tuli, Shubh Khanna, Anna Goldie 및 Christopher D Manning. 랩터: 재귀적 트리 구조 검색을 위한 추상적 처리. arXiv 사전 출판 논문 arXiv:2401.18059, 2024.

Timo Schick, Jane Dwivedi-Yu, Roberto Dessì, Roberta Raileanu, Maria Lomeli, Eric Hambro, Luke Zettlemoyer, Nicola Cancedda, and Thomas Scialom. Toolformer: 언어 모델은 도구 사용법을 스스로 학습할 수 있습니다. 신경 정보 처리 시스템의 발전, 36, 2024.

Abhinav Sharma, Arpit Jain, Prateek Gupta 및 Vinay Chowdary. 정밀도를 위한 기계 학습 애플리케이션 농업: 종합적인 검토. IEEE Access, 9:4843–4873, 2020.

Karan Singhal, Shekoofeh Azizi, Tao Tu, S Sara Mahdavi, Jason Wei, 정형원, Nathan Scales, Ajay Tanwani, Heather Cole-Lewis, Stephen Pfohl 등 대규모 언어 모델은 임상 지식을 인코딩합니다. 자연, 620(7972): 172–180, 2023.

Aviv Slobodkin, Eran Hirsch, Arie Cattan, Tal Schuster 및 Ido Dagan. 먼저 속성을 지정한 후 생성: 로컬로-귀속 가능한 기반 텍스트 생성. arXiv 사전 출판물 arXiv:2403.17104, 2024.

Yixuan Tang 및 Yi Yang. Multihop-rag: 다중 홉 쿼리를 위한 검색 증강 생성 벤치마킹. arXiv 사전 인쇄본 arXiv:2401.15391, 2024.

Arun James Thirunavukarasu, Darren Shu Jeng Ting, Kabilan Elangovan, Laura Gutierrez, Ting Fang Tan 및 Daniel 슈 웨이 텅. 의학 분야의 대규모 언어 모델. 자연 의학, 29(8):1930–1940, 2023.

왕시위안, 웨이중위, 최예진, 런샹. LLM은 규칙으로 추론할 수 있을까? 스트레스 테스트를 위한 논리 구조 그리고 llms를 개선합니다. arXiv 사전 출판물 arXiv:2402.11442, 2024.

Sean Welleck, Amanda Bertsch, Matthew Finlayson, Hailey Schoelkopf, Alex Xie, Graham Neubig, Ilia Kulikov, Zaid Harchaoui. 디코딩에서 메타 생성까지: 대규모 언어 모델을 위한 추론 시간 알고리즘. arXiv 사전 출판물 arXiv:2406.16838, 2024.

Tianjun Zhang, Shishir G Patil, Naman Jain, Sheng Shen, Matei Zaharia, Ion Stoica 및 Joseph E Gonzalez. 뗏목: 도메인별 rag에 언어 모델을 적용합니다. arXiv 사전 인쇄본 arXiv:2403.10131, 2024.

Yuchen Zhuang, Yue Yu, Kuan Wang, Haotian Sun 및 Chao Zhang. Toolqa: LLM 질문 답변을 위한 데이터셋 외부 도구를 사용하여. 신경 정보 처리 시스템의 발전, 36:50117–50143, 2023.

총수

데이터셋 예시

A.1 대두

— 제목: 대두: 소개 6대 주요 대두 생산지의 주별 분류

재배 지역: 콩은 주로 다음 지역에서 재배됩니다. # 콩: 소개 6대 주요 콩 재배 지역으로의 주 분류 : 콩은 주로 다음 지역에서 재배됩니다. ## 경작 • 라비 작물 수확 후 여름에는 깊이 쟁기질을 하는 것이 필수적입니다. 이는 동면 중인 곤충을 고온과 포식성 조류에 노출시키고, 영양분의 이동과 토양 수분 침투를 촉진합니다. 따라서 3~4년에 한 번 씩 깊이 쟁기질을 하거나, 여름에 일반 쟁기질을 한 후 흙덩이를 부수기 위해 2번의 십자형 쟁기질 또는 경운 작업을 하는 것이 콩 재배에 이상적인 종자상을 만드는 데 도움이 됩니다. 또한 4~5년에 한 번씩 10미터 간격으로 심토 경운 작업을 하면 심토의 단단함을 풀어주고 빗물 침투를 촉진하여 가뭄 기간에도 작물 생장이 지속될 수 있도록 도와줍니다.

A.2 밀

기후

밀은 적응력이 뛰어난 작물입니다. 주로 온대 작물이지만 아열대 지역에서 널리 재배되며 일부 열대 국가에서도 재배됩니다. • 밀 종자의 발아에 이상적인 온도는 20~23°C이지만 3.5~35°C 범위에서도 발아 할 수 있습니다. • 이삭이 펴고 꽃이 피는 시기에 지나치게 높거나 낮은 온도, 그리고 가뭄은 밀에 해롭습니다. • 곡물 충실 및 발달 시기의 온도 조건은 수확량에 매우 중요합니다. • 곡물 충실 및 발달 기간 동안 온도가 25°C를 넘으면 곡물 무게가 감소하는 경향이 있습니다. 온도가 높으면 식물의 증산 작용으로 인해 에너지 손실이 과도하게 발생하고, 남은 에너지가 부족해져 곡물 형성이 불완전해지고 수확량이 감소합니다.

A.3 뉴스

레이더스 vs. 라이온스 NFL '먼데이 나이트 풋볼' 경기 실시간 스코어, 업데이트, 하이라이트 **작성자: 댄 트레이시 ** 출처: 스포팅 뉴스 **게시일: 2023년 10월 30일 22:20:03*** 카테고리: 스포츠 **URL: <https://www.sportingnews.com/us/nfl/news/raiders-lions-live-score-highlights-monday-night-football/d022b1d62b18af8a70c516f4> 라이온스는 볼티모어에서 대패한 후 승리가 절실했고, 월요일 밤 홈 팬들 앞에서 그 목표를 달성했습니다.

디트로이트는 레이더스를 26-14로 완승했는데, 경기 내용은 점수 보다 훨씬 일방적이었다.

라이온스는 레이더스를 상대로 329야드나 더 많은 공격 야드를 기록하며 압도적인 경기력을 보여줬지만, 결정적인 실책으로 상대에게 실점을 허용했습니다. 전반전에는 레드존 기회를 독점으로 연결시키지 못했고, 후반전에는 레이더스 진영 깊숙한 곳에서 두 차례의 턴오버(자레드 고프의 픽업스 포함)로 라스베이거스가 추격할 기회를 내줬습니다. 더 보기: 라이언스의 레트로 '호놀룰루 블루' 헬멧에 대해 알아야 할 모든 것

B 온톨로지

B.1 온톨로지 프롬프트

다음은 밑 작물 재배 온톨로지에 대한 컨텍스트 정의입니다.
컨텍스트 정의: {context_definition}

위의 컨텍스트 정의와 다음 데이터를 사용하여 작물 재배 온톨로지에 대한 JSON-LD를 생성합니다.

JSON-LD에서 데이터에 '@graph' 객체 네임스페이스를 사용하세요.

꼼꼼하게 모든 정보를 입력해 주세요.

중첩 구조를 최소화하면서도 의미를 명확하게 구분할 수 있도록 하세요.

'List' 네임스페이스에 여러 하위 필드가 열거되어 있는 경우, 이를 하나의 하위 필드로 결합하지 말고, 모호성을 방지하기 위해 각각 별도의 하위 필드로 유지 하십시오.

'List' 네임스페이스의 모든 항목을 채워 넣고, 누락되는 항목이 없도록 하십시오.

답변에 어떠한 설명이나 사과도 포함하지 마십시오.

응답에 생성된 JSON-LD 외에 다른 텍스트를 추가하지 마십시오.

JSON 형식으로 생성합니다.

데이터:

{데이터}

JSON-LD json:

B.2 예시

그림 3과 4는 본 연구에서 사용된 농업 및 뉴스 온톨로지를 보여줍니다.

C 평가 질문

C.1 대두

질문: 콩 작물에서 이미다클로프리드 48 FS 살충제로 방제할 수 있는 해충은 무엇입니까?

OG-RAG 답변: 콩 작물에서 이미다클로프리드 48 FS 살충제로 방제할 수 있는 해충은 흰점박이꽃뽕입니다.

질문: 영양분 보유 능력이 중간에서 높고 수분 보유 능력이 중간 정도인 토양은 콩 재배에 적합하지 않으므로 피해야 합니다.

RAPTOR 답변: 문맥상 영양분 보유 능력이 중간에서 높고 수분 보유 능력이 중간 정도인 토양을 콩 재배에 피해야 한다는 구체적인 언급은 없습니다.

하지만, 이 지침서는 다양한 토양 유형 관리 방법에 대한 권장 사항을 제시합니다. - 염류 토양(pH

>7.5)에서는 유기질 비료와 함께 석회 150~200kg/ha를 시비해야 합니다. - 산성 토양 (pH <6.5)에서는 석회 600kg/ha를 시비하는 것이 좋습니다.

이 정보를 바탕으로, 콩은 다양한 토양 유형에서 재배할 수 있지만, 염류 토양이나 산성 토양에서는 최적의 성장을 위해 특정 토양 개량이 필요하다는 것을 알 수 있습니다. 따라서 특정 토양 유형을 명시적으로 피해야 한다고 권장할 수는 없지만, 다양한 토양 조건에 맞는 적절한 토양 관리 방법을 적용 해야 합니다.

OG-RAG 답변: 사질토는 양분 보유 능력이 중간에서 높고 수분 보유 능력도 중간 정도이므로 콩 재배에는 적합하지 않습니다.

질문: 발아율이 최소 80% 이상인 종자를 필요로 하고, 꼬투리의 85~90%가 갈색으로 변하고 녹색을 잃었을 때 수확해야 하며, 장기간 보관을 위해 밀폐된 저장 백을 사용하여 서늘하고 건조한 곳에 보관해야 하는 작물의 이름은 무엇입니까?

RAPTOR 답변: 주어진 문맥에는 발아율이 최소 80% 이상이어야 하고, 꼬투리의 85~90%가 갈색으로 변하고 녹색을 잃었을 때 수확해야 하며, 서늘하고 건조한 곳에 밀폐형 저장 백을 사용하여 장기간 보관해야 하는 작물에 대한 언급이 없습니다. 문맥은 특히 콩의 수확, 탈곡 및 저장 방법에 대해 논의하고 있으며, 여기에는 발아율 최소 70%, 꼬투리의 95%가 색이 변했을 때 수확, 그리고 저장 권장 사항이 포함됩니다. 따라서 주어진 문맥에 따르면, 질문에서 설명한 기준에 맞는 작물은 없습니다.

정답: 그 작물의 이름은 대두입니다.

질문: 2016년 1월 1일에 파종 시기가 이른 중부 지역용 콩 작물은 무엇입니까?

RAPTOR 답변: 제공된 정보에는 2016년 1월 1일 조기 파종이 권장되는 중부 지역용 콩 작물에 대한 언급이 없습니다. 중부 지역의 권장 파종 시기는 6월 20일부터 7월 5일까지입니다. 따라서 2016년 1월 1일 파종이 권장되는 중부 지역용 콩 작물은 없습니다.

OG-RAG 답변: 2016년 1월 1일 부터 조기 파종 가능한 중부 지역에 권장되는 콩 품종 은 "JS 20-69"입니다.

질문: 콩 발아에 필요한 온도 범위는 무엇이며, 개화 및 곡물 충실에 필요한 온도와 비교했을 때 어떤 차이가 있습니까?

RAPTOR 답변: 제공된 정보에는 콩의 발아, 개화 또는 곡물 충실에 필요한 정확한 온도 범위가 명시되어 있지 않습니다. 따라서 일반적인 농업 지식을 바탕으로 다음과 같이 답변합니다. 1. **콩 발아**: 콩은 일반적으로 토양 온도가 15°C~30°C(59°F~86°F)일 때 가

장 잘 발아합니다. 최적의 발아 온도는 보통 25°C(77°F) 정도입니다.

2. **개화 및 종자 충실기**: 콩은 개화 및 종자 충실기에 일반적으로 약간 더 높은 온도를 필요로 합니다. 이 단계에 적합한 최적 온도는 일반적으로 20°C~30°C(68°F~86°F)입니다.

섭씨 30도(화씨 86도) 이상의 온도는 이러한 과정에 부정적인 영향을 미칠 수 있으며, 특히 장기간 지속될 경우 더욱 그렇습니다.

요약하자면, 콩의 발아는 약 15°C부터 다양한 온도 범위에서 일어날 수 있지만, 개화와 곡물 충실에 최적의 조건은 일반적으로 이와 비슷하지만 약간 더 높은 온도 범위에 있습니다. 이는 최적의 수확량을 얻기 위해서는 생육 기간 내내 적절한 온도를 유지하는 것이 중요하다는 것을 강조합니다.

OG-RAG 답변: 콩 발아에 필요한 온도 범위는 15~30°C입니다. 개화에는 20~30°C, 곡물 충실에도 20~30°C가 필요합니다. 즉, 발아에 필요한 온도 범위는 개화 및 곡물 충실에 필요한 온도 범위보다 낮은 온도 쪽이 약간 더 넓습니다.

C.2 밀

질문: 밀 수확 시 권장 수분 함량은 얼마이며, 저장 전에 곡물을 어떻게 건조해야 하나요?

OG-RAG 답변: 밀 수확 시 권장 수분 함량은 25%입니다. 저장하기 전에 곡물을 방수포 위에 펼쳐 놓고 햇볕에 말려 수분 함량이 12% 미만이 되도록 해야 합니다.

질문: 식량 생산과 관련하여 밀 종자 발아 시험을 실시하는 이유는 무엇입니까?

OG-RAG 답변: 밀 종자 발아율 검사는 최소 85%의 발아율을 확보하는 데 필수적입니다. 이는 최적의 식물 밀도를 달성하는 데 매우 중요하며, 궁극적으로 수확량에 직접적인 영향을 미칩니다. 종자의 발아 상태를 확인함으로써 농부들은 성공적으로 자랄 가능성이 높은 종자를 파종할 수 있으며, 이는 더 나은 식량 생산과 수확량 증대로 이어집니다.

질문: 북동부 유럽 지역(NEP Zone)에서 밀을 수확하고 저장하기 전에 건조하는 데 권장되는 방법은 무엇입니까?

OG-RAG 답변: 북서부 평원(NEP) 지역에서 밀을 수확하고 저장하기 전에 건조하는 권장 방법은 다음과 같습니다. 1. **수확:** - 곡물의 수분 함량이 25%일 때 수확합니다. - 밀은 완전히 익기 4~5일 전에 수확해야 합니다. - 아침이 수확하기 가장 좋은

은 시간입니다. - 빠른 수확을 위해서는 콤바인 수확기를 사용하여 탈곡 및 쓰러짐으로 인한 손실을 방지하십시오. - 수작업으로 수확하는 경우, 묶음으로 만들어 3~4 일 동안 건조시킨 후 탈곡기로 탈곡하십시오.

2. **건조:** - 보관 전, 곡물을 방수포 위에 펼쳐 햇볕이 잘 드는 곳에 두어 건조시키십시오. - 보관 전 수분 함량이 12% 미만으로 감소되었는지 확인하십시오.

질문: 북부 구릉지대에서 밀을 수확하고 저장하기 전에 건조하는 데 권장되는 방법은 무엇입니까?

OG-RAG 답변: 북부 구릉지대에서 밀을 수확하고 저장하기 전에 건조하는 데 권장되는 방법은 다음과 같습니다.

1. **수확:** - 곡물의 수분 함량이 25%일 때 수확합니다. - 밀은 일반적으로 수작업으로 수확 하지만, 탈곡이나 쓰러짐으로 인한 손실을 줄이기 위해 콤바인 수확기를 사용하여 신속하게 수확할 수 있습니다. - 밀이 완전히 익기 4~5일 전에 수확합니다. - 아침이 수확하기 가장 좋은 시간입니다. - 수작업으로 수확할 경우, 묶음으로 만들어 3~4일 동안 말린 후 탈곡기로 탈곡합니다.

2. **건조:** - 보관하기 전에 곡물을 방수포 위에 펼쳐 놓고 햇볕이 잘 드는 곳에서 건조시켜 수분 함량을 12% 이하로 낮추십시오.

C.3 뉴스

질문: 세련되면서 투명한 이어폰은 어떤 것이 있을까요?

OG-RAG 답변: 스타일리시하고 투명한 이어버드는 "Nothing Ear Stick"입니다.

질문: 11월 1일 넷플릭스에서 '허리케인 시즌'과 함께 공개되는 다른 작품은 무엇인가요?

OG-RAG 답변: 11월 1일 넷플릭스에서 "허리케인 시즌"과 함께 다음과 같은 작품들이 공개됩니다.

- Locked In (넷플릭스 영화) - Mysteries of the Faith (넷플릭스 다큐멘터리) - Nuovo Olimpo (넷플릭스 영화) - Till Murder Do Us Part: Soering vs. Haysom (넷플릭스 다큐멘터리) - Wingwomen (넷플릭스 영화) - 13 Going on 30 - 13 Hours: The Secret Soldiers of Benghazi - 60 Days In: 시즌 5 - The Addams Family - The Big Lebowski - The Change-Up - Desperado - Downsizing - Drag Me to Hell - Love in the Wild: 시즌 1 - Madea's Family Reunion - The Mummy (2017) - Paul Blart: Mall Cop - Paul Blart: Mall Cop 2 - Pitch Perfect - The Scorpion King - Scott Pilgrim vs. the World - Sherlock Gnomes - Six Feet Under: 시즌 1-5 - Sixteen Candles - The Social Network - Ted 2 - Victorious: 시즌 3 - Whiplash

질문: 가격 비교 정책은 대규모 판매 시 고객 이탈을 어떻게 방지합니까?

OG-RAG 답변: 최저가 보장 정책은 고객이 여러 소매점을 돌아다니며 가격을 비교하지 않고도 최적의 가격으로 구매할 수 있도록 보장함으로써 대규모 할인 행사 기간 동안 고객 이탈을 방지하는 데 도움이 됩니다. 베스트바이, 월마트, 델, 아베이, 로우스 같은 소매업체들은 다른 곳에서 더 저렴한 가격을 발견하면 동일한 가격으로 판매함으로써 고객 만족도와 충성도를 높이고 경쟁업체로의 이탈을 막으려 합니다. 이러한 전략은 가격 경쟁이 치열한 블랙프라이데이와 사이버먼데이 같은 주요 할인 행사 기간에 특히 효과적입니다. . 경쟁력 있는 가격을 보장함으로써 소매업체는 기존 고객층을 유지하고 최고의 거래를 찾는 신규 고객을 유치할 수 있습니다 .

질문: 인공지능의 위험성과 창작 계층에 대해 글을 쓴 사람은 누구인가요?

OG-RAG 답변: 다니엘 텐서는 AI의 위험성과 창작 계층에 대해 글을 썼습니다.

질문: 타이판스와의 경기에서 호크스의 결승 버저비터를 넣은 선수는 누구인가요?

OG-RAG 답변: 타이러 하비가 애틀랜타 호크스와 뉴욕 타이판스를 상대로 경기 종료 버저와 함께 결승골을 넣었습니다.

질문: 스티븐 테이가 개발한 어떤 크롬 확장 프로그램이 AI 답변을 공유하는 데 도움이 되나요?

OG-RAG 답변: 스티븐 테이가 개발한 AI 답변 공유를 도와주는 크롬 확장 프로그램은 "ShareGPT"입니다.

질문: 캐피톨 뮤직 그룹에서 미셸 주벨리라의 지휘 아래 성공을 거둔 아티스트는 누구였습니까?

OG-RAG 답변: 미셸 주벨리라가 이끌던 캐피톨 뮤직 그룹에서 성공을 거둔 아티스트로는 아이스 스파이스와 비틀즈가 있습니다.

질문: JLab 이어폰이 EQ 프리셋이 내장된 가성비 좋은 보조 이어폰으로 여겨지는 이유는 무엇인가요?

OG-RAG 답변: JLab 이어폰은 세 가지 EQ 프리셋을 이어폰에 내장하여 뛰어난 가성비를 제공하기 때문에 가격 대비 성능이 우수한 보조 이어폰으로 여겨집니다. 이 기능은 높은 가격 부담 없이 청취 경험을 향상시켜주므로, 주력 무선 이어폰을 대체할 저렴한 대안을 찾는 사람들에게 매력적인 선택입니다.

C.4 사실적 추론

질문: 북동부 평원 지대에 위치한 농장에서 권장되는 제초제를 사용하여 잎말이풀(Phalaris minor)을 방제할 경우, 제초제 생산으로 인한 총 CO₂e 배출량을 계산하십시오. 농장 면적은 1헥타르라고 가정합니다. 주어진 데이터와 규칙에 따라 CO₂e 배출량 범위를 제시하십시오.

OG-RAG 답변: 북동부 평원 지대 에 위치한 농장의 제초제 생산으로 인한 총 CO₂e 배출량을 계산하려면 다음 단계를 따라야 합니다. 1. **권장 제초제 및 사용량 확인:** - 갯쑥부쟁이(Phalaris minor) 방제를 위한 권장 제초제는 클

로디나포프(Clodinafop)입니다. - 권장 사용량은 헥타르당 60g의 활성 성분(ai)입니다.

2. **필요한 제초제 총량 계산:** - 농장 면적이 1헥타르이므로 필요한 총 제초제 양은 60입니다.그램.

3. **그램을 킬로그램으로 변환하기:** - 60그램은 0.06킬로그램과 같습니다.

4. **CO₂e 배출량 계산:** - 제초제 생산으로 인한 CO₂e 배출량은 제초제 1kg당 18.22kg에서 26.63kg 사이입니다. - 제초제 0.06kg에 대한 CO₂e 배출량은 다음과 같이 계산됩니다. - 하한: 0.06kg * 18.22kg CO₂e/kg = 1.0932kg CO₂e - 상한: 0.06kg * 26.63kg CO₂e/kg = 1.5978kg CO₂e 따라서, 해당 농장의 제초제 생산으로 인한 총 CO₂e 배출량은 1.0932kg에서 1.5978kg CO₂e 사이입니다.

질문: 북부 평원 지대에 위치한 농장에서 제초제, 살충제, 살균제 생산으로 인한 총 잠재적 CO₂e 배출량을 계산하십시오. 권장 제초제 사용량은 헥타르당 2kg, 살충제 사용량은 헥타르당 1.5kg, 살균제 사용량은 헥타르당 1kg이라고 가정합니다. 계산에는 평균 CO₂e 값을 사용하십시오.

OG-RAG 답변: 북부 평원 지대에 위치한 농장 의 제초제, 살충제 및 살균제 생산으로 인한 총 잠재적 CO₂e 배출량을 계산하려면 다음 단계를 따라야 합니다.

1. **농지 면적 결정:** 북부 평원 구릉 지대의 농지 면적은 2헥타르입니다.

2. **각 화학물질의 총 사용량을 계산합니다.** - 제초제: 2kg/ha × 2ha = 4kg - 살충제: 1.5kg/ha × 2ha = 3kg - 살균제: 1kg/ha × 2ha = 2kg 3. **각 화학물질의 평균 CO₂e 값을 사용합니다.** - 제초제: 평균 CO₂e = (18.22

+ 26.63) / 2 = 22.425kg CO₂e/kg - 살충제: 평균 CO₂e = (14.79 + 18.91) / 2 = 16.85kg CO₂e/kg - 살균제: 평균 CO₂e = (11.94 + 29.19) / 2 = 20.565kg CO₂e/kg

4. ****각 화학물질 종류별 총 CO2e 배출량을 계산하십시오.**** - 제초제: $4\text{kg} \times 22.425\text{kg CO2e/kg} = 89.7\text{kg CO2e}$ - 살충제: $3\text{kg} \times 16.85\text{kg CO2e/kg} = 50.55\text{kg CO2e}$ - 살균제: $2\text{kg} \times 20.565\text{kg CO2e/kg} = 41.13\text{kg CO2e}$

5. ****총 잠재적 CO2e 배출량을 계산합니다.**** - 총 CO2e = $89.7\text{ kg} + 50.55\text{ kg} + 41.13\text{ kg} = 181.38\text{ kg CO2e}$

따라서 북부 평원 지역 농장의 제초제, 살충제 및 살균제 생산으로 인한 총 잠재적 CO2e 배출량은 181.38kg CO2e입니다.

질문: 북동부 구릉지대에 위치한 농장에서 제초제 생산으로 인한 총 CO2e 배출량을 계산하십시오. 권장 제초제 사용량은 헥타르당 3kg입니다. 제초제 1kg당 CO2e 배출량 범위가 제시되어 있으므로, 최소 및 최대 배출량을 구하십시오.

OG-RAG 답변: 북동부 구릉지대 에 위치한 농장의 제초제 생산으로 인한 총 CO2e 배출량을 계산하려면 다음 단계를 따라야 합니다.

1. ****농지 면적 결정****: 상황에 따라 북동부 구릉지대의 농지 면적은 1 헥타르입니다.

2. ****총 제초제 사용량 계산****: 권장 제초제 사용량은 헥타르당 3kg입니다. 따라서 1헥타르 농장의 경우 총 제초제 사용량은 다음과 같습니다.

$$3\text{kg/ha} \times 1\text{ha} = 3\text{kg}$$

3. ****CO2e 배출량 계산****: 제초제 1kg당 CO2e 배출량은 18.22kg에서 26.63kg 사이입니다 . 따라서 제초제 3kg 사용 시 총 CO2e 배출량은 다음과 같습니다.

- ****최소 배출량****:

$$3\text{kg} \times 18.22\text{kg CO2e/kg} = 54.66\text{kg CO2e}$$

- ****최대 배출량****:

$$3\text{kg} \times 26.63\text{kg CO2e/kg} = 79.89\text{kg CO2e}$$

따라서 북동부 구릉지대에 위치한 농장의 제초제 생산으로 인한 총 CO2e 배출량은 54.66kg에서 79.89kg 사이입니다.

D 설문조사 설계

그림 5는 서론과 하나의 예시 질문을 포함한 설문조사 설계도를 보여줍니다.





그림 3: 농업 온톨로지



(a) 소개 ^{Qualtrics 기반 A}페이지

(b) RAG 컨텍스트 속성

(c) OG-RAG 컨텍스트 속성

그림 5: 설문 조사 설계