

대규모 언어 모델을 활용한 지식 그래프 융합
정확하고 설명 가능한 제조 공정을 위해
계획

대니 호앙
기계, 항공우주 및 제조공학과
코네티컷 대학교
미국 코네티컷주 스토어스

데이비드 고르시치
미국 육군 전투능력개발사령부
지상 차량 시스템 센터
워렌, 미시간, 미국

매튜 P. 카스타니아, 미국 육군 전
투능력개발사령부 지상차량체계센터, 미시간주 워렌, 미국

파르하드 이마니
기계, 항공우주 및 제조공학과
코네티컷 대학교
미국 코네티컷주 스토어스

추상적인

CNC(컴퓨터 수치 제어) 가공에서 정밀한 공정 계획은 공구 선택, 이송 속도 조합, 다축 경로 설정에 있어 신속하고 상황 인식적인 의사 결정을 요구하며, 이는 설계 사양부터 최종 부품 검사에 이르기까지 엔지니어에게 막대한 인지적 및 절차적 부담을 안겨줍니다. 기존의 규칙 기반 컴퓨터 지원 공정 계획 및 지식 공학 프레임워크는 도메인 노하우를 정적 테이블에 고정시켜, 미지의 형상, 새로운 재료 상태, 변화하는 비용-품질-지속가능성 가중치, 또는 공구 부족 및 에너지 제한과 같은 현장 제약 조건에 대응할 때 한계를 드러냅니다. 대규모 언어 모델(LLM)은 G 코드 합성부터 스핀들 부하 질의에 이르기까지 다양한 작업에 대해 유연하고 명령어 중심적인 추론을 제공한다고 하지만, 수치 값을 임의로 생성하고 출처 정보를 제공하지 않는 경우가 많습니다. 본 논문에서는 CNC 공정 계획에 대한 검증 가능하고 수치적으로 정확한 답변을 제공하기 위해 제로샷 지식 그래프(KG) 구성과 검색 증강 생성을 융합하는 엔드투엔드 프레임 워크인 증강 검색 지식 네트워크 강화 검색 및 합성(ARKNESS)을 제시합니다. ARKNESS는 (1) 이기종 가공 문서, 핸드북, G 코드 주석 및 공급업체 데이터시트를 수동 레이블링 없이 증강된 트리플 다중 관계 그래프로 자동 추출하고, (2) 모든 오픈프레임스 LLM을 쿼리에 답변하는 데 필요한 최소한의 증거 연결 하위 그래프를 주입하는 검색기와 결합합니다. 공구 크기 조정, 이송 속도 최적화 및 공차 진단을 아우르는 155개의 업계 전문 질문을 기준으로 벤치마킹한 결과, ARKNESS로 보강된 경량 3B-매개변수 Llama-3는 GPT-4o와 동일한 정확도를 달성하는 동시에 객관식 문항 정확도에서 +25%포인트(pp), F1 점수에서 +22.4pp, 주관식 문항에서 ROUGE-L보다 8.1배 높은 성능을 보였습니다. 또한, 정확한 트리플 기반 추론을 통해 ARK-

*교신 저자: farhad.imani@uconn.edu 배포 고지 A. 공개 배포 승인; 배포 제한 없음. OPSEC9768

2025.12.506.13026v1

NESS는 더 작은 모델이 훨씬 더 큰 클라우드 모델의 정확도와 같거나 그 이상의 정확도를 달성할 수 있도록 지원하며, 수치적 오류를 22%p 감소시키고, 개인 정보 보호를 유지하면서 현장에서 실시간으로 추론할 수 있도록 온프레미스에서 완벽하게 실행됩니다.

키워드: 대규모 언어 모델, 검색 증강 생성, 지식 그래프, 제조 공정 계획

1. 서론

정밀 가공과 같은 현대 생산 공정은 정확도 마진을 요구하며 수치적 오차를 거의 허용하지 않아 초기 설계 사양부터 최종 부품 평가에 이르기까지 엔지니어에게 상당한 정신적, 운영적 부담을 안겨줍니다 [1, 2, 3]. 항공우주 및 에너지와 같은 중요 산업 분야에서는 치수 공차가 일반적으로 $\pm 5 \mu\text{m}$ 까지 엄격해지는 반면, 표면 무결성, 화이트 레이어 두께 및 잔류 응력은 엄격하게 정의된 임계값 내에 유지되어야 합니다[4]. 이러한 기준을 충족하기 위해 기계 가공 작업자는 공구 종류, 이송 속도, 스피들 속도 및 절삭 깊이와 같은 다양한 상호 연관된 공정 변수를 동시에 최적화하고, 사이클 시간과 표면 조도, 공구 마모 및 기하학적 정확도 사이의 균형을 신중하게 맞춰야 합니다 [5, 6, 7]. 따라서 잘못된 소수점 드릴 크기 또는 오래된 절삭 속도 차트는 불량품, 재작업 또는 치명적인 고장 후에야 드러날 수 있는 잠재적 결함으로 직결됩니다 [8]. 이러한 계획되지 않은 다운타임으로 인해 Fortune Global 500 제조업체의 연간 매출이 약 11% 감소하는 것으로 추산되며, 이는 매년 약 1조 5천억 달러의 손실로 이어집니다[9].

주류 컴퓨터 지원 설계(CAD) 제품군(예: Siemens NX, CATIA 및 SolidWorks)에 포함된 컴퓨터 지원 공정 계획(CAPP) 엔진과 컴퓨터 지원 제조(CAM) 모듈은 STEP 호환 제품 모델(AP203/242)을 입력받아 실행 가능한 수치 제어(NC) 결과를 출력하는 자동화 파이프라인을 구성합니다 [10]. 전용 CAPP 시스템은 고수준 분석 루프, 형상 조회, 특징 인식, 우선순위, 제약 조건 해결, 원자재/고정 장치/기계 할당 및 작업 그래프 합성을 실행한 후 이송 속도, 절삭 속도 및 공구 교환 주기를 ISO6983 또는 STEP-NC로 컴파일합니다. 내장형 CAM 모듈은 중간 계층을 세분화합니다. 즉, 공급업체 라이브러리에서 절삭 공구를 선택하고, 매개변수 사전 설정을 적용하고, 충돌 검사 및 재료 제거량 예측을 통해 공구 경로를 생성 및 시뮬레이션하고, 일반적인 각형 형상에 대해 형상 기반 가공 또는 지식 기반 엔지니어링 규칙을 호출합니다. 이러한 규칙 기반 프레임워크는 계획 소요 시간을 2~10배 단축할 수 있지만, 구조적 취약성을 공유합니다. 하드 코딩된 휴리스틱은 이전에 보지 못한 형상(예: 자체 교차하는 자유형 포켓), 새로운 재료 상태, 변화하는 비용-품질-지속 가능성 가중치 또는 공구 사용 불가 및 에너지 제한과 같은 작업 현장 제약 조건에 직면할 때 제대로 작동하지 않습니다. 더욱이, 두 계층 모두 가공 셀에서 생성된 원격 측정 데이터(예: 절삭력, 진동 및 열화상)를 기본적으로 수집하지 않으므로 전문가가 개입하여 문서를 대조하고 매개변수를 수동으로 재조정해야 합니다. 이는 기하학적 복잡성과 처리량 요구 사항이 증가함에 따라 점점 더 감당하기 어려운 병목 현상입니다.

대규모 언어 모델(LLM)은 도메인 지식을 합성하고, 불확실성 하에서 추론하며, 실행 가능한 결과를 생성할 수 있는 다재다능하고 지시를 따르는 에이전트로 등장했습니다 [11]. 최근 연구에서는 LLM이 3축 드릴링 경로를 합성하고, 스피들 부하 및 이송 속도에 대한 상황별 질문에 답변하며, 설명적 작업에서 사람 수준의 정확도로 컨트롤러 경보 문제를 해결할 수 있음을 보여주었습니다 [12]. ket 등은 독립적인 G 코드 생성, 자체 해석 및 오류 단순화 측면에서 GPT-3.5와 GPT-4를 벤치마킹했습니다. GPT-4는 더 정확한 토크스를 생성했지만 여전히 간단한 드릴링 작업에만 국한되었고 광범위한 프롬프트 제어가 필요했습니다 [12]. 코드 합성을 넘어 기능을 확장하기 위해 ChatCNC가 도입되었으며, 여러 LLM 에이전트를 실시간 기계 원격 측정과 결합하여 작업자가 예를 들어 "09:32에 스피들 부하는 얼마였습니까?"라고 질문할 수 있도록 했습니다. 이 시스템은 복잡한 생산 추적 쿼리에서 93.3%의 정확도를 달성했습니다 [13]. 그럼에도 불구하고 두 연구 모두 두 가지 시스템적 병목 현상을 드러냅니다. 첫째, 정확한 사용자 프롬프트 또는 제한적인 구조의 SQL 검색에 대한 의존성, 둘째, 로컬 데이터베이스에 필요한 컨텍스트가 없을 때 성능이 저하되는 현상입니다.

도메인별 미세 조정은 하나의 완화 전략을 제공합니다. Rosati et al.은 산업 사용자 매뉴얼을 사용하여 Llama-3의 ROUGE-1 점수를 0.164에서 0.314로 향상시켰습니다 [14]. CNCGPT는 기계 명령어와 문제 해결 로그를 사용하여 GPT-3.5 Turbo를 미세 조정하여 사실 정확도를 ROUGE-L 0.296에서 0.692로 향상시켰습니다 [15]. 그러나 집중적인 미세 조정은 다음과 같은 새로운 절충점을 제시합니다. (1) 질의-응답 인벤토리가 수천 개로 증가함에 따라 계산 비용이 증가합니다. (2) 빠른 노후화로 인해 잦은 재학습이 필요합니다. (3) 독점 부품 파일이나 생산 지표가 외부 클라우드 API를 통해 전송될 때 데이터 주권 문제가 발생합니다. 따라서 모델을 지속적으로 재학습하거나 민감한 데이터를 노출하지 않고 LLM에 풍부하고 검증 가능한 컨텍스트를 제공하는 보완적인 메커니즘이 필요합니다.

반면 지식 그래프(KG)는 가공 노하우를 유형화된 엔티티(특징, 도구, 작업, 기계)와 관계(예: 도구 필요, 선행, 원인)로 캡처하기 위한 구조화되고 의미론적으로 풍부한 기반을 제공합니다.

[16, 17, 18]. CAPP의 경우, Wang et al.은 특징 가공 KG를 생성하고 전문가 템플릿과 0.8450의 유사도를 갖는 산업적으로 유효한 홀 가공 방식을 선택하는 코사인 유사도 검색을 제안했습니다 [19]. Guo et al.은 조직화했습니다.




그림 1: 동일한 내용을 처리하는 지식 그래프(위)와 대규모 언어 모델(아래)을 비교한 그림
 탭 드릴 크기 조회. 지식 그래프 섹션에서 기술 엔티티(예: 트위스트 드릴, 클리어런스 높이, 탭 드릴)
 질화티타늄, 5축 CNC 밀링 머신, 임펠러 블레이드는 명시적인 관계로 연결되어 있지만 종종 그렇지 않을 수도 있습니다.
 맥락적 연결 고리와 발견되지 않은 사실이 누락되었을 수 있습니다. LLM 섹션에는 모델이 생성한 답변("8mm 드릴")이 표시됩니다.
 "비트"라고 주석을 달아 부정확성 위험, 추적 불가능한 암묵적 지식, 전문 분야의 비효율성을 드러냅니다.
 기계 가공.

기능 토폴로지와 장비 성능에 따른 기존 공정 경로를 분석하여 부품 경로 설정 시간을 50~80분 단축합니다.
 약 15분까지 [20] 소요됩니다. 계획 수립 외에도 KG는 근본 원인 진단에서 90% 이상의 정확도를 달성했습니다.
 센서 데이터가 누락된 경우에도 인과 관계 사슬에 대한 추론을 통해 회전 기계를 작동시킬 수 있습니다 [21]. 이러한 이점에도 불구하고 KG는
 배포는 여전히 힘들고 수동적인 쿼리에 의존합니다. (1) 도메인 전문가는 소스 텍스트에 주석을 달고 트리플을 검증해야 합니다.
 (1) 주기적으로 새로운 기계 가공 지식을 주입합니다. (2) 단순한 주어-술어-목적어 삼중체도 인코딩에 어려움을 겪습니다.
 공차 누적, 고정 장치 제약 조건 또는 미묘한 구성 요소에 대한 공정 체인 논리와 같은 맥락. 예를 들어,
 얇은 벽 형상을 생성하는 데 사용되는 도구 간의 특정 연결은 다음 간의 의존성을 생략할 수 있습니다.
 특정 부품에 필요한 형상 크기 및 특정 공차에 대응하는 최적의 공구 형상.

그림 1은 (1) 추적 가능하지만 독립형 지식 그래프와 대조하여 이러한 한계를 보여줍니다.
 맥락이 부족한 추론은 재질별 여유 공간이나 초과 크기와 같은 중요한 관계가 있을 때 답을 내놓지 못합니다.
 규칙이 없고, (2) 잘못된 8mm 권장 사항을 확신 있게 환각하는 독립형 LLM이 드러납니다.
 출처 인식 및 컨텍스트 적응성을 모두 갖춘 하이브리드 KG 및 LLM 아키텍처의 필요성. 본 연구는
 증강 검색 지식 네트워크 강화 검색 및 합성(ARKNESS)이라는 하이브리드 프레임워크를 소개합니다.
 LLM과 의미론적으로 풍부하고 도메인 특화된 KG를 결합하여 다음과 같은 근거에 기반한 답변을 제공합니다.
 검증된 정보는 가공 공정 계획 질의에 대한 권장 사항이 신뢰할 수 있음을 보장합니다.
 맥락적으로 관련성이 있습니다. 또한, ARKNESS는 이러한 풍부한 하위 그래프에 LLM 프롬프트를 기반함으로써 간결한 방식을 적용할 수 있습니다.
 온프레미스 환경에서 훨씬 더 큰 클라우드 LLM과 동등하거나 그 이상의 정확도를 제공하는 파라미터 모델을 구축하여 컴퓨팅 비용을 대폭 절감합니다.
 배포 오버헤드. 이 논문의 주요 이점은 다음과 같습니다.

1. 모델에 구매되지 않는, 지식 기반(KG)으로 강화된 CAPP 보조 도구. 검색 기능이 강화된 생성 파이프라인을 제시합니다.
 이는 대규모 언어 모델을 다중 관계형 기계 학습 지식 그래프와 결합하는 것입니다. 그래프 인식
 프롬프트 컴파일러는 출처 링크 트리플을 컨텍스트 창에 삽입하여 수치적으로 정확한 결과를 생성합니다.
 설명 가능한 프로세스 계획 답변.

2. 기술 코퍼스를 이용한 자체 지도형 지식 알고리즘(KG) 종류. 제조 샷 방식의 GPT 기반 엔티티-관계 추출기는 다양한 가공 문서(예: PDF 매뉴얼, 사양서, NC 코드 주석)를 문맥에 맞는 트리플로 변환하여, 기존 CAPP 기반 KG의 한계였던 수동 큐레이션 병목 현상을 해소합니다.

3. 경량 온프레미스 환각 억제. 155개 쿼리 벤치마크에서 ARKNESS는 더 작은 LLM 모델과 결합하여 훨씬 더 큰 클라우드 LLM과 동등하거나 그 이상의 성능을 보이면서 환각을 줄여 실시간 현장 배포를 위한 개인정보 보호 방식을 제시합니다.

본 논문의 나머지 부분은 다음과 같습니다. 2절에서는 제조 계획 맥락에서 관련 지식 그래프 및 대규모 언어 모델링 연구를 제시하고, 3절에서는 검색 및 답변을 위한 자동 그래프 생성 도구인 ARKNESS의 구현을 설명합니다. 4절에서는 실험 설정을 설명하고, 5절에서는 실험 결과를 제시하며, 6절에서는 결론을 제시합니다.

2. 연구 배경

2.1 머신러닝에서의 대규모 언어 모델

LLM(언어 학습 모델)은 자유 형식의 지시사항을 분석하고, 이질적인 맥락을 융합하며, 실행 가능한 도메인별 지침을 제공하는 능력 덕분에 연구 대상에서 AI 기반 생산의 핵심 동력으로 빠르게 전환하고 있습니다.

Li et al.의 최근 조사에서는 LLM이 제조 스택에 초기부터 널리 적용되어 왔으며, 생성형 CAD 모델링, 생물 공정 레시피 설계, 로봇 경로 계획, 비전 기반 품질 관리 등 다양한 분야에 활용되고 있다고 밝혔습니다 [22]. 절삭 가공 분야에서 가장 직접적인 응용 분야는 자연어를 G 코드로 변환하는 것입니다. ket et al.은 상용 ChatGPT 모델을 사용하여 3축 G 코드 생성을 평가했는데, GPT-3.5와 GPT-4를 독립적인 G 코드 생성, 생성된 G 코드 해석, 오류 감지 및 단순화의 세 단계로 테스트했습니다 [12]. 연구 결과, GPT-4가 더 정확한 톨패스를 생성하는 등 LLM을 G 코드 생성에 적용할 가능성이 있음을 보여주었지만, 드릴링과 같은 간단한 작업에만 적용 가능하다는 한계가 있었습니다. 또한, LLM 생성을 위해 사용자 입력에 크게 의존하는 방식이기 때문에 제조 환경에 적용할 경우 가동 중지 시간이 증가할 수 있습니다. Jeon et al.은 G 코드 생성을 넘어 다양한 LLM 에이전트를 실시간 CNC 가공 데이터와 통합한 ChatCNC를 개발했습니다 [13]. 이 방법을 통해 사용자는 특정 시점이나 상황에서의 스피들 부하와 같은 3축 CNC 기계의 상태에 대한 상황 인식 정보를 얻을 수 있었습니다. 이 방법은 생산 추적과 같이 복잡한 데이터 추론이 필요한 쿼리에서 93.3%의 정확도를 달성하여 제조 공정에서 기록된 데이터를 분석하는 데 활용될 수 있음을 보여주었습니다. 높은 정확도에도 불구하고, 저자들은 컨텍스트 정보가 부족하거나 데이터베이스에서 정보를 검색할 수 없는 경우 모델이 오류를 발생시킨다는 점을 인정했습니다. 이는 기존의 SQL 데이터베이스 구조와 같은 일반적인 검색 방법을 넘어서는 보다 심층적인 탐색이 기존 지식 격차를 해소하는 데 필요함을 시사합니다.

연구자들은 프롬프트 및 전통적인 검색 기법 외에도, LLM의 응답을 특정 분야 지식에 더 잘 맞추기 위해 도메인별 미세 조정 기법을 도입했습니다. Rosati 등은 360도 카메라 사용자 설명서를 학습 데이터로 사용하여 Llama 3를 산업 응용 분야에 맞게 미세 조정함으로써 평균 ROUGE-1 F1 점수를 0.164에서 0.314로 향상시켰습니다 [14]. Wang 등은 항공기 정비에 맞게 GPT-3.5를 미세 조정하여 일반 GPT-3.5 및 업그레이드 버전인 GPT-4.0 보다 우수한 성능을 달성했습니다 [23]. 기계 가공 분야에서는 Soundararajan 등이 기계별 데이터, 작동 지침 및 문제 해결 주장을 기반으로 GPT-3.5 Turbo를 미세 조정하여 현장 CNC 작업자 지원을 위한 CNCPT를 개발했습니다 [15]. 미세 조정 전후의 ROGUE-L 점수가 각각 0.296에서 0.692로 증가한 것으로 나타났습니다. 그들의 방법론이 타당함에도 불구하고, 공장 현장에 적용하는 데에는 몇 가지 어려움이 있을 수 있습니다. 그중 하나는 필요한 자원과 학습 시간입니다. 저자들은 약 30개의 질의-응답 예제만으로 학습을 진행했기 때문입니다. 실제 환경에서는 수백에서 수천 개의 시나리오와 응답이 존재할 수 있으므로, 학습 과정에서 확장성이 크게 제한될 수 있습니다.

더욱이, 새로운 시나리오가 지속적으로 등장함에 따라 시스템을 최신 상태로 유지하기 위해 빈번하게 재학습해야 하므로 컴퓨팅 자원에 부담이 가중되고 유지 관리가 복잡해집니다. 생산 공정 및 그 안에 포함된 정보와 관련된 보안 문제도 존재합니다. 저자들은 외부 클라우드 기반 플랫폼에서 작동하는 상용 LLM을 사용했는데, 데이터 흐름 및 저장 방식에서 데이터 개인정보 보호 및 지적 재산권 보호에 대한 우려가 제기될 수 있습니다. 이러한 타사 시스템에 대한 의존은 무단 접근이나 데이터 유출 위험을 증가시키므로, 독점적인 제조 데이터가 엄격하게 기밀로 유지되도록 온프레미스 솔루션을 구현하는 것이 필수적입니다.

2.2 가공 분야에서의 지식 그래프

구조화된 방식으로 가공 지식을 재사용하고 구현하는 능력은 계획 및 의사 결정 전반에 걸쳐 일관성을 향상시킬 뿐만 아니라 기존의 지식 격차를 완화하는 데에도 도움이 됩니다. Xiao et al.은 이를 검토했습니다.

지식 그래프를 활용한 컴퓨터 지원 공정 계획이 노동 비용 절감, 생산 주기 단축, 기존 정보의 보다 지능적인 활용을 통해 어떻게 이점을 얻을 수 있는지에 대한 연구가 진행되었다 [16]. 저자들은 공정 지식 표현에서 공정 지식 그래프 구축 및 검증에 이르기까지 지식 그래프 구현의 핵심 단계를 분석하여, 이러한 방법들이 과도한 수동 개입을 줄이고 유연성과 일반화 능력을 향상시켜 기존 CAPP를 어떻게 극복할 수 있는지 보여주었다. 이러한 공정 지식 구현은 Wang et al. 이 특징 기반 가공을 위한 공정 지식 그래프를 구축하여 가공 계획 선택을 자동화한 사례에서 확인할 수 있다 [19].

개선된 코사인 유사도 공식을 사용하여 가공 계획 선택을 수행함으로써, 6개의 구멍으로 구성된 일반적인 쉘 부품에 대해 산업계에서 구현된 기존의 성숙한 계획과 매우 유사한 0.8450의 유사도 점수를 달성했습니다. Wang et al.은 자신들의 방법을 사용하여 권장되는 가공 단계가 공구 부하를 줄이고 부품 품질과 가공 안전성을 모두 향상시킬 수 있다고 주장했습니다. 유사한 연구에서 Guo et al.은 부품 특징 토폴로지와 기계 기능을 사용하여 과거 공정 계획을 구성함으로써 공정 경로 재사용을 위한 지식 그래프를 생성했습니다 [20].

새로운 부품을 도입할 때, 저자들은 기존 공정 경로와의 유사성 검사를 통해 해당 부품의 형상 토폴로지에 가장 잘 맞는 공정 경로를 결정합니다. 샤프트 부품에 대한 사례 연구를 통해 전체 가공 공정 경로를 약 15분 만에 완료할 수 있었는데, 이는 일반적인 50~80분에서 크게 단축된 시간으로 효율성을 향상시켰습니다.

가공 지식 그래프의 또 다른 주요 응용 분야는 CNC 장비의 고장 진단 및 유지 보수입니다.

제조 시스템은 센서, 로그, 유지보수 보고서 등 다양한 소스에서 이기종 데이터를 생성하는데, 이러한 데이터가 서로 분리되거나 사일로 형태로 존재할 경우 문제 발생 시 진단이 어려울 수 있습니다. 지식 그래프는 물리적 구성 요소, 신호, 고장 모드를 원인-결과 및 부분-전체 관계의 네트워크로 연결하여 통합적인 표현을 제공합니다.

Qiu 등은 센서 데이터와 도메인 지식을 통합한 다층 지식 그래프를 구축하여 "데이터 섬" 문제를 해결했습니다. 이를 통해 수직 밀링 공구(모델 XHK-5140)의 X축 볼 스크류 구동 시스템에서 201일 동안의 상태 변화를 자동으로 식별할 수 있었으며, 그래프에 대한 유사성 기반 추론을 통해 정상 기준선과의 편차를 정량화했습니다 [24]. 이 아이디어를 바탕으로 Cai 등은 하위 시스템 상태에 대한 계층적 지식과 베이저안 추론을 결합한 회전 기계용 다단계 고장 진단 지식 그래프(KG)를 도입하여 그래프 전반에 걸친 확률적 추론을 통해 근본 원인을 찾아냈습니다 [21]. 특히, 센서 출력이 누락된 경우에도 관련 증상 간의 관계를 활용하여 91.1%의 진단 정확도를 달성했으며, 기존 규칙 기반 고장 진단보다 우수한 성능을 보였습니다.

지식 그래프 구현에 상당한 진전이 있었음에도 불구하고, 가공 및 산업 분야에서 대규모로 이를 적용하는 데에는 여전히 어려움이 있습니다. 앞서 언급한 방법들은 여전히 광범위한 수동 큐레이션에 크게 의존하고 있습니다. 도메인 지식을 추출, 검증 및 지속적으로 업데이트하는 과정에는 상당한 인적 지식과 개입이 필요하므로, 신속한 확장이나 새로운 정보에 대한 빠른 적응이 어렵습니다. 이러한 노동 집약적인 접근 방식은 불일치나 누락의 위험을 증가시킬 뿐만 아니라, 역동적인 제조 환경에서 실시간 대응력을 저해합니다. 더욱이, 기존의 단순한 트리플 기반 표현 방식은 가공 공정에서 미묘한 의사 결정을 위해 필요한 풍부한 맥락적 정보를 온전히 포착하는 데 한계를 보입니다. 이러한 표현 방식은 복잡한 제조 작업의 근간이 되는 세부적인 상황, 근거, 그리고 복잡한 관계를 제대로 담아내지 못하는 경우가 많습니다. 결과적으로, 다양한 가공 작업 간의 상호 관계나 특정 공정 선택의 이유를 충분히 표현하지 못할 수 있습니다. 이는 근본적인 메커니즘과 공정 의존성에 대한 피상적인 이해로 이어질 수 있습니다. 이러한 한계는 현대 기계 가공 응용 분야의 진화하는 요구 사항을 지원하기 위해 지식 표현에 있어 더욱 유연하고 풍부한 맥락을 고려한 접근 방식이 필요함을 강조합니다.

3. 연구 방법론

이 섹션에서는 ARKNESS 프레임워크의 두 가지 주요 구성 요소인 1) 지식 그래프 구축과 2) 그래프 탐색, 검색 및 LLM 응답에 대해 자세히 설명합니다. 그림 2는 이 두 구성 요소에 대한 전반적인 개요를 제공합니다.

3.1 지식 그래프

지식 그래프는 튜플 집합 $G = \{(v, r, w)\}$ 로 간주할 수 있습니다. 여기서 v 와 w 는 정점 집합 V 의 정점(개체)이고, r 은 관계 집합 R 의 간선(관계)입니다. 이러한 튜플 집합은 일반적으로 (헤드, 관계, 테일)로 표시되는 트리플로 알려져 있으며, 각각 v , r , w 를 나타냅니다.

3.2 자동 그래프 생성

ARKNESS의 지식 그래프 구축은 주로 사용자가 선택한 도메인과 관련된 문서의 텍스트 데이터를 사용하여 이루어집니다. 문서 유형과 파일 형식(예: .docx, .pdf, .pptx)이 매우 다양하기 때문에, 먼저 이러한 여러 소스에서 텍스트 정보를 추출하기 위한 전처리 작업을 수행했습니다. 이 작업은 다음과 같은 방법을 통해 이루어졌습니다.




그림 2: 대규모 언어 모델에 지식 그래프를 통합한 프레임워크 개요. 그래프 생성 및 저장부터 의미 검색, 매칭 및 검색, 그리고 최종적으로 언어 모델의 응답에 이르는 과정을 보여준다.

문서를 효율적으로 구문 분석하고 원시 텍스트를 추출한 다음 추가 처리를 위해 콘텐츠를 Markdown 파일로 내보내는 Docling [25] Python 패키지입니다.

문서 분할은 각 단락을 개별적으로 파싱하는 방식으로 수행되었습니다. p 개의 단락 으로 구성된 문서가 주어졌을 때 , 각 단락은 LLM(로지스틱 회귀 모델)에 입력되어 T개의 트리플을 형성하는 엔티티와 관계를 추출합니다. LLM이 아래와 같은 구조화된 정보를 출력하도록 구체적인 지침이 제공되었습니다.

-목표-

입력 텍스트에서 다음 형식의 구조화된 트리플을 직접 추출합니다.

엔티티_1, 관계 유형, 엔티티_2, 관계 설명

-단계- 1.

입력 텍스트를 주의 깊게 읽고 다음을 파악합니다. - 핵심 요소: 텍스트의 중심이 되는 개념, 시스템, 기술 또는 프로세스.

- 관계: 텍스트에 명확하게 설명된, 두 개체를 연결하는 행동 또는 연결 관계.

- 설명: 본문에서 발제하거나 의역하여 관계를 설명하는 내용.

2. 각 관계에 대해 세 가지 요소로 이루어진 트리 구조를 만드세요.

- ENTITY_1: 관계를 시작하는 주요 개념 또는 개체입니다.

- RELATIONSHIP_TYPE: 본문에 설명된 작업 또는 연결 유형입니다.

- ENTITY_2: ENTITY_1의 영향을 받는 대상 개념 또는 엔티티.

- 관계 설명: 직접 가져온 관계에 대한 간결한 설명

입력 텍스트에서.

3. 각 트리플은 명확해야 하며 다음 형식이어야 합니다: ENTITY_1, RELATIONSHIP_TYPE, ENTITY_2, "RELATIONSHIP_DESCRIPTION"

4. 가능한 한 원문을 그대로 사용하여 설명을 작성하고 정확성을 확보하십시오.

외부의 해석이나 설명을 덧붙이지 마십시오.

선택된 각 문서에 대해 이 과정을 반복하여 GD 서브그래프를 생성했습니다. 트리플릿 정보에 '관계 설명'을 포함하는 목적은 트리플릿이 생성된 관련 맥락 정보를 유지하기 위함입니다.

이를 통해 기존 지식 그래프에서 흔히 발견되는 모호성과 정보 누락 문제를 해결할 수 있습니다. 모든 하위 그래프는 각각의 텍스트 파일에 저장된 후, 추가 처리를 위해 하나로 결합되었습니다.

효율적으로 엔티티, 관계 및 관련 컨텍스트를 저장하고 검색하기 위해 PostgreSQL을 사용하여 계층적 데이터베이스를 구축했습니다. 특히 Python과 Psycopg 라이브러리를 사용하여 데이터베이스와 상호 작용했으며, 초기화 과정에서 세 개의 주요 테이블이 생성되었습니다. (1) 주제 테이블: 순차 기본 키를 사용하여 고유한 엔티티 이름을 저장합니다. (2) 관계 테이블: 각 주제를 해당 관계와 연결하며, 각 항목은 주제의 고유 식별자를 참조하여 관계가 올바르게 연결되도록 합니다. (3) 객체 테이블: 끝자리 세 개로 이루어진 엔티티와 해당 컨텍스트 정보를 저장합니다. 이 구조는 다음과 같이 표현할 수도 있습니다. S 를 주제(엔티티) 집합이라고 합니다. 각 주제 $s \in S$ 에 대해 $R(s)$ 를 s 와 연결된 관계 집합이라고 합니다. 각 관계 $r \in R(s)$ 에 대해 $O(r)$ 를 r 에 연결된 끝자리 객체 집합이라고 합니다. 여기서 각 객체는 튜플 (v, c) 로 표현되며, v 는 연결된 엔티티를, c 는 해당 컨텍스트를 나타냅니다. 따라서 전체 데이터베이스는 다음과 같은 집합으로 정의됩니다.

$$D = \{ s, r, (v, c) \mid s \in S, r \in R, (v, c) \in O(r) \} \quad (1)$$

다음과 같이 단일 3개 항목으로 표시됩니다.

$$s, r, (v, c) \quad (2)$$

3.3 그래프 검색 및 횡단




그림 3: 사용자 질의에 대한 지식 그래프 구축 및 그래프 탐색 개요. 왼쪽은 문서 선택, 전처리, 개체-관계 추출, 트리플 생성 및 문맥 매칭, 데이터베이스 저장에 이르는 자동화된 그래프 구축 과정을 보여줍니다. 오른쪽은 사용자 질의를 임베딩하여 벡터 표현을 얻고, 그래프 내 트리플에 대한 유사도 검사를 수행한 후, 가장 관련성이 높은 트리플을 순위별로 정렬하여 대규모 언어 모델에 입력하여 답변을 생성하는 지식 그래프 검색 과정을 보여줍니다.

그림 3은 트리플렛이 쿼리와 어떻게 비교되고 LLM에 제공될 수 있도록 검색되는지에 대한 자세한 설명을 제공합니다.

데이터베이스가 생성 및 저장되면, 그 안에 포함된 정보는 후속 질문에 대한 추가적인 맥락과 정보를 제공하기 위해 통합됩니다. 이는 지식 그래프에서 관련 트리플렛과 맥락을 검색함으로써 이루어집니다. 검색 프로세스는 먼저 주어진 자연어 쿼리 또는 질문을 벡터 $q \in R$ 로 인코딩하는 것으로 시작됩니다. 데이터베이스의 트리플렛 t_i 는 동일한 의미 임베딩 모델($f: t_i \rightarrow R$)을 사용하여 임베딩 e_i 로 인코딩됩니다.

이 선택된 의미론적 임베딩 모델 $f: \text{텍스트} \rightarrow R$ 을 사용하여 구현됩니다.

마찬가지로, 각각

쿼리와 각 트리플 간의 유사도는 다음과 같은 코사인 유사도를 사용하여 계산됩니다.

$$\text{sim}(q, ei) = \frac{q \cdot ei}{\|q\| \|ei\|} \quad (3)$$

이 유사도 점수는 주어진 쿼리가 지식 그래프의 각 트리플릿과 의미적으로 얼마나 유사한지를 평가하여 쿼리의 관련성을 판단할 수 있도록 합니다.

잠재적으로 수십만 개 이상의 연결을 가질 수 있는 방대한 규모의 지식 그래프를 고려하여, 후보 풀 C는 가장 높은 유사도 점수 $si = \text{sim}(q, ei)$ 를 갖는 상위 K개의 트리플에 해당하는 인덱스를 선택하여 구성됩니다. 가장 높은 유사도만을 선택함으로써 의미적으로 가장 관련성이 높은 트리플을 추가 처리를 위해 선택할 수 있습니다. 따라서 후보 풀은 다음과 같이 정의됩니다.

$$C = \{i \in \{1, 2, \dots, K\} \mid si1 \geq si2 \geq \dots \geq sik\} \quad (4)$$

앞서 언급했듯이 지식 그래프는 수십만 또는 수백만 개의 연결을 포함할 수 있으므로 상위 K개의 트리플에만 의존하면 연결된 추가적인 관련 트리플을 간과할 수 있습니다. 이러한 트리플의 확장된 이웃을 탐색하기 위해 빔 검색 확장을 수행하여 그래프를 순회합니다. $E(i)$ 는 인덱스 i 로 표시된 인접한 내장 트리플 (즉, 트리플 i 와 노드를 공유하는 트리플)의 집합을 나타냅니다. 선택된 최대 확장 깊이 $d_{\max}$ 에 대해 재귀적으로 빔 검색을 수행합니다. 깊이가 클수록 그래프를 더 깊이 탐색하여 더 많은 정보를 검색할 수 있습니다. 초기 깊이 $d = 0$ 의 경우, 먼저 초기 후보를 $C_0 = C$ 로 설정합니다. 이후 깊이 $d \geq 1$ 마다 다음 방법을 사용하여 추가 후보를 찾습니다.

$$C_{d+1} = \bigcup_{i \in C_d} \text{Top-}b \{j \in E(i) \mid \text{sim}(q, ej)\} \quad (5)$$

여기서 $\text{Top-}b(\cdot)$ 는 임베디드 쿼리 q 에 대한 유사도 점수가 높은 후보들을 b 개(빔 폭)만큼 선택합니다. 빔 폭은 선택된 매개변수로, b 값이 클수록 모델은 각 단계에서 확장할 수 있는 더 넓은 후보 집합을 탐색할 수 있습니다. 이는 초기 상위 K개에서 놓친 의미적으로 관련된 트리플을 더 많이 포착할 수 있게 합니다. 반대로 b 값이 작으면 검색 범위가 더 유망한 후보로 제한되어 계산 오버헤드가 줄어들지만, 상위 b 개 후보 외부에 있는 관련 연결을 놓칠 가능성이 있습니다. 트리플의 재처리를 방지하기 위해 방문한 트리플 집합 E_v 가 유지되며, 재귀적 확장은 다음과 같이 정의된 새로운 노드만 고려합니다.

$$C_{d+1} = \bigcup_{i \in C_d} \text{Top-}b \{j \in E(i) \mid i \in C_d \setminus V\} \quad (6)$$

선택한 깊이와 빔 크기를 통해 재귀적으로 확장한 후, 최종적으로 검색되는 트리플 집합은 다음과 같이 정의됩니다.

$$C_{\text{beam}} = \bigcup_{d=0}^{d_{\max}} C_d \quad (7)$$

최종 후보 트리플 세트가 선택된 후, 마지막 단계로 데이터베이스에서 해당 컨텍스트 c 도 검색합니다. 이렇게 하면 관련 정보 집합 C 가 생성됩니다.

$$C = \{si, ri, (oi, ci) : i \in I\} \quad (8)$$

3.4 대규모 언어 모델 생성

질의 q 에 답하는 마지막 단계는 프롬프트 구성입니다. 이 단계에서는 지식 그래프에서 가져온 정보를 대규모 언어 모델(LLM)에 제공하여 답변을 돕습니다. 이는 LLM이 자체 지식과 제공된 검색된 지식을 모두 활용하여 질문에 답하도록 설계되었음을 나타내는 시스템 지침 세트를 정의함으로써 이루어집니다. 예를 들어, 시스템 지침은 다음과 같이 정의됩니다. '귀하는 검색된 지식을 사용하여 질문에 답하도록 설계되었습니다. 제공된 모든 지식을 사용할 필요는 없으며 가장 중요한 정보에 집중하십시오. 의사 결정에 도움이 되도록 이러한 지식(있는 경우)을 기억하십시오.'

(9)

그런 다음 LLM에 제공되는 최종 프롬프트 P 는 시스템 지침, 질의 및 검색된 지식 그래프 정보를 연결하여 구성됩니다.

$$P(q, C) = I_{\text{sys}} \oplus C \oplus q \quad (10)$$

최종 답변 ALLM은 LLM에 의해 생성됩니다.

$$\text{ALLM} = \text{LLM}(P(q, C)) \quad (11)$$

4. 실험 설계

4.1 지식 그래프

ARKNESS의 효능을 검증하기 위해, 먼저 5축 밀링 기능, CNC 가공에서의 산업용 로봇 통합, CNC 가공의 지속가능성, CNC 프로그래밍 및 공정 계획, 그리고 CNC 가공의 기본 원리에 관한 연구 및 기술 문서를 포함하는 가공 지식 그래프를 생성했습니다. 다양한 복잡성 수준과 도메인별 전문 용어를 ARKNESS에 노출시킴으로써, 생성된 문서들을 통해 모델의 CNC 가공 지식을 종합적으로 평가할 수 있었습니다. 각 문서는 3.2절에 자세히 설명된 자동 그래프 생성 파이프라인을 사용하여 GPT-4o [26]로 처리되었습니다. 텍스트 정보를 입력했을 때의 출력 예시는 다음 상자에 제시되어 있습니다 [27]. 선택된 각 문서에 대한 설명은 처리 후 엔티티, 관계, 트리플의 총 개수와 함께 표 1에 나열되어 있습니다. 전체 지식 그래프는 총 4329개의 트리플, 6659개의 고유 엔티티, 1251개의 고유 관계를 포함하고 있어, ARKNESS의 강력한 추론 능력과 다양한 CNC 가공 시나리오에서의 정확한 지식 검색 능력을 검증하기에 충분한 규모를 제공합니다. 텍스트 입력에 대한 그래프 구성 출력 예시는 다음과 같습니다.

입력: 5축

CNC 밀링 머신은 높은 정확도와 일관성을 바탕으로 복잡한 부품을 정밀 가공하는 데 사용되는 정교한 장비입니다. 5축 운동을 통해 절삭 공구를 다양한 방향으로 움직여 복잡한 형상과 윤곽을 구현할 수 있습니다. 이 기계는 다축 운동을 이용하여 밀링, 드릴링, 절단, 조각 등 광범위한 작업을 수행하도록 설계되었습니다. 5축 CNC 밀링 머신은 5축 운동을 활용하여 기존의 3축 기계로는 구현하기 어렵거나 불가능한 매우 복잡한 형상을 가공할 수 있습니다.

출력: 5축

CNC 밀링 머신은 정밀 가공에 사용됩니다. "5축 CNC 밀링 머신은 복잡한 부품을 높은 정확도와 일관성으로 정밀 가공하는 데 사용되는 정교한 장비입니다."

5축 CNC 밀링 머신은 5축 운동을 가지고 있으며, "다섯 개의 축을 통해 절삭 공구를 다양한 방향으로 움직여 복잡한 형상과 윤곽을 만들 수 있습니다."

5축 CNC 밀링 머신은 "밀링, 드릴링, 절단 및 조각" 작업을 수행합니다. 이 기계는 다축 운동을 이용하여 밀링, 드릴링, 절단 및 조각을 포함한 광범위한 작업을 수행하도록 설계되었습니다.

5축 CNC 밀링 머신은 매우 복잡한 형상을 가공할 수 있습니다. "5축 CNC 밀링 머신은 5축의 움직임을 이용하여 가공 작업을 수행함으로써 기존의 3축 머신으로는 구현하기 어렵거나 불가능한 매우 복잡한 형상을 만들어낼 수 있습니다."

기존 3축 가공기의 한계, 복잡한 형상, "기존 3축 가공기를 사용해서는 구현하기 어렵거나 불가능한 가공 작업."

4.2 모델

모델 선택이 프레임워크의 성능을 어떻게 형성하는지 엄격하게 평가하기 위해, 우리는 다양한 매개변수 규모에 걸쳐 오픈 소스 및 클로즈드 소스 대규모 언어 모델을 다양하게 평가했습니다. 오픈 소스 모델의 경우, 접근성이 용이하고 계산 요구 사항이 상대적으로 낮기 때문에 Llama 3.2 3B Instruct [36], Llama 3.1 8B Instruct [37], Qwen 2.5 7B Instruct [38]를 선택했습니다. 여기서 B는 매개변수 수를 수십억 단위로 나타냅니다.

30억, 70억, 80억 개의 파라미터 계층을 아우르면서 모델 용량과 설계 선택이 지식 그래프 증강에 어떻게 상호작용하는지 분리하여 분석할 수 있습니다. 다양한 파라미터 규모에 걸쳐 이러한 모델들을 평가함으로써, 추가적인 지식 그래프 정보 통합이 전반적인 성능에 미치는 영향을 정량화할 수 있습니다.

달성 가능한 성능의 상한을 설정하기 위해 GPT-4o [26], 더 작은 GPT-4o-mini, Gemini 2.0 Flash [39] 및 Gemini 2.0 Flash-Lite [40]를 포함한 최첨단 폐쇄형 소스 모델과도 벤치마킹했습니다. 이러한 포괄적인 모델을 통해 보충 구조화된 지식이 오픈 소스 기준선과 주요 독점 제품 간의 격차를 어떻게 줄이는지 정확하게 정량화할 수 있습니다.

설명 가능한 프로세스 계획을 위한 KG 융합 LLM

표 1: 소스 문서 개요 및 해당 지식 그래프 크기.

문서	설명	지식 그래프 크기
역량에 대한 검토 및 5축 CNC 가공의 과제 밀링 머신 공구 작업 [27]	본 논문에서는 최근의 발전과 과제를 살펴봅니다. 5축 CNC 밀링(오차 모델링 및 보정, 공구 경로 및 공정 최적화, 가상 가공 시스템, 공구 마모 및 온도 예측 포함) 그리고 지속가능성에 대한 고려 사항.	트리플 개수: 464개 고유 개체 수: 654 고유 관계 수: 199
설계 및 개발 CNC 가공 공정 클라우드를 활용한 지식 기반 구축 기술 [28]	본 논문은 클라우드 기반 CNC 가공 공정을 제시합니다. STEP-NC를 OWL 온톨로지에 매핑하고 확장 가능한 스토리지를 위해 Hadoop의 HBase를 활용하는 지식 기반. MapReduce 기반 쿼리 및 SWRL 기반 추론 지능적이고 처리량이 높은 공정 계획을 가능하게 합니다.	트리플 개수: 559개 고유 개체 수: 828 고유 관계 수: 291
응용 분야 탐구 CNC 산업용 로봇 가공[29]	본 논문은 산업용 로봇의 도입에 대해 살펴봅니다. CNC 가공 분야에서 로봇 선택, 작업 흐름 등을 자세히 다룹니다. 또한 제어 프로그램 설계, 관절 및 변속 메커니즘, 구동 시스템 선택을 통해 적재/하역 작업을 자동화 하고 운영 유연성, 정밀도 및 효율성을 향상시킵니다. 능률.	트리플 개수: 98개 고유 개체 수: 151 고유 관계 수: 57
CNC 기계의 기초 - 가공[30]	이 가이드는 작업장 안전, 공구, 좌표계, 밀링 머신의 프로그래밍 및 작업을 포함하여 CNC 가공의 기본 사항에 대한 실용적인 소개를 제공합니다. 선반, 2D/3D 공구 경로, 공작물 고정 장치 예시 및 최적 시제품 및 소량 생산을 위한 실무 지침.	트리플 개수: 1902 고유 개체 수: 2966 고유 관계 수: 512
혁신적인 접근 방식 지속 가능한 CNC 가공: 에너지 최적화에 대한 기계 학습 관 점 [31]	본 논문은 기계 학습 프레임워크를 개발합니다. 축별 조합을 통한 지속 가능한 5축 CNC 밀링 타구치 실험 설계를 이용한 전력 모니터링 트리 기반 회귀 분석을 사용하여 에너지 소비량을 모델링하고 예측 합니다.	트리플 개수: 278개 고유 개체 수: 452 고유 관계 수: 183
다구치와 통합 CNC용 PROMETHEE 밀링 가공 매개변수 최적화 [32]	본 논문은 스핀들 속도, 이송 속도 및 절삭 깊이를 최적화하기 위해 타구치 직교 배열 실험 설계와 PROMETHEE 다기준 순위 결정 방법 을 통합합니다. AA6061 CNC 밀링 가공용 절삭.	트리플 개수: 227개 고유 개체 수: 366 고유 관계 수: 74
CNC 프로그래밍 및 가공 공정에 대 한 연구 CAD/CAM 기술 기반 [33]	본 논문은 베이지안 프로세스-스켈레톤 매핑 을 사용하여 부품 특징 을 재사용 가능한 매크로 프로세스 와 연결하는 CAD/CAM 기반 CNC 프로그래밍 프레임워크를 소개합니다. 그리고 잔여 높이 궤적 생성을 적용합니다. 다축 공구 경로를 최적화하기 위한 비선형 오차 보정 .	트리플 개수: 269개 고유 개체 수: 443 고유 관계 수: 167
디자인 연구에 대한 리뷰 CNC 공작기계 에너지 소비량 기준 [34]	본 논문은 CNC 공작기계의 모델링, 설계 및 평가 분야에서 전 세계 적으로 이루어진 발전을 개괄적으로 살펴봅니다. 에너지 소비 관점.	트리플 개수: 270 고유 개체 수: 470 고유 관계 수: 140
로봇 자동화 CNC 공작기계, 검토 [35]	본 논문에서는 로봇 기술을 활용한 CNC 가공 분야의 발전상을 살펴보 입니다 . 자동화된 자재 처리 및 공구 교환에 대한 내용도 포함됩니다. 적응형 제어, 품질 검사, 데이터 분석 등에 이르기까지 협동 로봇은 효율성, 정밀도 및 안전성 에 미치는 영향에 대해 평가됩니다 .	트리플 개수: 262개 고유 개체 수: 380 고유 관계 수: 129

4.3 질문 유형

지식 그래프 구축 후, 우리는 객관식과 주관식이라는 두 가지 질문 형식을 고안했습니다.

각 모델의 기능을 평가합니다. 객관식 문제는 검색 정확도를 측정하는 통제된 기준점을 제공합니다.

객관적인 측정과 모델 간의 직접적인 비교를 가능하게 하는 동시에, 개방형 질문은 실제 상황을 시뮬레이션합니다.

생성적 합성을 수행하고 검색된 정보를 일관되게 통합하도록 모델에 도전하는 사례 연구

포괄적인 답변으로 변환합니다. 각 질문 형식에 대해 내용이라는 두 가지 범주의 질문이 생성되었습니다.

내용 관련 문제와 가공 관련 문제로 나뉩니다. 내용 관련 문제는 문서에 기재된 정보 중 정량적 분석이 필요하지 않은 내용을 묻는 문제입니다. 가공 관련 문제는 정량적 정확성과 수치적 매개변수에 기반한 의사 결정이 필요한 문제를 말합니다. 각 문제의 객관식 예시는 아래와 같습니다.

콘텐츠 관련 질문

다음 중 3축 CNC 밀링 머신과 5축 CNC 밀링 머신의 주요 차이점을 가장 잘 설명하는 문장은 무엇입니까?

- A. 3축 가공기는 금속 가공에 사용되고, 5축 가공기는 플라스틱 가공에만 사용됩니다.
- B. 5축 기계는 X, Y, Z축 운동 외에도 공작물이나 공구의 기울기 및 회전 기능을 포함합니다.
- C. 3축 가공기는 5축 가공기보다 크기가 크고 더 많은 설치 공간을 필요로 합니다.
- D. 5축 기계는 수직 이동을 허용하지 않지만 3축 기계는 허용합니다.[4pt]

가공 관련 특정 질문

스테인리스강(303) 드릴링 작업에 권장되는 이송 속도(인치/회전)는 얼마입니까?

- A. 0.0005인치/회전 B.
- 0.0010인치/회전 C.
- 0.0020인치/회전 D.
- 0.0030인치/회전

GPT-4o를 사용하여 선택된 문서로부터 각 질문을 생성했으며, 총 65개의 내용 관련 객관식 문제, 45개의 기계 가공 관련 객관식 문제, 104개의 내용 관련 주관식 문제, 그리고 45개의 기계 가공 관련 주관식 문제가 포함되었습니다.

5. 실험 결과




그림 4: 대규모 언어 모델의 정확도를 그래프 탐색 깊이와 Top K 트리플 검색 횟수의 함수로 나타낸 그래프 (a) 콘텐츠 관련 쿼리 및 (b) 기계 가공 관련 쿼리.

ARKNESS는 Python, PyTorch 및 선택된 각 모델에 대한 해당 API를 사용하여 구현되었습니다. 먼저, 식 5에 정의된 제어된 그래프 탐색을 사용하여 지식 그래프 증강이 대규모 언어 모델의 성능을 어떻게 향상시킬 수 있는지 살펴봅니다. 그림 4는 이러한 탐색 깊이를 변화시키고 LLM 답변의 정확도에 미치는 영향을 측정할 실험 결과를 보여줍니다. 이 실험에서는 가장 높은 점수를 받은 상위 K개의 트리플과 해당 컨텍스트를 선택하는 데에도 중점을 두었습니다. 그림 4a는 내용별로 지정된 객관식 문제에 대한 결과를 나타냅니다. 그림에서 볼 수 있듯이, 그래프에서 추출하여 LLM에 제공하는 상위 K개 트리플의 수를 늘릴수록 성능이 향상되는 일반적인 경향이 나타납니다. 이러한 경향은 테스트된 대부분의 깊이에서 유지되지만, 깊이 1에서 GPT-4o mini의 성능이 저하되는 예외가 있습니다. 이는 추가된 그래프 기반 정보가 중복되거나 정보량이 부족하여 모델의 초기 컨텍스트를 압도하기 때문일 수 있습니다. 주목할 만한 점이 있습니다.

Gemini 2.0 Flash의 경우, 깊이 0에서 정보가 전혀 없는 경우(Top K 0)부터 Top K 10까지 정확도가 0.867에서 0.933으로 증가했습니다. 깊이가 증가함에 따라 검색된 Top K 전반에 걸쳐 성능이 안정화되는 것을 확인할 수 있는데, 이는 이러한 유형의 질문에서는 추가 정보가 더 이상의 이점을 제공하지 않으므로 깊이 0이 가장 최적임을 나타냅니다. 이러한 안정화는 초기 검색된 컨텍스트가 이미 충분히 풍부하며, 깊이 0을 넘어 추가적인 그래프 기반 세부 정보를 통합해도 모델 정확도가 향상되지 않고 오히려 불필요한 노이즈를 유발할 수 있음을 의미합니다. 콘텐츠 관련 질문과 비교했을 때, 정량적 기계 가공 관련 질문에서 훨씬 더 큰 성능 향상 추세가 관찰되었으며, 그림 4b)에서 볼 수 있듯이 모든 깊이와 Top K 값에서 성능 향상이 나타났습니다. 이는 추가적인 그래프 기반 컨텍스트가 기계 가공 관련 쿼리에 대한 정확한 정량적 값을 식별하는 데 중요한 역할을 하며, 깊이 2 부근에서 안정화되는 것은 이러한 더 어려운 질문의 경우 필요한 관련 정보를 포착하기 위해 더 깊은 그래프 탐색이 필요함을 보여줍니다.




그림 5: 콘텐츠별 객관식 질의와 기계 가공별 객관식 질의에 대해, 기준선(0%)부터 전체 그래프(100%)까지 다양한 지식 그래프 완성도 수준에 따른 대규모 언어 모델의 평균 정확도 성능을 나타낸 레이더 플롯.

그림 5는 실제 시나리오를 모방하기 위해 불완전한 지식 그래프 조건에서 우리 모델의 성능을 보여줍니다. 이러한 시나리오에서는 사용 가능한 데이터가 부분적으로만 연결되어 있거나 연결성이 부족할 수 있습니다. 이 접근 방식은 그래프 증강 메커니즘의 견고성을 검증할 뿐만 아니라, 누락된 노드와 관계가 관련 정보 검색 및 궁극적으로 LLM 응답의 정확도에 어떤 영향을 미치는지 이해하는 데 도움이 됩니다. 우리는 앞서 언급한 LLM 모델들을 다양한 그래프 크기, 즉 그래프가 없는 기준 모델, 25%, 50%, 75%, 그리고 100% 전체 그래프 조건에서 다시 테스트했습니다. 선택된 그래프 크기를 얻기 위해 트리플을 무작위로 제거했으며, 각 모델은 각 그래프 크기에 대해 10회씩 테스트하여 평균값을 그래프에 표시했습니다. 녹색으로 표시된 증가율은 그래프 크기 증가에 따른 모든 모델에서 최대 증가율을 나타냅니다. 그림 5a는 다양한 LLM 모델에서 콘텐츠 관련 질문에 대한 성능 지표를 보여줍니다. 결과는 추가적인 그래프 컨텍스트가 제공될 때 성능 향상이 미미함을 보여주는데, 이는 이러한 질문들이 각 모델에서 사용 가능한 기본 컨텍스트 정보만으로도 충분히 해결될 수 있음을 시사합니다. 특히, 그래프 크기를 기준선에서 25%로 늘렸을 때 최대 성능 향상(약 3% 절대 증가)이 관찰되었는데, 이는 추가적으로 검색된 데이터가 어느 정도 이점을 제공하지만 콘텐츠 관련 쿼리에는 그 영향이 상대적으로 제한적임을 보여줍니다. 그림 5b는 그래프 크기 확장이 보다 전문적인 정량적 가공 관련 질문의 성능에 미치는 영향을 보여줍니다. 그림 5a의 콘텐츠 관련 쿼리와 달리, 이러한 질문은 그래프 크기가 기준선을 넘어 증가함에 따라 모델 전반에 걸쳐 최대 증가폭이 더 크게 나타나는 등 더욱 뚜렷한 성능 향상을 보입니다. 폐쇄형 소스 모델과 오픈 소스 모델을 비교했을 때, GPT-4o는 추가 그래프 컨텍스트를 효과적으로 활용하여 그래프 크기가 100%일 때 기준선 대비 12.1%의 성능 향상을 달성했습니다. 또한, Gemini 2.0 Flash-Lite는 그래프 크기가 100%일 때 기준선 대비 15.1%라는 비교적 높은 성능 향상을 보였습니다. 반면, 오픈 소스 Llama 3.2 3B Instruct는 기준선 대비 그래프 크기 100%에서 20.3%라는 훨씬 더 큰 상대적 성능 향상을 보여주며, 이는 기준 성능이 낮을 수 있는 이러한 모델들이 향상된 외부 컨텍스트를 통해 크게 개선될 수 있음을 시사합니다. 특히, 더 작은 오픈 소스 모델에서 나타난 상당한 개선은 공장 현장과 같은 제조 환경에서 이러한 모델들이 유용할 수 있음을 의미합니다.

모델은 추가적인 맥락 정보를 활용하면 특히 효과적일 수 있습니다. 이러한 모델의 낮은 계산량은 다음과 같은 장점을 제공합니다. 오버헤드가 적고 추론 속도가 빠르기 때문에 실시간 산업 환경에 배포하기에 특히 적합합니다. 비용 효율성과 신속한 대응이 매우 중요합니다.

표 2: 각 대규모 데이터셋에 대한 기준 모델과 지식 그래프를 적용한 모델 간의 벤치마크 정확도 및 F1 점수 성능 비교 언어 모델. 절대적인 증가(또는 변화 없음)는 **녹색으로**, 감소는 **빨간색으로** 표시됩니다.

모델	파일	기준선		지식 그래프	
		정확도 F1 점수 정확도		F1 점수	
제미니 2.0 플래시	콘텐츠 관련성 0.867 가공 관련성 0.267	0.535 0.933	(+0.066) 0.569	(+0.034) 0.224	(+0.072)
이트 가공별 0.333	콘텐츠별 0.933 제미니 2.0 플래시라	0.888 0.933	(0.000) 0.688	(-0.200) 0.338	(+0.061)
GPT-4o	콘텐츠별 가공별 0.667	0.933	0.716 0.950	(+0.017) 0.719	(+0.003)
			0.464 0.733	(+0.066) 0.573	(+0.109)
GPT-4o 미니	콘텐츠 관련성 0.933 가공 관련성 0.567	0.906 0.933	(0.000) 0.901	(-0.005) 0.549	(+0.158)
지시 가공별 0.433	콘텐츠별 라마 3.1 8B	0.940	0.925 0.953	(+0.013) 0.940	(+0.015)
			0.244 0.633	(+0.200) 0.404	(+0.160)
라마 3.2 3B 지침	콘텐츠 관련성 0.933 가공 관련성 0.367	0.718 0.950	(+0.017) 0.712	(-0.006) 0.543	(+0.224)
			0.319 0.583	(+0.216) 0.543	(+0.224)
Qwen 2.5 7B 사용 설명서	콘텐츠별 가공별 0.567	0.867	0.580 0.883	(+0.016) 0.614	(+0.034)
			0.371 0.700	(+0.133) 0.463	(+0.092)

표 2는 기준 모델 성능과 최소 실행 가능 모델을 사용한 결과 간의 벤치마크 비교를 제공합니다. 객관식 문제 모듈에 대해 지식 그래프 정보 통합(즉, 선택된 상위 K개 10개 및 깊이 0) 데이터 세트. 정확도와 F1 점수 모듈에 대한 결과는 절대적인 증가 또는 증가 없음 여부와 함께 보고됩니다. 기준선 및 지식 그래프 증강 출력은 녹색으로 강조 표시되고 감소 추세는 빨간색으로 표시됩니다. 그림에서 볼 수 있듯이 표로 정리하자면, 기준 성능이 이미 높았던 콘텐츠 관련 질문의 경우 개선 효과는 매우 미미합니다. 정확도 측면에서 범위는 0.013에서 0.066 사이입니다. 하지만 이처럼 비교적 작은 상승폭조차도 포함 요소가 존재함을 나타냅니다. 지식 그래프는 답변을 더욱 정교하게 다듬는 데 도움이 되는 귀중한 도메인별 통찰력을 제공합니다. 반면, 정량적 가공 관련 특정 질문에 대한 결과는 훨씬 더 의미 있는 결과를 보여줍니다. 예를 들어, 제미니 2.0이 있습니다. Flash-Lite는 정확도에서 0.250, F1 점수에서 0.072의 향상을 달성했습니다. 마찬가지로, 개선 정도도 표시됩니다. Llama 3.2 3B Instruct와 Llama 3.1 8B Instruct는 각각 0.216과 0.200의 정확도 향상을 보였습니다. 이러한 개선 사항은 지식 그래프가 제공하는 구조화된 도메인별 컨텍스트가 효과적이라는 증거를 제공합니다. 각 LLM의 내부 표현에 존재하는 결함을 효과적으로 해결합니다. 주목할 만한 점이 있다는 점에 유의해야 합니다. Gemini 2.0 Flash-Lite의 콘텐츠 관련 질문 테스트 시 F1 점수가 0.200 감소했습니다. 이러한 감소는 다음과 같은 이유 때문일 수 있습니다. 지식 그래프가 제공하는 추가적인 맥락에 기인하는 것으로, 일반적으로 유익하지만 증가할 수도 있습니다. 입력값의 복잡성으로 인해 모델의 내부 표현과 최종 의사 결정 과정에서 혼란이 발생할 수 있습니다. 요약하자면, 입력 복잡성 증가로 인한 일부 지역적 감소에도 불구하고 지식 통합은 전반적으로 지속되고 있습니다. 그래프 정보는 대부분의 모델에서 성능을 일관되게 향상시켜 상당한 개선을 제공합니다. 콘텐츠 관련 쿼리와 정량적 가공 관련 쿼리 모두에서 도메인별 정확성과 신뢰성을 보장합니다. 이를 통해 기술 응용 분야에서 LLM 결과물을 향상시키는 데 있어 그 중요성이 입증되었습니다.

다음 실험에서는 LLM이 주관식 질문과 객관식 질문에 어떻게 반응하는지 살펴볼 것입니다. 이 섹션에서는 사전 정의된 답변 없이 해답을 생성해야 할 때 모델이 어떻게 작동하는지 이해하고자 합니다. 제한된 수의 잠재적 응답 중에서 선택해야 하는 경우와 비교하여, 더 많은 선택지를 제공합니다. 이러한 접근 방식을 통해 우리는 다음과 같은 이점을 얻을 수 있습니다. 보다 제약 없는 시나리오에서 외부 지식 증강의 효과를 평가합니다. 그림 6은 평균값을 제공합니다. 각 데이터 세트에 대해 4가지 지표(의미 유사성, ROUGE-1, ROUGE-2)에 대한 10회 실행 결과를 보여줍니다. 그리고 ROUGE-L입니다. 여기서 의미 유사성은 생성된 답변과 원래 답변 사이의 의미적 유사성을 평가합니다. 벡터 임베딩을 비교하여 참조 응답을 분석함으로써 단순한 정보 전달을 넘어 전체적인 의미론적 내용을 포착합니다. 단어 일치도 측정. ROUGE-1은 생성된 텍스트와 실제 텍스트 간의 개별 단어(단어 단위) 중복률을 측정합니다. 근거 있는 답변은 어휘 유사성의 기준 지표 역할을 합니다. ROUGE-2는 이러한 비교를 쌍으로 확장합니다. 연속된 단어(이중어)를 분석하여 짧은 구문의 일관성에 대한 통찰력을 제공합니다. 마지막으로 ROUGE-L은 다음을 평가합니다. 생성된 텍스트와 참조 텍스트 간의 가장 긴 공통 부분 수열을 찾아 구조적 유사성을 강조합니다. 서술 흐름의 유지. 그림 6a)에서 볼 수 있듯이, 추가 정보가 포함된 내용별 질문의 경우 지식 그래프를 기준으로 보면, 대부분의 모델에서 모든 지표에 걸쳐 전반적인 점수가 더 높습니다. 특히 이러한 경향이 두드러집니다.

설명 가능한 프로세스 계획을 위한 KG 융합 LLM




그림 6: 평가 대상 대규모 언어 모델에 대해 10회 실행 동안의 평균 성능을 나타낸 것으로, 기준 출력과 지식 그래프 데이터로 증강된 출력을 비교한 결과입니다. a)는 콘텐츠 관련 질문에 대한 성능을 보여주고, b)는 의미 유사성, ROUGE-1, ROUGE-2 및 ROUGE-L 지표를 사용하여 기계 학습 관련 질문에 대한 결과를 보여줍니다.

표 3: 오픈소스 모델인 Llama 3.2 3B Instruct, Llama 3.1 8B Instruct, 그리고 Qwen 2.5 7B Instruct에서 CNC 가공용 드릴 크기에 대해 제시된 개방형 응답. 정량적 근거에 기반한 답변은 **노란색**으로, 기준값은 **빨간색**으로, 지식 그래프를 통해 증강된 값은 **녹색**으로 표시했습니다.

모델/질문: 드릴 사이즈 82는 소수로 어떻게 표현되나요?	드릴 사이즈 84는 소수로 얼마입니까?	드릴 사이즈 89는 소수로 얼마입니까?
근거 있는 답변 드릴 크기의 소수점 값 82는 0.0125인치입니다.	드릴 사이즈 84의 소수점 표기는 0.0115인치입니다.	드릴 사이즈 89의 소수점 표기는 0.0091인치입니다.
라마 3.1 8B 지침 기준선: 우리는 드릴 크기를 발견했습니다. 82는 실제로 0.082인치와 같습니다. 이는 숫자 82가 해당 시리즈에서 82번째 드릴 크기를 나타내며, 소수점 환산은 드릴 크기와 시리즈를 고려한 공식을 사용하여 계산되기 때문입니다. 지식 그래프: 드릴 사이즈 82의 소수점 값은 0.0125인치입니다.	기준선: 드릴 사이즈 84의 소수점 표기는 0.84인치이며, 이는 분수로 84/64로도 나타낼 수 있습니다. 지식 그래프: 드릴 사이즈 84의 소수점 값은 0.0115인치입니다.	기준값: 드릴 사이즈 89의 소수점 값은 약 0.139 인치입니다. 지식 그래프: 드릴 사이즈 89의 소수점 값은 0.0091인치입니다.
라마 3.2 3B 지침 기준: 표준 드릴 크기표에 따르면, 드릴 크기 82는 직경 0.820인치에 해당합니다. 지식 그래프: 드릴 사이즈 82의 소수점 값을 찾으려면 제공된 정보를 살펴봐야 합니다. 드릴 사이즈 82는 소수점 값으로 0.0125인치에 해당합니다. 지식 그래프: 드릴 사이즈 82의 소수점 값은 0.0125인치입니다.	기준: 드릴 사이즈 84는 직경이 84mm인 드릴 비트를 의미합니다. 이를 소수로 변환하려면 직경을 소수로 나타내기만 하면 됩니다. 이 경우 드릴 사이즈 84의 소수 값은 84.00mm입니다. 지식 그래프: 드릴 사이즈 84의 소수점 값은 0.0115인치입니다.	기준선: 드릴 사이즈 89의 소수점 표기는 0.89인치 또는 0.0089인치입니다. 지식 그래프: 드릴 사이즈 89의 소수점 값은 0.0091인치입니다.
Qwen 2.5 7B 사용 설명서 기준: "드릴 크기 82"는 직경이 82/1000인치인 드릴 비트에 해당할 가능성이 높습니다. 이는 다음과 같은 경우에 0.82인치에 해당합니다. 소수로 표현됩니다. 지식 그래프: 드릴 사이즈 82의 소수점 값은 0.0125인치입니다.	기준: 드릴 사이즈 84의 십진수 값은 일반적으로 미국 관습 단위계에서 드릴 비트 크기를 나타냅니다. 소수점 넷째 자리까지 반올림하면 드릴 사이즈 84의 십진수 값은 약 0.0119 인치입니다. 지식 그래프: 드릴 사이즈 84의 소수점 값은 0.0115인치입니다.	기준: 미국 관습 단위계에서 일반적으로 드릴 비트 크기를 나타내는 드릴 크기 89의 십진수 값은 1/2인치입니다. 지식 그래프: 드릴 사이즈 89의 소수점 값은 0.0091인치입니다.

설명 가능한 프로세스 계획을 위한 KG 융합 LLM

GPT-4o, GPT-4o mini, Gemini 2.0 Flash, Gemini 2.0 Flash-Lite, Llama 3.1 8B Instruct 및 Llama 3.2 3B Instruct와 같은 모델의 경우 ROUGE-1은 최대 3.1배, ROUGE-2는 최대 2.8배, ROUGE-L은 최대 2.9배 향상되었습니다. 이러한 상당한 성능 향상은 그래프 기반 정보의 통합이 모델의 관련 기본 정보 포착 및 재현 능력을 크게 향상시켜 콘텐츠 관련 질문에 대한 생성된 응답의 품질과 정확도를 현저히 개선함을 분명히 보여줍니다. 그림 6b)는 정량적 가공 관련 질의에 대한 테스트에서 개방형 질문 생성 성능이 더욱 두드러지게 향상되었음을 보여줍니다. 의미 유사성 측면에서 Gemini 2.0 Flash-Lite를 제외한 모든 모델에서 최대 1.2배의 향상이 나타났습니다. ROUGE 지표의 경우, 모든 모델이 기준선 대비 ROUGE-1, ROUGE-2, ROUGE-L 에서 각각 최대 8.5배, 8.8배, 8.1배의 점수 증가를 보였습니다. 이러한 결과는 정확한 수치적 정확성과 기술적 세부 사항을 요구하는 정량적 질문이 특히 풍부한 맥락 정보의 혜택을 받는다는 것을 입증합니다. 의미 유사성은 정량적 콘텐츠에 대한 기본적인 이해도가 이미 높다는 것을 나타내지만, ROUGE 점수의 상당한 향상은 추가적인 맥락 정보가 모델이 훨씬 더 정확하고 상세한 정량적 응답을 생성하는 데 도움이 된다는 것을 보여줍니다.

표 4: 폐쇄형 소스 모델인 Gemini 2.0 Flash, Gemini 2.0 Flash-Lite, GPT-4o 및 GPT-4o-mini의 CNC 가공용 드릴 크기에 대한 개방형 응답. 정량적 답변은 **노란색으로**, 기준값은 **빨간색으로**, 지식 그래프로 증강된 값은 **녹색으로** 표시했습니다.

모델/질문: 드릴 사이즈 82 는 소수로 어떻게 표현되나요 ?	드릴 사이즈 84 는 소수로 얼마입니까 ?	드릴 사이즈 89 는 소수로 얼마입니까 ?
근거 있는 답변 드릴 크기의 소수점 값 82는 0.0125인치입니다.	드릴 사이즈 84의 소수점 표기는 0.0115인치입니다.	드릴 사이즈 89의 소수점 표기는 0.0091인치입니다.
제미니 2.0 플래시 기본 정보: 드릴 크기는 일반적으로 숫자, 문자 또는 인치 단위의 분수로 표시됩니다. 드릴 크기 82는 숫자로 표시된 드릴 크기입니다. 숫자로 표시된 드릴 크기는 0.0135인치인 80번부터 0.228인치인 1번까지 있으며, 숫자가 작아질수록 크기가 커집니다. 드릴 사이즈 82는 0.0156인치와 같습니다. 지식 그래프: 드릴 사이즈 82의 소수점 값은 0.0125인치입니다.	기준값: 드릴 사이즈 84의 소수점 값은 0.0095인치입니다. 지식 그래프: 드릴 사이즈 84의 소수점 값은 0.0115인치입니다.	기준값: 드릴 사이즈 89의 소수점 표기는 0.2010인치입니다. 지식 그래프: 드릴 사이즈 89의 소수점 값은 0.0091인치입니다.
제미니 2.0 플래시 라이트 기준값: 드릴 사이즈 82의 소수점 값은 약 0.0400 인치입니다. 지식 그래프: 드릴 사이즈 82의 소수점 값은 0.0125 인치입니다.	기준값: 드릴 사이즈 84의 소수점 값은 0.040인치입니다. 지식 그래프: 드릴 사이즈 84의 소수점 값은 0.0115 인치입니다.	기준값: 드릴 사이즈 89의 소수점 값은 약 0.040 인치입니다. 지식 그래프: 드릴 사이즈 89의 소수점 값은 0.0091 인치입니다.
GPT-4o 기준: 번호가 매겨진 드릴 비트 시스템의 일부인 82번 드릴 크기의 경우, 소수점 값은 0.0120 인치입니다. 지식 그래프: 드릴 사이즈 82의 소수점 값은 0.0125인치입니다.	기준선: 표준 숫자 연습에서 규칙 체계에서 가장 작은 크기는 80이며, 이는 직경 0.0135 인치에 해당합니다. 만약 이 표준 범위를 벗어난 드릴 크기를 탐사하는 것이면, 오타이거나 특정 제조업체 또는 용도에 특화된 비표준 크기일 수 있습니다. 지식 그래프: 드릴 사이즈 84의 소수점 값은 0.0115인치입니다.	기준: 표준 번호가 매겨진 드릴 비트의 경우, 드릴 사이즈 89는 일반적으로 인정되지 않습니다. 표준 번호가 매겨진 드릴 비트 사이즈는 80부터 시작하며, 80은 소수점으로 환산하면 0.0135인치입니다. 지식 그래프: 드릴 사이즈 89의 소수점 값은 0.0091인치입니다.
GPT-4o-mini 기준: 드릴 사이즈 82의 직경은 약 0.4130인치입니다. 지식 그래프: 드릴 사이즈 82의 소수점 값은 0.0125인치입니다.	기준: 드릴 크기 84는 직경 0.0860인치에 해당합니다. 지식 그래프: 드릴 사이즈 84의 소수점 값은 0.0115인치입니다.	기준: 드릴 크기 89는 직경이 약 0.0135 인치에 해당합니다. 지식 그래프: 드릴 사이즈 89의 소수점 값은 0.0091인치입니다.

각 모델의 응답을 평가하기 위해 의미 유사도 및 ROUGE 점수와 같은 정량적 지표를 사용하는 것 외에도, 정량적 질문에 대해 생성된 전체 답변을 포함합니다. 이러한 접근 방식은 폐쇄형 소스 모델과 개방형 소스 모델 간의 차이점을 명확히 보여줄 뿐만 아니라, 각 모델이 검색된 그래프 지식을 응답에 어떻게 통합하는지에 대한 심층적인 통찰력을 제공합니다. 표 3과 표 4는 정확한 드릴 크기를 결정하는 데 초점을 맞춘 드릴 크기 질문에 대한 기준선 및 지식 그래프 증강 출력 결과를 보여줍니다.

설명 가능한 프로세스 계획을 위한 KG 융합 LLM

각각 오픈 소스 모델과 클로즈드 소스 모델의 값을 나타냅니다. 각 표에서 각 질문에 대한 정확한 정량적 답변은 노란색으로, 기준 LLM 값은 빨간색으로, 지식 그래프로 보강된 값은 녹색으로 강조 표시됩니다. 보시다시피, 지식 그래프를 사용하면 기준 답변에 존재하는 오류를 수정하여 LLM의 모든 개방형 질문 답변의 결과가 일관되게 향상됩니다. 예를 들어, 오픈 소스 그룹에서 Llama 3.2 3B 및 Llama 3.1 8B와 같은 모델은 기준 답변에서 실제 값과 크게 차이가 나는 결과를 제공했습니다(예: 드릴 크기 82에 대해 0.820인치 또는 0.082인치 보고). 그러나 지식 그래프로 보강했을 때 이러한 모델은 모두 정확한 소수점 값인 0.0125인치로 수렴했습니다. 마찬가지로 Qwen 2.5 7B Instruct는 드릴 크기 숫자를 인치 단위로 잘못 해석했지만, 그래프의 정보를 통해 효과적으로 수정되었습니다. 폐쇄형 소스 모델들은 Gemini 2.0-flash, Gemini 2.0-flash-lite, GPT-4o, GPT-4o-mini 모두에서 유사한 경향을 보이며 부정확한 정량적 답변을 제공했습니다. 이러한 답변들은 드릴 크기 82에 대해 GPT-4o가 0.012인치를 출력하는 것처럼 거의 정확한 값부터 GPT-4o-mini가 동일한 드릴 크기에 대해 0.4130인치를 출력하는 것처럼 매우 부정확한 값까지 다양했습니다. 개방형 소스 모델과 폐쇄형 소스 모델을 비교해 보면, 소규모 개방형 소스 모델은 드릴 크기 숫자와 해당 소수점 값을 혼동하여 숫자 레이블을 측정값 자체로 잘못 인식하는 경향이 있습니다. 반면, 폐쇄형 소스 모델은 종종 완전히 잘못된 값을 생성합니다. GPT-4o와 같은 경우에는 지정된 드릴 크기가 존재하지 않는다고 주장하기도 합니다. 이러한 결과는 드릴 크기 정보를 정확하게 변환하기 위해 선택지가 주어지지 않는 개방형 시나리오에서 지식 그래프를 활용하는 것이 중요하다는 점을 강조합니다.

표 5: 오픈소스 모델인 Llama 3.2 3B Instruct, Llama 3.1 8B Instruct, 그리고 Qwen 2.5 7B Instruct에서 CNC 가공 작업의 파라미터 선택에 대한 개방형 응답. 정량적 근거에 기반한 답변은 노란색으로, 기준값은 빨간색으로, 지식 그래프로 증강된 값은 녹색으로 표시했습니다.

모델/질문	4140 강에 대한 드릴링 작업 시 권장되는 절삭 속도(SFM)는 얼마입니까?	알루미늄 탭 가공 시 권장 절삭 속도(SFM)는 얼마입니까?	공구 직경이 0.5~1.0인치 인 황동 밀링 작업 시 권장 되는 칩 부하는 얼마입니까?
강철(4140) 드릴링 작업의 경우 90 SFM의 절삭 속도가 권장됩니다.		알루미늄 탭 가공 작업에는 100 SFM의 절삭 속도가 권장됩니다.	공구 직경이 0.5~1.0 인치인 황동 밀링 작업의 경우, 회전당 0.004인치의 칩 부하가 권장됩니다.
라마 3.1 8B 지침	기준: 4140강 드릴링 작업에 권장되는 절삭 속도는 드릴 비트 종류와 원하는 표면 마감에 따라 50~300 SFM 범위입니다.	기본 사항: 일반적으로 알루미늄 탭 가공에 권장되는 절삭 속도는 특정 조건에 따라 50~150 SFM 범위입니다.	기준치: 황동에 대한 칩 부하의 일반적인 범위는 치아당 0.002~0.008인치(ipi)입니다.
	지식 그래프: 강철(4140) 드릴링 작업의 경우 권장 절삭 속도는 90 sfm입니다.	지식 그래프: 알루미늄 탭핑 작업 시 권장 절삭 속도는 100 sfm입니다.	지식 그래프: 공구 직경이 0.5~1.0인치인 황동 밀링 작업 시 권장 칩 부하는 0.004 ipr입니다.
라마 3.2 3B 지침	기본 사항: 4140강 드릴링 작업 시 권장 절삭 속도는 일반적으로 60~120 SFM 범위이며, 최적 속도는 특정 드릴링 조건에 따라 달라집니다.	기본 조건: 알루미늄 합금 탭 가공 작업에는 일반적으로 분당 30~50피트(FPM)의 절삭 속도가 권장되지만, 최적의 절삭 속도는 적용 분야, 공구 및 가공 조건에 따라 달라질 수 있습니다.	기준: 황동 밀링 작업의 경우, 일반적으로 공구 직경이 0.5~1.0인치일 때 칩 발생량은 0.002~0.005인치 사이가 적당합니다.
	지식 그래프: 4140강에 대한 드릴링 작업에는 90 SFM의 절삭 속도가 권장됩니다.	지식 그래프: 알루미늄 탭핑 작업 시 권장 절삭 속도는 100 sfm입니다.	지식 그래프: 제공된 맥락을 바탕으로, 공구 직경이 0.5~1.0 인치인 황동 밀링 작업의 경우 권장 칩 부하는 회전당 0.004 인치(ipi)입니다.
Qwen 2.5 7B 사용 설명서	기준치: 4140강 드릴링 에 권장되는 분당 드릴링 속도 (SFM)는 일반적으로 25~35피트 (FPM) 범위입니다.	기준: 알루미늄 탭핑 작업의 경우 권장 절삭 속도(분당 피트, SFM)는 일반적으로 100~ 200 SFM입니다.	기준선: 이 범위에서 칩 부하의 일반적인 시작점은 치아당 약 0.003~0.005인치 (IPM)입니다.
	지식 그래프: 강철(4140) 드릴링 작업의 경우 권장 절삭 속도(SFM)는 90 sfm입니다.	지식 그래프: 알루미늄 탭핑 작업 시 권장 절삭 속도(SFM)는 100 sfm입니다.	지식 그래프: 공구 직경이 0.5~1.0인치인 황동 밀링 작업의 경우, 회전당 0.004인치(ipi)의 칩 부하가 권장됩니다.

표 5와 표 6은 각각 오픈소스 및 클로즈드소스 모델 응답을 제시하며, 이는 다양한 작업 조건에서 최적의 가공 성능, 정밀한 재료 제거 및 공구 수명 연장을 보장하는 데 특히 중요한 올바른 공정 매개변수 선택과 관련된 정량적 질문에 대한 것입니다. 앞서 언급한 표들과 마찬가지로, 각 질문에 대한 올바른 정량적 답변은 노란색으로, 기준 LLM 값은 빨간색으로 강조 표시되어 있습니다.

설명 가능한 프로세스 계획을 위한 KG 융합 LLM

표 6: 폐쇄형 소스 모델인 Gemini 2.0 Flash, Gemini 2.0 Flash-Lite, GPT-4o 및 GPT-4o-mini의 CNC 가공 작업 매개변수 선택에 대한 개방형 응답. 정량적 근거에 기반한 답변은 **노란색으로**, 기준값은 **빨간색으로**, 지식 그래프로 증강된 값은 녹색으로 표시했습니다.

모델/질문	4140 강에 대한 드릴링 작업 시 권장되는 절삭 속도(SFM)는 얼마입니까?	알루미늄 탭 가공 시 권장 절삭 속도(SFM)는 얼마입니까?	공구 직경이 0.5~1.0인치 인 황동 밀링 작업 시 권장되는 칩 부하는 얼마입니까?
강철(4140) 드릴링 작업의 경우 90 SFM의 절삭 속도가 권장됩니다.		알루미늄 탭 가공 작업에는 100 SFM의 절삭 속도가 권장됩니다.	공구 직경이 0.5~1.0 인치인 황동 밀링 작업의 경우, 회전당 0.004인치의 칩 부하가 권장됩니다.
제미니 2.0-플래시	기준: 고강도 및 우수한 경화성으로 알려진 중탄소 저합금강인 4140강의 경우, 일반적인 드릴링 작업의 절삭 속도는 보통 70~120 SFM 범위입니다. 지식 그래프: 4140강에 대한 드릴링 작업에는 90 SFM의 절삭 속도가 권장됩니다.	기준: 6061-T6과 같은 알루미늄 합금의 일반적인 탭핑 작업에서 흔히 사용되는 시작 속도는 30~60 SFM입니다. 그러나 1100이나 3003과 같은 연질 합금은 종종 더 빠른 속도, 최대 75 SFM 이상 에서도 탭핑이 가능합니다. 지식 그래프: 알루미늄 탭핑 작업에는 100 SFM의 절삭 속도가 권장됩니다.	기준: 공구 직경이 0.5~1.0인치인 황동을 밀링할 때 권장되는 칩 부하는 일반적으로 날당 0.001~0.004인치 범위에 속합니다. 지식 그래프: 공구 직경이 0.5~1.0인치인 황동 밀링 작업의 경우, 회전당 0.004인치(ipr)의 칩 부하가 권장됩니다.
Gemini 2.0-flash-lite 기준선: 고속강(HSS) 드릴의 경우, 경화 상태의 4140강을 드릴링할 때 절삭 속도의 시작점은 일반적으로 분당 40~60 표면 피트(SFM) 범위입니다.		기준점: 대부분의 알루미늄 합금의 경우 절삭 속도의 시작점은 일반적으로 분당 50~200 표면 피트(SFM) 범위입니다. 지식 그래프: 알루미늄 탭핑 작업에는 100 SFM(분당 표면 피트)의 절삭 속도가 권장됩니다.	기준점: 공구 직경이 0.5~1.0인치인 황동을 밀링 가공할 경우, 칩 부하량은 0.003~0.010 IPT가 적절한 시작점입니다.
지식 그래프: 강철(4140) 드릴링 작업의 경우 권장 절삭 속도는 90 SFM입니다.		지식 그래프: 알루미늄 탭핑 작업에는 분당 100 표면 피트(SFM)의 절삭 속도가 권장됩니다.	지식 그래프: 공구 직경이 0.5~1.0인치인 황동 밀링 작업의 경우, 회전당 0.004인치(ipr)의 칩 부하가 권장됩니다.
GPT-4o	기준: 일반적으로 브리넬 경도가 150~200 정도인 어닐링 처리된 AISI 4140 강철의 경우, 고속강(HSS) 드릴 비트를 사용할 때 권장 절삭 속도는 보통 분당 70~100 표면 피트(SFM) 범위입니다. 지식 그래프: 4140강에 대한 드릴링 작업에는 90 SFM의 절삭 속도가 권장됩니다.	기준: 알루미늄 탭 가공에 권장되는 절삭 속도는 일반적으로 분당 75~150 표면 피트(SFM)입니다. 지식 그래프: 알루미늄 탭핑 작업에는 분당 100 표면 피트(SFM)의 절삭 속도가 권장됩니다.	기준: 공구 직경이 0.5~1.0인치인 황동의 일반적인 밀링 작업의 경우, 일반적인 칩 부하 권장 범위는 분당 약 0.002~0.010인치(IPT)입니다. 지식 그래프: 공구 직경이 0.5~1.0인치인 황동 밀링 작업 시 권장 칩 부하는 회전당 0.004인치(ipr)입니다.
GPT-4o-mini	기본 사항: 일반적으로 4140강에 대한 드릴링 작업 시 고속강(HSS) 드릴 비트를 사용할 경우 60~100 SFM 범위의 절삭 속도가 권장됩니다. 지식 그래프: 강철(4140) 드릴링 작업의 경우 권장 절삭 속도는 분당 90 표면 피트(SFM)입니다.	기준: 대부분의 알루미늄 합금의 경우, 탭핑 속도에 대한 일반적인 권장 범위는 100~300 SFM입니다. 지식 그래프: 알루미늄 탭핑 작업 시 권장 절삭 속도는 분당 100 표면 피트(SFM)입니다.	기준치: 비교적 부드럽고 연성이 좋은 재질인 황동의 경우, 권장되는 칩 부하량은 일반적으로 치아당 0.002~0.008인치 범위에 속합니다. 지식 그래프: 공구 직경이 0.5~1.0인치인 황동 밀링 작업 시 권장 칩 부하는 회전당 0.004인치(ipr)입니다.

각 표에 대해 지식 그래프로 보강된 값은 녹색으로 표시되어 있습니다. 오픈 소스 모델의 경우, 기본 출력값은 일반적으로 Llama 3.2 3B Instruct가 분당 표면 피트(SFM) 60~120 SFM, Llama 3.1 8B Instruct가 50~300 SFM과 같이 광범위한 값을 제시합니다. 이러한 넓은 범위는 불확실성과 일반적인 지침에 대한 의존성을 반영하며, 사용자가 기술 문서에 명시된 최적의 공정 매개변수를 결정할 수 있도록 해주지 않습니다. 그러나 LLM에 지식 그래프 정보를 추가하면, 이러한 모델은 4140강 드릴링의 경우 90 SFM, 알루미늄 탭핑의 경우 100 SFM, 황동 밀링의 경우 회전당 칩 부하 0.004인치(IPR)라는 정확한 권장값으로 수렴하여 실제 결과와 일치합니다. 이처럼 모호한 범위에서 명확하게 정의된 단일 값으로의 변화는 도메인별 정보의 교정 효과를 보여줍니다. 폐쇄형 소스 LLM은 유사한 경향을 보이며, 매개변수 권장 사항을 자주 제공합니다.

광범위한 범위는 내재된 불확실성과 산업별 기술 표준의 부족을 반영합니다. 그러나 지식 그래프를 추가하면 모델은 다시 올바르게 권장되는 공정 매개 변수로 수렴합니다.

개방형 모델과 폐쇄형 모델을 비교해 보면, 모든 모델이 드릴링, 탭핑, 밀링과 같은 작업에 대해 광범위하고 부정확한 매개변수 범위를 권장하는 경향이 있음을 알 수 있습니다. 모델의 크기나 구조와 관계없이, 기본 출력값은 재료 특성과 정밀한 가공 요구 사항을 고려하지 않은 넓은 범위를 일관되게 보여줍니다.

이는 모델의 내재적인 복잡성과 규모가 도메인별 가공 표준에 대한 정확한 내부 표현으로 반드시 이어지지 않는음을 시사합니다. 요약하자면, 지식 그래프 정보를 통합하지 않으면 출력 결과가 너무 일반적이어서 최적의 매개변수 선택을 안내하기 어렵습니다. 따라서 구조화된 도메인별 데이터를 통합하는 것이 출력 결과를 제한하고 검증된 제조 표준에 맞춰 공정 매개변수를 조정하는 데 필수적입니다.

6. 결론

본 논문에서는 의미론적으로 풍부한 자동 구축 지식 그래프를 모든 대규모 언어 모델(LLM)과 결합하여 기술적으로 정확하고 수치적으로 타당한 답변을 제공하는 하이브리드 LLM 비의존적 파이프라인인 ARKNESS(Augmented Retrieval Knowledge Network Enhanced Search and Synthesis)를 소개합니다. ARKNESS는 문단 수준의 엔티티-관계 추출을 통해 추적 가능하고 기술 정보에서 검증된 답변을 제공합니다. 이 추출 과정은 다양한 문서 형식을 원래의 문맥 정보를 유지하면서 트리플로 변환합니다. 그런 다음, 지식 그래프를 관계형 데이터베이스에 저장하여 벡터 임베딩 검색과 범 검색을 활용하여 가장 관련성이 높은 트리플과 문맥 정보를 검색함으로써 LLM이 사용자 쿼리에 대해 정확하고 기술적으로 검증된 답변을 제공하도록 최적화합니다. 콘텐츠별 및 기계 가공별 쿼리에 대한 객관식 문제 실험 결과, 정확도는 최대 25%, F1 점수는 최대 22.4% 향상되었습니다. 개방형 질문의 경우, ROGUE-L 점수가 최대 8.1배까지 향상되는 것은 이 프레임워크가 실제 답변에 비해 생성된 응답의 구조적 및 의미적 정보를 개선함을 보여줍니다. 이러한 장점은 LLM에서 흔히 발생하는 착각을 제거하여 CNC 가공 환경에서의 공정 계획 및 유용성을 향상시킵니다. 향후 연구에서는 ARKNESS를 이기종 멀티모달 지식 그래프로 확장하여 사실적 근거를 더욱 강화하고 첨단 제조 환경에서 폐쇄 루프 의사결정 지원을 가능하게 하는 데 집중할 것입니다.

이해 충돌 신고

저자들은 본 논문에 보고된 연구 결과에 영향을 미칠 수 있는 어떠한 경쟁적인 재정적 이해관계나 개인적인 관계가 없음을 밝힙니다.

감사의 말씀

본 연구는 미국 육군 개발사령부 지상 차량 시스템 센터(GVSC)와의 협력 협정 W56HZV-21-2-0001에 따라 자율 주행 가능 지상 시스템 가상 프로토타이핑(VIPR-GS) 프로그램을 통해 지원되었습니다.

배포 승인 A. 공개 배포 승인; 배포 제한 없음. OPSEC9768

참고 자료

- [1] M. Wiessner, P. Blaser, S. Böhl, J. Mayr, W. Knapp, K. Wegener, 5축 공작기계용 열 테스트 부품, 정밀공학 52(2018) 407–417.
- [2] D. Hoang, H. Errahmouni, H. Chen, S. Rachuri, N. Mannan, R. ElKharboutly, M. Imani, R. Chen, F. Imani, 가공 공정의 가속 품질 모니터링을 위한 계층적 표현 및 해석 가능한 학습, CIRP Journal of Manufacturing Science and Technology 50(2024) 198–212.
- [3] Z. Chen, D. Hoang, R. Chen, F. Imani, 제조 분야의 실시간 데이터 집계 및 해석 가능한 품질 모니터링을 위한 분산형 초차원 컴퓨팅, ASME 국제 기계 공학 학술대회 및 박람회, 88605권, 미국 기계 공학회, 2024, V002T03A092페이지.
- [4] Z. Li, Y. Dai, Z. Sun, CL Guan, T. Lai, H. Xu, X. Zhou, 장거리 이동 금속 가이드웨이의 서브마이크론 정밀 가공 및 측정 방법, 제조 공정 저널 133(2025) 947–956.
- [5] ForInsights Consultancy, 컴퓨터 수치 제어(CNC) 기계 시장 예측 2030, <https://www.forinsightsconsultancy.com/reports/computer-numerical-control-cnc-machine-market/>, 2023년. 접속일: 2025년 5월 12일.

- [6] D. Hoang, N. Mannan, R. ElKharboutly, R. Chen, F. Imani, 애지 인지 데이터 융합: 하이브리드 제조 공정에서 현장 감지에서 품질 특성화까지, 국제 제조 과학 및 공학 컨퍼런스, 87240권, 미국 기계 공학회, 2023, V002T06A029페이지.
- [7] D. Hoang, H. Chen, M. Imani, R. Chen, F. Imani, 간략 논문: 부품의 기하학적 편차와 가공 역학을 상호 연결하기 위한 다중 작업 뇌에서 영감을 받은 학습, 국제 제조 과학 및 공학 컨퍼런스, 88117권, 미국 기계 공학회, 2024, p. V002T05A012.
- [8] K. Spanaki, D. Dennehy, T. Papadopoulos, R. Dubey, 운영 및 공급망 관리의 데이터 기반 디지털 전환, 2025.
- [9] Siemens AG, 2022년 다운타임의 실제 비용, 기술 보고서, Siemens, 2022. URL: [https:// assets.new.siemens.com/siemens/assets/api/uuid:3d606495-dbe0-43e4-80b1-d04e27ada920/ dics-b10153-00-7600truecostofdowntime2022-144.pdf](https://assets.new.siemens.com/siemens/assets/api/uuid:3d606495-dbe0-43e4-80b1-d04e27ada920/dics-b10153-00-7600truecostofdowntime2022-144.pdf).
- [10] NC Nwasuka, U. Nwaiwu, 컴퓨터 기반 생산 계획, 일정 관리 및 제어: 개요, Journal of 공학 연구 12(2024) 275-280.
- [11] M. Raza, Z. Jahangir, MB Riaz, MJ Saeed, MA Sattar, 대규모 언어 모델의 산업 응용, 과학보고서 15(2025) 13755.
- [12] K. Ket, D. Potocniĳ, M. Ficko, S. Klanĳnik, ĳatgpt를 사용한 CNC 가공에서 g-코드 프로그래밍 향상: gpt-3.5와 gpt-4.0의 비교 연구, SSRN 4940034(2024)에서 이용 가능.
- [13] J. Jeon, Y. Sim, H. Lee, C. Han, D. Yun, E. Kim, SL Nagendra, MB Jun, Y. Kim, SW Lee 등, Chatcnc: 대규모 언어 모델 및 실시간 데이터 검색 증강 생성을 통한 대화형 기계 모니터링, Journal of Manufacturing Systems 79(2025) 504-514.
- [14] R. Rosati, F. Antonini, N. Muralikrishna, F. Tonetto, A. Mancini, 도메인별 llms 미세 조정을 통한 산업용 질문 답변 챗봇 개선, 2024년 제20회 IEEE/ASME 국제 메카트로닉 및 임베디드 시스템 및 응용 컨퍼런스(MESA), IEEE, 2024, pp. 1-7.
- [15] S. Kanimozhi, Y. Sriker 등, 현장 컴퓨터 수치 제어 기계 운영자 지원을 위한 미세 조정된 대규모 언어 모델의 탐색적 배포, 2024 IEEE Silchar Subsection Conference(SILCON 2024), IEEE, 2024, pp. 1-6.
- [16] Y. Xiao, S. Zheng, J. Shi, X. Du, J. Hong, 지식 그래프 기반 제조 공정 계획: 최첨단 검토, Journal of Manufacturing Systems 70(2023) 417-435.
- [17] P. Wen, Y. Ma, R. Wang, 지식 그래프 기반 제조 공정 계획을 위한 체계적인 지식 모델링 및 추출 방법, Advanced Engineering Informatics 58(2023) 102172.
- [18] D. Hoang, D. Gorsich, M. Castanier, F. Imani, 향상된 기억을 위한 벡터 기호 지식 그래프 디지털 제조에서의 추론 및 분석, SSRN 5097516(2025)에서 이용 가능.
- [19] L. Wang, H. Cheng, R. Wang, X. Huang, 공정 지식을 기반으로 한 특징 가공 계획 선택 그래프 및 개선된 코사인 유사도 매칭, 머신즈 13(2025) 188.
- [20] J. Guo, J. Wu, J. Bian, Q. He, 지식 그래프 기반 가공 공정 경로 생성 방법, in: 인간-컴퓨터 상호작용에 관한 국제 학술대회, Springer, 2023, 35-48쪽.
- [21] C. Cai, Z. Jiang, H. Wu, J. Wang, J. Liu, L. Song, 지능형 제조를 위한 지식 그래프 기반 장비 고장 진단 방법 연구, 국제 첨단 제조 기술 저널 130(2024) 4649-4662.
- [22] Y. Li, H. Zhao, H. Jiang, Y. Pan, Z. Liu, Z. Wu, P. Shu, J. Tian, T. Yang, S. Xu 등, 대규모 언어 모델 제조, arXiv 사전 인쇄본 arXiv:2410.21418 (2024).
- [23] P. Wang, J. Karigiannis, RX Gao, 지능형 유지 관리를 위한 대규모 언어 모델의 온톨로지 통합 튜닝, CIRP annals 73(2024) 361-364.
- [24] C. Qiu, B. Li, H. Liu, S. He, C. Hao, 지식 그래프 기반 공작기계 구조 상태 모니터링을 위한 새로운 방법, 국제 첨단 제조 기술 저널 120(2022) 563-582.
- [25] C. Auer, M. Lysak, A. Nassar, M. Dolfi, N. Livathinos, P. Vagenas, CB Ramis, M. Omenetti, F. Lindlbauer, K. Dinkla, et al., Docling 기술 보고서, arXiv 사전 인쇄본 arXiv:2408.09869(2024).
- [26] A. Hurst, A. Lerer, AP Goucher, A. Perelman, A. Ramesh, A. Clark, A. Ostrow, A. Welihinda, A. Hayes, A. Radford, et al., Gpt-4o 시스템 카드, arXiv 사전 인쇄본 arXiv:2410.21276 (2024).
- [27] M. Soori, FKG Jough, R. Dastres, B. Arezoo, 5축 CNC 밀링의 기능 및 과제에 대한 검토 공작기계 작업, 사전 출판본(2024).

- [28] Y. Ye, T. Hu, C. Zhang, W. Luo, 클라우드 기술을 이용한 CNC 가공 공정 지식 기반의 설계 및 개발, 국제 첨단 제조 기술 저널 94(2018) 3413–3425.
- [29] FN Guo, CNC 가공에서 산업용 로봇의 응용 탐구, 글로벌 인문사회과학 저널 4(2023) 231–235. URL: <http://ojs.bonfuturepress.com/index.php/GHSS/article/view/1499> . doi:doi:10.61360/BoniGHSS232014990503.
- [30] Autodesk, Inc., CNC 가공의 기초: 초보자를 위한 실용 가이드, 미국, 2014.
URL: https://academy.titansofcnc.com/files/Fundamentals_of_CNC_Machining.pdf 책상용 사본.
문서 번호: 060711.
- [31] I. Nugrahanto, H. Gunawan, H.-y. Chen, 지속 가능한 CNC 가공을 위한 혁신적인 접근 방식: 기계 학습 에너지 최적화에 대한 관점(2023).
- [32] M. Ihsan, Y. Sumantri, Y. Irawan, aa6061의 CNC 밀링 가공 매개변수 최적화를 위한 Taguchi 및 Promethee 통합, 국제 기계 공학 기술 및 응용 저널 5(2024) 96–107.
- [33] S. Zhang, J. Bai, CAD/CAM 기술 기반 CNC 프로그래밍 및 가공 공정 연구, 응용 수학 및 비선형 과학 9(2024) 1–18. URL: <https://doi.org/10.2478/amns-2024-0516>.
doi:doi:10.2478/amns-2024-0516.
- [34] H. Wu, X. Wang, X. Deng, H. Shen, X. Yao, 에너지 기반 CNC 공작기계 설계 연구 검토 소비, 지속가능성 16(2024) 847.
- [35] M. Soori, FKG Jough, R. Dastres, B. Arezoo, CNC 공작기계의 로봇 자동화: 개요, acta 기계 및 자동 18(2024).
- [36] Meta AI, Llama 3.2 모델 카드, https://github.com/meta-llama/llama-models/tree/main/models/llama3_2, 2024. 버전 3.2, 2024년 9월 25일 출시.
- [37] A. Grattafiori, A. Dubey, A. Jauhri, A. Pandey, A. Kadian, A. Al-Dahle, A. Letman, A. Mathur, A. Schelten, A. Vaughan, et al., 라마 3 모델 무리, arXiv 사전 인쇄본 arXiv:2407.21783 (2024).
- [38] A. Yang, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Li, D. Liu, F. Huang, H. Wei 등, Qwen2. 5 기술 보고서, arXiv 사전 인쇄본 arXiv:2412.15115 (2024).
- [39] Google DeepMind, Gemini 2.0 플래시, 2025. URL: <https://deepmind.google/technologies/gemini/플래시/>.
- [40] Google DeepMind, Gemini flash lite, 2025. URL: <https://deepmind.google/technologies/gemini/플래시라이트/>.