

LettuceDetect: RAG를 위한 환각 감지 프레임워크

응용 프로그램

아담 코바치¹, 가보르 레츠키^{1,2}

¹ KR 랩스

² TU Wien

lastname@krlabs.eu

firstname.lastname@tuwien.ac.at

추상적인

검색 증강 생성(RAG) 시스템은 외부 지식 소스를 통합했음에도 불구하고 여전히 왜곡된 답변에 취약합니다. 본 논문에서는 LettuceDetect를 소개합니다.

기존 환각 탐지의 두 가지 중요한 한계를 해결하는 프레임워크

방법: (1) 컨텍스트 창 제약 조건

기존의 인코더 기반 방식과

(2) LLM 기반 접근 방식의 계산 비효율성. Modern-BERT의 확장된 컨텍스트 기능(최대)을 기반으로 구축

8천 개의 토큰으로 구성되었으며 RAGTruth 데이터셋으로 학습되었습니다.

벤치마크 데이터셋에서 우리 접근 방식이 더 우수한 성능을 보였습니다.

이전의 모든 인코더 기반 모델과 대부분의 모델

프롬프트 기반 모델은 최고의 모델보다 약 30배 더 작습니다.

LettuceDetect는 토큰 분류 도구입니다.

문맥-질문-답변을 처리하는 모델

트리플을 사용하여 토큰 수준에서 지원되지 않는 클레임을 식별할 수 있습니다. 평가

RAGTruth 코퍼스에서 F1을 보여줍니다

예시 수준 탐지에서 79.22%의 점수를 받았습니다.

이는 루나에 비해 14.8% 향상된 수치입니다.

기존의 최첨단 인코더 기반 아키텍처보다 우수합니다. 또한,

이 시스템은 다음과 같은 작업을 처리할 수 있습니다.

단일 GPU에서 초당 30~60개의 예제 처리 가능.

실제 RAG 환경에서 더욱 실용적으로 사용할 수 있도록

응용 프로그램.

1. 서론

최근 몇 년 동안 대규모 언어 모델(LLM)은 여러 측면에서 상당한 발전을 이루었습니다.

성능 (OpenAI 외, 2024; Grattafiori 외, 2024; Team et al., 2024). 그러나 실제 응용 분야에서 이러한 기술을 사용하는 데 가장 큰 장애물은 다음과 같습니다.

환각을 경험하는 경향 (Kaddour et al., 2023)

Huang et al., 2025). 검색 증강 생성 (RAG)은 LLM을 향상시키는 방법입니다.

답변을 맥락 문서로 뒷받침하고 외부 자료에서 지식을 검색하도록 유도하여 학습자들이 자신의 답변을 근거에 기반하여 제시하도록 합니다.

이 정보 (Gao et al., 2024). 이 기술

LLM 환각을 최소화하기 위해 널리 사용됩니다.

맥락 문서를 통합했음에도 불구하고

RAG와 LLMs는 계속해서 환각 증상을 경험하고 있습니다.

(Niu et al., 2024).

환각은 다음과 같은 결과물로 정의됩니다.

터무니없거나, 사실과 다르거나, 일관성이 없는

제시된 증거에 따르면 (Ji et al., 2023). Ji

et al. (2023)은 이러한 오류를 두 가지 유형으로 분류합니다.

내재적 환각은 다음과 같은 원인에서 발생합니다.

모델의 내재적 지식과, 반응이 실패할 때 발생하는 외재적 환각

제공된 맥락에 근거해야 합니다. 예를 들어,

RAG 환각의 경우 (Niu et al., 2024).

RAG는 내재적 환각을 완화할 수 있지만

LLM을 외부 지식, 즉 외재적 지식에 기반을 두는 것

환각은 불완전한 회상 과정이나 모델이 외부 맥락보다 내재

적 지식을 우선시하는 경향 때문에 지속됩니다 (Sun et al.,

2025년), 사실과 모순되는 결과를 초래합니다. LLM으로서

환각에 취약한 상태로 남아 있는 경우, 환각을 활용하는 것은

의료 또는 법률 분야와 같은 고위험 환경

위험에 처할 수 있습니다 (Lozano et al., 2023; Magesh

et al., 2024).

우리는 환각인 LettuceDetect를 소개합니다.

ModernBERT를 활용하는 탐지 프레임워크

(Warner et al., 2024). 본 연구에서 제시하는 접근 방식은 토큰 분

류 모델을 학습시켜 토큰이 특정 유형인지 여부를 예측합니다.

맥락 문서와 질문을 통해 뒷받침됩니다.

그것이 환각인지 아닌지를 판단하는 것입니다. 우리는 이것을 다음과 같이 구성합니다.

생성된 답변에서 토큰을 예측하는 작업

대규모 언어 모델(LLM)을 기반으로,

제공된 컨텍스트 문서와 제시된 질문을 사용했습니다. 저희 모델은

RAGTruth를 사용하여 학습되었습니다.

데이터셋 (Niu et al., 2024). 우리가 사용하는 아키텍처

고용은 Luna와 유사합니다 (Belyi et al., 2025).

우리는 이 작업을 위해 인코더 기반 모델을 학습시킵니다.

당사 웹 애플리케이션의 데모 버전이 표시됩니다.

그림 1에서.

저희 시스템의 모든 구성 요소는 다음 라이선스 하에 배포됩니다. MIT 라이선스가 적용되며 GitHub에서 접근할 수 있습니다. pip 를 통해 lettuceDetect2를 설치하여 사용할 수도 있습니다. 패키지.

학습된 모델은 Hugging에 게시됩니다.

Face도 MIT 라이선스 하에 있습니다. 저희는 3개의 이미지를 제공합니다.

대형 모델도 가능 그리고 기본 모델로서, 우리⁴의 기여가 가치 있을 것이라고 믿습니다.

특히 많은 효과적인 것들이 있기 때문에 지역 사회는 환각 탐지 방법은 다음과 같습니다.

비허가적 라이선스를 사용하거나 더 큰 규모의 LLM 기반 모델에 의존합니다.

본 논문의 나머지 부분은 다음과 같이 구성됩니다. 2 절에서는 환각을 유발하는 최근 방법들을 검토합니다.

국가 탐지. 섹션 4에서는 본 방법론에 대해 자세히 설명합니다.

인코더 기반 환각 탐지 훈련

ModernBERT를 기반으로 구축된 모델입니다. 섹션 5에서 다음 내용을 제시합니다.

예시 및 범위 수준 과제에 대한 우리의 연구 결과 RAGTruth 데이터셋을 사용합니다.

2. 관련 연구

ModernBERT BERT (Devlin et al., 2019) 는 다음과 같습니다.

적용의 첫 번째 주요 성공 사례 중 하나

트랜스포머 아키텍처 (Vaswani et al., 2017)

자연어 이해. BERT는 자연어 이해만을 사용합니다. 트랜스포머의 인코더 블록은 양방향으로 작동합니다.

이러한 특징 덕분에 양방향에서 맥락을 학습할 수 있게 되었습니다. 그 결과, BERT는 빠르게 가장 인기 있는 알고리즘 중 하나가 되었습니다. NLP 파이프라인의 핵심 구성 요소로서 다음과 같은 작업에 사용됩니다. 분류, 질문 답변, 명명된 개체 인정 등

BERT의 초기 설계에는 최대 시퀀스 길이가 512로 제한되는 등의 몇 가지 제약 사항이 포함되어 있었습니다.

토큰과 효율성이 떨어지는 주의 메커니즘,

아키텍처 업그레이드 및 대규모 학습을 위한 여지를 남겨둡니다. NLP에서 LLM 기반 아키텍처의 인기가 현재 높아지고 있음에도 불구하고,

GPT-4 (OpenAI 외, 2024), Mistral (Jiang 등, 2023) 또는 Llama-3 (Grattafiori 등, 2024), 인코더 기반 모델은 여전히 많은 분야에서 널리 사용되고 있습니다.

크기가 훨씬 작기 때문에 응용 프로그램

그리고 추론 요구 사항에 더 적합한 것은 다음과 같습니다. 그것들은 실제 적용에 적합합니다.

ModernBERT (Warner et al., 2024) 는 최첨단 기술입니다.

1<https://github.com/KRLabsOrg/lettuceDetect>

2<https://pypi.org/project/lettuceDetect/>

3<https://huggingface.co/KRLabsOrg/lettuceDetect-라지-모던버트-en-v1>

4<https://huggingface.co/KRLabsOrg/lettuceDetect-베이스-모던버트-en-v1>



Let Us Detect Your Hallucinations

Context

France is a country in Europe. The capital of France is Paris. The population of France is 67 million.

Question

What is the capital of France? What is the population of France?

Answer

The capital of France is Paris. The population of France is 69 million.

Detect Hallucinations

The capital of France is Paris. The population of France is 69 million.

그림 1: Stream- lit5 로 구축된 애플리케이션의 웹 데모

이 프로그램에는 질문, 맥락, 그리고 세 가지 입력 필드가 있습니다.

답변. 출력 결과는 강조 표시된 환각을 보여줍니다.

범위.

최첨단 인코더 전용 트랜스포머 아키텍처

여러 가지 현대적인 디자인 개선을 통합했습니다.

기존 BERT 모델보다 우수합니다. 여러 가지 요소를 활용합니다.

기존 방식 대신 회전 위치 삽입(RoPE)을 포함한 개선 사항 (Su et al., 2024)

절대 위치 임베딩. 또한,

(Team et al., 2024) 에 설명된 바와 같이 지역-전역 주의 메커니즘이 교대로 작동하는 특징을 가지고 있어,

최대 8,192개의 시퀀스를 효율적으로 관리하기 위해

토큰을 사용합니다. 이렇게 하면 효율성이 훨씬 높아집니다.

현대 정보 검색 과 같은 장기 컨텍스트 작업의 경우

(Nussbaum et al., 2025; Zhang et al.,

2024). ModernBERT는 하드웨어 인식 기능을 제공합니다.

설계 및 텍스트와 코드 데이터를 포함하여 2조 개의 토큰으로 구성된 확장된 훈련 코퍼스.

결과적으로 다양한 측면에서 우수한 성능을 달성합니다.

분류를 위한 GLUE 및 검색을 위한 BEIR과 같은 하위 벤치마크 (동시에 더 빠른 추론 속도 유지) (Nussbaum et al.,

2025; Zhang et al., 2024). 이러한 연구 결과를 바탕으로,

본 논문의 주요 내용은 ModernBERT의 발전된 기술을 환각 탐지에 활용하는 것입니다.

RAG 환경에서 LLM의 구성. 이 영역에서,

장기적인 맥락 인식은 필연적인 특징입니다.

환각 탐지는 세분화 정도가 다양하며, 예시 기반 탐지

답변에 환각이 포함되어 있는지 평가합니다.

토큰, 스펠 또는 문장 수준 감지 (Niu et al., 2024). 환각을 감지하는 방법

또한 사용된 기술에 따라 차이가 있습니다.

프롬프트 기반 기법은 일반적으로 0을 사용합니다.

또는 소규모 대규모 언어 모델(LLM)을 사용하여 LLM이 생성한 응답에서 환각을 식별합니다.

소규모 데이터셋 또는 정밀하게 조정된 평가 프레임워크

RAGAS (Es et al., 2024), Trulens6 등, 그리고

ARES (Saad-Falcon et al., 2024) 가 등장했습니다.

LLM을 사용하여 대규모 환각 감지 기능을 제공합니다.

판사들. 하지만 실시간 예측은 여전히 어려운 과제입니다.

이러한 방법들에 대한 도전 과제. 다른 프롬프트 기반 SelfCheck- GPT (Manakul et al., 2023) 와 같은 제로샷 방식은 확률적 방법을 사용합니다.

다양한 응답 변형 간의 불일치를 식별하기 위한 샘플링입니다.

단일 프롬프트에 의존하는 대신, Chainpoll (Friel and Sanyal, 2023) 은 환각을 감지하기 위한 일련의 검증 단계를 구현합니다. Cohen et al. (2023) 은 다음과 같은 방법을 제시합니다.

두 LLM 간의 교차 심문을 통해 불일치를 밝혀내는 방법. Chang et al. (2024)

은 이를 활용했습니다.

합성 오류로 학습된 LLM 기반 분류기

환각과 커버리지 오류를 모두 감지하기 위해

LLM에서 생성된 응답에서.

정교하게 다듬어진 LLM 심사위원 접근 방식에는 다음이 포함됩니다.

특정 훈련 데이터를 사용하여 환각 탐지 작업에 대한 LLM을 훈련합니다. Niu et al. (2024) 은 뿐만 아니라 RagTruth 데이터셋을 소개했을 뿐만 아니라 다음과 같은 내용도 제시했습니다.

미세 조정된 Llama-2-13B LLM은 다음과 같은 결과를 달성했습니다.

테스트 세트에서 최첨단 성능을 보여주었으며, 심지어

GPT-4와 같은 더 큰 모델들을 능가합니다. RAG-HAT

(송 등, 2024) 은 새로운 접근 방식을 도입했습니다.

환각 인지 튜닝(HAT)이라고 불리는 것은

탐지 레이블을 생성하고 식별된 항목에 대한 자세한 설명을 제공하기 위해 모델을 훈련하는 과정이 포함됩니다.

환각. 그들은 선호도 데이터셋을 만들었다.

직접 선호 최적화(DPO)를 용이하게 하기 위해

훈련. DPO를 통한 미세 조정으로 SOTA를 달성합니다.

RAGTruth 테스트 세트에서의 성능.

인코더 기반 솔루션은 계산 효율성 제약 조건을 해결하는 데 중점을 둡니다.

도메인별 적응. RAGHalu (Zimmerman et al., 2024) 는 2단계 인코더를 사용합니다.

각 단계에서 이진 분류를 활용하는 모델

[6https://www.trulens.org/](https://www.trulens.org/)

레이어, 자연어 추론 미세 조정

(NLI) 모델은 DeBERTa (He et al., 2021)를 기반으로 합니다. 저희 연구와 가장 유사한 접근 방식은 Luna입니다.

(Belyi et al., 2025) 는 De-BERTa와 NLI를 기반으로 하여 경량의 장시간 컨텍스트 환각 탐지 시스템을 구축했습니다.

더 긴 맥락을 효과적으로 관리합니다. 루나는 그림을 그립니다.

NLI에서 함의를 감지하는 것 사이의 연결

그들은 과제를 수행하고 환각을 식별했습니다. 그들은 주석이 달린 질문 답변 기반 RAG 샘플로 구성된 대규모의 다양한 영역 코퍼스를 사용하여 미세 조정을 했습니다.

GPT-4에서 제공합니다. 추론 단계에서,

Luna는 문장 또는 토큰 수준의 검사를 수행합니다.

검색된 구절에 대한 각 모델의 응답을 분석하여 지원되지 않는 부분을 효과적으로 표시합니다.

FACTOID (Rawte et al., 2024) 는 사실적 함의(FE) 프레임워크를 도입했는데, 이는 다음을 나타냅니다.

새로운 형태의 텍스트 함의는 위치를 파악하는 것을 목표로 합니다.

토큰 또는 스펠 수준에서의 환각. 기타

ReDeEp (Sun et al., 2025) 과 같은 접근 방식은 모델의 내부 상태를 분석하는 기술을 도입합니다.

환각 감지를 위해.

3 데이터

우리는 다음을 사용하여 모델을 학습시키고 평가했습니다.

RAGTruth 데이터셋 (Niu et al., 2024). RAGTruth

이는 평가를 위한 최초의 대규모 벤치마크입니다.

RAG 환경에서의 환각. 데이터 세트는 스펠 레벨에서 주석이 달린 18,000개의 예제를 포함합니다.

세 가지 작업(질문 답변, 데이터-텍스트 변환)에 걸쳐 생성 및 뉴스 요약.

질문 답변 작업의 경우, MS MARCO 데이터셋 (Bajaj et al.,) 에서 데이터를 샘플링했습니다.

2018) 각 질문에는 최대 세 개의 대응 맥락이 있었습니다. 그런 다음 저자들은 다음과 같은 질문을 했습니다.

검색된 정보를 기반으로 답변을 생성하는 LLM

구절. 데이터-텍스트 생성 작업에서 LLM은

Yelp 공개 데이터 세트 (Yelp, 2021) 에서 표본으로 추출된 사업체에 대한 리뷰를 작성해 달라는 요청을 받았습니다.

뉴스 요약 작업을 위해 훈련 데이터 세트에서 무작위로 선택된 문서들을 사용했습니다.

CNN/데일리 메일 데이터 세트의 경우 (See et al., 2017 참조), 그리고 LLM 학생들은 요약을 작성하도록 요청받았습니다.

응답 생성을 위해 다양한 LLM이 사용되었습니다.

GPT-4-0613 (OpenAI 외)을 포함한 여러 기술이 사용되었습니다.

2024), Mistral-7B-Instruct (Jiang et al., 2023) 및 Llama 모델에서 선택한 항목들(예: Llama-2-7b-chat 및 Llama-2-13B-chat) (Grattafiori et al.,

2024). 데이터 세트의 각 샘플에는 각 모델에서 나온 하나의 응답이 포함되어 총 6개의 응답이 있습니다.

RAGTruth의 샘플당.

전체 데이터 세트는 인간 평가자가 직접 주석을 달았으며, 응답에 주석을 표시하고 그 이유를 설명했습니다. RAGTruth는 환각을 명백한 갈등, 미묘한 갈등, 근거 없는 정보의 명백한 도입, 근거 없는 정보의 미묘한 도입과 같은 유형으로 분류합니다. 본 연구에서는 학습 과정에서 이러한 특정 범주를 고려하지 않고 환각을 인식하는 이진 작업에만 집중했습니다. 데이터 세트의 예시는 표 1에서 확인할 수 있습니다.

우리는 RAGTruth를 토큰화했고 다음과 같은 사실을 발견했습니다. 평균 토큰 길이는 801개이며, 중앙값은 741개, 최소값은 194개, 최대값은 2632개입니다. 이는 환각을 효과적으로 감지하기 위해서는 ModernBERT와 같은 장문맥 모델이 필요함을 강조합니다.

질문	사분위수를 어떻게 설명해야 할까요?
참조	지문 2: 제2사분위수(Q2)는 중앙값으로 더 흔히 알려져 있으며, 데이터를 절반(50%)으로 나눕니다. 중앙값은 데이터를 하위 절반과 상위 절반으로 나눕니다. 제3사분위수(Q3)는 상위 사분위수라고도 하며, 데이터의 하위 75%(또는 상위 25%)를 나눕니다.
응답	... 제1사분위수(Q1)는 데이터의 하위 25%를 나누고, 제2사분위수(Q2)는 데이터를 두 개의 동일한 절반으로 나누며, 중앙값은 하위 절반의 중간값입니다. 마지막으로 제3사분위수(Q3)는 데이터의 상위 75%를 나눕니다.
주석	범위: 최고 75% 유형: 명백한 갈등 이유: 원문: "하위 75% 또는 상위 25%" 생성형: "상위 75%"

표 1: 질문, 참고 자료, 응답 및 주석을 포함한 RAGTruth 데이터의 예시.

4가지 방법

우리는 RAGTruth 데이터셋에서 토큰 분류기로 ModernBERT 기반 및 대규모 변형 모델을 학습시켰습니다.

입력 시퀀스는 특수 토큰([CLS]는 컨텍스트, [SEP]는 분리)을 사용하여 컨텍스트, 질문 및 답변 세그먼트를 연결하고 최대 4,096개의 토큰 길이로 토큰화하여 구성했습니다(현재 버전에서는 ModernBERT의 전체 8,192개 컨텍스트 길이를 모두 사용하지 않았습니다). 토큰화에는 AutoTokenizer (Wolf et al., 2020)를 사용했습니다. 저희 모델은 ModernBERT 아키텍처만을 기반으로 하며, 이전의 인코더 기반 아키텍처와는 달리 자연어 처리 (NLI) 작업에 대한 사전 학습을 거치지 않았습니다.

이 아키텍처는 Hugging Face의 기능을 활용했습니다. 토큰 분류를 위한 자동 모델 (Wolf et al., 2020) ModernBERT를 기반으로 하고 그 위에 분류 헤드를 탑재했습니다. 문맥/질문 토큰은 마스킹(레이블=-100)되었고, 답변 토큰은 다음과 같이 레이블이 지정되었습니다.




그림 2: LettuceDetect의 아키텍처. 이 그림은 질문, 맥락, 답변으로 구성된 트리플릿을 아키텍처 입력으로 사용하는 예시를 보여줍니다. 토큰화 단계를 거친 후, 토큰들은 토큰 수준 분류를 위해 LettuceDetect에 입력됩니다. 질문과 맥락의 토큰들은 손실 계산을 위해 마스킹 처리됩니다(빨간색 선으로 표시). LettuceDetect의 출력에는 각 답변 토큰에 대한 확률이 제공됩니다. 출력 유형이 스파ن 수준인 경우, 스파ن 수준 출력을 위해 이후 토큰들을 집계합니다.

0(자원됨) 또는 1(환각됨)으로 설정했습니다. 학습에는 NVIDIA A100 GPU에서 6 에포크 동안 AdamW 최적화 (Loshchilov and Hutter, 2019)를 사용했습니다 (학습률 1×10^{-4} , 가중치 감소 0.01). 데이터 및 배치 처리는 PyTorch DataLoader (Paszke et al., 2019)를 사용했습니다 (배치 크기=8, 서플링 활성화). 토큰 수준의 F1 점수를 사용하여 모델을 평가했으며, 가장 성능이 좋은 체크포인트를 safetensors를 통해 저장했습니다.

동적 패딩은 다음을 사용하여 구현되었습니다.

토큰 분류용 데이터 수집기

가변 길이 시퀀스를 효율적으로 처리하기 위해.

최종 모델은 각 답변 토큰에 대한 환각 확률을 예측하며, 연속된 토큰 중 0.5 이상의 신뢰도 임계값을 만족하는 토큰들을 집계하여 스파ن 레벨 출력을 생성합니다. 최적의 모델들은 huggingface에 업로드됩니다. 본 연구 방법은 그림 2에서 확인할 수 있습니다. 결과는 5절에서 논의합니다.

5. 평가

우리는 질문 및 답변을 포함한 모든 작업 유형에 걸쳐 RAGTruth 테스트 데이터를 사용하여 모델을 평가합니다.

방법	질문 답변, 데이터-텍스트 변환, 요약 작성, 정확성									전반적인		
	녹음	F1 기록	정밀도	F1	정밀도	녹음	F1	정밀도	녹음	F1		
Promptgpt-3.5-turbo	18.8	84.4	30.8	65.1	95.5	77.4	23.4	89.2	37.1	37.1	92.3	52.9
Promptgpt-4-turbo	33.2	90.6	45.6	64.3	100.0	78.3	31.5	97.6	47.6	46.9	97.9	63.4
SelCheckGPTgpt-3.5-turbo	35.0	58.0	43.7	68.2	82.8	74.8	31.1	56.5	40.1	49.7	71.9	58.8
LMvLMgpt-4-turbo	18.7	76.9	30.1	68.0	76.7	72.1	23.2	81.9	36.2	36.2	77.8	49.4
Finetuned Llama-2-13B RAG-HAT	61.6	76.3	68.2	85.4	91.0	88.1	64.0	54.9	59.1	76.9	80.7	78.7
	76.5	73.1	74.8	92.9	90.3	91.6	77.7	59.8	67.6	87.3	80.8	83.9
제인플그프-3.5-터보 라가	33.5	51.3	40.5	84.6	35.1	49.6	45.8	48.0	46.9	54.8	40.6	46.7
스 충실함 트롤렌스 안정감 루	31.2	41.9	35.7	79.2	50.8	61.9	64.2	29.9	40.8	62.0	44.8	52.0
나	22.8	92.5	36.6	66.9	96.5	79.0	40.2	50.0	44.5	46.5	85.8	60.4
	37.8	80.0	51.3	64.9	91.2	75.9	40.0	76.5	52.5	52.7	86.1	65.4
lettucedetect-base-v1	60.64	71.25	65.93	65.52	89.30	86.53	87.89	53.89	47.55	64.04	50.52	76.64
lettucedetect-large-v1	75.00		70.18	90.45	86.70	88.54	55.88		59.69		80.44	75.50
											76.07	79.22

표 2: 다양한 작업에 걸쳐 예제 수준에서의 성능 비교. 우리의 결과를 모델들과 비교했습니다. Luna (Belyi et al., 2025) 및 RAGtruth (Niu et al., 2024) 및 평가 프레임워크 RAGAS 에 제시된 그리고 Trulens도 포함됩니다. 평가에는 RAG-HAT (Song et al., 2024) 논문 에서 가져온 미세 조정된 LLM도 포함됩니다.

방법	질문 답변, 데이터-텍스트 변환, 요약 작성, 정확성									전반적인		
	녹음	F1 기록	정밀도	F1	정밀도	녹음	F1	정밀도	녹음	F1		
Prompt Baselinegpt-3.5-turbo	7.9	25.1	12.1	8.7	45.1	14.6	6.1	33.7	10.3	7.8	35.3	12.8
Prompt Baselinegpt-4-turbo	23.7	52.0	32.6	17.9	66.4	28.2	14.7	65.4	24.3	18.4	60.9	28.3
Finetuned Llama-2-13B	55.8	60.8	58.2	56.5	50.7	53.5	52.4	30.8	38.6	55.6	50.2	52.7
레투세디텍트-베이스-v1	62.65	60.40	61.50	58.24	56.57	57.39	52.98	28.08	60.17	36.71	59.36	52.01
상추 감자-대형-v1	66.85	62.14	64.41	64.71	55.99	60.04	35.47		44.63	64.92	53.96	58.93

표 3: 다양한 작업에 걸쳐 스펙 수준에서의 성능 비교. 우리는 우리의 결과를 모델들과 비교했습니다. RAGTruth (Niu et al., 2024)에 제시된 내용입니다. 다른 연구에서는 다루지 않았기 때문에 본 비교는 이 논문들에 한정합니다. 범위 수준 과제에서 그들의 수행 능력을 평가했습니다.

답변(QA), 데이터-텍스트 변환 및 요약. (Niu et al.,) 에 설명된 방법론을 따릅니다. 2024년), 우리는 예시 수준과 범위 수준 모두를 보고합니다. 탐지 성능, 보고 정밀도, 재현율 그리고 F1 점수입니다. 저희 모델은 다음과 비교됩니다. (Niu et al.,) 에 제시된 최첨단 기준선 2024년; 송 외, 2024; Belyi et al., 2025). 이것 프롬프트 기반 방법과의 비교를 포함합니다. gpt-4-turbo 및 gpt-3.5-turbo와 같은 것들뿐만 아니라 최첨단 성능을 보여준 정밀하게 조정된 LLM RAGTruth 데이터에 대한 성능(다음 사항 포함) 이전에 확립된 최첨단 모델 (Niu et al., 2024) (정밀 조정된 Llama-2-13B) 및 현재까지 가장 좋은 결과는 (Song et al., 2024) 에서 나왔습니다. (Llama-3-8B 학습 기반의 미세 조정된 LLM) DPO 훈련을 통해) 우리 모델 을 우리와 유사한 인코더 기반 접근 방식과 비교합니다. 토큰 분류기 방법을 포함하여 제시된 내용을 포함합니다. (Belyi et al., 2025), 이는 DeBERTa를 기반으로 합니다.

표 2는 예제 수준 작업에 대한 결과를 보여줍니다. 저희의 대규모 모델 (lettucedetect-large-v1)은 모든 프롬프트 기반 방법보다 우수한 성능을 보였습니다(gpt-4-turbo는 전체 F1 점수 63.4%를 달성했습니다).

lettucedetect-large-v1의 79.22%와 비교했을 때, 또한 기존의 최첨단 인코더 기반 모델인 Luna (65.4% 대 79.22%) 를 능가하며, 이전에 확립된 최첨단 정밀 조정

(Niu et al., 2024) 에 제시된 LLM (미세 조정됨) Llama-2-13B는 78.7% 대 79.22%의 비율을 보였습니다. 유일한 우리의 대형 모델보다 성능이 뛰어난 모델 현재 최첨단 정밀 조정 LLM 기반입니다. RAG-HAT 논문에 제시된 Llama-3-8B에 대한 내용입니다. (송 등, 2024) (83.9% 대 79.22%). 우리의 기본 모델(lettucedetect-base-v1)은 또한 다양한 작업에서 뛰어난 성능을 보여줍니다. 큰 모델의 절반 크기입니다. 저희의 상황을 고려해 보세요. 모델의 컴팩트한 크기 (기본 모델의 경우 150M) (대형 모델의 경우 396M) 및 최적화된 ModernBERT 기반 아키텍처를 사용하여 다음과 같은 기능을 수행할 수 있습니다. 약 30~60개의 예제를 처리합니다. 단일 GPU에서 초당. 이러한 최적화된 성능을 고려할 때 추론 속도 면에서는 다른 제품에 비해 다소 뒤쳐질 뿐입니다. 더 큰 모델(8B 라마). 전반적으로 저희 모델은 다음과 같습니다. 크기는 약 30배 작으면서 효율성은 매우 뛰어납니다. 크기 면에서.

표 3에서는 범위 수준 작업에 대한 결과를 제시합니다. 이 작업에서는 중복도를 평가합니다. 금 함량 범위와 예측 범위 사이. RAGTruth 논문에 따라 우리는 측정했습니다. 문자 수준 중복 및 계산된 정밀도, 재현율과 F1 점수를 기준으로 평가했을 때, 저희 모델은 Llama-2-13B 모델을 통해 최첨단 성능을 달성했습니다. 우리는 전반적인 F1 점수 52.7%를 달성했습니다. 대형 모델이 58.93%의 F1 점수를 달성했습니다.

참고로, RAG-HAT은 이 수준에서 측정 하지 않았기 때문에 저희 결과를 RAG-HAT과 비교할 수 없었습니다 . 또한, RAGTruth는 공개된 코드에 이 평가 항목을 포함하지 않았으므로, 저희는 자체 구현을 통해 이 분석을 수행했습니다 .

6. 결론

본 논문에서는 RAG 시스템 에서 환각을 탐지하기 위한 경량의 효율적인 프레임워크 인 LettuceDetect를 소개합니다 . ModernBERT의 장 문맥 처리 기능을 활용하여, 본 프레임워크의 기본 모델은 RAGTruth 벤치마크에서 우수한 성능을 달성 하는 동시에 추론 환경에서도 높은 효율성을 유지합니다. 본 연구는 향후 연구의 토대가 되며, 더 많은 데이터셋, 추가 언어 및 향상된 아키텍처를 포함하도록 프레임워크를 확장할 계획입니다. 현재 버전에서도 LettuceDetect는 효과적인 환각 탐지가 가능하다는 것을 보여줍니다.

간결하고 목적에 맞게 설계된 모델을 사용합니다.

참고 자료

파얌 바자즈, 다니엘 캄포스, 닉 크래스웰, 리 덩, Jianfeng Gao, Xiaodong Liu, Rangan Majumder, 앤드류 맥나마라, 바스카르 미트라, 트리 응우옌, 미르 로젠버그, 샤 송, 알라나 스토티카, 사우라브 티와리, 그리고 통 왕. 2018. [마르코 씨: 인간 기계가 생성한 독해 데이터 세트](#). 사전출판본, arXiv:1611.09268.

마샤 벨리, 로버트 프리엘, 슈아이 샤오, 아틴드리요 사니알. 2025. [루나: 경량 평가 모델 높은 수준의 언어 모델 환각을 포착하기 위해 정확성과 저렴한 비용](#). 제31차 회의록에서 국제 전산언어학 학술대회 : 산업 트랙, 398~409쪽, 아부다비,

UAE 전산언어학회.

타일러 A. 창, 카트린 토마넥, 제시카 호프만, Nithum Thain, Erin MacMurray van Liemt, Kathleen 마이어-헬스틴(Meier-Hellstern), 루카스 딕슨(Lucas Dixon). 2024. [감지 논란이 되는 주제에 대한 검색 증강 생성에서 발생하는 환각 및 커버리지 오류](#). 2024년 공동 국제 학술대회 논문집

전산언어학, 언어자원 분야 및 평가(LREC-COLING 2024), 4729페이지~4743, 토리노, 이탈리아. ELRA 및 ICCL.

Roi Cohen, May Hamri, Mor Geva, and Amir Globerson . 2023. [LM vs LM: Detecting factual errors via 반대 심문](#). 2023년 자연어 처리 분야 경험적 방법론 학술대회 논문집 Processing, 페이지 12621–12640, 싱가포르. 전산언어학협회.

제이콥 데블린, 밍웨이 창, 켄튼 리, 그리고 크리스티나 투타노바. 2019. [BERT: 사전 훈련 언어 이해를 위한 심층 양방향 변환기](#). 2019년 학술대회 논문집

협회의 북미 지부 계산언어학: 인간 언어 기술, 제1권(장편 및 단편 논문), 페이지 4171–4186, 미니애폴리스, 미네소타. 협회 전산언어학 분야를 위해서.

샤홀 에스(Shahul Es), 지틴 제임스(Jithin James), 루이스 에스피노사 안케(Luis Espinosa Anke), 스티븐 쇼카에르트. 2024. [RAGAS: 검색 증강 생성의 자동 평가](#). 제18 회 유럽 지부 학술대회 논문집

전산언어학회 회원: 시스템 시연, 150~158페이지, 세인트 줄리안스, 몰타. 전산언어학 협회.

로버트 프리엘(Robert Friel)과 아틴드리요 사날(Atindriyo Sanyal). 2023. [체인플: LLM 환각 탐지를 위한 고효율 방법](#). 사전출판본, arXiv:2310.18344.

Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Meng Wang, Haofen Wang. 2024. 대규모 언어 모델을 위한 [검색 증강 생성 : 설문 조사](#). 출판 전 논문, arXiv:2312.10997.

아론 그라타피오리, 아비마뉴 두베이, 아비나브 자우리, 아비나브 판데이, 아비셰크 카디안, 아마드 알-달레, 아이샤 레트만, 아킬 마투르, 앨런 셀튼,

알렉스 본, 에이미 양, 안젤라 팬, 아니루드 고얄, 앤서니 하트쇼른, 아오보 양, 아치 미트라, 아치 스라반쿠마르, 아르템 코레네프, 아서 힌스바크와 542마리 외. 2024년. [라마 3 무리 모델들](#). 사전출판본, arXiv:2407.21783.

He Pengcheng, Liu Xiaodong, Jianfeng Gao 등 웨이주 첸. 2021. [데버타: 디코딩 - 분리된 주의력을 통해 향상된 bert](#). 출판 전 논문, arXiv:2006.03654.

레이 황, 웨이장 유, 웨이타오 마, 웨이홍 중, Zhangyin Feng, Haotian Wang, Qianglong Chen, 웨이화 팡, 샤오청 평, 빙 친, 텡 Liu. 2025. [대규모 언어 모델에서의 환각 현상에 대한 조사 : 원칙, 분류, 과제 및 미해결 질문들](#). ACM 정보 거래 시스템, 43(2):1–55.

Ziwei Ji, 아나연, Rita Frieske, Tiezheng Yu, Dan 수, 안 쉬, 이시이 에츄코, 방예진, 안드레아 Madotto와 Pascale Fung. 2023. [자연어 생성에서 의 환각 현상에 대한 조사](#). ACM 컴퓨팅 Surv., 55(12).

알버트 Q. 장, 알렉산드르 사블레이롤, 아서 멘슈, 크리스 뱅포드, 데벤드 라 싱 사플룻, 디에고 드 라스 카사스, 플로리안 브레상, 지아나 령겔, 기욤 램플(Guillaume Lample), 루실 솔니에(Lucile Saulnier), 펠리오 르나르 라보(Lélio Re-nard Lavaud), 마리-앤 라쇼(Marie-Anne Lachaux), 피에르 스톡(Pierre Stock), Teven Le Scao, Thibaut Lavril, Thomas Wang, Timothée Lacroix 및 William El Sayed. 2023. [미스트랄 7b](#). 사전출판본, arXiv:2310.06825.

진 카두르, 조슈아 해리스, 막시밀리안 모제스, 허비 브레들리, 로버타 라일레아누, 로버트 맥하디. 2023. [대규모 언어의 과제와 응용 모델들](#). 사전출판본, arXiv:2307.10169.

일리아 로칠로프와 프랭크 휘터. 2019. [분리 된 가중치 감소 정규화](#). 출판 전 논문, arXiv:1711.05101.

알레한드로 로자노, 스콧 L 플레밍, 치아춘 치앙, 니감 샤푸(Nigam Shah). 2023. [Clinfo.ai: 오픈 소스 검색 기능이 강화된 대규모 언어 모델 시스템 과학 문헌을 활용하여 의학적 질문에 답하기](#). 사전출판본, arXiv:2310.16146.

Varun Magesh, Faiz Surani, Matthew Dahl, Mirac Suzgun , Christopher D. Manning 및 Daniel E. Ho. 2024. [환각 없는가? 주요 AI 법률 연구 도구의 신뢰성 평가](#). 출판 전 논문, arXiv:2405.20362.

포사위 마나쿨, 아디안 류지, 마크 게일스. 2023. [SelfCheckGPT: 생성형 대규모 언어를 위한 제로 리소스 블랙박스 환각 탐지 모델들](#). 2023년 컴퍼런스 회의록에서 자연어 처리의 경험적 방법론, 9004~9017쪽, 싱가포르. 협회

계산언어학. Cheng Niu, Yuanhao Wu, Juno Zhu, Siliang Xu, KaShun Shum, Randy Zhong, Juntong Song 및

Tong Zhang. 2024. RAGTruth: 신뢰할 수 있는 검색 증강 시스템 개발을 위한 환각 코퍼스 언어 모델. 제62회 전산공학회 연례 회의 회의록

언어학(제1권: 장편 논문), 10862쪽~10878, 방콕, 태국. 전산언어학회 .

잭 누스바움, 존 X. 모리스, 브랜든 듀더슈타트, 그리고 Andriy Mulyar. 2025. Nomic 임베드: 훈련 재현 가능한 장문 문맥 텍스트 임베드. 출판 전 논문, arXiv:2402.01613.

OpenAI, 조쉬 아치암(Josh Achiam), 스티븐 아들러(Steven Adler), 산디니 아가르왈(Sandhini Agarwal), Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman , Diogo Almeida, Janko Altenschmidt, Sam Alt-man, Shyamal Anadkat, Red Avila, Igor Babuschkin, 수치르 발라지, 발레리 발콤, 폴 발테스쿠, 하임 잉 바오, 모하마드 바바리안, 제프 벨검, 그리고 262개 기타. 2024. GPT-4 기술 보고서. 출판 전 논문, arXiv:2303.08774.

아담 패스케, 샘 그로스, 프란시스코 마사, 아담 레러, 제임스 브래드버리, 그레고리 차난, 트레버 킬린, 제밍 린, 나탈리아 가멜세인, 루카 안티가, 알반 데스메중, 안드레아스 쿠피, 에드워드 Yang, Zach DeVito, Martin Raison, Alykhan Tejani , Sasank Chilamkurthy, Benoit Steiner, Lu Fang, 그리고 다른 2명. 2019. PyTorch: 명령형 스타일, 고성능 딥러닝 라이브러리. 출판 전 논문, arXiv:1912.01703.

Vipula Rawte, S. M Towhidul Islam Tonmoy, Krishnav Rajbangshi, Shravani Nag, Aman Chadha, Amit P. 세스, 아마타바 다스. 2024. 팩트이드: 사실적 환각 탐지에 대한 합의. 출판 전 논문, arXiv:2403.19113.

존 사드-팔콘, 오마르 카탐, 크리스토퍼 포츠, 그리고 마테이 자하리아. 2024. Ares: 검색 증강 생성을 위한 자동 평가 프레임워크 시스템. 사전출판본, arXiv:2311.09476.

애비게일 시, 피터 J. 류, 그리고 크리스토퍼 D. 매닝. 2017. 핵심만 전달하기: 포인터 생성기 네트워크를 이용한 요약. 제55회 전산공학회 연례 회의 회의록

언어학(제1권: 장편 논문), 1073쪽~1083, 밴쿠버, 캐나다. 전산언어학회 .

송준통, 왕싱광, 주노, 위안하오 Wu, Xuxin Cheng, Randy Zhong 및 Cheng Niu. 2024. RAG-HAT: 환각을 인지하는 튜닝 검색 증강 생성에서 LLM을 위한 파이프라인. 2024년 실증적 연구 컨퍼런스 회의록 자연어 처리 방법론: 산업 트랙, 1548~1558페이지, 마이애미, 플로리다, 미국. 전산언어학 협회.

Jianlin Su, Murtadha Ahmed, Yu Lu, Shengfeng Pan, Wen Bo, and Yunfeng Liu. 2024. Roformer: 회전 위치 내장 기능이 강화된 변압기. 신경 컴퓨팅, 568:127063.

Zhongxiang Sun, Xiaoxue Zang, Kai Zheng, Yang Song, Jun Xu, Xiao Zhang, Weijie Yu, Yang Song 및 한리. 2025. 리답: 환각 탐지 기계적 해석 가능성을 통한 검색 증강 생성 . 사전출판본, arXiv:2410.11414.

젤마 팀, Morgane Riviere, Shreya Pathak, 피에르 주세페 세사, 캐시디 하딘, 수리아 부파티 라주, 레오나르 후세노, 토마스 메스나드, 보박 샤리아리, 알렉상드르 라메, 요한 페레, 피터 리우, 포우야 타프티, 아베 프리젠, 마셀 카스본, 사벨라 라모스, 라빈 쿠마르, 샤를린 르 란, 새미 제롬 외 179명. 2024. 젤마 2: 개선 중 실용적인 크기의 개방형 언어 모델. 출판 전 논문, arXiv:2408.00118.

아시시 바스와니, 노암 셰지어, 니키 파마, 제이콥 Uszkoreit, Llion Jones, Aidan N Gomez, ukasz 카이저, 그리고 일리아 폴로스킨. 2017. 모든 것은 관심에 달려 있다. 당신에게 필요한 것. 《신경 정보 처리 시스템의 발전》 30권. Curran Associates, Inc.

벤저민 워너, 앙투안 샤핀, 벤자민 클라비에, 오리온 웰러, 오스카 할스트롬, 사이드 타가두이니, 알렉시스 갤러거, 라자 비스워스, 파이살 라닥, 톰 아르센, 네이션 쿠퍼, 그리핀 아담스, 제레미 하워드, 그리고 이아코포 폴리. 2024. 더 똑똑하고, 더 나은. 더 빠르고, 더 오래: 최신 양방향 인코더 빠르고, 메모리 효율적이며, 장기적인 컨텍스트 미세 조정이 가능합니다. 그리고 추론. 사전출판본, arXiv:2412.13663.

Thomas Wolf, Lysandre Debut, Victor Sanh, Julien 소몽, 클레망 델랑그, 앤서니 모이, 피 에릭 시스타크, 팀 로, 레미 루프, 모건 푼토비츠, 조 데이비스, 샘 슬라이퍼, 패트릭 폰 플레튼, 클라라 Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger 외 3명. 2020. Hugging- face의 트랜스포머: 최첨단 자연어 처리 처리 중입니다. 사전출판본, arXiv:1910.03771.

Yelp. 2021. Yelp 공개 데이터 세트. 접속일: 2023년 11월 3일.

Xin Zhang, Yanzhao Zhang, Dingkun Long, Wen Xie, Ziqi Dai, Jialong Tang, Huan Lin, Baosong Yang, 시에 평준, 페이 황, 장 메이산, 웬지에 Li, and Min Zhang. 2024. mGTE: 일반화된 장 문맥 텍스트 표현 및 재순위 모델 다국어 텍스트 검색. 다음 학술대회 논문집에서 2024 자연과학 분야의 경험적 방법론 컨퍼런스 언어 처리: 산업 분야, 1393페이지~1412, 미국 플로리다주 마이애미. 전산 언어학회.

일라나 짐머만, 자딘 트레덱, 에단 셀프리지, 그리고 조셉 브래들리. 2024. 야생 환경에서 검색 증강 생성을 위한 2단계 인코더 기반 환각 감지. 2024년 자연어 처리 분야 실증적 방법론 컨퍼런스: 산업 트랙 회의록, 8~22쪽, 마이애미, 플로리다.

미국 전산언어학회.