

정밀 조정된 문서 이해 트랜스포머를 활용한 구조화된 정보 추출을 위한 엔지니어링 도면 자동 파싱

Muhammad Tayyab Khan^{1,3#}, Zane Yong^{2#}, Lequn Chen², Jun Ming Tan², Wenhe Feng¹, 및 Seung Ki Moon^{3*}

¹ 싱가포르 제조기술연구소(SIMTech), 과학기술연구청(A*STAR), 5 CleanTech Loop, #01-01 CleanTech Two Block B, 싱가포르 636732, 싱가포르 공화국

² 첨단 재제조 및 기술 센터(ARTC), 과학기술연구청(A*STAR), 3 CleanTech Loop, #01-01 CleanTech Two, 싱가포르 637143, 싱가포르 공화국

³ 난양공과대학교 기계항공공학과, 639798, 싱가포르

*skmoon@ntu.edu.sg (S.K. Moon)

동등한 기여

초록 - 2차원(2D) 엔지니어링 도면에서 핵심 정보를 정확하게 추출하는 것은 고정밀 제조에 있어 매우 중요하다. 수동 추출은 속도가 느리고 노동 집약적인 반면, 기존의 광학 문자 인식(OCR) 기술은 복잡한 레이아웃과 겹치는 기호 처리에서 어려움을 겪어 비정형적인 결과를 산출하는 경우가 많다. 이러한 문제를 해결하기 위해 본 논문은 방향성 바운딩 박스(OBB) 탐지 모델과 트랜스포머 기반 문서 파싱 모델(Donut)을 통합하여 정형화된 정보 추출을 위한 새로운 하이브리드 딥러닝 프레임워크를 제안한다. 사내에서 주석이 달린 데이터셋을 사용하여 YOLOv11을 훈련시켜 9가지 주요 범주(기하 치수 및 공차(GD&T), 일반 공차, 치수, 재료, 주석, 반경, 표면 거칠기, 나사산, 도면 제목 블록)를 탐지하도록 했다. 탐지된 OBB는 이미지로 잘라내어 라벨링한 후, 구조화된 JSON 출력을 위해 Donut을 미세 조정하는 데 활용했다. 미세 조정 전략에는 모든 범주에 걸쳐 훈련된 단일 모델과 범주별 모델이 포함된다. 결과에 따르면 단일 모델은 모든 평가 지표에서 범주별 모델보다 일관되게 우수한 성능을 보였으며, 더 높은 정밀도(GD&T의 경우 94.77%), 재현율(대부분의 범주에서 100%), F1 점수(97.3%)를 달성하는 동시에 허위 예측(5.23%)을 줄였다. 제안된 프레임워크는 정확도를 향상시키고 수작업 노력을 줄이며, 정밀도가 중요한 산업 분야에서 확장 가능한 배포를 지원한다.

키워드 - 2D 엔지니어링 도면, 딥 러닝, 문서 이해 트랜스포머(Donut), 파인 튜닝, 구조화된 정보 추출, YOLOv11

I. 서론

2D 엔지니어링 도면에서 핵심 정보를 정확하게 추출하는 것은 정밀 제조에 필수적이며, 이는 제품 품질, 효율성 및 비용 효율성에 직접적인 영향을 미칩니다[1], [2], [3]. 이러한 도면에는 제조 공구 및 공정 선택과 같은 주요 의사 결정을 안내하는 기술 사양이 포함되어 있으며, 이는 궁극적으로 생산 비용과 일정에 영향을 미칩니다. 전통적으로 이러한 정보는 도면의 주석을 해석하는 숙련된 엔지니어에 의해 수동으로 추출됩니다 [4]. 그러나 수동 추출은 시간이 많이 소요되고 오류가 발생하기 쉬우며, 특히

복잡한 기호나 주석이 뺄뺄하게 적힌 레이아웃을 다룰 때 특히 어려운 과제입니다. 오해는 잘못된 공구 및 가공 매개변수 설정, 결함 있는 부품, 그리고 상당한 생산 지연으로 이어질 수 있습니다 [5].

풍선 표시 기법[6]이나 미츠토요(Mitutoyo)의 MeasurLink[7]와 같은 상용 도구와 같은 기존의 반자동화 접근 방식은 부분적인 자동화를 제공하지만 여전히 사람의 입력에 크게 의존합니다. 이러한 의존성은 확장성을 제한하고 일관성 문제를 야기합니다. YOLO[8]를 이용한 객체 탐지 및 광학 문자 인식(OCR) 도구[9]를 포함한 머신러닝 기반 방법들은 유망한 성과를 보여주었으나, 여전히 상당한 과제에 직면해 있습니다. 일반적인 OCR 모델은 중첩된 주석, 비표준 기호 또는 복잡한 레이아웃을 처리할 때 종종 분할 오류를 발생시킵니다. 이러한 한계는 대부분 도메인 특화 미세 조정의 부재에서 비롯되는데, 대부분의 OCR 시스템이 엔지니어링 문서가 아닌 일반적인 데이터셋으로 훈련되기 때문입니다.

Khan 등[5]은 2D 도면에 최적화된 미세 조정된 OCR 기반 방법을 제안하여 정확도를 향상시켰다. 그러나 이 방법은 전체 도면에서 모든 기하 치수 및 공차(GD&T) 주석을 추출하도록 설계되었기 때문에, 레이아웃이 복잡해질수록 성능이 저하되었다. 이는 보다 견고한 분할 전략이 필요함을 시사한다. YOLO 기반의 방향성 바운딩 박스(OBB) 탐지 모델은 관련 영역을 분리하여 후속 처리 단계를 단순화할 수 있다.

이러한 과제를 해결하기 위해, 본 논문은 주석 영역 탐지를 위한 YOLOv11-obb와 트랜스포머 기반 Donut 모델을 통합하여 구조화된 정보 파싱을 위한 새로운 하이브리드 딥러닝 프레임워크를 제시한다. 이 시스템은 OCR을 사용하지 않는 접근 방식을 통해 구조화된 JSON 출력을 생성한다. 일반화 능력과 정밀도 간의 상충 관계를 평가하기 위해 단일 모델과 범주별 모델이라는 두 가지 훈련 전략을 탐구한다. 이 프레임워크는 수작업 부담을 줄이고 정밀도 중심의 제조 애플리케이션을 위한 확장 가능하고 정확한 정보 추출을 가능하게 하도록 설계되었다.

II. 방법론

본 연구는 2D 엔지니어링 도면에서 구조화된 정보를 추출하기 위해 2단계 딥러닝 프레임워크를 채택한다. 시스템은 OBB 검출을 위한 YOLOv11과 검출된 영역 내의 내용을 파싱하기 위한 트랜스포머 기반 Donut 모델을 통합하며, 이는 그림 1에 표시되어 있다.

공개된 자료에서 총 1,367개의 2D 엔지니어링 도면을 수집하였다. 이 도면들은 GD&T, 일반 공차, 재료, 치수, 주석, 반경, 표면 거칠기, 나사산, 도면 제목 블록 등 9가지 주요 범주에 걸친 주석을 포함하고 있다. 컴퓨터 비전 주석 도구(CVAT) [10]를 사용하여 수동 주석 작업을 수행하였으며, 각 인스턴스는 해당 범주에 따라 라벨링되었다.

YOLOv11은 이 주석이 달린 데이터셋을 기반으로 훈련되어 9가지 특징 유형에 해당하는 OBB를 탐지합니다. 탐지된 영역에서 각각 하나의 주석이 달린 특징을 포함하는 11,469개의 이미지 패치가 추출됩니다. 이 패치들은 레이아웃의 복잡도, 글꼴 스타일, 주석 밀도 면에서 다양합니다.

방대한 수동 라벨링의 부담을 줄이기 위해, 분야 전문가들이 1,000개의 패치로 구성된 대표 하위 집합을 수동으로 주석 처리했습니다. 이 하위 집합은 후속 모델 미세 조정을 위한 균형과 다양성을 보장하기 위해 9개 범주 전체에 고르게 분포되어 있습니다. 이러한 접근 방식은 모든 범주를 포괄하면서도 주석 작업의 노력을 최소화합니다.

모델의 일반화 능력을 향상시키기 위해, PyTorch 라이브러리[11]를 활용한 데이터 증강을 통해 라벨링된 데이터셋을 확장했습니다. 이러한 변환은 스캔 아티팩트, 일관되지 않은 인쇄 품질, 글꼴 왜곡 등 엔지니어링 문서에서 흔히 발견되는 실제 환경의 변동성을 시뮬레이션합니다. 다음의 증강 기법이 적용되었습니다:

1. 흐릿한 버전, 원본, 선명하게 보정된 버전 중에서 무작위로 선택하여 선명도를 조정합니다.
2. 0.5의 확률로 대비를 수정합니다.
3. 0도, 90도, 180도 또는 270도 회전.
4. 0.5의 확률로 그레이스케일 변환.
5. 0.5의 확률로 이미지 반전.




그림 1. 2D 엔지니어링 도면에서 구조화된 정보를 추출하기 위해 제안된 하이브리드 딥러닝 프레임워크의 개요. (a) YOLOv11은 주석이 달린 2D 도면 전체에서 OBB를 감지하고 관련 이미지 패치를 추출하도록 훈련됩니다. (b) Donut은 추출된 이미지 패치와 해당 JSON 그라운드 트루스를 사용하여 구조화된 주석 구문 분석을 학습하도록 미세 조정됩니다.

(c) 추론 단계에서 YOLOv11은 미지 도면의 주석 영역을 탐지하며, 훈련된 Donut 모델이 이를 파싱하여 JSON 형식의 구조화된 출력을 생성한다.

이러한 데이터 증강을 통해 훈련 데이터셋이 1,000개에서 6,000개의 이미지-라벨 쌍으로 확장되어, 그림 2에서 볼 수 있듯이 모델 훈련 중 시각적 다양성이 증대되고 견고성이 향상된다.




그림 2. 데이터 증강 전후 9개 특징 범주에 걸친 이미지 패치의 분포.

그림 3에는 원본 패치, 증강된 변형, 그리고 Donut 훈련에 사용된 해당 구조화된 JSON 그라운드 트루스의 시각적 예시가 나와 있으며, 이를 통해 미세 조정 데이터 세트의 형식과 다양성을 확인할 수 있습니다.




그림 3. Donut의 미세 조정에 사용된, 증강 변형이 적용된 샘플 이미지 패치와 이에 대응하는 구조화된 JSON 정답 데이터.

OBB 검출 후, Donut은 잘린 이미지 패치를 대상으로 미세 조정되어 JSON 형식의 구조화된 텍스트 및 기하학적 정보를 추출합니다. 트랜스포머 기반 아키텍처는 시각적 콘텐츠와 텍스트 콘텐츠를 함께 처리하므로, 기존의 OCR이나 명시적인 텍스트 분할 과정이 필요하지 않습니다. 이로 인해 중첩되거나, 스타일화된, 또는 불규칙한 주석이 포함된 2D 도면을 분석하는 데 특히 효과적입니다.



두 가지 훈련 전략을 탐구했습니다. 첫 번째 전략은 단일 모델 접근법으로, 하나의 Donut 모델을 9개 특징 범주 전체에 걸쳐 훈련합니다. 두 번째

전략은 범주별 접근법으로, 각 범주 유형에 대해 9개의 개별 Donut 모델을 훈련시킵니다. 모델들은 크로스 엔트로피 손실과 Adam 최적화기를 사용하여 배치 크기 1로 30 에포크 동안 미세 조정됩니다. 모든 모델은 동일한 하이퍼파라미터를 사용하여 단일 NVIDIA GeForce RTX 4090 GPU에서 훈련되었습니다. 단일 모델 훈련에는 약 20시간이 소요되는 반면, 개별 범주별 모델은 해당 데이터셋의 크기에 따라 수 분에서 몇 시간까지 소요되어 훨씬 더 빠르게 훈련됩니다.

모델 성능은 정밀도(precision), 재현율(recall), F1 점수, 환각률(hallucination rate)이라는 네 가지 주요 지표를 통해 평가됩니다. 정밀도는 전체 출력 중 정확한 예측이 차지하는 비율을 측정하는 반면, 재현율은 실제 특징 중 성공적으로 식별된 특징의 비율을 나타냅니다. F1 점수는 정밀도와 재현율 모두를 균형 있게 반영한 지표입니다. 환각률은 모델이 입력에 존재하지 않는 특징을 잘못 예측하는 빈도를 정량화합니다. 이 평가 프레임워크는 일반화 능력과 범주별 정확도를 비교할 수 있는 명확한 기준을 제공하며, 도면 내 정보 분석에 대한 최적의 전략을 도출하는 데 도움을 줍니다.

III. 결과

9개 주석 범주에 걸쳐 단일 모델 및 범주별 훈련 전략의 성능은 정밀도, 재현율, F1 점수, 환각률이라는 네 가지 지표를 사용하여 평가되었으며, 이는 그림 4에 요약되어 있다.






그림 4. 4가지 평가 지표(a) 정밀도, (b) 재현율, (c) F1 점수, (d) 환각률을 사용하여 9개 특징 범주에 걸쳐 단일 모델과 범주별 훈련 전략의 성능을 비교한 결과.

단일 모델은 모든 특징 범주에서 일관되게 더 높은 정밀도를 달성합니다. 예를 들어, *표면 거칠기*(Surface Roughness)의 정밀도는 범주별 모델의 65.4%에 비해 단일 모델에서는 89.7%입니다. 마찬가지로, *주석*(Notes)의 정밀도는 60.5%에서 71.1%로, *나사산*(Threads)은 70%에서 100%로, *제목 블록*(Title Blocks)은 55.1%에서 72.9%로, *반경*(87.5%에서 92.7%로)에서도 정밀도가 향상되었습니다. 이러한 일관된 우위는 단일 모델이 훈련 과정에서 전체 주석 공간과 더 광범위한 문맥 패턴에 노출되었기 때문일 가능성이 높으며, 다양한 범주에 걸쳐 오탐을 최소화하는 데 더 효과적임을 시사합니다.

두 모델 모두 거의 모든 특징 범주에서 리콜이 지속적으로 높은 수준을 유지합니다. 대부분의 특징 유형은 *일반 공차*, *재료*, *치수*, *표면 거칠기*, *주석*, *GD&T*, *반경* 및 *나사산*에서 완벽한 리콜(100%)을 달성합니다. 범주별 모델의 경우 '*제목 블록*'에서 약간의 감소가 관찰되는데, 리콜이 72.9%에서 56.3%로 떨어집니다. 이러한 감소는 제목 블록 레이아웃의 다양성과 복잡성 때문일 가능성이 높으며, 범주별 훈련에서 제한된 데이터로는 이를 학습하기가 더 어렵기 때문입니다.

F1 점수도 비슷한 추세를 보이며, 단일 모델이 대부분의 특징 범주에서 범주별 모델보다 우수한 성능을 보이거나 동등한 수준을 기록했습니다. 예를 들어, *표면 거칠기*(94.6% 대 79.1%), *메모*

(83.1% 대 75.4%), *타이틀 블록*(72.9% 대 55.7%), *나사산*(100% 대 82.4%)에서 F1 점수가 향상되었습니다. *GD&T*, *일반 공차*, *반지름*의 F1 점수는 두 모델 모두에서 일관된 수준을 유지합니다. 두 경우 모두 *재료* 및 *일반 공차*에서 F1 점수가 낮은 것으로 관찰되는데, 이는 주로 훈련 샘플이 제한적이기 때문입니다.

환각 분석은 대부분의 범주에서 일관되게 더 낮은 환각률을 보이는 단일 모델의 정밀도 우위를 더욱 확고히 합니다. 예를 들어, *표면 거칠기*의 환각률은 34.6%(범주별)에서 10.3%(단일 모델)로, *제목 블록*은 44.9%에서 27.1%로, *주석*은 39.5%에서 28.9%로 감소합니다. *GD&T*의 경우 두 모델 모두 5.23%라는 낮은 환각률을 기록하며 동등한 성능을 보였으며, 이는 강력하고 일관된 성능을 나타냅니다. 그러나 두 모델 모두 '*재료*' 및 '*일반 공차*' 범주에서는 여전히 높은 환각률을 보입니다. 단일 모델은 '*재료*'의 환각률을 83.3%에서 80.0%로 소폭 감소시켰으나, '*일반 공차*'에서는 개선이 관찰되지 않았으며 두 모델 모두 66.7%의 환각률을 유지했습니다. 이러한 결과는 해당 범주에 대한 대표적인 훈련 데이터가 부족하기 때문인 것으로 보입니다.

전반적으로 단일 모델은 높은 재현율을 일관되게 유지하면서 정밀도, F1 점수, 환각률 측면에서 우수한 성능을 보여줍니다. 반면, 범주별 모델은 대부분의 경우 완벽한 재현율을 달성하지만, 정밀도가 떨어지고 일반화 능력이 제한적입니다. 이러한 결과는 단일 모델이 광범위하고 높은 재현율이 요구되는 응용 분야에 더 적합하다는 것을 시사하는 반면, 범주별 모델은 특징 유형이 명확하게 정의된 정밀도가 매우 중요한 작업에서만 유리할 수 있음을 보여줍니다.

IV. 토론

OBB 탐지를 위한 YOLOv11-obb와 구조화된 정보 파싱을 위한 Donut을 결합한 제안된 하이브리드 프레임워크는 2D 엔지니어링 도면에서 주석을 추출하는 데 있어 견고한 성능을 보여준다. 단일 모델 구성은 강력한 일반화 능력을 보여주며, 대부분의 범주에서 완벽한 리콜을 달성하고 환각률을 현저히 낮췄다. 이러한 성능은 전체 주석 공간에 노출됨으로써 광범위한 레이아웃 구조와 주석 스타일을 포착할 수 있었기 때문으로 볼 수 있다. 이러한 경향은 평가 지표에 명확히 반영되어 있으며, 단일 모델은 모든 특징 범주에서 정밀도, F1 점수, 환각률 측면에서 범주별 모델을 일관되게 능가한다.

반면, 범주별 모델은 전문화를 위해 설계되었음에도 불구하고, '재료'나 '*표면 거칠기*'와 같이 데이터가 부족한 범주에서 더 높은 환각률과 더 낮은 정밀도를 보입니다. 제한된 훈련 데이터와 감소된 문맥적 다양성이 이러한 모델의 낮은 일반화 능력과 높은 오탐률의 원인으로 작용했을 가능성이 높습니다.

제안된 프레임워크의 주요 장점은 구조화된 JSON 출력을 직접 생성할 수 있다는 점입니다.

CAD/CAM 시스템, 품질 보증 도구, 디지털 제조 워크플로우와 같은 후속 애플리케이션에서 활용할 수 있습니다. 이는 종종 추가적인 후처리가 필요한 단편적이거나 비정형적인 출력을 생성하는 일반적인 OCR 시스템과는 대조적입니다. 또한, 이 프레임워크는 반자동 데이터셋 라벨링을 지원하여 수작업 부담을 줄이고 향후 모델 훈련을 위한 확장성을 향상시킵니다.

성능 외에도, 이 프레임워크의 모듈식 설계는 변화하는 제조 요구 사항에 유연하게 대응할 수 있게 해줍니다. 추가적인 주석 범주를 수용하도록 확장할 수 있으며, 디지털 제조 파이프라인의 다양한 단계에 통합될 수 있습니다. 그러나 향후 연구에서는 표본이 적은 범주의 정확도를 높이고, 품질이 낮은 도면에서 발생하는 오인식을 줄이는 데 중점을 두어야 합니다. 이러한 개선 사항은 산업 현장에서의 도입을 촉진할 것입니다.

V. 결론

본 논문은 2D 엔지니어링 도면에서 구조화된 정보를 추출하기 위해 OBB 탐지를 위한 YOLOv11-obb와 콘텐츠 파싱을 위한 Donut을 통합한 하이브리드 딥러닝 프레임워크를 제안했다. 이 프레임워크는 정밀도, 재현율, F1 점수, 환각률이라는 네 가지 주요 성능 지표를 기준으로 단일 모델 및 범주별 훈련 전략을 모두 사용하여 평가되었다. 단일 모델은 범주별 모델보다 일관되게 우수한 성능을 보였으며, 더 높은 전체 정확도, 더 강력한 일반화 능력, 그리고 더 적은 오탐을 보여주었다.

본 연구의 주요 기여로는 다중 카테고리 주석 데이터셋 개발, 하류 제조 시스템과 호환되는 구조화된 JSON 출력 생성, 그리고 주석 작업 부담을 줄여주는 반자동 라벨링 프로세스 등이 있다. 기존의 OCR 기반 접근 방식과 비교할 때, 제안된 프레임워크는 향상된 정확도와 디지털 제조 워크플로우에 대한 더 큰 통합 잠재력을 제공한다.

향후 연구에서는 데이터셋을 확장하여 추가적인 2D 도면 유형과 주석 스타일을 포함시키고, 다중 작업 학습 전략을 탐구하며, 산업용 애플리케이션에서 구조화된 구문 분석을 향상시키기 위해 대체 오픈소스 비전-언어 모델을 평가하는 데 중점을 둘 것이다. 이 프레임워크는 항공우주, 자동차, 반도체 제조 등 정밀도가 요구되는 산업 분야에서 공정 계획, 품질 관리, 설계 검증과 같은 디지털 제조 작업을 지원할 강력한 잠재력을 보여준다.

감사의 말

본 연구는 A*STAR가 지원하는 싱가포르 국제 대학원 장학금 (SINGA)(수혜자: Muhammad Tayyab Khan), 싱가포르 교육부 및 난양 공과대학교(NTU)의 AcRF Tier 1 연구비(RG70/23), 그리고 한국산업기술평가원(KEIT)의 연구비

(No. RS-2024-00442448)의 지원을 받았습니다.

참고문헌

- [1] J. Gao, D. T. Zheng, N. Gindy, 및 D. Clark, “가공 특징에 대한 기하학적 치수 및 공차의 추출/변환,” *Int J Adv Manuf Technol*, vol. 26, no. 4, pp. 405–414, 2005년 8월, doi: 10.1007/s00170-004-2195-3.
- [2] W. Sun 및 Y. Gao, “기하 치수 및 공차 표기 실습을 위한 기준점 기반 모델,” *Journal of Engineering Technology*, 제35권, pp. 38–47, 2018년 9월.
- [3] Y. Xu 외, “기계 공학 도면의 공차 정보 추출 – 디지털 이미지 처리 및 딥 러닝 기반 모델,” *CIRP Journal of Manufacturing Science and Technology*, 제50권, pp. 55–64, 2024년 6월, doi: 10.1016/j.cirpj.2024.01.013.
- [4] Y.-H. Lin, Y.-H. Ting, Y.-C. Huang, K.-L. Cheng, 및 W.-R. 종, “2D 엔지니어링 도면의 자동 인식을 위한 딥러닝 통합,” *Machines*, 제11권, 제8호, 논문 번호 8, 2023년 8월, doi: 10.3390/machines11080802.
- [5] M. T. Khan, L. Chen, Y. H. Ng, W. Feng, N. Y. J. Tan, 및 S. K. Moon, “자동화된 엔지니어링 도면 정보 추출을 위한 비전-언어 모델 미세 조정,” 2024년 11월 6일, *arXiv: arXiv:2411.03707*. doi: 10.48550/arXiv.2411.03707.
- [6] “AutoCAD Mechanical 2022 도움말 | 풍선 정보 (AutoCAD Mechanical 도구 모음) | Autodesk.” 접속일: 9월 27일, 2024년 9월 27일. [온라인]. 이용 가능: https://help.autodesk.com/view/AMECH_PP/2022/ENU/?guid=GUID-F12F0EA0-0810-42EE-A3FE-327041AFAEEE
- [7] “데이터 관리 및 SPC 소프트웨어,” MeasurLink. 접속일: 2024년 9월 27일. [온라인]. 이용 가능: <https://measurlink.com/>
- [8] J. Redmon, S. Divvala, R. Girshick, 및 A. Farhadi, “You Only Look Once: 통합 실시간 객체 탐지,” 2016년 5월 9일, *arXiv: arXiv:1506.02640*. doi: 10.48550/arXiv.1506.02640.
- [9] *tesseract-ocr/tesseract*. (2024년 9월 26일). C++. *tesseract-ocr*. 접속일: 2024년 9월 27일. [온라인]. 이용 가능: <https://github.com/tesseract-ocr/tesseract>
- [10] “선도적인 이미지 및 비디오 데이터 주석 플랫폼 | CVAT.” 접속일: 2025년 3월 22일. [온라인]. 이용 가능: <https://www.cvat.ai>
- [11] “torchvision.transforms — Torchvision 마스터 문서.” 접속일: 2025년 3월 22일. [온라인]. 이용 가능: <https://pytorch.org/vision/0.9/transforms.html>