

도면에서 의사결정으로: 2D 엔지니어링 도면을 구조화된 제조 지식으로 분석하기 위한 하 이브리드 비전-언어 프레임워크

Muhammad Tayyab Khan ^{a,c*}, Lequn Chen ^{b*}, Zane Yong ^b, Jun Ming Tan ^b, Wenhe Feng ^a, Seung Ki Moon ^{c*}

^a 싱가포르 제조기술연구소(SIMTech), 과학기술연구청(A*STAR), 5 CleanTech Loop, #01-01 CleanTech Two Block B, Singapore 636732, Republic of Singapore

^b 첨단 재제조 및 기술 센터(ARTC), 과학기술연구청(A*STAR), 3 CleanTech Loop, #01-01 CleanTech Two, 싱가포르 637143, 싱가포르 공화국

^c南洋공과대학교 기계항공공학과, 639798, 싱가포르

* 교신저자: khan0022@e.ntu.edu.sg (M.T. Khan), chen1470@e.ntu.edu.sg (L. Chen), skmoon@ntu.edu.sg (S.K. Moon)

초록

2D 엔지니어링 도면에서 핵심 정보를 효율적이고 정확하게 추출하는 것은 디지털 제조 워크플로우를 발전시키는 데 필수적입니다. 이러한 정보에는 기하학적 치수 및 공차(GD&T), 치수, 재료 사양, 텍스트 주석 등의 요소가 포함됩니다. 수동 추출은 여전히 느리고 노동 집약적인 반면, 일반적인 광학 문자 인식(OCR) 모델은 복잡한 레이아웃, 엔지니어링 기호, 회전된 주석 등으로 인해 2D 도면을 정확하게 해석하지 못하는 경우가 많습니다. 이러한 한계로 인해 출력이 불완전하고 신뢰할 수 없게 됩니다. 이러한 과제를 해결하기 위해 본 논문은 회전 인식 객체 탐지 모델(YOLOv11-obb)과 트랜스포머 기반 비전-언어 파서를 통합한 하이브리드 비전-언어 프레임워크를 제안합니다. 본 연구에서는 먼저 YOLOv11-obb를 적용하여 주석을 위치 파악하고 방향이 지정된 바운딩 박스(OBB) 이미지 패치를 추출한 후, 이를 미세 조정된 경량 비전-언어 모델(VLM)을 사용하여 구조화된 출력으로 파싱하는 구조화된 파싱 파이프라인을 소개한다. 이 파이프라인을 개발하고 평가하기 위해, 우리는 GD&T, 일반 공차, 치수, 재료, 주석, 반경, 표면 거칠기, 나사산, 도면 블록 등 9가지 주요 범주에 걸쳐 수동으로 주석이 달린 1,367개의 2D 기계 도면 데이터셋을 구축했다. YOLOv11-obb는 이 데이터셋을 통해 훈련되어 OBB를 탐지하고 주석 패치를 추출합니다. 이후 이러한 이미지 패치는 두 가지 미세 조정된 오픈소스 VLM을 사용하여 파싱됩니다. 첫 번째는 Donut으로, Swin-B 시각 인코더와 BART 텍스트 디코더를 결합한 트랜스포머 기반 모델로, OCR에 의존하지 않고 이미지에서 직접 종단간(end-to-end) 파싱을 가능하게 합니다. 두 번째 모델은 Florence-2로, DaViT 비전 백본을 통합하고 다중 모달 토큰 정렬을 통해 구조화된 출력 생성을 지원하는 프롬프트 기반 인코더-디코더 모델입니다. 두 모델 모두 경량화되어 있어 제한된 계산 자원 하에서 특수한 산업용 작업에 적합합니다. 구조화된 주석 라벨과 페어링된 선별된 이미지 패치 데이터셋을 사용하여 두 모델을 미세 조정 후, 구문 분석 성능을 평가하기 위한 비교 실험을 수행합니다.

4가지 주요 지표에서 Donut은 Florence-2를 능가하며, 89.2%의 정밀도, 99.2%의 재현율, 94%의 F1 점수를 기록했고, 환각 발생률은 10.8%를 나타냈다. 마지막으로, 사례 연구를 통해 추출된 구조화된 정보가 공정 및 공구 선정과 같은 후속 제조 작업을 어떻게 지원하는지 보여줌으로써, 2D 도면 해석의 현대화에 있어 제안된 프레임워크의 실질적인 유용성을 입증한다.

키워드: 2D 엔지니어링 도면, 비전-언어 모델, 객체 탐지, 미세 조정, 구조화된 정보 추출, 제조 의사 결정

1. 서론

엔지니어링 도면은 제품 품질, 생산 효율성 및 비용에 직접적인 영향을 미치는 기하학적 치수, 공차, 표면 마감 및 주석과 같은 필수 정보를 전달함으로써 제조의 근간을 이루고 있다[1]. 2차원(2D) 도면은 설계와 제조 사이의 중요한 소통 창구 역할을 하며, 공구 선정, 공정 계획, 검사 및 품질 보증을 포함한 하류 작업을 안내한다. 가장 중요한 주석 중에는 ASME Y14.5-2018 표준에 따라 규격화되어 설계 의도와 허용 가능한 기하학적 편차를 나타내는 기하치수 및 공차(GD&T) 기호가 있다[2]. 도면 정보를 정확하게 추출하는 것은 생산 품질과 비용 효율성을 보장하는데 필수적이다. 왜냐하면 오해나 추출 오류는 결함 있는 부품, 잘못된 기계 설정, 그리고 막대한 비용이 드는 지연으로 이어질 수 있기 때문이다 [3].

디지털 도구가 널리 보급되었음에도 불구하고, 2D 엔지니어링 도면을 해석하는 작업은 여전히 노동 집약적이고 시간이 많이 소요되는 작업입니다. 이는 주석이 밀집되어 있거나 복잡한 GD&T 표기가 포함된 도면의 경우 특히 그렇습니다. 특징과 공차를 스프레드시트나 검사 보고서에 수기로 옮겨 적는 '발룬(ballooning)'과 같은 수작업 방식은 디지털 환경에서도 여전히 흔히 사용되고 있습니다. AutoCAD의 발룬(ballooning) 유틸리티[4]와 같은 반자동화 도구나 미츠토요(Mitutoyo)의 MeasurLink[5]와 같은 상용 플랫폼은 부분적인 지원을 제공하지만, 여전히 사람의 입력에 크게 의존하여 확장성을 제한하고 일관성 문제를 야기합니다. 엔지니어링 도면으로부터의 정보 추출을 자동화하는 것은 효율성, 일관성 및 디지털 통합을 개선할 수 있는 상당한 잠재력을 지니고 있습니다.

최근 딥러닝(DL) 분야의 발전은 수작업 부담을 줄이는 데 중점을 두고 있습니다. 물체 탐지 모델, 특히 *You Only Look Once*(YOLO) 아키텍처 [6]를 기반으로 한 모델들은 도면 내 관심 영역을 찾아내는 데 활용되어 왔으며, 광학 문자 인식(OCR) 도구는 텍스트 추출에 사용되어 왔습니다. 그러나 이러한 모델들은 회전된 기호, 특이한 서체, 복잡한 레이아웃 등이 포함된 실제 엔지니어링 도면을 처리하는 데 종종 어려움을 겪습니다. 일반적인 OCR 모델은 대개 분할 오류를 발생시키거나 광범위한 후처리가 필요한 비정형 출력을 생성한다 [7].

이러한 과제를 해결하기 위해, 최근 일부 연구에서는 기술 문서의 해석 능력을 향상시키기 위해 컴퓨터 비전 기술과 비전-언어 모델(VLM)을 결합한 하이브리드 파이프라인을 탐구해 왔다. 예를 들어, eDOCr2 프레임워크[8]는 엔지니어링 도면을 제목 블록, 치수, 특징 제어 프레임(FCF)과 같은 기능 영역으로 분할하고, Qwen2-VL-7B 및 GPT-

의미 분석을 위해 4o를 사용합니다. 이러한 시스템은 설계 검증에 유망하지만, 엔지니어링 맥락에 맞게 미세 조정되지 않은 모델에 의존하기 때문에, 도메인 특유의 기호나 복잡한 레이아웃을 분석할 때 종종 허위 정보나 부정확한 결과를 산출합니다. 또한, 저희의 이전 연구에서는 2D 엔지니어링 도면에서 GD&T를 추출하기 위해 특별히 맞춤화된 미세 조정 VLM 파이프라인을 활용했습니다[7]. 이러한 문서의 시각적 및 기호적 특성에 적응함으로써 일반 모델 대비 향상된 정확도를 달성했다. 그러나 이 파이프라인은 전체 도면을 단일 패스로 처리하기 때문에 주석이 밀집된 입력에 대해서는 성능 저하가 발생한다. 주석의 수가 증가함에 따라 모델은 개별 기호와 구조를 식별하는 데 어려움을 겪으며, 이는 종종 요소 누락이나 오류로 이어진다. 이러한 한계는 엔지니어링 도면을 해석하기 위해 보다 국소적이고 모듈화되며 도메인에 적응된 방법의 필요성을 강조한다.

엔지니어링 도면의 자동 해석은 여전히 두 가지 지속적인 과제에 직면해 있다. 첫째, 다양한 주석 유형을 정확하게 위치 파악하기 위해서는 레이아웃, 방향, 축척의 변화를 처리할 수 있는 컴퓨터 비전 모델이 필요하다. 둘째, 이러한 주석을 분석하기 위해서는 엔지니어링 문서의 시각적 및 기호적 관례에 맞춰 미세 조정된 모델이 필요하다. 일반적인 모델은 기호 오분류, 일관성 없는 서식, 또는 도메인별 적응 부족으로 인해 구조화된 지식을 추출하는 데 종종 실패한다.

이러한 과제를 해결하기 위해, 본 논문은 2D 엔지니어링 도면에서 구조화된 정보를 추출하기 위한 새로운 하이브리드 비전-언어 프레임워크를 제안한다. 이 시스템은 2단계 아키텍처를 따른다. 첫 번째 단계에서는 YOLOv11-obb [9]를 사용하여 도면 공간 전반에 걸쳐 주석 영역을 위치 파악하고 추출한다. 두 번째 단계에서는 두 가지 오픈소스 VLM인 Donut [10]과 Florence-2 [11]를, 구조화된 정답 데이터와 페어링된 주석 이미지 패치로 구성된 큐레이션 데이터셋을 사용하여 미세 조정한다. 이후 이 미세 조정된 모델들을 활용하여 국소화된 영역을 의미론적으로 분석하고 구조화된 출력을 생성한다. Donut과 Florence-2는 경량 아키텍처와 제한된 환경에서의 작업 특화적 적응에 적합하다는 점에서 선정되었다. 구조화된 테스트 세트를 사용하여 수동으로 검증된 정답 데이터와 비교 분석함으로써 구문 분석 성능을 평가한다. 평가는 정밀도(precision), 재현율(recall), F1 점수(F1-score), 환각률(hallucination rate)이라는 네 가지 핵심 지표를 통해 수행된다. 이 프레임워크는 다양한 주석 유형에 걸쳐 견고하고 범주 인식이 가능한 구문 분석을 지원하며, 디지털 제조 워크플로우로의 하류 통합을 위한 기반을 형성한다.

본 연구의 주요 공헌은 2D 도면에서 구조화된 정보를 추출하기 위해 회전 인식 객체 탐지 기술과 미세 조정된 비전-언어 파싱 기술을 결합한 2단계 하이브리드 프레임워크를 제안한 점이다. 이 프레임워크를 뒷받침하기 위해 1,367개의 주석이 달린 2D 도면으로 구성된 선별된 데이터셋을 활용하였으며, 수동으로 검증된 정답 데이터와 비교하여 두 가지 미세 조정된 비전-언어 모델(VLM)에 대한 비교 평가를 수행했다. 사례 연구를 통해 추출된 구조화된 출력이 하류 제조 작업에서 갖는 실질적인 유용성을 보여준다.

본 논문의 나머지 구성은 다음과 같다. 제2장에서는 공학 도면 정보 추출에 관한 선행 연구를 검토하고, 확인된 연구 격차를 제시하며 마무리한다. 제3장에서는 데이터셋 큐레이션, 방향성 바운딩 박스(OBB)를 이용한 주석 탐지, VLM 미세 조정 등을 포함하여 제안된 방법론을 상세히 설명한다. 제4장에서는 탐지 및 파싱 성능과 정성적 검증을 포함한 실험 결과를 제시한다. 제5장에서는 디지털 제조

워크플로우로의 통합을 보여주는 사례 연구를 제시한다. 마지막으로 제6장에서는 논문을 결론짓고 향후 연구 방향을 논의한다.

2. 문헌 고찰

엔지니어링 도면 해석 분야의 발전을 위해서는 기존 접근 방식, 그 한계, 그리고 최근 기술 발전에 대한 포괄적인 이해가 필요합니다. 이 절에서는 도면 해석 방법의 진화, 구조화된 이해를 위한 트랜스포머 기반 모델의 등장, 추출된 정보의 디지털 제조 시스템 통합이라는 세 가지 주제 영역에 걸친 주요 기여를 검토합니다.

2.1 전통적 및 딥러닝 기반 주석 추출

엔지니어링 도면은 오랫동안 설계 의도를 전달하는 주요 수단으로 활용되어 왔다. 모델 기반 정의(MBD) [12] 및 모델 기반 시스템 엔지니어링(MBSE) [13]과 같은 현대적인 관행이 풍부한 정보를 담은 3D 모델의 사용을 권장하고 있음에도 불구하고, 많은 산업 분야에서는 여전히 기존의 2D 도면에 크게 의존하고 있다. 이러한 문서들은 스캔된 이미지, PDF, 또는 래스터화된 CAD 출력물 형태로 자주 접하게 된다 [14]. 이러한 형식은 단순히 과거 기록을 보존하기 위해서뿐만 아니라, 의미적 유출을 줄여 지적 재산을 보호하려는 의도적인 배포 전략에서 비롯되기도 한다. 중요한 점은, 종종 CAD에서 파생되었으며 구식이 아닌 최신 버전인 2D 엔지니어링 도면이 여전히 GD&T, 공차, 표면 마감, 주석 등 제조 관련 의미 정보를 전달하는 주요 매체로 남아 있다는 것이다. 3D CAD 모델은 형상을 포착하지만, 완전한 MBD를 통해 보강되지 않는 한 일반적으로 이러한 주석이 부족하다. 도면의 기호적 및 공간적 정보는 부품의 기능성, 제품 품질, 제조 가능성을 보장하는 데 여전히 필수적이다. 이러한 정보를 추출하여 하류 제조 공정에 통합하는 것의 중요성은 오랫동안 인식되어 왔다. 예를 들어, Gao 등[15]은 컴퓨터 지원 공정 계획(CAPP)을 위해 설계 공차를 가공 공차로 변환하는 프레임워크를 도입함으로써, GD&T 사양을 제조 특징과 일치시켰다. 이후 Sun과 Gao [3]는 일관되고 기계가 해석 가능한 GD&T 표현을 가능하게 하는 규칙 기반의 기준점 중심 스키마를 제안함으로써 이 연구를 확장했다.

자동 해석 분야의 초기 연구는 주로 도면을 정투영도로 분해하고 기하학적 특징을 추출하는 규칙 기반 시스템에 의존했다 [16]. 이러한 방법들은 자동화의 가능성을 입증했으나, 노이즈가 많거나 복잡한 환경에서는 종종 실패하곤 했다. 딥러닝(DL)의 등장으로, 방대한 주석이 달린 데이터셋에서 패턴을 학습할 수 있는 데이터 주도형 모델이라는 대안이 제시되었다. 예를 들어, Xie 등[17]은 영역 탐지를 위한 컨볼루션 신경망(CNN)과 구조적 추론을 위한 그래프 신경망(GNN)을 통합한 파이프라인을 제안했다. 이들의 시스템은 영역 탐지에서 97%의 정밀도와 제조 방법 예측에서 90.8%의 정확도를 달성하여, 딥러닝이 CAD와 CAM 시스템을 연결할 수 있는 잠재력을 보여주었다.

공학 도면 해석의 핵심적인 측면은 기하학적 특징을 보완하는 주석을 추출하는 것입니다. 여기에는 치수, 주석, 표준 기호 등이 포함되며, 이 모든 요소는 제조에 필수적인 의미를 전달합니다. 그러나 텍스트의 불규칙한 배치, 다양한 글꼴 스타일, 그래픽 요소와의 중첩, 그리고 분야별 고유 표기법 등으로 인해 이 작업은 여전히 어려운 과제입니다. 기존의 OCR 및 템플릿 매칭

기술은 이러한 조건에서 종종 실패하여, 더 견고한 대안의 개발을 촉진하고 있다.

최근 연구에서는 이미지 전처리, 객체 탐지, OCR을 결합한 하이브리드 파이프라인을 점점 더 많이 채택하고 있다. 예를 들어, Xu 등[18]은 이미지 노이즈 필터링, 블록 분할, CNN 기반 문자 인식 기술을 적용하여 기하 공차 명세 주석(GTSC)을 추출했다. Lin 등[1]은 YOLOv7을 사용하여 도면 요소를 탐지하고 Tesseract를 텍스트 추출에 활용함으로써, 산업용 스캔 데이터에서 최대 85%의 정확도를 달성했다. Jamieson 등[17]은 CNN 기반 전처리를 통해 회전 및 기울어진 텍스트를 처리함으로써 견고성을 향상시켰다. Francois 등[19]은 도메인 특화 OCR 후처리 보정 모듈을 통합하여 87.2%의 탐지 정확도와 79.2%의 인식 정확도를 달성했다. Khallouli 등[14]은 기존 조선 도면에 특화된 트랜스포머 기반 OCR을 개발하여, 전문 분야에서 일반적인 OCR 시스템보다 우수한 성능을 보여주었다. 텍스트 요소 외에도, 엔지니어링 도면에는 특히 GD&T 프레임워크 내에서 표면 마감 및 FCF와 같은 기호 주석이 포함된다. 이러한 시각적 개체는 일반적으로 객체 탐지 기법을 사용하여 추출된다. CNN 기반 YOLO 탐지기는 밀집되고 노이즈가 많은 레이아웃을 처리하는 데 있어 뛰어난 견고성으로 인해 주목받고 있다. 예를 들어, Mani 등[20]은 기호를 식별할 뿐만 아니라 이를 인접한 텍스트 레이블과 연관시키는 특화된 탐지기를 개발했다. Yu 등[21]은 배관 및 계기 배치도(P&ID)에서 기호, 텍스트, 선, 표 형식의 범례(legend)를 추출하기 위한 다중 탐지기 프레임워크를 제안했다.

이러한 발전에도 불구하고 여전히 상당한 과제가 남아 있습니다. 다양한 유형의 엔지니어링 도면을 대상으로 YOLO를 평가한 연구에 따르면, 단순한 요소의 경우 높은 정밀도(87.6%)를 보였으나, IoU(Intersection over Union) 임계값 0.5에서 평균 정밀도(mAP)는 61%로 낮은 수치를 기록했습니다 [22]. 주석이 겹치거나, 드문 기호가 사용되거나, 시각적으로 복잡한 레이아웃이 존재할 경우 성능이 저하된다. OCR 시스템은 여전히 공학 전용 폰트, 중첩된 공차 구조, 비표준 표기 형식에 어려움을 겪고 있다. 미쓰토요(Mitutoyo)의 MeasurLink나 HighQA의 Inspection Manager[23]와 같은 상용 도구는 일부 자동화 기능을 제공하지만, 깨끗한 CAD 입력 데이터나 표준화된 템플릿에 의존하기 때문에 다양한 도면 유형에 대한 일반화 능력이 제한된다.

이러한 한계를 해결하기 위해 최근 연구에서는 클래스 불균형 및 시각적 변동성 하에서 모델의 일반화 능력을 향상시키기 위해 데이터 증강 기법과 기호별 탐지 전략을 탐구해 왔다[24]. 이러한 기초적인 발전은 시각적 특징과 텍스트적 특징을 공동으로 활용하는 보다 정교한 다중 모달 접근법의 토대를 마련했다. 그럼에도 불구하고, 특히 복잡한 레이아웃과 높은 주석 밀도가 특징인 도메인 특화 시나리오에서 엔지니어링 주석의 완전 자동화되고 견고한 파싱은 여전히 해결해야 할 과제로 남아 있다.

2.2 엔지니어링 도면을 위한 트랜스포머 기반 모델

기존 OCR 및 객체 탐지 파이프라인의 한계를 해결하기 위해, 최근 연구에서는 엔지니어링 도면의 구조화된 이해를 위한 트랜스포머 기반 모델을 탐구해 왔다. 이러한 모델은 시각적 및 텍스트적 입력을 모두 처리할 수 있어[25], 통합적이고 문맥을 고려한 문서 해석을 가능하게 한다. 일반적인 문서 분석 분야에서 LayoutLM[26] 및 DocFormer[27]와 같은 다중 모달 트랜스포머는

텍스트 콘텐츠와 시각적 레이아웃을 함께 모델링함으로써 뛰어난 성능을 보여주었다. 자연어 문서 처리 분야에서 거둔 성공에 고무된 연구자들은 이러한 아키텍처를 공학 및 회로도 등 기술 분야에 적용하기 시작했다. 예를 들어, Gu 등[28]은 회로도의 그래픽 요소를 표 형식의 주석 내 해당 항목과 매핑하도록 설계된 트랜스포머 기반 모델인 ViRED를 소개했다. 이 모델은 구성 요소를 올바른 표 항목에 매핑하는 데 96%의 정확도를 달성하여, 구조화된 문서에서 시각-텍스트 관계를 포착하는 데 있어 어텐션 메커니즘의 효과성을 입증했다. Toro와 Tarkian [8]은 eDOCr2 프레임워크를 제안했는데, 이는 엔지니어링 도면을 제목 블록 및 FCF와 같은 기능적 영역으로 분할하고, OCR을 적용한 후 GPT-4o 및 Qwen2-VL-7B와 같은 VLM에 의미 해석을 요청하는 방식이다. 이 하이브리드 접근 방식은 문맥 추론을 활용하여 OCR 출력물을 수정하고 노이즈가 많은 스캔 데이터에 구조를 부여함으로써 추출된 정보의 품질을 향상시킵니다. 그러나 이러한 시스템은 일반적으로 제로샷 환경에서 배포되며, 도메인별 정렬이 부족하고, 종종 허위 출력을 생성하거나 엔지니어링 기호를 잘못 해석하는 경우가 있습니다. 또한, 독점 모델에 의존하기 때문에 개인정보 보호, 비용 및 미세 조정 제한으로 인해 사용자 정의 가능성이 제한됩니다.

이러한 한계를 해결하기 위해, 일부 연구에서는 엔지니어링 응용을 위해 오픈소스 VLM을 미세 조정하는 방안을 모색해 왔다. 저희의 이전 연구[7]에서는 400개의 주석이 달린 기계 도면을 사용하여 Florence-2를 미세 조정했으며, 제로샷 평가에서 GPT-4o 및 Claude-3.5-Sonnet과 같은 비오픈소스 모델보다 훨씬 더 높은 정밀도와 재현율을 보여주었습니다. 이러한 발전은 단편적이고 특정 작업에 국한된 파이프라인에서, 엔지니어링 도면을 통합된 다중 모달 문서로 취급하는 전체적인 엔드투엔드 모델로의 광범위한 전환을 반영합니다. 트랜스포머 기반 모델, 특히 비전-언어 기능을 갖춘 모델은 통합된 아키텍처 내에서 공간적 계층 구조, 기호적 관계 및 의미적 구조를 표현할 수 있습니다. 기술 분야에서의 활용은 아직 초기 단계이지만, 초기 결과는 특히 하류 디지털 제조 시스템과의 통합이 필요한 응용 분야에서 엔지니어링 도면 해석의 신뢰성과 확장성을 향상시킬 강력한 잠재력을 시사합니다.

2.3 지식 주도형 제조를 위한 구조화된 도면 정보

2D 엔지니어링 도면에서 추출된 구조화된 정보는 공구 선정, 공정 계획, 품질 관리와 같은 하류 제조 작업에서 중요한 역할을 합니다. 특히 GD&T 주석은 가공 결정과 검사 전략에 영향을 미치며, 여기서 오해석은 불합격 부품과 비용이 많이 드는 재작업으로 이어질 수 있습니다 [7].

여러 연구에서 구조화된 도면 기능이 자동화에 유용함을 입증했다. Xie 등[29]은 이를 제조 공법별 부품 분류에 활용했으며, Gao 등[30]은 공차 정보가 누락되면 공정 계획 수립에 차질이 생긴다고 강조했다. 공정 산업 분야에서 Dzhusupova 등[31]은 기호 패턴 탐지가 설계 검증을 어떻게 지원하는지 보여주었다. 이러한 구조화된 주석은 기준점, 공차 계층 구조, 재료 사양에 대한 쿼리 기능을 가능하게 하여, 추적 가능하고 지능적인 의사결정을 지원한다. 이러한 응용 사례는 엔지니어링 지식의 재사용과 자동화에 중점을 두는 지식 기반 엔지니어링(KBE)과 부합한다 [32].

도면 내용을 구조화된 형식으로 변환하면, 이를 온톨로지와 규칙 기반 시스템에 입력하여 후속 추론 및 제어에 활용할 수 있다[33]. MBE 프레임워크는 주로 주석이 달린 3D 모델에 초점을 맞추지만, 실무에서는 2D 도면이 여전히 널리 사용되고 있어[12], 이를 상호 운용 가능한 디지털 형식으로 변환하는 방법의 필요성이 대두된다. 본 논문에서는 제안된 하이브리드 추출 프레임워크가 생성한 구조화된 출력을 활용하여, 공정 및 공구 선정을 후속 활용 사례로 제시한다.

2.4 연구의 공백

앞서 살펴본 문헌 고찰을 통해, 딥러닝 기반 객체 탐지기, OCR 시스템 및 VLM을 활용하여 2D 엔지니어링 도면에서 정보를 자동으로 추출하는 데 상당한 진전이 있었음이 드러났다. 이러한 접근 방식들은 텍스트 및 기호 주석을 모두 분석할 수 있는 잠재력을 보여주었으며, 객체 탐지와 VLM을 결합한 하이브리드 방식은 다양한 레이아웃과 주석 스타일에 걸쳐 향상된 견고성을 보여주었다. 그러나 여전히 몇 가지 주요한 한계가 남아 있다. 대부분의 기존 솔루션은 산업 현장에서 발견되는 엔지니어링 도면의 복잡성과 다양성을 처리할 수 있는 도메인 맞춤형 엔드투엔드 프레임워크가 부족하다. 범용 VLM은 일반적으로 제로샷 환경에서 적용되며 엔지니어링 특화 데이터로 미세 조정되지 않아, 도메인 특유의 그래픽 기호에 대한 빈번한 환각 현상이나 오해석이 발생한다. 또한, 엔지니어링 도면에 맞춤형된 풍부한 주석이 달린 공개 데이터셋이 부족하여, 다양한 주석 범주와 시각적 스타일에 걸쳐 광범위한 일반화 능력을 갖춘 모델의 개발이 제한되어 왔다. 일부 연구는 기호 탐지나 텍스트 파싱과 같은 개별적인 작업을 대상으로 하지만, 원시 도면 콘텐츠를 하류 제조 작업에 적합한 구조화된 형식으로 변환하는 포괄적인 파이프라인을 제공하는 연구는 거의 없다. 이러한 격차는 실제 생산 워크플로우에서 자동화된 도면 해석의 도입을 제한하고 있다. 이러한 과제를 해결하기 위해, 본 논문은 회전 정보를 고려한 객체 탐지 기술과 구조화된 주석 추출을 위한 미세 조정된 VLM(Visual Language Model)을 통합한, 도메인 적응형 하이브리드 프레임워크를 제안한다. 기존 연구와 달리, 제안된 접근 방식은 주석 수준의 정확도와 하류 적용 가능성을 모두 강조함으로써, 지식 기반 제조 워크플로우로의 통합을 가능하게 한다.

3. 연구 방법론

제안된 프레임워크는 그림 1에 표시된 바와 같이 2D 엔지니어링 도면에서 구조화된 정보를 추출하기 위해 2단계 하이브리드 비전-언어 프레임워크를 채택합니다. 첫 번째 단계에서는 YOLOv11-obb 모델을 훈련시켜 OBB를 사용하여 회전되고 크기가 다양한 주석 영역을 탐지합니다. 그런 다음 훈련된 모델을 사용하여 전체 도면 세트에서 주석 패치의 위치를 파악한다. 이 패치들은 JSON 형식의 구조화된 레이블과 짝을 이루어 비전-언어 구문 분석을 위한 데이터셋을 생성한다. 두 번째 단계에서는 두 개의 오픈소스 VLM을 미세 조정하여 개별 주석 패치로부터 구조화된 출력을 생성함으로써, 기계가 읽을 수 있는 의미적 콘텐츠를 산출한다. 추론 단계에서는 새로운 그림을 훈련된 YOLOv11-obb 모델을 통해 처리하여 주석 영역을 추출하고, 이를 미세 조정된 모델들이 독립적으로 파싱합니다. 결과로 생성된 구조화된 출력은 정밀도(precision), 재현율(recall), F1 점수, 환각률(hallucination rate)이라는 네 가지 지표를 사용하여 수동으로 검증된 정답(ground truth)과 비교 평가됩니다. 이러한 출력은 하류 애플리케이션에 직접 통합될 수 있습니다. 사례 시연

추출된 정보가 디지털 제조 워크플로우에서 공구 및 공정 선택을 어떻게 지원하는지 강조한다.




그림 1. 2D 엔지니어링 도면에서 구조화된 정보를 추출하기 위해 제안된 2단계 하이브리드 비전-언어 프레임워크. 입력 도면은 먼저 YOLOv11-obb를 통해 처리되어 OBB를 탐지합니다. 탐지된 OBB는 개별 주석 유형을 나타내는 이미지 패치로 잘립니다. 이러한 패치는 미세 조정된 VLM에 의해 분석되어 JSON 형식의 구조화된 출력을 생성하며, 이를 통해 공정 및 공구 선택과 같은 후속 응용이 가능해집니다.


3.1 데이터셋 및 주석 범주

제안된 방법을 훈련하고 평가하기 위해, 공개 데이터셋, 표준 문서 및 오픈소스 CAD 저장소에서 수집한 1,367개의 2D 기계 도면으로 구성된 새로운 ‘엔지니어링 도면 주석 데이터셋’을 구축했습니다. 이 데이터셋에는 가공 부품부터 조립체에 이르기까지 다양한 유형의 도면이 포함되어 있으며, 깨끗한 CAD 출력물부터 스캔된 구형 청사진에 이르는 다양한 형식을 아우르므로, 산업 현장에서 접할 수 있는 문서의 폭넓은 스펙트럼을 반영하고 있습니다. 이 컬렉션은 항공우주, 자동차, 일반 기계 공학을 포함한 여러 분야를 아우르며, 다양한 도면 작성 관례와 복잡도 수준에 걸쳐 대표성을 확보합니다. 모든 도면은 원본 파일 형식(예: PDF, JPEG)에 관계없이 PNG 형식으로 표준화되었습니다. 각 도면은 컴퓨터 비전 주석 도구(CVAT) [34]를 사용하여 수동으로 주석이 달렸으며, 9가지 주요 범주에 속하는 요소들에 대해 정렬된 바운딩 박스가 적용되어 일관성을 보장합니다.

벤치마킹을 위한 그라운드 트루스. 주석 범주는 다음과 같습니다:

- **GD&T:** 기하학적 기호, 공차 및 기준점 참조를 포함하는 직사각형 FCF
- **일반 공차:** 기본 공차 값을 명시하는 주석 또는 표
- **재료 사양:** 재료 유형 또는 처리에 대한 텍스트 표시
- **치수:** 선형 및 각도 치수 표기
- **주석:** 일반적인 지침 또는 보충 설계 세부 사항
- **반경:** 반경에 대한 치수 표시
- **표면 거칠기:** 마감 또는 질감 요구 사항을 나타내는 기호
- **나사산 표기:** 나사산 형상에 대한 표기
- **제목 블록:** 구조화된 메타데이터로, 일반적으로 도면의 우측 하단에 위치함

이 범주들은 2D 도면에서 관찰되는 가장 일반적이고 제조와 관련된 주석 유형을 나타냅니다. 이 분류 체계는 모델 훈련 및 평가를 위해 선정된 실용적인 그룹화 방식이라는 점을 유의해야 합니다. 이는 뷰와 주석을 구분하고 치수 해석에 대한 보다 엄격한 의미론적 규칙을 정의하는 기존 관례를 보완할 뿐, 이를 대체하지는 않습니다. 이 분류 체계는 표준화된 주석 의미론과의 일관성을 유지하면서 데이터셋 특유의 패턴을 반영합니다. 색상 코드화된 경계 상자가 표시된 주석이 달린 도면의 예는 그림 2에 나와 있습니다. 데이터셋 구축에 사용되는 도면의 품질은 편향 및 도면 작성 오류의 위험을 최소화하기 위해 신중하게 관리됩니다. 불일치나 불명확한 사양이 있는 도면은 제외됩니다. 모든 주석 작업은 기계 설계 및 제조 분야의 배경 지식을 갖춘 훈련된 주석 담당자가 수행하며, 이후 두 명의 분야 전문가가 검증하여 그라운드 트루스의 일관성과 신뢰성을 보장한다. 이러한 조치들은 최근 엔지니어링 도면 데이터셋의 편향 및 도면 작성 오류 위험을 강조하는 권고 사항[35]에 부합하여, 데이터셋이 자동화 접근법 벤치마킹을 위해 대표성과 신뢰성을 모두 유지하도록 보장한다.



Material	GD&T	General Tolerance	Surface Roughness
Threads	Title Block	Notes	Measure
			Radii

그림 2. 선별된 데이터셋의 주석이 달린 샘플. 색상으로 구분된 바운딩 박스는 9가지 제조 관련 주석 범주에 속하는 요소들을 강조 표시하고 있다.

3.2 OBB 기반 주석 탐지 및 데이터셋 구축

이 섹션에서는 YOLOv11-obb를 사용하여 2D 기계 도면 내 주석을 탐지하고, 이미지 패치를 추출하며, 후속 파싱을 위해 이미지-JSON 쌍으로 구성된 구조화된 데이터셋을 준비하는 전체 파이프라인을 소개합니다.

3.2.1 YOLOv11-obb 훈련

OBB를 지원하는 1단계 객체 탐지기인 YOLOv11-obb를 사용하여 2D 도면 내 회전 및 크기가 다양한 주석을 위치 파악한다. 이러한 방향 인식 탐지 방식은 각도가 있는 치수, 비스듬한 GD&T 기호, 수직으로 쌓인 제목 블록 항목이 포함된 기술 문서에 특히 적합하다. 이는 2단계 방식을 사용하는 다른 회전 인식 탐지기(예: Oriented R-CNN [36], ReDet [37])보다 선택되었습니다.

이 모델은 단일 단계 아키텍처를 채택하여 정확도와 효율성 사이에서 탁월한 균형을 제공합니다. DOTA-v1(80.9 mAP)과 같은 벤치마크에서 최첨단 성능을 달성하면서도 실시간 추론 속도(TensorRT 기준 ≈ 10.1 ms)를 유지하므로[38], 대규모 산업 현장에 특히 적합합니다. 이 모델은 COCO 사전 학습된 가중치[39]로 초기화되며, 다양한 주석 스타일, 레이아웃 및 시각적 조건을 포괄하는 1,367개의 선별된 엔지니어링 도면 중 일부를 사용하여 미세 조정되었습니다. 전체 훈련 구성은 표 1에 제시되어 있습니다.

표 1. YOLOv11-obb 훈련 구성.

매개변수	값/유형
모델	Yolo11m-obb.pt
이미지 크기	1024×1024 픽셀
에포크	400
배치 크기	16
사전 학습	COCO (예)

3.2.2 라벨링, 탐지 및 이미지 패치 추출

훈련된 YOLOv11-obb 모델을 사용하여 총 1,367개의 엔지니어링 도면 전체에서 주석을 탐지한 결과, 총 11,469개의 국소화된 주석 인스턴스가 도출되었습니다. 탐지된 각 영역은 앞서 4.1절에서 설명한 9가지 사전 정의된 범주 중 하나로 분류됩니다. 탐지 후, 각 방향 지정 바운딩 박스(OBB)를 사용하여 원본 도면에서 직사각형 이미지 패치를 잘라냅니다. 주석 주변의 관련 시각적 단서를 보존하기 위해 약간의 맥락 여백이 유지됩니다. 패치는 크기와 형식이 표준화되어 하류 구조화 파싱의 입력으로 사용됩니다. 패치는 크기와 내용이 다양하며, 단순한 치수 표기 및 반지름부터 복잡한 GD&T 프레임 및 제목 블록 항목에 이르기까지 다양합니다. 복잡도에 따라 다르지만, 평균적으로 각 도면은 8.4개의 주석 패치를 생성합니다.

추출된 11,469개의 주석에 대한 범주별 분포는 그림 3에 시각화되어 있으며, 이는 '측정값(Measures)', 'GD&T', '주석(Notes)'과 같은 주요 범주가 우세하고, '나사산(Threads)', '일반 공차(General Tolerances)', '재료(Materials)'와 같은 유형은 상대적으로 적은 편인 비대칭적인 분포를 보여줍니다. 이러한 경향은 도면 작성 관례와 일치합니다. 치수는 모든 부품 또는 조립체 뷰에 걸쳐 반복되는 반면, 일반 공차나 제목 블록과 같은 요소는 일반적으로 도면당 발생 빈도가 낮으며, 주석이나 표면 거칠기 같은 범주는 더 큰 변동성을 보입니다. 이러한 불균형은 다음 절에서 설명하는 표적 보강을 통해 해결됩니다.




그림 3. 9개의 사전 정의된 범주에 따른 11,469개의 탐지된 주석 분포.

검출 및 패치 추출 과정을 시각적으로 보여주기 위해, 그림 4는 검출된 OBB가 중첩된 2D 도면 샘플과 함께 주석 범주별로 정리된 해당 추출 패치를 보여줍니다.




그림 4. 탐지 및 패치 추출 과정. 탐지된 OBB가 주석 범주별로 색상 코딩된 2D 도면 예시(위)와, 구조적 구문 분석의 입력으로 사용된 해당 추출 이미지 패치(아래).

3.2.3 OBB 패치의 주석 처리

검출된 각 이미지 패치는 범주별 스키마로 정의된 구조화된 JSON 라벨과 연결됩니다. 이러한 스키마는 VLM 훈련에 적합한 기계 판독 가능한 형식으로 주석의 의미적 내용을 표현하도록 설계되었습니다. 예를 들어:

- **GD&T** 주석에는 다음이 포함됩니다:
 1. **기하학적 특성:** 제어 유형(예: 위치, 평탄도)
 2. **공차:** 허용 가능한 편차로, 종종 수식어가 포함됨(예: 수식어가 포함된 $\varnothing 0.020$)
 3. **기준점 참조:** 공차 프레임을 정의하는 기준점 요소(예: A, B, C)
- **측정** 주석에는 다음이 포함됩니다:
 1. **개수:** 반복되는 피처의 개수(예: $2 \times$ 구멍)
 2. **공칭값:** 의도된 치수 또는 설계상 지정된 치수(예: $\varnothing 28$)
 3. **상한/하한:** 허용되는 치수 편차(예: ± 0.05)

그림 5는 GD&T 및 측정 범주에 대한 이미지-JSON 쌍의 예시를 보여주며, 패치와 이에 대응하는 구조화된 레이블을 보여줍니다. 이러한 쌍은 수동 감독 및 후속 모델 훈련 모두에 사용되는 기초 데이터 형식을 구성합니다. JSON은 가볍고 널리 채택되었으며 스키마 제약이 있어, 범주별 정보를 일관되게 인코딩하면서도 하류 추론 엔진과의 상호 운용성을 유지할 수 있기 때문에 표현 형식으로 선택되었습니다. 이러한 쌍은 수동 감독과 하류 모델 훈련 모두에 사용되는 기초 데이터 형식을 구성합니다.


Paired Annotation Examples: GD&T and Dimensional Measurement	
GD&T OBB Image Patch 	Measure OBB Image Patch 
Structured Ground Truth (JSON) <pre>{ "GD&Ts": [{ "index": 1, "geometricCharacteristic": "U+2316", "tolerance": "U+2300 0.014 (M)", "datumReference": ["A", "B", "C"] }] }</pre>	Structured Ground Truth (JSON) <pre>{ "Measures": [{ "quantity": "8", "nominalValue": "U+2300 6.5", "tolerance": "", "upperLimit": "+0.1", "lowerLimit": "-0.1" }] }</pre>

그림 5. GD&T 및 Measure 범주에 대한 대표적인 주석 예시. 각 예시는 OBB로 잘린 이미지 패치(상단)와 그에

구조화된 JSON 레이블(하단)을 보여줍니다.

일관된 표현을 보장하고 인식 오류를 줄이기 위해, 14개의 일반적인 GD&T 기호는 ASME Y14.5 [40]에 따라 표준화된 유니코드 문자를 사용하여 인코딩됩니다. 이러한 정규화는 일관성을 높이고, 구문 분석을 단순화하며, 특히 양식화된 기호나 드물게 사용되는 기호를 해석할 때 인식 오류를 줄여줍니다. 표 2에는 이러한 기호와 해당 유니코드 표현이 나열되어 있으며, 이는 주석 스키마에 통합되어 데이터셋 전반에 걸쳐 일관되게 사용됨으로써 주석 표현 및 모델 입력 형식화에 대한 표준화된 접근 방식을 지원합니다.

표 2. GD&T 기호의 유니코드 표현.

이름	기호	유니코드
위치		U+2316
평탄도		U+23E5
둥글기		U+25CB
원통도		U+232D
선의 윤곽		U+2312
평면의 단면		U+2313
평행성		U+2225
수직도		U+27C2
직선도		U+23E4
동심도		U+25CE
각도		U+2220
대칭성		U+232F
원형 편심		U+2197
전체 런아웃		U+2330

3.2.4 데이터 증강 및 최종 데이터셋 구축

모델의 견고성을 강화하고 다양한 도면 조건에 대한 일반화 능력을 향상시키기 위해, 훈련 세트 내에서 표본이 부족한 주석 범주에 시각적 데이터 증강을 선택적으로 적용합니다. 여기에는 '일반 공차', '재료', '나사산', '제목 블록', '표면 거칠기', '반지름' 등이 포함되며, 이는 '치수'나 'GD&T'와 같은 주요 범주에 비해 자연스럽게 발생 빈도가 낮은 범주들입니다. 증강 과정은 PyTorch 라이브러리[41]를 사용하여 구현되며, 보관되거나 스캔된 기술 문서의 실제 왜곡을 모방하도록 설계된 확률적 변환 전략을 적용합니다. 목표는 이미지-JSON 쌍 전반에 걸쳐 의미적 레이블의 일관성을 유지하면서 다양성을 높이는 것입니다. 다음의 다섯 가지 증강 기법이 사용됩니다:

- **선명도 변동**: 스캔된 기술 문서에서 흔히 볼 수 있는 흐릿하거나 과도하게 선명해진 스캔 효과를 재현합니다
- **명암 대비 조정**: 과다 노출되거나 색이 바랜 인쇄 상태를 반영하도록 명암 대비 수준을 변경합니다(50% 확률로 적용됨)
- **회전**: 레이아웃 방향에 대한 모델의 불변성을 높이기 위해 0°, 90°, 180° 또는 270°의 무작위 방향 변환을 적용합니다
- **그레이스케일 변환**: 컬러 또는 다중 톤 도면을 흑백으로 변환하여(50% 확률) 보관된 청사진을 모방합니다
- **색상 반전**: 흑백 픽셀을 반전시켜 네거티브 스캔이나 화이트프린트 형식을 시뮬레이션합니다(50% 확률)

대표적인 예시는 표 3에 제시되어 있으며, 여기서는 스레드 주석 이미지 패치를 5가지 기법 모두를 사용하여 증강한 결과를 보여줍니다. 각 변환은 주석 구조를 유지하면서 뚜렷한 시각적 변이를 도입하므로, 증강된 데이터는 트랜스포머 기반 모델 훈련에 적합합니다.

표 3. 스레드 주석 패치에 적용된 증강 예시. 각 행은 원본 이미지(왼쪽), 증강 유형(가운데), 그리고 이에 대응하는 증강 변형(오른쪽)을 보여줍니다.

원본 이미지 패치	증강 유형	증강 변형
6X M20 X2-6H	선명도 변형	6X M20 X2-6H
	명암 조절	6X M20 X2-6H
	회전	6X M20 X2-6H
	그레이스케일 변환	6X M20 X2-6H
	색상 반전	6X M20 X2-6H

이러한 보강 기법은 훈련 데이터의 클래스 균형을 개선하기 위해 소수 클래스에 독점적으로 적용됩니다. 이 표적 전략의 효과는 그림 6에 표시된 업데이트된 클래스 분포에서 확인할 수 있습니다.




그림 6. 표적 증강 전후의 도면 요소 주석에 대한 범주별 분포. ‘스레드(Threads)’, ‘재질(Material)’, ‘표면 거칠기(Surface Roughness)’, ‘일반 공차(General Tolerances)’와 같은 소수 범주의 데이터 균형이 개선되었다.

그 결과, 의미론적으로 일관되고 시각적으로 다양하며 클래스 균형이 잡힌 이미지-JSON 쌍 데이터셋이 생성되었습니다. 이 강화된 데이터셋은 광범위한 2D 기계 도면 전반에 걸쳐 견고하고 레이아웃에 영향을 받지 않는 주석 파싱이 가능한 하류 트랜스포머 기반 모델을 훈련하는 기반이 됩니다.

3.3 비전-언어 모델 미세 조정

최종 확정된 11,469개의 이미지-JSON 쌍 데이터셋을 바탕으로, 두 가지 트랜스포머 기반 VLM(Vision-Language Model)인 Donut과 Florence-2를 공학 주석의 구조화된 파싱을 위해 미세 조정했습니다. 두 모델 모두 단일 주석이 포함된 잘린 이미지 패치로 훈련되었으며, 범주별 JSON 스키마에 부합하는 구조화된 출력을 생성하도록 훈련되었습니다. 이 모델들은 시각적 정보와 기호적 정보를 공동으로 처리하고, OCR 의존성을 제거하며, 다양한 주석 스타일, 기하학적 레이아웃, 그리고 엔지니어링 문서에서 흔히 볼 수 있는 도면 아티팩트에 걸쳐 일반화할 수 있는 능력을 기준으로 선정되었습니다.

3.3.1 Donut 미세 조정

Donut은 인코더-디코더 아키텍처를 갖춘 트랜스포머 기반 문서 파싱 모델로, 이미지 입력을 JSON과 같은 구조화된 텍스트 형식으로 직접 변환할 수 있습니다. 이 모델은 일반적인 OCR이나 영역 기반 분할에 의존하지 않고 작동하므로, 기호, 텍스트, 기하학적 정보가 혼합된 엔지니어

링 도면에 특히 적합합니다. 본 연구에서는 Donut-base [42]가 뛰어난 성능을 보여주기 때문에 이를 선정하였습니다.

반구조화 문서에서의 성능, 노이즈가 많거나 왜곡된 시각 자료에서도 공간적·의미적 무결성을 유지하는 능력, 그리고 종단간 미세 조정 기능이 특징입니다. 이 OCR이 필요 없는 파이프라인은 텍스트 위치 파악 및 글꼴 일관성에 대한 의존성을 제거하는데, 이는 기존 CAD 도면, 스캔된 청사진, 또는 회전된 주석에서 종종 신뢰할 수 없는 요소들입니다. 분류, VQA, 파싱 등 다양한 작업을 지원하는 기존 Donut 모델과 달리, 본 연구는 파싱에만 집중합니다. 각 입력은 단일 국소 주석이 포함된 잘린 이미지 패치로 구성되며, 이에 대응하는 카테고리별 JSON 스키마와 짝을 이룹니다. 목표는 추가적인 작업 조건 설정 없이도 하류 제조 공정을 위한 구조화된 출력을 직접 생성하는 것입니다.

Donut 아키텍처는 인코더-디코더 트랜스포머 설계를 따릅니다. 시각 인코더는 Swin Transformer Base(Swin-B) 아키텍처[43]를 사용하여 구현되며, 이는 시프트 윈도우 기반의 멀티헤드 셀프 어텐션(MHSA)을 통해 공간적 특징을 계층적으로 모델링합니다. 인코더는 먼저 입력 이미지 패치를 겹치지 않는 4×4 패치로 분할하고, Donut에서 원래 정의된 대로 {2, 2, 14, 2}개의 트랜스포머 레이어와 10의 윈도우 크기로 구성된 4개의 Swin Transformer 단계를 통해 이를 처리합니다. 각 Swin 블록은 레이어 정규화, GELU 활성화 함수, 2층 MLP, 그리고 키-쿼리-값(KQV) 어텐션을 사용하는 윈도우 기반 MHSA로 구성됩니다. 인코더는 입력 이미지 패치(자른 엔지니어링 주석 패치)를 1024차원 잠재 시각 임베딩 시퀀스로 변환하며, 이는 디코더의 조건부 입력으로 사용됩니다.

텍스트 디코더는 원본 Donut 구현 방식과 일관되게, 사전 훈련된 다국어 BART 모델[44]을 기반으로 초기화됩니다. 디코더는 주석 스키마에 맞춰 정렬된 구조화된 JSON 필드에 해당하는 출력 토큰을 자기회귀 방식으로 생성합니다. 추론 단계에서는 프롬프트 토큰을 적용하여 범주별 구문 분석에 필요한 디코딩 조건을 설정합니다. 디코더는 마스킹된 멀티헤드 자기 주의(self-attention), 인코더-디코더 교차 주의(cross-attention), 그리고 GELU 활성화 함수를 사용하는 표준 피드포워드 레이어를 활용합니다. 미세 조정 단계에서는 출력 토큰 시퀀스에 대한 교차 엔트로피 손실(cross-entropy loss)을 사용하여 전체 인코더-디코더 모델을 종단 간(end-to-end)으로 공동 훈련합니다. 총 1억 4,300만 개의 파라미터가 최적화되며, 이는 원본 Donut 구성과 일치합니다. 아키텍처 변경은 도입되지 않았으며, 구조화된 엔지니어링 주석 추출을 위해 파싱 전용 모드로 작업 목표만 조정되었습니다. 전체 파싱 파이프라인은 그림 7에 표시되어 있습니다.




그림 7. 엔지니어링 주석 파싱에 최적화된 Donut 아키텍처. Swin Transformer 인코더는 개별 주석이 포함된 입력 이미지 패치로부터 계층적 시각

임베딩을 추출한다. BART 기반 디코더는 프롬프트 조건 하에서 구조화된 JSON 출력을 생성하여, 후속 제조 작업을 위한 기계 판독 가능한 주석을 산출한다 [10].

미세 조정 과정에서 두 가지 모델링 전략이 탐구됩니다:

- **통합 모델:** 단일 Donut 모델을 사용하여 공유된 구조화된 출력 형식을 기반으로 9가지 주석 범주 전체에 걸쳐 훈련합니다. 각 이미지 패치는 해당 범주별 JSON 라벨과 짝을 이루며, 모델은 하나의 통합된 아키텍처 내에서 다양한 주석 유형과 레이아웃을 처리하는 방법을 학습합니다. 이 접근 방식은 클래스 간 일반화 능력을 향상시키고, 모든 추론 작업을 단일 모델로 통합함으로써 배포 과정을 간소화합니다.
- **범주별 모델:** 9개의 독립적인 Donut 모델이 각각 하나의 주석 범주와 해당 스키마로 제한되어 별도로 미세 조정됩니다. 이 전략은 각 주석 유형에 맞춘 학습을 강조하지만, 범주당 하나의 모델씩 총 여러 모델을 훈련, 관리 및 배포해야 합니다.

이 두 전략의 차이점은 그림 8에 설명되어 있습니다. 통합 설정(그림 8a)에서는 단일 Donut 모델이 주석 유형에 관계없이 이미지와 JSON 정답 데이터를 함께 입력으로 받아, 일반적인 스키마를 사용하여 구조화된 데이터를 출력합니다. 반면, 범주별 전략(그림 8b)은 각 주석 유형(예: GD&T, Measure, Thread)에 별도의 모델을 할당하며, 각 모델은 해당 하위 집합에 대해서만 훈련된다. 명확성을 위해 그림 8에는 세 가지 주석 범주만 표시되었으며, 동일한 구조를 따르는 나머지 여섯 가지 범주는 간결성을 위해 생략되었다. [45]의 선행 연구 결과에 따르면, 통합 모델은 일반화 능력, 훈련 효율성, 배포 용이성 측면에서 범주별 모델보다 일관되게 우수한 성능을 보인다. 또한 범주 간 시각적 및 구조적 패턴의 공유 학습을 가능하게 함으로써 중복을 추가로 줄여준다. 따라서 본 연구에서는 최종 평가를 위해 통합 Donut 모델만 채택하였다. 두 Donut 모델에 사용된 전체 미세 조정 구성은 표 4에 요약되어 있다.




그림 8. Donut 미세 조정 전략: 통합 방식 대 범주별 방식. (a) 통합 설정에서는 공유된 구조화된 JSON 출력을 사용하여 단일 Donut 모델을 모든 주석 범주에 대해 훈련합니다. (b) 범주별 접근 방식에서는 주석 유형별로 개별 모델을 미세 조정합니다. 대표적인 세 가지 범주(GD&T, Measure, Thread)가 표시되어 있으며, 나머지는 점선으로 표시된 확장 부분으로 나타냅니다.

3.3.2 Florence-2 미세 조정

Florence-2는 다양한 시각 이해 작업을 단일 프롬프트 기반 생성 프레임워크로 통합하도록 설계된 인코더-디코더 아키텍처를 갖춘 트랜스포머 기반 VLM입니다. 이 아키텍처는 OCR 모듈이나 영역별

특정 탐지기에 의존하지 않고 구조화된 텍스트 출력을 직접 생성합니다. 이러한 OCR이 필요 없는 종단간 생성형 설계 덕분에 Florence-2는 스캔된 청사진, CAD 출력물, 기존 문서 간에 주석 스타일, 기하학적 레이아웃, 시각적 아티팩트가 빈번하게 달라지는 엔지니어링 도면의 구조화된 파싱에 특히 적합합니다.

본 연구에서는 효율적인 모델 규모와 시각적으로 복잡한 구조적 도메인에 걸친 강력한 일반화 능력을 고려하여, 파인 튜닝에 Florence-2-base(매개변수 2억 3천만 개) [46]를 선정하였다. 이 아키텍처는 비전 인코더와 다중 모달 트랜스포머 인코더-디코더라는 두 가지 주요 모듈로 구성된다. 비전 인코더는 DaViT(Dual Attention Vision Transformer) 백본 [47]을 사용하여 구현되며, 이는 공간적 및 채널별 어텐션 메커니즘을 통해 공간적 특징을 계층적으로 인코딩한다. 인코더는 잘라낸 각 주석 이미지 패치를 겹치지 않는 패치로 분할하며, 이 패치들은 임베딩 차원 [128, 256, 512, 1024], 트랜스포머 블록 구성 [1, 1, 9, 1], 어텐션 헤드 [4, 8, 16, 32]를 가진 DaViT 단계를 통해 처리됩니다. 이러한 계층적 설계는 입력 패치를 잠재 시각 임베딩 시퀀스로 변환합니다.

다중 모달 트랜스포머 인코더-디코더는 사전 훈련된 BART 모델을 기반으로 하며, 여기서 텍스트 임베딩과 비전 임베딩이 공유된 표현 공간으로 통합됩니다. 인코더는 768차원 임베딩을 가진 6개의 트랜스포머 레이어로 구성되며, 디코더 역시 동일한 임베딩 크기를 가진 6개의 트랜스포머 레이어로 구성됩니다. 트랜스포머 레이어에는 마스크된 멀티헤드 자기 주의(self-attention), 인코더-디코더 교차 주의(cross-attention), 그리고 표준 피드포워드 레이어가 포함됩니다. 위치 임베딩은 Pix2Seq와 유사한 방식[48]에 따라 공간 좌표를 1,000개의 이산 bin으로 양자화하여 토큰 시퀀스에 통합됩니다. 이를 통해 모델은 공간 기반 구문 분석 작업을 위해 바운딩 박스, 사각형 및 다각형 영역을 위치 토큰 시퀀스로 일관되게 표현할 수 있습니다. 전체 Florence-2-base 모델은 약 2억 3,200만 개의 매개변수를 포함하며, 범주별 구조화된 JSON 스키마와 정렬된 출력 토큰 시퀀스에 대해 크로스 엔트로피 손실을 사용하여 종단 간(end-to-end)으로 미세 조정됩니다. 엔지니어링 주석 구문 분석에 사용된 전체 모델 아키텍처는 그림 9에 설명되어 있습니다.




그림 9. 구조화된 엔지니어링 어노테이션 파싱을 위한 Florence-2 아키텍처. DaViT 인코더는 잘린 어노테이션 패치에서 계층적 시각 임베딩을 추출하며, 이는 다중 모달 트랜스포머 인코더-디코더를 통해 프롬프트 임베딩과 융합되어 구조화된 JSON 출력을 생성한다 [11].

파인 튜닝은 프롬프트 기반의 구조화된 생성 작업으로 구성되며, 각 훈련 인스턴스는 단일 주석이 포함된 잘린 이미지 패치와 이에 수반되는 자연어 프롬프트로 이루어집니다. 프롬프트는 다음 템플릿을 따릅니다: *{Category}*에 대한 구조화된 정보를 JSON 형식으로 추출하십시오. 여기서

여기서 {Category}는 9가지 주석 유형 중 하나로 동적으로 대체됩니다. 이러한 구성 방식은 Florence-2가 시각적 콘텐츠와 프롬프트 의도를 모두 조건으로 하여 출력을 생성할 수 있게 하여, 올바른 주석 스키마에 부합하는 구조화된 정보 추출을 용이하게 합니다. 이 미세 조정 파이프라인의 전체 아키텍처는 그림 10에 설명되어 있으며, 여기서 각 훈련 쌍(이미지 패치와 JSON 레이블)은 모델에 의해 종단 간(end-to-end)으로 처리됩니다. Florence-2는 전체 매개변수 미세 조정[49]을 거치며, 이 과정에서 예측된 구조화된 출력과 참조 구조화된 출력 간의 일관성을 극대화하고, 작업 특유의 시각적 및 의미적 패턴을 효과적으로 학습하기 위해 훈련 중 모든 모델 가중치가 업데이트됩니다.




그림 10. 구조화된 주석 분석을 위한 Florence-2 미세 조정 파이프라인.

Donut과의 공정한 비교를 보장하기 위해, Florence-2는 동일한 구성으로 훈련됩니다. 각 인스턴스는 구조화된 라벨과 짝을 이룬 이미지 패치를 포함합니다. 공유된 구성은 표 4에 요약되어 있습니다.

표 4. Donut 및 Florence-2 모델 모두에 사용된 공통 미세 조정 구성.

매개변수	값/유형
모델	Donut-base 및 Florence-2-base
최적화기	AdamW (코사인 감쇠)
학습률	1e-6
배치 크기	1
에포크	30
손실 함수	교차 엔트로피

4. 결과 및 논의

이 섹션에서는 제안된 하이브리드 비전 기반 파싱 프레임워크에 대한 정량적 및 정성적 평가 결과를 제시하며, 여기에는 (1) YOLOv11-obb 모델의 객체 탐지 성능, (2) 미세 조정된 Donut 및 Florence-2 모델의 구조화된 파싱 결과, (3) GUI 기반 시맨틱 오버레이를 통한 실제 환경 검증 결과가 포함됩니다. 전체 결과는 탐지 및 구조화된 이해 작업 모두에서 강력한 성능을 보여주며, 제안된 시스템이 지식 기반 제조 워크플로우에 적용 가능성을 입증합니다.

4.1 YOLOv11-obb 탐지 성능

추론 단계에서, 훈련된 YOLOv11-obb 모델은 2D 기계 도면 전반에 걸쳐 다양한 주석 유형을 탐지하는 데 뛰어난 성능을 보여줍니다. 그림 11에서 볼 수 있듯이, 평가 지표들은 높은 안정성을 보이며 수렴하며, 최종 정밀도(precision), 재현율(recall), 정밀도-재현율 교차점(mAP@0.5), 그리고 정밀도-재현율 교차점-0.95(mAP@0.5-0.95) 모두 일관되게 0.95를 상회합니다. 데이터셋은 도면 수준에서 90:10으로 분할되어, 테스트 샘플이 다양한 형식의 이전에 보지 못한 도면에서 추출되었음을 보장합니다. 이 홀드아웃 세트에 대한 평가 결과, 모든 주석 범주에서 95% 이상의 신뢰도 점수를 달성하며 견고한 일반화 능력을 확인했습니다. 이는 주석 각도와 스타일이 크게 달라지는 엔지니어링 도면에서 필수적인 요건인, 복잡하거나 회전된 주석 환경에서도 모델의 신뢰성을 강조합니다.




그림 11. 주요 지표(바운딩 박스 손실, 분류 손실, DFL 손실, 정밀도, 재현율, 0.95 미만의 정밀도)에 대한 YOLOv11-obb의 성능 곡선.

대표적인 탐지 결과는 그림 12에 시각화되어 있으며, 여기에는 원본 입력 도면 위에 예측된 주석 영역이 중첩되어 있고, 관련 신뢰도 점수와 함께 범주화 및 색상 코딩되어 있습니다. 이 결과는 표면 거칠기 기호, GD&T 프레임, 치수 표기, 제목 블록 항목과 같은 중첩된 요소를 정확하게 분할함으로써, 주석이 밀집된 환경에서도 견고한 성능을 보여줍니다.




그림 12. YOLOv11-obb의 탐지 결과 예시. 왼쪽: 원본 엔지니어링 도면. 오른쪽: 범주 레이블과 신뢰도 점수가 중첩된 탐지된 주석 영역.

그림 13(a)(정규화)와 그림 13(b)(원계수)의 혼동 행렬을 통해 보다 세분화된 평가 결과를 제시합니다. 정규화 행렬은 거의 모든 범주에서 1.0에 근접한 점수를 보여줌으로써, 거의 완벽한 분류 정확도를 강조합니다.




그림 13. YOLOv11-obb에 대한 혼동 행렬 평가. (a) 높은 클래스 구분 능력을 보여주는 정규화 정확도 행렬. (b) 클래스 빈도와 사소한 오분류를 강조하는 원시 예측 개수.

원시 혼동 행렬은 데이터 세트 내의 롱테일(long-tail) 클래스 분포를 추가로 확인시켜 주며, Material, Threads, General Tolerances와 같은 범주는 발생 빈도가 낮습니다. 이러한 불균형은 클래스 빈도에 영향을 미치지만, 정밀도와 재현율이

이러한 희소 클래스에서도 정밀도와 재현율이 높게 유지되기 때문이다. 이러한 불균형에도 불구하고 모델이 일관된 분류 정확도를 보여주는 것은 실제 환경의 다양한 주석 처리 조건 하에서도 모델이 견고함을 입증한다. 이러한 결과들은 종합적으로 YOLOv11-obb가 제안된 프레임워크의 탐지 백본으로서 적합함을 확인시켜 준다. 이 모델은 다양한 도면 레이아웃 하에서도 강력한 위치 파악 및 분류 성능을 달성하여, 후속 구조화된 파싱 및 다운스트림 애플리케이션을 위한 신뢰할 수 있는 기반을 제공한다.

4.2 구조화된 파싱 성능

YOLOv11-obb에 의해 수행된 주석 국소화 후, 각 탐지된 영역은 Donut 또는 Florence-2 중 하나의 미세 조정된 VLM을 사용하여 의미론적으로 파싱됩니다. 출력은 각 주석 범주에 특화된 구조화된 JSON 필드입니다. 추론 시점의 모델 성능을 평가하기 위해, 예측된 JSON 출력을 전체 데이터셋의 10%로 구성된 테스트 하위 집합에서 수동으로 검증된 정답과 비교하며, 9가지 주석 유형 모두에 걸쳐 대표성을 확보합니다.

평가는 OBB 패치 수준에서 수행되며, 각 예측은 필드 수준 비교를 통해 독립적으로 평가됩니다. 각 주석 패치에 대해, 예측된 JSON 필드와 정답 JSON 필드 간의 정확한 키-값 일치치를 기반으로 진양성(TP), 오양성(FP), 오음성(FN)의 수가 계산됩니다. 정의는 다음과 같습니다:

- **TP:** 해당 정답과 정확히 일치하는 예측된 키-값 쌍.
- **FP:** 예측된 키-값 쌍 중, 오류이거나 정답에 존재하지 않는 것.
- **FN:** 예측 결과에서 누락된 정답 키-값 쌍.

이러한 개수를 바탕으로 각 주석 범주별로 4가지 평가 지표가 계산된 후, 이를 집계하여 종합 점수를 산출합니다. 이러한 지표는 주석 클래스별로 계산된 후 집계되어 클래스별 및 전체 성능을 모두 보고합니다. 사용되는 지표는 다음과 같습니다:

$$\text{정밀도} = \frac{TP}{TP + FP} \quad (1)$$

$$\text{재현율} = \frac{TP}{TP + FN} \quad (2)$$

$$F1 \text{ 점수} = 2 \times \frac{\text{정확도} \times \text{재현율}}{\text{정확도} + \text{재현율}} \quad (3)$$

$$\text{환각률} = 1 - \text{정밀도} \quad (4)$$

환각률은 특히 엔지니어링 환경에서 매우 중요한데, 의미론적으로 유효하지 않거나 잘못된 필드가 과도하게 생성될 경우 오해, 후속 오류 또는 규정 미준수를 초래할 수 있기 때문이다.

환각 필드란 정답 데이터의 유효한 키-값 쌍과 일치하지 않는 모든 예측을 의미하며,

이는 모델 출력의 의미론적 규율 부족을 반영합니다.

표 5는 테스트 데이터의 모든 주석 범주에 대한 Donut과 Florence-2의 구문 분석 결과를 요약한 것이다. Donut은 전반적으로 더 높은 정확도를 보여주며, 전체 F1 점수 94%, 정밀도 89.2%, 재현율 99.2%, 그리고 10.8%의 낮은 환각률을 기록했다. 반면, Florence-2는 F1 점수 85.0%, 정밀도 78.4%, 재현율 92.7%를 기록했으며, 환각률은 21.6%로 더 높았습니다. 이러한 결과는 스키마 준수를 강화하고 과도한 생성을 완화하는 데 있어 Donut의 인코더-디코더 아키텍처가 갖는 비교 우위를 잘 보여줍니다.

표 5. 9개 주석 범주에 걸친 테스트 세트(11,469개 이미지 패치의 10%)에서의 구조화된 파싱 성능.

범주	Donut				Florence-2			
	정밀도	재현율	F1 점수	환각	정확도	재현율	F1 점수	환각
측정 지표	0.896	0.992	0.941	0.104	0.76	0.873	0.813	0.24
제목 블록	0.522	0.545	0.533	0.478	0.302	0.52	0.382	0.698
GD&T	0.933	1.0	0.965	0.067	0.838	0.995	0.91	0.162
주석	0.681	1.0	0.81	0.319	0.655	1.0	0.791	0.345
재료	1.0	1.0	1.0	0.0	1.0	1.0	1.0	0.0
표면 거칠기	1.0	1.0	1.0	0.0	0.857	0.923	0.889	0.143
반지름	0.891	1.0	0.943	0.109	0.837	0.818	0.828	0.163
스레드	0.833	0.909	0.870	0.167	0.75	0.6	0.667	0.25
일반 공차	0.5	1.0	0.667	0.5	0.5	1.0	0.667	0.5
전체	0.892	0.992	0.940	0.108	0.784	0.927	0.85	0.216

범주별 결과를 자세히 살펴보면 뚜렷한 행동 패턴이 드러납니다. ‘측정값(Measures)’이나 ‘GD&T’와 같이 빈도가 높고 구조적으로 일관된 범주는 두 모델 모두에서 높은 리콜(recall) 및 F1 점수를 보입니다. 그러나 Donut은 특히 유니코드(Unicode)로 인코딩된 제어 특성 및 기준점 참조를 정밀하게 분석해야 하는 GD&T 프레임과 같이 기호가 많은 형식에서 더 높은 스키마 준수율과 토큰 수준 정확도를 보여줍니다. ‘표면 거칠기(Surface Roughness)’나 ‘반경(Radii)’과 같이 기호에 제약이 있는 범주는 빈도는 낮지만 높은 정확도로 파싱되며, Donut을 사용했을 때 완벽하거나 거의 완벽한 F1 점수를 달성합니다. 이러한 범주는 시각적 규칙성과 일관된 레이아웃 단서를 활용하므로, 미세 조정 단계에서 노출된 데이터가 제한적임에도 불구하고 모델이 일반화 능력을 발휘할 수 있습니다.

반면, 제목 블록(Title Block), 일반 공차(General Tolerances), 주석(Notes)과 같이 시각적 구조가 약하거나 서식이 일관되지 않은 항목들은 더 큰 난제를 제기합니다. 두 모델 모두 주석 항목에서 완벽한 리콜(recall)을 보여주지만, 정밀도(precision)가 낮아 환각(hallucination) 발생률이 높으며, 이는 자유 형식이나 중복된 콘텐츠가 존재할 때 과도하게 내용을 생성하려는 경향을 나타냅니다. 제목 블록의 성능은 표 형식의 밀도와 재료 사양 및 주석과 같은 인접 요소와의 의미적 중복으로 인해 더욱 저해되며, 이로 인해 예측된 필드와 실제 스키마 간에 빈번한 불일치가 발생합니다. 특히 Florence-2는 광범위한 사전 훈련과 강제적인 구조적 디코딩의 부재로 인해 이러한 모호한 영역에서 더 큰 변동성을 보입니다.

Donut이 보여주는 일관된 우위는 구조화된 출력 정렬을 강조하는 디코더 중심 아키텍처와 작업 특화 미세 조정 덕분이라고 할 수 있습니다.



OCR을 사용하지 않는 파이프라인 덕분에 이 모델은 명시적인 토큰 로컬라이제이션에 대한 의존도를 최소화하면서도 회전되거나 왜곡된

텍스트를 처리할 수 있게 해줍니다. 플로렌스-2(Florence-2)는 프롬프트 기반 디코딩을 통해 가볍고 적응력이 뛰어나지만, 시각적 규칙성이 부족한 범주에서는 출력 형식에 대한 제어력이 떨어지는 단점이 있습니다. 그럼에도 불구하고 두 모델 모두 다중 모달 환경에서 트랜스포머 기반 구문 분석의 타당성을 성공적으로 입증하며, 비정형적인 그림 주석을 실행 가능한 의미적 표현으로 변환해 냅니다.

전반적으로, 이러한 결과는 고정밀 객체 탐지에 이어 견고한 의미론적 파싱이 수행되는 모듈식 2단계 파이프라인의 설계를 입증한다. 주석 범주 전반에 걸쳐 관찰된 성능 추세는 향후 개선을 위한 귀중한 통찰력을 제공한다. 일관된 상징적 레이아웃을 가진 범주는 종단간 시각 학습의 이점을 누리는 반면, 자유 형식 및 레이아웃이 복잡한 영역의 경우 실제 운영 환경에서 신뢰성을 보장하기 위해 트랜스포머 출력을 스키마 제약 후처리 또는 규칙 기반 검증과 결합한 하이브리드 접근 방식이 필요할 수 있다.

4.3 정성적 검증 및 실무 적용 가능성

앞서 제시된 정량적 결과는 제안된 프레임워크가 엔지니어링 주석의 구조화된 구문 분석에 효과적임을 입증하지만, 정성적 분석은 실제 시나리오에서의 유용성을 더욱 명확히 보여준다. 이를 뒷받침하기 위해, 2D 기계 도면에서 주석 탐지부터 구조화된 의미 구문 분석에 이르는 전체 추론 파이프라인을 시각화할 수 있는 맞춤형 그래픽 사용자 인터페이스(GUI)가 개발되었다. 이 GUI를 통해 사용자는 2D 도면을 업로드하고, 범주별 신뢰도 점수 및 추출된 의미 필드와 함께 주석이 달린 오버레이를 실시간으로 확인할 수 있다. 그림 14(a)에 표시된 바와 같이, 대표적인 입력 도면에는 치수 표기, GD&T 특징 프레임, 표면 거칠기 기호, 재료 사양, 자유 텍스트 메모 등 다양한 주석 유형이 포함되어 있다. 그림 14(b)에는 모델 예측 결과가 오버레이되어 있으며, 각 탐지 영역은 주석 범주별로 색상 코딩되고 신뢰도 점수가 표시되어 있다. 이 오버레이는 모델이 도면을 의미 있는 영역으로 분할하고 시각적 요소에 의미론적 레이블을 어떻게 연결하는지를 직관적으로 시각화해 준다.



Detection Overview

Class	Count	Avg. Confidence
Surface Roughness	6	94.50%
GD&Ts	5	95.06%
Notes	4	94.15%
Measures	23	92.73%
Title Block	1	95.07%
Material	1	91.58%

Detection Details

Index	Geometric Characteristic	Tolerance	Datum Reference
1	1	0.02	[A]
2	1	0.02	[]
3	1	0.02	[]
4	1	0.02	[]
5	1	0.020	[A,'B(M),'C(M)]

그림 14. 정성적 구문 분석 검증용 그래픽 인터페이스. (a) 원본 설계 도면. (b) 탐지된

주석, 예측된 범주 및 신뢰도 점수를 보여주는 파싱 결과.

시각적 오버레이 외에도, GUI에는 분석된 필드를 범주별로 정리하여 표시하는 구조화된 표 형식의 인터페이스가 포함되어 있습니다. 예를 들어, '측정값(Measures)' 섹션에서는 샤프트 길이, 직경, 슬롯 크기 등의 특징이 해당 값 및 공차와 함께 나열됩니다. 마찬가지로, GD&T 주석은 기하학적 특성, 공차 영역, 기준점 참조를 포함한 구조화된 필드로 변환됩니다. 이러한 대화형 표현 방식은 시각적 위치 파악과 의미적 이해를 연결하여, 사용자가 결과를 검토하고 해석하며 후속 워크플로우를 위해 내보낼 수 있도록 지원합니다.

출력 결과의 일관성과 통합 준비 상태를 평가하기 위해, 본 시스템은 분석된 전체 내용을 포함하는 내보내기 가능한 구조화된 JSON 파일도 제공합니다. 그림 15에서 볼 수 있듯이, 이 출력 결과는 모든 주석 범주를 기계가 읽을 수 있는 형식으로 담아내며, 이는 CAD/CAM 환경, 규칙 기반 공정 계획 시스템 또는 검사 보고서 생성 파이프라인과의 통합에 적합합니다. 주요 주석 필드는 앞서 방법론에서 설명한 범주별 스키마에 맞춰 표준화된 키와 명확하게 추출된 값으로 표시됩니다. 다양한 주석 레이아웃과 도면 복잡도에 걸친 시스템의 일반화 능력을 더욱 명확히 보여주기 위해, 다양한 엔지니어링 도면에 대한 추가적인 GUI 기반 파싱 결과가 **부록 A**에 포함되어 있습니다.

```

{
  "Material": "C-45",
  "Threads": [{"Type": "6×M5 TAP THRU"}], "GD&T": [
    {"Type": "Position", "Tolerance": "Ø0.020", "Datums": ["A", "B(M)", "C(M)"]},
    {"Type": "Straightness", "Tolerance": "0.020", "Datums": ["A"]},
    {"Type": "원통도", "Tolerance": "0.020", "Datums": []},
    {"Type": "평탄도", "Tolerance": "0.020", "Datums": []}, "General
Tolerance": "",
  "반경": "",
  "표면 거칠기": [
    {"Ra": "0.8 µm"}],
  "측정값": [
    {"특성": "축 길이", "값": "81 ±0.05 mm"},
    {"특성": "직경", "값": "Ø28 ±0.05 mm"},
    {"특성": "슬롯", "값": "2×4 mm"}], "제목 블록": {
    "설계자": "Shubham", "날짜":
    "2020.06.09",
    "도면 이름": "입구 샤프트", "비고": "모든 치수는
mm 단위입니다.

    날카로운 모서리는 0.5 모따기 처리하십시오.

    명시되지 않은 공차는 0.050 mm입니다.

    연마는 도금 후 수행해야 합니다."
  }
}

```

그림 15. 도면에서 추출된 모든 의미 영역을 포함하는 구조화된 JSON 출력 예시.

질적으로 볼 때, 이 시스템은 주석 밀도, 도면 스타일, 시각적 조건 전반에 걸쳐 강력한 일반화 능력을 보여줍니다. 또한 결과는 밀집된 제목 블록에서 나타나는 약간의 과분할이나 변동성이 큰 범주에서 발생하는 사소한 필드 환각과 같은 미묘한 성능 차이를 드러냅니다. 이러한 관찰 결과는 기반 모델들의 뚜렷한 작동 방식을 뒷받침합니다. 인코더-디코더 구조를 갖춘 Donut은 스키마에 더 부합하고 구조화된 출력을 생성하며, 이는 제조 자동화와 같은 하류 애플리케이션에 필수적인 특징이다. Florence-2는 더 유연하고 경량적이지만, 레이아웃이 밀집된 영역이나 제목 블록 및 주석과 같은 자유 텍스트 범주에서 과다 생성 경향이 더 높다.

이러한 출력이 의미론적으로 관련성 있는 내용을 담고 있을 수 있지만, 때로는 엔지니어링 검증에 필요한 엄격한 주석 스키마에서 벗어나기도 한다. 특히 기호가 많거나 표본이 적은 범주에서 나타나는 이러한 한계는, 실제 배포 시 후처리 검증과 스키마 제약 추론의 필요성을 강조한다. 경량 규칙 기반 검증, 범주 인식 디코딩 헤드, 또는 하이브리드 검색 강화 워크플로우를 통합하여 의미적 규율을 강화하고 환각 현상을 줄이는 것이 개선 방안이 될 수 있다. 또한 주석의 엄격한 의미적 해석을 위해서는 주석을 참조 기하 구조 및 뷰와 연결해야 한다는 점도 주목해야 한다. 현재 프레임워크는 주석 콘텐츠의 탐지 및 구조화된 표현에 중점을 두고 있으나, 뷰-주석 통합과 심층적인 의미 추론은 향후 연구의 중요한 방향으로 인식되고 있다.

전반적으로, GUI 기반 검증 결과 제안된 파이프라인이 통제된 평가 환경뿐만 아니라 복잡하고 기호가 풍부한 산업용 도면에서도 안정적으로 작동함을 확인했다. 높은 신뢰도의 탐지, 구조화된 의미론적 디코딩, 사용자 친화적인 해석 가능성의 결합은 이 프레임워크가 실제 설계, 검사 및 제조 환경에 배포될 준비가 되었음을 보여준다. 이러한 결과들은 공학 분야의 구조화된 정보 추출을 위해 미세 조정된 트랜스포머 기반 모델의 광범위한 활용 가능성을 입증하는 동시에, 데이터가 부족하거나 반구조화된 환경에서 견고성을 강화하기 위한 명확한 방향을 제시한다. 이전에 비구조화되었던 도면 내용을 실행 가능한 디지털 표현으로 변환함으로써, 이 시스템은 지식 주도형 엔지니어링 프로세스를 지원하고 디지털 스레드 생태계와의 긴밀한 통합을 위한 토대를 마련한다.

5. 사례 연구: 디지털 제조를 위한 추출된 도면 정보의 규칙 기반 해석

제안된 파이프라인을 통해 추출된 구조화된 주석 데이터는 정확한 해석뿐만 아니라 후속 제조 워크플로우로의 원활한 통합을 목적으로 합니다. 그림 16에서 볼 수 있듯이, 이러한 구조화된 출력은 도면에서 파생된 정보를 공정 계획, 공구 선정, 검사 설정 및 비용 산정과 연결함으로써 다양한 의사결정 작업의 토대가 됩니다. 효과적인 통합은 설계자와 제조업체 간의 관점 차이를 해소하는 데에도 달려 있습니다. 이러한 해석상의 격차는 본 연구의 범위를 벗어나지만, 2D 도면의 정보를 구조화되고 기계가 읽을 수 있는 형태로 변환함으로써 필수적인 전제 조건을 충족시킵니다. 이러한 방식으로, 이전에는 비구조화되었던 주석 정보가 실행 가능한 입력으로 변환되어 규칙 기반 시스템이 종단간 제조 작업을 지원할 수 있게 됩니다.




그림 16. 추출된 엔지니어링 도면 정보를 하류 제조 워크플로우에 통합하는 과정.

이러한 기능을 설명하기 위해, 다음 사례 연구에서는 축 도면을 활용한 실제 적용 사례를 제시합니다. 이 사례는 제안된 방법으로 추출된 구조화된 출력이 규칙 기반 추론 엔진을 통해 어떻게 해석되어 가공 결정을 내리고, 적절한 공구를 선택하며, 모델 기반 제조 원칙에 부합하는 계획 활동을 지원하는지 보여줍니다.

5.1 해석 전제 조건

신뢰할 수 있는 해석을 보장하기 위해, 이 프레임워크는 다음과 같은 일련의 핵심 가정 하에서 작동합니다:

1. 부품 재료(및 그 특성)는 도면에서 추출되거나 외부에서 제공됩니다.
2. 도면은 공인된 표준(예: GD&T의 경우 ASME Y14.5 [2], 표면 마감의 경우 ISO 21920 [50])을 준수합니다.
3. 그림 16에서 볼 수 있듯이, 모든 관련 주석은 구조화된 JSON으로 정확하게 파싱됩니다. 잘못 분류되거나 누락된 주석은 후속 단계에서 오류를 유발할 수 있습니다(예: 허용 오차가 누락되면 부적절한 공정 선택으로 이어질 수 있음 [29]).
4. 제조 환경에는 허용되는 공구 및 작업의 정의된 집합이 있으며, 이는 로컬 공구 데이터베이스에 관리됩니다.

이러한 전제 조건은 의미적 완전성을 보장하고, 오분류로 인한 오류를 방지하며, 해석 과정을 공구 가용성 및 규정 준수 요구 사항과 같은 실제 제약 조건에 부합하도록 합니다.

5.2 규칙 기반 추론 엔진

이 추론 프레임워크의 핵심에는 KBE 원칙에 기반을 둔 결정론적 규칙 엔진이 자리 잡고 있습니다. 이 엔진은 크기, 공차 등급, 표면 마감, 재질과 같은 주석 속성을 평가하여 이에 상응하는 가공 공정, 공구 및 매개변수 세트를 도출합니다. 각 규칙은 ASME Y14.5, ISO 21920, ISO IT 등급표[51]를 포함한 분야 표준을 기반으로 작성되었으며, 『Machinery’s Handbook』 [52] 및 공급업체별 지침(예: Sandvik Coromant)과 같은 참고 자료에서 도출된 산업계 모범 사례로 보완되었습니다. 이러한 규칙들은 형식적 지식과 전문가의 휴리스틱을 모두 포괄하여 추적 가능하고 기계가 해석할 수 있는 논리로 구성합니다.

그림 16에 표시된 바와 같이, 분석 대상 도면에서 파싱된 출력은 앞서 소개한 표준화된 스키마로 구조화됩니다. 이러한 구조화된 표현은 규칙 기반 추론 시스템에 대한 직접적인 입력으로 사용되며, 이 시스템은 구조화된 데이터를 해석하여 적절한 제조 조치를 권장합니다.

핵심 추론 과정을 설명하기 위해, 표 6에는 형상 수준 입력과 가공 권장 사항 간의 결정론적 매핑을 포착한 일련의 대표적인 규칙이 제시되어 있다. 각 규칙은 형상 유형, 치수, 공차, 재료 특성 등과 같은 입력 조건 집합을 정의하고, 이를 권장 작업 집합 및 호환 가능한 공구로 매핑한다. 이러한 매핑은 산업적 관련성과 추적성을 보장하기 위해 국제 표준 및 검증된 현장 경험적 규칙과 일치한다.

표 6. 특징 기반 해석 논리를 반영한 대표적인 규칙표.

특징 유형	조건	권장 연산	공구 선택
나사 구멍	6×M5 관통 탭; 재질: C-45 강철	드릴 Ø4.2 mm, 탭 M5×0.8	트위스트 드릴 (Ø4.2 mm, HSS); 나선형 플루트 탭 (M5×0.8 mm, HSS-E, TiN 코팅)
원통형 샤프트	Ø28 mm; 공차 ±0.05 mm; 표면 거칠기 Ra 0.8 µm	황삭, 정삭	초경 인서트(황삭); 와이퍼 인서트(정삭)
구멍 (공차 공차)	직경 공차 범위 ISO IT6–IT8	드릴링 + 마무리 가공 (리밍/보링)	리머 (H7 등급); 정밀 드릴
샤프트 (초정밀 마감)	표면 거칠기 Ra < 0.4 µm 또는 엄격한 직경 공차	정밀 선삭 또는 연삭	초정밀 연마 인서트; 와이퍼 인서트; 연삭 휠
위치 정밀도	Ø0.020 mm 위치 기준점 A, B, C에 적용된 위치 공차	공정 중 프로빙을 이용한 CNC 마무리 가공	맞춤형 고정 장치 설정; CNC 터치 프로브; 적응형 경로
구멍 또는 축	느슨한 공차 (예: ISO IT12)	단일 황삭 패스	표준 초경 인서트

예를 들어, 시스템이 C-45 강철 부품에서 “6×M5 TAP THROUGH”로 주석이 달린 나사 구멍을 감지하면, 다음과 같이 자동으로 추론합니다:

- **가공:** 드릴 Ø4.2 mm, 탭 M5×0.8 mm

- **공구 선택:** 트위스트 드릴($\varnothing 4.2$ mm, HSS), 나선형 홈 탭(M5×0.8 mm, HSS-E, TiN 코팅) 이 규칙은 중탄소강에서 M5×0.8 mm 피치에 대한 ISO 나사산 표준[53]을 반영하여, 최적의 맞물림(~75%)과 공구-재료 호환성을 보장합니다. 또 다른 사례로, 공차 ± 0.05 mm 및 표면 거칠기 Ra 0.8 μm 를 갖는 직경 28 mm 샤프트의 검출 결과는 다음과 같습니다:

- **가공 공정:** 황삭 선삭, 정삭 선삭
- **공구 선정:** 초경 인서트(황삭), 와이퍼 인서트(정삭)

와이퍼 insets를 사용하면 더 높은 이송 속도에서도 $Ra \leq 0.8 \mu m$ 를 달성할 수 있어, 선반 가공의 현대적인 마무리 전략과 부합합니다 [54]. 다른 규칙 예시들은 초정밀 표면 마감, 엄격한 공차 범위(IT6-IT8), 느슨한 공차(예: IT12), 기준점 기준의 고정밀 위치 공차와 같은 특별한 사례를 다룹니다. 이러한 규칙은 추출된 주석 값을 기반으로 동적으로 호출되며, 후속 제조 공정 및 공구 선택을 주도합니다. 전문가의 의사 결정 논리를 명시적인 규칙 집합으로 인코딩함으로써, 시스템은 산업 환경에서 CAD/CAM 자동화와 인간의 감독을 연결하는 데 필수적인, 추적 가능하고 설명 가능한 결과를 산출합니다.

5.3 공구 및 파라미터 데이터베이스

규칙의 산출 결과를 실제 적용하기 위해, 구조화된 공구 및 공정 파라미터 데이터베이스를 활용하여 호환 가능한 공구와 가공 파라미터를 검색합니다. 이 데이터베이스는 CAM 시스템 및 공급업체 카탈로그와의 상호 운용성을 보장하기 위해 ISO 13399 [55] 표준에 따라 구성됩니다. 이 데이터베이스에는 각 공구의 형상 및 재료 속성이 저장되어 있으며, 특정 재료-공구 조합에 대한 절삭 속도와 이송량 값과 연계되어 있습니다. 시스템은 호환성 기준에 따라 필터링하여 이 데이터베이스를 조회하고, 공정 계획을 위한 최적의 파라미터를 검색합니다. **부록 B**에는 공구 항목 예시, 스키마 구조 및 쿼리 예시가 제공되어, 데이터베이스가 실시간 조회 및 통합을 위한 디지털 라이브러리 역할을 수행하는 방식을 보여줍니다.

5.4 후속 공정 통합

마지막으로, 규칙 엔진의 출력은 포괄적인 의사 결정을 지원하기 위해 하류 제조 계획 프레임워크에 통합됩니다. 그림 17에 표시된 바와 같이, 구조화된 주석은 특징 기반 추론을 가능하게 하여 작업 순서 결정, 가공 매개변수 선택 및 검사 계획을 안내합니다. 이러한 출력은 제조 실행 시스템(MES), 견적 워크플로 및 품질 보증 절차와의 연동을 가능하게 하여, 설계 도면과 실행 가능한 생산 전략 간의 격차를 해소합니다.




그림 17. 구조화된 도면 정보를 하류 단계의 계획 및 제조 의사결정 지원 시스템과 연결하는 규칙 기반 해석 파이프라인의 개략도.

이 사례 연구는 제안된 시스템의 광범위한 가치를 보여준다. 기존 도면에서 의미론적으로 구조화된 데이터를 추출하여 이를 공식적인 의사결정 프레임워크에 통합함으로써, 이 파이프라인은 지능적이고 확장 가능한 제조 워크플로우를 가능하게 하는 핵심 요소인 자동화와 일관성을 제공한다.

6. 결론

본 연구는 디지털 제조 워크플로우의 오랜 병목 현상이었던 2D 엔지니어링 도면에서 구조화된 정보를 자동으로 추출하기 위한 하이브리드 비전 기반 프레임워크를 제시했다. 회전 인식 객체 탐지기와 경량 VLM을 결합함으로써, 제안된 파이프라인은 다양한 주석 유형을 효과적으로 위치 파악하고 구조화된 데이터 형식으로 파싱했다. 이 작업은 9개 산업 관련 범주에 걸친 1,367개의 엔지니어링 도면으로 구성된 수동 큐레이션 데이터셋을 기반으로 수행되었으며, 이를 통해 모델 훈련과 벤치마킹이 모두 가능했다.

본 연구의 주요 성과는 YOLOv11-obb와 미세 조정된 비전-언어 파싱을 결합하여 설계 도면에서 구조화된 정보를 추출하는 2단계 하이브리드 프레임워크를 제안한 것이다. 이는 주석이 달린 도면 데이터셋과, 네 가지 주요 평가 지표를 기준으로 수동으로 검증된 정답 데이터와 비교하여 두 가지 미세 조정된 VLM(Donut 및 Florence-2)을 평가한 결과를 바탕으로 이루어졌다. 제안된 파이프라인은 다양한 주석 범주를 구조화된 출력으로 신뢰성 있게 위치 파악 및 파싱하는 능력을 보여주었다. 실증적 결과

강력한 성능을 보여주었으며, Donut은 낮은 환각률을 유지하면서 높은 리콜(99.2%)과 균형 잡힌 정밀도 및 F1 점수를 달성했다. 이러한 결과는 도면 해석을 현대화하고 디지털 제조 워크플로우에서 자동화 및 데이터 상호 운용성을 향상시키는 데 있어 이 프레임워크의 효과성을 입증했다. 연쇄적인 오류가 잠재적인 우려 사항이 될 수 있지만, 공간적 탐지와 의미적 파싱을 분리하는 2단계 설계는 이러한 오류의 영향을 완화하는 데 도움이 되었다. 높은 탐지 정확도는 신뢰할 수 있는 하류 파싱을 위한 견고한 기반을 제공했다. 사례 연구를 통해 공구 및 공정 선택과 같은 하류 작업에서 추출된 출력의 실질적인 유용성이 추가로 입증되었다.

그러나 본 연구에는 몇 가지 한계가 있다. 세심한 선별 과정에도 불구하고, 데이터셋의 범위는 여전히 제한적이며, 특히 대규모 어셈블리나 비표준 주석 형식이 포함된 실제 산업 도면의 다양성과 복잡성을 완전히 포착하지 못할 수 있다. 데이터셋이 여러 분야(항공우주, 자동차, 일반 기계 공학)에 걸쳐 있으며 CAD 기반 및 스캔 형식의 부품 수준 및 어셈블리 수준 도면을 모두 포함하고 있음에도 불구하고, 더 광범위한 산업적 다양성을 포착하기 위해서는 추가적인 확장이 필요하다. 또한, 사례 연구의 하류 추론은 이상적인 조건과 표준화된 공구를 가정하고 있어, 더 광범위한 산업적 맥락으로의 일반화 가능성을 제한할 수 있다. 그럼에도 불구하고, 본 사례 연구는 추출된 구조화된 정보가 공구 및 공정 선택과 같은 후속 작업에 있어 정확하고 활용 가능함을 입증한다. 향후 연구에서는 더 광범위한 산업적 관련성을 입증하기 위해, 다수의 제조 분야(예: 가공, 적층 제조, 판금, 검사 등)에 걸친 폭넓은 검증과 더불어, 구조화된 출력이 실제 디지털 워크플로우를 주도할 수 있는 CAD/CAM 환경과의 통합을 추진할 예정이다.

향후 연구에서는 현재 데이터셋의 제한된 범위를 보완하기 위해, 더 다양하고 복잡한 엔지니어링 도면을 포함하도록 데이터셋을 확장하고, 대표성이 낮은 주석 유형의 표현을 개선하는 데 주력할 것이다. 또한, 포컬 손실(focal loss), 클래스 가중치 훈련(class-weighted training), 정교한 대표본 추출 기법과 같은 불균형 인식 전략을 탐구하여, 드문 주석 범주에 대한 견고성을 한층 강화할 수 있을 것이다. 또한 CAD/CAM 워크플로우 및 검사 파이프라인에 구조화된 출력을 적용하여 실제 제조 환경에서의 적용 가능성을 평가함으로써 산업 규모 검증도 추진될 것입니다. 향후 연구에는 그라운드 트루스와 탐지된 패치에 대한 파싱 성능을 벤치마킹하여 잠재적인 연쇄 오류 효과에 대한 체계적인 연구도 포함될 것이며, 이를 통해 탐지 품질이 하류 의미 추출에 미치는 영향을 보다 상세히 이해할 수 있을 것입니다. 또한 수동 개입을 최소화하기 위해 오류 탐지 및 수정 메커니즘을 통합하는 데 주력할 것입니다. 더불어, 구조화된 출력을 실시간 제조 피드백과 통합하고 적응형, 상황 인식 의사결정 모듈을 개발함으로써 다양한 생산 환경에서 프레임워크의 견고성과 적응성을 향상시킬 것입니다.

이해 상충 선언

저자들은 본 논문에 보고된 연구에 영향을 미쳤을 것으로 보일 수 있는 알려진 이해 상충이나 개인적 관계가 없음을 선언합니다.

감사의 말

본 연구는 싱가포르 과학기술연구청(A*STAR)의 RIE2025 MTC IAF-PP 연구비(연구비 번호 M22K5a0045) 지원을 받아 수행되었습니다. 또한 A*STAR와 싱가포르 난양공과대학교(NTU)가 지원하는 싱가포르 국제 대학원 장학금(SINGA)(수혜자: Muhammad Tayyab Khan)의 지원을 받았습니다.

참고문헌

- [1] Y.-H. Lin, Y.-H. Ting, Y.-C. Huang, K.-L. Cheng, 및 W.-R. Jong, “2D 엔지니어링 도면의 자동 인식을 위한 딥러닝 통합,” *Machines*, vol. 11, no. 8, Art. no. 8, 2023년 8월, doi: 10.3390/machines11080802.
- [2] “Y14.5 치수 및 공차 - ASME.” 접속일: 2024년 9월 27일. [온라인]. 이용 가능: <https://www.asme.org/codes-standards/find-codes-standards/y14-5-dimensioning-tolerancing>
- [3] W. Sun 및 Y. Gao, “기하 치수 및 공차 표기 실습을 위한 기준점 기반 모델,” *J. Eng. Technol.*, vol. 35, pp. 38–47, 2018년 9월.
- [4] “AutoCAD Mechanical 2022 도움말 | 풍선 정보 (AutoCAD Mechanical 도구 모음) | Autodesk.” 접속일: 9월 27, 2024년 [온라인]. 출처: https://help.autodesk.com/view/AMECH_PP/2022/ENU/?guid=GUID-F12F0EA0-0810-42EE-A3FE-327041AFAEEE
- [5] “데이터 관리 및 SPC 소프트웨어,” MeasurLink. 접속일: 2024년 9월 27일. [온라인]. 이용 가능: <https://measurlink.com/>
- [6] J. Redmon, S. Divvala, R. Girshick, 및 A. Farhadi, “You Only Look Once: 통합 실시간 물체 탐지,” *2016 IEEE 컴퓨터 비전 및 패턴 인식 컨퍼런스(CVPR)*, 미국 네바다주 라스베이거스: IEEE, 2016년 6월, pp. 779–788. doi: 10.1109/CVPR.2016.91.
- [7] M. T. Khan, L. Chen, Y. H. Ng, W. Feng, N. Y. J. Tan, 및 S. K. Moon, “자동화된 엔지니어링 도면 정보 추출을 위한 비전-언어 모델 미세 조정,” 2024년 11월 6일, *arXiv*: arXiv:2411.03707. doi: 10.48550/arXiv.2411.03707.
- [8] J. V. Toro 및 M. Tarkian, “기계 도면 내 텍스트 인식 최적화: 포괄적 접근법,” *Machines*, 제13권, 제3호, 254쪽, 2025년 3월, doi: 10.3390/machines13030254.
- [9] “방향성 바운딩 박스 객체 탐지 - Ultralytics YOLO 문서.” 접속일: 2025년 4월 18일. [온라인]. 이용 가능: <https://docs.ultralytics.com/tasks/obb/>
- [10] G. Kim 외, “OCR-Free Document Understanding Transformer,” in *Computer Vision – ECCV 2022*, vol. 13688, S. Avidan, G. Brostow, M. Cissé, G. M. Farinella, 및 T. Hassner 편집, Lecture Notes in Computer Science, vol. 13688. , Cham: Springer Nature Switzerland, 2022, pp. 498–517. doi: 10.1007/978-3-031-19815-1_29.
- [11] B. Xiao 외, “Florence-2: 다양한 비전 작업을 위한 통합 표현의 발전,” *2024 IEEE/CVF 컴퓨터 비전 및 패턴 인식 컨퍼런스(CVPR)*, 미국 워싱턴주 시애틀: IEEE, 2024년 6월, pp. 4818–4829. doi: 10.1109/CVPR52733.2024.00461.
- [12] A. Corallo, V. Del Vecchio, M. Lezzi, 및 A. Luperto, “제품 수명 주기 관리에서의 모델 기반 기업 접근법: 최신 동향 및 향후 연구 방향,” *Sustainability*, 제14권, 제3호, Art. No. 3, 2022년 1월, doi: 10.3390/su14031370.
- [13] M. Dalibor, N. Jansen, B. Rumpe, L. Wachtmeister, 및 A. Wortmann, “가상 제품 설계를 위한 모델 주도 시스템 엔지니어링,” *2019 ACM/IEEE 제22회 모델 주도 엔지니어링 언어 및 시스템 국제 컨퍼런스 부록 (MODELS-C)*, 독일 뮌헨: IEEE, 2019년 9월, pp. 431–436. doi: 10.1109/MODELS-C.2019.00069.

- [14] W. Khallouli, M. S. Uddin, A. Sousa-Poza, J. Li, 및 S. Kovacic, “생성적 데이터 증강을 활용한 트랜스포머 기반 OCR 모델을 이용한 엔지니어링 문서 인식,” *Electronics*, 제14권, 제1호, Art. No. 1, 2025년 1월, doi: 10.3390/electronics14010005.
- [15] J. Gao, D. T. Zheng, N. Gindy, 및 D. Clark, “가공 특징에 대한 기하학적 치수 및 공차 추출/변환,” *Int. J. Adv. Manuf. Technol.*, 제26권, 제4호, pp. 405–414, 2005년 8월, doi: 10.1007/s00170-004-2195-3.
- [16] D. B. Lysak, P. M. Devaux, 및 R. Kasturi, “엔지니어링 도면의 자동 해석을 위한 뷰 라벨링,” *Pattern Recognit.*, 제28권, 제3호, pp. 393–407, 1995년 3월, doi: 10.1016/0031-3203(94)00103-S.
- [17] L. Jamieson, C. Francisco Moreno-García, 및 E. Elyan, “복잡한 문서 및 엔지니어링 도면의 디지털화를 위한 딥 러닝 방법의 고찰,” *Artif. Intell. Rev.*, vol. 57, no. 6, p. 136, 2024년 5월, doi: 10.1007/s10462-024-10779-2.
- [18] Y. Xu 외, “기계 공학 도면을 위한 공차 정보 추출 - 디지털 이미지 처리 및 딥 러닝 기반 모델,” *CIRP J. Manuf. Sci. Technol.*, 제50권, 55–64쪽, 2024년 3월, doi: 10.1016/j.cirpj.2024.01.013.
- [19] M. Francois, V. Eglin, 및 M. Biou, “공학 문서에서의 텍스트 탐지 및 OCR 후 보정,” 2022, pp. 726–740. doi: 10.1007/978-3-031-06555-2_49.
- [20] S. Mani, M. A. Haddad, D. Constantini, W. Douhard, Q. Li, 및 L. Poirier, “딥 러닝 및 그래프 검색을 이용한 엔지니어링 도면의 자동 디지털화,” *2020 IEEE/CVF 컴퓨터 비전 및 패턴 인식 워크숍(CVPRW)*, 미국 워싱턴주 시애틀: IEEE, 2020년 6월, pp. 673–679. doi: 10.1109/CVPRW50498.2020.00096.
- [21] E.-S. Yu, J.-M. Cha, T. Lee, J. Kim, 및 D. Mun, “딥러닝 네트워크를 이용한 이미지 형식의 배관 및 계장 도면 특징 인식,” *Energies*, 제12권, 제23호, 논문 번호 23, 2019년 1월, doi: 10.3390/en12234425.
- [22] M. S. M. Yazed, E. F. A. Shaubari, 및 M. H. Yap, “엔지니어링 도면 인식에 대한 신경망 접근법의 검토 및 향후 방향,” *JOIV Int. J. Inform. Vis.*, 제7권, 제4호, pp. 2513–2522, 2023년 12월, doi: 10.62527/joiv.7.4.1716.
- [23] “High QA - 제조 품질 전문가.” 접속일: 2025년 4월 13일. [온라인]. 이용 가능: <https://www.highqa.com/>
- [24] B. Faltin, P. Schönfelder, 및 M. König, “키포인트 기반 딥러닝 접근법을 이용한 엔지니어링 도면상의 기호 탐지 성능 향상,” *EG-ICE 20223 학회 논문집*, pp. 1–10, 2023년 7월.
- [25] M. T. Khan, L. Chen, Y. H. Ng, W. Feng, N. Y. J. Tan, 및 S. K. Moon, “컴퓨터 지원 설계에서 제조 특징 인식을 위한 비전-언어 모델 활용,” *J. Comput. Inf. Sci. Eng.*, 제25권, 제104501호, 2025년 8월, doi: 10.1115/1.4069266.
- [26] Y. Xu, M. Li, L. Cui, S. Huang, F. Wei, 및 M. Zhou, “LayoutLM: 문서 이미지 이해를 위한 텍스트 및 레이아웃 사전 학습,” *제26회 ACM SIGKDD 국제 지식 발견 및 데이터 마이닝 컨퍼런스 논문집*, 2020년 8월, pp. 1192–1200. doi: 10.1145/3394486.3403172.
- [27] S. Appalaraju, B. Jasani, B. U. Kota, Y. Xie, 및 R. Manmatha, “DocFormer: 문서 이해를 위한 종단간 트랜스포머,” *2021 IEEE/CVF 국제 컴퓨터 비전 컨퍼런스(ICCV)*, 캐나다 퀘벡주 몬트리올: IEEE, 2021년 10월, pp. 973–983. doi: 10.1109/ICCV48922.2021.00103.
- [28] C. Gu, K. Lin, Y. Luo, J. Hou, 및 X.-Y. Li, “ViRED: 엔지니어링 도면 내 시각적 관계 예측,” 2024년 제20회 모빌리티, 센싱 및 네트워킹 국제 컨퍼런스(MSN)에서 발표, IEEE 컴퓨터 학회, 2024년 12월, pp. 681–688. doi: 10.1109/MSN63567.2024.00097.
- [29] L. Xie 외, “그래프 신경망을 활용한 엔지니어링 도면 기반 제조 방법 분류,” *Comput. Ind.*, vol. 142, p. 103697, 2022년 11월, doi: 10.1016/j.compind.2022.103697.
- [30] J. Gao, D. T. Zheng, N. Gindy, 및 D. Clark, “기하 치수의 추출/변환 및

“가공 형상의 공차,” *Int. J. Adv. Manuf. Technol.*, 제26권, 제4호, 405–414쪽, 2005년 8월, doi: 10.1007/s00170-004-2195-3.

- [31] R. Dzhupova, R. Banotra, J. Bosch, 및 H. H. Olsson, “기술 도면의 설계 오류를 탐지하기 위한 패턴 인식 방법,” *2022 IEEE World AIoT Congress (AIoT)*, 2022년 6월, pp. 642–648. doi: 10.1109/AIoT54504.2022.9817294.
- [32] J. Esanakula, Naga venkata Sridhar, 및 V. Rangadu, “지식 기반 엔지니어링: 개념, 접근법 및 미래 동향,” *Am. J. Intell. Syst.*, vol. 2015, pp. 1–17, 2015년 1월, doi: 10.5923/j.ajis.20150501.01.
- [33] G. Stavropoulou 외, “지능형 제조 공정을 위한 디지털 트윈과 지식 그래프의 결합,” *Sensors*, 제24권, 제8호, 2618쪽, 2024년 1월, doi: 10.3390/s24082618.
- [34] “선도적인 이미지 및 비디오 데이터 주석 플랫폼 | CVAT.” 접속일: 2025년 3월 22일. [온라인].
출처: <https://www.cvat.ai>
- [35] P. Company, R. Plumed, C. González-Lluch, M. Contero, 및 J. D. Camba, “도면을 CAD 모델로 리버스 엔지니어링할 때 모호성을 분류하고 해결하는 전략,” *Cogent Eng.*, 제12권, 제1호, p. 2438810, 2025년 12월, doi: 10.1080/23311916.2024.2438810.
- [36] X. Xie, G. Cheng, J. Wang, X. Yao, 및 J. Han, “물체 검출을 위한 Oriented R-CNN,” *2021 IEEE/CVF 국제 컴퓨터 비전 컨퍼런스 (ICCV)*, 캐나다 퀘벡주 몬트리올: IEEE, 2021년 10월, pp. 3500–3509. doi: 10.1109/ICCV48922.2021.00350.
- [37] J. Han, J. Ding, N. Xue, 및 G.-S. Xia, “ReDet: 항공 물체 탐지를 위한 회전 불변 탐지기,” *2021 IEEE/CVF 컴퓨터 비전 및 패턴 인식 컨퍼런스 (CVPR)*, 미국 테네시주 내슈빌: IEEE, 2021년 6월, pp. 2785–2794. doi: 10.1109/CVPR46437.2021.00281.
- [38] Ultralytics, “OBB.” 접속일: 2025년 9월 2일. [온라인]. 이용 가능: <https://docs.ultralytics.com/tasks/obb>
- [39] “COCO 데이터셋 - Ultralytics YOLO 문서.” 접속일: 2025년 4월 17일. [온라인]. 이용 가능:
<https://docs.ultralytics.com/datasets/detect/coco/#usage>
- [40] “ASME Y14.5 GD&T 표준 | GD&T 기초.” 접속일: 2025년 4월 19일. [온라인]. 이용 가능: <https://www.gdandtbasics.com/asme-y14-5-gdt-standard/>
- [41] “torchvision.transforms — Torchvision 마스터 문서.” 접속일: 2025년 3월 22일. [온라인].
참조: <https://pytorch.org/vision/0.9/transforms.html>
- [42] “naver-clova-ix/donut-base · Hugging Face.” 접속일: 2025년 6월 9일. [온라인]. 이용 가능: <https://huggingface.co/naver-clova-ix/donut-base>
- [43] Z. Liu 외, “Swin Transformer: Hierarchical Vision Transformer using Shifted Windows,” *2021 IEEE/CVF 국제 컴퓨터 비전 컨퍼런스 (ICCV)*, 캐나다 퀘벡주 몬트리올: IEEE, 2021년 10월, pp. 9992–10002. doi: 10.1109/ICCV48922.2021.00986.
- [44] Y. Liu 외, “신경망 기계 번역을 위한 다국어 노이즈 제거 사전 학습,” *Trans. Assoc. Comput. Linguist.*, vol. 8, pp. 726–742, 2020, doi: 10.1162/tacl_a_00343.
- [45] M. T. Khan, Z. Yong, L. Chen, J. M. Tan, W. Feng, 및 S. K. Moon, “정밀 조정된 문서 이해 트랜스포머를 활용한 구조화된 정보 추출을 위한 엔지니어링 도면 자동 구문 분석,” 2025년 5월 2일, *arXiv*: arXiv:2505.01530. doi: 10.48550/arXiv.2505.01530.
- [46] “microsoft/Florence-2-base · Hugging Face.” 접속일: 2025년 6월 9일. [온라인]. 이용 가능:
<https://huggingface.co/microsoft/Florence-2-base>
- [47] M. Ding, B. Xiao, N. Codella, P. Luo, J. Wang, 및 L. Yuan, “DaViT: Dual Attention Vision Transformers,” in *Computer Vision – ECCV 2022*, vol. 13684, S. Avidan, G. Brostow, M. Cissé, G. M. Farinella, and T. Hassner, Eds., in Lecture Notes in Computer Science, vol. 13684., Cham: Springer Nature Switzerland, 2022, pp. 74–92. doi: 10.1007/978-3-031-20053-3_5.
- [48] T. Chen, S. Saxena, L. Li, D. J. Fleet, 및 G. Hinton, “Pix2seq:

물체 탐지를 위한 언어 모델링 프레임워크,” 2022년 3월 27일, *arXiv*: arXiv:2109.10852. doi: 10.48550/arXiv.2109.10852.

- [49] K. Lv, Y. Yang, T. Liu, Q. Guo, 및 X. Qiu, “제한된 자원을 가진 대규모 언어 모델을 위한 전체 매개변수 미세 조정,” *제62회 계산언어학회 연례 회의 논문집 (제1권: 장문 논문)*, L.-W. Ku, A. Martins, 및 V. Srikumar 편집, 태국 방콕: 컴퓨터언어학회, 2024년 8월, pp. 8187–8198. doi: 10.18653/v1/2024.acl-long.445.
- [50] “ISO 21920-1:2021,” ISO. 접속일: 2025년 5월 14일. [온라인]. 이용 가능: <https://www.iso.org/standard/72196.html>
- [51] “국제 공차(IT) 등급 ISO 286-1 - 2010(E) 표.” 접속일: 2025년 5월 14일. [온라인]. 이용 가능: https://www.engineersedge.com/international_tol.htm#google_vignette
- [52] “Machinery’s Handbook 제29판.” 접속일: 2025년 5월 14일. [온라인]. 참조: <https://dl.icdst.org/pdfs/files4/80364b03673ba30eb5ccf1e27e119ffc.pdf>
- [53] “ISO 529:2017 - 단형 기계용 탭 및 수동 탭,” iTeh Standards. 확인일: 2025년 5월 15일. [온라인]. 이용 가능: <https://standards.itih.ai/catalog/standards/iso/2a88e2d4-ca61-475e-a535-80496ea77a81/iso-529-2017>
- [54] Caro, “표면 거칠기 설명: Ra, Rq, Rz 등,” Richconn | 정밀 CNC 부품 제조 | 중국 CNC 가공 제조업체. 접속일: 2025년 5월 15일. [온라인]. 이용 가능: <https://richconn.com/surface-roughness/>
- [55] “ISO 13399-1:2006,” ISO. 접속일: 2025년 8월 28일. [온라인]. 이용 가능: <https://www.iso.org/standard/36757.html>

부록

부록 A: 자체 개발 GUI를 통해 시연된 추가 주석 파싱 결과

이 부록에서는 제안된 프레임워크가 생성한 추가 파싱 결과를 사내 개발 GUI를 통해 시각화하여 제시합니다. 각 예시마다 원본 입력 도면, 신
뢰도 점수가 표시된 주석 영역 오버레이, 그리고 해당 구조화된 JSON 출력이 포함되어 있습니다. 이러한 예시들은 다양한 주석 스타일, 도면
형식 및 복잡도 수준에 걸쳐 모델이 일반화할 수 있는 능력을 보여줍니다. 종합적으로, 이 예시들은 제안된 파이프라인의 견고성을 뒷받침하며
제조 문서화 및 CAD/CAM 통합 워크플로우에 대한 실질적인 적용 가능성을 입증한다.

예시 1




그림 A1. 원본 2D 엔지니어링 도면: 스패너 조합.


```

{
  "Material": "",
  "나사산": "",
  "GD&T": [
    {"Type": "수직도", "Tolerance": "0.05", "Datums": ["A"]}, {"General Tolerance": "ISO_R
1051 – 5 x 30 x 15",
    "반경": {"R1", "R2", "R3", "R4", "R6", "R7", "R8", "R12"},
    "표면 거칠기": [
      {"Ra": "N6"},
      {"Ra": "N8"}],
    "치수": [
      {"특성": "전체 길이", "값": "55 ±0.2 mm"},
      {"특성": "조우 너비", "값": "7.2 ±0.1 mm"},
      {"특성": "손잡이 두께", "값": "9.5 ±0.4 mm"},
      {"특성": "구멍 직경", "값": "Ø5 +0.01/-0.00 mm"},
      {"특성": "링 폭", "값": "Ø14 H7 (+0.02/-0.00 mm)"},
      {"특성": "슬롯 길이", "값": "28 ±0.2 mm"},
      {"특성": "개구부 폭", "값": "13 mm"}], "제목 블록": {
    "설계자": "SMK NEGERI 26 JAKARTA", "날짜": "2013년 4월
6일",
    "축척": "2:1"
    "도면명": "스패너 조합", "비고": ""
  }
}

```

그림 A3. 국소화된 영역에 대한 비전-언어 파싱을 통해 생성된 구조화된 JSON 출력.




그림 A4. 원본 2D 설계 도면.

Detection Overview

Class	Count	Avg. Confidence
Measures	3	95.07%
Threads	1	95.73%
GD&Ts	2	95.25%

Detection Details

GD&Ts	Measures	Notes	Radii	Title Block	General Tolerances	Surfac
	Nominal Value	Tolerance	Upper Limit	Lower Limit		
1	U+2300 7		+0.5	+0.3		
2	15		0	-0.3		
3	18		+0.3	0		

Previous
Page 1/1
Next

Upload Drawing
Detect Features
Save Results

그림 A5. 방향이 지정된 주석 영역을 보여주는 YOLOv11-obb 기반 탐지 오버레이.

```

{
  "Material": "",
  "나사산": [{"유형": "M6"}], "GD&T": [
    {"Type": "Position", "Tolerance": "Ø0.2 (M)", "Datums": ["A", "B", "C"]},
    {"Type": "Position", "Tolerance": "Ø0.4", "Datums": ["A", "B", "C"]}, {"General Tolerance": ""},
    "반경": "",
    "표면 거칠기": "", "치수": [
      {"특성": "구멍 직경", "값": "Ø7 +0.5/+0.3"},
      {"Feature": "높이", "Value": "18 +0.3/0"},
      {"Feature": "나사산 깊이", "Value": "15 0/-0.3"}], "Title Block": "",
  "비고": ""
}

```

그림 A6. VLM 파서가 생성한 해당 구조화된 JSON 출력.




그림 A7. 원본 2D 설계 도면.




그림 A8. 회전 정보를 반영한 바운딩 박스를 사용한 YOLOv11-obb 기반 주석 위치 지정.

```

{
  "Material": "",
  "나사산": "",
  "GD&T": [
    {"Type": "Position", "Tolerance": "Ø0.002 (M)", "Datums": ["B (M)"]},
    {"Type": "Position", "Tolerance": "Ø0.003 (M)", "Datums": ["B (M)"]},
    {"Type": "Position", "Tolerance": "Ø0.005 (M)", "Datums": ["A", "C (M)"]},
    {"Type": "평탄도", "Tolerance": "0.002", "Datums": []},
    {"Type": "수직도", "Tolerance": "Ø0.0015", "Datums": ["A"]},
    {"Type": "평행도", "Tolerance": "0.003", "Datums": ["A"]},
    {"Type": "원형 편차", "Tolerance": "0.001", "Datums": ["B"]}, {"General Tolerance": ""},
    "반경": "",
    "표면 거칠기": "", "측정값": [
      {"특성": "면 두께", "값": "0.500 ±0.010"},
      {"특성": "전체 길이", "값": "2.75 ±0.02"},
      {"특성": "첫 번째 단계 길이", "값": "1.750 ±0.005"},
      {"특성": "두 번째 단계 길이", "값": "1.120 ±0.005"},
      {"특성": "세 번째 단 길이", "값": "0.450 ±0.005"},
      {"특성": "큰 직경", "값": "Ø1.375 ±0.005"},
      {"특성": "숄더 직경", "값": "Ø0.980 +0.005/-0.000"},
      {"Feature": "내부 스텝 직경", "Value": "Ø0.315 +0.003/-0.000"},
      {"Feature": "외경", "Value": "Ø0.820 +0.005/-0.000"},
      {"Feature": "볼트 구멍 원주 직경", "Value": "Ø2.125"},
      {"Feature": "볼트 구멍 직경", "Value": "Ø0.210 +0.005/-0.000"},
      {"Feature": "모따기", "Value": "8X 45°"}, {"제목 블록": ""},
      ""
    ],
    "Notes": ""
  }
}

```

그림 A9. 감지된 주석 내용을 나타내는 구문 분석된 JSON 출력.

부록 B: 공구 및 파라미터 데이터베이스 스키마

이 부록에서는 디지털 트윈 환경에서 규칙 기반 공구 선택 및 가공 매개변수 검색을 지원하는 기본 데이터 스키마를 제시합니다. 이 스키마는 ISO 13399 표준을 따르며, 내부 추론과 외부 시스템 통합 모두를 위해 공구 속성을 일관되고 상호 운용 가능한 방식으로 표현할 수 있게 합니다.

```
{
  공구 ID: 고유 식별자(예: DRILL_4.2_HSS),
  공구 유형: 공구의 범주(예: 트위스트 드릴, 엔드밀, 리머, 선반 인서트),
  형상: 주요 치수 (드릴의 경우: 직경 및 선단각; 선반 인서트의 경우: 노즈 반경, 내접원 등),
  재질: 공구 재질 또는 등급 (예: HSS, 카바이드 P20 등급, CBN),
  적용 재료: 공구가 적합한 공작물 재료 (예: 45 HRC 이하의 강철, 알루미늄 등),
  절삭 조건: 각 적용 가능한 재료 등급에 대한 권장 절삭 속도(m/min) 및 이송량(mm/rev 또는 mm/tooth).
  표준 코드: ISO 13399 매개변수 코드 또는 공구 카탈로그 번호와 연결되는 선택적 필드.
}
```

그림 B1. 규칙 기반 공구 및 매개변수 선택을 위한 공구 스키마 및 조회 로직.

공구 데이터베이스는 서로 연관된 두 개의 테이블로 구성됩니다:

1. **공구 인벤토리 테이블:** 기하학적 및 분류 메타데이터를 저장합니다.
2. **절삭 데이터 테이블:** 특정 공구-재료 조합에 대한 공정 매개변수를 저장합니다.

표 B1. 형상, 재료 및 분류 필드가 포함된 공구 목록(ISO 13399 준수).

공구 ID	공구 유형	직경	재질	코팅	ISO 코드
T042	나사형 드릴	4.2 mm	HSS	—	ISO13399_001
T043	나선형 탭	M5×0.8	HSS-E	TiN	ISO13399_002

표 B2. 공구-재료 조합에 대한 권장 절삭 파라미터.

공구 ID	재료	속도 (m/min)	이송량 (mm/rev)
T042	C-45 강철	20	0.1
T043	C-45 강철	15	0.05

조회 예시 (사례 연구 참조):

규칙 기반 시스템이 C-45 강철에 M5 나사산을 가공해야 할 필요성을 식별하면(5.2절에서 시연한 바와 같이), 공구 데이터베이스를 조회합니다. 표 B1에서 해당 재료에 적합한 M5×0.8 규격의 나선형 탭인 공구 T043을 선택합니다. 그런 다음 표 B2를 사용하여 권장 절삭 속도인 15를 검

색합니다.

분당 미터(m/min) 및 회전당 0.05mm의 이송 속도. 이러한 매개변수는 디지털 공정 계획에 적용되어, 일관되고 표준을 준수하는 가공 권장 사항을 보장합니다.