

비전-언어 모델을 활용한 다중 뷰 엔지니어링 도면의 자동 해석을 위한 다단계 하이브리드 프레임워크

Muhammad Tayyab Khan^{1,3*#}, Zane Yong^{2#}, Lequn Chen², Wenhe Feng¹, Nicholas Yew Jin Tan¹,
Seung Ki Moon³

¹ 싱가포르 제조기술연구소(SIMTech), 과학기술연구청(A*STAR), 5 CleanTech Loop, #01-01 CleanTech Two
Block B, Singapore 636732, Republic of Singapore

² 첨단 재제조 및 기술 센터(ARTC), 과학기술연구청(A*STAR), 3 CleanTech Loop, #01-01 CleanTech Two, 싱
가포르 637143, 싱가포르 공화국

³ 난양공과대학교 기계항공공학과, 639798, 싱가포르

*KHAN0022@e.ntu.edu.sg #동등한 기여

초록. 엔지니어링 도면은 제조 분야의 의사소통에 있어 핵심적인 역할을 하며, 설계 의도, 공차 및 생산 세부 사항을 전달하는 주요 수단이다. 그러나 다양한 레이아웃, 방향, 기호와 텍스트가 혼합된 콘텐츠로 인해, 복잡한 다중 뷰 도면에 포함된 밀집된 주석을 수동 방식, 일반적인 광학 문자 인식(OCR) 시스템 또는 기존의 딥러닝 접근법으로 해석하는 것은 여전히 어려운 과제이다. 이러한 문제를 해결하기 위해, 본 논문은 최신 탐지 모델과 비전 언어 모델(VLM)을 활용하여 2D 다중 뷰 엔지니어링 도면을 자동으로 해석하기 위한 3단계 하이브리드 프레임워크를 제안한다. 첫 번째 단계에서는 YOLOv11-det이 레이아웃 분할을 수행하여 *뷰*, *제목 블록*, *주석과* 같은 핵심 영역을 위치 파악한다. 두 번째 단계에서는 YOLOv11-obb를 사용하여 *치수*, *GD&T* 기호, *표면 거칠기* 지표 등 주석을 방향성을 고려하여 세밀하게 탐지한다. 세 번째 단계에서는 의미론적 콘텐츠 분석을 위해 두 개의 도넛(Donut) 기반, OCR이 필요 없는 VLM을 활용한다. *알파벳* VLM은 *제목블록*과 *주석에서* 텍스트 및 범주형 정보를 추출하고, *수치* VLM은 *치수*, *GD&T* 프레임, *표면 거칠기* 등의 정량적 데이터를 해석한다. 견고성과 일반화 능력을 보장하기 위해 두 가지 특수 데이터셋이 개발되었습니다: 레이아웃 검출용 1,000개의 도면과 주석 수준 훈련용 1,406개의 도면입니다. *Alphabetical* VLM은 전체 F1 점수 0.672를, *Numerical* VLM은 0.963을 기록하여 각각 텍스트 및 정량적 해석에서 뛰어난 성능을 입증했습니다. 통합된 JSON 출력을 통해 CAD 및 제조 데이터베이스와의 원활한 통합이 가능해져, 지능형 엔지니어링 도면 분석을 위한 확장 가능한 솔루션을 제공합니다.

키워드: 2D 엔지니어링 도면, 다중 뷰 해석, 비전 언어 모델, 기술 문서 이해, 구조화 데이터 추출

1 서론

엔지니어링 도면은 제조 가능성, 제품 품질 및 비용에 영향을 미치는 핵심 정보를 포함하고 있어 산업 커뮤니케이션의 중심에 여전히 자리 잡고 있다 [1–3]. 이 정보를 구조화되고 기계가 읽을 수 있는 형식으로 변환하는 것은 컴퓨터 지원 설계(CAD), 공정 계획 및 검사에서 자동화를 가능하게 하는 데 매우 중요하다. 그러나 산업 현장에서는 이 추출 과정이 여전히 대부분 수작업으로 이루어지고 있어, 디지털 제조 워크플로우에 큰 병목 현상을 초래하고 있다. 수작업 전사는 시간이 많이 소요되고 확장성이 떨어지는데, 특히 수백 개의 주석이 여러 도면 뷰에 분산되어 있는 복잡한 도면의 경우 더욱 그러하다. 일반적인 광학 문자 인식(OCR) 도구는 회전된 텍스트, 밀집된 레이아웃, 기하학적 치수 및 공차(GD&T) 피처 프레임과 같은 기호 구조를 해석하는 데 어려움을 겪기 때문에 이러한 문제를 더욱 악화시킵니다[4]. 이러한 한계는 신뢰할 수 있는 정보 추출을 위해 OCR에 의존하지 않고 레이아웃을 인식하는 접근 방식이 필요함을 강조합니다.

최근 딥러닝 기술이 이 문제의 특정 측면을 자동화하는 데 적용되고 있다. 예를 들어, Reddy 등[5]은 기계 도면 내 GD&T 기호를 인식하기 위해 탐지 모델을 미세 조정했으며, Yazed 등[6]은 GD&T 인식을 위한 하이브리드 YOLO-OCR 파이프라인을 제안했다. Faltin 등[7]은 기호 탐지 작업에 대해 여러 객체 탐지기를 벤치마킹했다. 그러나 이러한 연구들은 도면 정보의 단편적인 측면에만 초점을 맞추고 있어, 복잡하고 주석이 밀집된 도면으로 일반화하거나 다양한 주석 유형에 걸쳐 정확한 문맥 인식 파싱을 달성하는 데는 실패했다.

저희의 선행 연구 [4,8,9]에서는 Document Understanding Transformer(Donut) 및 Florence-2와 같은 오픈소스 비전 언어 모델(VLM)을 엔지니어링 도면 데이터에 대해 미세 조정하여 2D 입력으로부터 정보를 추출했습니다. 또한, 비교 분석을 위해 GPT-4o 및 Claude-3.5-Sonnet과 같은 비공개 소스 모델도 평가했습니다. 미세 조정된 VLM들은 단일 부품 도면에서 우수한 성능을 보였으며, 기호적 요소와 텍스트적 요소를 모두 효과적으로 파싱했다. 그러나 복잡한 다중 뷰 도면에서는 밀집된 주석과 중첩된 뷰로 인해 성능이 저하되었다. 전체 도면을 단일 패스로 처리할 경우 영역 중복, 위치 파악 오류, 그리고 일관성 없는 추출 결과가 발생했다. 이러한 한계로 인해 해석 전에 의미적으로 일관된 영역을 분리하기 위한 영역 인식 세분화 전략의 필요성이 대두되었다.

이러한 과제를 해결하기 위해, 본 연구는 도면 해석을 레이아웃 분할, 방향 인식 주석 위치 파악, 그리고 작업 특화 의미 분석으로 분해하는 계층적 다단계 하이브리드 프레임워크를 제안한다. 이 프레임워크는 기존의 탐지 기술과 VLM을 활용하지만, 그 독창성은 엔지니어링 도면의 의미 구조를 반영하기 위해 이러한 구성 요소들을 작업 중심으로 조율한다는 점에 있다. 기존의 단일 단계 또는 종단 간(end-to-end) 접근법과 달리, 제안된 설계는 세밀한 분석 전에 뷰를 명시적으로 분리하고, 방향성 바운딩 박스(OBB) 탐지를 중간 추론 계층으로 통합하며, 텍스트 및 수치 콘텐츠를 위한 특화된 VLM을 활용하여 복잡한 다중 뷰 레이아웃을 견고하게 해석할 수 있게 한다. 이 프레임워크는 두 가지 선별된 데이터셋을 사용하여 개발되었습니다: 뷰 수준 분할을 위한 1,000개의 도면과 주석 수준 훈련 및 벤치마킹을 위한 1,406개의 도면입니다. 통합된 평가 파이프라인은 단계 전반에 걸쳐 일관된 성능 측정을 보장합니다. 제안된 방법은 복잡한 다중 뷰 도면에 대한 강력한 일반화 능력을 보여주며, 조직별 표준에 적응하기 위한 지속적인 학습을 지원합니다.

본 논문의 나머지 구성은 다음과 같습니다. 2장에서는 제안된 방법론을 개괄합니다. 3장에서는 레이아웃 탐지, 주석 위치 지정, VLM 훈련을 포함한 데이터셋 개발 과정을 설명합니다. 4장에서는 방법 구현 및 결과를 제시합니다. 5장에서는 연구 결과를 논의하며, 6장에서는 한계점과 향후 연구 방향을 제시하며 결론을 맺습니다.

2 방법론 개요

제안된 프레임워크는 그림 1에 표시된 바와 같이, 2D 엔지니어링 도면에서 구조화된 정보를 자동으로 추출하기 위해 3단계 접근 방식을 채택합니다. 각 단계는 서로 다른 세부 수준에서 작동하며, 레이아웃 탐지, 세밀한 주석 위치 파악, 의미론적 구문 분석을 수행합니다. 첫 번째 단계에서 영역 탐지기(YOLOv11-det)는 주요 레이아웃 구성 요소(도면 뷰, 제목 블록, 주석)를 식별하고 해당 경계 영역을 윤곽선으로 표시합니다. 이러한 분할은 명확한 레이아웃 계층 구조를 확립하고 관련 관심 영역을 정의함으로써 후속 처리를 단순화합니다. 두 번째 단계에서는 방향 인식 객체 탐지(YOLOv11-obb)를 사용하여 상세한 뷰 분석을 수행함으로써, 탐지된 각 뷰 내에서 GD&T, 치수, 표면 거칠기 등의 주요 주석을 국소화합니다. 마지막 단계에서는 두 가지 특화된 VLM을 적용합니다: 텍스트 영역(제목 블록 및 주석)을 위한 알파벳 모델과 정량적 주석을 위한 숫자 모델입니다. 모든 단계의 출력은 기하학적 정보와 텍스트 정보를 모두 포함하는 통합된 JSON 형식으로 통합되어, 후속 제조 작업에 직접 적용할 수 있게 됩니다.




그림 1. 2D 도면에서 구조화된 정보를 추출하기 위해 제안된 3단계 파이프라인의 개요. 이 프레임워크는 레이아웃 탐지, 주석 위치 파악, 비전 언어 구문 분석을 통합하여 후속 제조 작업을 위한 통합된 JSON 출력을 생성한다.

3 데이터셋 구축 및 통계


제안된 프레임워크는 탐지 및 구문 분석 작업 모두에 맞춤형 도메인 특화 주석 데이터셋에 의존한다. 적절한 지도, 클래스 다양성, 균형 잡힌 평가를 보장하기 위해 각 단계별로 별도의 데이터셋을 큐레이션하였다.

3.1 레이아웃 탐지 데이터셋

다양한 도면 레이아웃과 내용 유형을 반영한 2D 기계 도면 1,000점(PDF 및 이미지 형식)을 수집했습니다. 이 데이터셋은 여러 정투영도와 단면도가 포함된 복잡한 조립 도면부터 간단한 부품 도면에 이르기까지 광범위한 엔지니어링 문서를 포괄합니다. 각 도면에는 '도면(Views)', '제목 블록(Title Block)', '주석(Notes)'의 세 가지 영역 유형에 대해 수동으로 바운딩 박스가 주석 처리되었습니다. 총 라벨 수는 도면 3,498개, 제목 블록 458개, 주석 1,127개로, 대부분의 도면이 여러 개의 도면 뷰를 포함하고 있으며 때로는 여러 개의 주석이 포함되어 있음을 나타냅니다. 이 데이터셋은 1단계에서 YOLOv11-det 모델을 훈련하는 데 사용되었습니다. 그림 2는 YOLOv11-det 훈련을 위한 주석이 달린 레이블 분포를 보여줍니다. 뷰가 레이블이 지정된 영역의 대부분을 차지하며, 그 다음으로 타이틀 블록과 노트가 뒤따르는데, 이는 시각적 콘텐츠가 가장 많이 나타나는 실제 엔지니어링 도면과 일치합니다.

3.2 주석 위치 지정 데이터셋

세부 주석 데이터셋의 경우, 상세한 주석 정보에 중점을 둔 1,406개의 도면으로 구성된 더 방대한 세트를 구축했습니다. 이 자료들은 다양한 도면 작성 및 주석 스타일을 확보하기 위해 온라인 저장소와 내부 아카이브에서 수집했습니다. 우리는 뷰 영역 내에서 치수(반경 및 나사산 주석 포함), GD&T 프레임, 표면 거칠기 기호라는 세 가지 범주에 주석을 달았습니다. 총 9,663개의 치수, 3,215개의 GD&T, 152개의 표면 거칠기 인스턴스에 주석이 달렸습니다. 그림 2에 시각화된 클래스 분포는 현저히 불균형한데, 치수 압도적으로 많고 GD&T 프레임은 적으며 표면 거칠기 기호는 상대적으로 드물다. 이는 일반적으로 다른 유형보다 치수 주석이 훨씬 더 많이 포함되는 실제 도면과 일치한다. 이 데이터셋은 2단계에서 사용된 YOLOv11-obb 모델을



을 훈련하는 데 활용되었다.

그림 2. 레이아웃 영역 유형(왼쪽) 및 세분화된 주석 범주(오른쪽)에 대한 주석이 달린 레이블 분포.

3.3 VLM 훈련 데이터셋

두 가지 서로 다른 VLM을 훈련하고 평가하기 위해, 우리는 감지된 각 영역이나 주석을 해당 그라운드 트루 텍스트 콘텐츠와 짝지은 참조 데이터셋을 구축했습니다. 모든 *타이틀 블록*(Title Block) 및 *노트*(Notes) 영역에 대해, 도면에서 추출된 실제 정보를 나타내기 위해 구조화된 텍스트와 JSON 필드를 준비했습니다. 마찬가지로, 각 *GD&T* 기호, *치수*(Measure), *표면 거칠기*(Surface Roughness) 이미지 패치에 대해 올바른 수치 또는 기호 사양(예: 공차 값 또는 거칠기 매개변수)을 기록했습니다. 전체적으로 이 데이터셋은 탐지 데이터셋 내의 모든 주석이 달린 영역에서 파생된 약 15,000개의 이미지-텍스트 쌍을 포함하고 있습니다. 이 중 약 1,585개 샘플은 *제목 블록* 및 *주석* 영역에 해당하며, 약 13,000개 샘플은 수치 주석을 나타냅니다. 이 구조화된 데이터셋은 후속 VLM 미세 조정 및 평가의 기반을 제공하며, 정확한 필드 추출과 구조화된 정보 생성을 지원하는 정밀한 JSON 출력을 통한 감도를 보장합니다. 모든 주석의 품질은 신중하게 검증되었으며, 실제 분포를 반영하도록 클래스 비율을 유지했습니다.

4 상세한 방법 구현 및 결과

데이터셋 준비 후, 제안된 프레임워크의 각 단계는 모듈별 신뢰성과 유효성을 보장하기 위해 독립적인 감독 학습을 통해 훈련 및 평가되었습니다. 그림 3은 단일 엔지니어링 도면에 적용된 전체 프레임워크의 대표적인 예시를 보여주며, 레이아웃 탐지에서 주석 위치 지정 및 비전-언어 파싱으로의 전환 과정을 보여줌으로써 통합된 구조화된 JSON 출력을 생성하는 과정을 보여줍니다.




그림 3. 제안된 프레임워크를 샘플 도면에 적용한 예시. 레이아웃 탐지, 세밀한 주석 위치 지정, 의미적 구문 분석을 거쳐 통합된 JSON 출력을 생성하는 과정을 보여준다.

4.1 1단계: 영역 탐지 (레이아웃 분할)

첫 번째 단계는 도면의 주요 레이아웃 구성 요소인 도면 *뷰*, *제목 블록*, *주석*을 식별하는 데 중점을 둡니다. 이러한 상위 레벨 영역을 분리하면 후속 모듈에 공간적 맥락과 집중 대상을 제공함으로써 후속 처리를 단순화할 수 있습니다. 이 단계는 높은 위치 식별 정확도와 빠른 추론 속도를 바탕으로 선택된 YOLOv11-det 단일 단계 객체 탐지기를 사용하여 구현되었습니다. 이 모델은 세 가지 영역 클래스로 구성된 1,000개의 도면이 포함된 맞춤형 주석이 달린 레이아웃 탐지 데이터셋으로 훈련되었습니다. 데이터셋은 편향 없는 평가를 보장하기 위해 훈련용 80%, 테스트용 20%로 분할되었습니다. 추론 과정에서 탐지기는 각 영역 유형에 대해 축 정렬 바운딩 박스와 클래스 레이블을 출력하여, 각 도면을 논리적인 하위 문서로 자동 분할할 수 있게 합니다. 탐지된 각 *뷰(View)*는 이후 기술적 주석을 위해 처리되며, *타이틀 블록(Title Block)* 및 *노트(Notes)* 영역(일반적으로 표 형식 및 텍스트 콘텐츠가 포함됨)은 텍스트 중심 파싱 단계로 전달됩니다.

YOLOv11-det 모델은 상위 레벨 영역을 탐지하는 데 뛰어난 성능을 보였습니다. 정규화된 혼동 행렬(그림 4)에서 볼 수 있듯이, 이 모델은 '*Views*'에서 0.96, '*Title Block*'에서 0.99, '*Notes*'에서 0.98의 정확도를 기록했습니다. 이러한 결과는 이 탐지기가 다양한 도면 스타일과 템플릿 변형에 걸쳐 주요 레이아웃 구성 요소를 효과적으로 구별해 낸다는 사실을 입증합니다.

4.2 2단계: 상세 뷰 분석 (주석 위치 파악)

두 번째 단계는 국소화된 *뷰* 영역 내의 세밀한 주석을 탐지하는 데 중점을 둡니다. 엔지니어링 도면에는 치수, GD&T 형상 제어 프레임, 표면 거칠기 표시와 같이 회전되거나 방향이 지정된 수많은 기호 및 텍스트 요소가 포함되어 있는 경우가 많습니다. 이러한 주석을 효과적으로 포착하기 위해, 객체 각도와 이방성 박스 치수를 예측하도록 OBB에 최적화된 YOLO의 변형인 YOLOv11-obb를 사용했습니다. 이 모델은 *치수*, *GD&T* 프레임, *표면 거칠기* 인스턴스를 포함하는 1,406개의 주석이 달린 국소화 데이터셋으로 훈련되었습니다. 데이터셋은 훈련용 80%, 테스트용 20%로 분할되었습니다. 추론 단계에서 YOLOv11-obb는 (1단계에서) 잘라낸 각 *뷰*에 적용되어 미세 주석을 탐지하고 분류합니다. 이를 통해 해당 레이블이 부여된 OBB 집합이 생성되며, 이 결과는 비전-언어 파싱 단계로 전달됩니다.

한 번에 하나의 뷰만 처리함으로써, 여러 투영 방향의 주석이 겹쳐진 전체 도면을 탐지기가 처리할 때 발생할 수 있는 혼란을 최소화합니다. 방향성 박스 접근법은 기존의 축 정렬 검출기나 OCR 시스템이 종종 놓치는 회전된 요소의 위치를 확실하게 파악할 수 있게 해줍니다. 그림 4에서 볼 수 있듯이, 이 모델은 *치수(Measures)*에서 0.95, *GD&T*에서 0.97, *표면 거칠기(Surface Roughness)*에서 0.54의 정확도를 달성했습니다. *표면 거칠기* 항목의 정확도가 낮은 주된 이유는 데이터셋의 불균형 때문인데, 수천 개의 *치수* 및 *GD&T* 샘플에 비해 표면 거칠기 샘플은 152개에 불과하기 때문입니다. 이러한 클래스 분포의 불균형은 치수 주석이 다른 기호 유형보다 훨씬 더 흔한 실제 엔지니어링 도면의 특성을 반영한다. 그럼에도 불구하고, 이 모델은 다양한 방향의 주석을 일관되게 위치 파악하고 분류함으로써, 제한된 거칠기 데이터에도 불구하고 강력한 일반화 능력을 입증했다.




그림 4. 두 가지 주요 단계인 레이아웃 영역 탐지(왼쪽)와 세밀한 주석 위치 파악(오른쪽)에 대한 탐지 성능을 보여주는 정규화된 혼동 행렬.

4.3 3단계: 비전 언어 분석

관련 영역과 주석이 위치 파악되면, 최종 단계에서는 이들의 의미적 내용을 해석하여 텍스트가 많은 영역과 수치 영역의 시각적 데이터를 구조화된 디지털 형식으로 변환합니다.

이 단계에서는 OCR 없이도 엔드투엔드 다중 모달 추론이 가능하며, 이전 연구[8,9]에서 입증된 성능을 바탕으로 선정된 두 가지 특화된 Donut 기반 VLM을 활용합니다. 두 가지 유형의 Donut 모델이 사용됩니다: *제목 블록*(Title Block) 및 *주석*(Notes) 영역을 처리하여 범주형 및 자유 형식 텍스트를 추출하는 'Alphabetical VLM'과, *치수*(Measures), *표면 거칠기*(Surface Roughness) 주석이 포함된 잘린 이미지 패치를 처리하여 정량적 사양을 추출하는 'Numerical VLM'입니다. 두 모델은 동일한 아키텍처를 공유하지만, 수치형 VLM만이 훈련 데이터셋을 통해 미세 조정되었습니다. 이는 해당 모델의 출력이 유니코드 인코딩된 공학 기호를 포함하는 스키마 정의의 JSON으로 매핑되어 신뢰할 수 있는 감독 데이터를 제공하기 때문입니다. 반면, *제목 블록*과 *주석 영역*은 일관된 스키마가 없고 서식적 변이가 크기 때문에, *알파벳형 VLM*은 제로샷 모드로 사용되었습니다.

*수치적 VLM*은 3.3절에 설명된 데이터셋을 사용하여 훈련, 검증, 테스트에 각각 70:20:10의 비율로 분할하여 훈련되었습니다. 파인 튜닝은 NVIDIA GeForce RTX 5090 GPU에서 30 에포크 동안 수행되었으며, 코사인 학습률 감쇠(초기 학습률 1×10^{-6} , 워밍업 없음)를 적용한 AdamW 최적화기를 사용했습니다. 배치 크기 4와 혼합 정밀도(FP16) 훈련을 통해 계산 효율성을 높였습니다.

모델 성능은 정확도와 신뢰성을 평가하기 위해 정밀도, 재현율, F1 점수, 환각률을 사용하여 평가되었습니다. *Alphabetical VLM*은 Title Block에서 0.533, Notes에서 0.810의 F1 점수를 기록했으며, 이는 각각 0.478과 0.319에 해당한다. 전체 F1 점수 0.672는 텍스트가 많고 범주형인 필드가 OCR을 사용하지 않는 모델에게는 여전히 어려운 과제를 시사한다. *Numerical VLM*은 정량적 주석 유형 전반에 걸쳐 강력하고 일관된 성능을 보여주었으며, 치수(Measures)에서 0.923, GD&T(GD&Ts)에서 0.965, 표면 거칠기(Surface Roughness)에서 1.0의 F1 점수를 달성했다. 이러한 결과는 미세 조정된 Donut 모델이 엔지니어링 도면의 수치 및 기호 해석에 매우 효과적임을 입증한다. 두 VLM에 대한 정량적 평가의 상세 요약

두 VLM에 대한 정량적 평가의 상세한 요약은 표 1에 제시되어 있습니다.

추론이 완료되면 두 VLM의 출력이 통합된 JSON 형식으로 병합되며, 이때 *제목 블록* 필드, *주석* 및 모든 마디와 관련 사양이 통합됩니다. 이러한 구조화된 출력은 CAD, 공정 계획 또는 제조 데이터베이스에 직접 통합될 수 있어, 수동 전사 과정 없이도 엔지니어링 정보를 원활하고 자동으로 전송할 수 있습니다.

표 1. 테스트 데이터셋에 대한 알파벳 및 숫자 VLM의 성능 지표.

범주	정밀도	재현율	F1 점수	환각
알파벳 VLM				
제목 블록	0.522	0.545	0.533	0.478
비고	0.681	1.0	0.810	0.319
전체	0.601	0.773	0.672	0.399
숫자 VLM				
측정값	0.864	0.991	0.923	0.136
GD&T	0.933	1.0	0.965	0.067
거칠기	1.0	1.0	1.0	0.0
전체	0.932	0.997	0.963	0.067

5 토론

이 결과는 제안된 방법이 2D 도면의 자동 해석 분야에서 오랫동안 제기되어 온 과제들을 효과적으로 해결함을 보여줍니다. 전체 작업을 레이아웃 탐지, 주석 위치 파악, 의미 분석으로 분해함으로써, 이 시스템은 정확도, 해석 가능성, 계산 효율성 사이에서 실용적인 균형을 달성합니다. 기존의 단일 단계 접근법과 달리, 본 연구는 해석 전에 뷰를 분리하는 계층적 분해 방식을 도입하여, 모델 수준에서의 점진적인 개선이 아닌 복잡한 다중 뷰 도면의 견고한 처리를 가능하게 한다.

레이아웃 분할 단계는 다양한 템플릿에 걸쳐 안정적인 분할을 제공하여 도면의 각 기능적 섹션이 독립적으로 처리되도록 보장한다. 이러한 구조는 중첩되거나 주석이 밀집된 영역 간의 간섭을 현저히 줄여주며, 이는 초기 단일 패스 아키텍처에서 빈번히 관찰되던 한계점이었다. 방향 인식 검출 기능은 임의의 방향에서 상세한 주석을 인식함으로써 견고성을 한층 강화하며, 회전이나 왜곡이 발생한 상황에서도 GD&T 프레임, 치수, 표면 마감 기호를 일관되게 식별할 수 있게 한다.

두 VLM의 동작은 도메인 적응에 대한 중요한 통찰력을 제공하기도 합니다. 미세 조정된 *숫자/형* VLM은 출력 변동성을 최소화하고 안정적인 예측을 보장하는 스키마 제약 학습 설정을 통해 모든 정량적 범주에서 일관된 성능을 보였습니다. 기호 및 수치 정밀도를 유지하는 이 모델의 능력은 OCR을 사용하지 않는 접근 방식이 고정밀 기술 해석에 매우 적합함을 입증합니다. 반면, *알파벳 기반* VLM은 제목 블록이나 저품질 스캔 이미지를 분석할 때 변동성을 보였다. 이러한 결과는

2D 엔지니어링 문서의 자유 형식 텍스트 필드가 지닌 본질적인 복잡성을 반영한 것으로, 조직마다 글꼴, 간격, 약어가 크게 다르기 때문이다. 이러한 어려움에도 불구하고, 이 모델은 자유 형식 메모 추출에서 합리적인 성능을 보여주었으며, 이는 레이아웃을 고려한 사전 훈련이 텍스트 중심 이해를 더욱 향상시킬 수 있음을 시사한다.

산업적 관점에서 볼 때, 이 프레임워크는 디지털 통합을 향한 직접적인 경로를 제공합니다. 통합된 JSON 출력을 통해 추출된 데이터를 수동 입력 과정 없이 제조 실행 시스템, CAD/CAM 환경 및 품질 관리 데이터베이스로 원활하게 전송할 수 있습니다. 기존의 OCR 파이프라인과 달리, 제안된 접근 방식은 언어별 광학 인식이나 규칙 기반의 후처리에 의존하지 않으므로 다국어 및 기호가 많은 문서 전반에 걸쳐 확장성이 뛰어납니다. 또한, 모듈식 아키텍처는 새로운 데이터 세트가 확보될 때마다 지속적인 재훈련을 지원하여, 변화하는 도면 작성 관례와 조직별 템플릿에 유연하게 적응할 수 있게 합니다. 전반적으로, 이번 연구 결과는 구조화된 영역 인식 처리와 다중 모달 의미 추론을 결합하면 제조 분야에서 지능형 문서 이해를 위한 실용적이고 확장 가능한 기반을 제공한다는 점을 입증합니다.

6 결론

본 논문은 2D 도면에서 구조화된 정보를 추출하기 위한 3단계 프레임워크를 제시하였다. 이 아키텍처는 레이아웃 분할을 위한 YOLOv11-det, 주석 탐지를 위한 YOLOv11-obb, 그리고 콘텐츠의 의미적 구문을 분석하기 위한 도넛(Donut) 기반 VLM을 통합하였다. 결과를 통해 본 시스템이 레이아웃 및 주석 탐지에서 높은 정확도를 달성하고 수치 데이터 해석에서 뛰어난 성능을 발휘하여, 일반적인 OCR 기반 솔루션에 대한 신뢰할 수 있고 효율적인 대안을 제공함을 확인했다. 제안된 프레임워크는 기계가 읽을 수 있는 JSON 형식의 데이터를 생성함으로써 도면 아카이브와 디지털 제조 생태계 간의 격차를 해소하고, CAD/CAM 및 검사 파이프라인으로의 자동화된 데이터 흐름을 가능하게 한다.

뛰어난 성능에도 불구하고 몇 가지 한계는 남아 있었다. *Alphabetical* Donut 모델은 미세 조정이 이루어지지 않아 텍스트 데이터, 특히 표 형식이 밀집된 제목 블록 필드에서 성능이 저조했다. 또한 *표면 거칠기* (Surface Roughness) 클래스는 주석이 달린 훈련 샘플 수가 제한적이어서 탐지 정확도가 낮게 나타났다. 이러한 과제들은 더 크고 균형 잡힌 데이터셋과 텍스트 중심 정보에 대한 처리 능력 개선의 필요성을 강조한다.

향후 연구에서는 텍스트 이해 및 구조화된 출력 생성에 뛰어난 GPT-4o와 같은 고급 VLM(시각 언어 모델) 및 관련 아키텍처를 통합하여, 범주형 및 자유 형식 텍스트 영역에서의 성능을 향상시키는 것을 목표로 합니다. 또한 향후 연구에서는 표본이 부족한 주석에 대한 합성 데이터 증강과, 생성된 출력의 일관성을 교차 검증하기 위한 VLM 기반 검증 모듈의 통합에 중점을 둘 것입니다. 결론적으로, 본 연구는 비전 기반 레이아웃 이해와 OCR이 필요 없는 의미 추론을 결합하는 것이 자동화된 엔지니어링 도면 분석을 위한 효과적이고 일반화 가능한 해결책임을 입증합니다. 제안된 프레임워크는 현대 제조 산업 전반에 걸쳐 디지털 전환을 가속화할 수 있는 지능적이고 자체 개선이 가능한 시스템을 향한 견고한 한 걸음을 나타냅니다.

감사의 말

본 연구는 A*STAR가 지원하는 싱가포르 국제 대학원 장학금(SINGA) (수상자: Muhammad Tayyab Khan)의 지원을 받았으며, 싱가포르 교육부(MOE)와 난양공과대학교(NTU)의 AcRF Tier 1 연구비(RG70/23), 그리고 한국 정부(산업통상자원부, MOTIE)가 지원하는 한국산업기술기획평가원(KEIT) 연구비(No. RS-2024-00442448)의 지원을 받았습니다.

참고문헌

- [1] Lin, Y.-H., Ting, Y.-H., Huang, Y.-C., Cheng, K.-L., and Jong, W.-R., 2023, “2D 엔지니어링 도면 자동 인식을 위한 딥러닝 통합,” *Machines*, **11**(8), p. 802. <https://doi.org/10.3390/machines11080802>.
- [2] Gao, J., Zheng, D. T., Gindy, N., 및 Clark, D., 2005, “가공 형상에 대한 기하학적 치수 및 공차의 추출/변환,” *Int J Adv Manuf Technol*, **26**(4), pp. 405–414. <https://doi.org/10.1007/s00170-004-2195-3>.
- [3] Xu, Y., Zhang, C., Xu, Z.-J., Kong, C., Tang, D., Deng, X., Li, T., 및 Jin, J., 2024, “기계 공학 도면의 공차 정보 추출 - 디지털 이미지 처리 및 딥 러닝 기반 모델,” *CIRP Journal of Manufacturing Science and Technology*, **50**, pp. 55–64. <https://doi.org/>
기계 공학 도면의 간섭 정보 추출 - 디지털 이미지 처리 및 딥러닝 기반 모델,” *CIRP Journal of Manufacturing Science and Technology*, **50**, pp. 55–64. <https://doi.org/10.1016/j.cirpj.2024.01.013>.
- [4] Khan, M. T., Chen, L., Ng, Y. H., Feng, W., Tan, N. Y. J., 및 Moon, S. K., 2024, “Fine-“자동화된 엔지니어링 도면 정보 추출을 위한 비전-언어 모델 튜닝.” <https://doi.org/10.48550/arXiv.2411.03707>.
- [5] Reddy, T. N., Kumar, N., Ponnappa, N. P., Mohana, N., Vinod, P., Herbert, M. A., 및 Rao, S. S., 2025, “기계 도면에서의 지능형 GD&T 기호 탐지: 품질 보증을 위한 YOLOv11, Faster R-CNN 및 RetinaNet의 비교 연구,” *J Intell Manuf*. <https://doi.org/10.1007/s10845-025-02669-3>.
- [6] Mohd Yazed, M. S., Fadzrin Ahmad Shaubari, E., 및 Yap, M. H., 2024, “GD&T 인식을 위한 YOLOv5 및 비전 OCR 하이브리드 모델 구현,” *2024 IEEE 제6회 컴퓨터 및 정보학 심포지엄 (ISCI)*, IEEE, 말레이시아 쿠알라룸푸르, pp. 18–23. <https://doi.org/10.1109/ISCI62787.2024.10667691>.
- [7] Gann, D., Faltin, B., 및 König, M., 2023, “기술 도면 내 기호 탐지를 위한 딥러닝 모델 비교 연구.” [온라인]. 이용 가능: <https://li-brary.oapen.org/handle/20.500.12657/89045>. [접속일: 2025년 10월 10일].
- [8] Khan, M. T., Yong, Z., Chen, L., Tan, J. M., Feng, W., 및 Moon, S. K., 2025, “정밀 조정된 모델을 활용한 구조화된 정보 추출을 위한 엔지니어링 도면의 자동 구문 분석 문서
Understanding 트랜스포머를 활용한 공학 도면의 자동 구문 분석.” <https://doi.org/10.48550/arXiv.2505.01530>.
- [9] Khan, M. T., Chen, L., Yong, Z., Tan, J. M., Feng, W., 및 Moon, S. K., 2026, “도면에서 의사 결정으로: 2D 엔지니어링 도면을 구조화된 제조 지식으로 파싱하기 위한 하이브리드 비전-언어 프레임워크,” *Robotics and Computer-Integrated Manufacturing*, **99**, p. 103186. <https://doi.org/10.1016/j.rcim.2025.103186>.