

안나 C. 도리스¹ 매사추세츠 공과
대학교, 미국 매사추세츠주 케임브리지, 매사추세츠
애비뉴 77번지, 우편번호 02139 이
메일: adoris@mit.edu

Daniele Grandi
Autodesk Research,
The Landmark @ One Market, Ste.
400, 샌프란시스코, 캘리포니아 94105, 미국

라이언 토마치
MIT 모터스포트스,
매사추세츠 애비뉴 77번지,
미국 매사추세츠주 케임브리지 02139

Md 페르도우스 알람
매사추세츠 공과대학,
매사추세츠 애비뉴 77번지,
미국 매사추세츠주 케임브리지 02139

모하마드메흐디 아타에이
오토데스크 리서치,
유니버시티 애비뉴 661번지,
토론토, 온타리오 M5G 1M1, 캐나다

정현민
오토데스크 리서치,
유니버시티 애비뉴 661번지,
토론토, 온타리오 M5G 1M1, 캐나다

파에즈 아흐메드
매사추세츠 공과대학,
매사추세츠 애비뉴 77번지,
미국 매사추세츠주 케임브리지 02139

DesignQA: 멀티모달 대규모 평가를 위한 벤치마크 언어 모델의 엔지니어링 문서 이해

본 연구는 기술 문서에 제시된 엔지니어링 요구사항을 이해하고 적용하는 데 있어 멀티모달 대규모 언어 모델(MLLM)의 속련도를 평가하기 위한 새로운 벤치마크인 DesignQA를 소개합니다. 실제 엔지니어링 문제를 중심으로 개발된 DesignQA는 Formula SAE 학생 경진대회에서 수집한 텍스트 기반 설계 요구사항, CAD 이미지, 엔지니어링 도면 등 다양한 멀티모달 데이터를 독창적으로 결합합니다. 기존의 많은 MLLM 벤치마크와 달리 DesignQA는 입력 이미지와 입력 문서가 서로 다른 출처에서 제공되는 문서 기반 시각적 질문을 포함합니다. 이 벤치마크는 자동 평가 지표를 제공하며, 엔지니어가 요구사항에 따라 설계할 때 수행하는 작업에 따라 규칙 이해, 규칙 준수, 규칙 추출의 세 부분으로 나뉩니다. 본 연구에서는 GPT-4o, GPT-4, Claude-Opus, Gemini-1.0, LLaVA-1.5와 같은 (작성 시점 기준) 최첨단 모델들을 벤치마크와 비교하여 평가하고, 복잡한 엔지니어링 문서를 해석하는 데 있어 다층적 언어 모델(MLLM)의 능력에 존재하는 격차를 밝혀냈습니다.

테스트에 사용된 다중 모드 모델(MLLM)들은 유망한 성능을 보였지만, Formula SAE 문서에서 관련 규칙을 안정적으로 추출하는 데 어려움을 겪었고, CAD 이미지에서 기술 구성 요소를 인식하는 데에도 난항을 겪었으며, 엔지니어링 도면을 분석하는 데에도 어려움을 겪었습니다. 이러한 결과는 기술 문서에 따른 설계의 특징인 다면적인 문제들을 더 잘 처리할 수 있는 다중 모드 모델의 필요성을 강조합니다. 본 벤치마크는 인공지능 기반 엔지니어링 설계 프로세스의 미래 발전을 위한 토대를 마련합니다.

DesignQA는 https://github.com/anniedoris/design_qa/ 에서 공개적으로 이용할 수 있습니다 .

2404.07917v2

1. 서론

ChatGPT[1]와 같은 대규모 언어 모델(LLM)은 사용자 쿼리를 기반으로 대화에 참여할 수 있는 챗봇입니다. 인터넷의 방대한 데이터를 기반으로 훈련된 LLM은 Transformer 아키텍처 [2]를 기반으로 하며 입력 텍스트 시퀀스 [3]를 기반으로 다음 단어를 예측하는 방법을 학습했습니다. ChatGPT는 출시 2개월 만에 1억 명 이상의 사용자를 확보하며 역사상 가장 빠르게 채택된 기술입니다 [4]. LLM은 대화 능력으로 상당한 주목을 받았으며, 의학 [5, 6], 교육 [7], 공학 [8, 9] 등 다양한 주제에 대한 질문에 답하는 능력을 조사하고 정량화한 연구가 진행되었습니다 .

대화형 비서로서 LLM이 등장함에 따라, 엔지니어링 설계 문제에 대한 질문에 인간이 답하는 데 어떻게 도움을 줄 수 있는지에 대한 중요한 질문이 제기되었습니다. 설계 자동화의 핵심 목표는 인간 설계자가 더 나은 제품을 더 쉽고 빠르게 만들 수 있도록 지원하는 AI 도우미를 확보하는 것이었습니다. 생성형 AI는 상당한 진전을 이루었지만, 엔지니어링 설계 작업은 여러 소스의 다중 모드 정보를 종합해야 하므로 이 목표를 달성하기는 어려웠습니다. 엔지니어링 설계에 중요한 작업 중 하나는 기술 요구 사항을 기반으로 제품을 설계하는 것인데, 이러한 요구 사항에는 측정 기준과 값으로 구성된 규칙이 나열됩니다(예: 최대 타이어 너비는 5인치를 넘을 수 없음) [10].

실제 설계의 복잡성에 필적하는 기술적

사양서는 길고 매우 상세할 수 있으며, 중요한 안전 또는 규제 사양을 참조하는 경우가 많습니다. 요구 사항에 따라 설계하려면 엔지니어 또는 설계자는 다양한 출처(예: 요구 사항 문서, CAD, 엔지니어링 도면, 문서, 표준 등)의 다중 모드 데이터를 해석하고 종합할 수 있어야 합니다.



최근에는 멀티모달 기능 [11-13], 장문 문서(장문 텍스트) 처리 기능 [14, 15], 멀티모달 및 장문 텍스트 기능 [1, 16]을 모두 갖춘 모델이 개발되었습니다.

이러한 발전은 요구사항 문서에 따라 엔지니어링 설계를 자동화하는 데 도움을 줄 수 있는 멀티모달 AI 어시스턴트의 현실에 한 걸음 더 다가서게 합니다. 새로운 멀티모달 러닝 모델(MLLM)이 등장함에 따라, 이러한 필수적인 설계 요구사항 관련 작업을 수행하는 능력을 평가하는 것이 중요해졌습니다. 이는 다음과 같은 질문을 제기합니다. 현재의 MLLM은 요구사항에 따른 엔지니어링 설계를 얼마나 잘 수행할 수 있을까요? 이러한 작업에서 MLLM의 효율성 향상을 어떻게 실질적으로 측정할 수 있을까요? 따라서 본 연구에서는 설계 프로세스에서 기술 요구사항의 복잡하고 멀티모달적인 요구사항을 해석하고 준수하는 MLLM의 속련도를 평가하기 위한 새로운 벤치마크를 제안합니다.

본 논문에서는 엔지니어링 설계 기술 요구사항 질의응답을 위한 최초의 제로샷 벤치마크인 DesignQA(그림 1)를 소개합니다 . 이 벤치마크는 1451개의 문항으로 구성되어 있으며, SAE 2024 규정과 MIT 모터스포트스 팀에서 제공한 데이터(CAD, 문서 등)를 기반으로 합니다. MIT 모터스포트스 팀과 협력하여 이 벤치마크를 개발함으로써, 실제 상황을 잘 반영하는 데이터셋을 구축하는 데 중점을 두었습니다.

¹교신 저자.

RULE EXTRACTION	
Retrieval Tell me verbatim rule V.1.2.   The vehicle must have a minimum wheelbase... 	Compilation List all the rules relevant to "aerodynamic."   T.7, T.7.1, T.7.1.1, T.7.1.3... 

RULE COMPLIANCE	
Dimension  Does the design comply with T.7.7.1b?   Explanation: T.7.7.1b states that... Answer: No 	Functional Performance  Does the design comply with F.8.7.2?   Explanation: The plot shows... Answer: No 

RULE COMPREHENSION	
Definition  What is the name of the component highlighted in pink?   Chassis 	Presence  Is the front hoop visible in the close-up view?   No 

Section	Subset	Metric	# QAs
Extraction	Retrieval	F1 BoW	1192
	Compilation	F1 Rules	30
Comprehension	Definition	F1 BoC	31
	Presence	ACC	62
Compliance	Dimension	ACC/Bleu/Rouge	120
	Functional Performance	ACC/Bleu/Rouge	16
Total			1451

그림 1. 세 가지 주요 부분(규칙 추출, 규칙 이해, 규칙 준수)과 여섯 가지 하위 집합에 대한 개요
 DesignQA에서 (검색, 컴파일, 정의, 존재 여부, 차원 및 기능적 성능)을 평가합니다. 프롬프트와 이미지가 표시됩니다.
 위 내용은 실제로 사용된 프롬프트와 이미지의 요약본입니다. 오른쪽 하단 표에는 측정 항목과 수치가 나와 있습니다.
 벤치마크의 각 하위 집합에 대한 질문 수입니다.

세계적인 설계 요구사항 과제. DesignQA에는 다음 내용이 포함됩니다.
 문서 기반 참조 의존적 시각적 질문-답변
 (VQAs)는 긴 텍스트 문서와 이미지를 분석해야 하는 질문에 대한 모델의 답변 능력을 테스트하는 몇 안 되는 벤치마크 중 하나입니다. 특히, 본 벤치마크는 모델의 다음과 같은 능력을 평가합니다.
 모델이 이미지를 직접 보지 않은 상태에서, 서로 다른 출처의 이미지와 텍스트에서 정보를 종합하는 능력
 원래의 훈련(사전 훈련).
 데이터셋 개발 외에도 DesignQA를 사용했습니다.
 (글을 쓰는 시점에서) 여러 최첨단 기술을 벤치마킹하기 위해2
 MLLM, GPT-4o [16], GPT-4 [1], Gemini-1.0 3, Claude-Opus 4,
 그리고 LLaVA-1.5 [17]는 모델에 FSAE 규칙을 제공합니다.
 컨텍스트 창을 통해서 또는 간단한 검색 방법을 통해서.
 GPT-4o는 테스트된 모델들 중에서 전반적으로 가장 우수한 성능을 보였습니다.
 DesignQA에 대한 우리의 연구 결과는 다음과 같은 MLLM의 필요성을 강조합니다.
 엔지니어링 설계의 복잡한 작업을 더 잘 수행할 수 있도록 하는 것, 예를 들어 긴 텍스트를 더 잘 분석하고 이미지를 더 잘 분석할 수 있는 모델을 만드는 것 등이 있습니다.
 동시에 기술적 지식을 적용 합니다. 벤치마크에서 이러한 모델의 성능에 대한 관찰을 바탕으로,
 모델을 어떻게 수정할 수 있는지에 대한 제안을 제공합니다.
 DesignQA 및 설계 요구사항 관련 질문에서 향상된 결과를 얻었습니다.
 일반적으로.

요약하자면, 저자의 기여는 다음과 같습니다.

- (1) MLLM을 위한 새로운 다면적인 벤치마크: 본 논문에서는 엔지니어링 요구사항에 따른 MLLM의 설계 이해도를 테스트하는 벤치마크인 DesignQA를 소개합니다.
 DesignQA는 시각적 입력과 장문 텍스트 입력 모두에서 정보를 분석하고 통합하기 위한 모델이 필요하다는 점에서 독특하며, 이는 실제 엔지니어링 작업의 복잡성과 다중 모드적 특성을 강조합니다.
- (2) 세분화되고 자동화된 평가 프레임워크: 우리는 DesignQA는 철저하면서도 사용하기 쉽도록 설계되었습니다. 벤치마크는 규칙 추출, 이해, 준수라는 세 부분으로 나누어 모델의 강점과 약점을 세밀하게 조사할 수 있도록 합니다.

기술 영역에서 인공지능에 대한 이해를 풍부하게 합니다. 각각 DesignQA의 하위 집합에는 자동 평가 지표가 있어 향후 MLLM을 신속하게 평가할 수 있습니다.

- (3) 고품질의 실제적인 질문-답변 쌍: 우리는 실제 데이터를 기반으로 고품질 벤치마크를 개발합니다.
 그리고 문제점들. DesignQA의 질문과 답변은 다음과 같은 것들을 기반으로 합니다. FSAE 대회 규칙 및 MIT에서 제공한 데이터에 관하여 모터스포츠 팀. 질문은 다음 담당자가 설계하고 검토합니다. MIT 모터스포츠 팀 구성원, 업계 전문가 및 엔지니어링 연구원.
- (4) 최신 MLLM 평가: GPT-4o, GPT-4, Gemini-1.0, Claude-Opus 및 LLaVA-1.5를 평가합니다.
 DesignQA와의 비교를 통해 AI의 현재 한계를 드러냅니다.
 다중 모드 데이터 처리 및 처리 엔지니어링 요구 사항에서의 검색 방법과 몇 가지 어려움이 있습니다.
 테스트된 모델들이 직면한 과제에는 규칙을 안정적으로 추출하는 것이 포함됩니다.
 CAD에서 기술적 구성 요소를 식별하는 문서화
 이미지 분석 및 엔지니어링 도면 분석.

2. 관련 작품

이 섹션에서는 먼저 기존 연구에 대한 개요를 제공합니다.
 엔지니어링 설계를 위한 AI에 대해 MLLM이 새로운 기능을 갖추고 있음을 보여줍니다. 인간의 설계 및 설계 요구 사항을 지원할 수 있는 잠재력 문제점을 살펴봅니다. 그런 다음 LLM에 대한 기존 벤치마크를 검토하고 MLLM은 엔지니어링 설계 및 설계 요구 사항에 대한 벤치마크가 부족하다는 점을 강조합니다. 그런 다음 기존 벤치마크를 참조 유형별로 분류합니다. 이는 본 연구의 맥락을 설정합니다.
 이 연구는 텍스트 정보와 시각 정보를 연결하는 실제적이고 문서 기반의 벤치마크에 대한 필요성을 다루는 데 기여합니다.
 종합적으로.

2.1 엔지니어링 설계를 위한 AI. 기존 연구의 상당 부분은 다음과 같습니다. 디자인을 위한 AI는 이미지와 같은 단일 모달리티에 초점을 맞추었습니다 [27]. 또는 텍스트, 텍스트의 경우, 자연어에 대한 연구가 진행되었습니다. 텍스트의 경우, 자연어에 대한 연구가 여러 건 이루어졌습니다. 기술 엔지니어링 텍스트에 대한 자연어 처리(NLP)입니다. 예를 들면, [28] 및 [29]는 기술 언어 처리 프레임워크를 설명합니다.
 비정형 엔지니어링 데이터에 대한 기존 NLP의 한계를 극복하기 위해 텍스트를 넘어 확장하여 [30] 심층적인 분석을 수행합니다.

2 "작성 시점"에 대한 모든 언급은 2024년 4월부터 8월까지의 기간을 의미합니다.
 3 <https://ai.google.dev/gemini-api/docs/models/gemini?authuser=1>
 4 <https://www.anthropic.com/news/claude-3-family>

표 1. 주요 LLM 및 MLLM 벤치마크, 해당 도메인 및 참조 의존성에 대한 개요. 본 벤치마크는 독창적입니다. 설계 요구사항에 중점을 두고 있으며, 여러 출처의 문서를 기반으로 하는 VQA를 포함하고 있다는 점에서 그렇습니다.

기준	도메인	참조 유형			VQA
		자체 포함형 개방형 도메인	Doc-Grounded 단일 공급원*	Doc-Grounded 다중 소스**	
McTest [18]	이야기 형식의 어린이 동화	✓	-	-	
스쿼드 [19]	위키피디아 위	-	✓	-	
위키QA [20]	키피디아 자연	-	✓	-	
QASPER [21]	어 처리 논문 혼	-	-	✓	
제로스크롤 [14]	합: 위키, 정부 등	-	-	✓	
MME [22]	머리	✓	-	-	✓
MM-벤치 [23]	혼합: 코코넛, 라바 등	✓	-	-	✓
MMM [24]	대학 자료 ScienceQA	-	✓	-	✓
[25]	오픈 소스 과학 자료 Wikipedia	-	✓	-	✓
[26]	InfoSeek	-	-	✓	✓
DesignQA(당사) FSAE 규정 문서 및 데이터		-	-	✓	✓

*단일 출처: 해당 이미지가 문서 내에 포함된 경우; **다중 출처: 해당 이미지가 문서 내에 포함되지 않은 경우

이미지와 텍스트를 모두 고려하는 기술 문서 분류를 위한 학습 아키텍처. 상당한 발전에도 불구하고, 많은 자연어 처리 및 답변 방법은 단일 분야에 특화되어 있습니다. 특정 영역에 국한되어 있으며 엔지니어링 설계 내의 다른 문제로 일반화하기 어렵습니다.

LLM은 다양한 문제에 대해 보다 일반화 가능한 해결책을 제공합니다. 엔지니어링 설계 내에서, [31]은 잠재력을 보여줍니다. LLM(GPT-2 및 GPT-3)을 사용하여 초기 단계 설계 개념을 자동화합니다. 세대, [8] LLM이 엔지니어들을 어떻게 도울 수 있는지 탐구합니다. 다양한 설계 및 제조 작업. LLM은 특정 엔지니어링 설계 작업에 유용하지만, 많은 엔지니어링 작업은 LLM을 사용하지 않습니다. 이미지, CAD, 그래프 등을 포함하는 고도로 다중 모달적인 데이터 처리 방식입니다. 따라서 최근 다중 모드 모바일 컴퓨팅(MLLM)의 발전은 아직 활용되지 않은 잠재력을 지니고 있습니다. [9] 엔지니어링 설계 작업의 자동화를 조사합니다. GPT-4의 엔지니어링 설계 작업 자동화 가능성 이미지를 사용하여 1000개 이상의 제로샷 쿼리 데이터셋을 생성했습니다. 그러나 이 데이터 세트는 엔지니어링 문서에 초점을 맞추지 않습니다. 최근 구글의 제미니, 메타의 라마 패밀리, 앤트로픽의 클로드 모델과 같은 수많은 AI 모델들이 등장했습니다. 효과성은 거의 전적으로 비교학적 측면에서 평가됩니다. 벤치마크. MLLM의 기능을 특성화하는 데 매우 중요합니다. 엔지니어링 설계 작업의 경우, 엄격하게 검증할 수 있는 벤치마크가 있습니다. 그들의 성과를 정량화하는 것이 De-signQA에 영감을 주었습니다.

2.2 LLM 및 MLLM 벤치마크. 이 섹션에서는 도메인을 기반으로 한 기존 LLM 및 MLLM 벤치마크를 살펴봅니다. 및 참조 유형. 간략한 개요는 표 1을 참조하십시오.

2.2.1 엔지니어링 설계 및 설계 요구사항에 대한 벤치마크. 엔지니어링 설계에 대한 벤치마크는 매우 드물다. 문제 또는 설계 요구사항 관련 작업. 수많은 문제에도 불구하고 기술적으로 풍부한 설계 요구사항 문서, 매우 적은 데이터 세트 또는

이 영역에 대한 벤치마크가 개발되었습니다. PURE(PUB-lic REquirements) [32]는 79개의 요구사항으로 구성된 데이터 세트입니다. 웹에서 수집한 문서들입니다. 하지만 데이터셋에는 다음이 포함되지 않습니다. QA 쌍을 제공하므로 벤치마킹에 쉽게 사용할 수 없습니다. DesignQA는 FSAE 경쟁 규칙과 MIT의 방식을 활용합니다. 모터스포츠 설계 데이터를 활용하여 품질 보증(QA)에 대한 벤치마크를 개발합니다. 실제 설계 요구사항에 맞춰.

2.2.2 LLM 참조 의존 벤치마크. 텍스트 기반 QA 모델이 추가 참조를 구문 분석해야 하는 벤치마크 제시된 질문에 대한 답변은 "참조 의존적"이라고 할 수 있습니다.

벤치마크. 참조 종속 벤치마크는 다른 많은 벤치마크와 다릅니다. McTest [18]와 같은 고전적인 읽기 이해 벤치마크, 이러한 질문들은 "자체 완결된" 질문이며, 질문과 함께 짧은 텍스트(대략 단락 길이)로 답변할 수 있습니다. 참조 종속 벤치마크는 위치를 파악하는 모델을 필요로 하기 때문에 관련 정보 - 일반적으로 하나 또는 여러 개의 긴 텍스트에 걸쳐 있음 그리고 나서 그 정보를 제시된 질문에 적용하는 경향이 있습니다. 더 복잡한 질문들이 될 것입니다. 앞서 언급한 구분을 따르면서 Dasigi et al. [21]에 따르면, 참조 종속 벤치마크는 "개방형 도메인" 벤치마크와 "문서 기반" 벤치마크로 further 세분화될 수 있습니다. 개방형 도메인 질문의 예는 다음과 같습니다. SQUAD에서 발췌한 내용은 다음과 같습니다. "물방울은 어디에서 얼음과 충돌합니까?" 결정이 침전물을 형성합니까?" [19] 개방형 도메인 벤치마크, SQUAD [19] 및 WikiQA [20]와 같은 도구는 모델의 능력을 테스트합니다. 일반 상식이나 잡다한 사실 같은 질문에 답하세요. 이는 일반적으로 모델의 사전 학습된 코퍼스에 있는 여러 소스에 포함되어 있습니다.

대조적으로 QASPER [21]와 같은 문서 기반 벤치마크가 있습니다. 그리고 ZeroScrolls [14]는 특정 장문 문서에 제공된 정보를 기반으로 질문에 답하는 모델의 능력을 테스트합니다. 문서 기반 질문의 예는 다음과 같습니다.

QASPER는 다음과 같습니다. "[특정 NLP 논문을 참조하여] 그들은 주의 충돌 처리를 위한 기반으로 어떤 신경망 아키텍처를 사용합니까?" 메카니즘은 무엇일까요? [21] Dasigi et al. 이 지적인 바와 같이, 문서 기반 QA는 개방형 도메인 QA보다 더 복잡한 경향이 있는데, 그 이유는 다음과 같습니다. 사용자 컨텍스트에 기반을 두고 있으며 답변은 널리 사용 가능한 사실이 아닙니다 [21]. FSAE 규칙 문서에 근거한 DesignQA는 이러한 문서 기반 범주에 속합니다. 결과적으로, 저희 벤치마크에서 제거된 질문들은 복잡하며 사용자 요구에 기반을 두고 있습니다. 상식보다는 문서에 근거한 질문이 훨씬 더 중요합니다. 문서에 근거한 질문은 매우 효과적입니다. 공학 설계 문제의 특징은 다양한 유형으로 나타난다는 점입니다. 표준, 매뉴얼, 문서 등과 같은 자료에는 인터넷에서 쉽게 찾을 수 없는 특정 정보가 포함되어 있는 경우가 많습니다.

2.2.3 MLLM 벤치마크. 멀티모달 데이터셋은 일반적으로 다음과 같은 테스트를 수행합니다. MLLM이 텍스트가 아닌 요소를 분석하는 능력은 다음과 같습니다. 질문 텍스트. 이 글을 쓰는 시점에서 대부분의 MLLM은 다음만 허용합니다. 이미지를 텍스트가 아닌 입력으로 사용하기 때문에 멀티모달 QA 벤치마크는 다음과 같은 경향이 있습니다. 시각적 요소(이미지)와 질문/답변 쌍으로 구성됩니다. 시각적 질문-답변(VQA)은 동일한 범주로 분류될 수 있습니다. 텍스트 기반 QA 벤치마크와 같은 방식입니다. 대다수의 VQA는 벤치마크는 자체적으로 완결성을 갖습니다. 자체 완결성을 갖춘 벤치마크의 예는 다음과 같습니다. MME에서 가져온 VQA 질문은 다음과 같습니다. "[테니스 복식 파트너가 나오는 사진과 관련하여] 이 사진에는 두 사람이 있습니까?" 이것들은 이미지 외에는 어떤 맥락도 없는 질문들입니다.

질문에 답해야 합니다. Chang과 Wang 등의 리뷰 논문 [33] 에서 강조된 MME [22] 및 MMBench [23] 벤치마크는 둘 다 자체 포함된 VQA입니다. 이러한 벤치마크는 주로 추론 및 인식과 같은 기본 작업에 중점을 두고 있으며 평가의 용이성을 위해 일반적으로 객관식 형식으로 제시됩니다 [22].

자체 포함형 VQA보다 더 어렵고 덜 일반적인 참조 추측형 VQA는 모델이 이미지 분석을 추가 지식(공개 도메인 또는 특정 문서)과 통합하는 능력을 테스트합니다. 대학 자료에서 수집한 객관식 문제로 구성된 MMMU [24]는 공개 도메인 VQA로 간주될 수 있으며, 초등학교부터 고등학교 수준의 과학 객관식 문제로 구성된 ScienceQA [25] 도 마찬가지입니다. 이 벤치마크는 각 VQA에 대해 질문과 관련된 일반 지식에 대한 여러 문장으로 구성된 "강의"와 특정 답변을 선택한 이유에 대한 "설명"을 제공하여 완전한 "사고 과정" 추론을 장려합니다. InfoSeek [26] 는 특정 위키백과 문서의 이미지에 대한 질문으로 구성된 최초의 문서 기반 VQA이며, 해당 문서를 참조해야만 답변할 수 있습니다 .

텍스트.

하지만 실제 작업 환경을 더 잘 반영하는 문서 기반 시각적 질의응답(VQA)에 대한 필요성은 여전히 큼니다. InfoSeek은 이미지와 문서가 직접적으로 연결되어 있는(즉, 이미지가 문서 내에 포함된) 반면, 사용자가 묻는 대부분의 시각적 질문은 이러한 직접적인 검색 프레임워크에 맞지 않습니다(예: 고장난 기계 이미지와 해당 기계의 설명서가 제공되는 경우, 설명서에 정확히 같은 이미지가 포함되어 있지 않음). InfoSeek의 이미지와 문서는 모두 위키피디아에서 가져온 것이므로, 모델은 사전 학습 과정에서 이미 이러한 자료들을 접했을 가능성이 높습니다. 따라서 사용자가 묻는 많은 질문의 경우, 문서나 이미지 중 하나는 사전 학습 과정에서 접하지 못했을 것입니다. DesignQA는 이러한 격차를 해소하고 실제 시나리오를 더 잘 반영하도록 설계되었습니다.

3 DesignQA 벤치마크 3.1 데이터셋. DesignQA는 세 가지

지 방식으로 실제 엔지니어링 문제의 특징을 반영하도록 설계되었습니다. 첫째, 이 벤치마크는 140페이지 분량의 Formula SAE 규칙 문서를 기반으로 합니다. Formula SAE 규칙 문서는 학생 경진대회를 위해 만들어진 것이지만, 젊은 엔지니어들이 완벽하게 작동하는 가솔린 또는 전기 자동차를 설계, 제작, 테스트 및 경주하는 데 필요한 지침을 제공합니다. 학생 엔지니어들은 대회에 참가하기 전 차량을 개발하는 과정에서 이 규칙 문서를 반복적으로 참조합니다. 둘째, 이 벤치마크는 MIT 모터스포츠 팀에서 제공한 실제 CAD 모델과 테스트 데이터를 사용하여 제작되었으며, 엔지니어링 회사에서 이와 동등한 자료를 쉽게 구할 수 없습니다.

셋째, QA는 MIT 모터스포츠 팀 구성원, 업계(Autodesk) 출신의 팀 구성원 또는 학술 연구 출신의 팀 구성원이 작성했습니다. 다른 질문이나 규칙 준수 설명에서 파생된 질문을 제외한 모든 수동으로 생성된 QA는 질문을 작성하지 않은 두 당사자가 검토했습니다. 많은 LLM 및 MLLM 데이터 세트가 크라우드소싱 또는 합성 데이터 [34] 에 의존하고 있으며, 이러한 데이터는 종종 다른 LLM에 의해 생성되기 때문에 이 두 번째 및 세 번째 사항의 중요성은 아무리 강조해도 지나치지 않습니다. 크라우드소싱 및 합성 데이터는 생성하기는 훨씬 간단하지만, 특히 고도의 기술 영역에서는 QA 품질 저하를 초래하는 경우가 많습니다.

Formula SAE 규칙 문서는 다른 많은 엔지니어링 설계 규칙 문서 및 표준과 유사합니다. 실제로 실제 Formula 1 경주를 규정하는 2024 Formula 1 기술 규정 문서 [35] 는 178페이지 분량이며 학생용 SAE 버전과 매우 유사한 내용 섹션을 가지고 있습니다. 따라서 DesignQA와 그 주제는 엔지니어링 설계 유형의 질문을 잘 포착한다고 생각합니다. Formula SAE 규칙 문서는 논리적으로 그룹화된 번호가 매겨진 규칙(예: V.1, V.2 등)으로 구성된 섹션(예: V-"차량 요구 사항", F-"채시 및 구조" 등)으로 구성되어 있습니다. 이는 NASA 기술 메모 [36]와 같은 다른 기술 문서에서 흔히 사용되는 형식입니다.

이러한 문서들 또한 유사한 열거형 구조를 따릅니다. Formula SAE 규칙 문서와 마찬가지로, 이러한 다른 문서들에 명시된 많은 규칙들은 문서 내 다른 곳에서 정의된 기술 용어를 참조하며, 많은 규칙들이 치수 제약 조건이나 기능적 성능과 관련이 있습니다.

DesignQA는 1451개의 질문과 답변으로 구성되어 있으며(그림 1), 규칙 추출, 규칙 이해, 규칙 준수의 세 부분으로 나뉩니다. 이 세 부분은 서로 연관되어 있으며, 기술 문서에 따라 설계하는 프로세스에 대한 MLLM(Managed Leadership Management)의 역량을 평가하도록 설계되었습니다. 엔지니어는 규칙 문서나 표준을 바탕으로 설계 과정 전반에 걸쳐 해당 문서를 반복적으로 참조하여 설계가 규칙을 준수하는지 확인합니다. 마찬가지로, 벤치마크의 규칙 준수 부분은 MLLM이 엔지니어링 도면과 테스트 데이터를 검토하여 규칙을 준수하는지 확인하는 능력을 평가합니다. 벤치마크의 나머지 두 부분은 규칙 준수 여부를 평가하는 데 필요한 필수 역량을 평가합니다. 예를 들어, 엔지니어가 규칙 준수 여부를 확인하려면 먼저 규칙 문서에 제시된 모든 용어와 정의를 이해해야 합니다 . 벤치마크의 규칙 이해 부분은 MLLM이 시각적 설계에서 규칙 문서에 나오는 전문 용어를 인식하는 능력을 평가합니다. 마찬가지로, 규칙 준수 여부를 확인하기 위해 엔지니어는 규칙 문서에서 자신의 설계 작업과 관련된 규칙을 추출 할 수 있어야 합니다.

이와 유사하게, 규칙 추출 문제는 MLLM이 긴 규칙 문서에서 관련 정보를 식별하는 능력을 테스트합니다. 이러한 비교적 간단한 식별 작업을 수행할 수 없으면 모델은 해당 규칙에 대한 의미 있는 질문에 답할 수 없습니다.

모델에 대한 더 자세한 맥락을 제공하기 위해 각 QA는 다음과 같이 시작합니다. 다음과 같은 서문을 덧붙입니다.

저희는 FSAE 대회에 출품할 차량을 설계하는 학생 엔지니어링 팀입니다. FSAE 규정 문서를 첨부했습니다.

각 질문을 할 때 규칙 문서가 모델에 제공되었습니다. 세 가지 벤치마크 세그먼트 각각은 다시 두 개의 하위 집합, 즉 특정 작업으로 나뉩니다. 각 벤치마크 세그먼트 및 하위 집합에 대한 자세한 내용은 다음 섹션에서 설명합니다.

3.1.1 규칙 추출. 엔지니어에게 중요한 작업 중 하나는 요구사항 문서에서 특정 규칙을 찾는 것입니다. 비록 일반적으로는 간단하지만, 규칙에 대한 질문에 답하려면 관련 규칙을 찾아 추출할 수 있어야 합니다. 벤치마크의 규칙 추출 부분은 140페이지 분량의 FSAE 규칙 문서에서 모델을 사용하여 규칙을 추출하는 능력을 테스트합니다. 이 벤치마크 부분은 다시 검색 QA와 컴파일 QA의 두 하위 집합으로 나뉩니다.

정보 검색 문제는 모델이 긴 문서에서 특정 정보를 추출하는 능력을 테스트합니다. 원본 규칙 문서의 페이지 수가 매우 많기 때문에 규칙 텍스트를 단어 하나하나 정확하게 검색하는 것은 결코 쉬운 일이 아닙니다. 향후 더 나은 모델이 개발됨에 따라 이러한 정보 검색 작업은 불필요해질 수도 있지만, 정확한 정보 검색은 이 벤치마크의 다른 유형의 문제를 해결하기 위한 필수적인 전제 조건이므로 모델이 정확한 정보를 검색하는 것이 매우 중요합니다.

먼저 PDF 문서에서 헤더, 바닥글, 페이지 번호를 제외한 모든 텍스트를 추출하여 검색 QA를 프로그래밍적으로 생성합니다. 규칙 문서는 'AA.##.#' 형식으로 번호가 매겨진 섹션과 하위 섹션(제목이 있을 수도 있고 없을 수도 있음)으로 잘 구성되어 있습니다. 수동으로 작성한 스크립트와 정규 표현식 패턴을 조합하여 개별 규칙을 식별하고, 규칙 세트를 표로 정리한 후 규칙 번호, 규칙 제목, 규칙 내용을 표시합니다. 마지막으로 텍스트가 없는 규칙(하위 규칙은 유지)과 차량 설계 사양과 관련이 없는 경주의 다른 측면(예: 행정 규정, 문서 요구 사항)에 관련된 규칙 세트를 제거합니다.

표로 정리된 규칙들을 바탕으로, 검색 QA 집합을 프로그래밍적으로 구성할 수 있습니다. 서문에 설명된 내용으로 돌아가서...




그림 2. 3D CAD 모델을 2D 이미지로 표현한 것. A) 다중 시점 CAD 이미지. B) 확대 CAD 이미지. C) 엔지니어링 도면 이미지. C)는 직접 치수 기입법을 사용하고, D)는 축척 막대 치수 기입법을 사용한다.

이전 섹션에 다음 내용을 추가합니다.

규칙 {규칙의 텍스트만 표시하고 다른 단어는 포함하지 마세요.}

정확히 어떤 상태인가요? 답변은 다음과 같습니다.

여기서 { }는 선택된 각 규칙 번호로 대체됩니다. 이 과정을 통해 1192개의 검색 QA가 생성됩니다.

컴파일 관련 질문은 모델이 긴 문서 전체에 걸쳐 정보를 찾는 능력을 평가합니다. 설계자가 설계 요구사항 문서를 다룰 때 흔히 수행하는 작업 중 하나는 '서스펜션'이나 '핵심 체결 부품'과 같은 특정 주제와 관련된 모든 규칙을 컴파일하는 것입니다. 이러한 질문 세트를 만들기 위해, 먼저 규칙 문서에 나오는 30개의 일반적인 용어(이 중 9개는 동의어, 약어 또는 복수형 포함)를 수동으로 선별합니다. 그 결과 다음과 같은 형식의 30개 질문이 생성됩니다.

{ }에 해당하는 모든 규칙을 나열해 주십시오. 규칙 번호(예: AA.1.1.1)만 심표로 구분하여 입력하고 다른 단어는 포함하지 마십시오.
{ }에 적용되는 규칙은 다음과 같습니다.

어디 { }는 30개의 일반적인 용어 각각으로 대체됩니다. 정답을 생성하기 위해 먼저 이전 섹션에서 설명한 표로 정리된 규칙들을 간단히 검색하여 해당 용어가 포함된 규칙 목록을 작성합니다. 또한 발견된 각 규칙의 하위 규칙과 상위 규칙과 하위 규칙 모두에서 언급될 수 있는 다른 규칙들도 포함합니다.

3.1.2 CAD 표현. 본 벤치마크의 규칙 이해 및 규칙 준수 부분은 설계된 차량의 3D CAD 모델에 대한 질문을 포함합니다. MIT Motorsports에서 제공한 차량, 차량과 공기역학 패키지, 후륜 패키지, 파워트레인 등 네 가지 3D CAD 모델을 질문응답(QA)을 개발했습니다. 이러한 질문응답에 대한 세부 사항을 설명하기 전에, 이 섹션에서는 MLLM에 3D CAD 모델 정보를 제공하는 방법을 자세히 설명합니다. 현재 MLLM은 일반적인 3D CAD 모델 형식(예: .stl, .step 등)을 지원하지 않으므로, 모델을 표시하고자 하는 CAD 파일을 2D 이미지 형식으로 변환하여 가능한 한 많은 3D 공간 정보를 보존합니다.

우리는 세 가지 종류의 표현 방식을 사용하여 3D CAD 모델을 2D로 나타냅니다.

이미지: 1) 다중 시점 CAD 이미지, 2) 근접 CAD 이미지, 3) 엔지니어링 도면 이미지 (그림 2).

다중 뷰 CAD 이미지 (그림 2A)는 CAD 모델의 상면, 하단, 전면, 후면, 좌측면 및 등각 투영도 등 6가지 뷰를 보여줍니다. CAD 소프트웨어의 GUI에서는 3D CAD 모델을 회전할 수 없으므로, 이 6가지 뷰는 각 뷰가 어떻게 결합되어 3D 모델을 구성하는지에 대한 정보를 제공합니다. 각 뷰에는 해당 좌표계가 있고, 보는 사람이 6가지 뷰 각각이 다른 뷰와 어떤 관계를 가지는지 명확하게 알 수 있습니다.

확대된 CAD 이미지 (그림 2B)는 CAD 모델의 특정 영역을 자세히 보여줍니다. 이 이미지는 모델의 특정 영역에 대한 세부적인 내용을 보여주기 위한 것입니다. 확대된 CAD 이미지는 해당 다중 뷰 CAD 이미지의 뷰 중 하나와 방향(및 좌표계)이 일치하는 모델의 단일 뷰를 보여줍니다. 이 이미지에서 치수를 나타내기 위해 두 가지 서로 다른 치수 표기법을 사용했습니다.

공학 도면 이미지 (그림 2C 및 2D)는 3D 모델의 치수 정보를 보여줍니다. 이 이미지는 공학 도면 소프트웨어를 사용하여 생성되었으므로 표시된 치수는 매우 정확합니다. 이 이미지는 해당 다중 뷰 CAD 이미지의 뷰 중 하나와 방향(및 좌표계)이 일치하는 모델의 단일 뷰를 보여줍니다. 이 이미지에서 치수를 나타내기 위해 두 가지 서로 다른 치수 표기법을 사용했습니다.

첫 번째 방법은 직접 치수 기입 방식(그림 2C 참조)으로, 특정 규칙과 관련된 치수를 도면에 명시적으로 표시하는 방식입니다. 두 번째 방법은 축척 막대를 이용한 치수 기입 방식(그림 2D 참조)으로, 축척 막대가 제공되어 모델이 필요한 치수를 추론할 수 있도록 하는 방식입니다. 우리는 치수 기입 방식이 모델 성능에 미치는 영향을 알아보기 위해 품질 보증 과정에서 이 두 가지 방법을 혼합하여 사용했습니다.

다음 섹션에서는 이러한 세 가지 이미지 유형이 QA에 어떻게 활용되는지 설명합니다. 종종 이 세 가지 이미지 유형 중 두 가지를 결합하여 더 많은 정보를 전달하는 이미지를 만들기도 합니다.

우리는 다양한 2D 이미지 유형을 사용하여 3D CAD 모델을 표현하지만, MLLM이 더욱 정교해지고 고요한 3D 모델 파일 형식을 구문 분석할 수 있게 됨에 따라 이러한 3D 모델 표현 방식도 업데이트해야 합니다.

3.1.3 규칙 이해. 규칙이 설계와 어떻게 관련되는지 이해하기 위해 엔지니어는 먼저 규칙에 제시된 용어와 설계의 다양한 구성 요소의 명칭을 이해해야 합니다. 벤치마크의 규칙 이해 부분은 이러한 이해를 바탕으로 합니다.

3D 모델의 요소를 참조하는 모델의 능력을 평가합니다.
규칙에 제시된 정의 및 용어에 따르면
문서입니다. 벤치마크의 이 부분은 다시 두 부분으로 나뉩니다.
하위 집합: 정의 QA 및 존재 QA.
정의 관련 질문은 모델이 사물의 이름을 식별하는 능력을 테스트합니다.
CAD 모델에서 강조 표시된 구성 요소입니다. 31개의 구성 요소 목록에서 다중 뷰 CAD 이미지(그림 2A)를 생성했습니다.
식별 대상 구성 요소가 분홍색으로 강조 표시되어 있습니다. 구성 요소 점수 계산을 위해 동의어(예: frame 및 chassis)도 수집했습니다.
목적에 따라서는 일부 구성 요소를 숨겨야 할 필요가 있었습니다.
CAD 모델에서 강조 표시된 구성 요소를 볼 수 있도록 시각화가 더 잘 되었습니다. 구성 요소가 숨겨진 경우 해당 내용이 표시되었습니다.
프롬프트. 서문에 다음과 같은 프롬프트가 추가됩니다.
그 결과 31개의 VQA 쌍이 생성되었습니다.

또한, 저희 차량의 CAD 도면 6면을 보여주는 이미지를 첨부했습니다.
디자인. 분홍색으로 강조 표시된 구성 요소의 이름은 무엇입니까?
[구성 요소가 숨겨진 경우] 디자인의 일부가 숨겨져 있습니다.
강조 표시된 구성 요소를 더 잘 시각화할 수 있도록 하기 위함입니다.} 강조 표시된 구성 요소의 이름만 적어서 답변해 주세요.
또 다른.

존재 여부 질문은 모델의 이해 능력을 평가합니다.
클로즈업 사진에 특정 구성 요소가 있는지 없는지 CAD 이미지입니다. 따라서 이러한 QA는 모델에게 예/아니오 답변을 요구하기 때문에 정의 QA보다 더 쉬운 변형입니다.
구성 요소의 이름 대신에. 동일한 31개 목록을 사용합니다.
정의 QA에서 구성 요소를 추출하여 두 개의 클로즈업 이미지를 생성했습니다.
(그림 2B와 같은) CAD 이미지 두 장으로, 하나는 구성 요소를 포함하고 다른 하나는 포함하지 않는 이미지입니다. 이 62개의 근접 CAD 이미지를 사용했습니다.
해당 다중 뷰 CAD 이미지에 추가되었습니다(예: 그림 2A에서처럼, 이는 클로즈업 이미지에 더 많은 3D 맥락을 제공했습니다. 그 결과 62개의 VQA 쌍이 생성되었으며, 각 쌍은 다음과 같은 특징을 가졌습니다.
다음 프롬프트에서 { }는 다음으로 대체됩니다.
31개 구성 요소 중 하나:

또한 7개의 CAD 뷰(각각 네모로 표시됨)를 보여주는 이미지가 첨부되어 있습니다.
(검은색으로 된) 저희 차량 디자인의 일부입니다. 위쪽 큰 사진은 클로즈업된 모습을 보여줍니다.
디자인의 전경입니다. 이미지 하단에 있는 6개의 작은 전경 사진입니다.
차량 CAD 도면의 다양한 전체 모습을 보여주며, 이해를 돕기 위해 제공됩니다. 확대된 이미지의 방향이 일치하는 것을 확인하세요.
6가지 전체 보기 방향 중 하나입니다. 클로즈업 보기가 될 수 있습니다.
또한 특정 구성 요소를 시각화하기 위해 (해당 전체 보기와 비교하여) 일부 구성 요소가 숨겨져 있습니다. 확대 보기에서 { }가 보이는지 확인하십시오.
클로즈업 사진에서 보셨나요? 예 또는 아니오로 간단히 답해주세요.

정의 및 존재 여부 질문의 경우, 우리는 또한 어떻게 진행되었는지 추적했습니다.
문제의 구성 요소는 규칙 문서에 언급되어 있습니다.
FSAE의 "정의" 섹션에 명시적으로 언급된 경우
규칙 문서("정의 구성 요소")에 정의 섹션에 포함되지 않았지만 문서 전체에 걸쳐 여러 번 언급된 경우("다중 언급 구성 요소") 또는 전혀 언급되지 않은 경우

문서에 전혀 언급되지 않도록 했습니다("언급되지 않은 구성 요소"). 이러한 추적의 목적은 빈도와
규칙 문서에서 구성 요소의 이름이 언급되는 방식은 모델이 해당 구성 요소를 시각적으로 식별하는 능력과 상관관계가 있습니다.
규칙 이해 문제의 구성 요소입니다.

3.1.4 규정 준수. 엔지니어는 설계가 특정 요구 사항을 준수하는지 확인하기 위해 요구 사항 문서를 자주 참조합니다.
사양. 벤치마크의 규칙 준수 부분
모델이 설계가 규정에 부합하는지 확인할 수 있는 능력을 나타냅니다.
특정 규칙. 벤치마크의 이 부분은 다시 다음과 같이 세분화됩니다.
두 가지 하위 집합: 차원 QA 및 기능 성능 QA,
해당 규칙의 유형에 따라 다릅니다.
치수 관련 질문은 모델이 설계의 타당성을 검증할 수 있는 능력을 테스트합니다.
치수 제한을 규정하는 규칙을 준수합니다.
20가지 치수 규칙 목록을 바탕으로 3개의 엔지니어링 도면을 생성했습니다.
각 규칙에 대한 이미지:

- (1) 직접 치수화되고 규칙을 준수하는 이미지(그림 참조 2C).
- (2) 직접 차원의 규칙 위반 이미지. 이것들은 다음과 같습니다.
첫 번째 이미지의 크기를 편집하여 생성된 해당 규칙을 명시적으로 위반하거나, 규칙을 수정함으로써 CAD 모델의 업데이트된 치수가 규칙을 위반했습니다.
- (3) 눈금 막대가 표시되고 규칙을 준수하는 이미지(예: 그림 2D).

눈금 막대가 있는 규칙이나 규칙을 위반하는 QA는 생성되지 않았습니다.
MIT 모터스포츠에서 제공하는 CAD는 본질적으로 규정을 준수하므로, 편집 과정에서 규정 위반 사례를 만들어내기 어렵습니다.
직접적인 치수 측정은 불가능합니다. 이러한 엔지니어링 각각은 도면 이미지가 해당 다중 뷰 CAD에 추가되었습니다.
(그림 2A와 같은) 이미지를 통해 전체 내용에 대한 맥락을 제공합니다.
모델입니다. 그 결과 다음과 같은 프롬프트가 포함된 60개의 VQA가 생성되었습니다.
서문에 추가된 내용:

또한 첨부된 이미지는 해당 제품의 엔지니어링 도면을 보여줍니다.
상단에는 차량 이미지가 있고, 그 옆에는 차량의 CAD 도면 6개가 함께 표시됩니다.
하단에는 6개의 CAD 뷰가 각각 다른 방향으로 디자인의 모습을 보여주므로 디자인에 대한 3D 정보를 확인할 수 있습니다.
추론된 것입니다. CAD 뷰는 엔지니어링 도면을 맥락화하기 위해 제공되며, 해당 도면은 6개의 CAD 뷰 중 하나와 동일한 방향을 가지고 있습니다.
도면의 모든 단위는 mm입니다. 엔지니어링 도면에 표시된 모든 단위는 다음과 같습니다.
mm. 엔지니어링 도면을 기준으로 볼 때, 우리 설계가 해당 요건을 충족합니까?
FSAE 규칙 문서에 { } 규칙이 지정되어 있습니까?
[[직접 치수를 기입한 경우:] 명시적으로 표시된 치수만 사용하십시오.]
질문에 답하려면 설계 도면을 참조하십시오. 치수가 있는 경우 명시적으로 표시되지 않았으므로, 해당 사항이 준수된다고 가정할 수 있습니다.
규칙.]
[[눈금 막대가 있는 경우:] 질문에 답하려면 다음을 사용하세요.
도면 상단에 표시된 눈금 막대를 사용하여 계산합니다.
도면에 필요한 치수를 기입하십시오.
먼저 답변에 대한 설명을 제공하십시오('설명:'으로 시작). 그런 다음 답변을 요약하는 예/아니오 답변을 제공하십시오('답변:'으로 시작).

이 질문들은 예/아니오로 답할 수 있지만,
또한, 설계가 규정을 준수했는지 여부를 설명하는 모델의 능력을 평가하여 사고 연쇄 추론을 유도하고자 했습니다 [25]. 각 직접 차원 질문에 대해 저희(또는 MIT 모터스포츠 팀 구성원)는 그 이유를 설명하는 글을 작성했습니다.

정답인 예/아니오 답변입니다. 이러한 설명은 정답을 뒷받침하는지 확인하는 것 외에는 광범위하게 검토되지 않았습니다.
해당 정답에 대한 예/아니오 답변입니다. 이 답변들은 사람이 직접 작성한 것입니다.
그런 다음 이러한 설명을 생성된 모델 설명과 비교할 수 있습니다.

이 60개의 VQA로부터, 우리는 다음과 같은 조건을 만족하는 또 다른 60개의 VQA 세트를 생성했습니다.
질문에 답하는 데 도움이 될 추가적인 맥락을 알려주세요.
원래 60개의 VQA 세트 중에서 다중 뷰 CAD를 교체했습니다.
다른 다중 뷰 CAD 이미지가 포함된 이미지의 일부
규칙과 관련된 구성 요소는 분홍색으로 강조 표시했습니다.
또한 강조 표시된 내용이 무엇인지 설명하는 문구를 프롬프트에 추가했습니다.
구성 요소는 다음과 같습니다(예: "CAD 뷰에서 하단 측면 충격 구조가 분홍색으로 강조 표시됨"). 총 120개의 치수
VQA는 다음과 같이 생성되었습니다: 추가 컨텍스트 없이 60개, 추가 컨텍스트를 포함하여 60개.
추가적인 맥락.

기능 성능 관련 질문은 모델의 능력도 테스트합니다.
주어진 관련 이미지를 바탕으로 디자인이 규칙을 준수하는지 확인합니다.
하지만 이 범주에서는 규칙, 이미지 또는 둘 다 해당됩니다.
설계의 기능적 성능과 관련된 질문들이 많습니다. 대부분의 질문은 특정 기능에 제약을 가하는 규칙에 관한 것입니다.
디자인 기준과 이미지가 규칙 확인에 필요한 정보를 전달합니다. 예를 들어, 제한 사항이 있을 수 있습니다.
부품에 사용할 재료 선택에 관하여 (따라서 해당 재료)
규칙에서 강도)를 고려하고 FEA 결과의 시각화를 통해 부품에서 발견되는 최대 응력을 나타낼 수 있습니다. 적용 가능한 경우, 한 쌍의
긍정적 및 부정적 사례가 생성되며, 변형이 발생합니다.
질문이나 이미지 중 하나에 소개되는데, 이때 첫 번째
첫 번째 예시는 규칙을 위반하는 반면, 두 번째 예시는 그렇지 않습니다.

아닙니다. 이미지와 규칙에는 상당한 차이가 있습니다. 이 하위 집합 내에는 표준화된 프롬프트가 없습니다. 더 자세한 내용을 알아보시려면 저희 코드 탐색을 권장합니다. 이러한 질문들은 제한된 정보로 인해 сформулирование하기가 더 어려웠습니다. 기능적 성능 데이터의 이 하위 집합에는 16개의 VQA가 있습니다. 차원 관련 질문에 대해서는 사람이 직접 작성한 설명을 생성했습니다. 각 VQA에 대해.

3.2 평가 지표. DesignQA에서 테스트된 모델은 다음과 같습니다. 완전히 자동으로 평가됩니다. 6개의 하위 집합 각각에 대해 벤치마크에 적합한 자동 평가 지표가 있습니다. 모델의 (예측값)을 얻기 위해 코드에 선택 및 구현되었습니다. 답변은 실제 정답과 쉽게 비교할 수 있습니다. 평가 지표 중 일부는 직관적으로 이해하기 어려울 수 있습니다. 예측값이 실제 정답에 비해 얼마나 높은 점수를 받을지 나타냅니다. 따라서 그림 3에서는 모델 평가 섹션에서 제시된 모델 예측 결과와 그에 상응하는 결과를 몇 가지 예시로 보여주었습니다. 정답과 그에 따른 점수를 보여줍니다. 각 평가 지표는 아래에서 자세히 설명합니다.

3.2.1 F1 점수. 데이터셋의 여러 하위 집합에 대해 F1 점수가 매겨집니다. F1-스코어의 변형입니다. F1-스코어는 널리 사용되는 지표입니다. 이진 분류 작업에서 모델 성능을 평가하는 것, 예를 들어 이 지표는 정밀도와 재현율을 모두 고려합니다. 정의는 다음과 같습니다.
$$F1\text{ 점수} = 2 \times \frac{\text{정밀도} \times \text{재현율}}{\text{정밀도} + \text{재현율}}$$
 F1 Bag of Words: Bag of Words(BoW)에 F1을 적용한 결과는 다음과 같습니다. [19–21]에서 벤치마크를 위한 자동 측정 기준으로 사용됨 모델에게 텍스트 본문에서 정확한 구절을 추출하여 질문에 답하도록 요청했습니다. [19]에서 정의한 바와 같이, 해당 측정 기준은 먼저 다음을 포함합니다. 청소 단계. 예측된 답변(모델 응답)과 정답은 소문자로 변환됩니다. 공백이 제거되고, 구두점과 관사가 삭제됩니다. 출력됩니다. 그런 다음 각각은 예측된 단어 목록으로 "토큰화"됩니다.

리스트(P)와 정답 리스트(GT) - F1 점수는 정밀도와 재현율을 사용하여 계산할 수 있으며, 여기서 및
$$= \frac{n}{\text{길이}(\text{len})}$$
 검색 QA에서도 모델에게 다음 위치에서 텍스트를 가져오도록 요청하기 때문에 규칙 문서를 그대로 사용하며, F1 Bag of Words 지표를 활용합니다. 벤치마크의 검색 하위 집합을 평가하기 위해 계산합니다. 각 QA에 대한 F1 BoW를 계산하고, 전체 평균값을 보고합니다. 질문.

F1 규칙: 검색 QA와 유사하게, 컴파일 질문은 모델에게 규칙 문서에 포함된 텍스트(특히 규칙 번호)를 식별하도록 요구합니다. 따라서 매우 유사한 방식을 사용합니다.

검색 QA에 사용되는 F1 Bag of Words의 메트릭은 제외됩니다. 리스트 P와 GT는 규칙 번호 리스트로 대체됩니다. 각 QA에 대해 F1 규칙을 계산하고, 전체 평균값을 보고합니다. 모든 질문.

F1 문자 모음(BoC): 정의 QA는 모델에게 질문합니다 다중 뷰 CAD 이미지에서 강조 표시된 구성 요소를 식별하려면, 규칙 문서를 참조하여. 이 QA들은 다음과 같이 보였습니다. 검색 QA와 유사하게 점수를 매겨야 하지만, 이제 모델에게 구성 요소 이름(여러 단어)을 입력하라는 요청이 있었습니다. 완전한 규칙(문장)보다는 처벌을 가하고 싶지 않았습니다. 작은 철자 오류나 어미 차이에 대한 모델입니다. 예를 들어, 정답이 "프론트 후프"인 경우 예측 응답은 다음과 같습니다. "프론트 후프"는 "프론트"보다 더 정확한 표현으로 간주되어야 합니다. 모터." F1 Bag of Words는 "프론트 후프드"와 "프론트"를 득점할 것입니다. "모터"도 마찬가지로 정확합니다. F1 Bag of Characters는 상대적인 것을 반영합니다. "프론트 후프드"와 "프론트 모터"의 정확성 비교입니다. 계산되었습니다. F1 Bag of Words와 동일한 방식이지만, 토큰화는 다음에서 발생합니다. 단어 수준이 아닌 문자 수준에서 F1 BoC를 계산합니다. 모든 단어에 걸쳐 각 정의 QA를 수행하고 매크로를 보고합니다. 각 질의응답 항목별 최고 점수의 평균.

3.2.2 정확도. 벤치마크의 몇 가지 하위 집합 - 존재 여부, 차원 및 기능 성능 관련 질문은 모델에 문의하세요. 예/아니오로 답하도록 합니다. 정확도(ACC)를 사용하여 점수를 매깁니다.

3.2.3 설명 지표. 규칙 준수 질문에 대해 모델은 예/아니오 답변과 함께 설명을 반환합니다. 모델이 생성한 설명 텍스트의 의미론적 측면을 자동으로 평가합니다.

사람이 작성한 참고 문헌과의 유사성을 평가하는 것은 복잡한 작업입니다. 완벽한 해결책은 없습니다. 최근 개발된 벤치마크 테스트 객관식 과학 문제에 대한 대규모 언어 모델인 Sci-enceQA [25]는 BLEU [37]를 비롯한 세 가지 다른 자동화된 측정 기준을 사용했습니다. ROUGE [38] 및 유사성 [39] - 유사성을 평가하기 위해 LLM이 생성한 설명과 사람이 작성한 설명. 우리는 루를 따릅니다. et al.의 예시를 참고하여 이 세 가지 지표를 사용하여 MLLM이 생성한 설명을 사람이 직접 수집한 설명과 비교하여 평가합니다. 벤치마크. 각 지표에 대한 자세한 설명은 아래에 있습니다.

BLEU: BLEU(이중언어 평가 예비 과정) 점수는 다음과 같습니다. Papineni et al. [37]이 인간의 참조 번역에 대한 기계 번역의 자동 점수 매기기로 개발했습니다. BLEU를 계산하기 위해 예측 문장과 참조 문장을 먼저 보리합니다. n-그램으로 변환되는데, n-그램은 사용자가 지정한 n개의 단어로 이루어진 세그먼트입니다. 예측된 단어와 참조 단어 간의 n-그램 일치 여부를 확인합니다. 그런 다음 문장을 찾습니다. 예측된 n-그램이 일치하면 참조 n-그램의 경우, "클리핑"이라는 과정을 통해 해당 n-그램이 참조 n-그램 풀에서 제거됩니다. 일치하는 n-그램의 수는 전체 n-그램의 수로 나뉩니다. 예측된 문장은 수정된 정밀도 점수를 생성합니다. 저자들은 BLEU-4를 계산할 것을 제안합니다. n = 1부터 n = 4이므로 4의 가하 평균을 취합니다(n이 증가함에 따라 지수적으로 감소하기 때문입니다) [37]. 그러나 우리는 참고 문헌(설명)을 하나만 사용했을 경우, BLEU-4 점수는 항상 0에 가까웠습니다. 따라서 0이 아닌 값을 가지는 BLEU-2 점수를 보고합니다. 점수를 매기지만 인접성에 대한 일부 정보는 여전히 보존합니다. 단어 수. BLEU-2(최대 n-gram 2개 사용)는 다음과 같이 계산할 수 있습니다.

$$\log(\text{BLEU}) = \min \left(\frac{1}{n}, 0 \right) + \sum_{n=1}^4 \frac{1}{2} \log \left(\frac{\text{정밀도}_n}{\text{정밀도}_1} \right)$$
 "간결성 페널티"이며, 실제 값(길이 c)보다 짧은 예측값에 불이익을 주는 역할을 합니다.

r). 규칙 준수 질문의 설명 부분에 대해서는, 우리는 모델 간의 유사성을 정량화하기 위해 BLEU-2를 보고합니다. 생성된 설명과 사람이 생성한 설명.

ROUGE: ROUGE(요점 정리를 위한 회상 중심의 보조 연구원) 평가 측정 기준은 Lin et al. [38]에 의해 개발되었으며, 이는 다음을 측정하기 위한 것입니다. 컴퓨터로 생성된 텍스트 요약의 품질이 사람이 작성한 요약의 품질과 비교했을 때 어떨지, 참고 요약. 최장 공통 부분 수열(LCS)을 사용하는 ROUGE-L은 문장 수준의 단어 순서 유사성을 특징화하는 데 유용합니다. LCS는 가장 긴 단어 시퀀스를 의미합니다.

같은 순서로 나타나지만 반드시 연속적일 필요는 없는 것들 두 문장. ROUGE-L은 F1 점수로 계산됩니다.
$$\text{LCS: } 2 \times \frac{\text{정밀도} \times \text{재현율}}{\text{정밀도} + \text{재현율}}, \text{ 그리고 } = \frac{\text{정밀도} \times \text{재현율}}{\text{정밀도} + \text{재현율}}$$

여기서는 참조 문장이고, 는 예측된 문장이며, 는 참조 문장의 길이이고, 는 예측된 문장의 길이입니다. 문장의 경우, 는 재현율이고 는 정밀도입니다. 규칙 준수 질문에 대한 설명 부분 외에도, BLEU-2 보고와 더불어 ROUGE-L도 보고합니다. 유사성: 유사성 측정 기준은 Sentence-BERT 기반 문장 임베딩 코사인 유사성을 의미합니다 [39, 40]. 모델이 생성한 설명과 사람이 작성한 설명 sentence-transformers/all-MiniLM-L6-v2를 사용하여 내장됩니다. 문장 변환기는 두 개의 벡터를 생성하여 인코딩합니다. 설명의 의미. 두 그래프 사이의 코사인 유사도 그런 다음 벡터를 계산하여 얼마나 겹치는지 확인합니다. 두 설명 사이의 의미 차이.

4. 모델 평가

우리는 간단한 기준 모델과 최첨단 MLLM을 평가합니다. 이 글을 쓰는 시점에서, 현재 상황을 이해하기 위해 DesignQA 벤치마크를 진행하고 있습니다. 엔지니어링 요구사항을 이해하는 데 있어 AI 모델의 능력 문서화. 이러한 평가의 목표는 모든 것을 망라하는 것이 아닙니다. 테스트해야 할 다른 모델들이 많이 있으며, 시간과 비용이 허락한다면. MLLM 개발 속도가 매우 빠르다는 점을 고려할 때, 벤치마킹을 위해 연구 커뮤니티의 도움을 요청합니다.

Retrieval - F1 BoW			
	GPT-4-AllRules	GPT-4-RAG	LLaVA-1.5-RAG
Prediction	V.1.2 Wheelbase The vehicle must have a minimum wheelbase of 1525 mm	I'm sorry, but I cannot provide the text for rule S.3.7.1 as it is not included in the provided context from the Formula SAE rule document. If you can provide the specific text or section of the document where this rule is located, I would be able to help you further.	V.1.4 states that the vehicle must be open wheeled and open cockpit with four wheels that are not in a straight line.
Score	Score: 0.947	Score: 0.123	Score: 0.050
Ground Truth	Wheelbase The vehicle must have a minimum wheelbase of 1525 mm	A supplement to the Cost Report that reflects any changes or corrections made after the submission of the Cost Report may be submitted.	The distance to the ground below the Lower Side Impact Structure (F.6.4.5, F.7.5.1) at its lowest point should be 75 mm or less

Compilation - F1 Rules			
	GPT-4-AllRules	GPT-4-RAG	LLaVA-1.5-RAG
Prediction	T.3.2, T.3.3, T.4.3, IC.3.3, EV.4.6, EV.4.7 , EV.7.2.2, EV.7.7.2, EV.9.3.2, EV.9.4.2 , D.3.2.4, D.12.4.2, D.12.4.3, D.12.8.1, D.12.8.2, D.13.2.1, D.13.2.4.	EV.6.3, EV.6.3.1 , EV.6.3.2 , EV.6.3.3 , EV.6.3.4 , EV.6.3.5 , EV.6.4, EV.6.4.1, EV.6.4.2, EV.6.4.3	EV.4.4, EV.4.4.1, EV.4.4.2, EV.4.4.3, EV.4.4.4, EV.4.4.5, EV.4.4.6, EV.4.4.7, EV.4.4.8
Score	Score: 0.242	Score: 0.343	Score: 0.0
Ground Truth	T.3.2, T.3.2.1, T.3.2.2, T.3.2.3, T.3.2.4, T.3.3.1, T.4.3.1, EV.4.7, EV.7.7.1, EV.7.7.4, EV.9.4.2, EV.4.7.1, EV.4.7.2, EV.9.3, EV.4.6, EV.4.5	F.11.1.3, T.1.8.4, T.4.2.9, T.4.3.3, T.8.3.2, IC.4.4.7, EV.4.1.3, EV.4.3.4, EV.6.3, EV.6.3.2, EV.6.3.3, EV.6.3.4, EV.6.3.5, EV.7.8.4, EV.6.3.1, EV.1.1, F.11.1.2, F.1.13, F.5.16, T.4.2.4, EV.7.8, EV.7.2.2, F.10.4, EV.6.1, EV.6.5	F.10.4.3, T.9.2.4, T.9.2.5, IC.9.3.2, EV.1.3, EV.6.6.3, EV.6.6.5, EV.7.7.2, EV.6.6.2, EV.7.2.2, EV.4.6

Definition - F1 BoC			
	GPT-4-AllRules	GPT-4-RAG	LLaVA-1.5-RAG
P	Roll hoop bracing	Suspension arms	steering
Score	Score: 0.609	Score: 0.455	Score: 0.235
GT	main hoop	uprights	roll hoop; roll hoops

Compliance Explanations - Bleu/Rouge/Similarity			
	GPT-4-AllRules	GPT-4-RAG	LLaVA-1.5-RAG
Prediction	Rule T.7.5.a from the FSAE rule document states that in plan view, any part of any Aerodynamic Device must be no more than 700 mm forward of the fronts of the front tires. The engineering drawing provided shows a dimension of 705.28 mm from the front of the front tire to the most forward part of the nosecone, which is likely to be considered an Aerodynamic Device. Since this dimension exceeds the maximum allowed 700 mm, the design does not comply with rule T.7.5.a.	Unfortunately, the rule F.5.9.5 is not included in the provided excerpt from the FSAE rule document. Without the specific requirements of rule F.5.9.5, it is not possible to assess compliance based on the engineering drawing provided. To determine compliance, the exact wording and specifications of rule F.5.9.5 are necessary.	To determine if the design complies with rule F.3.2.1g, we need to compare the dimensions of the main hoop with the minimum size requirements given in the rule. In the engineering drawing, the main hoop is a steel tube with dimensions (height) x (outer diameter) = 300 mm x 35 mm. The rule F.3.2.1g states that the main hoop must be a single piece of uncut, continuous, closed section steel tubing meeting F.3.2.1.g. F.3.2.1.g does not provide any specific size requirements, but it refers to F.3.4.1. Since the main hoop in the image is a single piece of uncut, continuous, closed section steel tubing, we can conclude that it meets the requirements of F.3.2.1.g.
Score	Score: 0.320/0.468/0.868	Score: 0.070/0.215/0.273	Score: 0.097/0.268/0.717
Ground Truth	The rule states that no part of any aerodynamic device can be more than 700 mm forward of the fronts of the front tires. In the drawing, the front of the front wing is 705.28 mm (less than 700 mm) in front of the fronts of the front tires. Therefore, this design is rule compliant.	F.5.9 says: The included angle formed by the Main Hoop and the Main Hoop Braces must be 30° or more, and this image shows an angle of 28.76 degrees.	F.3.2.1g says the main hoop must meet size A requirements - 25mm outer diameter. The drawing shows the outer diameter of the main hoop is only 24.3mm

그림 3. 벤치마크의 다양한 하위 집합에 대한 GPT-4-AllRules, GPT-4-RAG 및 LLaVA-1.5-RAG의 샘플 응답.

해석하기 어려운 평가 지표를 포함하는 하위 집합을 보여줌으로써 다양한 점수에 대한 참고 자료를 제공합니다. 예측 응답 중 굵게 표시된 부분은 저허가 정확하다고 해석한 부분입니다.

새로운 최첨단 모델들이 개발되는 대로 이를 평가합니다. 우리가 수행한 평가의 목표는 현재 AI 기술의 한계를 보여주며, 다른 연구자들이 이러한 한계를 극복하는 더 나은 AI 모델과 프레임워크를 개발하고 훈련하도록 장려하는 것입니다. 또한, 다양한 MLLM 모델을 평가함으로써 문제의 상대적인 난이도를 파악할 수 있으며, 실패 양상은 향후 설계 요구사항 유형의 문제 벤치마킹에 대한 영감을 제공할 수 있습니다.

4.1 기준선 및 모델.

4.1.1 단순 기준선. [14]와 유사하게, 벤치마크의 다양한 하위 집합 및 지표에 걸쳐 모델 성능을 쉽게 맥락화할 수 있도록 무작위 선택에 기반한 기본 기준선을 생성합니다. 검색 질문의 경우, 규칙 목록에 있는 1192개의 규칙 중에서 무작위로 하나를 선택합니다. 컴파일 질문의 경우, 1192개의 규칙 목록에서 10개의 규칙을 무작위로 선택합니다. 정의 질문의 경우, 규칙 문서에서 연속된 두 단어를 무작위로 선택합니다. 정확도(존재, 차원 및 기능 성능)를 기준으로 평가되는 질문의 경우에도 마찬가지입니다.

질문들에 대해 50%의 확률로 '예' 또는 '아니오'를 무작위로 선택합니다.

참고로, 이러한 기준선은 모든 머신러닝 모델에 대해 (학습 없이 무작위로 예측했을 때의) 최소 임계값 점수를 파악하기 위해 평가된 것입니다.

4.1.2 MLLM 모델. 본 평가에서는 최근 개발된 MLLM 5개를 고려합니다. 이 중 4개는 클로드 소스 모델로, OpenAI의 gpt-4o (GPT-4o) [16], OpenAI의 gpt-4-1106-vision-preview (GPT-4) [1], Google AI의 models/gemini-1.0-pro-vision (Gemini-1.0) 5, Anthropic의 claude-3-opus-20240229 (Claude-Opus) 6이며, 나머지 1개는 오픈 소스 모델인 LLaVA-1.5-13b (LLaVA-1.5) [17]입니다. 달리 명시되지 않는 한, GPT-4o, GPT-4, Gemini-1.0, Claude-Opus 또는 LLaVA-1.5에 대한 모든 언급은 이러한 특정 모델 버전을 가리킵니다. GPT-4, Gemini-1.0 및 Claude-Opus는 기존 멀티모달 벤치마크에서 클로드 소스 모델로서 뛰어난 성능을 보였기 때문에 원래 선택되었습니다 [9, 14]. 예를 들어, Gemini-1.0 Ultra, Claude-Opus 및 GPT-4V(ision)는 최고 성능을 보였습니다.

5<https://ai.google.dev/gemini-api/docs/models/gemini?authuser=1>

6<https://www.anthropic.com/news/claude-3-family>

2024년 4월 기준으로 MMMU 벤치마크에서 세 가지 모델이 사용되었으며, 이 벤치마크는 대학 커리큘럼 콘 텐츠에서 가져온 11,500개의 멀티모달 질문으로 구성됩니다 [24]. GPT-4o는 이 연구의 후반부에 출시되었 으며, 2024년 8월 기준으로 MMMU 리더보드에서 1위를 차지하고 있습니다[24]. 이러한 뛰어난 성능과 GPT-4와의 비교 가능성 때문에 본 연구의 비공개 소스 모델 평가에 추가되었습니다. 이러한 방식으로 DesignQA는 모델이 시간이 지남에 따라 발전하는 과정을 지속적으로 측정하는 데 사용될 수 있습니다. LLaVA-1.5는 오픈 소스 MLLM [41]으로서의 가능성(및 파생 모델의 가능성) 때문에 선택되었습니다.

벤치마크의 검색 및 컴파일 문제는 텍스트 전용 모델로도 답변할 수 있지만, 본 연구에서는 MLLM에 대해 이 미지가 없는 상태로 이 부분의 문제를 제시합니다.

FSAE 규칙 문서 PDF에서 추출한 텍스트는 대략 70,091개의 토큰으로 구성되어 있습니다. GPT-4o와 GPT-4는 128,000개의 토큰 컨텍스트 창을, Claude-Opus는 200,000개의 토큰 컨텍스트 창을 가지고 있으므로, 이러한 모델들은 프롬프트에 있는 전체 규칙 텍스트를 처리할 수 있습니다.

그러나 LLaVA-1.5와 Gemini-1.0은 각각 4,096개의 토큰 컨텍스트 윈도우와 12,288개의 토큰 컨텍스 트 윈도우만 가지고 있어 전체 규칙 텍스트를 컨텍스트 입력으로 사용할 수 없습니다. 따라서 이 두 모델은 FSAE 규칙 문서에서 질문과 관련된 적절한 컨텍스트를 검색하기 위해 검색 증강 생성(RAG) 시스템이 필요 합니다 [42]. 본 연구의 목표는 다양한 RAG 기법을 평가하는 것이 아니었으므로, 4.1.3절에서 자세히 설명 하는 LlamaIndex 프레임워크를 사용하여 매우 간단한 RAG를 구현했습니다 .

GPT-4o, GPT-4, 그리고 Claude-Opus의 경우, 컨텍스트 창을 통해 전체 규칙 문서를 입력하는 것이 비용 이 많이 드는 것으로 나타났습니다. 이는 간단한 RAG를 통해 규칙 문서를 모델에 제공하는 것보다 10배 이 상 높은 비용이었습니다. 이 모델들 중 Claude-Opus는 작성 시점을 기준으로 입력 토큰당 비용이 가장 높 았기 때문에 RAG 시스템을 사용한 테스트는 Claude-Opus에만 적용했습니다. GPT-4o와 GPT-4의 경우, 컨텍스트 창을 통해 전체 규칙 문서를 제공하는 방식과 RAG를 통해 규칙 문서를 제공하는 방식 모두를 테스 트하여 RAG를 통해 규칙을 입력받은 다른 모델들과의 비교를 용이하게 했습니다.

요약하자면, 우리는 다음과 같은 모델 조합을 테스트했습니다: GPT-4o-AllRules(컨텍스트 창을 통 해 전체 규칙 문서를 제공받음), GPT-4-AllRules(컨텍스트 창을 통해 전체 규칙 문서를 제공받음), GPT-4o-RAG, GPT-4-RAG, LLaVA-1.5-RAG, Gemini-1.0-RAG 및 Claude-Opus-RAG. 모든 모델에서 시스 템 프롬프트 템플릿을 지정하지 않았으므로 기본 시스템 프롬프트가 사용되었습니다.

또한, MLLM을 호출하는 데 사용한 프레임워크인 LlamaIndex에서 설정한 각 모델의 기본 매개변수(top_p 및 온도)를 사용했습니다. 자세한 내용은 보충 자료(SI)에서 확인할 수 있습니다.

4.1.3 RAG. RAG는 외부 지식을 통합하여 텍스트 생성을 향상시키는 자연어 처리 기술로, 데이터베이스 또는 코퍼스에서 관련 정보를 동적으로 검색하여 생성되는 콘텐츠를 개선합니다 [42]. 특히 컨텍스트 창이 작 은 모델에 유용하며, 방대한 문서에서 관련 정보를 선택적으로 추출하여 더 많은 정보를 담고 문맥적으로 정 확한 텍스트 출력을 생성하는 데 도움을 줍니다. 앞서 언급했듯이, 본 연구의 목표는 다양한 RAG 기술을 연 구하는 것이 아닙니다. 따라서 LlamaIndex를 사용하여 매우 간단한 RAG 시스템을 구현하고, OpenAI의 text-embedding-3-large를 사용하여 FSAE 규칙 문서에 정보를 임베딩했습니다 [43]. 규칙 문서의 텍스 트를 250개 토큰 청크로 인덱싱하고, 각 청크는 50개 토큰씩 겹치도록 했습니다. 그런 다음 임베딩된 각 청크 와 질문 간의 코사인 유사도를 계산합니다. 가장 관련성이 높은 상위 15개 페이지(규정 준수 QA의 경우 상 위 12개)를 벤치마크에서 질문을 제시하기 전에 컨텍스트로 프롬프트에 입력합니다. 상위 15개 페이지를 포 함하는 것이 모델의 컨텍스트 창 크기를 초과하는 경우, 상위 k 값을 낮췄습니다. FSAE 규칙 문서에는 몇 개 의 이미지가 있지만, 추가 처리가 필요하고 LLaVA-1.5가 여러 이미지 입력으로 학습되지 않았기 때문에 평가 대상에서 제외했으며 RAG에도 포함하지 않았습니다. FSAE 규칙 문서의 몇몇 표는 특별한 처리를 하지 않 고 PDF 텍스트 추출 스크립트에서 추출한 일반 텍스트와 함께 모델에 입력합니다.

페이지. 벤치마크의 정의(Definition) 질문 하위 집합에 대해서만 *RAG 모델에 RAG에서 생성된 컨텍스트를 제 공하지 않았습니다. 정의 하위 집합의 질문은 모두 동일하기 때문입니다. 즉, 이미지는 질문마다 다르지만 "강 조 표시된 구성 요소의 이름을 말하세요"와 같은 질문입니다. 따라서 RAG는 각 질문에 대해 항상 동일한 규 칩 문서 부분을 반환합니다. 이러한 동일한 컨텍스트는 유용하지 않으므로 정의 질문에 대해서는 모델에 제공 하지 않았습니다. 결과적으로 테스트된 모든 *RAG 모델은 정의 하위 집합에 대해서만 문서 컨텍스트를 받 지 않았습니다.

4.2 결과 및 분석. 표 2 는 기준선 결과와 모델 결과를 모두 보여줍니다. 먼저 전반적인 결과를 논의한 다 음, 벤치마크의 각 하위 집합에 대한 결과를 구체적으로 살펴보겠습니다.

전반적인 결과. 테스트된 모델 중 GPT-4o-AllRules가 벤치마크의 거의 모든 지표에서 가장 우수한 성 능을 보였습니다. GPT-4o-AllRules와 GPT-4-AllRules는 한 가지 하위 집합을 제외한 모든 경우에서 해 당 -RAG 모델보다 우수한 성능을 나타냈는데, 이는 단순한 LlamaIndex RAG 구현이 모델에 관련 규칙 정보를 제공하는 데 일반적으로 효과적이지 않았음을 보여줍니다. 반면, 컨텍스트 창에 전체 규칙 텍스트를 입력하면 GPT-4o-AllRules와 GPT-4-AllRules가 필요한 정보에 접근할 수 있었습니다. 테스트된 모델 중 GPT-4o-AllRules는 규칙 준수 설명 부문에서 최고의 성능을 보이는 않았습니다. Gemini-1.0-RAG는 BLEU 및 ROUGE 지표에서 더 높은 점수(또는 동점)를 받았는데, 이는 모델의 간결한 설명 덕분에일 가능성이 이 높습니다. 또한 Claude-Opus-RAG는 기능 성능 설명 유사성 점수에서 GPT-4o-AllRules와 동점을 기 록했습니다. 테스트된 *RAG 모델 중 GPT-4o-RAG가 기능 수행 관련 질문을 제외하고는 전반적으로 우수 한 성능을 보였습니다. 기능 수행 관련 질문에서는 Claude-Opus-RAG가 테스트된 *RAG 모델 중 가장 높 은 정확도 점수를 기록했습니다. 이러한 결과는 Claude-Opus가 다른 모델들에 비해 엔지니어링 설계 관련 기술적 추론 능력이 더 뛰어나다는 것을 시사할 수 있습니다.

GPT-4o-AllRules는 테스트된 모델 중 뛰어난 성능을 보였지만, 벤치마크의 각 하위 집합에서 만점(1.0) 을 받지는 못했습니다. 전체 규칙 문서를 제공받더라도 GPT-4o-AllRules는 텍스트에서 특정 규칙을 안정적 으로 추출하지 못하는데, 이는 엔지니어에게는 사소하지만 매우 중요한 작업입니다. MLLM의 컴파일, 정의, 존재 하위 집합 점수 또한 Naive 기준선과 비교했을 때 상대적으로 낮습니다. 이는 해당 하위 집합의 질문이 모델을 규칙 문서의 특정 부분으로 안내하지 않아 더 어려운 검색 문제를 야기하기 때문일 수 있습니다. 실 제 엔지니어링 설계 과제의 특징인 이러한 문제를 해결할 수 있도록 엔지니어링 및 추론 지식을 갖춘 MLLM을 개발하기 위해서는 상당한 연구가 필요합니다. 엔지니어링 맥락에서 탁월한 성능을 발휘하고 실제 응용 분야 에서 정확성과 신뢰성을 향상시키는 MLLM 방법 개발에 노력을 집중해야 합니다.

규칙 추출: 검색. 평가된 모델 중 GPT-4o-AllRules와 GPT-4-AllRules는 요청된 규칙을 정확하게 검 색하는 데 있어 다른 모델보다 현저히 우수한 성능을 보였습니다(평균 F1 BoW 점수 각각 0.885 및 0.750). *-AllRules 모델의 답변이 정답과 다른 경우, 모델이 요청된 규칙 대신 인접한 규칙(예: V.3.2.4 대신 V.3.2.5) 을 보고하거나, 요청된 규칙(예: V.3.2.1) 대신 유사한 번호의 규칙(예: F.3.2.1)을 보고하는 경우가 많습니 다. 때로는 *-AllRules 모델의 답변이 정답과 다른 이유가 요청된 상위 규칙 외에 모든 하위 규칙을 포함했 기 때문인 경우도 있었습니다(예: V.1을 요청했을 때 V.1과 함께 V.1.1 및 V.1.2가 보고됨). 기술적으로 틀린 것은 아니지만, 이 결과는 저희 평가 지표에서 다르게 처리되지 않았으며, 향후에는 특별히 처리해야 할 결과 일 수 있습니다.

GPT-4o 또는 GPT-4에 컨텍스트를 통하지 않고 RAG를 통해 규칙을 제공한 결과 평균 F1 BoW 점수 가 훨씬 낮아졌습니다(0.186).

표 2. 이 표는 다양한 MLLM 모델의 벤치마크 점수를 자세히 비교한 결과를 보여줍니다. 테스트된 모델 중, GPT-4o-AllRules는 거의 모든 지표에서 최고의 성능을 보여줍니다. 특히, 구성, 정의 및 존재 여부 질문에서 뛰어난 성능을 보였습니다. 최고 성능 모델의 점수와 단순 기준 모델의 점수 간의 차이가 가장 작은 값입니다. 모든 지표에서 만점은 최고 점수입니다. 1.0이 될 것입니다.

위쪽 화살표가 가리키는 것처럼 값이 클수록 좋습니다.								
부분집합 (미터법)	기준선			모델				
	나이브	GPT-4o-AllRules	GPT-4-AllRules	GPT-4o-RAG	GPT-4-RAG	LLaVA-1.5-RAG	병동아자라-1.0-RAG	클로드-오퍼스-RAG
규칙 추출								
검색 (F1 BoW ↑)	0.082	0.885	0.750	0.186	0.181	0.112	0*	0.173
편집 (F1 규칙 ↑)	0.137	0.424	0.298	0.376	0.362	0.281	0.283	0.288
규칙 이해								
정의 (F1 BoC ↑)	0.358	0.540	0.470	0.525	0.420	0.393	0.488	0.423
있음 (ACC ↑)	0.5	0.726	0.629	0.710	0.532	0.484	0.548	0.5
규칙 준수								
차원 (ACC ↑)	0.5	0.825	0.533	0.675	0.300	0.408	0.525	0.508
(블루/루즈/유사성 ↑)	-	0.175/0.344/0.777	0.118/0.296/0.728	0.111/0.255/0.642	0.091/0.235/0.592	0.097/0.241/0.578	0.176/0.344/0.644	0.137/0.295/0.698
기능적 성능 (ACC ↑)	0.5	0.938	0.563	0.750	0.563	0.536	0.438	0.875
(블루/루즈/유사성 ↑)	-	0.230/0.408/0.745	0.167/0.342/0.697	0.181/0.367/0.736	0.121/0.306/0.698	0.163/0.321/0.650	0.266/0.444/0.725	0.172/0.354/0.745

*Gemini-1.0-RAG는 "RECITATION" 오류로 인해 응답 생성이 중단되어 검색 질문에서 0점을 받았습니다.

(각각 0.181 및 0.181). 여러 질문(그림 3에 표시된 GPT-4-RAG 검색 예시와 같은)의 경우 GPT-4o-RAG와 GPT-4-RAG는 해당 규칙의 텍스트를 생성할 수 없다고 답변했습니다. 해당 내용이 규칙서에 포함되지 않았기 때문입니다. 단순한 LlamaIndex RAG가 관련 정보를 제공하지 못했다는 점 규칙 문서의 일부를 모델에 적용합니다. GPT-4o-RAG의 경우 그리고 GPT-4-RAG는 그 질문에 대한 답을 제시했습니다. 각각의 *-AllRules 모델과 유사한 반응을 보였습니다. Claude-Opus-RAG는 비슷한 평균 F1 BoW 점수(0.173)를 기록했습니다. GPT-4o-RAG 및 GPT-4-RAG, 그리고 Claude-Opus-RAG와 비교했을 때 또한 제공된 RAG에 해당 규칙이 없는 경우에도 이를 기록했습니다. 문맥.

LLaVA-1.5-RAG는 다른 *-RAG 모델들과 동일한 규칙 문서 부분을 받았지만, 평균 F1 BoW는 다른 모델과 차이가 있었습니다. 점수는 훨씬 더 낮았습니다(0.112). GPT-4o-RAG, GPT-4-RAG와는 달리, 그리고 Claude-Opus-RAG, LLaVA-1.5-RAG는 규칙을 환각으로 만들어낼 것입니다. 요청된 규칙이 포함되어 있지 않다는 것을 나타내는 것보다는 RAG를 통해 수신한 문서의 일부입니다. 또한, LLaVA-1.5-RAG는 규칙을 있는 그대로 반환하는 대신, 요청된 규칙에 대한 해석을 자주 제공했습니다(예: 그림 3은 LLaVA-1.5-RAG 검색 예시입니다. Gemini-1.0-RAG는 벤치마크의 검색 하위 집합에서 0점을 받았는데, 이는 모델이 각 질문에서 "RECITATION" 오류를 발생시켰기 때문입니다. 해당 모델은 다음과 같이 프로그래밍되었습니다.

생성된 콘텐츠가 일부를 반복하는 경우 콘텐츠 생성을 중지합니다. 입력 데이터의 특성입니다. 어떤 경우에는 이러한 동작이 유용할 수 있지만, 이는 벤치마크의 해당 하위 집합의 목적에는 유용하지 않습니다. 우리는 단어 그대로의 반복을 요청합니다. 우리는 다른 많은 경우를 상상할 수 있습니다. 사용자가 직접 견적을 원하는 유사한 문의 사항 이러한 반복 차단은 문제가 될 수 있습니다. 왜냐하면 이것은 폐쇄형 소스 모델이기 때문에 우리가 이 동작을 변경할 방법이 없습니다.

규칙 추출: 컴파일. GPT-4o-AllRules는 다음을 수행합니다. 모델의 컴파일 문제에서 최고 점수(F1 점수 0.424점)를 기록했습니다. 테스트는 완료되었습니다. 하지만, 구성 문제는 (정의 및 존재 문제와 함께) 벤치마크 범주 중 하나입니다. 이는 가장 우수한 성능을 보인 모델 점수(GPT-4o-AllRules)와 단순 무작위 기준선 간의 차이가 비교적 작다는 것을 의미합니다. 점수. 최고의 성능을 보이는 GPT-4o-AllRules의 성능을 저해하는 요인은 무엇일까요? 더 높은 점수를 얻고 싶어요? 모델이 반복적으로 오류를 일으키는 것을 발견했습니다. 답변에 검색어 "verba-tim"을 포함하는 규칙을 추가하도록 합니다. 예를 들어, 첫 번째 컴파일 질문에서 다음과 같이 묻습니다. "공기역학" 또는 "공기역학"과 관련된 규칙에 대한 모델

해당 모델은 T.7.2.1, T.7.2.2 및 T.7.5를 포함하지 않습니다. 모든 규칙에는 "공기역학"이라는 단어가 그대로 포함되어 있습니다. 개선 MLLM의 기본적인 텍스트 추출 능력은 설계 요구사항 유형의 작업에서 더 나은 성과를 내는 데 필수적입니다. 또한 우리는 다음과 같은 점을 관찰했습니다. GPT-4o-AllRules가 자주 보고하지 않는 규칙은 다음과 같습니다. 검색어를 포함하는 규칙에 의해 언급됩니다. 예를 들어, 공기역학 문제에 있어서 GPT-4o-AllRules는 언급하지 않습니다. GR.6.4.1, V.1.1 및 V.1.4.1은 모두 다른 문서에서 참조됩니다. "공기역학"이라는 단어가 포함된 규칙들. 어쩌면 우리의 프롬프트는 규칙에서 참조하는 규칙을 명시적으로 언급해야 합니다. 검색어를 포함하는 것이 관련성이 있다면, MLLM은 서로 연결되지 않은 부분들을 가로지르는 규칙 체인을 따라갈 수 있는 능력을 갖춰야 합니다. 문서.

*-RAG 모델 측면에서 보면 GPT-4o-RAG와 GPT-4-RAG가 있습니다. 컴파일 문제에서는 비슷한 수행 능력을 보였지만, 다른 *-RAG 모델은 성능이 좋지 않았습니다. Claude-Opus-RAG의 하위 모델은 (GPT-4o-RAG와 비교했을 때) 점수가 높은 것은 다음과 같은 이유 때문일 수 있습니다. 제공된 지침을 따르지 않았습니. 해당 메시지는 구체적으로 다음과 같습니다. 심표로 구분된 규칙 목록을 요청했으며, 다른 단어는 사용하지 않았습니다. 응답. Claude-Opus-RAG에는 각각에 다른 단어들이 포함되어 있습니다. 답변은 각각 "관련 규칙은..."으로 시작합니다. 규칙을 심표 대신 공백으로 구분하는 경우가 있습니다. 자동화된 평가가 사용되었으며, 이러한 지침 부족은 다음과 같은 결과를 초래했습니다. 결과적으로 점수가 낮아졌습니. Gemini-1.0-RAG 및 LLaVA-1.5-RAG 또한 GPT-4o-RAG보다 낮은 점수(각각 0.283 및 0.281)를 기록했습니다. 6/30(Gemini-1.0-RAG) 및 5/30에 대한 모델의 답변은 다음과 같습니다. (LLaVA-1.5-RAG) 질문 중 0점(중복 없음)을 받은 질문이 있었습니다. (실제 규칙 목록 포함). 이와 대조적으로 GPT-4o-RAG는 다음과 같은 특징을 가졌습니다. 30개 문항 중 단 한 문항에서만 0점을 받았습니다.

규칙 이해: 정의. 테스트된 모델 중 GPT-4o-AllRules가 정의 하위 집합에서 가장 우수한 성능을 보였습니다. 벤치마크. 정의 관련 질문에서 차이가 가장 작았습니다. 최고 성능을 보이는 모델 점수와 단순 무작위 점수 사이의 차이 벤치마크의 하위 집합의 기준 점수는 그들이 이 질문들은 MLLM들이 답변하기 어려운 질문들입니다. GPT-4o-AllRules가 정의 질문에서 상대적으로 낮은 점수를 받은 데에는 다음과 같은 요인들이 작용했습니다. 시각적 구성 요소 인식 오류. 예를 들어, 표시될 때 스티어링 휠, 스티어링 칼럼이 포함된 독립적인 이미지 스티어링 랙은 각각 분홍색으로 강조 표시되어 있습니다. GPT-4o-AllRules 강조된 것처럼 "조향"과 관련된 내용은 전혀 언급하지 않았습니다. 문제의 구성 요소를 묻는 대신 "충격 흡수 장치"라고 답했습니다. 두 번, 그리고 "프론트 후프"는 한 번입니다. 이 구성 요소들은 매우 다릅니다.

표 3. GuaranteedRAG 실험 결과. 주어진 조건에서 LLaVA-1.5의 벤치마크 성능을 비교했습니다. FSAE 규칙 문서 섹션은 간단한 LlamaIndex RAG를 통해, 그리고 GuranteedRAG가 제공될 때 확인할 수 있습니다.

부분집합 (미터법)	모델	
	LLaVA-1.5-RAG	LLaVA-1.5-보장된RAG
규칙 추출		
검색 (F1 BoW ↑)	0.112	0.699 ± 0.00590
컴파일 (F1 규칙 ↑)	0.281	0.357 ± 0.0205
규칙 이해		
정의 (F1 BoC ↑)	0.393	0.471 ± 0.0255
존재감 (ACC ↑)	0.484	0.543 ± 0.0353
규칙 준수		
차원 (ACC ↑)	0.408	0.482 ± 0.0473
(블루/루즈/유사성 ↑)	0.097/0.241/0.578	0.121 ± 0.008/0.266 ± 0.0105/0.652 ± 0.0158
기능적 성능 (ACC ↑)	0.536	0.375 ± 0.159
(블루/루즈/유사성 ↑)	0.163/0.321/0.650	0.152 ± 0.0165/0.316 ± 0.0269/0.650 ± 0.0154

차량의 일부 부품을 조항 시스템에서 분리합니다. 따라서 시각적인
특히 다음과 같은 경우에 있어서 구성 요소 인식 기능
기술적 구성 요소는 MLLM을 위해 개선되어야 합니다.
구성 요소에 대한 이해도가 높으면 MLLM은 답변하기 어려울 것입니다.
해당 구성 요소와 관련된 규칙 준수 관련 질문입니다.

규칙 이해: 존재 여부. GPT-4o-AllRules 실행됨
테스트된 모델 중 존재 여부 질문에서 가장 좋은 결과(정확도 0.726)를 보였습니다. *-RAG
모델들은 모두 평균 정확도가 더 낮았습니다.
아마도 이러한 모델들이 제한된 (15개 이하) 데이터에만 접근할 수 있었기 때문일 것입니다.
해당 구성요소를 참조하는 규칙 문서 페이지.
특히 Claude-Opus-RAG와 LLaVA-1.5-RAG는 각각 단순 기준선과 동등하거나 더 나은
성능을 보였습니다. 28/30의 경우
클로드-오푸스-RAG는 제시된 질문들에 대해 "아니오"라고 답했습니다.
질문은 아마도 신중한 입장을 반영하는 것일 수 있습니다. 왜냐하면 절반만이
질문에는 정답이 '아니오'였는데, 일관되게 '아니오'라고 답하는 것은 무작위로 찍는 것과 마
찬가지입니다(순진한 사람).
기준선). LLaVA-1.5-RAG는 예/아니오에서 뚜렷한 경향을 보이지 않았습니
다. 예측은 했지만 무작위 선택보다는 성능이 떨어졌다.

규칙 준수: 차원. 테스트된 모델 중 GPT-4o-AllRules가 차원에 대한 정확도 측면에서
가장 우수한 성능을 보였습니다.
질문들입니다. 0.825의 정확도 점수로 우수한 성능을 보입니다.
GPT-4o-AllRules가 답변하는 데 어려움을 겪었던 부분을 더 자세히 살펴보았습니다.
기본 차원 질문 (추가적인 맥락 없음, 3.1.4절 참조)을 통해 고장 모드에 대한 통찰력을 얻습
니다. 다음 다섯 가지 질문에 대해
GPT-4o-AllRules는 잘못된 답변을 했으며, 눈금 막대를 사용하여 정확한 치수를 계산하
는 데 어려움을 겪었습니다. 모델의 척도 이해도
막대 그래프와 직접 치수가 표시된 엔지니어링 도면을 비교 분석합니다.
섹션 5에서 더 자세히 살펴보겠습니다. GPT-4o-AllRules에서 제기된 두 가지 질문은 다음과 같습니다.
잘못된 답변에는 표시된 엔지니어링 도면이 포함되었습니다.
2차원; 질문에 대한 정답은 다음을 요구했습니다.
이 모델은 두 차원의 합 또는 차이를 구합니다.
해당 모델은 단 하나의 결과만 얻었기 때문에 이러한 질문에서 어려움을 겪었습니다.
두 차원 모두를 폐기하는 대신, 차원을 해답으로 삼는 것이 더 적절합니다.
그것들을 조합하여 답을 구했습니다. GPT-4o-AllRules는 다른 두 문제에서도 잘못된 답을
내렸는데, 어떤 문제인지 잘못 식별했습니다.
차량 부품의 치수는 엔지니어링 도면에 명시되어 있었습니다. 또한 모델이 추출되는 사례도
관찰했습니다.
설계 도면 이미지의 잘못된 숫자(9 대신)
0.9의 값)과 모델이 잘못된 규칙을 참조하는 사례
규칙 문서에서 발췌했습니다. 이러한 결과는 MLLM이 여전히
시각적인 능력과 같은 기술적인 면에서 개선의 여지가 있습니다.
구성 요소 인식, OCR 및 차원 계산 – 즉
엔지니어링 도면과 관련된 질문에 답하려면 필요합니다.
테스트된 모델 중 GPT-4o-AllRules는 차원 설명에 대한 유사성 점수가 가장 높았으며,
이는 최고의 결과와 일치합니다.

수행자의 정확도 점수는 높지만, 최고의 수행자는 아닙니다.
Gemini-1.0-RAG는 BLEU 및 ROUGE 지표에서 다음과 같은 결과를 보였습니다.
더 높은 점수(ROUGE의 경우 동점)를 받았습니다. 우리는 다음과 같은 사실을 관찰했습니다.
MLLM의 설명 중 상당수는 기존 설명보다 훨씬 더 길다.
우리가 수집한 참고 설명(그림 3 참조). 우리는 다음과 같이 추측합니다.
Gemini-1.0-RAG는 BLEU 및 ROUGE 지표에서 높은 점수를 받았습니다.
그 이유는 설명이 더 짧고, 사람이 작성한 참고 설명과 길이가 더 비슷했기 때문입니다.

따라서 설명의 정확성을 파악하는 것은 어려운 일입니다.
BLEU 및 ROUGE 점수를 통해, 해석 가능성
더 많은 인간의 참조 설명을 확보함으로써 이러한 점수를 향상시킬 수 있으며, 이를 통해 울
바르다고 간주될 수 있는 가능한 설명의 분포를 더 잘 포착할 수 있을 것입니다.

규칙 준수: 기능 성능. GPT-4o-AllRules
벤치마크의 이 하위 집합에서 다시 한번 최고의 성능을 보여주었습니다.
테스트된 모델 중 가장 높은 정확도를 보였으며, 16개 질문 중 단 하나만 틀렸습니다.

모델이 잘못 답변했습니다. 이는 의인화된 데이터와 관련이 있습니다.
인간의 신체 치수(키, 몸무게 등)에 필요한 조건을 보여주는 차트
차량용 차트와 사람 크기를 보여주는 또 다른 차트가 있습니다.
제작된 차량은 실제로 수용할 수 있습니다. 이 모델은 단지 비교만 할 뿐입니다.
차량이
차량의 실제 용량에 대한 중량 항목이 요구 사항의 해당 중량 항목을 위반하는 경우, 규정을
준수하는 것으로 간주됩니다.
차트.

*-RAG 모델들을 비교할 때, GPT-4o-RAG가 다른 벤치마크 하위 집합에서 가
장 우수한 결과를 보이는 것과는 달리, 다음과 같은 차이점을 발견했습니다.
최고의 성능을 보여주는 Claude-Opus-RAG는 기능성 분야에서 최고의 성능을 발휘합니다.
성능 정확도는 0.875점으로 나타났습니다. 이 모델은 또한
이는 GPT-4o-AllRules의 설명 유사성 부분 최고 점수와 동률을 이루며, 이러한 질문에 대
한 뛰어난 이해도를 더욱 강조합니다.
벤치마크의 하위 집합은 상당한 기술 전문 지식을 필요로 했습니다.
이는 클로드-오푸스가 테스트된 MLLM 중에서 공학적 배경이 가장 뛰어난 사
람 중 하나임을 시사하는 것일 수도 있습니다. 흥미로운 점이 될 것입니다.
Claude-Opus-AllRules와 GPT-4o-AllRules를 테스트하고 비교하기 위해,
하지만 Claude-Opus-AllRules를 실행하는 데 드는 비용 제약을 고려하면
앞서 언급했듯이, 이는 향후 연구 과제로 남겨두겠습니다.

5. 토론

(이 글을 쓰는 시점에서) 다양한 최첨단 모델을 테스트한 결과
DesignQA에서는 어떤 요소들이 영향을 미치는지에 대한 질문들을 개발했습니다.
벤치마크에서 모델의 점수. 예를 들어, 어느 정도까지.
DesignQA에서 모델의 점수는 RAG 시스템의 영향을 받습니다.
사용되는 방식은 무엇인가요? 구성 요소가 언급되는 방식은 어떻게 되나요?
규칙 문서의 내용은 모델이 질문에 답하는 능력에 영향을 미칩니다.

표 4. 차량-구성 요소-언급별로 분류한 규칙 이해 질문에 대한 MLLM의 성능 분석
유형. Def는 규칙 문서 내에서 명시적으로 정의된 정의 구성 요소를 나타냅니다. MultM은 규칙 문서 내에서 여러 번 나타나지만 명시적으로 정의되지 않은 다중 언급 구성 요소를 나타냅니다. NoM은 언급 없음(no-mention)을 나타냅니다.
규칙 문서에 그대로 나타나지 않는 구성 요소들입니다. 모든 모델이 가장 높은 점수를 받는 경향이 나타납니다.
정의 하위 집합 내의 정의 구성 요소 질문에서 가장 높은 점수를 받았으며, 모든 모델은 존재 하위 집합 내의 다중 언급 구성 요소 질문에서 가장 높은 점수를 받았습니다.

부분집합	언급하다 유형	모델						
		GPT-4o- 모든 규칙	GPT-4- 모든 규칙	GPT-4o- 조각	GPT-4- 조각	LLaVA-1.5- 조각	제미니-1.0- 조각	클로드- 작- 조각
정의 (F1 BoC ↑)	정의	0.78	0.74	0.69	0.56	0.50	0.51	0.48
	멀트엠	0.47	0.42	0.47	0.39	0.37	0.48	0.40
	NoM	0.54	0.35	0.54	0.35	0.37	0.48	0.46
있음 (ACC ↑)	정의	0.67	0.58	0.5	0.50	0.42	0.50	0.50
	멀트엠	0.73	0.68	0.78	0.55	0.53	0.63	0.50
	NoM	0.80	0.50	0.70	0.50	0.40	0.30	0.50

해당 구성 요소에 대한 것인가요? 모델이 이러한 질문에 더 잘 답할 수 있을까요?
도면에서 치수가 축적 막대를 통해 표시되는 경우와 도면에 직접 표시되는 경우에 대해 어떻게 생각하시나요?
추가적인 이미지와 텍스트 맥락은 모델이 질문에 답하는 데 도움이 됩니다.
규칙 준수에 관한 것인가요? 이 섹션에서는 이러한 질문들을 살펴봅니다.
그리고 우리는 모델 개발 방법에 대한 일반적인 제안을 제시합니다.
제시된 질문에 답하기에 더 적합한 것을
디자인QA.

RAG 시스템이 모델의 설계QA 점수에 미치는 영향
본 연구의 핵심은 MLLM을 평가하기 위한 벤치마크를 개발하는 것이었습니다.
기술 문서에 대한 이해를 바탕으로 벤치마크를 활용하여 작성 시점의 최첨단 모델의 강점과 약점
을 설명하는 데 시간을 투자하지 않았습니다. 따라서 우리는 기술 문서에 대한 이해와 벤치마크
를 활용하여 최첨단 모델의 강점과 약점을 파악하는 데 시간을 투자하지 않았습니다.
DesignQA에 특화된 RAG 솔루션의 튜닝 또는 개발; 유용한 RAG 방법론 개발은 하나의 과
학 분야입니다.
그 자체로. [44] 그러나 이전 절에서 우리가 발견한 것 중 하나는
*-RAG 모델에 사용되는 간단한 LlamaIndex RAG가 MLLM에 유용한 컨텍스트를 제공하
지 못하는 경우가 많았다는 것이 문제였습니다.
FSAE 규정 문서.

RAG의 효과와 모델 자체의 성능을 구분하기 위해, 각 질문에 대해 GuaranteedRAG를
생성했습니다.
벤치마크. 키워드 매칭을 사용하는 일련의 스크립트를 통해 생성된 GuaranteedRAG는 당연
한 질문과 관련된 맥락 정보를 포함하고 있음을 보장합니다. 예를 들어, 다음의 경우

검색 질문에서 GuaranteedRAG 컨텍스트는 문제의 규칙을 포함하도록 설계되었습니다.
GuaranteedRAG 구현에 대한 자세한 내용은 부록 B에서 확인할 수 있습니다.

폐쇄형 소스 모델을 실행하는 데 드는 비용은 다음과 같습니다.
오픈소스 모델인 LLaVA-1.5에 GuaranteedRAG를 적용했습니다(LLaVA-1.5-
GuaranteedRAG). 무작위성을 고려하기 위해 GuaranteedRAG를 다섯 번 생성했습니다
(부록 B 참조).
저희는 LLaVA-1.5를 이 다섯 가지 GuaranteedRAG 각각에 대해 테스트했습니다.
5개 GuaranteedRAG에 걸쳐 평균과 표준 편차를 보고합니다.

이 실험의 결과는 표 3에서 확인할 수 있습니다.
우리는 LLaVA-1.5의 점수가 크게 향상될 것으로 예상했습니다.
단순 RAG 대신 GuaranteedRAG를 사용한 LLaVA-1.5-GuaranteedRAG 테스트 - 벤치
마크의 대부분 하위 집합에서 -
LLaVA-1.5-RAG보다 성능이 약간 더 우수할 뿐입니다. 테스트된 다른 모든 모델과 비교했을
때(표 2), LLaVA-1.5-
GuaranteedRAG는 어떤 하위 집합에서도 최고의 성능을 보여주지 않습니다.
벤치마크. 이 결과는 DesignQA의 많은 부분이 벤치마크라는 점을 강조합니다.
적어도 LLaVA-1.5의 경우, 점수는 본질적인 결과입니다.
RAG의 효율성보다는 모델의 역량(및 그 부족함)에 초점을 맞추었습니다.

LLaVA-1.5-RAG와 점수 간의 가장 큰 향상은 다음과 같습니다.
LLaVA-1.5-GuaranteedRAG는 검색 질문(0.112)에 사용됩니다.
(0.699 F1 BoW 대비). 유용한 규칙 문서 맥락을 고려하면,
검색 질문은 간단해집니다. 그러나 8716자 이내의 문자 그대로의 규칙을 다시 받았음에도 불
구하고

텍스트 스니펫(전체 규칙 문서의 약 3%)에 대해 LLaVA-1.5-GuaranteedRAG는 검색 질문
에 대한 해당 규칙을 안정적으로 반환하는 데 여전히 어려움을 겪고 있습니다.

검색 문제에서는 여전히 최고의 성능을 보이는 GPT-4o-AllRules보다 성능이 떨어지는
데, GPT-4o-AllRules는 관련 규칙을 찾아야 하기 때문입니다.
훨씬 더 길고 완전한 규칙 텍스트에서. 이 발견은 다음을 보여줍니다.
LLaVA-1.5는 GPT-4o에 비해 추출 능력이 떨어집니다.
본문에서 관련 정보를 추출합니다.
관련 컨텍스트를 수신하는 것은 LLaVA-1.5의 성능 향상에 도움이 됩니다.
전체적으로 DesignQA가 더 낫다는 점을 이 실험은 강조합니다.
고품질 RAG가 벤치마크에서 MLLM 점수를 향상시키는 데 가장 중요한 요소가 아닐 수도 있
습니다. LLaVA-1.5는 다음을 필요로 할 것입니다.
이미지 분석, 엔지니어링 지식, 관련 정보 추출 등 모델의 고유 기능이 크게 향상되었습니다.

텍스트의 일부를 수정하여 DesignQA 점수를 더욱 향상시키겠습니다.
저희는 GuaranteedRAG가 텍스트의 격리를 돕는 데 도움이 되기를 바랍니다.
RAG 구현 테스트에서 얻은 내재적 모델 기술 -
연구자들이 진단을 내릴 때 유용한 도구 역할을 할 수 있습니다.
기초 모델을 개선합니다.

차량 부품 언급 유형이 규칙에 미치는 영향
이해도 점수
우리는 그 방식과
규칙 문서에서 차량 구성 요소가 언급되는 횟수는 해당 구성 요소에 대한 질문에 답하는 모델
의 능력에 영향을 미칩니다. 규칙 이해도 질문의 경우, 각 질문에서 문제의 구성 요소는 규칙 문
서에서 언급된 방식(정의-구성 요소, 다중 언급)을 기준으로 추적되었습니다.

구성 요소 또는 언급되지 않은 구성 요소)는 이전에 설명한 바와 같습니다.
섹션 3.1.3. 표 4는 각 모델의 규칙에 대한 점수를 자세히 보여줍니다.
이해력 질문 (정의 및 존재 여부 질문 모두 포함)
세 가지 서로 다른 구성 요소 언급 유형에 따라.
명확한 경향이 있습니다. 정의 문제의 경우,
모델에게 이미지에서 강조 표시된 차량 부품의 이름을 식별하도록 요청하면, 각 모델은 항상
가장 높은 점수를 받습니다.
정의 구성 요소. 정의 문제의 경우, 다음 사항을 기억하세요.
*-RAG 모델은 규칙 문서로부터 어떠한 컨텍스트도 받지 못했는데, 이는 구현된 간단한 RAG
가 항상 다음을 반환했기 때문입니다.
규칙 문서의 동일한 섹션(프롭र्ट 텍스트와 동일)
각 정의 질문에 대해 동일합니다.) 모델의 더 높은 점수
정의 하위 집합 내의 정의 구성 요소 질문에 대한 답변은 모델이 이미 확인했다는 사실로 설명
될 수 있습니다.
강조 표시된 정의 구성 요소의 유사한 이미지
사전 학습. 예를 들어, 메인 후프와 프론트 후프와 같은 차량 구성 요소의 위치를 강조하는 이
미지가 온라인에 있습니다.
정의 구성 요소는 다소 구체적인 용어이기 때문에
Formula SAE 대화는 온라인에서 주로 관심을 끄는 종목입니다.
Formula SAE 규정을 설명하는 콘텐츠 및 시각 자료.
존재 여부 질문의 경우, 모델에게 식별을 요청하는 질문입니다.
(예/아니오) 지정된 구성 요소가 이미지에 있는지 여부

표 5. 도면에서 사용되는 차수 기입 시스템이 차수 품질 보증(Dictionary QA)의 모델 정확도에 미치는 영향. 테스트된 MLLM이 일반적으로 엔지니어링 도면에 관한 질문에 더 잘 답변할 수 있다는 사실을 강조합니다. 눈금 막대가 있는 차수표보다는 직접 차수를 사용하는 것이 좋습니다. 다만 Gemini-1.0-RAG는 예외적으로 더 나은 성능을 보여줍니다. 축척 막대가 표시된 차수 도면.

ACC 제공 차원 체계	모델						
	GPT-4o- 모든 규칙	GPT-4- 모든 규칙	GPT-4o- 조각	GPT-4- 조각	LLaVA-1.5- 조각	제미니-1.0- 조각	클로드- 작- 조각
직접	0.79	0.66	0.66	0.45	0.41	0.51	0.54
눈금 막대	0.75	0.28	0.70	0	0.40	0.55	0.45

- 모델들은 서로 다른 경향을 보입니다. 거의 모든 모델이 점수를 받았습니다.

다중 언급 요소에서 가장 높은 점수를 받았습니다(GPT-4o-AllRules 및 Claude-Opus-RAG는 모든 요소에서 동일한 점수를 받았습니다).

구성 요소 유형). 이러한 질문은 모델의 관점을 보여줍니다.

차량 - 확대 보기 - 유사 이미지가 없는 경우

온라인 환경이기 때문에, 모델들은 시각적으로 식별하는 데 가장 적합합니다.

여러 번 언급되는 구성 요소는 일반적으로 차량에서 더 흔히 볼 수 있는 경향이 있습니다.

(페달 어셈블리, 브레이크 시스템, 로커 암과 같은) 용어들.

이러한 관찰된 패턴의 구체적인 이유와 관계없이,

표 4에 제시된 결과는 다음과 같은 경향이 있음을 보여줍니다.

규칙 문서 및 모델에서 구성 요소 언급 유형과 함께

규칙 이해 문제 점수가 궁금하네요. 흥미로운 것 같아요.

향후 연구에서 이러한 경향을 더 자세히 살펴볼 것입니다.

공학 도면 차수 기입 시스템이 미치는 영향

모델의 디자인QA 점수

섹션 3.1.2에서 설명했듯이, Dimension QA를 구성하는 질문의 3분의 1은 엔지니어링 설계에 스케일바를 사용했습니다.

도면을 사용했고, 나머지 3분의 2는 직접 차수를 사용했습니다.

우리는 이 두 가지 다른 차원 설정이 어떤 영향을 미칠지 궁금했습니다.

시스템은 모델 성능에 영향을 미쳤습니다. 표 5에서 볼 수 있듯이 대부분의 시스템은 모델 성능에 영향을 미쳤습니다.

모델은 직접 차수가 기입된 도면에서보다 간접 차수 도면에서 더 나은 성능을 보였습니다.

축척 도면. 모형들은 축척을 맞추는 데 어려움을 겪는 것 같았다.

눈금 막대. 예를 들어, GPT-4는 설명에서 "추정치" 차수를 나타내기 위해 눈금 막대를 사용하고 있다고 언급한 적이 있습니다.

정확한 차수 측정보다는 다른 방식으로 표현했으며, 경우에 따라서는 "이미지 처리 기능에는 차수 측정 기능이 포함되지 않는다"고 설명했습니다. GPT-4는 이미지 측정의 어려움이 개선된 것으로 보였습니다.

최신 버전인 GPT-4o, 즉 GPT-4o-RAG에서는 실제로 그렇습니다.

눈금 막대가 표시된 이미지에서 더 높은 정확도 점수를 얻었습니다.

직접 측정된 이미지보다 더 나은 결과를 보였습니다. Gemini-1.0-RAG 또한 마찬가지였습니다.

이는 이상치였는데, 스케일바 차수에서 더 나은 성능을 보였기 때문입니다.

직접적인 차원의 질문보다 더 많은 질문을 던집니다. 그 능력은

척도 막대 관련 질문 중 일부에 정답을 맞춘 것이 기여했을 가능성이 높습니다.

테스트된 *-RAG 모델 중 두 번째로 우수한 성능을 보였다는 사실에 주목해야 합니다.

다. 향후 연구 및 모델 개발에서는 다음 사항을 우선적으로 고려해야 합니다.

이 기능은 모델이 정확하게 해석하고 적용할 수 있도록 보장합니다.

다양한 엔지니어링 작업 전반에 걸친 차원 데이터. 이 글에서는 이러한 측면에 초점을 맞출 것입니다.

복잡한 환경에서 MLLM의 정확성과 적용성을 향상시킵니다.

실제 엔지니어링 환경.

추가 컨텍스트가 모델의 차원 부분집합에 미치는 영향

점수

섹션 3.1.4에서 설명했듯이, 차원 관련 질문의 절반에는 이해를 돕기 위해 추가적인 맥락 정보가 제공되었습니다.

절반은 질문에 답했지만 나머지 절반은 답하지 않았습니다.

추가적인 맥락 정보는 다중 시점 CAD 이미지에서 차량 구성 요소와 관련된 강조 표시 형태로 제공되었습니다.

문제의 규칙과 그에 해당하는 프롬프트 텍스트를 통해 드러난 내용

강조 표시된 구성 요소의 이름(예: "앞쪽 고리는")

분홍색으로 강조 표시됨). 놀랍게도, 우리는 눈에 띄는 점을 발견하지 못했습니다.

추가 요소를 포함했을 때와 포함하지 않았을 때 모델 성능 추세

컨텍스트. GPT-4o-AllRules, GPT-4-AllRules 및 LLaVA-1.5-RAG

추가적인 컨텍스트가 있을 때 성능이 더 떨어졌으며, GPT-4o-AllRules는 그보다 성능이 떨어졌습니다.

GPT-4-RAG, Gemini-1.0-RAG 및 Claude-Opus-RAG가 수행했습니다.

더 나아졌습니다. 추가적인 맥락의 효과에 대한 추가 조사가 필요합니다.

필요합니다.

향후 연구 과제: 본 벤치마크에 적합한 모델에 대한 권장 사항 제시

지금까지 제시된 결과에서 우리는 다음과 같은 사실을 입증했습니다.

이 글을 쓰는 시점에서 최첨단 모델은 다음과 같은 성능을 보입니다.

우리의 기준점입니다. 여기서는 한 가지가 어떻게 작용하는지에 대한 몇 가지 관찰 결과를 제시합니다.

성능 향상을 위해 이러한 모델을 수정할 수 있습니다.

우리의 기준점입니다.

첫째, DesignQA에서 더 높은 점수를 얻으려면 MLLM 모델의 고유한 기능을 향상시켜야 합니다. 우리가 테스트한 모델들은 다음과 같습니다.

*-AllRules 및 *-GuaranteedRAG를 사용하면 다음과 같은 경우에도

관련 규칙 맥락을 고려할 때, MLLM은 다음과 같은 기술을 보류해야 합니다.

기술 문서에 따른 설계 유형의 작업에서 성능을 향상시키기 위해 역량을 강화했습니다. 우리는 이를 관찰했습니다.

테스트된 모델들이 규칙을 안정적으로 참조하는 데 어려움을 겪는다는 점

SAE 공식 규칙 문서. 규칙 추론은 매우 중요한 기술입니다.

모델은 완벽하게 작동해야 합니다. 그렇지 못할 경우 문제가 발생할 수 있습니다.

이는 이후 규칙 준수에 치명적인 결과를 초래할 수 있습니다.

질문. LoRA [45], QLoRA [46]와 같은 미세 조정 방법 또는

InstructLAB [47]은 검색 QA를 사용하는 모델에서 수행될 수 있습니다. 이 프로세스는 MLLM이 더 잘 이해하는 데 도움이 될 수 있습니다.

규칙 문서를 "암기"함으로써 전체 벤치마크에서 성능이 향상됩니다.

미세 조정은 MLLM의 시각적 성능을 향상시키는 데에도 사용될 수 있습니다.

기술적 구성 요소를 인식하고 엔지니어링 도면 분석 능력을 강화하는 데 도움이 됩니다. 그러나 본 연구 맥락에서 미세 조정에는 몇 가지 한계가 있습니다. 특히 방대한 양의 데이터가 필요합니까.

항상 이용 가능한 정보가 아니기 때문에 정확한 기억이 필요한 작업에서 어려움을 겪는 경우가 많고, 설계 문서 작성 시 비효율적이게 됩니다.

자주 업데이트됩니다. 검색 증강 생성이나 최신 모델의 확장된 컨텍스트 창을 활용하는 등의 접근 방식이 사용됩니다.

설계 요구사항 작업의 필요성에 더 잘 부합하도록 조정합니다.

미세 조정과 관련된 제약 조건.

둘째, RAG 모델을 개선하는 것이 매우 중요합니다. 그라야만 규칙 문서의 관련 부분에 접근할 수 있기 때문입니다. 우리는 다음과 같은 점을 확인했습니다.

모든 맥락을 고려했을 때, GPT-4o-AllRules와 GPT-4-AllRules는 거의 항상 각각의 RAG 모델보다 더 나은 성능을 보였습니다.

선택된 규칙 문서 페이지가 간단한 방식으로 제공되었습니다.

검색. 이러한 결과가 다음을 보여준다고 주장할 수도 있지만

더 긴 컨텍스트 길이를 가진 모델을 개발하고 사용해야 합니다.

컨텍스트 입력값이 더 긴 모델을 사용하는 것이 중요하다는 점에 유의해야 합니다.

현재(글을 쓰는 시점 기준) 가격이 상당히 더 비쌉니다. 비용은 다음과 같습니다.

각 질문에 대한 맥락에 맞춰 전체 규칙 문서를 제공하기 위해

관련 페이지를 선택하는 데 드는 비용보다 10배 이상 비쌌습니다.

RAG. 따라서 효과적인 RAG는 계산량을 줄이는 데 도움이 될 수 있습니다.

부담을 줄이고 관련 사항에 대해 사용자에게 유용한 맥락을 제공합니다.

원본 문서의 섹션.

GuarnateedRAG와 결합된 MLLM은 단순 RAG와 결합된 MLLM보다 개선된 결과를 보였지만, GuarnateedRAG는

De-signQA의 질문들을 위해 키워드 매칭 스크립트를 사용하여 맞춤 개발된 이 솔루션은 일관화할 수 없습니다.

다른 종류의 설계 요구사항 관련 질문에 대해서도 마찬가지입니다. 멀티모달

RAG는 VQA의 이미지가 관련 부분을 선택하는 데 도움이 될 수 있으므로 탐구해 볼 만한 흥미로운 분야일 수 있습니다.

규칙 문서. RAG도 개선될 여지가 있을 수 있습니다.

다양한 청킹 방법을 실험해 보았습니다. 그럼에도 불구하고,

모델이 더 저렴해지고, 계산 효율성이 높아짐에 따라 더 큰 컨텍스트 창으로 학습된 경우, RAG 접근 방식은 유용성이 떨어질 수 있습니다.

실용적인 응용 분야에 본질적으로 기반을 둔 엔지니어링 설계는 기술 문서에 대한 깊은 이해를 필요로 합니다. 디자인이 엄격한 기준을 충족할 뿐만 아니라 준수하도록 보장하기 위해 요구사항 및 표준, 새롭게 떠오르는 중요한 통찰력 중 하나는 바로 이것입니다. 벤치마크 평가를 통해 얻은 결론은 현대 AI가 모델은 엔지니어링 문서를 진정으로 이해하는 데 있어 아직 초기 단계에 있습니다. 이러한 한계는 중요한 격차를 드러냅니다. 완전 자동화된 설계 프로세스로 가는 길입니다. 따라서 MLLM 모델을 개선하기 위해 앞으로 상당한 노력이 필요합니다. 엔지니어링 설계 및 설계 요구사항 문제를 해결하는 능력.

제한 사항 이 벤치마크는 모델이 설계 요구사항 문서를 해석하고 이해하는 능력을 공식적으로 평가하는 첫걸음을 제시하지만, DesignQA는 단 하나의 규칙에만 초점을 맞춥니다.

해당 문서는 DesignQA에서 어떤 결과가 나올지는 알려지지 않았습니 다. 데이터셋 구성에 다른 기술 문서를 사용했는지 여부에 따라 결과가 달라질 수 있습니다. 하지만 벤치마크 개발 비용(전문가의 수동 QA 생성 및 검증 필요)으로 인해 데이터셋 규모나 기술 문서 수를 늘리는 데 제약이 있습니다.

참조되었습니다. 또한 저희 벤치마크는 설계 요구사항 기반 작업 유형 6가지로 제한되어 있지만, 물론 다른 유형도 존재합니다. 탐구해 볼 가치가 있습니다. 하지만 저희는 여섯 가지 하위 집합이 다음과 같다고 생각합니다. 벤치마크는 엔지니어들이 주로 사용하는 방식을 반영합니다. 설계 요구사항 문서를 참조하십시오. 또한 우리는 본질적으로 프롬프트 형식과 CAD/엔지니어링 도면에 대한 선택을 했습니다. 벤치마크 구축에 있어 이미지 프레젠테이션. DesignQA 결과 질문이나 이미지가 약간씩 변형된 유사한 질문에는 결과가 일반화되지 않을 수 있습니다. 다른 질문과 이미지의 효과를 탐구해 볼 필요가 있습니다. DesignQA에서 모델 점수에 대한 형식은 주제가 될 수 있습니다. 향후 연구. 전반적으로 일반화 가능성(다른 유사한 질문에 대한 일반화 가능성). 테스트 데이터 세트에 포함되지 않은 경우(테스트 데이터 세트에 포함되지 않음)는 일반적인 한계점입니다. LLM 벤치마크 [48]. 일반화 가능성이 한계일 수 있지만, DesignQA는 MLLM이 답변할 수 있는 능력을 추적하려는 시도입니다. 설계 요구사항에 관한 질문입니다.

DesignQA의 유효성 측면에서 자동 평가는 우리가 사용한 지표는 한계점으로 볼 수 있습니다. 여기서 모델 응답은 자동 평가 지표에 대한 점수를 나타냅니다. 사람이 동일한 응답에 부여하는 타당도와 일치하지 않을 수 있습니다. 예를 들어, 모델이 다음 규칙을 따르지 않는 경우가 있습니다. 지정된 응답 형식(예: 컴파일 질문 규칙을 심표로 구분하지 않음)은 인위적으로 낮은 점수를 초래할 수 있습니다. 해당 지표를 기반으로 한 모델이 있었습니다. 검색과 관련해서도 비슷한 사례들이 있었습니다. 모델이 하위 규칙을 포함하는 규칙을 반환한 질문입니다. (엄밀히 말하면 틀린 것은 아니지만) 우리의 정답 참조에는 하위 규칙이 포함되지 않았습니 다. 의미적 동등성 평가 이는 어려운 문제이며, BLEU 및 ROUGE 점수가 사용됩니다. 모델 설명을 평가하는 데에는 알려진 한계가 있습니다. 수집 시간이 더 많이 소요되더라도, 사람이 직접 작성한 참조 설명을 더 많이 확보하면 모델 설명에 대한 보다 정확한 점수 매기기가 가능해질 것입니다. 자동화된 평가 지표가 모델에 다소 인위적인 불이익을 줄 수 있지만, 대안인 수동 채점 방식은 이러한 문제를 방지할 수 있습니다. 수천 개의 질문에 대응해야 하므로 엄청난 자원 소모가 예상됩니다. 또한 많은 편견을 가지고 있습니다. 사실 자동 평가는 필수적입니다. 커뮤니티에서 사용할 목적으로 만들어진 벤치마크 데이터셋의 경우 향후 개발될 모델들을 지속적으로 테스트하기 위해. DesignQA의 또 다른 한계점은 특정 벤치마크 하위 집합의 크기가 작다는 점으로, 이는 벤치마크 유효성에 영향을 미칠 수 있습니다. 검색 관련 질문은 천 개가 넘습니다. 왜냐하면 그럴 수 있기 때문입니다. 자동으로 생성되었지만, 나머지 하위 집합들은 수동으로 생성하고 철저히 검토해야 했기 때문에 크기가 더 작습니다. 크기 면에서 그렇습니다. 특히, 기능 성능 관련 질문은 다음과 같습니다. 차량 테스트 데이터 확보의 어려움 때문에 16개의 QA를 보유하고 있습니다. 그것은 요구사항 문서와 직접적으로 관련이 있었습니다. 벤치마크 하위 집합 중 일부는 규모가 작을 수 있으므로, 다른 대안보다 전문가가 직접 수행하는 고품질의 수동 QA 생성 및 검증을 우선시했습니다. 합성 데이터 생성이나 클라우드소싱과 같은 방법들은

데이터셋 품질이 저하될 수 있습니다.

6. 결론

본 연구는 새로운 MLLM 벤치마크인 DesignQA를 소개합니다. MIT 모터스포츠 데이터와 FSAE 경기 규칙 문서를 기반으로 한 1451개의 질문과 답변으로 구성된 벤치마크입니다. 이 연구는 대규모 언어 모델의 답변 능력을 평가하기 위해 설계되었습니다. 기술 요구사항에 따른 설계 관련 질문입니다. 벤치마크는 검색, 컴파일, 정의, 존재, 차원 및 기능적 성능 - 기술 사양에 따라 설계할 때 엔지니어가 수행하는 작업을 대표합니다. 벤치마크의 각 하위 집합 자체적인 자동 평가 지표를 가지고 있으므로 새로운 MLLM은 원활하게 테스트될 수 있도록 설계되었습니다. 벤치마크의 문제는 다음과 같이 설계되었습니다. 인간에 의해 - MIT 모터스포츠 회원, 업계 전문가, 연구원들과 협력하여 고품질 벤치마크를 보장합니다. 기존의 많은 MLLM 벤치마크와 달리 DesignQA는 다음과 같은 특징을 가지고 있습니다. 문서 기반 VQA는 입력 이미지와 문서가 서로 다른 출처에서 제공되는 것으로, 실제 사나리오에서 흔히 볼 수 있는 특징입니다.

DesignQA를 사용하여 (본문 작성 시점을 기준으로) 여러 최첨단 MLLM 변형에 대한 엄격한 평가를 수행했습니다. GPT-4o, GPT-4, Claude-Opus, Gemini-1.0 및 LLaVA-1.5. GPT-4o는 MLLM 모델 중 가장 우수한 성능을 보였습니다. 테스트를 통해 MLLM의 현재 기술에 상당한 한계가 있음을 발견했습니다. 복잡한 기술 문서를 정확하게 해석하는 능력, 특히 관련 요구사항을 참조하고 분석할 때 기술 이미지. 이러한 결과는 분석과 기술 문서에 따라 설계하려면 다양한 요소가 필요합니다. 기술 역량 측면에서, 그리고 더 적합한 MLLM을 개발할 필요가 있다는 것입니다. 엔지니어링 설계의 다면적인 특성. 본 연구는 이러한 특성을 향상시키기 위해 AI 모델의 발전이 필요함을 강조합니다. 엔지니어링 요구사항 및 문서에 대한 이해, 향후 연구 방향을 제시합니다. 저희 연구는 다음과 같은 목표를 달성하고자 합니다. 인공지능이 엔지니어링 설계 프로세스를 지원하는 능력의 격차 보다 효과적으로, 정교한 AI 기반 엔지니어링 솔루션의 길을 열어줍니다.

감사의 말씀

저자들은 헨리 스미스에게 감사를 표하고 싶습니다. 데이터셋 구축에 중요한 기여를 해주신 MIT 모터스포츠 팀에게 감사드립니다. 생성 및 검증을 통해 품질이 크게 향상되었습니다. 본 연구의 내용은 다음의 지원을 받아 수행되었습니다. 국립과학재단 대학원 연구 펠로우십 연구비 지원 번호 2023345746. 모든 의견, 조사 결과 및 결론 본 자료에 제시된 내용이나 권장 사항은 다음의 의견입니다. 이 글은 저자(들)의 의견이며, 반드시 국립기관의 견해를 반영하는 것은 아닙니다. 과학재단.

명명법

Claude-Opus = 특히 claude-3-opus-20240229 를 지칭합니다. Gemini-1.0 = 특히 다음을 지칭합니다. 모델/제미니-1.0-프로-비전 GPT-4 = gpt-4-1106-vision-preview를 구체적으로 지칭합니다. GPT-4o = gpt-4o를 구체적으로 지칭합니다. FSAE = 포뮬러 SAE LLaVA-1.5 = 특히 llava-1.5-13b 를 지칭합니다. LLM = 대규모 언어 모델 MLLM = 멀티모달 대규모 언어 모델 RAG = 검색 증강 생성 -RAG = LlamaIndex의 간단한 RAG를 사용하여 테스트된 모델 뼈대 VQA = 시각적 질문 답변(벤치마크)

참고 자료

[1] OpenAI. "GPT-4V(ision) 시스템 카드." (2023).

[2] Vaswani, Ashish, Shazeer, Noam, Parmar, Niki, Uszkoreit, Jakob, Jones, Llion, Gomez, Aidan N, Kaiser, ukasz 및 Polosukhin, Illia. "당신이 필요로하는 것은 관심입니다." 신경 정보 처리 시스템의 발전 Vol. 30(2017).

[3] Bubeck, Sébastien, Chandrasekaran, Varun, Eldan, Ronen, Gehrke, Johannes, Horvitz, Eric, Kamar, Ece, Lee, Peter, Lee, Yin Tat, Li, Yuanzhi, Lundberg, Scott 외. "일반 인공지능의 불꽃: GPT-4를 사용한 초기 실험. arXiv." arXiv 사전 인쇄 arXiv:2303.12712 (2023).

[4] Barbhuiya, Rejaul Karim. "인공지능 소개: 교육에 대한 현재 개발, 우려 사항 및 가능성." 인도 교육 기술 저널 Vol. 5 No. 2 (2023): p. 266.

[5] Thirunavukarasu, Arun James, Ting, Darren Shu Jeng, Elangovan, Kabilan, Gutierrez, Laura, Tan, Ting Fang 및 Ting, Daniel Shu Wei. "의학의 대규모 언어 모델." 자연의학 Vol. 29 8호(2023): 1930–1940페이지.

[6] Clusmann, Jan, Kolbinger, Fiona R, Muti, Hannah Sophie, Carrero, Zunamys I, Eckardt, Jan-Niklas, Laleh, Narmin Ghaffari, Löffler, Chiara Maria Lavinia, Schwarzkopf, Sophie-Caroline, Unger, Michaela, Veldhuizen, Gregory P 외. "의학 분야 대규모 언어 모델의 미래 전망." 커뮤니케이션 의학 제3권 제1호(2023): 141쪽.

[7] Kasneci, Enkelejda, Seßler, Kathrin, Küchemann, Stefan, Bannert, Maria, De-mentieva, Daryna, Fischer, Frank, Gasser, Urs, Groh, Georg, Günemann, Stephan, Hüllermeier, Eyke et al. "ChatGPT가 좋은가요? 교육을 위한 대규모 언어 모델의 기회와 과제에 대하여." 학습 및 개인화 Vol. 103 (2023): p. 102274.

[8] Makatura, Liane, Foshey, Michael, Wang, Bohan, Hähnlein, Felix, Ma, Pingchuan, Deng, Bolei, Tjandrasuwita, Megan, Spielberg, Andrew, Owens, Crystal Elaine, Chen, Peter Yichen et al. "대규모 언어 모델은 디자인 및 제조에서 인간에게 어떻게 도움이 될 수 있습니까?" arXiv preprint arXiv:2307.14377 (2023).

[9] Picard, Cyril, Edwards, Kristen M, Doris, Anna C, Man, Brandon, Giannone, Giorgio, Alam, Md Ferdous 및 Ahmed, Faez. "개념에서 제조까지: 엔지니어링 설계를 위한 비전-언어 모델 평가." arXiv preprint arXiv:2311.12668 (2023).

[10] Ulrich, Karl T 및 Eppinger, Steven D. 제품 디자인 및 개발. 맥그로힐(2016).

[11] Zeng, Yan, Zhang, Hanbo, Zheng, Jiani, Xia, Jiangnan, Wei, Guoqiang, Wei, Yang, Zhang, Yuchen 및 Kong, Tao. "다중 모드 입력을 사용하여 GPT4 스타일 언어 모델을 훈련하는 데 무엇이 중요합니까?" arXiv 사전 인쇄 arXiv:2307.02469 (2023).

[12] Wang, Lei, Hu, Yi, He, Jiabang, Xu, Xing, Liu, Ning, Liu, Hui 및 Shen, Heng Tao. "T-SciQ: 과학 질문 답변을 위한 대규모 언어 모델 신호를 통한 다중 모드 사고 연쇄 추론 교육." arXiv 사전 인쇄 arXiv:2305.03453 (2023).

[13] Liu, Haotian, Li, Chunyuan, Wu, Qingyang 및 이용재. "사각적 교육 튜닝." 신경 정보 처리 시스템의 발전 Vol. 36(2024).

[14] Shaham, Uri, Ivgi, Maor, Efrat, Avia, Berant, Jonathan 및 Levy, Omer. "Ze-roSCROLLS: 긴 텍스트 이해를 위한 제로샷 벤치마크." arXiv 사전 인쇄 arXiv:2305.14196 (2023).

[15] Xiong, Wenhan, Liu, Jingyu, Molybog, Igor, Zhang, Hejia, Bhargava, Prajjwal, Hou, Rui, Martin, Louis, Rungta, Rashi, Sankararaman, Karthik Abinav, Oguz, Barlas et al. "가변 모델의 효과적인 장기 컨텍스트 스케일링." arXiv 사전 인쇄 arXiv:2309.16039 (2023).

[16] OpenAI. "GPT-4o 시스템 카드."(2024).

[17] Liu, Haotian, Li, Chunyuan, Wu, Qingyang 및 이용재. "사각적 교육 튜닝." (2023).

[18] Richardson, Matthew, Burges, Christopher JC 및 Renshaw, Erin. "Mctest: 텍스트의 개방형 도메인 기계 이해를 위한 도전 데이터 세트." 자연어 처리의 경험적 방법에 관한 2013년 컨퍼런스 회의록: 193-203쪽. 2013.

[19] Rajpurkar, Pranav, Zhang, Jian, Lopyrev, Konstantin 및 Liang, Percy. "Squad: 텍스트의 기계 이해를 위한 100,000 개 이상의 질문." arXiv 사전 인쇄 arXiv:1606.05250 (2016).

[20] Yang, Yi, Yih, Wen-tau 및 Meek, Christopher. "Wikiqa: 개방형 도메인 질문 답변을 위한 도전 데이터 세트." 자연어 처리의 경험적 방법에 관한 2015년 컨퍼런스 회의록: pp. 2013-2018. 2015.

[21] Dasigi, Pradeep, Lo, Kyle, Beltagy, Iz, Cohan, Arman, Smith, Noah A 및 Gard-ner, Matt. "연구 문제에 기반한 정보 탐색을 위한 도전 데이터 세트." arXiv 사전 인쇄 arXiv:2105.03011 (2021).

[22] Fu, Chaoyou, Chen, Peixian, Shen, Yunhang, Qin, Yulei, Zhang, Mengdan, Lin, Xu, Qiu, Zhenyu, Lin, Wei, Yang, Jinrui, Zheng, Xiawu 외. "MME: 다중 모드 대형 언어 모델에 대한 종합 평가 벤치마크." arXiv 사전 인쇄 arXiv:2306.13394 (2023).

[23] Liu, Yuan, Duan, Haodong, Zhang, Yuanhan, Li, Bo, Zhang, Songyang, Zhao, Wangbo, Yuan, Yike, Wang, Jiaqi, He, Conghui, Liu, Ziwei et al. "음-벤치: 귀화의 다중 모드 모델은 다재다능한 플레이어입니까?" arXiv 사전 인쇄 arXiv:2307.06281 (2023).

[24] Yue, Xiang, Ni, Yunshe, Zhang, Kai, Zheng, Tianyu, Liu, Ruozhi, Zhang, Ge, Stevens, Samuel, Jiang, Dongfu, Ren, Weiming, Sun, Yuxuan 외. "Mmmu: 전문 민첩성을 위한 대규모 다분야 다중 모드 이해 및 추론 벤치마크입니다." arXiv 사전 인쇄 arXiv:2311.16502 (2023).

[25] Lu, Pan, Mishra, Swaroop, Xia, Tanglin, Qiu, Liang, Chang, Kai-Wei, Zhu, Song-Chun, Tafjord, Oyvind, Clark, Peter 및 Kalyan, Ashwin. "설명하는 법 배우기: 과학 질문에 답하기 위한 사고 기술을 통한 다중 모드 추론." 신경 정보 처리 시스템의 발전 Vol. 35(2022): pp. 2507–2521.

[26] Chen, Yang, Hu, Hexiang, Luan, Yi, Sun, Haitian, Changpinyo, Soravit, Ritter, Alan 및 Chang, Ming-Wei. "사전 훈련된 비전 및 언어 모델이 시각적 정보 탐색 질문에 답할 수 있습니까?" arXiv preprint arXiv:2302.11713 (2023).

[27] Song, Binyang, Zhou, Rui 및 Ahmed, Faez. "엔지니어링 설계의 다중 modal 라닝: 검토 및 향후 방향." 엔지니어링 컴퓨팅 및 정보 과학 저널 Vol. 24 No. 1 (2024): p. 010801.

[28] Dima, Alden, Lukens, Sarah, Hodkiewicz, Melinda, Sexton, Thurston 및 Brundage, Michael P. "기술 텍스트에 대한 자연어 처리 적용." 응용 인공지능 레터스 제2권 제3호(2021): p. e33.

[29] Brundage, Michael P, Sexton, Thurston, Hodkiewicz, Melinda, Dima, Alden 및 Lukens, Sarah. "기술 언어 처리: 유지 보수 지식 잠금 해제." Manufacturing Letters Vol. 27(2021): pp. 42–46.

[30] Jiang, Shuo, Hu, Jie, Magee, Christopher L 및 Luo, Jianxi. "기술 문서 분류를 위한 딥러닝." IEEE 엔지니어링 관리 거래 (2022).

[31] Zhu, Qihao 및 Luo, Jianxi. "설계 개념 생성을 위한 생성형 변환기." 공학 컴퓨팅 및 정보 과학 저널 Vol. 23 No. 4 (2023): p. 041003.

[32] Ferrari, Alessio, Spagnolo, Giorgio Oronzo 및 Gnesi, Stefania. "Pure: 공개 요구사항 문서 데이터 세트." 2017 IEEE 제25회 국제 요구사항 엔지니어링 컨퍼런스(RE): 502-505쪽. 2017. IEEE.

[33] Chang, Yupeng, Wang, Xu, Wang, Jindong, Wu, Yuan, Zhu, Kaie, Chen, Hao, Yang, Linyi, Yi, Xiaoyuan, Wang, Cunxiang, Wang, Yidong 외. "대규모 언어모델 평가에 관한 조사." arXiv 사전 인쇄 arXiv:2307.03109 (2023).

[34] Wang, Yizhong, Kordi, Yeganeh, Mishra, Swaroop, Liu, Alisa, Smith, Noah A, Khoshabi, Daniel 및 Hajishirzi, Hannaneh. "자체 교육: 자체 생성된 교육과 언어 모델 훈련." arXiv 사전 인쇄 arXiv:2212.10560 (2022).

[35] de l'Automobile, 2023 Federation Internationale. "2024 Formula 1 Technical Regulations." https://www.fia.com/sites/default/files/fia_2024_formula_1_technical_regulations_-_issue_1_-_2023-04-25.pdf.

[36] Kovich, Christine N. "인간 착륙 시스템(HLS) 프로그램 선외 활동(EVA) 호환성 인터페이스 요구 사항 문서(IRD)." 기술 보고 서 번호 2023.

[37] Papineni, Kishore, Roukos, Salim, Ward, Todd 및 Zhu, Wei-Jing. "Bleu: 기계 번역의 자동 평가 방법." 전산 언어학 협회 제40차 연례 회의 회의록: 311-318쪽. 2002.

[38] Lin, Chin-Yew. "Rouge: 요약의 자동 평가를 위한 패키지." 본문 요약은 74-81쪽에 자세히 다룬다. (2004)

[39] Reimers, Nils 및 Gurevych, Iryna. "Sentence-bert: siamese bert-networks를 사용한 문장 임베딩." arXiv preprint arXiv:1908.10084 (2019).

[40] Zhang, Tianyi, Kishore, Varsha, Wu, Felix, Weinberger, Kilian Q 및 Artzi, Yoav. "Bertscore: bert를 사용한 텍스트 생성 평가." arXiv 사전 인쇄 arXiv:1904.09675 (2019).

[41] Liu, Haotian, Li, Chunyuan, Li, Yuheng 및 Lee, Yong Jae. "사각적 지식 튜닝을 통한 개선된 기준선." arXiv 사전 인쇄 arXiv:2310.03744 (2023).

[42] Lewis, Patrick, Perez, Ethan, Piktus, Aleksandra, Petroni, Fabio, Karpukhin, Vladimir, Goyal, Naman, Küttler, Heinrich, Lewis, Mike, Yih, Wen-tau, Rock-täschel, Tim et al. "지식 집약적 NLP 작업을 위한 검색 증강 생성." 신경 정보 처리 시스템의 발전 Vol. 33 (2020): pp. 9459–9474.

[43] 리우, 제리. "라마인덱스." (2022). 도이: 10.5281/zenodo.1234. URL https://github.com/jerryliu/llama_index.

[44] Li, Huayang, Su, Yixuan, Cai, Deng, Wang, Yan 및 Liu, Lema. "검색증강 텍스트 생성에 관한 조사." arXiv 사전 인쇄 arXiv:2202.01110 (2022).

[45] Hu, Edward J, Shen, Yelong, Wallis, Phillip, Allen-Zhu, Zeyuan, Li, Yuanzhi, Wang, Shean, Wang, Lu 및 Chen, Weizhu. "Lora: 대규모 언어 모델의 낮은 순위 적응." arXiv 사전 인쇄 arXiv:2106.09685 (2021).

[46] Dettmers, Tim, Pagnoni, Artidoro, Holtzman, Ari 및 Zettlemoyer, Luke. "Qlora: 양자화된 llms의 효율적인 미세 조정." 신경 정보 처리 시스템의 발전 제36권(2024).

[47] Sudalairaj, Shivchander, Bhandwaldar, Abhishek, Pareja, Aldo, Xu, Kai, Cox, David D 및 Srivastava, Akash. "Lab: 챗봇을 위한 대규모 정렬." arXiv 사전 인쇄 arXiv:2403.01081 (2024).

[48] McIntosh, Timothy R, Susnjak, Teo, Liu, Tong, Watters, Paul 및 Halgamuge, Malka N. "생성 인공지능 시대의 대규모 언어 모델 벤치마크의 부적절함." arXiv 사전 인쇄 arXiv:2402.09880 (2024).

부록 A: 모델 매개변수

저자들이 평가한 모든 다중 선형 모델(MLLM)은 Lla-maIndex 프레임워크를 통해 실행되었습니다. 각 모델에 대해 Lla-maIndex에 설정된 기본 매개변수를 사용했습니다. LLaVA-1.5의 경우 기본 매개변수는 온도 0.75, top_p 0.9.7입니다. GPT-4o, GPT-4, Gemini-1.0 및 Claude-Opus의 경우 기본 온도 설정은 다음과 같습니다.

```
7https://github.com/run-llama/llama_index/blob/main/llama-index-integrations/multi_modal_llms/llama-index-multi-modal-llms-replicate/llama_index/multi_modal_llms/replicate/base.py
```

LlamaIndex 프레임워크의 버전은 0.1.8입니다. 이 모델들의 경우, LlamaIndex는 top_p에 대한 기본값을 설정하지 않으므로 각 모델은 자체적인 top_p 기본값을 유지해야 합니다. 규칙 추출 질문의 경우, 모든 모델에서 max_new_tokens는 250으로 설정되었습니다. 규칙 이해 질문의 경우, max_new_tokens는 100으로 설정되었습니다. 규칙 준수 질문의 경우, max_new_tokens는 1500으로 설정되었습니다.

부록 B: GuaranteedRAG 검색 질문에 대한

GuaranteedRAG: 각 검색 질문에 대해 전체 규칙서에서 8716자 분량 의 텍스트 일부를 추출했습니다. 이 부분은 문제의 규칙이 포함되도록 특별히 선택되었으며, 추출된 텍스트 내에서 문제의 규칙이 위치하는 곳은 무작위로 지정되었습니다.

컴파일 질문에 대한 GuaranteedRAG: 각 컴파일 질문에 대한 정답은 규칙 번호 목록입니다.

각 컴파일 문제에 대해, 규칙 문서에서 각 정답 규칙의 텍스트를 추출했습니다. 추출한 규칙 텍스트의 총합이 8716자 미만인 경우, 8716자에 도달할 때까지 다른 규칙을 무작위로 추가했습니다. 반대로, 추가하기 전에 정답 규칙 텍스트의 총합이 8716자를 초과하는 경우, 8716자 제한에 도달할 때까지 목록에서 가장 긴 규칙을 반복적으로 제거했습니다. 규칙 텍스트는 (추가하기 전에) 무작위로 섞어서 특정 순서 없이 제시되도록 했습니다.

정의 및 존재 여부 질문에 대한 GuaranteedRAG: 섹션 3.1.3에서 설명했듯이, 각 정의 및 존재 여부 질문은 모델이 차량 구성 요소를 얼마나 잘 이해하고 있는지를 테스트합니다. 구성 요소는 다음과 같습니다. 1) 규칙 문서의 정의 섹션에 명시적으로 언급된 구성 요소("정의 구성 요소"), 2) 문서 전체에 걸쳐 여러 번 언급되었지만 정의 섹션에 명시적으로 언급되지 않은 구성 요소("다중 언급 구성 요소"), 또는 3) 규칙 문서에 전혀 언급되지 않은 구성 요소("언급되지 않은 구성 요소"). 각 정의 또는 존재 여부 질문에 대해 구성 요소의 언급 유형에 따라 GuaranteedRAG를 생성합니다. 정의의 경우

구성 요소 관련 질문의 경우, 규칙 문서에서 두 개의 "정의" 섹션을 추출하여 규칙 텍스트의 다른 두 개의 무작위로 선택된 부분 사이에 배치합니다. 이때 추출된 텍스트의 총 길이는 8716자입니다. 구성 요소가 여러 번 언급된 질문의 경우, 규칙 문서 내에서 해당 구성 요소가 언급된 모든 부분을 찾습니다. 각 언급에 대해, 해당 언급이 발제문의 중앙에 오도록 규칙 문서에서 일정한 길이의 텍스트 발제문을 추출합니다. 이 텍스트 발제문들을 합치면 총 길이는 8716자가 됩니다. 구성 요소가 언급되지 않은 질문의 경우, 규칙 문서에서 8716자 길이의 부분을 무작위로 선택합니다.

차수 및 기능 성능 질문에 대한 보장된 RAG: 각 질문은 모델에게 설계가 특정 규칙 번호를 준수하는지 여부를 묻습니다. 각 질문에 대해 규칙집에서 8716자 분량의 텍스트가 추출되었습니다. 이 부분에는 해당 규칙의 텍스트가 포함되어 있음이 보장되며, 추출된 텍스트 내에서 해당 규칙의 위치는 무작위로 지정됩니다. 경우에 따라 해당 규칙이 FSAE 규칙 문서의 다른 규칙을 참조할 수 있습니다. 이러한 경우, 보장된 RAG는 두 개의 동일한 부분으로 나누어 합쳐져 완전한 8716자 분량의 RAG를 구성합니다. 첫 번째 부분은 해당 규칙의 텍스트(임의의 위치)를 포함하고, 두 번째 부분은 참조된 규칙의 텍스트(임의의 위치)를 포함하고 있음이 보장됩니다.

8https://github.com/run-llama/llama_index/blob/main/llama-index-core/llama_index/core/constants.py
9규칙 준수 질문을 제외한 대부분의 질문에 대해 간단한 LlamaIndex RAG를 생성할 때, 가장 관련성이 높은 상위 15개 문서 덩어리를 사용했습니다. 이 상위 15개 덩어리의 평균 문자 수는 10,895자였습니다. 처음에는 GuaranteedRAG에 대해 10,895자 길이의 발제문을 생성하려고 시도했지만, 이러한 컨텍스트와 프롬프트가 결합될 때 LLaVA의 토큰 제한을 초과하는 경우가 많았습니다. 이는 문자 수와 토큰 수의 차이 때문이었습니다. 토큰 제한에 걸리지 않도록 모든 질문에 대해 GuaranteedRAG 컨텍스트 길이를 8,716자로 줄였습니다. 8,716자는 간단한 LlamaIndex RAG 구현에서 가장 관련성이 높은 상위 12개 문서 덩어리의 평균 길이에 해당합니다.